



超级畅销书全新升级，第1版两年内重印近10次，Java图书领域公认的经典著作，
繁体版台湾发行

基于最新JDK 1.7，围绕内存管理、执行子系统、程序编译与优化、高效并发等核心主题对JVM进行全面而深入的分析，深刻揭示JVM的工作原理

以实践为导向，通过大量与实际生产环境相结合的案例展示了解决各种常见JVM问题的技巧和最佳实践

华章 精品
创造未来

第2版

深入理解 Java 虚拟机

JVM高级特性与最佳实践

Understanding the JVM

Advanced Features and Best Practices, Second Edition

周志明 著

本书由“行行”整理，如果你不知道读什么书或者想获得更多免费电子书请加小编微信或QQ：491256034 小编也和结交一些喜欢读书的朋友 或者关注小编个人微信公众号id：d716-716 为了方便书友朋友找书和看书，小编自己做了一个电子书下载网站，网站的名称为：周读
网址：<http://www.ireadweek.com>

深入理解Java虚拟机

——JVM高级特性与最佳实践

周志明 著

ISBN：978-7-111-42190-0

本书纸版由机械工业出版社于2013年出版，电子版由华章分社（北京华章图文信息有限公司）全球范围内制作与发行。

版权所有，侵权必究

客服热线：+ 86-10-68995265

客服信箱：service@bbbvip.com

官方网址：www.hzmedia.com.cn

新浪微博 @研发书局

腾讯微博 @yanfabook

目 录

前言

第2版与第1版的区别

本书面向的读者

如何阅读本书

语言约定

内容特色

参考资料

勘误和支持

致谢

第一部分 走近Java

第1章 走近Java

1.1 概述

1.2 Java技术体系

1.3 Java发展史

1.4 Java虚拟机发展史

1.4.1 Sun Classic/Exact VM

1.4.2 Sun HotSpot VM

1.4.3 Sun Mobile-Embedded VM/Meta-Circular VM

1.4.4 BEA JRockit/IBM J9 VM

1.4.5 Azul VM/BEA Liquid VM

1.4.6 Apache Harmony/Google Android Dalvik VM

1.4.7 Microsoft JVM及其他

1.5 展望Java技术的未来

1.5.1 模块化

1.5.2 混合语言

1.5.3 多核并行

1.5.4 进一步丰富语法

1.5.5 64位虚拟机

1.6 实战：自己编译JDK

1.6.1 获取JDK源码

1.6.2 系统需求

1.6.3 构建编译环境

1.6.4 进行编译

1.6.5 在IDE工具中进行源码调试

1.7 本章小结

第二部分 自动内存管理机制

第2章 Java内存区域与内存溢出异常

2.1 概述

2.2 运行时数据区域

2.2.1 程序计数器

2.2.2 Java虚拟机栈

2.2.3 本地方法栈

2.2.4 Java堆

2.2.5 方法区

2.2.6 运行时常量池

2.2.7 直接内存

2.3 HotSpot虚拟机对象探秘

2.3.1 对象的创建

2.3.2 对象的内存布局

2.3.3 对象的访问定位

2.4 实战：OutOfMemoryError异常

2.4.1 Java堆溢出

2.4.2 虚拟机栈和本地方法栈溢出

2.4.3 方法区和运行时常量池溢出

2.4.4 本机直接内存溢出

2.5 本章小结

第3章 垃圾收集器与内存分配策略

3.1 概述

3.2 对象已死吗

3.2.1 引用计数算法

3.2.2 可达性分析算法

3.2.3 再谈引用

3.2.4 生存还是死亡

3.2.5 回收方法区

3.3 垃圾收集算法

3.3.1 标记-清除算法

3.3.2 复制算法

3.3.3 标记-整理算法

3.3.4 分代收集算法

3.4 HotSpot的算法实现

3.4.1 枚举根节点

3.4.2 安全点

3.4.3 安全区域

3.5 垃圾收集器

3.5.1 Serial收集器

3.5.2 ParNew收集器

3.5.3 Parallel Scavenge收集器

3.5.4 Serial Old收集器

3.5.5 Parallel Old收集器

3.5.6 CMS收集器

3.5.7 G1收集器

3.5.8 理解GC日志

3.5.9 垃圾收集器参数总结

3.6 内存分配与回收策略

3.6.1 对象优先在Eden分配

3.6.2 大对象直接进入老年代

3.6.3 长期存活的对象将进入老年代

3.6.4 动态对象年龄判定

3.6.5 空间分配担保

3.7 本章小结

第4章 虚拟机性能监控与故障处理工具

4.1 概述

4.2 JDK的命令行工具

4.2.1 jps: 虚拟机进程状况工具

4.2.2 jstat: 虚拟机统计信息监视工具

4.2.3 jinfo: Java配置信息工具

4.2.4 jmap: Java内存映像工具

4.2.5 jhat: 虚拟机堆转储快照分析工具

4.2.6 jstack: Java堆栈跟踪工具

4.2.7 HSDIS: JIT生成代码反汇编

4.3 JDK的可视化工具

4.3.1 JConsole: Java监视与管理控制台

4.3.2 VisualVM：多合一故障处理工具

4.4 本章小结

第5章 调优案例分析与实战

5.1 概述

5.2 案例分析

5.2.1 高性能硬件上的程序部署策略

5.2.2 集群间同步导致的内存溢出

5.2.3 堆外内存导致的溢出错误

5.2.4 外部命令导致系统缓慢

5.2.5 服务器JVM进程崩溃

5.2.6 不恰当数据结构导致内存占用过大

5.2.7 由Windows虚拟内存导致的长时间停顿

5.3 实战：Eclipse运行速度调优

5.3.1 调优前的程序运行状态

- 5.3.2 升级JDK 1.6的性能变化及兼容问题
- 5.3.3 编译时间和类加载时间的优化
- 5.3.4 调整内存设置控制垃圾收集频率
- 5.3.5 选择收集器降低延迟

5.4 本章小结

第三部分 虚拟机执行子系统

第6章 类文件结构

- 6.1 概述
- 6.2 无关性的基石
- 6.3 Class类文件的结构
 - 6.3.1 魔数与Class文件的版本
 - 6.3.2 常量池
 - 6.3.3 访问标志
 - 6.3.4 类索引、父类索引与接口索引集合
 - 6.3.5 字段表集合

6.3.6 方法表集合

6.3.7 属性表集合

6.4 字节码指令简介

6.4.1 字节码与数据类型

6.4.2 加载和存储指令

6.4.3 运算指令

6.4.4 类型转换指令

6.4.5 对象创建与访问指令

6.4.6 操作数栈管理指令

6.4.7 控制转移指令

6.4.8 方法调用和返回指令

6.4.9 异常处理指令

6.4.10 同步指令

6.5 公有设计和私有实现

6.6 Class文件结构的发展

6.7 本章小结

第7章 虚拟机类加载机制

7.1 概述

7.2 类加载的时机

7.3 类加载的过程

7.3.1 加载

7.3.2 验证

7.3.3 准备

7.3.4 解析

7.3.5 初始化

7.4 类加载器

7.4.1 类与类加载器

7.4.2 双亲委派模型

7.4.3 破坏双亲委派模型

7.5 本章小结

第8章 虚拟机字节码执行引擎

8.1 概述

8.2 运行时栈帧结构

8.2.1 局部变量表

8.2.2 操作数栈

8.2.3 动态连接

8.2.4 方法返回地址

8.2.5 附加信息

8.3 方法调用

8.3.1 解析

8.3.2 分派

8.3.3 动态类型语言支持

8.4 基于栈的字节码解释执行引擎

8.4.1 解释执行

8.4.2 基于栈的指令集与基于寄存器的指

令集

8.4.3 基于栈的解释器执行过程

8.5 本章小结

第9章 类加载及执行子系统的案例与实战

9.1 概述

9.2 案例分析

9.2.1 Tomcat：正统的类加载器架构

9.2.2 OSGi：灵活的类加载器架构

9.2.3 字节码生成技术与动态代理的实现

9.2.4 Retrotranslator：跨越JDK版本

9.3 实战：自己动手实现远程执行功能

9.3.1 目标

9.3.2 思路

9.3.3 实现

9.3.4 验证

9.4 本章小结

第四部分 程序编译与代码优化

第10章 早期（编译期）优化

10.1 概述

10.2 Javac编译器

10.2.1 Javac的源码与调试

10.2.2 解析与填充符号表

10.2.3 注解处理器

10.2.4 语义分析与字节码生成

10.3 Java语法糖的味道

10.3.1 泛型与类型擦除

10.3.2 自动装箱、拆箱与遍历循环

10.3.3 条件编译

10.4 实战：插入式注解处理器

10.4.1 实战目标

10.4.2 代码实现

10.4.3 运行与测试

10.4.4 其他应用案例

10.5 本章小结

第11章 晚期（运行期）优化

11.1 概述

11.2 HotSpot虚拟机内的即时编译器

11.2.1 解释器与编译器

11.2.2 编译对象与触发条件

11.2.3 编译过程

11.2.4 查看及分析即时编译结果

11.3 编译优化技术

11.3.1 优化技术概览

11.3.2 公共子表达式消除

11.3.3 数组边界检查消除

11.3.4 方法内联

11.3.5 逃逸分析

11.4 Java与C/C++的编译器对比

11.5 本章小结

第五部分 高效并发

第12章 Java内存模型与线程

12.1 概述

12.2 硬件的效率与一致性

12.3 Java内存模型

12.3.1 主内存与工作内存

12.3.2 内存间交互操作

12.3.3 对于volatile型变量的特殊规则

12.3.4 对于long和double型变量的特殊规则

12.3.5 原子性、可见性与有序性

12.3.6 先行发生原则

12.4 Java与线程

12.4.1 线程的实现

12.4.2 Java线程调度

12.4.3 状态转换

12.5 本章小结

第13章 线程安全与锁优化

13.1 概述

13.2 线程安全

13.2.1 Java语言中的线程安全

13.2.2 线程安全的实现方法

13.3 锁优化

13.3.1 自旋锁与自适应自旋

13.3.2 锁消除

13.3.3 锁粗化

13.3.4 轻量级锁

13.3.5 偏向锁

13.4 本章小结

附录

附录A 编译Windows版的OpenJDK

A.1 获取JDK源码

A.2 系统需求

A.3 构建编译环境

A.4 准备依赖项

A.5 进行编译

附录B 虚拟机字节码指令表

附录C HotSpot虚拟机主要参数表

C.1 内存管理参数

C.2 即时编译参数

C.3 类型加载参数

C.4 多线程相关参数

C.5 性能参数

C.6 调试参数

附录D 对象查询语言（OQL）简介

D.1 SELECT子句

D.2 FROM子句

D.3 WHERE子句

D.4 属性访问器

D.5 OQL语言的BNF范式

附录E JDK历史版本轨迹

前言

Java是目前用户最多、使用范围最广的软件开发技术之一。Java的技术体系主要由支撑Java程序运行的虚拟机、提供各开发领域接口支持的Java API、Java编程语言及许多第三方Java框架（如Spring、Struts等）构成。在国内，有关Java API、Java语言语法及第三方框架的技术资料和书籍非常丰富，相比之下，有关Java虚拟机的资料却显得异常贫乏。

这种状况在很大程度上是由Java开发技术本身的一个重要优点导致的：在虚拟机层面隐藏了底层技术的复杂性以及机器与操作系统的差异性。运行程序的物理机器的情况千差万别，而

Java虚拟机则在千差万别的物理机上建立了统一的运行平台，实现了在任意一台虚拟机上编译的程序都能在任何一台虚拟机上正常运行。这一极大优势使得Java应用的开发比传统C/C++应用的开发更高效和快捷，程序员可以把主要精力集中在具体业务逻辑上，而不是物理硬件的兼容性上。在一般情况下，一个程序员只要了解了必要的Java API、Java语法，以及学习适当的第三方开发框架，就已经基本能满足日常开发的需要了，虚拟机会在用户不知不觉中完成对硬件平台的兼容及对内存等资源的管理工作。因此，了解虚拟机的运作并不是一般开发人员必须掌握的知识。

然而，凡事都具备两面性。随着Java技术的不断发展，它被应用于越来越多的领域之中。其

中一些领域，如电力、金融、通信等，对程序的性能、稳定性和可扩展性方面都有极高的要求。程序很可能在10个人同时使用时完全正常，但是在10000个人同时使用时就会缓慢、死锁，甚至崩溃。毫无疑问，要满足10000个人同时使用需要更高性能的物理硬件，但是在绝大多数情况下，提升硬件效能无法等比例地提升程序的运作性能和并发能力，甚至可能对程序运作状况完全没有任何改善。这里面有Java虚拟机的原因：为了达到给所有硬件提供一致的虚拟平台的目的，牺牲了一些与硬件相关的性能特性。更重要的是人为原因：如果开发人员不了解虚拟机一些技术特性的运行原理，就无法写出最适合虚拟机运行和自优化的代码。

其实，目前商用的高性能Java虚拟机都提供

了相当多的优化特性和调节手段，用于满足应用程序在实际生产环境中对性能和稳定性的要求。如果只是为了入门学习，让程序在自己的机器上正常运行，那么这些特性可以说是可有可无的；如果用于生产开发，尤其是企业级生产开发，就迫切需要开发人员中至少有一部分人对虚拟机的特性及调节方法具有很清晰的认识，所以在Java开发体系中，对架构师、系统调优师、高级程序员等角色的需求一直都非常大。学习虚拟机中各种自动运作特性的原理也成为了Java程序员成长道路上必然会接触到的一课。本书可以使读者以一种相对轻松的方式学习虚拟机的运作原理，对Java程序员的成长也有较大的帮助。

第2版与第1版的区别

JDK 1.7在2011年7月28日正式发布，相对于2006年发布的JDK 1.6，新版的JDK有了许多新的特性和改进。本书的第2版也相应地进行了修改和升级，把讲解的技术平台从JDK 1.6提升至JDK 1.7。例如，增加了对JDK 1.7中最新的G1收集器，以及JDK 1.7中JSR-292 InvokeDynamic（对非Java语言的调用支持）的分析讲解等内容。

在第1版出版后，笔者收到了许多热心读者的反馈意见，部分读者提出OpenJDK开源已久，第1版却很少有直接分析OpenJDK源码的内容，有点“视宝山而不见”的感觉。因此，在本书第2版中，笔者特别加强了对这部分内容的讲解，其中在第1章中就介绍了如何分析、调试OpenJDK

源码等。在本书后续章节中，不少关于功能点的讲解都直接使用OpenJDK中的HotSpot源码或者JIT编译器生成的本地代码作为论据。

如何把Java虚拟机原理中许多理论性很强的知识、特性应用于实践开发，是本书贯穿始终的主旨。由于笔者希望在本书第2版中进一步加强知识的实践性，因此增加了许多对处理JVM常见问题技能的讲解，包括如何分析GC日志、如何分析JIT编译器代码优化过程和生成代码等。并且，在第1版的基础上，第2版中进一步增加了若干处理JVM问题的实践案例供读者参考。

另外，本书第2版还修正了第1版中多处错误的、有歧义的和不完整的描述。有关勘误信息，可以参考第1版的勘误页面

(<http://icyfenix.iteye.com/blog/1119214>）。

本书面向的读者

(1) 使用Java技术体系的中、高级开发人员

Java虚拟机作为中、高级开发人员必须修炼的知识，有着较高的学习门槛，本书可作为学习虚拟机的优秀教材。

(2) 系统调优师

系统调优师是近几年才兴起的职业，本书中的大量案例、代码和调优实战将会对系统调优师的日常工作有直接的帮助。

(3) 系统架构师

保障系统的性能、并发和伸缩等能力是系统

架构师的主要职责之一，而这部分与虚拟机的运作密不可分，本书可以作为他们制定应用系统底层框架的参考资料。

如何阅读本书

本书一共分为五个部分：走近Java、自动内存管理机制、虚拟机执行子系统、程序编译与代码优化、高效并发。各部分基本上是互相独立的，没有必要必然的前后依赖关系，读者可以从任何一个感兴趣的专题开始阅读，但是每个部分中的各个章节间有先后顺序。

本书并没有假设读者在Java领域具备很专业的技术水平，因此在保证逻辑准确的前提下，尽量用通俗的语言和案例讲述虚拟机中与开发的关系最为密切的内容。当然，学习虚拟机技术本身就需要读者有一定的基础，且本书的读者定位是中、高级程序员，因此本书假设读者自己了解一

些常用的开发框架、Java API和Java语法等基础知识。

笔者希望读者在阅读本书的同时，把本书中的实践内容亲自验证一遍，其中用到的代码清单可以从华章网站（<http://www.hzbook.com>）下载。

语言约定

本书在语言和技术上有如下约定：

本书中提到HotSpot、JRockit虚拟机、WebLogic服务器等产品的所有者时，仍然使用Sun和BEA公司的名称，实际上，BEA和Sun分别于2008年和2009年被Oracle公司收购，现在已经不存在这两个商标了，但毫无疑问的是，它们都

是在Java领域中做出过卓越贡献的、值得程序员纪念的公司。

JDK从1.5版本开始，在官方的正式文档与宣传资料中已经不再使用类似“JDK 1.5”的名称，只有程序员内部使用的开发版本号（Developer Version，例如`java-version`的输出）才继续沿用1.5、1.6和1.7的版本号，而公开版本号（Product Version）则改为JDK 5、JDK 6和JDK 7的命名方式，为了行文一致，本书所有场合统一采用开发版本号的命名方式。

由于版面关系，本书中的许多示例代码都没有遵循最优的代码编写风格，如使用的流没有关闭流等，请读者在阅读时注意这一点。

如果没有特殊说明，本书中所有讨论都是以

Sun JDK 1.7为技术平台的。不过如果有某个特性在各个版本间的变化较大，一般都会说明它在各个版本间的差异。

内容特色

第一部分 走近Java

本书的第一部分为后文的讲解建立了良好的基础。尽管了解Java技术的来龙去脉，以及编译自己的OpenJDK对于读者理解Java虚拟机并不是必需的，但是这些准备过程可以为走近Java技术和Java虚拟机提供很好的引导。第一部分只有第1章：

第1章 介绍了Java技术体系的过去、现在和未来的一些发展趋势，并介绍了如何独立地编译一个OpenJDK 7。

第二部分 自动内存管理机制

因为程序员把内存控制的权力交给了Java虚拟机，所以可以在编码的时候享受自动内存管理的诸多优势，不过也正是这个原因，一旦出现内存泄漏和溢出方面的问题，如果不了解虚拟机是怎样使用内存的，那么排查错误将会成为一项异常艰难的工作。第二部分包括第2~5章：

第2章 讲解了虚拟机中内存是如何划分的，以及哪部分区域、什么样的代码和操作可能导致内存溢出异常，并讲解了各个区域出现内存溢出异常的常见原因。

第3章 分析了垃圾收集的算法和JDK 1.7中提供的几款垃圾收集器的特点及运作原理。通过代码实例验证了Java虚拟机中自动内存分配及回收的主要规则。

第4章 介绍了随JDK发布的6个命令行工具与两个可视化的故障处理工具的使用方法。

第5章 与读者分享了几个比较有代表性的实际案例，还准备了一个所有开发人员都能“亲身实战”的练习，读者可通过实践来获得故障处理和调优的经验。

第三部分 虚拟机执行子系统

执行子系统是虚拟机中必不可少的组成部分，了解了虚拟机如何执行程序，才能写出更优秀的代码。第三部分包括第6~9章：

第6章 讲解了Class文件结构中的各个组成部分，以及每个部分的定义、数据结构和使用方法，以实战的方式演示了Class文件的数据是如何

存储和访问的。

第7章 介绍了类加载过程的“加载”、“验证”、“准备”、“解析”和“初始化”5个阶段中虚拟机分别执行了哪些动作，还介绍了类加载器的工作原理及其对虚拟机的意义。

第8章 分析了虚拟机在执行代码时如何找到正确的方法，如何执行方法内的字节码，以及执行代码时涉及的内存结构。

第9章 通过4个类加载及执行子系统的案例，分享了使用类加载器和处理字节码的一些值得欣赏和借鉴的思路，并通过一个实战练习来加深对前面理论知识的理解。

第四部分 程序编译与代码优化

Java程序从源码编译成字节码和从字节码编译成本地机器码的这两个过程，合并起来其实就等同于一个传统编译器所执行的编译过程。第四部分包括第10~11章：

第10章 分析了Java语言中泛型、主动装箱和拆箱、条件编译等多种语法糖的前因后果，并通过实战演示了如何使用插入式注解处理器来实现一个检查程序命名规范的编译器插件。

第11章 讲解了虚拟机的热点探测方法、HotSpot的即时编译器、编译触发条件，以及如何从虚拟机外部观察和分析JIT编译的数据和结果，此外，还讲解了几种常见的编译优化技术。

第五部分 高效并发

Java语言和虚拟机提供了原生的、完善的多线程支持，这使得它天生就适合开发多线程并发的应用程序。不过我们不能期望系统来完成所有并发相关的处理，了解并发的内幕也是成为一个高级程序员不可缺少的课程。第五部分包括第12～13章：

第12章 讲解了虚拟机Java内存模型的结构及操作，以及原子性、可见性和有序性在Java内存模型中的体现，介绍了先行发生原则的规则及使用，还了解了线程在Java语言中是如何实现的。

第13章 介绍了线程安全涉及的概念和分类、同步实现的方式及虚拟机的底层运作原理，并且介绍了虚拟机实现高效并发所采取的一系列

锁优化措施。

参考资料

本书名为“深入理解Java虚拟机”，但要想深入理解虚拟机，仅凭一本书肯定是远远不够的，读者可以通过以下信息找到更多关于Java虚拟机方面的资料。我在写作此书的时候，也从下面这些参考资料中获得了很大的帮助。

(1) 书籍

《The Java Virtual Machine Specification, Java SE 7 Edition》[\[1\]](#)

要学习虚拟机，无论如何都必须掌握“Java虚拟机规范”。这本书的概念和细节描述与Sun的早期虚拟机（Sun Classic VM）高度吻合，不过，

随着技术的发展，高性能虚拟机真正的细节实现方式已经渐渐与虚拟机规范所描述的差距越来越大，如果只能选择一本参考书来了解虚拟机，那我推荐这本书。此书的Java SE 7版在2011年7月出版发行，这是自1999年发布的《Java虚拟机规范（第2版）》以来的第一次版本更新。笔者对Java SE 7版的全文进行了翻译，并与原书一样在网上免费发布了全文PDF^[2]。

《The Java Language Specification,Java SE 7 Edition》^[3]

虽然虚拟机并不是Java语言专有的，但是了解Java语言的各种细节规定对理解虚拟机的行为也是很有帮助的，它与上一本《Java虚拟机规范》都是Sun官方出品的书籍，而且这本书还是

由Java之父James Gosling亲自执笔撰写的。这本书也与《Java虚拟机规范》一样，可以在官方网站完全免费下载到全文PDF，但暂时没有中文译本，《Java语言规范（第3版）》于2005年7月由机械工业出版社引进出版。

《Oracle JRockit The Definitive Guide》

《Oracle JRockit权威指南》，2010年7月出版，国内也没有（可能是尚未）引进这本书，它是由JRockit的两位资深开发人员（其中一位还是JRockit Mission Control团队的TeamLeader）撰写的JRockit虚拟机高级使用指南。虽然JRockit的用户量可能不如HotSpot多，但也是目前最流行的三大商业虚拟机之一，并且不同虚拟机中的很多实现思路都是可以对比参照的。这本书是了解现代

高性能虚拟机很好的参考资料。

《Inside the Java 2 Virtual Machine,Second Edition》

《深入Java虚拟机（第2版）》，2000年1月出版，2003年由机械工业出版社出版其中文译本。在相当长的时间里，这本书是唯一的一本关于Java虚拟机的中文图书。

《Java Performance》

《Java Performance》是“The Java”系列（许多人都读过该系列中最出名的《Effective Java》）图书中最新的一本，2011年10月出版，暂时没有中文版。这本书并非全部都围绕Java虚拟机（只有第3、4、7章直接与Java虚拟机相

关），而是从操作系统到基于Java的上层程序性能度量和调优的全面介绍，其中涉及Java虚拟机的内容具备一定的深度和可实践性。

（2）网站资源

高级语言虚拟机圈子：

<http://hllvm.group.iteye.com/>

里面有一些国内关于虚拟机的讨论，并不只限于JVM，而是涉及对所有的高级语言虚拟机（High-Level Language Virtual Machine）的讨论，但该网站建立在ITEye上，自然还是以讨论Java虚拟机为主。圈主RednaxelaFX（莫枢）的博客（<http://rednaxelafx.iteye.com/>）是另外一个非常有价值的虚拟机及编译原理等资料的分享园地。

HotSpot Internals:

<https://wikis.oracle.com/display/HotSpotInternals/Home>

一个关于OpenJDK的Wiki网站，许多文章都由JDK的开发团队编写，更新较慢，但是仍然有很高的参考价值。

The HotSpot Group:

<http://openjdk.java.net/groups/hotspot/>

HotSpot组群，包含虚拟机开发、编译器、垃圾收集和运行时4个邮件组，其中有关于HotSpot虚拟机的最新讨论。

[1] 官方地址：

<http://docs.oracle.com/javase/specs/jvms/se7/jvms7.pdf>

[2] 官方地址：

[http://docs.oracle.com/javase/specs/jls/se7/jls7.pdf。](http://docs.oracle.com/javase/specs/jls/se7/jls7.pdf)

[3] 中文译本地址：

<http://icyfenix.iteye.com/blog/1256329。>

勘误和支持

在本书交稿的时候，我并不像想象中的那样兴奋或放松，写作之时那种“战战兢兢、如履薄冰”的感觉依然萦绕在心头。在每一章、每一节落笔之时，我都在考虑如何才能把各个知识点更有条理地讲述出来，同时也在担心会不会由于自己理解有偏差而误导了读者。由于写作水平和写作时间所限，书中难免存在不妥之处，所以特地开通了一个读者邮箱

（understandingjvm@gmail.com）与大家交流，大家如有任何意见或建议欢迎与我联系。相信写书与写程序一样，作品一定都是不完美的，因为不完美，我们才有不断追求完美的动力。

本书第2版的勘误，将会在作者的博客
(<http://icyfenix.iteye.com/>) 中发布。欢迎读者在
博客上留言。

致谢

首先要感谢我的家人，在本书写作期间全靠他们对我的悉心照顾，才让我能够全身心地投入到写作之中，而无后顾之忧。

同时要感谢我的工作单位远光软件，公司为我提供了宝贵的工作、学习和实践的环境，书中的许多知识点都来自于工作中的实践；也感谢与我一起工作的同事们，非常荣幸能与你们一起在这个富有激情的团队中共同奋斗。

还要感谢Oracle公司虚拟机团队的莫枢，在百忙之中抽空审阅了本书，提出了许多宝贵的建议和意见。

最后，感谢机械工业出版社华章公司的编辑，本书能够顺利出版离不开他们的敬业精神和一丝不苟的工作态度。

周志明

第一部分 走近Java

第1章 走近Java

第1章 走近Java

世界上并没有完美的程序，但我们并不因此而沮丧，因为写程序本来就是一个不断追求完美的过程。

1.1 概述

Java不仅仅是一门编程语言，还是一个由一系列计算机软件和规范形成的技术体系，这个技术体系提供了完整的用于软件开发和跨平台部署的支持环境，并广泛应用于嵌入式系统、移动终端、企业服务器、大型机等各种场合，如图1-1所示。时至今日，Java技术体系已经吸引了900多万软件开发者，这是全球最大的软件开发团队。使用Java的设备多达几十亿台，其中包括11亿多台

个人计算机、30亿部移动电话及其他手持设备、数量众多的智能卡，以及大量机顶盒、导航系统和其他设备^[1]。



图 1-1 Java技术的广泛应用

Java能获得如此广泛的认可，除了它拥有一门结构严谨、面向对象的编程语言之外，还有许多不可忽视的优点：它摆脱了硬件平台的束缚，

实现了“一次编写，到处运行”的理想；它提供了一个相对安全的内存管理和访问机制，避免了绝大部分的内存泄露和指针越界问题；它实现了热点代码检测和运行时编译及优化，这使得Java应用能随着运行时间的增加而获得更高的性能；它有一套完善的应用程序接口，还有无数来自商业机构和开源社区的第三方类库来帮助它实现各种各样的功能……Java所带来的这些好处使程序的开发效率得到了很大的提升。作为一名Java程序员，在编写程序时除了尽情发挥Java的各种优势外，还应该去了解和思考一下Java技术体系中这些技术特性是如何实现的。认识这些技术运作的本质，是自己思考“程序这样写好不好”的基础和前提。当我们在使用一种技术时，如果不再依赖书本和他人就能得到这些问题的答案，那才算上

升到了“不惑”的境界。

本书将与读者一起分析Java技术中最重要的那些特性的实现原理。在本章中，我们将重点介绍Java技术体系内容以及Java的历史、现在和未来的发展趋势。

[1]这些数据是Java的广告词，它们来源于：

[http://www.java.com/zh_CN/about/。](http://www.java.com/zh_CN/about/)

1.2 Java技术体系

从广义上讲，Clojure、JRuby、Groovy等运行于Java虚拟机上的语言及其相关的程序都属于Java技术体系中的一员。如果仅从传统意义上来看，Sun官方所定义的Java技术体系包括以下几个组成部分：

Java程序设计语言

各种硬件平台上的Java虚拟机

Class文件格式

Java API类库

来自商业机构和开源社区的第三方Java类库

我们可以把Java程序设计语言、Java虚拟机、Java API类库这三部分统称为JDK（Java Development Kit），JDK是用于支持Java程序开发的最小环境，在后面的内容中，为了讲解方便，有一些地方会以JDK来代替整个Java技术体系。另外，可以把Java API类库中的Java SE API子集^[1]和Java虚拟机这两部分统称为JRE（Java Runtime Environment），JRE是支持Java程序运行的标准环境。图1-2展示了Java技术体系所包含的内容，以及JDK和JRE所涵盖的范围。

| Java语言 | | Java Language | | | | | |
|-----------------------------------|----------------|---------------------|---------------|-----------------------|-----------|--------------------|-----------------|
| 工具及 工具API | java | javac | javadoc | jar | javap | JPDA | |
| | JConsole | Java VisualVM | Java DB | Security | Int'l | RMI | |
| 程序部署发布 | IDL | Deploy | Monitoring | Troubleshoot | Scripting | JVM TI | Web Services |
| | Java Web Start | | | Applet / Java Plug-in | | | |
| JDK | JavaFX | | | | | | |
| | Swing | | Java 2D | | AWT | Accessibility | |
| JRE | Drag and Drop | | Input Methods | | Image I/O | Print Service | Sound |
| | IDL | JDBC | JNDI | RMI | RMI-IIOP | | Scripting |
| 其他基础库 | Beans | Int'l Support | | Input/Output | | JMX | |
| | JNI | Math | | Networking | | Override Mechanism | |
| 语言和工具 基础库 | Security | Serialization | | Extension Mechanism | | XML JAXP | |
| | lang and util | Collections | | Concurrency Utilities | | JAR | |
| Java虚拟机 | Logging | Management | | Preferences API | | Ref Objects | |
| | Reflection | Regular Expressions | | Versioning | | Zip | Instrumentation |
| Java HotSpot Client and Server VM | | | | | | | |

Java SE API

图 1-2 Java技术体系所包含的内容^[2]

以上是根据各个组成部分的功能来进行划分的，如果说按照技术所服务的领域来划分，或者说按照Java技术关注的重点业务领域来划分，Java技术体系可以分为4个平台，分别为：

Java Card：支持一些Java小程序（Applets）运行在小内存设备（如智能卡）上的平台。

Java ME (Micro Edition) : 支持Java程序运行在移动终端（手机、PDA）上的平台，对Java API有所精简，并加入了针对移动终端的支持，这个版本以前称为J2ME。

Java SE (Standard Edition) : 支持面向桌面级应用（如Windows下的应用程序）的Java平台，提供了完整的Java核心API，这个版本以前称为J2SE。

Java EE (Enterprise Edition) : 支持使用多层架构的企业应用（如ERP、CRM应用）的Java平台，除了提供Java SE API外，还对其做了大量的扩充^[3]并提供了相关的部署支持，这个版本以前称为J2EE。

[http://download.oracle.com/javase/7/docs/api/。](http://download.oracle.com/javase/7/docs/api/)

[2] 图片来源：

[http://download.oracle.com/javase/7/docs/。](http://download.oracle.com/javase/7/docs/)

[3] 这些扩展一般以javax.*作为包名，而以java.*为包名的包都是Java SE API的核心包，但由于历史原因，一部分曾经是扩展包的API后来进入了核心包，因此核心包中也包含了不少javax.*的包名。

1.3 Java发展史

从第一个Java版本诞生到现在已经有18年的时间了。沧海桑田一瞬间，转眼18年过去了，在图1-3所展示的时间线中，我们看到JDK已经发展到了1.7版。在这18年里还诞生了无数和Java相关的产品、技术和标准。现在让我们走入时间隧道，从孕育Java语言的时代开始，再来看看一下Java的发展轨迹和历史变迁。




图 1-3 Java技术发展的时间线

1991年4月，由James Gosling博士领导的绿色计划（Green Project）开始启动，此计划的目的是开发一种能够在各种消费性电子产品（如机顶盒、冰箱、收音机等）上运行的程序架构。这个计划的产品就是Java语言的前身：Oak（橡树）。Oak当时在消费品市场上并不算成功，但随着1995年互联网潮流的兴起，Oak迅速找到了最适合自己的市场定位并蜕变成为Java语言。

1995年5月23日，Oak语言改名为Java，并且在SunWorld大会上正式发布Java 1.0版本。Java语言第一次提出了“Write Once,Run Anywhere”的口号。

1996年1月23日，JDK 1.0发布，Java语言有

了第一个正式版本的运行环境。JDK 1.0提供了一个纯解释执行的Java虚拟机实现（Sun Classic VM）。JDK 1.0版本的代表技术包括：Java虚拟机、Applet、AWT等。

1996年4月，10个最主要的操作系统供应商申明将在其产品中嵌入Java技术。同年9月，已有大约8.3万个网页应用了Java技术来制作。在1996年5月底，Sun公司于美国旧金山举行了首届JavaOne大会，从此JavaOne成为全世界数百万Java语言开发者一年一度的技术盛会。

1997年2月19日，Sun公司发布了JDK 1.1，Java技术的一些最基础的支撑点（如JDBC等）都是在JDK 1.1版本中发布的，JDK 1.1版的技术代表有：JAR文件格式、JDBC、JavaBeans、RMI。

Java语法也有了一定的发展，如内部类（Inner Class）和反射（Reflection）都是在这个时候出现的。

直到1999年4月8日，JDK 1.1一共发布了1.1.0～1.1.8九个版本。从1.1.4之后，每个JDK版本都有一个自己的名字（工程代号），分别为：JDK 1.1.4-Sparkler（宝石）、JDK 1.1.5-Pumpkin（南瓜）、JDK 1.1.6-Abigail（阿比盖尔，女子名）、JDK 1.1.7-Brutus（布鲁图，古罗马政治家和将军）和JDK 1.1.8-Chelsea（切尔西，城市名）。

1998年12月4日，JDK迎来了一个里程碑式的版本JDK 1.2，工程代号为Playground（竞技场），Sun在这个版本中把Java技术体系拆分为3

个方向，分别是面向桌面应用开发的J2SE（Java 2 Platform,Standard Edition）、面向企业级开发的J2EE（Java 2 Platform,Enterprise Edition）和面向手机等移动终端开发的J2ME（Java 2 Platform, Micro Edition）。在这个版本中出现的代表性技术非常多，如EJB、Java Plug-in、Java IDL、Swing等，并且这个版本中Java虚拟机第一次内置了JIT（Just In Time）编译器（JDK 1.2中曾并存过3个虚拟机，Classic VM、HotSpot VM和Exact VM，其中Exact VM只在Solaris平台出现过；后面两个虚拟机都是内置JIT编译器的，而之前版本所带的Classic VM只能以外挂的形式使用JIT编译器）。在语言和API级别上，Java添加了strictfp关键字与现在Java编码之中极为常用的一系列Collections集合类。在1999年3月和7月，分

别有JDK 1.2.1和JDK 1.2.2两个小版本发布。

1999年4月27日，HotSpot虚拟机发布，HotSpot最初由一家名为“Longview Technologies”的小公司开发，因为HotSpot的优异表现，这家公司在1997年被Sun公司收购了。HotSpot虚拟机发布时是作为JDK 1.2的附加程序提供的，后来它成为了JDK 1.3及之后所有版本的Sun JDK的默认虚拟机。

2000年5月8日，工程代号为Kestrel（美洲红隼）的JDK 1.3发布，JDK 1.3相对于JDK 1.2的改进主要表现在一些类库上（如数学运算和新的Timer API等），JNDI服务从JDK 1.3开始被作为一项平台级服务提供（以前JNDI仅仅是一项扩展），使用CORBA IIOP来实现RMI的通信协议，

等等。这个版本还对Java 2D做了很多改进，提供了大量新的Java 2D API，并且新添加了JavaSound类库。JDK 1.3有1个修正版本JDK 1.3.1，工程代号为Ladybird（瓢虫），于2001年5月17日发布。

自从JDK 1.3开始，Sun维持了一个习惯：大约每隔两年发布一个JDK的主版本，以动物命名，期间发布的各个修正版本则以昆虫作为工程名称。

2002年2月13日，JDK 1.4发布，工程代号为Merlin（灰背隼）。JDK 1.4是Java真正走向成熟的一个版本，Compaq、Fujitsu、SAS、Symbian、IBM等著名公司都有参与甚至实现自己独立的JDK 1.4。哪怕是在十多年后的今天，仍然有许多主流应用（Spring、Hibernate、Struts等）能直接

运行在JDK 1.4之上，或者继续发布能运行在JDK 1.4上的版本。JDK 1.4同样发布了很多新的技术特性，如正则表达式、异常链、NIO、日志类、XML解析器和XSLT转换器等。JDK 1.4有两个后续修正版：2002年9月16日发布的工程代号为Grasshopper（蚱蜢）的JDK 1.4.1与2003年6月26日发布的工程代号为Mantis（螳螂）的JDK 1.4.2。

2002年前后还发生了一件与Java没有直接关系，但事实上对Java的发展进程影响很大的事件，那就是微软公司的.NET Framework发布了。这个无论是技术实现上还是目标用户上都与Java有很多相近之处的技术平台给Java带来了很多讨论、比较和竞争，.NET平台和Java平台之间声势浩大的孰优孰劣的论战到目前为止都在继续。

2004年9月30日，JDK 1.5^[1]发布，工程代号Tiger（老虎）。从JDK 1.2以来，Java在语法层面上的变换一直很小，而JDK 1.5在Java语法易用性上做出了非常大的改进。例如，自动装箱、泛型、动态注解、枚举、可变长参数、遍历循环（foreach循环）等语法特性都是在JDK 1.5中加入的。在虚拟机和API层面上，这个版本改进了Java的内存模型（Java Memory Model,JMM）、提供了java.util.concurrent并发包等。另外，JDK 1.5是官方声明可以支持Windows 9x平台的最后一个JDK版本。

2006年12月11日，JDK 1.6发布，工程代号Mustang（野马）。在这个版本中，Sun终结了从JDK 1.2开始已经有8年历史的J2EE、J2SE、J2ME

的命名方式，启用Java SE 6、Java EE 6、Java ME 6的命名方式。JDK 1.6的改进包括：提供动态语言支持（通过内置Mozilla JavaScript Rhino引擎实现）、提供编译API和微型HTTP服务器API等。同时，这个版本对Java虚拟机内部做了大量改进，包括锁与同步、垃圾收集、类加载等方面的算法都有相当多的改动。

在2006年11月13日的JavaOne大会上，Sun公司宣布最终会将Java开源，并在随后的一年多时间内，陆续将JDK的各个部分在GPL v2（GNU General Public License v2）协议下公开了源码，并建立了OpenJDK组织对这些源码进行独立管理。除了极少量的产权代码（Encumbered Code，这部分代码大多是Sun本身也无权限进行开源处理的）外，OpenJDK几乎包括了Sun JDK的全部

代码，OpenJDK的质量主管曾经表示，在JDK 1.7中，Sun JDK和OpenJDK除了代码文件头的版权注释之外，代码基本上完全一样，所以OpenJDK 7与Sun JDK 1.7本质上就是同一套代码库开发的产品。

JDK 1.6发布以后，由于代码复杂性的增加、JDK开源、开发JavaFX、经济危机及Sun收购案等原因，Sun在JDK发展以外的事情上耗费了很多资源，JDK的更新没有再维持两年发布一个主版本的发展速度。JDK 1.6到目前为止一共发布了37个Update版本，最新的版本为Java SE 6 Update 37，于2012年10月16日发布。

2009年2月19日，工程代号为Dolphin（海豚）的JDK 1.7完成了其第一个里程碑版本。根据

JDK 1.7的功能规划，一共设置了10个里程碑。最后一个里程碑版本原计划于2010年9月9日结束，但由于各种原因，JDK 1.7最终无法按计划完成。

从JDK 1.7最开始的功能规划来看，它本应是一个包含许多重要改进的JDK版本，其中的Lambda项目（Lambda表达式、函数式编程）、Jigsaw项目（虚拟机模块化支持）、动态语言支持、GarbageFirst收集器和Coin项目（语言细节进化）等子项目对于Java业界都会产生深远的影响。在JDK 1.7开发期间，Sun公司由于相继在技术竞争和商业竞争中都陷入泥潭，公司的股票市值跌至仅有高峰期的3%，已无力推动JDK 1.7的研发工作按正常计划进行。为了尽快结束JDK 1.7长期“跳票”的问题，Oracle公司收购Sun公司后不久便宣布将实行“B计划”，大幅裁剪了JDK 1.7

预定目标，以便保证JDK 1.7的正式版能够于2011年7月28日准时发布。“B计划”把不能按时完成的Lambda项目、Jigsaw项目和Coin项目的一部分改进延迟到JDK 1.8之中。最终，JDK 1.7的主要改进包括：提供新的G1收集器（G1在发布时依然处于Experimental状态，直至2012年4月的Update 4中才正式“转正”）、加强对非Java语言的调用支持（JSR-292，这项特性到目前为止依然没有完全实现定型）、升级类加载架构等。

到目前为止，JDK 1.7已经发布了9个Update版本，最新的Java SE 7 Update 9于2012年10月16日发布。从Java SE 7 Update 4起，Oracle开始支持Mac OS X操作系统，并在Update 6中达到完全支持的程度，同时，在Update 6中还对ARM指令集架构提供了支持。至此，官方提供的JDK可以

运行于Windows（不含Windows 9x）、Linux、Solaris和Mac OS平台上，支持ARM、x86、x64和Sparc指令集架构类型。

2009年4月20日，Oracle公司宣布正式以74亿美元的价格收购Sun公司，Java商标从此正式归Oracle所有（Java语言本身并不属于哪间公司所有，它由JCP组织进行管理，尽管JCP主要是由Sun公司或者说Oracle公司所领导的）。由于此前Oracle公司已经收购了另外一家大型的中间件企业BEA公司，在完成对Sun公司的收购之后，Oracle公司分别从BEA和Sun中取得了目前三大商业虚拟机的其中两个：JRockit和HotSpot，Oracle公司宣布在未来1~2年的时间内，将把这两个优秀的虚拟机互相取长补短，最终合二为一^[2]。可以预见在不久的将来，Java虚拟机技术将会产生相

当巨大的变化。

根据Oracle官方提供的信息，JDK 1.8的第一个正式版本将于2013年9月发布，JDK 1.8将会提供在JDK 1.7中规划过，但最终未能在JDK 1.7中发布的特性，即Lambda表达式、Jigsaw（很不幸，随后Oracle公司又宣布Jigsaw在JDK 1.8中依然无法完成，需要延至JDK 1.9）和JDK 1.7中未实现的一部分Coin等。

在2011年的JavaOne大会上，Oracle公司还提到了JDK 1.9的长远规划，希望未来的Java虚拟机能够管理数以GB计的Java堆，能够更高效地与本地代码集成，并且令Java虚拟机运行时尽可能少人工干预，能够自动调节。

[1]JDK从1.5版本开始，官方在正式文档与宣传上

已经不再使用类似JDK 1.5的命名，只有在程序员内部使用的开发版本号（Developer Version，例如java-version的输出）中才继续沿用1.5、1.6、1.7的版本号，而公开版本号（Product Version）则改为JDK 5、JDK 6、JDK 7的命名方式，本书为了行文一致，所有场合统一采用开发版本号的命名方式。

[2] “HotRockit” 项目的相关介绍：

<http://hirt.se/presentations/WhatToExpect.ppt>。

1.4 Java虚拟机发展史

上一节我们从整个Java技术的角度观察了Java技术的发展，许多Java程序员都会潜意识地把它与Sun公司的HotSpot虚拟机等同看待，也许还有一些程序员会注意到BEA JRockit和IBM J9，但对JVM的认识不仅仅只有这些。

从1996年初Sun公司发布的JDK 1.0中所包含的Sun Classic VM到今天，曾经涌现、湮灭过许多或经典或优秀或有特色的虚拟机实现，在这一节中，我们先暂且把代码与技术放下，一起来回顾一下Java虚拟机家族的发展轨迹和历史变迁。

1.4.1 Sun Classic/Exact VM

以今天的视角来看，Sun Classic VM的技术可能很原始，这款虚拟机的使命也早已终结。但仅凭它“世界上第一款商用Java虚拟机”的头衔，就足够有让历史记住它的理由。

1996年1月23日，Sun公司发布JDK 1.0，Java语言首次拥有了商用的正式运行环境，这个JDK中所带的虚拟机就是Classic VM。这款虚拟机只能使用纯解释器方式来执行Java代码，如果要使用JIT编译器，就必须进行外挂。但是假如外挂了JIT编译器，JIT编译器就完全接管了虚拟机的执行系统，解释器便不再工作了。用户在这款虚拟机上执行java-version命令，将会看到类似下面这行输出：

```
java version "1.2.2"
Classic VM (build JDK-1.2.2-001, green
```

其中的“sunwjit”就是Sun提供的外挂编译器，其他类似的外挂编译器还有Symantec JIT和shuJIT等。由于解释器和编译器不能配合工作，这就意味着如果要使用编译器执行，编译器就不得不对每一个方法、每一行代码都进行编译，而无论它们执行的频率是否具有编译的价值。基于程序响应时间的压力，这些编译器根本不敢应用编译耗时稍高的优化技术，因此这个阶段的虚拟机即使用了JIT编译器输出本地代码，执行效率也和传统的C/C++程序有很大差距，“Java语言很慢”的形象就是在这时候开始在用户心中树立起来的。

Sun的虚拟机团队努力去解决Classic VM所面临的各种问题，提升运行效率。在JDK 1.2时，曾

在Solaris平台上发布过一款名为Exact VM的虚拟机，它的执行系统已经具备现代高性能虚拟机的雏形：如两级即时编译器、编译器与解释器混合工作模式等。Exact VM因它使用准确式内存管理（Exact Memory Management，也可以叫Non-Conservative/Accurate Memory Management）而得名，即虚拟机可以知道内存中某个位置的数据具体是什么类型。譬如内存中有一个32位的整数123456，它到底是一个reference类型指向123456的内存地址还是一个数值为123456的整数，虚拟机将有能力分辨出来，这样才能在GC（垃圾收集）的时候准确判断堆上的数据是否还可能被使用。由于使用了准确式内存管理，Exact VM可以抛弃以前Classic VM基于handler的对象查找方式（原因是进行GC后对象将可能会被移动位置，如

果将地址为123456的对象移动到654321，在没有明确信息表明内存中哪些数据是reference的前提下，虚拟机是不敢把内存中所有为123456的值改成654321的，所以要使用句柄来保持reference值的稳定），这样每次定位对象都少了一次间接查找的开销，提升执行性能。

虽然Exact VM的技术相对Classic VM来说先进了许多，但是在商业应用上只存在了很短暂的时间就被更为优秀的HotSpot VM所取代，甚至还没有来得及发布Windows和Linux平台下的商用版本。而Classic VM的生命周期则相对长了许多，它在JDK 1.2之前是Sun JDK中唯一的虚拟机，在JDK 1.2时，它与HotSpot VM并存，但默认使用的是Classic VM（用户可用java-hotspot参数切换至HotSpot VM），而在JDK 1.3时，HotSpot VM成为

默认虚拟机，但Classic VM仍作为虚拟机的“备用选择”发布（使用java-classic参数切换），直到JDK 1.4的时候，Classic VM才完全退出商用虚拟机的历史舞台，与Exact VM一起进入了Sun Labs Research VM之中。

1.4.2 Sun HotSpot VM

提起HotSpot VM，相信所有Java程序员都知道，它是Sun JDK和OpenJDK中所带的虚拟机，也是目前使用范围最广的Java虚拟机。但不一定所有人都知道的是，这个目前看起来“血统纯正”的虚拟机在最初并非由Sun公司开发，而是由一家名为“Longview Technologies”的小公司设计的；甚至这个虚拟机最初并非是为Java语言而开发的，它来源于Strongtalk VM，而这款虚拟机中相当多的技术又是来源于一款支持Self语言实现“达到C语言50%以上的执行效率”的目标而设计的虚拟机，Sun公司注意到了这款虚拟机在JIT编译上有许多优秀的理念和实际效果，在1997年

收购了Longview Technologies公司，从而获得了HotSpot VM。

HotSpot VM既继承了Sun之前两款商用虚拟机的优点（如前面提到的准确式内存管理），也有许多自己新的技术优势，如它名称中的HotSpot指的就是它的热点代码探测技术（其实两个VM基本上是同时期的独立产品，HotSpot还稍早一些，HotSpot一开始就是准确式GC，而Exact VM之中也有与HotSpot几乎一样的热点探测。为了Exact VM和HotSpot VM哪个成为Sun主要支持的VM产品，在Sun公司内部还有过争论，HotSpot打败Exact并不能算技术上的胜利），HotSpot VM的热点代码探测能力可以通过执行计数器找出最具有编译价值的代码，然后通知JIT编译器以方法为单位进行编译。如果一个方法被频繁调用，或方

法中有效循环次数很多，将会分别触发标准编译和OSR（栈上替换）编译动作。通过编译器与解释器恰当地协同工作，可以在最优化的程序响应时间与最佳执行性能中取得平衡，而且无须等待本地代码输出才能执行程序，即时编译的时间压力也相对减小，这样有助于引入更多的代码优化技术，输出质量更高的本地代码。

在2006年的JavaOne大会上，Sun公司宣布最终会把Java开源，并在随后的一年，陆续将JDK的各个部分（其中当然也包括了HotSpot VM）在GPL协议下公开了源码，并在此基础上建立了OpenJDK。这样，HotSpot VM便成为了Sun JDK和OpenJDK两个实现极度接近的JDK项目的共同虚拟机。

在2008年和2009年，Oracle公司分别收购了BEA公司和Sun公司，这样Oracle就同时拥有了两款优秀的Java虚拟机：JRockit VM和HotSpot VM。Oracle公司宣布在不久的将来（大约应在发布JDK 8的时候）会完成这两款虚拟机的整合工作，使之优势互补。整合的方式大致上是在HotSpot的基础上，移植JRockit的优秀特性，譬如使用JRockit的垃圾回收器与MissionControl服务，使用HotSpot的JIT编译器与混合的运行时系统。

1.4.3 Sun Mobile-Embedded VM/Meta-Circular VM

Sun公司所研发的虚拟机可不仅有前面介绍的服务器、桌面领域的商用虚拟机，除此之外，Sun公司面对移动和嵌入式市场，也发布过虚拟机产品，另外还有一类虚拟机，在设计之初就没抱有商用的目的，仅仅是用于研究、验证某种技术和观点，又或者是作为一些规范的标准实现。这些虚拟机对于大部分不从事相关领域开发的Java程序员来说可能比较陌生。Sun公司发布的其他Java虚拟机有：

(1) KVM

KVM中的K是“Kilobyte”的意思，它强调简单、轻量、高度可移植，但是运行速度比较慢。在Android、iOS等智能手机操作系统出现前曾经在手机平台上得到非常广泛的应用。

(2) CDC/CLDC HotSpot Implementation

CDC/CLDC全称是Connected (Limited) Device Configuration，在JSR-139/JSR-218规范中进行定义，它希望在手机、电子书、PDA等设备上建立统一的Java编程接口，而CDC-HI VM和CLDC-HI VM则是它们的一组参考实现。

CDC/CLDC是整个Java ME的重要支柱，但从目前Android和iOS二分天下的移动数字设备市场看来，在这个领域中，Sun的虚拟机所面临的局面远不如服务器和桌面领域乐观。

(3) Squawk VM

Squawk VM由Sun公司开发，运行于Sun SPOT（Sun Small Programmable Object Technology，一种手持的WiFi设备），也曾经运用于Java Card。这是一个Java代码比重很高的嵌入式虚拟机实现，其中诸如类加载器、字节码验证器、垃圾收集器、解释器、编译器和线程调度都是Java语言本身完成的，仅仅靠C语言来编写设备I/O和必要的本地代码。

(4) JavaInJava

JavaInJava是Sun公司于1997年~1998年间研发的一个实验室性质的虚拟机，从名字就可以看出，它试图以Java语言来实现Java语言本身的运行环境，既所谓的“元循环”（Meta-Circular，是

指使用语言自身来实现其运行环境）。它必须运行在另外一个宿主虚拟机之上，内部没有JIT编译器，代码只能以解释模式执行。在20世纪末主流Java虚拟机都未能很好解决性能问题的时代，开发这种项目，其执行速度可想而知。

（5）Maxine VM

Maxine VM和上面的JavaInJava非常相似，它也是一个几乎全部以Java代码实现（只有用于启动JVM的加载器使用C语言编写）的元循环Java虚拟机。这个项目于2005年开始，到现在仍然在发展之中，比起JavaInJava，Maxine VM就显得“靠谱”很多，它有先进的JIT编译器和垃圾收集器（但没有解释器），可在宿主模式或独立模式下执行，其执行效率已经接近了HotSpot Client VM。

的水平。

1.4.4 BEA JRockit/IBM J9 VM

前面介绍了Sun公司的各种虚拟机，除了Sun公司以外，其他组织、公司也研发过不少虚拟机实现，其中规模最大、最著名的就是BEA和IBM公司了。

JRockit VM曾经号称“世界上速度最快的Java虚拟机”（广告词，貌似J9 VM也这样说过），它是BEA公司在2002年从Appeal Virtual Machines公司收购的虚拟机。BEA公司将其发展为一款专门为服务器硬件和服务器端应用场景高度优化的虚拟机，由于专注于服务器端应用，它可以不太关注程序启动速度，因此JRockit内部不包含解析器实现，全部代码都靠即时编译器编译后执行。除

除此之外，JRockit的垃圾收集器和MissionControl服务套件等部分的实现，在众多Java虚拟机中也一直处于领先水平。

IBM J9 VM并不是IBM公司唯一的Java虚拟机，不过是目前其主力发展的Java虚拟机。IBM J9 VM原本是内部开发代号，正式名称是“IBM Technology for Java Virtual Machine”，简称IT4J，只是这个名字太拗口了一点，普及程度不如J9。J9 VM最初是由IBM Ottawa实验室一个名为SmallTalk的虚拟机扩展而来的，当时这个虚拟机有一个bug是由8k值定义错误引起的，工程师花了很多时间终于发现并解决了这个错误，此后这个版本的虚拟机就称为K8了，后来扩展出支持Java的虚拟机就被称为J9了。与BEA JRockit专注于服务器端应用不同，IBM J9的市场定位与Sun

HotSpot比较接近，它是一款设计上从服务器端到桌面应用再到嵌入式都全面考虑的多用途虚拟机，J9的开发目的是作为IBM公司各种Java产品的执行平台，它的主要市场是和IBM产品（如IBM WebSphere等）搭配以及在IBM AIX和z/OS这些平台上部署Java应用。

1.4.5 Azul VM/BEA Liquid VM

我们平时所提及的“高性能Java虚拟机”一般是指HotSpot、JRockit、J9这类在通用平台上运行的商用虚拟机，但其实Azul VM和BEA Liquid VM这类特定硬件平台专有的虚拟机才是“高性能”的武器。

Azul VM是Azul Systems公司在HotSpot基础上进行大量改进，运行于Azul Systems公司的专有硬件Vega系统上的Java虚拟机，每个Azul VM实例都可以管理至少数十个CPU和数百GB内存的硬件资源，并提供在巨大内存范围内实现可控的GC时间的垃圾收集器、为专有硬件优化的线程调度等优秀特性。在2010年，Azul Systems公司开始从硬件

转向软件，发布了自己的Zing JVM，可以在通用x86平台上提供接近于Vega系统的特性。

Liquid VM即是现在的JRockit VE（Virtual Edition），它是BEA公司开发的，可以直接运行在自家Hypervisor系统上的JRockit VM的虚拟化版本，Liquid VM不需要操作系统的支持，或者说它自己本身实现了一个专用操作系统的必要功能，如文件系统、网络支持等。由虚拟机越过通用操作系统直接控制硬件可以获得很多好处，如在线程调度时，不需要再进行内核态/用户态的切换等，这样可以最大限度地发挥硬件的能力，提升Java程序的执行性能。

1.4.6 Apache Harmony/Google Android Dalvik VM

这节介绍的Harmony VM和Dalvik VM只能称做“虚拟机”，而不能称做“Java虚拟机”，但是这两款虚拟机（以及所代表的技术体系）对最近几年的Java世界产生了非常大的影响和挑战，甚至有些悲观的评论家认为成熟的Java生态系统有崩溃的可能。

Apache Harmony是一个Apache软件基金会旗下以Apache License协议开源的实际兼容于JDK 1.5和JDK 1.6的Java程序运行平台，这个介绍相当拗口。它包含自己的虚拟机和Java库，用户可以在上面运行Eclipse、Tomcat、Maven等常见的Java

程序，但是它没有通过TCK认证，所以我们不得不用那么一长串拗口的语言来介绍它，而不能用一句“Apache的JDK”来说明。如果一个公司要宣布自己的运行平台“兼容于Java语言”，那就必须要通过TCK（Technology Compatibility Kit）的兼容性测试。Apache基金会曾要求Sun公司提供TCK的使用授权，但是一直遭到拒绝，直到Oracle公司收购了Sun公司之后，双方关系越闹越僵，最终导致Apache愤然退出JCP（Java Community Process）组织，这是目前为止Java社区最严重的一次“分裂”。

在Sun将JDK开源形成OpenJDK之后，Apache Harmony开源的优势被极大地削弱，甚至连Harmony项目的大参与者IBM公司也宣布辞去Harmony项目管理主席的职位，并参与OpenJDK

项目的开发。虽然Harmony没有经过真正大规模的商业运用，但是它的许多代码（基本上是Java库部分的代码）被吸纳进IBM的JDK 7实现及Google Android SDK之中，尤其是对Android的发展起到了很大的推动作用。

说到Android，这个时下最热门的移动数码设备平台在最近几年间的发展过程中所取得的成果已经远远超越了Java ME在过去十多年所获得的成果，Android让Java语言真正走进了移动数码设备领域，只是走的并非Sun公司原本想象的那一条路。

Dalvik VM是Android平台的核心组成部分之一，它的名字来源于冰岛一个名为Dalvik的小渔村。Dalvik VM并不是一个Java虚拟机，它没有遵

循Java虚拟机规范，不能直接执行Java的Class文件，使用的是寄存器架构而不是JVM中常见的栈架构。但是它与Java又有着千丝万缕的联系，它执行的dex（Dalvik Executable）文件可以通过Class文件转化而来，使用Java语法编写应用程序，可以直接使用大部分的Java API等。目前Dalvik VM随着Android一起处于迅猛发展阶段，在Android 2.2中已提供即时编译器实现，在执行性能上有了很大的提高。

1.4.7 Microsoft JVM及其他

在十几年的Java虚拟机发展过程中，除去上面介绍的那些被大规模商业应用过的Java虚拟机外，还有许多虚拟机是不为人知的或者曾经“绚丽”过但最终湮灭的。我们以其中微软公司的JVM为例来介绍一下。

也许Java程序员听起来可能会觉得惊讶，微软公司曾经是Java技术的铁杆支持者（也必须承认，与Sun公司争夺Java的控制权，令Java从跨平台技术变为绑定在Windows上的技术是微软公司的主要目的）。在Java语言诞生的初期（1996年～1998年，以JDK 1.2发布为分界），它的主要应用之一是在浏览器中运行Java Applets程序，微软

公司为了在IE3中支持Java Applets应用而开发了自己的Java虚拟机，虽然这款虚拟机只有Windows平台的版本，却是当时Windows下性能最好的Java虚拟机，它在1997年和1998年连续两年获得了《PC Magazine》杂志的“编辑选择奖”。但好景不长，在1997年10月，Sun公司正式以侵犯商标、不正当竞争等罪名控告微软公司，在随后对微软公司的垄断调查之中，这款虚拟机也曾作为证据之一被呈送法庭。这场官司的结果是微软公司赔偿2000万美金给Sun公司（最终微软公司因垄断赔偿给Sun公司的总金额高达10亿美元），承诺终止其Java虚拟机的发展，并逐步在产品中移除Java虚拟机相关功能。具有讽刺意味的是，到最后在Windows XP SP3中Java虚拟机被完全抹去的时候，Sun公司却又到处登报希望微

软公司不要这样做^[1]。Windows XP高级产品经理 Jim Cullinan称：“我们花费了3年的时间和Sun打官司，当时他们试图阻止我们在Windows中支持Java，现在我们这样做了，可他们又在抱怨，这太具有讽刺意味了。”

我们试想一下，如果当年Sun公司没有起诉微软公司，微软公司继续保持对Java技术的热情，那Java的世界会变得怎么样呢？.NET技术是否会发展起来？但历史是没有假设的。其他在本节中没有介绍到的Java虚拟机还有（当然，应该还有很多笔者所不知道的）：

JamVM.

cacaovm.

SableVM.

Kaffe.

Jelatine JVM.

NanoVM.

MRP.

Moxie JVM.

Jikes RVM.

[1]Sun公司在《纽约时报》、《圣约瑟商业新闻》和《华尔街周刊》上刊登了整页的广告，在广告词中Sun公司号召消费者“要求微软公司继续在其Windows XP系统包括Java平台”。

1.5 展望Java技术的未来

在2005年，Java语言诞生10周年的SunOne技术大会上，Java语言之父James Gosling做了一场题为“Java技术下一个十年”的演讲。笔者不具备James Gosling博士那样高屋建瓴的视角，这里仅从Java平台中几个新生的但已经开始展现出蓬勃之势的技术发展点来看一下后续1~2个JDK版本内的一些很有希望的技术重点。

1.5.1 模块化

模块化是解决应用系统与技术平台越来越复杂、越来越庞大问题的一个重要途径。无论是开发人员还是产品最终用户，都不希望为了系统中

一小块的功能而不得不下载、安装、部署及维护整套庞大的系统。站在整个软件工业化的高度来看，模块化是建立各种功能的标准件的前提。最近几年OSGi技术的迅速发展、各个厂商在JCP中对模块化规范的激烈斗争^[1]，都能充分说明模块化技术的迫切和重要。

在未来的Java平台中，很可能会对模块化提出语法层面的支持。早在2007年，Sun公司就提出过JSR-277：Java模块系统（Java Module System），试图建立Java平台的模块化标准，但受挫于以IBM公司为主导提交的JSR-291：Java SE动态组件支持（Dynamic Component Support for Java SE，这实际就是OSGi R4.1）。由于模块化规范主导权的重要性，Sun公司不能接受一个无法由它控制的规范，在整个Java SE 6期间都拒绝

把任何模块化技术内置到JDK之中。在Java SE 7发展初期，Sun公司再次提交了一个新的规范请求文档JSR-294：Java编程语言中的改进模块性支持（Improved Modularity Support in the Java Programming Language），尽管这个JSR仍然没有通过，但是Sun公司已经独立于JCP专家组在OpenJDK里建立了一个名为Jigsaw（拼图）的子项目来推动这个规范在Java平台中转变为具体的实现。Java的模块化之争目前还没有结束，OSGi已经发布到R5.0版本，而Jigsaw从Java 7延迟至Java 8，在2012年7月又不得不宣布推迟到Java 9中发布，从这点看来，Sun在这场战争中处于劣势，但无论胜利者是哪一方，Java模块化已经成为一项无法阻挡的变革潮流。

[1]如果读者对Java模块化之争感兴趣，可以阅读

笔者的另外一本书《深入理解OSGi：Equinox原理、应用与最佳实践》的第1章。

1.5.2 混合语言

当单一的Java开发已经无法满足当前软件的复杂需求时，越来越多基于Java虚拟机的语言开发被应用到软件项目中，Java平台上的多语言混合编程正成为主流，每种语言都可以针对自己擅长的方面更好地解决问题。试想一下，在一个项目之中，并行处理用Clojure语言编写，展示层使用JRuby/Rails，中间层则是Java，每个应用层都将使用不同的编程语言来完成，而且，接口对每一层的开发者都是透明的，各种语言之间的交互不存在任何困难，就像使用自己语言的原生API一样方便^[1]，因为它们最终都运行在一个虚拟机之上。

在最近的几年里，Clojure、JRuby、Groovy等新生语言的使用人数不断增长，而运行在Java虚拟机（JVM）之上的语言数量也在迅速膨胀，图1-4中列举了其中的一部分。这两点证明混合编程在我们身边已经有所应用并被广泛认可。通过特定领域的语言去解决特定领域的问题是当前软件开发应对日趋复杂的项目需求的一个方向。

Languages ♥ The JVM



图 1-4 可以运行在JVM之上的语言^[2]

除了催生出大量的新语言外，许多已经有很长历史的程序语言也出现了基于Java虚拟机实现的版本，这样使得混合编程对许多以前使用其他语言的“老”程序员也具备相当大的吸引力，软件企业投入了大量资本的现有代码资产也能很好地

保护起来。表1-1中列举了常见语言的JVM实现版本。

表 1-1 常见语言的 JVM 实现版本

| 语 言 | 基于 JVM 实现的版本 |
|------------------------|--|
| Ada | JGNAT |
| AWK | Jawk |
| C | C to Java Virtual Machine compilers |
| Cobol | Verrynt is Cobol |
| ColdFusion | Adobe ColdFusion、Railo、Open BlueDragon |
| Common Lisp | Armed Bear Common Lisp、CLforJava、Jatha (Common LISP) |
| Component Pascal | Gardens Point Component Pascal |
| Erlang | Erjang |
| Forth | myForth |
| JavaScript | Rhino |
| LOGO | jLogo、XLogo |
| Lua | Kahlua、Luaj、Jill |
| Oberon-2 | Canterbury Oberon-2 for JVM |
| Objective Caml (OCaml) | OCaml-Java |
| Pascal | Canterbury Pascal for JVM |
| PHP | IBM WebSphere sMash PHP (P8)、Cauchy Quercus |
| Python | Jython |
| Rexx | IBM NetRexx |
| Ruby | JRuby |
| Scheme | Bigloo、Kawa、SISC、JScheme |

对这些运行于Java虚拟机之上、Java之外的语言，来自系统级的、底层的支持正在迅速增强，以JSR-292为核心的一系列项目和功能改进（如Da Vinci Machine项目、Nashorn引擎、InvokeDynamic指令、java.lang.invoke包等），推动Java虚拟机从“Java语言的虚拟机”向“多语言虚拟机”的方向发展。

[1] 在同一个虚拟机上运行的其他语言与Java之间的交互一般都比较容易，但非Java语言之间的交互一般都比较繁琐。dynalang项目（<http://dynalang.sourceforge.net/>）就是为了解决这个问题而出现的。

[2] 图片来源：

<http://www.Slideshare.net/josebetomex/oow-2009-towards-a-universal-vm>。

1.5.3 多核并行

如今，CPU硬件的发展方向已经从高频率转变为多核心，随着多核时代的来临，软件开发越来越关注并行编程的领域。早在JDK 1.5就已经引入java.util.concurrent包实现了一个粗粒度的并发框架。而JDK 1.7中加入的java.util.concurrent.forkjoin包则是对这个框架的一次重要扩充。Fork/Join模式是处理并行编程的一个经典方法，如图1-5所示。虽然不能解决所有的问题，但是在此模式的适用范围之内，能够轻松地利用多个CPU核心提供的计算资源来协作完成一个复杂的计算任务。通过利用Fork/Join模式，我们能够更加顺畅地过渡到多核时代。




图 1-5 Fork/Join模式示意图^[1]

在Java 8中，将会提供Lambda支持，这将会极大改善目前Java语言不适合函数式编程的现状（目前Java语言使用函数式编程并不是不可以，只是会显得很臃肿），函数式编程的一个重要优点就是这样的程序天然地适合并行运行，这对Java语言在多核时代继续保持主流语言的地位有很大帮助。

另外，在并行计算中必须提及的还有

OpenJDK的子项目Sumatra^[2]，目前显卡的算术运算能力、并行能力已经远远超过了CPU，在图形领域以外发掘显卡的潜力是近几年计算机发展的方向之一，例如C语言的CUDA。Sumatra项目就是为Java提供使用GPU（Graphics Processing Units）和APU（Accelerated Processing Units）运算能力的工具，以后它将会直接提供Java语言层面的API，或者为Lambda和其他JVM语言提供底层的并行运算支持。

在JDK外围，也出现了专为满足并行计算需求的计算框架，如Apache的Hadoop Map/Reduce，这是一个简单易懂的并行框架，能够运行在由上千个商用机器组成的大型集群上，并且能以一种可靠的容错方式并行处理TB级别的数据集。另外，还出现了诸如Scala、Clojure及

Erlang等天生就具备并行计算能力的语言。

[1] 图片来源：

[http://www.ibm.com/developerworks/cn/java/j-lo-forkjoin/。](http://www.ibm.com/developerworks/cn/java/j-lo-forkjoin/)

[2] Sumatra项目主页：

[http://openjdk.java.net/projects/sumatra/。](http://openjdk.java.net/projects/sumatra/)

1.5.4 进一步丰富语法

Java 5曾经对Java语法进行了一次扩充，这次扩充加入了自动装箱、泛型、动态注解、枚举、可变长参数、遍历循环等语法，使得Java语言的精确性和易用性有了很大的进步。在Java 7（由于进度压力，许多改进已推迟至Java 8）中，对Java语法进行了另一次大规模的扩充。Sun（已被Oracle收购）专门为改进Java语法在OpenJDK中建立了Coin子项目^[1]来统一处理对Java语法的细节修改，如二进制数的原生支持、在switch语句中支持字符串、“<>”操作符、异常处理的改进、简化变长参数方法调用、面向资源的try-catch-finally语句等都是在Coin项目之中提交的内

容。

除了Coin项目之外，在JSR-335（Lambda Expressions for the Java TM Programming Language）中定义的Lambda表达式^[2]也将对Java的语法和语言习惯产生很大的影响，面向函数方式的编程可能会成为主流。

[1]Coin项目主页：

<http://wikis.sun.com/display/ProjectCoin/Home>。

[2]Lambda项目主页：

[http://openjdk.java.net/projects/lambd/。](http://openjdk.java.net/projects/lambd/)

1.5.5 64位虚拟机

在几年之前，主流的CPU就开始支持64位架构了。Java虚拟机也在很早之前就推出了支持64位系统的版本。但Java程序运行在64位虚拟机上需要付出比较大的额外代价：首先是内存问题，由于指针膨胀和各种数据类型对齐补白的原因，运行于64位系统上的Java应用需要消耗更多的内存，通常要比32位系统额外增加10%~30%的内存消耗；其次，多个机构的测试结果显示，64位虚拟机的运行速度在各个测试项中几乎全面落后于32位虚拟机，两者大约有15%左右的性能差距。

但是在Java EE方面，企业级应用经常需要使

用超过4GB的内存，对于64位虚拟机的需求是非常迫切的，但由于上述原因，许多企业应用都仍然选择使用虚拟集群等方式继续在32位虚拟机中进行部署。Sun也注意到了这些问题，并做出了一些改善，在JDK 1.6 Update 14之后，提供了普通对象指针压缩功能（-XX:

+UseCompressedOops，这个参数不建议显式设置，建议维持默认由虚拟机的Ergonomics机制自动开启），在执行代码时，动态植入压缩指令以节省内存消耗，但是开启压缩指针会增加执行代码数量，因为所有在Java堆里的、指向Java堆内对象的指针都会被压缩，这些指针的访问就需要更多的代码才可以实现，而且并不只是读写字段才受影响，在实例方法调用、子类型检查等操作中也受影响，因为对象实例指向对象类型的引用

也被压缩了。随着硬件的进一步发展，计算机终究会完全过渡到64位的时代，这是一件毫无疑问的事情，主流的虚拟机应用也终究会从32位发展至64位，而虚拟机对64位的支持也将进一步完善。

1.6 实战：自己编译JDK

想要一探JDK内部的实现机制，最便捷的路径之一就是自己编译一套JDK，通过阅读和跟踪调试JDK源码去了解Java技术体系的原理，虽然门槛会高一点，但肯定会比阅读各种书籍、文章更加贴近本质。另外，JDK中的很多底层方法都是本地化（Native）的，需要跟踪这些方法的运作或对JDK进行Hack的时候，都需要自己编译一套JDK。

现在网络上有不少开源的JDK实现可以供我们选择，如Apache Harmony、OpenJDK等。考虑到Sun系列的JDK是现在使用得最广泛的JDK版本，笔者选择了OpenJDK进行这次编译实战。

1.6.1 获取JDK源码

首先要先明确OpenJDK和Sun/OracleJDK之间，以及OpenJDK 6、OpenJDK 7、OpenJDK 7u和OpenJDK 8等项目之间是什么关系，这有助于确定接下来编译要使用的JDK版本和源码分支。

从前面介绍的Java发展史中我们了解到OpenJDK是Sun在2006年末把Java开源而形成的项目，这里的“开源”是通常意义上的源码开放形式，即源码是可被复用的，例如IcedTea^[1]、UltraViolet^[2]都是从OpenJDK源码衍生出的发行版。但如果仅从“开源”字面意义（开放可阅读的源码）上看，其实Sun自JDK 1.5之后就开始以Java Research License（JRL）的形式公布过Java源码，主要用于研究人员阅读（JRL许可证的开

放源码至JDK 1.6 Update 23为止）。把这些JRL许可证形式的Sun/OracleJDK源码和对应版本的OpenJDK源码进行比较，发现除了文件头的版权注释之外，其余代码基本上都是相同的，只有字体渲染部分存在一点差异，Oracle JDK采用了商业实现，而OpenJDK使用的是开源的FreeType。当然，“相同”是建立在两者共有的组件基础上的，Oracle JDK中还会存在一些Open JDK没有的、商用闭源的功能，例如从JRockit移植改造而来的Java Flight Recorder。预计以后JRockit的MissionControl移植到HotSpot之后，也会以Oracle JDK专有、闭源的形式提供。

Oracle的项目发布经理Joe Darcy在OSCON 2011上对两者关系的介绍^[3]也证实了OpenJDK 7 和Oracle JDK 7在程序上是非常接近的，两者共

用了大量相同的代码（如图1-6所示，注意图中提示了两者共同代码的占比要远高于图形上看到的比例），所以我们编译的OpenJDK，基本上可以认为性能、功能和执行逻辑上都和官方的Oracle JDK是一致的。




图 1-6 OpenJDK和Oracle JDK之间的关系

再来看一下OpenJDK 6、OpenJDK 7、OpenJDK 7u和OpenJDK 8这几个项目之间的关系，从图1-7（依然从Joe Darcy的OSCON 2011

演示稿中截取的图片)来看, OpenJDK 7是始于 JDK 6时期, 当时JDK 6和JDK 6 Update 1已经发布, JDK 7已经开始研发了, 所以OpenJDK 7是直接基于正在研发的JDK 7源码建立的。但考虑到 OpenJDK 7的状况在当时还不适合实际生产部署, 因此在OpenJDK 7 Build 20的基础上建立了 OpenJDK 6分支, 剥离掉JDK 7新功能的代码, 形成一个可以通过TCK 6测试的独立分支。




图 1-7 OpenJDK 6、OpenJDK 7、OpenJDK 7u、OpenJDK 8之间的关系

2012年7月，JDK 7正式发布，在OpenJDK中也同步建立了OpenJDK 7 Update项目对JDK 7进行更新升级，以及OpenJDK 8项目开始下一个JDK大版本的研发。按照开发习惯，新的功能或Bug修复通常是在最新分支上进行的，当功能或修复在最新分支上稳定之后会同步到其他老版本的维护分支上。

OpenJDK 6、OpenJDK 7、OpenJDK 7u和OpenJDK 8的源码都可以在它们相应的网页上找到，在本次编译实践中，笔者选用的项目是OpenJDK 7u，版本为7u6。

获取OpenJDK源码有两种方式，其中一种是通过Mercurial代码版本管理工具从Repository中直接取得源码（Repository地址：

<http://hg.openjdk.java.net/jdk7u/jdk7u>），获取过程如以下代码所示。

```
hg clone  
http://hg.openjdk.java.net/jdk7u/jdk7u-dev  
cd jdk7u-dev  
chmod 755 get_source.sh  
../get_source.sh
```

这是最直接的方式，从版本管理中看变更轨迹比看Release Note效果更好。但不足之处是速度太慢，虽然代码总容量只有300 MB左右，但是文件数量太多，在笔者的网络下全部复制到本地需要数小时。另外，考虑到Mercurial不如Git、SVN、ClearCase或CVS之类的版本控制工具那样普及，对于一般读者，建议采用第二种方式，即直接下载官方打包好的源码包，读者可以从Source Bundle Releases页面（地址：

<http://jdk7.java.net/source.html>) 取得打包好的源码，到本地直接解压即可。一般来说，源码包大概一至两个月左右会更新一次，虽然不够及时，但比起从Mercurial复制代码的确方便和快捷许多。笔者下载的是OpenJDK 7 Update 6 Build b21 版源码包，2012年8月28日发布，大概99MB，解压后约为339MB。

[1]IcedTea：

http://icedtea.classpath.org/wiki/Main_Page。

[2]UltraViolet：<https://www.reservoir.com/>?

q=uvform/form。

[3]全文地址：

<https://blogs.oracle.com/darcy/resource/OSCON/osc>

1.6.2 系统需求

如果可能，笔者建议尽量在Linux、MacOS或Solaris上构建OpenJDK，这要比在Windows平台上容易得多，本章实战中笔者将以Ubuntu 10.10和MacOS X 10.8.2为例进行构建。如果读者一定要在Windows平台上完成编译，可参考本书附录A，该附录是本书第一版中介绍如何在Windows下编译OpenJDK 6的例子，原有的部分内容现在已经过时了（例如安装Plug部分），但还是有一定参考意义，因此笔者没有把它删除掉，而是移到附录之中。

无论在什么平台下进行编译，都建议读者认真阅读一遍源码中的README-builds.html文档

（无论在OpenJDK网站上还是在下载的源码包中都有这份文档），因为编译过程中需要注意的细节非常多。虽然不至于像文档上所描述的“Building the source code for the JDK requires a high level of technical expertise. Sun provides the source code primarily for technical experts who want to conduct research.（编译JDK需要很高的专业技术，Sun提供JDK源码是为了技术专家进行研究之用）”那么夸张，但是如果读者是第一次编译，那有可能会在一些小问题上耗费许多时间。

在本次编译中采用的是64位操作系统，编译的也是64位的OpenJDK，如果需要编译32位版本，那建议在32位操作系统上进行。在官方文档上写到编译OpenJDK至少需要512MB的内存和600MB的磁盘空间。512MB的内存也许能凑合使

用，不过600MB的磁盘空间估计仅是指存放OpenJDK源码所需的空间，要完成编译，600MB肯定是无论如何都不够的，光输出的编译结果就有近3GB（因为有很多中间文件，以及会编译出不同优化级别（Product、Debug、FastDebug等）的虚拟机），建议读者至少保证5GB以上的空余磁盘。

对系统的最后一点要求就是所有的文件，包括源码和依赖项目，都不要放在包含中文的目录里面，这样做不是一定不可以，只是没有必要给自己找麻烦。

1.6.3 构建编译环境

在MacOS^[1]和Linux上构建OpenJDK编译环境比较简单（相对于Windows来说），对于Mac OS，需要安装最新版本的XCode和Command Line Tools for XCode，在Apple Developer网站（<https://developer.apple.com/>）上可以免费下载，这两个SDK包提供了OpenJDK所需的编译器以及Makefile中用到的外部命令。另外，还要准备一个6u14以上版本的JDK，因为OpenJDK的各个组成部分（Hotspot、JDK API、JAXWS、JAXP……）有的是使用C++编写的，更多的代码则是使用Java自身实现的，因此编译这些Java代码需要用到一个可用的JDK，官方称这个JDK

为“Bootstrap JDK”。如果编译OpenJDK 7，Bootstrap JDK必须使用JDK6 Update 14或之后的版本，笔者选用的是JDK7 Update 4。最后需要下载一个1.7.1以上版本的Apache Ant，用于执行Java编译代码中的Ant脚本。

对于Linux来说，所需要准备的依赖与Mac OS差不多，Bootstrap JDK和Ant都是一样的，在Mac OS中GCC编译器来源于XCode SDK，而在Ubuntu中GCC应该是默认安装好的，需要确保版本为4.3以上，如果没有找到GCC，安装binutils即可，在Ubuntu 10.10下编译OpenJDK 7u4所需的依赖可以使用以下命令一次安装完成。

```
sudo apt-get install build-essential gawk m4
openjdk-6-jdk
libasound2-dev libcups2-dev libxrender-dev
xorg-dev xutils-dev
```

```
x11proto-print-dev binutils libmotif3  
libmotif-dev ant
```

[1]注意，只有在OpenJDK 7u4和之后的版本才能编译出Mac OS系统下的JDK包，之前的版本虽然在源码和编译脚本中也包含了Mac OS目录，但是尚未完善。

1.6.4 进行编译

现在需要下载的编译环境和依赖项目都准备齐全了，最后我们还需要对系统的环境变量做一些简单设置以便编译能够顺利通过。OpenJDK在编译时读取的环境变量有很多，但大多都有默认值，必须设置的只有两个：`LANG`和`ALT_BOOTDIR`，前者是设定语言选项，必须设置为：

```
export LANG=C
```

否则，在编译结束前的验证阶段会出现一个`HashTable`内的空指针异常。另外一个`ALT_BOOTDIR`参数是前面提到的Bootstrap

JDK，在Mac OS上笔者设为以下路径，其他操作系统读者对应调整即可。

```
export  
ALT_BOOTDIR=/Library/Java/JavaVirtualMachines/jc
```

另外，如果读者之前设置了JAVA_HOME和CLASSPATH两个环境变量，在编译之前必须取消，否则在Makefile脚本中检查到有这两个变量存在，会有警告提示。

```
unset JAVA_HOME  
unset CLASSPATH
```

其他环境变量笔者就不再一一介绍了，代码清单1-1给出笔者自己常用的编译Shell脚本，读者可以参考变量注释中的内容。

代码清单1-1 环境变量设置

```
#语言选项，这个必须设置，否则编译好后会出现一个
HashTable的NPE错
export LANG=C
#Bootstrap JDK的安装路径。必须设置
export
ALT_BOOTDIR=/Library/Java/JavaVirtualMachines/jc
#允许自动下载依赖
export ALLOW_DOWNLOADS=true
#并行编译的线程数，设置为和CPU内核数量一致即可
export HOTSPOT_BUILD_JOBS=6
export ALT_PARALLEL_COMPILE_JOBS=6
#比较本次build出来的映像与先前版本的差异。这对我们
来说没有意义，
#必须设置为false，否则sanity检查会报缺少先前版本
JDK的映像的错误提示。
#如果已经设置dev或者DEV_ONLY=true，这个不显式设置
也行
export SKIP_COMPARE_IMAGES=true
#使用预编译头文件，不加这个编译会更慢一些
export USE_PRECOMPILED_HEADER=true
#要编译的内容
export BUILD_LANGTOOLS=true
#export BUILD_JAXP=false
#export BUILD_JAXWS=false
#export BUILD_CORBA=false
export BUILD_HOTSPOT=true
export BUILD_JDK=true
#要编译的版本
#export SKIP_DEBUG_BUILD=false
#export SKIP_FASTDEBUG_BUILD=true
```

```
#export DEBUG_NAME=debug
#把它设置为false可以避开javaws和浏览器Java插件之
类的部分的build
BUILD_DEPLOY=false
#把它设置为false就不会build出安装包。因为安装包里
有些奇怪的依赖,
#但即便不build出它也已经能得到完整的JDK映像, 所以还是
别build它好了
BUILD_INSTALL=false
#编译结果所存放的路径
export
ALT_OUTPUTDIR=/Users/IcyFenix/Develop/JVM/jdkBui
#这两个环境变量必须去掉, 不然会有很诡异的事情发生
(我没有具体查过这些"诡异的
#事情", Makefile脚本检查到有这2个变量就会提示警
告)
unset JAVA_HOME
unset CLASSPATH
make 2>&1|tee $ALT_OUTPUTDIR/build.log
```

全部设置结束之后, 可以输入make sanity来检查我们前面所做的设置是否全部正确。如果一切顺利, 那么几秒钟之后会有类似代码清单1-2所示的输出。

代码清单1-2 make sanity检查

```
~/Develop/JVM/jdkBuild/openjdk_7u4$make
sanity
Build Machine Information:
build machine=IcyFenix-RMBP.local
Build Directory Structure:
CWD=/Users/IcyFenix/Develop/JVM/jdkBuild/ope
TOPDIR=.
LANGTOOLS_TOPDIR=./langtools
JAXP_TOPDIR=./jaxp
JAXWS_TOPDIR=./jaxws
CORBA_TOPDIR=./corba
HOTSPOT_TOPDIR=./hotspot
JDK_TOPDIR=./jdk
Build Directives:
BUILD_LANGTOOLS=true
BUILD_JAXP=true
BUILD_JAXWS=true
BUILD_CORBA=true
BUILD_HOTSPOT=true
BUILD_JDK=true
DEBUG_CLASSFILES=
DEBUG_BINARIES=
.....因篇幅关系，中间省略了大量的输出内容.....
OpenJDK-specific settings:
FREETYPE_HEADERS_PATH=/usr/X11R6/include
ALT_FREETYPE_HEADERS_PATH=
FREETYPE_LIB_PATH=/usr/X11R6/lib
ALT_FREETYPE_LIB_PATH=
Previous JDK Settings:
PREVIOUS_RELEASE_PATH=USING-
PREVIOUS_RELEASE_IMAGE
ALT_PREVIOUS_RELEASE_PATH=
PREVIOUS_JDK_VERSION=1.6.0
```

```
ALT_PREVIOUS_JDK_VERSION=
PREVIOUS_JDK_FILE=
ALT_PREVIOUS_JDK_FILE=
PREVIOUS_JRE_FILE=
ALT_PREVIOUS_JRE_FILE=
PREVIOUS_RELEASE_IMAGE=/Library/Java/JavaVirtualMachines/jdk-11.0.1.jdk/Contents/Home
ALT_PREVIOUS_RELEASE_IMAGE=
```

Sanity check passed.

Makefile的Sanity检查过程输出了编译所需的所有环境变量，如果看到“Sanity check passed.”，说明检查过程通过了，可以输入“make”执行整个OpenJDK编译（make不加参数，默认编译make all），笔者使用Core i7 3720QM/16GB RAM的MacBook机器，启动6条编译线程，全量编译整个OpenJDK大概需20分钟，编译结束后，将输出类似下面的日志清单所示内容。如果读者之前已经全量编译过，只修改了少量文件，增量编译可以在数十秒内完成。

```
#--Build times-----
Target all_product_build
Start 2012-12-13 17: 12: 19
End 2012-12-13 17: 31: 07
00: 01: 19 corba
00: 01: 15 hotspot
00: 00: 14 jaxp
00: 7: 21 jaxws
00: 8: 11 jdk
00: 00: 28 langtools
00: 18: 48 TOTAL
-----
```

编译完成之后，进入OpenJDK源码下的 build/j2sdk-image目录（或者build-debug、build-fastdebug这两个目录），这是整个JDK的完整编译结果，复制到JAVA_HOME目录，就可以作为一个完整的JDK使用，编译出来的虚拟机，在version命令中带有用户的机器名。

```
>./java-version
openjdk version"1.7.0-internal-fastdebug"
OpenJDK Runtime Environment Environment
```

```
ent(b u i l d 1.7.0-i n t e r n a l-f a s t  
d e b u g-icyfenix_2012_12_24_15_57-b00)  
OpenJDK 64-Bit Server VM (build 23.0-b21-  
fastdebug,mixed mode)
```

在大多数时候，如果我们并不关心JDK中HotSpot虚拟机以外的内容，只想单独编译HotSpot虚拟机的话（例如调试虚拟机时，每次改动程序都执行整个OpenJDK的Makefile，速度肯定受不了），那么使用hotspot/make目录下的Makefile进行替换即可，其他参数设置与前面是一致的，这时候虚拟机的输出结果存放在build/hotspot/outputdir/bsd_amd64_compiler2目录^[1]中，进入后可以见到以下几个目录。

```
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13  
17: 24 debug  
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13  
17: 24 fastdebug  
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13  
17: 25 generated
```

```
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13
17: 24 jvmg
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13
17: 24 optimized
0 drwxr-xr-x 584 IcyFenix staff 19K 12 13
17: 25 product
0 drwxr-xr-x 15 IcyFenix staff 510B 12 13
17: 24 profiled
```

这些目录对应了不同的优化级别，优化级别越高，性能自然就越好，但是输出代码与源码的差距就越大，难于调试，具体哪个目录有内容，取决于make命令后面的参数。

在编译结束之后、运行虚拟机之前，还要手工编辑目录下的env.sh文件，这个文件由编译脚本自动产生，用于设置虚拟机的环境变量，里面已经发布了“JAVA_HOME、CLASSPATH、HOTSPOT_BUILD_USER”3个环境变量，还需要增加一个“LD_LIBRARY_PATH”，内容如下：

```
LD_LIBRARY_PATH=.:  
${JAVA_HOME}/jre/lib/amd64/native_threads:  
${JAVA_HOME}/jre/lib/amd64:  
export LD_LIBRARY_PATH
```

然后执行以下命令启动虚拟机（这时的启动器名为gamma），输出版本号。

```
./env.sh  
./gamma-version  
Using java runtime  
at: /Library/Java/JavaVirtualMachines/jdk1.7.0_0  
java version"1.7.0_04"  
Java (TM) SE Runtime Environment (build  
1.7.0_04-b21)  
OpenJDK 64-Bit Server VM (build 23.0-b21,  
mixed mode)
```

看到自己编译的虚拟机成功运行起来，很有成就感吧！

[1]在不同机器上，最后一个目录名称会有所差别，bsd表示Mac OS系统（内核为FreeBSD），

amd64表示是64位JDK（32位是x86），compiler2
表示是Server VM（Client VM表示是compiler1）。

1.6.5 在IDE工具中进行源码调试

在阅读OpenJDK源码的过程中，经常需要运行、调试程序来帮助理解。我们现在已经可以编译出一个调试版本HotSpot虚拟机，禁用优化，并带有符号信息，这样就可以使用GDB来进行调试了。据笔者了解，许多对虚拟机了解比较深的开发人员确实就是直接使用GDB加VIM编辑器来开发、修改HotSpot的，不过相信大部分读者更倾向于在IDE环境而不是纯文本的GDB下阅读、跟踪HotSpot源码，因此这节就简单介绍一下“如何在IDE中进行HotSpot源码调试”。

首先，到NetBeans网站

(<http://netbeans.org/>) 上下载最新版的

NetBeans，下载时选择支持C/C++开发的那个版本。安装后，新建一个项目，选择“基于现有源代码的C/C++项目”，在源码文件夹中填入OpenJDK目录下hotspot目录的路径，在下面的单选按钮中选择“定制”，如图1-8所示，然后单击“下一步”按钮。



图 1-8 在NetBeans中创建HotSpot项目（1）

接着，在“指定构建代码的方法”中选择“使用现有的makefile”，并填入Makefile文件的路径（在hotspot/make目录下），如图1-9所示。单击“下一步”按钮，将“构建命令”修改为以下内容：

```
$ {MAKE}-f Makefile clean jvmg  
ALT_BOOTDIR=/Library/Java/JavaVirtualMachine  
ARCH_DATA_MODEL=64 LANG=C
```



图 1-9 在NetBeans中创建HotSpot项目 (2)

OpenJDK 7u4源码Makefile在终端运行时能正确获取到系统指令集架构为64位，但在NetBeans中却没有取得正确的值，误认为是32位，因此这里必须使用ARCH_DATA_MODEL参数明确指定

为64位。另外两个参数ALT_BOOTDIR和LANG的作用前面已经介绍过。单击“完成”按钮，HotSpot项目就这样导入到NetBeans中了。

不过，这时候HotSpot还运行不起来，因为NetBeans根本不知道编译出来的结果放在哪里、哪个程序是虚拟机的入口等，这些内容都需要明确告知NetBeans。在HotSpot工程上单击右键，在弹出的快捷菜单中选择“属性”，在弹出的对话框中找到“运行”选项，设置运行命令为：

```
/Users/IcyFenix/Develop/JVM/jdkBuild/openjdk  
Queens
```

上面的Queens是Makefile脚本自动产生的一段解八皇后问题的Java程序，用于测试虚拟机，这里笔者直接拿来用了，读者完全可以将它替换

为自己的Java程序。

读者在调试Java代码执行时，如果要跟踪具体Java代码在虚拟机中是如何执行的，也许会觉得无从下手，因为目前在HotSpot主流的操作系统上，都采用模板解释器来执行字节码，它与JIT编译器一样，最终执行的汇编代码都是运行期间产生的，无法直接设置断点，所以HotSpot增加了以下参数来方便开发人员调试解释器。

```
-XX: +TraceBytecodes -XX: StopInterpreterAt=<n>
```

这组参数的作用是当遇到序号为<n>的字节码指令时，便会中断程序执行，进入断点调试。在调试解释器部分代码时，把这两个参数加到gamma后面即可。

最后，还需要在“环境”窗口中设置环境变量，也就是前面env.sh脚本所设置的那几个环境变量，如图1-10所示。




图 1-10 在NetBeans中创建HotSpot项目 (3)

完成以上配置之后，一个可修改、编译、调试的HotSpot工程就完全建立起来了，启动器的执

行入口是java.c的main（）方法，读者可以设置断点单步跟踪，如图1-11所示。




图 1-11 在NetBeans中创建HotSpot项目（4）

由于HotSpot的源码比较长，C/C++文件数量也很多，为了便于读者阅读，所以代码清单1-3给出了各个目录中代码的主要用途，供读者参考。

代码清单1-3 HotSpot源码结构[1]

```
hotspot
├── agent
├── make
├── src
│   ├── cpu
│   ├── os
│   ├── os_cpu
│   └── share
│       ├── tools
│       │   ├── hsdis
│       │   ├── IdealGraphVisualizer
│       │   ├── launcher
│       │   └── LogCompilation
```

Serviceability Agent 的实现
用来 build 出 HotSpot 的各种配置文件
HotSpot VM 的源代码
CPU 相关代码
操作系统相关代码
操作系统 +CPU 组合的相关代码
平台无关的共通代码
工具
反汇编插件
将 Server 编译器的中间代码可视化
启动程序 "java"
将 -XX:+LogCompilation 输出的日志 (hotspot.log)

| | | |
|--|---------------------|--|
| | ProjectCreator | 整理成更容易阅读的格式的工具 |
| | vm | 生成 Visual Studio 的 project 文件的工具 |
| | adlc | HotSpot VM 的核心代码 |
| | asm | 平台描述文件（上面的 cpu 或 os_cpu 里的 *.ad 文件）的编译器 |
| | cl | 汇编器接口 |
| | ci | Client 编译器 |
| | classfile | 动态编译器的公共服务 / 接口 |
| | code | 类文件的处理（包括类加载和系统符号表等） |
| | compiler | 动态生成的代码的管理 |
| | gcImplementation | 编译器接口 |
| | concurrentMarkSweep | GC 的实现 |
| | gl | Concurrent Mark Sweep GC 的实现 |
| | parallelScavenge | Garbage-First GC 的实现（不使用老的分代式 GC 框架） |
| | parNew | ParallelScavenge GC 的实现（Server VM 默认，不使用老的分代式 GC 框架） |
| | shared | ParNew GC 的实现 |
| | gcInterface | GC 的共通实现 |
| | interpreter | GC 的接口 |
| | libadt | 解释器，包括“模板解释器”（官方版在用）和“C++ 解释器”（官方版不再用） |
| | memory | 一些抽象数据结构 |
| | oops | 内存管理相关（老的分代式 GC 框架也在这里） |
| | opto | HotSpot VM 的对象系统的实现 |
| | prims | Server 编译器 |
| | runtime | HotSpot VM 的对外接口，包括部分标准库的 native 部分和 JVMTI 实现 |
| | services | 运行时支持库（包括线程管理、编译器调度、锁、反射等） |
| | shark | 主要是用来支持 JMX 之类的管理功能的接口 |
| | utilities | 基于 LLVM 的 JIT 编译器（官方版里没有使用） |
| | test | 一些基本的工具类 |
| | | 单元测试 |

[1] 该目录结构由 RednaxelaFX 整理：

[http://hllvm.group.iteye.com/group/topic/26998。](http://hllvm.group.iteye.com/group/topic/26998)

1.7 本章小结

本章介绍了Java技术体系的过去、现在以及未来的一些发展趋势，并通过实战介绍了如何自己来独立编译一个OpenJDK 7。作为全书的引言部分，本章建立了后文研究所必需的环境。在了解Java技术的来龙去脉后，后面章节将分为4部分去介绍Java在内存管理、Class文件结构与执行引擎、编译器优化及多线程并发方面的实现原理。

第二部分 自动内存管理机制

第2章 Java内存区域与内存溢出异常

第3章 垃圾收集器与内存分配策略

第4章 虚拟机性能监控与故障处理工具

第5章 调优案例分析与实战

第2章 Java内存区域与内存溢出异常

Java与C++之间有一堵由内存动态分配和垃圾收集技术所围成的“高墙”，墙外面的人想进去，墙里面的人却想出来。

2.1 概述

对于从事C、C++程序开发的开发人员来说，在内存管理领域，他们既是拥有最高权力的“皇帝”又是从事最基础工作的“劳动人民”——既拥有每一个对象的“所有权”，又担负着每一个对象生命开始到终结的维护责任。

对于Java程序员来说，在虚拟机自动内存管理机制的帮助下，不再需要为每一个new操作去

写配对的delete/free代码，不容易出现内存泄漏和内存溢出问题，由虚拟机管理内存这一切看起来都很美好。不过，也正是因为Java程序员把内存控制的权力交给了Java虚拟机，一旦出现内存泄漏和溢出方面的问题，如果不了解虚拟机是怎样使用内存的，那么排查错误将会成为一项异常艰难的工作。

本章是第二部分的第1章，笔者将从概念上介绍Java虚拟机内存的各个区域，讲解这些区域的作用、服务对象以及其中可能产生的问题，这是翻越虚拟机内存管理这堵围墙的第一步。

2.2 运行时数据区域

Java虚拟机在执行Java程序的过程中会把它所管理的内存划分为若干个不同的数据区域。这些区域都有各自的用途，以及创建和销毁的时间，有的区域随着虚拟机进程的启动而存在，有些区域则依赖用户线程的启动和结束而建立和销毁。根据《Java虚拟机规范（Java SE 7版）》的规定，Java虚拟机所管理的内存将会包括以下几个运行时数据区域，如图2-1所示。




图 2-1 Java 虚拟机运行时数据区

2.2.1 程序计数器

程序计数器（Program Counter Register）是一块较小的内存空间，它可以看作是当前线程所执行的字节码的行号指示器。在虚拟机的概念模型

里（仅是概念模型，各种虚拟机可能会通过一些更高效的方式去实现），字节码解释器工作时就是通过改变这个计数器的值来选取下一条需要执行的字节码指令，分支、循环、跳转、异常处理、线程恢复等基础功能都需要依赖这个计数器来完成。

由于Java虚拟机的多线程是通过线程轮流切换并分配处理器执行时间的方式来实现的，在任何一个确定的时刻，一个处理器（对于多核处理器来说是一个内核）都只会执行一条线程中的指令。因此，为了线程切换后能恢复到正确的执行位置，每条线程都需要有一个独立的程序计数器，各条线程之间计数器互不影响，独立存储，我们称这类内存区域为“线程私有”的内存。

如果线程正在执行的是一个Java方法，这个计数器记录的是正在执行的虚拟机字节码指令的地址；如果正在执行的是Native方法，这个计数器值则为空（`Undefined`）。此内存区域是唯一一个在Java虚拟机规范中没有规定任何`OutOfMemoryError`情况的区域。

2.2.2 Java虚拟机栈

与程序计数器一样，Java虚拟机栈（Java Virtual Machine Stacks）也是线程私有的，它的生命周期与线程相同。虚拟机栈描述的是Java方法执行的内存模型：每个方法在执行的同时都会创建一个栈帧（Stack Frame^[1]）用于存储局部变量表、操作数栈、动态链接、方法出口等信息。每一个方法从调用直至执行完成的过程，就对应着一个栈帧在虚拟机栈中入栈到出栈的过程。

经常有人把Java内存区分为堆内存（Heap）和栈内存（Stack），这种分法比较粗糙，Java内存区域的划分实际上远比这复杂。这种划分方式的流行只能说明大多数程序员最关注的、与对象

内存分配关系最密切的内存区域是这两块。其中所指的“堆”笔者在后面会专门讲述，而所指的“栈”就是现在讲的虚拟机栈，或者说是虚拟机栈中局部变量表部分。

局部变量表存放了编译期可知的各种基本数据类型（boolean、byte、char、short、int、float、long、double）、对象引用（reference类型，它不等同于对象本身，可能是一个指向对象起始地址的引用指针，也可能是指向一个代表对象的句柄或其他与此对象相关的位置）和returnAddress类型（指向了一条字节码指令的地址）。

其中64位长度的long和double类型的数据会占用2个局部变量空间（Slot），其余的数据类型只占用1个。局部变量表所需的内存空间在编译

期间完成分配，当进入一个方法时，这个方法需要在帧中分配多大的局部变量空间是完全确定的，在方法运行期间不会改变局部变量表的大小。

在Java虚拟机规范中，对这个区域规定了两种异常状况：如果线程请求的栈深度大于虚拟机所允许的深度，将抛出StackOverflowError异常；如果虚拟机栈可以动态扩展（当前大部分的Java虚拟机都可动态扩展，只不过Java虚拟机规范中也允许固定长度的虚拟机栈），如果扩展时无法申请到足够的内存，就会抛出OutOfMemoryError异常。

[1] 栈帧是方法运行时的基础数据结构，在本书的第8章中会对帧进行详细讲解。

2.2.3 本地方法栈

本地方法栈（Native Method Stack）与虚拟机栈所发挥的作用是非常相似的，它们之间的区别不过是虚拟机栈为虚拟机执行Java方法（也就是字节码）服务，而本地方法栈则为虚拟机使用到的Native方法服务。在虚拟机规范中对本地方法栈中方法使用的语言、使用方式与数据结构并没有强制规定，因此具体的虚拟机可以自由实现它。甚至有的虚拟机（譬如Sun HotSpot虚拟机）直接就把本地方法栈和虚拟机栈合二为一。与虚拟机栈一样，本地方法栈区域也会抛出 StackOverflowError 和 OutOfMemoryError 异常。

2.2.4 Java堆

对于大多数应用来说，Java堆（Java Heap）是Java虚拟机所管理的内存中最大的一块。Java堆是被所有线程共享的一块内存区域，在虚拟机启动时创建。此内存区域的唯一目的就是存放对象实例，几乎所有的对象实例都在这里分配内存。这一点在Java虚拟机规范中的描述是：所有的对象实例以及数组都要在堆上分配^[1]，但是随着JIT编译器的发展与逃逸分析技术逐渐成熟，栈上分配、标量替换^[2]优化技术将会导致一些微妙的变化发生，所有的对象都分配在堆上也渐渐变得不是那么“绝对”了。

Java堆是垃圾收集器管理的主要区域，因此

很多时候也被称做“GC堆”（Garbage Collected Heap，幸好国内没翻译成“垃圾堆”）。从内存回收的角度来看，由于现在收集器基本都采用分代收集算法，所以Java堆中还可以细分为：新生代和老年代；再细致一点的有Eden空间、From Survivor空间、To Survivor空间等。从内存分配的角度来看，线程共享的Java堆中可能划分出多个线程私有的分配缓冲区（Thread Local Allocation Buffer, TLAB）。不过无论如何划分，都与存放内容无关，无论哪个区域，存储的都仍然是对象实例，进一步划分的目的是为了更好地回收内存，或者更快地分配内存。在本章中，我们仅仅针对内存区域的作用进行讨论，Java堆中的上述各个区域的分配、回收等细节将是第3章的主题。

根据Java虚拟机规范的规定，Java堆可以处

于物理上不连续的内存空间中，只要逻辑上是连续的即可，就像我们的磁盘空间一样。在实现时，既可以实现成固定大小的，也可以是可扩展的，不过当前主流的虚拟机都是按照可扩展来实现的（通过-Xmx和-Xms控制）。如果在堆中没有内存完成实例分配，并且堆也无法再扩展时，将会抛出`OutOfMemoryError`异常。

[1]Java虚拟机规范中的原文：The heap is the runtime data area from which memory for all class instances and arrays is allocated。

[2]逃逸分析与标量替换的相关内容，参见第11章相关内容。

2.2.5 方法区

方法区（Method Area）与Java堆一样，是各个线程共享的内存区域，它用于存储已被虚拟机加载的类信息、常量、静态变量、即时编译器编译后的代码等数据。虽然Java虚拟机规范把方法区描述为堆的一个逻辑部分，但是它却有一个别名叫做Non-Heap（非堆），目的应该是与Java堆区分开来。

对于习惯在HotSpot虚拟机上开发、部署程序的开发者来说，很多人都更愿意把方法区称为“永久代”（Permanent Generation），本质上两者并不等价，仅仅是因为HotSpot虚拟机的设计团队选择把GC分代收集扩展至方法区，或者说使用

永久代来实现方法区而已，这样HotSpot的垃圾收集器可以像管理Java堆一样管理这部分内存，能够省去专门为方法区编写内存管理代码的工作。对于其他虚拟机（如BEA JRockit、IBM J9等）来说是不存在永久代的概念的。原则上，如何实现方法区属于虚拟机实现细节，不受虚拟机规范约束，但使用永久代来实现方法区，现在看来并不是一个好主意，因为这样更容易遇到内存溢出问题（永久代有-XX: MaxPermSize的上限，J9和JRockit只要没有触碰到进程可用内存的上限，例如32位系统中的4GB，就不会出现问题），而且有极少数方法（例如String.intern（））会因这个原因导致不同虚拟机下有不同的表现。因此，对于HotSpot虚拟机，根据官方发布的路线图信息，现在也有放弃永久代并逐步改为采用Native

Memory来实现方法区的规划了[1]，在目前已经发布的JDK 1.7的HotSpot中，已经把原本放在永久代的字符串常量池移出。

Java虚拟机规范对方法区的限制非常宽松，除了和Java堆一样不需要连续的内存和可以选择固定大小或者可扩展外，还可以选择不实现垃圾收集。相对而言，垃圾收集行为在这个区域是比较少出现的，但并非数据进入了方法区就如永久代的名字一样“永久”存在了。这区域的内存回收目标主要是针对常量池的回收和对类型的卸载，一般来说，这个区域的回收“成绩”比较难以令人满意，尤其是类型的卸载，条件相当苛刻，但是这部分区域的回收确实是必要的。在Sun公司的BUG列表中，曾出现过的若干个严重的BUG就是由于低版本的HotSpot虚拟机对此区域未完全回收

而导致内存泄漏。

根据Java虚拟机规范的规定，当方法区无法满足内存分配需求时，将抛出OutOfMemoryError异常。

[1]JEP 122-Remove the Permanent Generation:
<http://openjdk.java.net/jeps/122>。

2.2.6 运行时常量池

运行时常量池（Runtime Constant Pool）是方法区的一部分。Class文件中除了有类的版本、字段、方法、接口等描述信息外，还有一项信息是常量池（Constant Pool Table），用于存放编译期生成的各种字面量和符号引用，这部分内容将在类加载后进入方法区的运行时常量池中存放。

Java虚拟机对Class文件每一部分（自然也包括常量池）的格式都有严格规定，每一个字节用于存储哪种数据都必须符合规范上的要求才会被虚拟机认可、装载和执行，但对于运行时常量池，Java虚拟机规范没有做任何细节的要求，不同的提供商实现的虚拟机可以按照自己的需要来

实现这个内存区域。不过，一般来说，除了保存Class文件中描述的符号引用外，还会把翻译出来的直接引用也存储在运行时常量池中^[1]。

运行时常量池相对于Class文件常量池的另外一个重要特征是具备动态性，Java语言并不要求常量一定只有编译期才能产生，也就是并非预置入Class文件中常量池的内容才能进入方法区运行时常量池，运行期间也可能将新的常量放入池中，这种特性被开发人员利用得比较多的便是String类的intern（）方法。

既然运行时常量池是方法区的一部分，自然受到方法区内存的限制，当常量池无法再申请到内存时会抛出OutOfMemoryError异常。

[1]关于Class文件格式和符号引用等概念可参见第

6章。

2.2.7 直接内存

直接内存（Direct Memory）并不是虚拟机运行时数据区的一部分，也不是Java虚拟机规范中定义的内存区域。但是这部分内存也被频繁地使用，而且也可能导致`OutOfMemoryError`异常出现，所以我们放到这里一起讲解。

在JDK 1.4中新加入了NIO（New Input/Output）类，引入了一种基于通道（Channel）与缓冲区（Buffer）的I/O方式，它可以使用Native函数库直接分配堆外内存，然后通过一个存储在Java堆中的`DirectByteBuffer`对象作为这块内存的引用进行操作。这样能在一些场景中显著提高性能，因为避免了在Java堆和Native

堆中来回复制数据。

显然，本机直接内存的分配不会受到Java堆大小的限制，但是，既然是内存，肯定还是会受到本机总内存（包括RAM以及SWAP区或者分页文件）大小以及处理器寻址空间的限制。服务器管理员在配置虚拟机参数时，会根据实际内存设置-Xmx等参数信息，但经常忽略直接内存，使得各个内存区域总和大于物理内存限制（包括物理的和操作系统级的限制），从而导致动态扩展时出现OutOfMemoryError异常。

2.3 HotSpot虚拟机对象探秘

介绍完Java虚拟机的运行时数据区之后，我们大致知道了虚拟机内存的概况，读者了解了内存中放了些什么后，也许就会想更进一步了解这些虚拟机内存中的数据的其他细节，譬如它们是如何创建、如何布局以及如何访问的。对于这样涉及细节的问题，必须把讨论范围限定在具体的虚拟机和集中在某一个内存区域上才有意义。基于实用优先的原则，笔者以常用的虚拟机HotSpot和常用的内存区域Java堆为例，深入探讨HotSpot虚拟机在Java堆中对象分配、布局和访问的全过程。

2.3.1 对象的创建

Java是一门面向对象的编程语言，在Java程序运行过程中无时无刻都有对象被创建出来。在语言层面上，创建对象（例如克隆、反序列化）通常仅仅是一个new关键字而已，而在虚拟机中，对象（文中讨论的对象限于普通Java对象，不包括数组和Class对象等）的创建又是怎样一个过程呢？

虚拟机遇到一条new指令时，首先将去检查这个指令的参数是否能在常量池中定位到一个类的符号引用，并且检查这个符号引用代表的类是否已被加载、解析和初始化过。如果没有，那必须先执行相应的类加载过程，本书第7章将探讨这部分内容的细节。

在类加载检查通过后，接下来虚拟机将为新

生对象分配内存。对象所需内存的大小在类加载完成后便可完全确定（如何确定将在2.3.2节中介绍），为对象分配空间的任务等同于把一块确定大小的内存从Java堆中划分出来。假设Java堆中内存是绝对规整的，所有用过的内存都放在一边，空闲的内存放在另一边，中间放着一个指针作为分界点的指示器，那所分配内存就仅仅是把这个指针向空闲空间那边挪动一段与对象大小相等的距离，这种分配方式称为“指针碰撞”（Bump the Pointer）。如果Java堆中的内存并不是规整的，已使用的内存和空闲的内存相互交错，那就没有办法简单地进行指针碰撞了，虚拟机就必须维护一个列表，记录上哪些内存块是可用的，在分配的时候从列表中找到一块足够大的空间划分给对象实例，并更新列表上的记录，这种分配方

式称为“空闲列表”（Free List）。选择哪种分配方式由Java堆是否规整决定，而Java堆是否规整又由所采用的垃圾收集器是否带有压缩整理功能决定。因此，在使用Serial、ParNew等带Compact过程的收集器时，系统采用的分配算法是指针碰撞，而使用CMS这种基于Mark-Sweep算法的收集器时，通常采用空闲列表。

除如何划分可用空间之外，还有另外一个需要考虑的问题是对象创建在虚拟机中是非常频繁的行为，即使是仅仅修改一个指针所指向的位置，在并发情况下也并不是线程安全的，可能出现正在给对象A分配内存，指针还没来得及修改，对象B又同时使用了原来的指针来分配内存的情况。解决这个问题有两种方案，一种是对分配内存空间的动作进行同步处理——实际上虚拟

机采用CAS配上失败重试的方式保证更新操作的原子性；另一种是把内存分配的动作按照线程划分在不同的空间之中进行，即每个线程在Java堆中预先分配一小块内存，称为本地线程分配缓冲（Thread Local Allocation Buffer, TLAB）。哪个线程要分配内存，就在哪个线程的TLAB上分配，只有TLAB用完并分配新的TLAB时，才需要同步锁定。虚拟机是否使用TLAB，可以通过-XX:+/-UseTLAB参数来设定。

内存分配完成后，虚拟机需要将分配到的内存空间都初始化为零值（不包括对象头），如果使用TLAB，这一工作过程也可以提前至TLAB分配时进行。这一步操作保证了对象的实例字段在Java代码中可以不赋初始值就直接使用，程序能访问到这些字段的数据类型所对应的零值。

接下来，虚拟机要对对象进行必要的设置，例如这个对象是哪个类的实例、如何才能找到类的元数据信息、对象的哈希码、对象的GC分代年龄等信息。这些信息存放在对象的对象头（Object Header）之中。根据虚拟机当前的运行状态的不同，如是否启用偏向锁等，对象头会有不同的设置方式。关于对象头的具体内容，稍后再做详细介绍。

在上面工作都完成之后，从虚拟机的视角来看，一个新的对象已经产生了，但从Java程序的视角来看，对象创建才刚刚开始——<init>方法还没有执行，所有的字段都还为零。所以，一般来说（由字节码中是否跟随invokespecial指令所决定），执行new指令之后会接着执行<init>方

法，把对象按照程序员的意愿进行初始化，这样一个真正可用的对象才算完全产生出来。

下面的代码清单2-1是HotSpot虚拟机

bytecodeInterpreter.cpp中的代码片段（这个解释器实现很少有机会实际使用，因为大部分平台上都使用模板解释器；当代码通过JIT编译器执行时差异就更大了。不过，这段代码用于了解HotSpot的运作过程是没有什么问题的）。

代码清单2-1 HotSpot解释器的代码片段

```
//确保常量池中存放的是已解释的类
if (!constants->
tag_at(index).is_unresolved_klass()) {
    //断言确保是klassOop和instanceKlassOop（这部分
下一节介绍）
    oop entry= (klassOop) *constants->
obj_at_addr(index);
    assert(entry->is_klass(), "Should be
resolved klass");
    klassOop k_entry= (klassOop) entry;
```

```
assert (k_entry->klass_part () ->
oop_is_instance (), "Should be
instanceKlass") ;
    instanceKlass * ik= (instanceKlass*)
k_entry->klass_part () ;
    //确保对象所属类型已经经过初始化阶段
    if (ik->is_initialized () &&ik->
can_be_fastpath_allocated () )
    {
        //取对象长度
        size_t obj_size=ik->size_helper () ;
        oop result=NULL;
        //记录是否需要将对象所有字段置零值
        bool need_zero!=! ZeroTLAB;
        //是否在TLAB中分配对象
        if (UseTLAB) {
            result= (oop) THREAD->
tlab () .allocate (obj_size) ;
        }
        if (result==NULL) {
            need_zero=true;
            //直接在eden中分配对象
            retry:
                HeapWord * compare_to=*Universe: heap () ->
top_addr () ;
                HeapWord * new_top=compare_to+obj_size;
                /*cmpxchg是x86中的CAS指令，这里是一个C++方法，通过
                CAS方式分配空间，如果并发失败，
                转到retry中重试，直至成功分配为止*/
                if (new_top<=*Universe: heap () ->
end_addr ()) {
                    if (Atomic: cmpxchg_ptr (new_top,Universe:
heap () ->top_addr (), compare_to) !=
compare_to) {
```

```
    goto retry;
}
result= (oop) compare_to;
}
}
if (result!=NULL) {
//如果需要，则为对象初始化零值
if (need_zero) {
    HeapWord * to_zero= (HeapWord*)
result+sizeof (oopDesc) /oopSize;
    obj_size-=sizeof (oopDesc) /oopSize;
    if (obj_size>0) {
        memset (to_zero, 0, obj_size *
HeapWordSize);
    }
}
//根据是否启用偏向锁来设置对象头信息
if (UseBiasedLocking) {
    result->set_mark (ik->
prototype_header () );
} else{
    result->set_mark (markOopDesc:
prototype () );
}
result->set_klass_gap (0) ;
result->set_klass (k_entry) ;
//将对象引用入栈，继续执行下一条指令
SET_STACK_OBJECT (result, 0) ;
UPDATE_PC_AND_TOS_AND_CONTINUE (3, 1) ;
}
}
}
```

2.3.2 对象的内存布局

在HotSpot虚拟机中，对象在内存中存储的布局可以分为3块区域：对象头（Header）、实例数据（Instance Data）和对齐填充（Padding）。

HotSpot虚拟机的对象头包括两部分信息，第一部分用于存储对象自身的运行时数据，如哈希码（HashCode）、GC分代年龄、锁状态标志、线程持有的锁、偏向线程ID、偏向时间戳等，这部分数据的长度在32位和64位的虚拟机（未开启压缩指针）中分别为32bit和64bit，官方称它为“Mark Word”。对象需要存储的运行时数据很多，其实已经超出了32位、64位Bitmap结构所能记录的限度，但是对象头信息是与对象自身定义

的数据无关的额外存储成本，考虑到虚拟机的空间效率，Mark Word被设计成一个非固定的数据结构以便在极小的空间内存储尽量多的信息，它会根据对象的状态复用自己的存储空间。例如，在32位的HotSpot虚拟机中，如果对象处于未被锁定的状态下，那么Mark Word的32bit空间中的25bit用于存储对象哈希码，4bit用于存储对象分代年龄，2bit用于存储锁标志位，1bit固定为0，而在其他状态（轻量级锁定、重量级锁定、GC标记、可偏向）下对象的存储内容见表2-1。

表 2-1 HotSpot 虚拟机对象头 Mark Word

| 存储内容 | 标 志 位 | 状 态 |
|----------------------|-------|-----------|
| 对象哈希码、对象分代年龄 | 01 | 未锁定 |
| 指向锁记录的指针 | 00 | 轻量级锁定 |
| 指向重量级锁的指针 | 10 | 膨胀（重量级锁定） |
| 空，不需要记录信息 | 11 | GC 标记 |
| 偏向线程 ID、偏向时间戳、对象分代年龄 | 01 | 可偏向 |

对象头的另外一部分是类型指针，即对象指

向它的类元数据的指针，虚拟机通过这个指针来确定这个对象是哪个类的实例。并不是所有的虚拟机实现都必须在对象数据上保留类型指针，换句话说，查找对象的元数据信息并不一定要经过对象本身，这点将在2.3.3节讨论。另外，如果对象是一个Java数组，那在对象头中还必须有一块用于记录数组长度的数据，因为虚拟机可以通过普通Java对象的元数据信息确定Java对象的大小，但是从数组的元数据中却无法确定数组的大小。

代码清单2-2为HotSpot虚拟机markOop.cpp中的代码（注释）片段，它描述了32bit下Mark Word的存储状态。

代码清单2-2 markOop.cpp片段

```
//Bit-format of an object header (most  
significant first,big endian layout below) :  
    //32 bits:  
    //-----  
    //hash: 25----->| age: 4 biased_lock:  
1 lock: 2 (normal object)  
    //JavaThread*: 23 epoch: 2 age: 4  
biased_lock: 1 lock: 2 (biased object)  
    //size: 32-----  
----->| (CMS free block)  
    //PromotedObject*: 29-----  
>|promo_bits: 3---->| (CMS promoted object)
```

接下来的实例数据部分是对象真正存储的有效信息，也是在程序代码中所定义的各种类型的字段内容。无论是从父类继承下来的，还是在子类中定义的，都需要记录起来。这部分的存储顺序会受到虚拟机分配策略参数（FieldsAllocationStyle）和字段在Java源码中定义顺序的影响。HotSpot虚拟机默认的分配策略为longs/doubles、ints、shorts/chars、

bytes/booleans、oops（Ordinary Object Pointers），从分配策略中可以看出，相同宽度的字段总是被分配到一起。在满足这个前提条件的情况下，在父类中定义的变量会出现在子类之前。如果CompactFields参数值为true（默认为true），那么子类之中较窄的变量也可能会插入到父类变量的空隙之中。

第三部分对齐填充并不是必然存在的，也没有特别的含义，它仅仅起着占位符的作用。由于HotSpot VM的自动内存管理系统要求对象起始地址必须是8字节的整数倍，换句话说，就是对象的大小必须是8字节的整数倍。而对象头部分正好是8字节的倍数（1倍或者2倍），因此，当对象实例数据部分没有对齐时，就需要通过对齐填充来补全。

2.3.3 对象的访问定位

建立对象是为了使用对象，我们的Java程序需要通过栈上的reference数据来操作堆上的具体对象。由于reference类型在Java虚拟机规范中只规定了一个指向对象的引用，并没有定义这个引用应该通过何种方式去定位、访问堆中的对象的具体位置，所以对象访问方式也是取决于虚拟机实现而定的。目前主流的访问方式有使用句柄和直接指针两种。

如果使用句柄访问的话，那么Java堆中将会划分出一块内存来作为句柄池，reference中存储的就是对象的句柄地址，而句柄中包含了对象实例数据与类型数据各自的具体地址信息，如图2-2

所示。




图 2-2 通过句柄访问对象

如果使用直接指针访问，那么Java堆对象的布局中就必须考虑如何放置访问类型数据的相关信息，而reference中存储的直接就是对象地址，如图2-3所示。




图 2-3 通过直接指针访问对象

这两种对象访问方式各有优势，使用句柄来访问的最大好处就是reference中存储的是稳定的句柄地址，在对象被移动（垃圾收集时移动对象是非常普遍的行为）时只会改变句柄中的实例数据指针，而reference本身不需要修改。

使用直接指针访问方式的最大好处就是速度更快，它节省了一次指针定位的时间开销，由于对象的访问在Java中非常频繁，因此这类开销积

少或多后也是一项非常可观的执行成本。就本书讨论的主要虚拟机Sun HotSpot而言，它是使用第二种方式进行对象访问的，但从整个软件开发的范围来看，各种语言和框架使用句柄来访问的情况也十分常见。

2.4 实战：OutOfMemoryError异常

在Java虚拟机规范的描述中，除了程序计数器外，虚拟机内存的其他几个运行时区域都有发生OutOfMemoryError（下文称OOM）异常的可能，本节将通过若干实例来验证异常发生的场景（代码清单2-3～代码清单2-9的几段简单代码），并且会初步介绍几个与内存相关的最基本的虚拟机参数。

本节内容的目的有两个：第一，通过代码验证Java虚拟机规范中描述的各个运行时区域存储的内容；第二，希望读者在工作中遇到实际的内存溢出异常时，能根据异常的信息快速判断是哪个区域的内存溢出，知道什么样的代码可能会导

致这些区域内存溢出，以及出现这些异常后该如何处理。

下文代码的开头都注释了执行时所需要设置的虚拟机启动参数（注释中“VM Args”后面跟着的参数），这些参数对实验的结果有直接影响，读者调试代码的时候千万不要忽略。如果读者使用控制台命令来执行程序，那直接跟在Java命令之后书写就可以。如果读者使用Eclipse IDE，则可以参考图2-4在Debug/Run页签中的设置。




图 2-4 在Eclipse的Debug页签中设置虚拟机参数

下文的代码都是基于Sun公司的HotSpot虚拟机运行的，对于不同公司的不同版本的虚拟机，参数和程序运行的结果可能会有所差别。

2.4.1 Java堆溢出

Java堆用于存储对象实例，只要不断地创建对象，并且保证GC Roots到对象之间有可达路径来避免垃圾回收机制清除这些对象，那么在对象数量到达最大堆的容量限制后就会产生内存溢出异常。

代码清单2-3中代码限制Java堆的大小为20MB，不可扩展（将堆的最小值-Xms参数与最大值-Xmx参数设置为一样即可避免堆自动扩展），通过参数-XX:
+HeapDumpOnOutOfMemoryError可以让虚拟机在出现内存溢出异常时Dump出当前的内存堆转储快照以便事后进行分析^[1]。

代码清单2-3 Java堆内存溢出异常测试

```
/*
*VM Args: -Xms20m-Xmx20m-XX:
+HeapDumpOnOutOfMemoryError
*@author zzm
*/
public class HeapOOM{
    static class OOMObject{
    }
    public static void main (String[]args) {
        List<OOMObject>list=new ArrayList<
        OOMObject> () ;
        while (true) {
            list.add (new OOMObject () ) ;
        }
    }
}
```

运行结果：

```
java.lang.OutOfMemoryError: Java heap space
Dumping heap to java_pid3404.hprof.....
Heap dump file created[22045981 bytes in
0.663 secs]
```

Java堆内存的OOM异常是实际应用中常见的

内存溢出异常情况。当出现Java堆内存溢出时，异常堆栈信息“java.lang.OutOfMemoryError”会跟着进一步提示“Java heap space”。

要解决这个区域的异常，一般的手段是先通过内存映像分析工具（如Eclipse Memory Analyzer）对Dump出来的堆转储快照进行分析，重点是确认内存中的对象是否是必要的，也就是要先分清楚到底是出现了内存泄漏（Memory Leak）还是内存溢出（Memory Overflow）。图2-5显示了使用Eclipse Memory Analyzer打开的堆转储快照文件。




图 2-5 使用Eclipse Memory Analyzer打开的堆转储快照文件

如果是内存泄露，可进一步通过工具查看泄露对象到GC Roots的引用链。于是就能找到泄露对象是通过怎样的路径与GC Roots相关联并导致垃圾收集器无法自动回收它们的。掌握了泄露对

象的类型信息及GC Roots引用链的信息，就可以比较准确地定位出泄露代码的位置。

如果不存在泄露，换句话说，就是内存中的对象确实都还必须存活者，那就应当检查虚拟机的堆参数（-Xmx与-Xms），与机器物理内存对比看是否还可以调大，从代码上检查是否存在某些对象生命周期过长、持有状态时间过长的情况，尝试减少程序运行期的内存消耗。

以上是处理Java堆内存问题的简单思路，处理这些问题所需要的知识、工具与经验是后面3章的主题。

[1]关于堆转储快照文件分析方面的内容，可参见第4章。

2.4.2 虚拟机栈和本地方法栈溢出

由于在HotSpot虚拟机中并不区分虚拟机栈和本地方法栈，因此，对于HotSpot来说，虽然-Xoss参数（设置本地方法栈大小）存在，但实际上也是无效的，栈容量只由-Xss参数设定。关于虚拟机栈和本地方法栈，在Java虚拟机规范中描述了两种异常：

如果线程请求的栈深度大于虚拟机所允许的最大深度，将抛出StackOverflowError异常。

如果虚拟机在扩展栈时无法申请到足够的内存空间，则抛出OutOfMemoryError异常。

这里把异常分成两种情况，看似更加严谨，

但却存在着一些互相重叠的地方：当栈空间无法继续分配时，到底是内存太小，还是已使用的栈空间太大，其本质上只是对同一件事情的两种描述而已。

在笔者的实验中，将实验范围限制于单线程中的操作，尝试了下面两种方法均无法让虚拟机产生`OutOfMemoryError`异常，尝试的结果都是获得`StackOverflowError`异常，测试代码如代码清单2-4所示。

使用`-Xss`参数减少栈内存容量。结果：抛出`StackOverflowError`异常，异常出现时输出的堆栈深度相应缩小。

定义了大量的本地变量，增大此方法帧中本地变量表的长度。结果：抛出`StackOverflowError`

异常时输出的堆栈深度相应缩小。

代码清单2-4 虚拟机栈和本地方法栈OOM 测试（仅作为第1点测试程序）

```
/*
*VM Args: -Xss128k
*@author zzm
*/
public class JavaVMStackSOF{
private int stackLength=1;
public void stackLeak () {
stackLength++;
stackLeak () ;
}
public static void main (String[]args)
throws Throwable{
JavaVMStackSOF oom=new JavaVMStackSOF () ;
try{
oom.stackLeak () ;
}catch (Throwable e) {
System.out.println ("stack
length: "+oom.stackLength) ;
throw e;
}
}
}
```

运行结果：

```
stack length: 2402
Exception in
thread"main"java.lang.StackOverflowError
at
org.fenixsoft.oom.VMStackSOF.leak (VMStackSOF.ja
20)
at
org.fenixsoft.oom.VMStackSOF.leak (VMStackSOF.ja
21)
at
org.fenixsoft.oom.VMStackSOF.leak (VMStackSOF.ja
21)
.....后续异常堆栈信息省略
```

实验结果表明：在单个线程下，无论是由于栈帧太大还是虚拟机栈容量太小，当内存无法分配的时候，虚拟机抛出的都是StackOverflowError异常。

如果测试时不限于单线程，通过不断地建立线程的方式倒是可以产生内存溢出异常，如代码

清单2-5所示。但是这样产生的内存溢出异常与栈空间是否足够大并不存在任何联系，或者准确地说，在这种情况下，为每个线程的栈分配的内存越大，反而越容易产生内存溢出异常。

其实原因不难理解，操作系统分配给每个进程的内存是有限制的，譬如32位的Windows限制为2GB。虚拟机提供了参数来控制Java堆和方法区的这两部分内存的最大值。剩余的内存为2GB（操作系统限制）减去Xmx（最大堆容量），再减去MaxPermSize（最大方法区容量），程序计数器消耗内存很小，可以忽略掉。如果虚拟机进程本身耗费的内存不计算在内，剩下的内存就由虚拟机栈和本地方法栈“瓜分”了。每个线程分配到的栈容量越大，可以建立的线程数量自然就越少，建立线程时就越容易把剩下的

内存耗尽。

这一点读者需要在开发多线程的应用时特别注意，出现StackOverflowError异常时有错误堆栈可以阅读，相对来说，比较容易找到问题的所在。而且，如果使用虚拟机默认参数，栈深度在大多数情况下（因为每个方法压入栈的帧大小并不是一样的，所以只能说在大多数情况下）达到1000~2000完全没有问题，对于正常的方法调用（包括递归），这个深度应该完全够用了。但是，如果是建立过多线程导致的内存溢出，在不能减少线程数或者更换64位虚拟机的情况下，就只能通过减少最大堆和减少栈容量来换取更多的线程。如果没有这方面的处理经验，这种通过“减少内存”的手段来解决内存溢出的方式会比较难以想到。

代码清单2-5 创建线程导致内存溢出异常

```
/*
*VM Args: -Xss2M (这时候不妨设置大些)
*@author zzm
*/
public class JavaVMStackOOM{
private void dontStop () {
while (true) {
}
}
public void stackLeakByThread () {
while (true) {
Thread thread=new Thread (new Runnable () {
@Override
public void run () {
dontStop () ;
}
})
;
thread.start () ;
}
}
public static void main (String[]args)
throws Throwable{
JavaVMStackOOM oom=new JavaVMStackOOM () ;
oom.stackLeakByThread () ;
}
}
```

注意 特别提示一下，如果读者要尝试运行上面这段代码，记得要先保存当前的工作。由于在Windows平台的虚拟机中，Java的线程是映射到操作系统的内核线程上的^[1]，因此上述代码执行时有较大的风险，可能会导致操作系统假死。

运行结果：

```
Exception in  
thread "main" java.lang.OutOfMemoryError: unable  
to create new native thread
```

[1]关于虚拟机线程实现方面的内容可以参考本书第12章。

2.4.3 方法区和运行时常量池溢出

由于运行时常量池是方法区的一部分，因此这两个区域的溢出测试就放在一起进行。前面提到JDK 1.7开始逐步“去永久代”的事情，在此就以测试代码观察一下这件事对程序的实际影响。

`String.intern()` 是一个Native方法，它的作用是：如果字符串常量池中已经包含一个等于此 `String` 对象的字符串，则返回代表池中这个字符串的 `String` 对象；否则，将此 `String` 对象包含的字符串添加到常量池中，并且返回此 `String` 对象的引用。在JDK 1.6及之前的版本中，由于常量池分配在永久代内，我们可以通过`-XX: PermSize`和`-XX: MaxPermSize`限制方法区大小，从而间接限

制其中常量池的容量，如代码清单2-6所示。

代码清单2-6 运行时常量池导致的内存溢出

异常

```
/*
*VM Args: -XX: PermSize=10M-XX:
MaxPermSize=10M
 *@author zzm
 */
public class RuntimeConstantPoolOOM{
    public static void main (String[] args) {
        //使用List保持着常量池引用，避免Full GC回收常量池
行为
        List<String> list=new ArrayList<String>
        ();
        //10MB的PermSize在integer范围内足够产生OOM了
        int i=0;
        while (true) {
            list.add (String.valueOf (i++) .intern ());
        }
    }
}
```

运行结果：

```
Exception in  
thread "main" java.lang.OutOfMemoryError: PermGen  
space  
    at java.lang.String.intern (Native Method)  
    at  
org.fenixsoft.oom.RuntimeConstantPoolOOM.main (R  
18)
```

从运行结果中可以看到，运行时常量池溢出，在`OutOfMemoryError`后面跟随的提示信息是“`PermGen space`”，说明运行时常量池属于方法区（HotSpot虚拟机中的永久代）的一部分。

而使用JDK 1.7运行这段程序就不会得到相同的结果，`while`循环将一直进行下去。关于这个字符串常量池的实现问题，还可以引申出一个更有意思的影响，如代码清单2-7所示。

代码清单2-7 `String.intern()` 返回引用的测试

```
public class RuntimeConstantPoolOOM{  
    public static void main (String[]args) {  
        public static void main (String[]args) {  
            String str1=new StringBuilder ("计算  
机") .append ("软件") .toString () ;  
            System.out.println (str1.intern () ==str1) ;  
            String str2=new  
StringBuilder ("ja") .append ("va") .toString () ;  
            System.out.println (str2.intern () ==str2) ;  
        }  
    }  
}
```

这段代码在JDK 1.6中运行，会得到两个false，而在JDK 1.7中运行，会得到一个true和一个false。产生差异的原因是：在JDK 1.6中，intern（）方法会把首次遇到的字符串实例复制到永久代中，返回的也是永久代中这个字符串实例的引用，而由StringBuilder创建的字符串实例在Java堆上，所以必然不是同一个引用，将返回false。而JDK 1.7（以及部分其他虚拟机，例如

JRockit) 的intern() 实现不会再复制实例，只是在常量池中记录首次出现的实例引用，因此intern() 返回的引用和由StringBuilder创建的那个字符串实例是同一个。对str2比较返回false是因为“java”这个字符串在执行StringBuilder.toString() 之前已经出现过，字符串常量池中已经有它的引用了，不符合“首次出现”的原则，而“计算机软件”这个字符串则是首次出现的，因此返回true。

方法区用于存放Class的相关信息，如类名、访问修饰符、常量池、字段描述、方法描述等。对于这些区域的测试，基本的思路是运行时产生大量的类去填满方法区，直到溢出。虽然直接使用Java SE API也可以动态产生类（如反射时的GeneratedConstructorAccessor和动态代理等），但

在本次实验中操作起来比较麻烦。在代码清单2-8中，笔者借助CGLib^[1]直接操作字节码运行时生成了大量的动态类。

值得特别注意的是，我们在这个例子中模拟的场景并非纯粹是一个实验，这样的应用经常会出现在实际应用中：当前的很多主流框架，如Spring、Hibernate，在对类进行增强时，都会使用到CGLib这类字节码技术，增强的类越多，就需要越大的方法区来保证动态生成的Class可以加载入内存。另外，JVM上的动态语言（例如Groovy等）通常都会持续创建类来实现语言的动态性，随着这类语言的流行，也越来越容易遇到与代码清单2-8相似的溢出场景。

代码清单2-8 借助CGLib使方法区出现内存

溢出异常

```
/*
 *VM Args: -XX: PermSize=10M-XX:
MaxPermSize=10M
 *@author zzm
 */
public class JavaMethodAreaOOM{
    public static void main (String[]args) {
        while (true) {
            Enhancer enhancer=new Enhancer () ;
            enhancer.setSuperclass (OOMObject.class) ;
            enhancer.setUseCache (false) ;
            enhancer.setCallback (new
MethodInterceptor () {
                public Object intercept (Object obj,Method
method,Object[]args,MethodProxy proxy) throws
Throwable{
                    return proxy.invokeSuper (obj,args) ;
                }
            }) ;
            enhancer.create () ;
        }
    }
    static class OOMObject{
    }
}
```

运行结果：

```
Caused by: java.lang.OutOfMemoryError:  
PermGen space  
    at  
java.lang.ClassLoader.defineClass1 (Native  
Method)  
    at  
java.lang.ClassLoader.defineClassCond (ClassLoad  
632)  
    at  
java.lang.ClassLoader.defineClass (ClassLoader.j  
616)  
.....8 more
```

方法区溢出也是一种常见的内存溢出异常，一个类要被垃圾收集器回收掉，判定条件是比较苛刻的。在经常动态生成大量Class的应用中，需要特别注意类的回收状况。这类场景除了上面提到的程序使用了CGLib字节码增强和动态语言之外，常见的还有：大量JSP或动态产生JSP文件的应用（JSP第一次运行时需要编译为Java类）、基于OSGi的应用（即使是同一个类文件，被不同的

加载器加载也会视为不同的类) 等。

[1]CGLib开源项目：<http://cglib.sourceforge.net/>。

2.4.4 本机直接内存溢出

DirectMemory容量可通过-XX:

MaxDirectMemorySize指定，如果不指定，则默认与Java堆最大值（-Xmx指定）一样，代码清单2-9越过了DirectByteBuffer类，直接通过反射获取Unsafe实例进行内存分配（Unsafe类的getUnsafe（）方法限制了只有引导类加载器才会返回实例，也就是设计者希望只有rt.jar中的类才能使用Unsafe的功能）。因为，虽然使用DirectByteBuffer分配内存也会抛出内存溢出异常，但它抛出异常时并没有真正向操作系统申请分配内存，而是通过计算得知内存无法分配，于是手动抛出异常，真正申请分配内存的方法是

unsafe.allocateMemory()。

代码清单2-9 使用unsafe分配本机内存

```
/*
 *VM Args: -Xmx20M-XX:
MaxDirectMemorySize=10M
 *@author zzm
 */
public class DirectMemoryOOM{
    private static final int _1MB=1024*1024;
    public static void main (String[]args)
throws Exception{
    Field
unsafeField=Unsafe.class.getDeclaredFields ()
[0];
    unsafeField.setAccessible (true) ;
    Unsafe unsafe= (Unsafe)
unsafeField.get (null) ;
    while (true) {
        unsafe.allocateMemory (_1MB) ;
    }
}
}
```

运行结果：

Exception in

```
thread"main"java.lang.OutOfMemoryError  
    at sun.misc.Unsafe.allocateMemory (Native  
Method)  
    at  
org.fenixsoft.oom.DMOOM.main (DMOOM.java: 20)
```

由DirectMemory导致的内存溢出，一个明显的特征是在Heap Dump文件中不会看见明显的异常，如果读者发现OOM之后Dump文件很小，而程序中又直接或间接使用了NIO，那就应该考虑检查一下是不是这方面的原因。

2.5 本章小结

通过本章的学习，我们明白了虚拟机中的内存是如何划分的，哪部分区域、什么样的代码和操作可能导致内存溢出异常。虽然Java有垃圾收集机制，但内存溢出异常离我们仍然并不遥远，本章只是讲解了各个区域出现内存溢出异常的原因，第3章将详细讲解Java垃圾收集机制为了避免内存溢出异常的出现都做了哪些努力。

第3章 垃圾收集器与内存分配策略

Java与C++之间有一堵由内存动态分配和垃圾收集技术所围成的“高墙”，墙外面的人想进去，墙里面的人却想出来。

3.1 概述

说起垃圾收集（Garbage Collection,GC），大部分人都把这项技术当做Java语言的伴生产物。事实上，GC的历史比Java久远，1960年诞生于MIT的Lisp是第一门真正使用内存动态分配和垃圾收集技术的语言。当Lisp还在胚胎时期时，人们就在思考GC需要完成的3件事情：

哪些内存需要回收？

什么时候回收？

如何回收？

经过半个多世纪的发展，目前内存的动态分配与内存回收技术已经相当成熟，一切看起来都进入了“自动化”时代，那为什么我们还要去了解GC和内存分配呢？答案很简单：当需要排查各种内存溢出、内存泄漏问题时，当垃圾收集成为系统达到更高并发量的瓶颈时，我们就需要对这些“自动化”的技术实施必要的监控和调节。

把时间从半个多世纪以前拨回到现在，回到我们熟悉的Java语言。第2章介绍了Java内存运行时区域的各个部分，其中程序计数器、虚拟机栈、本地方法栈3个区域随线程而生，随线程而灭；栈中的栈帧随着方法的进入和退出而有条不

素地执行着出栈和入栈操作。每一个栈帧中分配多少内存基本上是在类结构确定下来时就已知的（尽管在运行期会由JIT编译器进行一些优化，但在本章基于概念模型的讨论中，大体上可以认为是编译期可知的），因此这几个区域的内存分配和回收都具备确定性，在这几个区域内就不需要过多考虑回收的问题，因为方法结束或者线程结束时，内存自然就跟着回收了。而Java堆和方法区则不一样，一个接口中的多个实现类需要的内存可能不一样，一个方法中的多个分支需要的内存也可能不一样，我们只有在程序处于运行期间时才能知道会创建哪些对象，这部分内存的分配和回收都是动态的，垃圾收集器所关注的是这部分内存，本章后续讨论中的“内存”分配与回收也仅指这一部分内存。

3.2 对象已死吗

在堆里面存放着Java世界中几乎所有的对象实例，垃圾收集器在对堆进行回收前，第一件事情就是要确定这些对象之中哪些还“存活”着，哪些已经“死去”（即不可能再被任何途径使用的对象）。

3.2.1 引用计数算法

很多教科书判断对象是否存活的算法是这样的：给对象中添加一个引用计数器，每当有一个地方引用它时，计数器值就加1；当引用失效时，计数器值就减1；任何时候计数器为0的对象就是不可能再被使用的。作者面试过很多的应届

生和一些有多年工作经验的开发人员，他们对于这个问题给予的都是这个答案。

客观地说，引用计数算法（Reference Counting）的实现简单，判定效率也很高，在大部分情况下它都是一个不错的算法，也有一些比较著名的应用案例，例如微软公司的COM（Component Object Model）技术、使用ActionScript 3的FlashPlayer、Python语言和在游戏脚本领域被广泛应用的Squirrel中都使用了引用计数算法进行内存管理。但是，至少主流的Java虚拟机里面没有选用引用计数算法来管理内存，其中最主要的原因是它很难解决对象之间相互循环引用的问题。

举个简单的例子，请看代码清单3-1中的

testGC（）方法：对象objA和objB都有字段instance，赋值令objA.instance=objB及objB.instance=objA，除此之外，这两个对象再无任何引用，实际上这两个对象已经不可能再被访问，但是它们因为互相引用着对方，导致它们的引用计数都不为0，于是引用计数算法无法通知GC收集器回收它们。

代码清单3-1 引用计数算法的缺陷

```
/*
 *testGC（）方法执行后，objA和objB会不会被GC呢？
 *@author zzm
 */
public class ReferenceCountingGC{
    public Object instance=null;
    private static final int _1MB=1024*1024;
    /**
     *这个成员属性的唯一意义就是占点内存，以便能在GC日志中看清楚是否被回收过
     */
    private byte[]bigSize=new byte[2*_1MB];
    public static void testGC () {
```

```
    ReferenceCountingGC objA=new
ReferenceCountingGC () ;
    ReferenceCountingGC objB=new
ReferenceCountingGC () ;
    objA.instance=objB;
    objB.instance=objA;
    objA=null;
    objB=null;
//假设在这行发生GC,objA和objB是否能被回收?
System.gc () ;
}
}
```

运行结果:

```
[F u l l G C (S y s t e m) [T e n u r e d: 0
K->210K (10240K), 0.0149142secs]4603K->210K (19456K), [Perm: 2999K->
2999K (21248K)], 0.0150007 secs][Times:
user=0.01 sys=0.00, real=0.02 secs]
    Heap
        def new generation total 9216K, used
82K[0x0000000055e0000, 0x000000005fe0000,
0x000000005fe0000)
        Eden space 8192K,
1%used[0x0000000055e0000, 0x0000000055f4850,
0x000000005de0000)
        from space 1024K,
0%used[0x000000005de0000, 0x000000005de0000,
0x000000005ee0000)
        to space 1024K, 0%used[0x000000005ee0000,
```

```
0x0000000005ee0000, 0x0000000005fe0000)
    tenured generation total 10240K, used
210K[0x0000000005fe0000, 0x00000000069e0000,
0x00000000069e0000)
    the space 10240K,
2%used[0x0000000005fe0000, 0x0000000006014a18,
0x0000000006014c00, 0x00000000069e0000)
    compacting perm gen total 21248K, used
3016K[0x00000000069e0000, 0x0000000007ea0000,
0x000000000bde0000)
    the space 21248K,
14%used[0x00000000069e0000, 0x0000000006cd2398,
0x0000000006cd2400, 0x0000000007ea0000)
    No shared spaces configured.
```

从运行结果中可以清楚看到，GC日志中包含“4603K->210K”，意味着虚拟机并没有因为这两个对象互相引用就不回收它们，这也从侧面说明虚拟机并不是通过引用计数算法来判断对象是否存活的。

3.2.2 可达性分析算法

在主流的商用程序语言（Java、C#，甚至包括前面提到的古老的Lisp）的主流实现中，都是称通过可达性分析（Reachability Analysis）来判定对象是否存活的。这个算法的基本思路就是通过一系列的称为“GC Roots”的对象作为起始点，从这些节点开始向下搜索，搜索所走过的路径称为引用链（Reference Chain），当一个对象到GC Roots没有任何引用链相连（用图论的话来说，就是从GC Roots到这个对象不可达）时，则证明此对象是不可用的。如图3-1所示，对象object 5、object 6、object 7虽然互相有关联，但是它们到GC Roots是不可达的，所以它们将会被判定为是

可回收的对象。




图 3-1 可达性分析算法判定对象是否可回收

在Java语言中，可作为GC Roots的对象包括下面几种：

虚拟机栈（栈帧中的本地变量表）中引用的对象。

方法区中类静态属性引用的对象。

方法区中常量引用的对象。

本地方法栈中JNI（即一般说的Native方法）

引用的对象。

3.2.3 再谈引用

无论是通过引用计数算法判断对象的引用数量，还是通过可达性分析算法判断对象的引用链是否可达，判定对象是否存活都与“引用”有关。在JDK 1.2以前，Java中的引用的定义很传统：如果reference类型的数据中存储的数值代表的是另外一块内存的起始地址，就称这块内存代表着一个引用。这种定义很纯粹，但是太过狭隘，一个对象在这种定义下只有被引用或者没有被引用两种状态，对于如何描述一些“食之无味，弃之可惜”的对象就显得无能为力。我们希望能描述这样一类对象：当内存空间还足够时，则能保留在内存之中；如果内存空间在进行垃圾收集后还是

非常紧张，则可以抛弃这些对象。很多系统的缓存功能都符合这样的应用场景。

在JDK 1.2之后，Java对引用的概念进行了扩充，将引用分为强引用（Strong Reference）、软引用（Soft Reference）、弱引用（Weak Reference）、虚引用（Phantom Reference）4种，这4种引用强度依次逐渐减弱。

强引用就是指在程序代码之中普遍存在的，类似“`Object obj=new Object ()`”这类的引用，只要强引用还存在，垃圾收集器永远不会回收掉被引用的对象。

软引用是用来描述一些还有用但并非必需的对象。对于软引用关联着的对象，在系统将要发生内存溢出异常之前，将会把这些对象列进回收

范围之中进行第二次回收。如果这次回收还没有足够的内存，才会抛出内存溢出异常。在JDK 1.2之后，提供了SoftReference类来实现软引用。

弱引用也是用来描述非必需对象的，但是它的强度比软引用更弱一些，被弱引用关联的对象只能生存到下一次垃圾收集发生之前。当垃圾收集器工作时，无论当前内存是否足够，都会回收掉只被弱引用关联的对象。在JDK 1.2之后，提供了WeakReference类来实现弱引用。

虚引用也称为幽灵引用或者幻影引用，它是最弱的一种引用关系。一个对象是否有虚引用的存在，完全不会对其生存时间构成影响，也无法通过虚引用来取得一个对象实例。为一个对象设置虚引用关联的唯一目的就是能在这个对象被收

集器回收时收到一个系统通知。在JDK 1.2之后，提供了PhantomReference类来实现虚引用。

3.2.4 生存还是死亡

即使在可达性分析算法中不可达的对象，也并非是“非死不可”的，这时候它们暂时处于“缓刑”阶段，要真正宣告一个对象死亡，至少要经历两次标记过程：如果对象在进行可达性分析后发现没有与GC Roots相连接的引用链，那它将会被第一次标记并且进行一次筛选，筛选的条件是此对象是否有必要执行`finalize()`方法。当对象没有覆盖`finalize()`方法，或者`finalize()`方法已经被虚拟机调用过，虚拟机将这两种情况都视为“没有必要执行”。

如果这个对象被判定为有必要执行`finalize()`方法，那么这个对象将会放置在一个

叫做F-Queue的队列之中，并在稍后由一个由虚拟机自动建立的、低优先级的Finalizer线程去执行它。这里所谓的“执行”是指虚拟机会触发这个方法，但并不承诺会等待它运行结束，这样做的原因是，如果一个对象在finalize（）方法中执行缓慢，或者发生了死循环（更极端的情况），将很可能会导致F-Queue队列中其他对象永久处于等待，甚至导致整个内存回收系统崩溃。

finalize（）方法是对象逃脱死亡命运的最后一次机会，稍后GC将对F-Queue中的对象进行第二次小规模的标记，如果对象要在finalize（）中成功拯救自己——只要重新与引用链上的任何一个对象建立关联即可，譬如把自己（this关键字）赋值给某个类变量或者对象的成员变量，那在第二次标记时它将被移除出“即将回收”的集合；如果

对象这时候还没有逃脱，那基本上它就真的被回收了。从代码清单3-2中我们可以看到一个对象的 finalize () 被执行，但是它仍然可以存活。

代码清单3-2 一次对象自我拯救的演示

```
/*
 *此代码演示了两点：
 *1.对象可以在被GC时自我拯救。
 *2.这种自救的机会只有一次，因为一个对象的
finalize () 方法最多只会被系统自动调用一次
 *@author zzm
 */
public class FinalizeEscapeGC{
    public static FinalizeEscapeGC
SAVE_HOOK=null;
    public void isAlive () {
        System.out.println ("yes,i am still
alive: ") ;
    }
    @Override
    protected void finalize () throws Throwable{
        super.finalize ();
        System.out.println ("finalize mehtod
executed! ") ;
        FinalizeEscapeGC.SAVE_HOOK=this;
    }
    public static void main (String[]args)
```

```
throws Throwable{
    SAVE_HOOK=new FinalizeEscapeGC();
    //对象第一次成功拯救自己
    SAVE_HOOK=null;
    System.gc();
    //因为finalize方法优先级很低，所以暂停0.5秒以等待
它
    Thread.sleep(500);
    if(SAVE_HOOK!=null){
        SAVE_HOOK.isAlive();
    }else{
        System.out.println("no,i am dead:()");
    }
    //下面这段代码与上面的完全相同，但是这次自救却失败了
    SAVE_HOOK=null;
    System.gc();
    //因为finalize方法优先级很低，所以暂停0.5秒以等待
它
    Thread.sleep(500);
    if(SAVE_HOOK!=null){
        SAVE_HOOK.isAlive();
    }else{
        System.out.println("no,i am dead:()");
    }
}
```

运行结果：

```
finalize method executed!
yes,i am still alive:)
```

no, i am dead: (

从代码清单3-2的运行结果可以看出，
SAVE_HOOK对象的finalize（）方法确实被GC收
集器触发过，并且在被收集前成功逃脱了。

另外一个值得注意的地方是，代码中有两段
完全一样的代码片段，执行结果却是一次逃脱成
功，一次失败，这是因为任何一个对象的
finalize（）方法都只会被系统自动调用一次，如
果对象面临下一次回收，它的finalize（）方法不
会被再次执行，因此第二段代码的自救行动失败
了。

需要特别说明的是，上面关于对象死亡时
finalize（）方法的描述可能带有悲情的艺术色
彩，笔者并不鼓励大家使用这种方法来拯救对

象。相反，笔者建议大家尽量避免使用它，因为它不是C/C++中的析构函数，而是Java刚诞生时为了使C/C++程序员更容易接受它所做出的一个妥协。它的运行代价高昂，不确定性大，无法保证各个对象的调用顺序。有些教材中描述它适合做“关闭外部资源”之类的工作，这完全是对这个方法用途的一种自我安慰。`finalize()`能做的所有工作，使用try-finally或者其他方式都可以做得更好、更及时，所以笔者建议大家完全可以忘掉Java语言中有这个方法的存在。

3.2.5 回收方法区

很多人认为方法区（或者HotSpot虚拟机中的永久代）是没有垃圾收集的，Java虚拟机规范中确实说过可以不要求虚拟机在方法区实现垃圾收集，而且在方法区中进行垃圾收集的“性价比”一般比较低：在堆中，尤其是在新生代中，常规应用进行一次垃圾收集一般可以回收70%~95%的空间，而永久代的垃圾收集效率远低于此。

永久代的垃圾收集主要回收两部分内容：废弃常量和无用的类。回收废弃常量与回收Java堆中的对象非常类似。以常量池中字面量的回收为例，假如一个字符串“abc”已经进入了常量池中，但是当前系统没有任何一个String对象是叫

做“abc”的，换句话说，就是没有任何String对象引用常量池中的“abc”常量，也没有其他地方引用了这个字面量，如果这时发生内存回收，而且必要的话，这个“abc”常量就会被系统清理出常量池。常量池中的其他类（接口）、方法、字段的符号引用也与此类似。

判定一个常量是否是“废弃常量”比较简单，而要判定一个类是否是“无用的类”的条件则相对苛刻许多。类需要同时满足下面3个条件才能算是“无用的类”：

该类所有的实例都已经被回收，也就是Java堆中不存在该类的任何实例。

加载该类的ClassLoader已经被回收。

该类对应的java.lang.Class对象没有在任何地方被引用，无法在任何地方通过反射访问该类的方法。

虚拟机可以对满足上述3个条件的无用类进行回收，这里说的仅仅是“可以”，而并不是和对象一样，不使用了就必然会回收。是否对类进行回收，HotSpot虚拟机提供了-Xnoclassgc参数进行控制，还可以使用-verbose: class以及-XX: +TraceClassLoading、-XX: +TraceClassUnLoading查看类加载和卸载信息，其中-verbose: class和-XX: +TraceClassLoading可以在Product版的虚拟机中使用，-XX: +TraceClassUnLoading参数需要FastDebug版的虚拟机支持。

在大量使用反射、动态代理、CGLib等

ByteCode框架、动态生成JSP以及OSGi这类频繁自定义ClassLoader的场景都需要虚拟机具备类卸载的功能，以保证永久代不会溢出。

3.3 垃圾收集算法

由于垃圾收集算法的实现涉及大量的程序细节，而且各个平台的虚拟机操作内存的方法又各不相同，因此本节不打算过多地讨论算法的实现，只是介绍几种算法的思想及其发展过程。

3.3.1 标记-清除算法

最基础的收集算法是“标记-清除”（Mark-Sweep）算法，如同它的名字一样，算法分为“标记”和“清除”两个阶段：首先标记出所有需要回收的对象，在标记完成后统一回收所有被标记的对象，它的标记过程其实在前一节讲述对象标记判定时已经介绍过了。之所以说它是最基础的收集

算法，是因为后续的收集算法都是基于这种思路并对其不足进行改进而得到的。它的主要不足有两个：一个是效率问题，标记和清除两个过程的效率都不高；另一个是空间问题，标记清除之后会产生大量不连续的内存碎片，空间碎片太多可能会导致以后在程序运行过程中需要分配较大对象时，无法找到足够的连续内存而不得不提前触发另一次垃圾收集动作。标记—清除算法的执行过程如图3-2所示。




图 3-2 “标记-清除” 算法示意图



3.3.2 复制算法

为了解决效率问题，一种称为“复制”（Copying）的收集算法出现了，它将可用内存按容量划分为大小相等的两块，每次只使用其中的一块。当这一块的内存用完了，就将还存活著的对象复制到另外一块上面，然后再把已使用过的内存空间一次清理掉。这样使得每次都是对整个半区进行内存回收，内存分配时也就不用考虑内存碎片等复杂情况，只要移动堆顶指针，按顺序分配内存即可，实现简单，运行高效。只是这种算法的代价是将内存缩小为了原来的一半，未免太高了一点。复制算法的执行过程如图3-3所示。




图 3-3 复制算法示意图

现在的商业虚拟机都采用这种收集算法来回收新生代，IBM公司的专门研究表明，新生代中的对象98%是“朝生夕死”的，所以并不需要按照1:1的比例来划分内存空间，而是将内存分为一块较大的Eden空间和两块较小的Survivor空间，每次使用Eden和其中一块Survivor^[1]。当回收时，将Eden和Survivor中还存活着的对象一次性地复制到另外一块Survivor空间上，最后清理掉Eden和

刚才用过的Survivor空间。HotSpot虚拟机默认Eden和Survivor的大小比例是8:1，也就是每次新生代中可用内存空间为整个新生代容量的90%（80%+10%），只有10%的内存会被“浪费”。当然，98%的对象可回收只是一般场景下的数据，我们没有办法保证每次回收都只有不多于10%的对象存活，当Survivor空间不够用时，需要依赖其他内存（这里指老年代）进行分配担保(Handle Promotion)。

内存的分配担保就好比我们去银行借款，如果我们信誉很好，在98%的情况下都能按时偿还，于是银行可能会默认我们下一次也能按时按量地偿还贷款，只需要有一个担保人能保证如果我不能还款时，可以从他的账户扣钱，那银行就认为没有风险了。内存的分配担保也一样，如果

另外一块Survivor空间没有足够空间存放上一次新生代收集下来的存活对象时，这些对象将直接通过分配担保机制进入老年带。关于对新生代进行分配担保的内容，在本章稍后在讲解垃圾收集器执行规则时还会再详细讲解。

[1]这里需要说明一下，在HotSpot中的这种分代方式从最初就是这种布局，与IBM的研究并没有什么实际联系。本书列举IBM的研究只是为了说明这种分代布局的意义所在。

3.3.3 标记-整理算法

复制收集算法在对象存活率较高时就要进行较多的复制操作，效率将会变低。更关键的是，如果不想要浪费50%的空间，就需要有额外的空间进行分配担保，以应对被使用的内存中所有对象都100%存活的极端情况，所以在老年代一般不能直接选用这种算法。

根据老年代的特点，有人提出了另外一种“标记-整理”（Mark-Compact）算法，标记过程仍然与“标记-清除”算法一样，但后续步骤不是直接对可回收对象进行清理，而是让所有存活的对象都向一端移动，然后直接清理掉端边界以外的内存，“标记-整理”算法的示意图如图3-4所示。




图 3-4 “标记-整理” 算法示意图

3.3.4 分代收集算法

当前商业虚拟机的垃圾收集都采用“分代收集”（Generational Collection）算法，这种算法并没有什么新的思想，只是根据对象存活周期的不同将内存划分为几块。一般是把Java堆分为新生代和老年代，这样就可以根据各个年代的特点采用最适当的收集算法。在新生代中，每次垃圾收集时都发现有大批对象死去，只有少量存活，那就选用复制算法，只需要付出少量存活对象的复制成本就可以完成收集。而老年代中因为对象存活率高、没有额外空间对它进行分配担保，就必须使用“标记—清理”或者“标记—整理”算法来进行回收。

3.4 HotSpot的算法实现

3.2 节和3.3节从理论上介绍了对象存活判定算法和垃圾收集算法，而在HotSpot虚拟机上实现这些算法时，必须对算法的执行效率有严格的考量，才能保证虚拟机高效运行。

3.4.1 枚举根节点

从可达性分析中从GC Roots节点找引用链这个操作为例，可作为GC Roots的节点主要在全局性的引用（例如常量或类静态属性）与执行上下文（例如栈帧中的本地变量表）中，现在很多应用仅仅方法区就有数百兆，如果要逐个检查这里面的引用，那么必然会消耗很多时间。

另外，可达性分析对执行时间的敏感还体现在GC停顿上，因为这项分析工作必须在一个能确保一致性的快照中进行——这里“一致性”的意思是指在整个分析期间整个执行系统看起来就像被冻结在某个时间点上，不可以出现分析过程中对象引用关系还在不断变化的情况，该点不满足的话分析结果准确性就无法得到保证。这点是导致GC进行时必须停顿所有Java执行线程（Sun将这件事情称为“Stop The World”）的其中一个主要原因，即使是在号称（几乎）不会发生停顿的CMS收集器中，枚举根节点时也是必须要停顿的。

由于目前的主流Java虚拟机使用的都是准确式GC（这个概念在第1章介绍Exact VM对Classic VM的改进时讲过），所以当执行系统停顿下来后，并不需要一个不漏地检查完所有执行上下文

和全局的引用位置，虚拟机应当是有办法直接得知哪些地方存放着对象引用。在HotSpot的实现中，是使用一组称为OopMap的数据结构来达到这个目的的，在类加载完成的时候，HotSpot就把对象内什么偏移量上是什么类型的数据计算出来，在JIT编译过程中，也会在特定的位置记录下栈和寄存器中哪些位置是引用。这样，GC在扫描时就可以直接得知这些信息了。下面的代码清单3-3是HotSpot Client VM生成的一段

String.hashCode () 方法的本地代码，可以看到在0x026eb7a9处的call指令有OopMap记录，它指明了EBX寄存器和栈中偏移量为16的内存区域中各有一个普通对象指针（Ordinary Object Pointer）的引用，有效范围为从call指令开始直到0x026eb730（指令流的起始位置）

+142 (OopMap记录的偏移量) =0x026eb7be, 即
hlt指令为止。

代码清单3-3 String.hashCode() 方法编译后的本地代码

```
[Verified Entry Point]
0x026eb730: mov%eax, -0x8000 (%esp)
.....
; ImplicitNullCheckStub slow case
0x026eb7a9: call 0x026e83e0
; OopMap{ebx=Oop[16]=Oop off=142}
; *caload
; -java.lang.String: hashCode@48 (line 1489)
; {runtime_call}
0x026eb7ae: push$0x83c5c18
; {external_word}
0x026eb7b3: call 0x026eb7b8
0x026eb7b8: pusha
0x026eb7b9: call 0x0822bec0; {runtime_call}
0x026eb7be: hlt
```

3.4.2 安全点

在OopMap的协助下，HotSpot可以快速且准确地完成GC Roots枚举，但一个很现实的问题随之而来：可能导致引用关系变化，或者说OopMap内容变化的指令非常多，如果为每一条指令都生成对应的OopMap，那将会需要大量的额外空间，这样GC的空间成本将会变得很高。

实际上，HotSpot也的确没有为每条指令都生成OopMap，前面已经提到，只是在“特定的位置”记录了这些信息，这些位置称为安全点（SafePoint），即程序执行时并非在所有地方都能停顿下来开始GC，只有在到达安全点时才能暂停。SafePoint的选定既不能太少以致于让GC等待

时间太长，也不能过于频繁以致于过分增大运行时的负荷。所以，安全点的选定基本上是以程序“是否具有让程序长时间执行的特征”为标准进行选定的——因为每条指令执行的时间都非常短暂，程序不太可能因为指令流长度太长这个原因而过长时间运行，“长时间执行”的最明显特征就是指令序列复用，例如方法调用、循环跳转、异常跳转等，所以具有这些功能的指令才会产生 Safepoint。

对于Sefepoint，另一个需要考虑的问题是如何在GC发生时让所有线程（这里不包括执行JNI调用的线程）都“跑”到最近的安全点上再停顿下来。这里有两种方案可供选择：抢先式中断（Preemptive Suspension）和主动式中断（Voluntary Suspension），其中抢先式中断不需

要线程的执行代码主动去配合，在GC发生时，首先把所有线程全部中断，如果发现有线程中断的地方不在安全点上，就恢复线程，让它“跑”到安全点上。现在几乎没有虚拟机实现采用抢先式中断来暂停线程从而响应GC事件。

而主动式中断的思想是当GC需要中断线程的时候，不直接对线程操作，仅仅简单地设置一个标志，各个线程执行时主动去轮询这个标志，发现中断标志为真时就自己中断挂起。轮询标志的地方和安全点是重合的，另外再加上创建对象需要分配内存的地方。下面代码清单3-4中的test指令是HotSpot生成的轮询指令，当需要暂停线程时，虚拟机把0x160100的内存页设置为不可读，线程执行到test指令时就会产生一个自陷异常信号，在预先注册的异常处理器中暂停线程实现等

待，这样一条汇编指令便完成安全点轮询和触发线程中断。

代码清单3-4 轮询指令

```
0x01b6d627: call 0x01b2b210; OopMap{[60]=Oop  
off=460}  
; *invokeinterface size  
; -Client1: main@113 (line 23)  
; {virtual_call}  
0x01b6d62c: nop  
; OopMap{[60]=Oop off=461}  
; *if_icmplt  
; -Client1: main@118 (line 23)  
0x01b6d62d: test%eax, 0x160100; {poll}  
0x01b6d633: mov 0x50(%esp), %esi  
0x01b6d637: cmp%eax, %esi
```

3.4.3 安全区域

使用Safepoint似乎已经完美地解决了如何进入GC的问题，但实际情况却并不一定。Safepoint机制保证了程序执行时，在不太长的时间内就会遇到可进入GC的Safepoint。但是，程序“不执行”的时候呢？所谓的程序不执行就是没有分配CPU时间，典型的例子就是线程处于Sleep状态或者Blocked状态，这时候线程无法响应JVM的中断请求，“走”到安全的地方去中断挂起，JVM也显然不太可能等待线程重新被分配CPU时间。对于这种情况，就需要安全区域（Safe Region）来解决。

安全区域是指在一段代码片段之中，引用关

系不会发生变化。在这个区域中的任意地方开始GC都是安全的。我们也可以把Safe Region看做是被扩展了的Safepoint。

在线程执行到Safe Region中的代码时，首先标识自己已经进入了Safe Region，那样，当在这段时间里JVM要发起GC时，就不用管标识自己为Safe Region状态的线程了。在线程要离开Safe Region时，它要检查系统是否已经完成了根节点枚举（或者是整个GC过程），如果完成了，那线程就继续执行，否则它就必须等待直到收到可以安全离开Safe Region的信号为止。

到此，笔者简要地介绍了HotSpot虚拟机如何去发起内存回收的问题，但是虚拟机如何具体地进行内存回收动作仍然未涉及，因为内存回收如

何进行是由虚拟机所采用的GC收集器决定的，而通常虚拟机中往往不止有一种GC收集器。下面继续来看HotSpot中有哪些GC收集器。

3.5 垃圾收集器

如果说收集算法是内存回收的方法论，那么垃圾收集器就是内存回收的具体实现。Java虚拟机规范中对垃圾收集器应该如何实现并没有任何规定，因此不同的厂商、不同版本的虚拟机所提供的垃圾收集器都可能会有很大差别，并且一般都会提供参数供用户根据自己的应用特点和要求组合出各个年代所使用的收集器。这里讨论的收集器基于JDK 1.7 Update 14之后的HotSpot虚拟机（在这个版本中正式提供了商用的G1收集器，之前G1仍处于实验状态），这个虚拟机包含的所有收集器如图3-5所示。




图 3-5 HotSpot虚拟机的垃圾收集器^[1]

图3-5展示了7种作用于不同分代的收集器，如果两个收集器之间存在连线，就说明它们可以搭配使用。虚拟机所处的区域，则表示它是属于

新生代收集器还是老年年代收集器。接下来笔者将逐一介绍这些收集器的特性、基本原理和使用场景，并重点分析CMS和G1这两款相对复杂的收集器，了解它们的部分运作细节。

在介绍这些收集器各自的特性之前，我们先来明确一个观点：虽然我们是在对各个收集器进行比较，但并非为了挑选出一个最好的收集器。因为直到现在为止还没有最好的收集器出现，更加没有万能的收集器，所以我们选择的只是对具体应用最合适的选择。这点不需要多加解释就能证明：如果有一种放之四海皆准、任何场景下都适用的完美收集器存在，那HotSpot虚拟机就没必要实现那么多不同的收集器了。

3.5.1 Serial收集器

Serial收集器是最基本、发展历史最悠久的收集器，曾经（在JDK 1.3.1之前）是虚拟机新生代收集的唯一选择。大家看名字就会知道，这个收集器是一个单线程的收集器，但它的“单线程”的意义并不仅仅说明它只会使用一个CPU或一条收集线程去完成垃圾收集工作，更重要的是在它进行垃圾收集时，必须暂停其他所有的工作线程，直到它收集结束。“Stop The World”这个名字也许听起来很酷，但这项工作实际上是由虚拟机在后台自动发起和自动完成的，在用户不可见的情况下把用户正常工作的线程全部停掉，这对很多应用来说都是难以接受的。读者不妨试想一下，要是你的计算机每运行一个小时就会暂停响应5分钟，你会有什么样的心情？图3-6示意了Serial/Serial Old收集器的运行过程。




图 3-6 Serial/Serial Old 收集器运行示意图

对于“Stop The World”带给用户的不良体验，虚拟机的设计者们表示完全理解，但也表示非常委屈：“你妈妈在给你打扫房间的时候，肯定也会让你老老实实地在椅子上或者房间外待着，如果她一边打扫，你一边乱扔纸屑，这房间还能打扫完？”这确实是一个合情合理的矛盾，虽然垃圾收集这项工作听起来和打扫房间属于一个性质的，但实际上肯定还要比打扫房间复杂得多啊！

从JDK 1.3开始，一直到现在最新的JDK 1.7，HotSpot虚拟机开发团队为消除或者减少工作线程因内存回收而导致停顿的努力一直在进行

着，从Serial收集器到Parallel收集器，再到Concurrent Mark Sweep（CMS）乃至GC收集器的最前沿成果Garbage First（G1）收集器，我们看到了一个个越来越优秀（也越来越复杂）的收集器的出现，用户线程的停顿时间在不断缩短，但是仍然没有办法完全消除（这里暂不包括RTSJ中的收集器）。寻找更优秀的垃圾收集器的工作仍在继续！

写到这里，笔者似乎已经把Serial收集器描述成一个“老而无用、食之无味弃之可惜”的鸡肋了，但实际上到现在为止，它依然是虚拟机运行在Client模式下的默认新生代收集器。它也有着优于其他收集器的地方：简单而高效（与其他收集器的单线程比），对于限定单个CPU的环境来说，Serial收集器由于没有线程交互的开销，专

心做垃圾收集自然可以获得最高的单线程收集效率。在用户的桌面应用场景中，分配给虚拟机管理的内存一般来说不会很大，收集几十兆甚至一两百兆的新生代（仅仅是新生代使用的内存，桌面应用基本上不会再大了），停顿时间完全可以控制在几十毫秒最多一百多毫秒以内，只要不是频繁发生，这点停顿是可以接受的。所以，Serial收集器对于运行在Client模式下的虚拟机来说是一个很好的选择。

[1] 图片来源：

http://blogs.sun.com/jonthecollector/entry/our_collec

3.5.2 ParNew收集器

ParNew收集器其实就是Serial收集器的多线程版本，除了使用多条线程进行垃圾收集之外，其余行为包括Serial收集器可用的所有控制参数（例如：-XX: SurvivorRatio、-XX: PretenureSizeThreshold、-XX: HandlePromotionFailure等）、收集算法、Stop The World、对象分配规则、回收策略等都与Serial收集器完全一样，在实现上，这两种收集器也共用了相当多的代码。ParNew收集器的工作过程如图3-7所示。




图 3-7 ParNew/Serial Old收集器运行示意图

ParNew收集器除了多线程收集之外，其他与Serial收集器相比并没有太多创新之处，但它却是许多运行在Server模式下的虚拟机中首选的新一代收集器，其中有一个与性能无关但很重要的原因是，除了Serial收集器外，目前只有它能与CMS收集器配合工作。在JDK 1.5时期，HotSpot推出了一款在强交互应用中几乎可认为有划时代意义的垃圾收集器——CMS收集器（Concurrent Mark Sweep，本节稍后将详细介绍这款收集器），这款收集器是HotSpot虚拟机中第一款真正意义上的并发（Concurrent）收集器，它第一次实现了让垃圾收集线程与用户线程（基本上）同时工作，用前面那个例子的话来说，就是做到了在你的妈妈打扫房间的时候你还能一边往地上扔纸

屑。

不幸的是，CMS作为老年代的收集器，却无法与JDK 1.4.0中已经存在的新生代收集器Parallel Scavenge配合工作^[1]，所以在JDK 1.5中使用CMS来收集老年代的时候，新生代只能选择ParNew或者Serial收集器中的一个。ParNew收集器也是使用-XX: +UseConcMarkSweepGC选项后的默认新生代收集器，也可以使用-XX: +UseParNewGC选项来强制指定它。

ParNew收集器在单CPU的环境中绝对不会比Serial收集器更好的效果，甚至由于存在线程交互的开销，该收集器在通过超线程技术实现的两个CPU的环境中都不能百分之百地保证可以超越Serial收集器。当然，随着可以使用的CPU的数

量的增加，它对于GC时系统资源的有效利用还是很有好处的。它默认开启的收集线程数与CPU的数量相同，在CPU非常多（譬如32个，现在CPU动辄就4核加超线程，服务器超过32个逻辑CPU的情况越来越多了）的环境下，可以使用-XX:ParallelGCThreads参数来限制垃圾收集的线程数。

注意 从ParNew收集器开始，后面还会接触到几款并发和并行的收集器。在大家可能产生疑惑之前，有必要先解释两个名词：并发和并行。这两个名词都是并发编程中的概念，在谈论垃圾收集器的上下文语境中，它们可以解释如下。

- 并行（Parallel）：指多条垃圾收集线程并行工作，但此时用户线程仍然处于等待状态。

- 并发（Concurrent）：指用户线程与垃圾收集线程同时执行（但不一定是并行的，可能会交替执行），用户程序在继续运行，而垃圾收集程序运行于另一个CPU上。

[1] Parallel Scavenge收集器及后面提到的G1收集器都没有使用传统的GC收集器代码框架，而另外独立实现，其余几种收集器则共用了部分的框架代码，详细内容可参考：

http://blogs.sun.com/jonthecollector/entry/our_collec

3.5.3 Parallel Scavenge收集器

Parallel Scavenge收集器是一个新生代收集器，它也是使用复制算法的收集器，又是并行的多线程收集器……看上去和ParNew都一样，那它有什么特别之处呢？

Parallel Scavenge收集器的特点是它的关注点与其他收集器不同，CMS等收集器的关注点是尽可能地缩短垃圾收集时用户线程的停顿时间，而Parallel Scavenge收集器的目标则是达到一个可控制的吞吐量（Throughput）。所谓吞吐量就是CPU用于运行用户代码的时间与CPU总消耗时间的比值，即吞吐量=运行用户代码时间/（运行用户代码时间+垃圾收集时间），虚拟机总共运行了100

分钟，其中垃圾收集花掉1分钟，那吞吐量就是99%。

停顿时间越短就越适合需要与用户交互的程序，良好的响应速度能提升用户体验，而高吞吐量则可以高效率地利用CPU时间，尽快完成程序的运算任务，主要适合在后台运算而不需要太多交互的任务。

Parallel Scavenge收集器提供了两个参数用于精确控制吞吐量，分别是控制最大垃圾收集停顿时间的-XX: MaxGCPauseMillis参数以及直接设置吞吐量大小的-XX: GCTimeRatio参数。

MaxGCPauseMillis参数允许的值是一个大于0的毫秒数，收集器将尽可能地保证内存回收花费的时间不超过设定值。不过大家不要认为如果把

这个参数的值设置得稍小一点就能使得系统的垃圾收集速度变得更快，GC停顿时间缩短是以牺牲吞吐量和新生代空间来换取的：系统把新生代调小一些，收集300MB新生代肯定比收集500MB快吧，这也直接导致垃圾收集发生得更频繁一些，原来10秒收集一次、每次停顿100毫秒，现在变成5秒收集一次、每次停顿70毫秒。停顿时间的的确在下降，但吞吐量也降下来了。

GCTimeRatio参数的值应当是一个大于0且小于100的整数，也就是垃圾收集时间占总时间的比率，相当于吞吐量的倒数。如果把这个参数设置为19，那允许的最大GC时间就占总时间的5%（即 $1/(1+19)$ ），默认值为99，就是允许最大1%（即 $1/(1+99)$ ）的垃圾收集时间。

由于与吞吐量关系密切，Parallel Scavenge收集器也经常称为“吞吐量优先”收集器。除上述两个参数之外，Parallel Scavenge收集器还有一个参数-XX: +UseAdaptiveSizePolicy值得关注。这是一个开关参数，当这个参数打开之后，就不需要手工指定新生代的大小（-Xmn）、Eden与Survivor区的比例（-XX: SurvivorRatio）、晋升老年代对象年龄（-XX: PretenureSizeThreshold）等细节参数了，虚拟机会根据当前系统的运行情况收集性能监控信息，动态调整这些参数以提供最合适的停顿时间或者最大的吞吐量，这种调节方式称为GC自适应的调节策略（GC Ergonomics）^[1]。如果读者对于收集器运作原来不太了解，手工优化存在困难的时候，使用Parallel Scavenge收集器配合自适应调节策略，把

内存管理的调优任务交给虚拟机去完成将是一个不错的选择。只需要把基本的内存数据设置好（如-Xmx设置最大堆），然后使用MaxGCPauseMillis参数（更关注最大停顿时间）或GCTimeRatio（更关注吞吐量）参数给虚拟机设立一个优化目标，那具体细节参数的调节工作就由虚拟机完成了。自适应调节策略也是Parallel Scavenge收集器与ParNew收集器的一个重要区别。

[1] 官方介绍：

<http://download.oracle.com/javase/1.5.0/docs/guide/ergonomics.html>。

3.5.4 Serial Old收集器

Serial Old是Serial收集器的老年代版本，它同样是一个单线程收集器，使用“标记-整理”算法。这个收集器的主要意义也是在于给Client模式下的虚拟机使用。如果在Server模式下，那么它主要还有两大用途：一种用途是在JDK 1.5以及之前的版本中与Parallel Scavenge收集器搭配使用^[1]，另一种用途就是作为CMS收集器的后备预案，在并发收集发生Concurrent Mode Failure时使用。这两点都将在后面的内容中详细讲解。

Serial Old收集器的工作过程如图3-8所示。




图 3-8 Serial/Serial Old收集器运行示意图

[1]需要说明一下，Parallel Scavenge收集器架构中本身有PS MarkSweep收集器来进行老年代收集，并非直接使用了Serial Old收集器，但是这个PS MarkSweep收集器与Serial Old的实现非常接近，所以在官方的许多资料中都是直接以Serial Old代替PS MarkSweep进行讲解，这里笔者也采用这种方式。

3.5.5 Parallel Old收集器

Parallel Old是Parallel Scavenge收集器的老年代版本，使用多线程和“标记-整理”算法。这个收集器是在JDK 1.6中才开始提供的，在此之前，新生代的Parallel Scavenge收集器一直处于比较尴尬的状态。原因是，如果新生代选择了Parallel Scavenge收集器，老年代除了Serial Old（PS MarkSweep）收集器外别无选择（还记得上面说过Parallel Scavenge收集器无法与CMS收集器配合工作吗？）。由于老年代Serial Old收集器在服务端应用性能上的“拖累”，使用了Parallel Scavenge收集器也未必能在整体应用上获得吞吐量最大化的效果，由于单线程的老年代收集中无法充分利用多线程的优势，所以Parallel Old收集器的性能并不理想。

用服务器多CPU的处理能力，在老年代很大而且硬件比较高级的环境中，这种组合的吞吐量甚至还不一定有ParNew加CMS的组合“给力”。

直到Parallel Old收集器出现后，“吞吐量优先”收集器终于有了比较名副其实的应用组合，在注重吞吐量以及CPU资源敏感的场合，都可以优先考虑Parallel Scavenge加Parallel Old收集器。Parallel Old收集器的工作过程如图3-9所示。




图 3-9 Parallel Scavenge/Parallel Old收集器运行示意图

3.5.6 CMS收集器

CMS（Concurrent Mark Sweep）收集器是一种以获取最短回收停顿时间为为目标的收集器。目前很大一部分的Java应用集中在互联网站或者B/S系统的服务端上，这类应用尤其重视服务的响应速度，希望系统停顿时间最短，以给用户带来较好的体验。CMS收集器就非常符合这类应用的需求。

从名字（包含“Mark Sweep”）上就可以看出，CMS收集器是基于“标记—清除”算法实现的，它的运作过程相对于前面几种收集器来说更复杂一些，整个过程分为4个步骤，包括：

初始标记（CMS initial mark）

并发标记（CMS concurrent mark）

重新标记（CMS remark）

并发清除（CMS concurrent sweep）

其中，初始标记、重新标记这两个步骤仍然需要“Stop The World”。初始标记仅仅只是标记一下GC Roots能直接关联到的对象，速度很快，并发标记阶段就是进行GC Roots Tracing的过程，而重新标记阶段则是为了修正并发标记期间因用户程序继续运作而导致标记产生变动的那一部分对象的标记记录，这个阶段的停顿时间一般会比初始标记阶段稍长一些，但远比并发标记的时间短。

由于整个过程中耗时最长的并发标记和并发清除过程收集器线程都可以与用户线程一起工作，所以，从总体上来说，CMS收集器的内存回收过程是与用户线程一起并发执行的。通过图3-10可以比较清楚地看到CMS收集器的运作步骤中并发和需要停顿的时间。




图 3-10 Concurrent Mark Sweep 收集器运行示意
图

CMS是一款优秀的收集器，它的主要优点在名字上已经体现出来了：并发收集、低停顿，Sun公司的一些官方文档中也称之为并发低停顿

收集器（Concurrent Low Pause Collector）。但是 CMS还远达不到完美的程度，它有以下3个明显的缺点：

CMS收集器对CPU资源非常敏感。其实，面向并发设计的程序都对CPU资源比较敏感。在并发阶段，它虽然不会导致用户线程停顿，但是会因为占用了一部分线程（或者说CPU资源）而导致应用程序变慢，总吞吐量会降低。CMS默认启动的回收线程数是 $(\text{CPU数量}+3)/4$ ，也就是当CPU在4个以上时，并发回收时垃圾收集线程不少于25%的CPU资源，并且随着CPU数量的增加而下降。但是当CPU不足4个（譬如2个）时，CMS对用户程序的影响就可能变得很大，如果本来CPU负载就比较大，还分出一半的运算能力去执行收集器线程，就可能导致用户程序的执行速度

忽然降低了50%，其实也让人无法接受。为了应付这种情况，虚拟机提供了一种称为“增量式并发收集器”（Incremental Concurrent Mark Sweep/i-CMS）的CMS收集器变种，所做的事情和单CPU年代PC机操作系统使用抢占式来模拟多任务机制的思想一样，就是在并发标记、清理的时候让GC线程、用户线程交替运行，尽量减少GC线程的独占资源的时间，这样整个垃圾收集的过程会更长，但对用户程序的影响就会显得少一些，也就是速度下降没有那么明显。实践证明，增量时的CMS收集器效果很一般，在目前版本中，i-CMS已经被声明为“deprecated”，即不再提倡用户使用。

CMS收集器无法处理浮动垃圾（Floating Garbage），可能出现“Concurrent Mode Failure”失

败而导致另一次Full GC的产生。由于CMS并发清理阶段用户线程还在运行着，伴随程序运行自然就还会有新的垃圾不断产生，这一部分垃圾出现在标记过程之后，CMS无法在当次收集中处理掉它们，只好留待下一次GC时再清理掉。这一部分垃圾就称为“浮动垃圾”。也是由于在垃圾收集阶段用户线程还需要运行，那也就还需要预留有足够的内存空间给用户线程使用，因此CMS收集器不能像其他收集器那样等到老年代几乎完全被填满了再进行收集，需要预留一部分空间提供并发收集时的程序运作使用。在JDK 1.5的默认设置下，CMS收集器当老年代使用了68%的空间后就会被激活，这是一个偏保守的设置，如果在应用中老年代增长不是太快，可以适当调高参数-XX: CMSInitiatingOccupancyFraction的值来提高

触发百分比，以便降低内存回收次数从而获取更好的性能，在JDK 1.6中，CMS收集器的启动阈值已经提升至92%。要是CMS运行期间预留的内存无法满足程序需要，就会出现一次“Concurrent Mode Failure”失败，这时虚拟机将启动后备预案：临时启用Serial Old收集器来重新进行老年代的垃圾收集，这样停顿时间就很长了。所以说参数-XX: CMSInitiatingOccupancyFraction设置得太高很容易导致大量“Concurrent Mode Failure”失败，性能反而降低。

还有最后一个缺点，在本节开头说过，CMS是一款基于“标记—清除”算法实现的收集器，如果读者对前面这种算法介绍还有印象的话，就可能想到这意味着收集结束时会有大量空间碎片产生。空间碎片过多时，将会给大对象分配带来很

大麻烦，往往会出现老年代还有很大空间剩余，但是无法找到足够大的连续空间来分配当前对象，不得不提前触发一次Full GC。为了解决这个问题，CMS收集器提供了一个-XX：

+UseCMSCompactAtFullCollection开关参数（默认就是开启的），用于在CMS收集器顶不住要进行FullGC时开启内存碎片的合并整理过程，内存整理的过程是无法并发的，空间碎片问题没有了，但停顿时间不得不变长。虚拟机设计者还提供了另外一个参数-XX：

CMSFullGCsBeforeCompaction，这个参数是用于设置执行多少次不压缩的Full GC后，跟着来一次带压缩的（默认值为0，表示每次进入Full GC时都进行碎片整理）。

3.5.7 G1收集器

G1（Garbage-First）收集器是当今收集器技术发展的最前沿成果之一，早在JDK 1.7刚刚确立项目目标，Sun公司给出的JDK 1.7 RoadMap里面，它就被视为JDK 1.7中HotSpot虚拟机的一个重要进化特征。从JDK 6u14中开始就有Early Access版本的G1收集器供开发人员实验、试用，由此开始G1收集器的“Experimental”状态持续了数年时间，直至JDK 7u4，Sun公司才认为它达到足够成熟的商用程度，移除了“Experimental”的标识。

G1是一款面向服务端应用的垃圾收集器。HotSpot开发团队赋予它的使命是（在比较长期

的) 未来可以替换掉JDK 1.5中发布的CMS收集器。与其他GC收集器相比，G1具备如下特点。

并行与并发： G1能充分利用多CPU、多核环境下的硬件优势，使用多个CPU（CPU或者CPU核心）来缩短Stop-The-World停顿的时间，部分其他收集器原本需要停顿Java线程执行的GC动作，G1收集器仍然可以通过并发的方式让Java程序继续执行。

分代收集： 与其他收集器一样，分代概念在G1中依然得以保留。虽然G1可以不需要其他收集器配合就能独立管理整个GC堆，但它能够采用不同的方式去处理新创建的对象和已经存活了一段时间、熬过多次GC的旧对象以获取更好的收集效果。

空间整合：与CMS的“标记—清理”算法不同，G1从整体来看是基于“标记—整理”算法实现的收集器，从局部（两个Region之间）上来看是基于“复制”算法实现的，但无论如何，这两种算法都意味着G1运作期间不会产生内存空间碎片，收集后能提供规整的可用内存。这种特性有利于程序长时间运行，分配大对象时不会因为无法找到连续内存空间而提前触发下一次GC。

可预测的停顿：这是G1相对于CMS的另一大优势，降低停顿时间是G1和CMS共同的关注点，但G1除了追求低停顿外，还能建立可预测的停顿时间模型，能让使用者明确指定在一个长度为M毫秒的时间片段内，消耗在垃圾收集上的时间不得超过N毫秒，这几乎已经是实时Java（RTSJ）的垃圾收集器的特征了。

在G1之前的其他收集器进行收集的范围都是整个新生代或者老年代，而G1不再是这样。使用G1收集器时，Java堆的内存布局就与其他收集器有很大差别，它将整个Java堆划分为多个大小相等的独立区域（Region），虽然还保留有新生代和老年代的概念，但新生代和老年代不再是物理隔离的了，它们都是一部分Region（不需要连续）的集合。

G1收集器之所以能建立可预测的停顿时间模型，是因为它可以有计划地避免在整个Java堆中进行全区域的垃圾收集。G1跟踪各个Region里面的垃圾堆积的价值大小（回收所获得的空间大小以及回收所需时间的经验值），在后台维护一个优先列表，每次根据允许的收集时间，优先回收

价值最大的Region（这也就是Garbage-First名称的来由）。这种使用Region划分内存空间以及有优先级的区域回收方式，保证了G1收集器在有限的时间内可以获取尽可能高的收集效率。

G1把内存“化整为零”的思路，理解起来似乎很容易，但其中的实现细节却远远没有想象中那样简单，否则也不会从2004年Sun实验室发表第一篇G1的论文开始直到今天（将近10年时间）才开发出G1的商用版。笔者以一个细节为例：把Java堆分为多个Region后，垃圾收集是否就真的能以Region为单位进行了？听起来顺理成章，再仔细想想就很容易发现问题所在：Region不可能是孤立的。一个对象分配在某个Region中，它并非只能被本Region中的其他对象引用，而是可以与整个Java堆任意的对象发生引用关系。那在做

可达性判定确定对象是否存活的时候，岂不是还得扫描整个Java堆才能保证准确性？这个问题其实并非在G1中才有，只是在G1中更加突出而已。在以前的分代收集中，新生代的规模一般都比老年代要小许多，新生代的收集也比老年代要频繁许多，那回收新生代中的对象时也面临相同的问题，如果回收新生代时也不得不同时扫描老年代的话，那么Minor GC的效率可能下降不少。

在G1收集器中，Region之间的对象引用以及其他收集器中的新生代与老年代之间的对象引用，虚拟机都是使用Remembered Set来避免全堆扫描的。G1中每个Region都有一个与之对应的Remembered Set，虚拟机发现程序在对Reference类型的数据进行写操作时，会产生一个Write Barrier暂时中断写操作，检查Reference引用的对

象是否处于不同的Region之中（在分代的例子中就是检查是否老年代中的对象引用了新生代中的对象），如果是，便通过CardTable把相关引用信息记录到被引用对象所属的Region的Remembered Set之中。当进行内存回收时，在GC根节点的枚举范围内加入Remembered Set即可保证不对全堆扫描也不会有遗漏。

如果不计算维护Remembered Set的操作，G1收集器的运作大致可划分为以下几个步骤：

初始标记（Initial Marking）

并发标记（Concurrent Marking）

最终标记（Final Marking）

筛选回收（Live Data Counting and

Evacuation)

对CMS收集器运作过程熟悉的读者，一定已经发现G1的前几个步骤的运作过程和CMS有很多相似之处。初始标记阶段仅仅只是标记一下GC Roots能直接关联到的对象，并且修改TAMS（Next Top at Mark Start）的值，让下一阶段用户程序并发运行时，能在正确可用的Region中创建新对象，这阶段需要停顿线程，但耗时很短。并发标记阶段是从GC Root开始对堆中对象进行可达性分析，找出存活的对象，这阶段耗时较长，但可与用户程序并发执行。而最终标记阶段则是为了修正在并发标记期间因用户程序继续运作而导致标记产生变动的那一部分标记记录，虚拟机将这段时间对象变化记录在线程Remembered Set Logs里面，最终标记阶段需要把

Remembered Set Logs的数据合并到Remembered Set中，这阶段需要停顿线程，但是可并行执行。最后在筛选回收阶段首先对各个Region的回收价值和成本进行排序，根据用户所期望的GC停顿时间来制定回收计划，从Sun公司透露出来的信息来看，这个阶段其实也可以做到与用户程序一起并发执行，但是因为只回收一部分Region，时间是用户可控制的，而且停顿用户线程将大幅提高收集效率。通过图3-11可以比较清楚地看到G1收集器的运作步骤中并发和需要停顿的阶段。




图 3-11 G1收集器运行示意图

由于目前G1成熟版本的发布时间还很短，G1收集器几乎可以说还没有经过实际应用的考验，网络上关于G1收集器的性能测试也非常贫乏，到目前为止，笔者还没有搜索到有关的生产环境下的性能测试报告。强调“生产环境下的测试报告”是因为对于垃圾收集器来说，仅仅通过简单的Java代码写个Microbenchmark程序来创建、移除Java对象，再用-XX: +PrintGCDetails等参数来查看GC日志是很难做到准确衡量其性能的。因此，关于G1收集器的性能部分，笔者引用了Sun实验室的论文《Garbage-First Garbage Collection》中的一段测试数据。

Sun给出的Benchmark的执行硬件为Sun V880服务器（8×750MHz UltraSPARC III CPU、32G内存、Solaris 10操作系统）。执行软件有两个，分

别为SPECjbb（模拟商业数据库应用，堆中存活对象约为165MB，结果反映吐量和最长事务处理时间）和telco（模拟电话应答服务应用，堆中存活对象约为100MB，结果反映系统能支持的最大吞吐量）。为了便于对比，还收集了一组使用ParNew+CMS收集器的测试数据。所有测试都配置为与CPU数量相同的8条GC线程。

在反应停顿时间的软实时目标（Soft Real-Time Goal）测试中，横向是两个测试软件的时间片段配置，单位是毫秒，以（X/Y）的形式表示，代表在Y毫秒内最大允许GC时间为X毫秒（对于CMS收集器，无法直接指定这个目标，通过调整分代大小的方式大致模拟）。纵向是两个软件在对应配置和不同的Java堆容量下的测试结果，V%、avgV%和wV%分别代表的含义如下。

V%：表示测试过程中，软实时目标失败的概率，软实时目标失败即某个时间片段中实际GC时间超过了允许的最大GC时间。

avgV%：表示在所有实际GC时间超标的时间片段里，实际GC时间超过最大GC时间的平均百分比（实际GC时间减去允许最大GC时间，再除以总时间片段）。

wV%：表示在测试结果最差的时间片段里，实际GC时间占用执行时间的百分比。

测试结果见表3-1。

表 3-1 测试结果

| Benchmark/ configuration | | Soft real-time goal compliance statistics by Heap Size | | | | | | | | |
|-----------------------------|-----------|--|--------|---------|--------|--------|---------|-------|--------|---------|
| | | V% | avgV% | wV% | V% | avgV% | wV% | V% | avgV% | wV% |
| SPECjbb | | 512M | | | 640M | | | 768M | | |
| Gl | (100/200) | 4.29% | 36.40% | 100.00% | 1.73% | 12.83% | 63.31% | 1.68% | 10.94% | 69.67% |
| Gl | (150/300) | 1.20% | 5.95% | 15.29% | 1.51% | 4.01% | 20.80% | 1.78% | 3.38% | 8.96% |
| Gl | (150/450) | 1.63% | 4.40% | 14.32% | 3.14% | 2.34% | 6.53% | 1.23% | 1.53% | 3.28% |
| Gl | (150/600) | 2.63% | 2.90% | 5.38% | 3.66% | 2.45% | 8.39% | 2.09% | 2.54% | 8.65% |
| Gl | (200/300) | 0.00% | 0.00% | 0.00% | 0.34% | 0.72% | 0.72% | 0.00% | 0.00% | 0.00% |
| CMS | (150/450) | 23.93% | 82.14% | 100.00% | 13.44% | 67.72% | 100.00% | 5.72% | 28.19% | 100.00% |
| Telco | | 384M | | | 512M | | | 640M | | |
| Gl | (50/100) | 0.34% | 8.92% | 35.48% | 0.16% | 9.09% | 48.08% | 0.11% | 12.10% | 38.57% |
| Gl | (75/150) | 0.08% | 11.90% | 19.99% | 0.08% | 5.60% | 7.47% | 0.19% | 3.81% | 9.15% |
| Gl | (75/225) | 0.44% | 2.90% | 10.45% | 0.15% | 3.31% | 3.74% | 0.50% | 1.04% | 2.07% |
| Gl | (75/300) | 0.65% | 2.55% | 8.76% | 0.42% | 0.57% | 1.07% | 0.63% | 1.07% | 2.91% |
| Gl | (100/400) | 0.57% | 1.79% | 6.04% | 0.29% | 0.37% | 0.54% | 0.44% | 1.52% | 2.73% |
| CMS | (75/225) | 0.78% | 35.05% | 100.00% | 0.54% | 32.83% | 100.00% | 0.60% | 26.39% | 100.00% |

从表3-1所示的结果可见，对于telco来说，软实时目标失败的概率控制在0.5%~0.7%之间，SPECjbb就要差一些，但也控制在2%~5%之间，概率随着(X/Y)的比值减小而增加。另一方面，失败时超出允许GC时间的比值随着总时间片段增加而变小（分母变大了），在(100/200)、512MB的配置下，G1收集器出现了某些时间片段下100%时间在进行GC的最坏情况。而相比之

下，CMS收集器的测试结果就要差很多，3种Java堆容量下都出现了100%时间进行GC的情况。

在吞吐量测试中，测试数据取3次SPECjbb和15次telco的平均结果如图3-12所示。在SPECjbb的应用下，各种配置下的G1收集器表现出了一致的行为，吞吐量看起来只与允许最大GC时间成正比关系，而在telco的应用中，不同配置对吞吐量的影响则显得很微弱。与CMS收集器的吞吐量对比可以看到，在SPECjbb测试中，在堆容量超过768MB时，CMS收集器有5%~10%的优势，而在telco测试中，CMS的优势则要小一些，只有3%~4%左右。




图 3-12 吞吐量测试结果

在更大规模的生产环境下，笔者引用一段在 StackOverflow.com 上看到的经验与读者分享：“我在一个真实的、较大规模的应用程序中使用过 G1：大约分配有 60~70GB 内存，存活对象大约在 20~50GB 之间。服务器运行 Linux 操作系统，JDK 版本为 6u22。G1 与 PS/PS Old 相比，最大的好处是停顿时间更加可控、可预测，如果我在 PS 中设置一个很低的最大允许 GC 时间，譬如期望 50 毫秒内完成 GC（-XX: MaxGCPauseMillis=50），

但在65GB的Java堆下有可能得到的直接结果是一次长达30秒至2分钟的漫长的Stop-The-World过程；而G1与CMS相比，虽然它们都立足于低停顿时间，CMS仍然是我现在的选择，但是随着Oracle对G1的持续改进，我相信G1会是最终的胜利者。如果你现在采用的收集器没有出现问题，那就没有任何理由现在去选择G1，如果你的应用追求低停顿，那G1现在已经可以作为一个可尝试的选择，如果你的应用追求吞吐量，那G1并不会为你带来什么特别的好处”。

3.5.8 理解GC日志

阅读GC日志是处理Java虚拟机内存问题的基础技能，它只是一些人为确定的规则，没有太多技术含量。在本书的第1版中没有专门讲解如何阅读分析GC日志，为此作者收到许多读者来信，反映对此感到困惑，因此专门增加本节内容来讲解如何理解GC日志。

每一种收集器的日志形式都是由它们自身的实现所决定的，换而言之，每个收集器的日志格式都可以不一样。但虚拟机设计者为了方便用户阅读，将各个收集器的日志都维持一定的共性，例如以下两段典型的GC日志：

33.125: [GC [DefNew: 3324K->152K (3712K) ,

```
0.0025925 secs] 3324K->152K (11904K), 0.0031680
secs]
   1 0 0.6 6 7: [F u l l G C[T e n u r e d: 0
K->2 1 0 K (1 0 2 4 0 K), 0.0 1 4 9 1 4 2 s e
c s]4603K->210K (19456K), [Perm: 2999K->
2999K (21248K)], 0.0150007 secs] [Times:
user=0.01 sys=0.00, real=0.02 secs]
```

最前面的数字“33.125:”和“100.667:”代表了GC发生的时间，这个数字的含义是从Java虚拟机启动以来经过的秒数。

GC日志开头的“[GC”和“[Full GC”说明了这次垃圾收集的停顿类型，而不是用来区分新生代GC还是老年代GC的。如果有“Full”，说明这次GC是发生了Stop-The-World的，例如下面这段新生代收集器ParNew的日志也会出现“[Full GC”（这一般是因为出现了分配担保失败之类的问题，所以才导致STW）。如果是调用System.gc（）方法所触发的收集，那么在这里将

显示“[Full GC (System) ”。

```
[Full GC 283.736: [ParNew: 261599K->  
261599K (261952K), 0.0000288 secs]
```

接下来的“[DefNew”、“[Tenured”、“[Perm”表示GC发生的区域，这里显示的区域名称与使用的GC收集器是密切相关的，例如上面样例所使用的Serial收集器中的新生代名为“Default New Generation”，所以显示的是“[DefNew”。如果是ParNew收集器，新生代名称就会变为“[ParNew”，意为“Parallel New Generation”。如果采用Parallel Scavenge收集器，那它配套的新生代称为“PSYoungGen”，老年代和永久代同理，名称也是由收集器决定的。

后方括号内部的“3324K->

152K (3712K) ”含义是“GC前该内存区域已使用容量->GC后该内存区域已使用容量（该内存区域总容量）”。而在方括号之外的“3324K->152K (11904K) ”表示“GC前Java堆已使用容量->GC后Java堆已使用容量（Java堆总容量）”。

再往后，“0.0025925 secs”表示该内存区域GC所占用的时间，单位是秒。有的收集器会给出更具体的时间数据，如“[Times: user=0.01 sys=0.00, real=0.02 secs]”，这里面的user、sys和real与Linux的time命令所输出的时间含义一致，分别代表用户态消耗的CPU时间、内核态消耗的CPU事件和操作从开始到结束所经过的墙钟时间（Wall Clock Time）。CPU时间与墙钟时间的区别是，墙钟时间包括各种非运算的等待耗时，例如等待磁盘I/O、等待线程阻塞，而CPU时间不包

括这些耗时，但当系统有多CPU或者多核的话，
多线程操作会叠加这些CPU时间，所以读者看到
user或sys时间超过real时间是完全正常的。

3.5.9 垃圾收集器参数总结

JDK 1.7中的各种垃圾收集器到此已全部介绍完毕，在描述过程中提到了很多虚拟机非稳定的运行参数，在表3-2中整理了这些参数供读者实践时参考。

表 3-2 垃圾收集相关的常用参数

| 参 数 | 描 述 |
|------------------------|--|
| UseSerialGC | 虚拟机运行在 Client 模式下的默认值，打开此开关后，使用 Serial + Serial Old 的收集器组合进行内存回收 |
| UseParNewGC | 打开此开关后，使用 ParNew + Serial Old 的收集器组合进行内存回收 |
| UseConcMarkSweepGC | 打开此开关后，使用 ParNew + CMS + Serial Old 的收集器组合进行内存回收。Serial Old 收集器将作为 CMS 收集器出现 Concurrent Mode Failure 失败后的后备收集器使用 |
| UseParallelGC | 虚拟机运行在 Server 模式下的默认值，打开此开关后，使用 Parallel Scavenge + Serial Old (PS MarkSweep) 的收集器组合进行内存回收 |
| UseParallelOldGC | 打开此开关后，使用 Parallel Scavenge + Parallel Old 的收集器组合进行内存回收 |
| SurvivorRatio | 新生代中 Eden 区域与 Survivor 区域的容量比值，默认为 8，代表 Eden : Survivor=8 : 1 |
| PretenureSizeThreshold | 直接晋升到老年代的对象大小，设置这个参数后，大于这个参数的对象将直接在老年代分配 |
| MaxTenuringThreshold | 晋升到老年代的对象年龄。每个对象在坚持过一次 Minor GC 之后，年龄就增加 1，当超过这个参数值时就进入老年代 |
| UseAdaptiveSizePolicy | 动态调整 Java 堆中各个区域的大小以及进入老年代的年龄 |
| HandlePromotionFailure | 是否允许分配担保失败，即老年代的剩余空间不足以应付新生代的整个 Eden 和 Survivor 区的所有对象都存活的极端情况 |
| ParallelGCThreads | 设置并行 GC 时进行内存回收的线程数 |

(续)

| 参 数 | 描 述 |
|--------------------------------|---|
| GCTimeRatio | GC 时间占总时间的比率，默认值为 99，即允许 1% 的 GC 时间。仅在使用 Parallel Scavenge 收集器时生效 |
| MaxGCPauseMillis | 设置 GC 的最大停顿时间。仅在使用 Parallel Scavenge 收集器时生效 |
| CMSInitiatingOccupancyFraction | 设置 CMS 收集器在老年代空间被使用多少后触发垃圾收集。默认值为 68%，仅在使用 CMS 收集器时生效 |
| UseCMSCompactAtFullCollection | 设置 CMS 收集器在完成垃圾收集后是否要进行一次内存碎片整理。仅在使用 CMS 收集器时生效 |
| CMSFullGCsBeforeCompaction | 设置 CMS 收集器在进行若干次垃圾收集后再启动一次内存碎片整理。仅在使用 CMS 收集器时生效 |

3.6 内存分配与回收策略

Java技术体系中所提倡的自动内存管理最终可以归结为自动化地解决了两个问题：给对象分配内存以及回收分配给对象的内存。关于回收内存这一点，我们已经使用了大量篇幅去介绍虚拟机中的垃圾收集器体系以及运作原理，现在我们再一起来探讨一下给对象分配内存的那点事儿。

对象的内存分配，往大方向讲，就是在堆上分配（但也可能经过JIT编译后被拆散为标量类型并间接地栈上分配^[1]），对象主要分配在新生代的Eden区上，如果启动了本地线程分配缓冲，将按线程优先在TLAB上分配。少数情况下也可能会直接分配在老年代中，分配的规则并不是百分

之百固定的，其细节取决于当前使用的是哪一种垃圾收集器组合，还有虚拟机中与内存相关的参数的设置。

接下来我们将会讲解几条最普遍的内存分配规则，并通过代码去验证这些规则。本节下面的代码在测试时使用Client模式虚拟机运行，没有手工指定收集器组合，换句话说，验证的是在使用Serial/Serial Old收集器下（ParNew/Serial Old收集器组合的规则也基本一致）的内存分配和回收的策略。读者不妨根据自己项目中使用的收集器写一些程序去验证一下使用其他几种收集器的内存分配策略。

3.6.1 对象优先在Eden分配

大多数情况下，对象在新生代Eden区中分配。当Eden区没有足够空间进行分配时，虚拟机将发起一次Minor GC。

虚拟机提供了-XX: +PrintGCDetails这个收集器日志参数，告诉虚拟机在发生垃圾收集行为时打印内存回收日志，并且在进程退出的时候输出当前的内存各区域分配情况。在实际应用中，内存回收日志一般是打印到文件后通过日志工具进行分析，不过本实验的日志并不多，直接阅读就能看得很清楚。

代码清单3-5的testAllocation（）方法中，尝试分配3个2MB大小和1个4MB大小的对象，在运行时通过-Xms20M、-Xmx20M、-Xmn10M这3个参数限制了Java堆大小为20MB，不可扩展，其中

10MB分配给新生代，剩下的10MB分配给老年代。-XX: SurvivorRatio=8决定了新生代中Eden区与一个Survivor区的空间比例是8:1，从输出的结果也可以清晰地看到“eden space 8192K、from space 1024K、to space 1024K”的信息，新生代总可用空间为9216KB（Eden区+1个Survivor区的总容量）。

执行testAllocation()中分配allocation4对象的语句时会发生一次Minor GC，这次GC的结果是新生代6651KB变为148KB，而总内存占用量则几乎没有减少（因为allocation1、allocation2、allocation3三个对象都是存活的，虚拟机几乎没有找到可回收的对象）。这次GC发生的原因是给allocation4分配内存的时候，发现Eden已经被占用了6MB，剩余空间已不足以分配allocation4所

需的4MB内存，因此发生Minor GC。GC期间虚拟机又发现已有的3个2MB大小的对象全部无法放入Survivor空间（Survivor空间只有1MB大小），所以只好通过分配担保机制提前转移到老年年代去。

这次GC结束后，4MB的allocation4对象顺利分配在Eden中，因此程序执行完的结果是Eden占用4MB（被allocation4占用），Survivor空闲，老年年代被占用6MB（被allocation1、allocation2、allocation3占用）。通过GC日志可以证实这一点。

注意 作者多次提到的Minor GC和Full GC有什么不一样吗？

新生代GC（Minor GC）：指发生在新生代

的垃圾收集动作，因为Java对象大多都具备朝生夕灭的特性，所以Minor GC非常频繁，一般回收速度也比较快。

老年代GC（Major GC/Full GC）：指发生在老年代的GC，出现了Major GC，经常会伴随至少一次的Minor GC（但非绝对的，在Parallel Scavenge收集器的收集策略里就有直接进行Major GC的策略选择过程）。Major GC的速度一般会比Minor GC慢10倍以上。

代码清单3-5 新生代Minor GC

```
private static final int _1MB=1024*1024;  
/**  
 *VM参数: -verbose: gc-Xms20M-Xmx20M-Xmn10M-  
XX: +PrintGCDetails  
-XX: SurvivorRatio=8  
*/  
public static void testAllocation () {  
byte[] allocation1, allocation2, allocation3,
```

```
allocation4;
    allocation1=new byte[2*_1MB];
    allocation2=new byte[2*_1MB];
    allocation3=new byte[2*_1MB];
    allocation4=new byte[4*_1MB]; //出现一次Minor
GC
}
```

运行结果：

```
[GC [DefNew: 6651K->148K (9216K), 0.0070106
secs] 6651K->6292K (19456K),
 0.0070426 secs] [Times: user=0.00 sys=0.00,
real=0.00 secs]
  Heap
    def new generation total 9216K, used
4326K[0x029d0000, 0x033d0000, 0x033d0000)
      eden space 8192K, 51%used[0x029d0000,
0x02de4828, 0x031d0000)
      from space 1024K, 14%used[0x032d0000,
0x032f5370, 0x033d0000)
      to space 1024K, 0%used[0x031d0000,
0x031d0000, 0x032d0000)
    tenured generation total 10240K, used
6144K[0x033d0000, 0x03dd0000, 0x03dd0000)
      the space 10240K, 60%used[0x033d0000,
0x039d0030, 0x039d0200, 0x03dd0000)
    compacting perm gen total 12288K, used
2114K[0x03dd0000, 0x049d0000, 0x07dd0000)
      the space 12288K, 17%used[0x03dd0000,
0x03fe0998, 0x03fe0a00, 0x049d0000)
```

No shared spaces configured.

[1]JIT即时编译器相关优化可参见第11章。

3.6.2 大对象直接进入老年代

所谓的大对象是指，需要大量连续内存空间的Java对象，最典型的大对象就是那种很长的字符串以及数组（笔者列出的例子中的byte[]数组就是典型的大对象）。大对象对虚拟机的内存分配来说就是一个坏消息（替Java虚拟机抱怨一句，比遇到一个大对象更加坏的消息就是遇到一群“朝生夕灭”的“短命大对象”，写程序的时候应当避免），经常出现大对象容易导致内存还有不少空间时就提前触发垃圾收集以获取足够的连续空间来“安置”它们。

虚拟机提供了一个-XX:

PretenureSizeThreshold参数，令大于这个设置值

的对象直接在老年代分配。这样做的目的是避免在Eden区及两个Survivor区之间发生大量的内存复制（复习一下：新生代采用复制算法收集内存）。

执行代码清单3-6中的

`testPretenureSizeThreshold()`方法后，我们看到Eden空间几乎没有被使用，而老年代的10MB空间被使用了40%，也就是4MB的allocation对象直接就分配在老年代中，这是因为

`PretenureSizeThreshold`被设置为3MB（就是3145728，这个参数不能像-Xmx之类的参数一样直接写3MB），因此超过3MB的对象都会直接在老年代进行分配。注意 `PretenureSizeThreshold` 参数只对Serial和ParNew两款收集器有效，Parallel Scavenge收集器不认识这个参数，Parallel

Scavenge收集器一般并不需要设置。如果遇到必须使用此参数的场合，可以考虑ParNew加CMS的收集器组合。

代码清单3-6 大对象直接进入老年代

```
private static final int _1MB=1024*1024;
/**
 *VM参数: -verbose: gc-Xms20M-Xmx20M-Xmn10M-
XX: +PrintGCDetails-XX: SurvivorRatio=8
*-XX: PretenureSizeThreshold=3145728
*/
public static void
testPretenureSizeThreshold () {
    byte[] allocation;
    allocation=new byte[4*_1MB]; //直接分配在老年代
    中
}
```

运行结果：

```
Heap
def new generation total 9216K, used
671K[0x029d0000, 0x033d0000, 0x033d0000)
eden space 8192K, 8%used[0x029d0000,
```

```
0x02a77e98, 0x031d0000)
    from space 1024K, 0%used[0x031d0000,
0x031d0000, 0x032d0000)
        to space 1024K, 0%used[0x032d0000,
0x032d0000, 0x033d0000)
            tenured generation total 10240K, used
4096K[0x033d0000, 0x03dd0000, 0x03dd0000)
                the space 10240K, 40%used[0x033d0000,
0x037d0010, 0x037d0200, 0x03dd0000)
                    compacting perm gen total 12288K, used
2107K[0x03dd0000, 0x049d0000, 0x07dd0000)
                        the space 12288K, 17%used[0x03dd0000,
0x03fdfdf0, 0x03fdf000, 0x049d0000)
    No shared spaces configured.
```

3.6.3 长期存活的对象将进入老年代

既然虚拟机采用了分代收集的思想来管理内存，那么内存回收时就必须能识别哪些对象应放在新生代，哪些对象应放在老年代中。为了做到这点，虚拟机给每个对象定义了一个对象年龄（Age）计数器。如果对象在Eden出生并经过第一次Minor GC后仍然存活，并且能被Survivor容纳的话，将被移动到Survivor空间中，并且对象年龄设为1。对象在Survivor区中每“熬过”一次Minor GC，年龄就增加1岁，当它的年龄增加到一定程度（默认为15岁），就将会被晋升到老年代中。对象晋升老年代的年龄阈值，可以通过参数-XX: MaxTenuringThreshold设置。

读者可以试试分别以-XX:

MaxTenuringThreshold=1和-XX:

MaxTenuringThreshold=15两种设置来执行代码清单3-7中的testTenuringThreshold（）方法，此方法中的allocation1对象需要256KB内存，Survivor空间可以容纳。当MaxTenuringThreshold=1时，allocation1对象在第二次GC发生时进入老年代，新生代已使用的内存GC后非常干净地变成0KB。而MaxTenuringThreshold=15时，第二次GC发生后，allocation1对象则还留在新生代Survivor空间，这时新生代仍然有404KB被占用。

代码清单3-7 长期存活的对象进入老年代

```
private static final int _1MB=1024*1024;
/**
 *VM参数: -verbose: gc-Xms20M-Xmx20M-Xmn10M-
XX: +PrintGCDetails-XX: SurvivorRatio=8-XX:
```

```
MaxTenuringThreshold=1
    *-XX: +PrintTenuringDistribution
    */
    @SuppressWarnings ("unused")
    public static void testTenuringThreshold ()
{
    byte[] allocation1, allocation2, allocation3;
    allocation1=new byte[_1MB/4];
    //什么时候进入老年代取决于xx:
MaxTenuringThreshold设置
    allocation2=new byte[4*_1MB];
    allocation3=new byte[4*_1MB];
    allocation3=null;
    allocation3=new byte[4*_1MB];
}
```

以MaxTenuringThreshold=1参数来运行的结果:

```
[GC [DefNew
Desired Survivor size 524288 bytes, new
threshold 1 (max 1)
-age 1: 414664 bytes, 414664 total
: 4859K->404K (9216K) , 0.0065012
secs] 4859K->4500K (19456K) , 0.0065283 secs]
[Times: user=0.02 sys=0.00, real=0.02 secs]
[GC [DefNew
Desired Survivor size 524288 bytes, new
threshold 1 (max 1)
: 4500K->0K (9216K) , 0.0009253 secs] 8596K->
```

4500K (19456K) , 0.0009458 secs] [Times:
user=0.00 sys=0.00, real=0.00 secs]

Heap

def new generation total 9216K, used
4178K[0x029d0000, 0x033d0000, 0x033d0000)
eden space 8192K, 51%used[0x029d0000,
0x02de4828, 0x031d0000)
from space 1024K, 0%used[0x031d0000,
0x031d0000, 0x032d0000)
to space 1024K, 0%used[0x032d0000,
0x032d0000, 0x033d0000)
tenured generation total 10240K, used
4500K[0x033d0000, 0x03dd0000, 0x03dd0000)
the space 10240K, 43%used[0x033d0000,
0x03835348, 0x03835400, 0x03dd0000)
compacting perm gen total 12288K, used
2114K[0x03dd0000, 0x049d0000, 0x07dd0000)
the space 12288K, 17%used[0x03dd0000,
0x03fe0998, 0x03fe0a00, 0x049d0000)

No shared spaces configured.

以MaxTenuringThreshold=15参数来运行的结果：

[GC[DefNew

Desired Survivor size 524288 bytes, new
threshold 15 (max 15)

-age 1: 414664 bytes, 414664 total

: 4859K->404K (9216K) , 0.0049637

secs] 4859K->4500K (19456K) , 0.0049932 secs]

[Times: user=0.00 sys=0.00, real=0.00 secs]

[GC[DefNew

Desired Survivor size 524288 bytes, new
threshold 15 (max 15)

-age 2: 414520 bytes, 414520 total

: 4500K->404K (9216K) , 0.0008091

secs] 8596K->4500K (19456K) , 0.0008305 secs]

```
[Times: user=0.00 sys=0.00, real=0.00 secs]
    Heap
        def new generation total 9216K,used
4582K[0x029d0000, 0x033d0000, 0x033d0000)
            eden space 8192K, 51%used[0x029d0000,
0x02de4828, 0x031d0000)
                from space 1024K, 39%used[0x031d0000,
0x03235338, 0x032d0000)
                    to space 1024K, 0%used[0x032d0000,
0x032d0000, 0x033d0000)
            tenured generation total 10240K,used
4096K[0x033d0000, 0x03dd0000, 0x03dd0000)
                the space 10240K, 40%used[0x033d0000,
0x037d0010, 0x037d0200, 0x03dd0000)
            compacting perm gen total 12288K,used
2114K[0x03dd0000, 0x049d0000, 0x07dd0000)
                the space 12288K, 17%used[0x03dd0000,
0x03fe0998, 0x03fe0a00, 0x049d0000)
        No shared spaces configured.
```

3.6.4 动态对象年龄判定

为了能更好地适应不同程序的内存状况，虚拟机并不是永远地要求对象的年龄必须达到了 MaxTenuringThreshold 才能晋升老年年代，如果在 Survivor 空间中相同年龄所有对象大小的总和大于 Survivor 空间的一半，年龄大于或等于该年龄的对象就可以直接进入老年年代，无须等到 MaxTenuringThreshold 中要求的年龄。

执行代码清单 3-8 中的 testTenuringThreshold2() 方法，并设置 -XX:MaxTenuringThreshold=15，会发现运行结果中 Survivor 的空间占用仍然为 0%，而老年年代比预期增加了 6%，也就是说，allocation1、allocation2 对

象都直接进入了老年代，而没有等到15岁的临界年龄。因为这两个对象加起来已经到达了512KB，并且它们是同年的，满足同年对象达到Survivor空间的一半规则。我们只要注释掉其中一个对象new操作，就会发现另外一个就不会晋升到老年代中去了。

代码清单3-8 动态对象年龄判定

```
private static final int _1MB=1024*1024;
/**
 *VM参数: -verbose: gc-Xms20M-Xmx20M-Xmn10M-
XX: +PrintGCDetails-XX: SurvivorRatio=8-XX:
MaxTenuringThreshold=15
 *-XX: +PrintTenuringDistribution
 */
@SuppressWarnings ("unused")
public static void
testTenuringThreshold2 () {
    byte[] allocation1, allocation2, allocation3,
allocation4;
    allocation1=new byte[_1MB/4];
    //allocation1+allocation2大于survivo空间一半
    allocation2=new byte[_1MB/4];
```

```
allocation3=new byte[4*_1MB];
allocation4=new byte[4*_1MB];
allocation4=null;
allocation4=new byte[4*_1MB];
}
```

运行结果：

```
[GC[DefNew
Desired Survivor size 524288 bytes, new
threshold 1 (max 15)
-age 1: 676824 bytes, 676824 total
: 5115K->660K (9216K), 0.0050136
secs]5115K->4756K (19456K), 0.0050443 secs]
[Times: user=0.00 sys=0.01, real=0.01 secs]
[GC[DefNew
Desired Survivor size 524288 bytes, new
threshold 15 (max 15)
: 4756K->0K (9216K), 0.0010571 secs]8852K->
4756K (19456K), 0.0011009 secs][Times:
user=0.00 sys=0.00, real=0.00 secs]
Heap
def new generation total 9216K, used
4178K[0x029d0000, 0x033d0000, 0x033d0000)
eden space 8192K, 51%used[0x029d0000,
0x02de4828, 0x031d0000)
from space 1024K, 0%used[0x031d0000,
0x031d0000, 0x032d0000)
to space 1024K, 0%used[0x032d0000,
0x032d0000, 0x033d0000)
tenured generation total 10240K, used
```

```
4756K[0x033d0000, 0x03dd0000, 0x03dd0000)
    the space 10240K, 46%used[0x033d0000,
0x038753e8, 0x03875400, 0x03dd0000)
    compacting perm gen total 12288K, used
2114K[0x03dd0000, 0x049d0000, 0x07dd0000)
    the space 12288K, 17%used[0x03dd0000,
0x03fe09a0, 0x03fe0a00, 0x049d0000)
No shared spaces configured.
```

3.6.5 空间分配担保

在发生Minor GC之前，虚拟机会先检查老年代最大可用的连续空间是否大于新生代所有对象总空间，如果这个条件成立，那么Minor GC可以确保是安全的。如果不成立，则虚拟机会查看HandlePromotionFailure设置值是否允许担保失败。如果允许，那么会继续检查老年代最大可用的连续空间是否大于历次晋升到老年代对象的平均大小，如果大于，将尝试着进行一次Minor GC，尽管这次Minor GC是有风险的；如果小于，或者HandlePromotionFailure设置不允许冒险，那这时也要改为进行一次Full GC。

下面解释一下“冒险”是冒了什么风险，前面

提到过，新生代使用复制收集算法，但为了内存利用率，只使用其中一个Survivor空间来作为轮换备份，因此当出现大量对象在Minor GC后仍然存活的情况（最极端的情况就是内存回收后新生代中所有对象都存活），就需要老年代进行分配担保，把Survivor无法容纳的对象直接进入老年代。与生活中的贷款担保类似，老年代要进行这样的担保，前提是老年代本身还有容纳这些对象的剩余空间，一共有多少对象会活下来在实际完成内存回收之前是无法明确知道的，所以只好取之前每一次回收晋升到老年代对象容量的平均大小值作为经验值，与老年代的剩余空间进行比较，决定是否进行Full GC来让老年代腾出更多空间。

取平均值进行比较其实仍然是一种动态概率

的手段，也就是说，如果某次Minor GC存活后的对象突增，远远高于平均值的话，依然会导致担保失败（Handle Promotion Failure）。如果出现了HandlePromotionFailure失败，那就只好在失败后重新发起一次Full GC。虽然担保失败时绕的圈子是最大的，但大部分情况下都还是会将HandlePromotionFailure开关打开，避免Full GC过于频繁，参见代码清单3-9，请读者在JDK 6 Update 24之前的版本中运行测试。

代码清单3-9 空间分配担保

```
private static final int _1MB=1024*1024;  
/**  
 * VM参数: -Xms20M-Xmx20M-Xmn10M-XX:  
 +PrintGCDetails-XX: SurvivorRatio=8-XX: -  
 HandlePromotionFailure  
 */  
 @SuppressWarnings ("unused")  
 public static void testHandlePromotion () {  
 byte[] allocation1, allocation2, allocation3,
```

```
allocation4, allocation5, allocation6,
allocation7;
    allocation1=new byte[2*_1MB];
    allocation2=new byte[2*_1MB];
    allocation3=new byte[2*_1MB];
    allocation1=null;
    allocation4=new byte[2*_1MB];
    allocation5=new byte[2*_1MB];
    allocation6=new byte[2*_1MB];
    allocation4=null;
    allocation5=null;
    allocation6=null;
    allocation7=new byte[2*_1MB];
}
```

以HandlePromotionFailure=false参数来运行的结果：

```
[GC [DefNew: 6651K->148K (9216K), 0.0078936
secs] 6651K->4244K (19456K), 0.0079192 secs]
[Times: user=0.00 sys=0.02, real=0.02 secs]
[G C[D e f N e w: 6 3 7 8 K->6 3 7 8 K (9 2
1 6 K), 0.0 0 0 0 2 0 6 s e c s][T e n u r e
d: 4096K->4244K (10240K), 0.0042901
secs] 10474K->4244K (19456K), [Perm: 2104K->
2104K (12288K)], 0.0043613 secs][Times:
user=0.00 sys=0.00, real=0.00 secs]
```

以HandlePromotionFailure=true参数来运行的结果：

```
[GC [DefNew: 6651K->148K (9216K), 0.0054913  
secs] 6651K->4244K (19456K), 0.0055327 secs]  
[Times: user=0.00 sys=0.00, real=0.00 secs]
```

```
[GC [DefNew: 6378K->148K (9216K), 0.0006584  
secs] 10474K->4244K (19456K), 0.0006857 secs]  
[Times: user=0.00 sys=0.00, real=0.00 secs]
```

在JDK 6 Update 24之后，这个测试结果会有差异，HandlePromotionFailure参数不会再影响到虚拟机的空间分配担保策略，观察OpenJDK中的源码变化（见代码清单3-10），虽然源码中还定义了HandlePromotionFailure参数，但是在代码中已经不会再使用它。JDK 6 Update 24之后的规则变为只要老年代的连续空间大于新生代对象总大小或者历次晋升的平均大小就会进行Minor GC，否则将进行Full GC。

代码清单3-10 HotSpot中空间分配检查的代码片段

```
bool TenuredGeneration::  
promotion_attempt_is_safe (size_t  
    max_promotion_in_bytes) const{  
    //老年代最大可用的连续空间  
    size_t  
available=max_contiguous_available ();  
    //每次晋升到老年代的平均大小  
    size_t av_promo= (size_t) gc_stats () ->  
avg_promoted () ->padded_average ();  
    //老年代可用空间是否大于平均晋升大小，或者老年代可用  
空间是否大于当此GC时新生代所有对象容量  
    bool res= (available>=av_promo) ||  
(available>=  
    max_promotion_in_bytes);  
    return res;  
}
```

3.7 本章小结

本章介绍了垃圾收集的算法、几款JDK 1.7中提供的垃圾收集器特点以及运作原理。通过代码实例验证了Java虚拟机中自动内存分配及回收的主要规则。

内存回收与垃圾收集器在很多时候都是影响系统性能、并发能力的主要因素之一，虚拟机之所以提供多种不同的收集器以及提供大量的调节参数，是因为只有根据实际应用需求、实现方式选择最优的收集方式才能获取最高的性能。没有固定收集器、参数组合，也没有最优的调优方法，虚拟机也就没有什么必然的内存回收行为。因此，学习虚拟机内存知识，如果要到实践调优

阶段，那么必须了解每个具体收集器的行为、优势和劣势、调节参数。在接下来的两章中，作者将会介绍内存分析的工具和调优的一些具体案例。

第4章 虚拟机性能监控与故障处理工具

Java与C++之间有一堵由内存动态分配和垃圾收集技术所围成的“高墙”，墙外面的人想进去，墙里面的人却想出来。

4.1 概述

经过前面两章对于虚拟机内存分配与回收技术各方面的介绍，相信读者已经建立了一套比较完整的理论基础。理论总是作为指导实践的工具，能把这些知识应用到实际工作中才是我们的最终目的。接下来的两章，我们将从实践的角度去了解虚拟机内存管理的世界。

给一个系统定位问题的时候，知识、经验是关键基础，数据是依据，工具是运用知识处理数据的手段。这里说的数据包括：运行日志、异常堆栈、GC日志、线程快照（`threaddump/javacore`文件）、堆转储快照（`heapdump/hprof`文件）等。经常使用适当的虚拟机监控和分析的工具可以加快我们分析数据、定位解决问题的速度，但在学习工具前，也应当意识到工具永远都是知识技能的一层包装，没有什么工具是“秘密武器”，不可能学会了就能包治百病。

4.2 JDK的命令行工具

Java开发人员肯定都知道JDK的bin目录中有“java.exe”、“javac.exe”这两个命令行工具，但并非所有程序员都了解过JDK的bin目录之中其他命令行程序的作用。每逢JDK更新版本之时，bin目录下命令行工具的数量和功能总会不知不觉地增加和增强。bin目录的内容如图4-1所示。

在本章中，笔者将介绍这些工具的其中一部分，主要包括用于监视虚拟机和故障处理的工具。这些故障处理工具被Sun公司作为“礼物”附赠给JDK的使用者，并在软件的使用说明中把它们声明为“没有技术支持并且是实验性质的”（unsupported and experimental）^[1]的产品，但

事实上，这些工具都非常稳定而且功能强大，能在处理应用程序性能问题、定位故障时发挥很大的作用。

The screenshot shows a Windows file explorer window with the following details:

Path: Documents (D:) > _DevSpace > jdk1.6.0_21 > bin

| 名称 | 修改日期 | 类型 | 大小 |
|-----------------|-----------------|------|--------|
| xjc.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| wimport.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| wsgen.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| unpack200.exe | 2010/7/19 11:56 | 应用程序 | 124 KB |
| tnameserv.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| servertool.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| serialver.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| schemagen.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| rmiregistry.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| rmid.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| rmic.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| policytool.exe | 2010/7/19 11:56 | 应用程序 | 27 KB |
| packager.exe | 2010/7/19 11:56 | 应用程序 | 72 KB |

图 4-1 Sun JDK 中的工具目录


说起JDK的工具，比较细心的读者，可能会注意到这些工具的程序体积都异常小巧。假如以前没注意到，现在不妨再看看图4-1中的最后一

列“大小”，几乎所有工具的体积基本上稳定在27KB左右。并非JDK开发团队刻意把它们制作得如此精炼来炫耀编程水平，而是因为这些命令行工具大多数是jdk/lib/tools.jar类库的一层薄包装而已，它们主要的功能代码是在tools类库中实现的。读者把图4-1和图4-2两张图片对比一下就可以看得很清楚。

假如读者使用的是Linux版本的JDK，还会发现这些工具中很多甚至就是由Shell脚本直接写成的，可以用vim直接打开它们。

JDK开发团队选择采用Java代码来实现这些监控工具是有特别用意的：当应用程序部署到生产环境后，无论是直接接触物理服务器还是远程Telnet到服务器上都可能会受到限制。借助

tools.jar类库里面的接口，我们可以直接在应用程序中实现功能强大的监控分析功能^[2]。



The screenshot shows a Windows-style file explorer window. The title bar reads "tools.jar\sun\tools - ZIP 压缩文件, 解包大小为 11,923,2". The main area is a table listing the contents of the "tools" folder:

| 名称 | 大小 | 压缩... | 类型 | 修改时间 |
|--------------|----|-------|--------|----------------|
| .. | | | Folder | |
| asm | | | Folder | 2010/9/15 0:53 |
| attach | | | Folder | 2010/9/15 1:15 |
| hprof | | | Folder | 2010/9/15 1:10 |
| jar | | | Folder | 2010/9/15 1:00 |
| java | | | Folder | 2010/9/15 1:10 |
| javac | | | Folder | 2010/9/15 1:06 |
| javap | | | Folder | 2010/9/15 1:10 |
| jinfo | | | Folder | 2010/9/15 1:10 |
| jmap | | | Folder | 2010/9/15 1:10 |
| jps | | | Folder | 2010/9/15 1:10 |
| jstack | | | Folder | 2010/9/15 1:10 |
| jstat | | | Folder | 2010/9/15 1:10 |
| jstati | | | Folder | 2010/9/15 1:10 |
| native2ascii | | | Folder | 2010/9/15 1:10 |
| serialver | | | Folder | 2010/9/15 1:10 |
| tree | | | Folder | 2010/9/15 0:53 |
| util | | | Folder | 2010/9/15 1:10 |

图 4-2 tools.jar包的内部状况

需要特别说明的是，本章介绍的工具全部基

于Windows平台下的JDK 1.6 Update 21，如果JDK版本、操作系统不同，工具所支持的功能可能会有较大差别。大部分工具在JDK 1.5中就已经提供，但为了避免运行环境带来的差异和兼容性问题，建议读者使用JDK 1.6来验证本章介绍的内容，因为JDK 1.6的工具可以正常兼容运行于JDK 1.5的虚拟机之上的程序，反之则不一定。表4-1中说明了JDK主要命令行监控工具的用途。

注意 如果读者在工作中需要监控运行于JDK 1.5的虚拟机之上的程序，在程序启动时请添加参数“-Dcom.sun.management.jmxremote”开启JMX管理功能，否则由于部分工具都是基于JMX（包括4.3节介绍的可视化工具），它们都将会无法使用，如果被监控程序运行于JDK 1.6的虚拟机之上，那JMX管理默认是开启的，虚拟机启

动时无须再添加任何参数。

表 4-1 Sun JDK 监控和故障处理工具

| 名 称 | 主要作用 |
|-------|--|
| jps | JVM Process Status Tool, 显示指定系统内所有的 HotSpot 虚拟机进程 |
| jstat | JVM Statistics Monitoring Tool, 用于收集 HotSpot 虚拟机各方面的运行数据 |
| jinfo | Configuration Info for Java, 显示虚拟机配置信息 |

(续)

| 名 称 | 主要作用 |
|--------|--|
| jmap | Memory Map for Java, 生成虚拟机的内存转储快照 (heapspace 文件) |
| jhat | JVM Heap Dump Browser, 用于分析 heapspace 文件, 它会建立一个 HTTP/HTML 服务器, 让用户可以在浏览器上查看分析结果 |
| jstack | Stack Trace for Java, 显示虚拟机的线程快照 |

4.2.1 jps：虚拟机进程状况工具

JDK的很多小工具的名字都参考了UNIX命令的命名方式，jps（JVM Process Status Tool）是其中的典型。除了名字像UNIX的ps命令之外，它的功能也和ps命令类似：可以列出正在运行的虚拟机进程，并显示虚拟机执行主类（Main Class,main（）函数所在的类）名称以及这些进程

的本地虚拟机唯一ID（Local Virtual Machine Identifier,LVMID）。虽然功能比较单一，但它是使用频率最高的JDK命令行工具，因为其他的JDK工具大多需要输入它查询到的LVMID来确定要监控的是哪一个虚拟机进程。对于本地虚拟机进程来说，LVMID与操作系统的进程ID（Process Identifier,PID）是一致的，使用Windows的任务管理器或者UNIX的ps命令也可以查询到虚拟机进程的LVMID，但如果同时启动了多个虚拟机进程，无法根据进程名称定位时，那就只能依赖jps命令显示主类的功能才能区分了。

jps命令格式：

```
jps [options] [hostid]
```

jps执行样例：

```
D:\Develop\Java\jdk1.6.0_21\bin>jps -l  
2388 D:  
\Develop\glassfish\bin..\modules\admin-cli.jar  
2764  
com.sun.enterprise.glassfish.bootstrap.ASMain  
3788 sun.tools.jps.Jps
```

jps可以通过RMI协议查询开启了RMI服务的远程虚拟机进程状态，hostid为RMI注册表中注册的主机名。jps的其他常用选项见表4-2。

表 4-2 jps 工具主要选项

| 选 项 | 作 用 |
|-----|----------------------------------|
| -q | 只输出 LVMID，省略主类的名称 |
| -m | 输出虚拟机进程启动时传递给主类 main() 函数的参数 |
| -l | 输出主类的全名，如果进程执行的是 Jar 包，输出 Jar 路径 |
| -v | 输出虚拟机进程启动时 JVM 参数 |

- [1]<http://download.oracle.com/javase/6/docs/technote/tools/jps.html>
- [2]tools.jar 中的类库不属于 Java 的标准 API，如果引入这个类库，就意味着用户的程序只能运行于

Sun Hotspot (或一些从Sun公司购买了JDK的源码
License的虚拟机，如IBM J9、BEA JRockit) 上
面，或者在部署程序时需要一起部署tools.jar。

4.2.2 jstat：虚拟机统计信息监视工具

jstat（JVM Statistics Monitoring Tool）是用于监视虚拟机各种运行状态信息的命令行工具。它可以显示本地或者远程^[1]虚拟机进程中的类装载、内存、垃圾收集、JIT编译等运行数据，在没有GUI图形界面，只提供了纯文本控制台环境的服务器上，它将是运行期定位虚拟机性能问题的首选工具。

jstat命令格式为：

```
jstat[option vmid[interval[s|ms][count]]]
```

对于命令格式中的VMID与LVMID需要特别说明一下：如果是本地虚拟机进程，VMID与

LVMID是一致的，如果是远程虚拟机进程，那
VMID的格式应当是：

```
[protocol: ] [//] lvmid[@hostname[:  
port]/servername]
```

参数interval和count代表查询间隔和次数，如
果省略这两个参数，说明只查询一次。假设需要
每250毫秒查询一次进程2764垃圾收集状况，一
共查询20次，那命令应当是：

```
jstat-gc 2764 250 20
```

选项option代表着用户希望查询的虚拟机信
息，主要分为3类：类装载、垃圾收集、运行期
编译状况，具体选项及作用请参考表4-3中的描
述。

表 4-3 jstat 工具主要选项

| 选 项 | 作 用 |
|-------------------|---|
| -class | 监视类装载、卸载数量、总空间以及类装载所耗费的时间 |
| -gc | 监视 Java 堆状况，包括 Eden 区、两个 survivor 区、老年代、永久代等的容量、已用空间、GC 时间合计等信息 |
| -gccapacity | 监视内容与 -gc 基本相同，但输出主要关注 Java 堆各个区域使用到的最大、最小空间 |
| -gcutil | 监视内容与 -gc 基本相同，但输出主要关注已使用空间占总空间的百分比 |
| -gccause | 与 -gcutil 功能一样，但是会额外输出导致上一次 GC 产生的原因 |
| -genew | 监视新生代 GC 状况 |
| -genewcapacity | 监视内容与 -genew 基本相同，输出主要关注使用到的最大、最小空间 |
| -gcold | 监视老年代 GC 状况 |
| -gcoldcapacity | 监视内容与 -gcold 基本相同，输出主要关注使用到的最大、最小空间 |
| -gepermcapacity | 输出永久代使用到的最大、最小空间 |
| -compiler | 输出 JIT 编译器编译过的方法、耗时等信息 |
| -printcompilation | 输出已经被 JIT 编译的方法 |

jstat 监视选项众多，囿于版面原因无法逐一演示，这里仅举监视一台刚刚启动的 GlassFish v3 服务器的内存状况的例子来演示如何查看监视结果。监视参数与输出结果如代码清单 4-1 所示。

代码清单 4-1 jstat 执行样例

```
D:\Develop\Java\jdk1.6.0_21\bin>jstat-gcutil 2764
S0 S1 E O P YGC YGCT FGC FGCT GCT
0.00 0.00 6.20 41.42 47.20 16 0.105 3 0.472
0.577
```

查询结果表明：这台服务器的新生代Eden区（E，表示Eden）使用了6.2%的空间，两个Survivor区（S0、S1，表示Survivor0、Survivor1）里面都是空的，老年代（O，表示Old）和永久代（P，表示Permanent）则分别使用了41.42%和47.20%的空间。程序运行以来共发生Minor GC（YGC，表示Young GC）16次，总耗时0.105秒，发生Full GC（FGC，表示Full GC）3次，Full GC总耗时（FGCT，表示Full GC Time）为0.472秒，所有GC总耗时（GCT，表示GC Time）为0.577秒。

使用jstat工具在纯文本状态下监视虚拟机状态的变化，确实不如后面将会提到的VisualVM等可视化的监视工具直接以图表展现那样直观。但许多服务器管理员都习惯了在文本控制台中工

作，直接在控制台中使用jstat命令依然是一种常用的监控方式。

[1]需要远程主机提供RMI支持，Sun提供的jstatd工具可以很方便地建立远程RMI服务器。

4.2.3 jinfo：Java配置信息工具

jinfo（Configuration Info for Java）的作用是实时地查看和调整虚拟机各项参数。使用jps命令的-v参数可以查看虚拟机启动时显式指定的参数列表，但如果想知道未被显式指定的参数的系统默认值，除了去找资料外，就只能使用jinfo的-flag选项进行查询了（如果只限于JDK 1.6或以上版本的话，使用java-XX: +PrintFlagsFinal查看参数默认值也是一个很好的选择），jinfo还可以使用-sysprops选项把虚拟机进程的System.getProperties（）的内容打印出来。这个命令在JDK 1.5时期已经随着Linux版的JDK发布，当时只提供了信息查询的功能，JDK 1.6之后，jinfo

在Windows和Linux平台都有提供，并且加入了运行期修改参数的能力，可以使用`-flag[+|-]name`或者`-flag name=value`修改一部分运行期可写的虚拟机参数值。JDK 1.6中，`jinfo`对于Windows平台功能仍然有较大限制，只提供了最基本的`-flag`选项。

`jinfo`命令格式：

```
jinfo [option] pid
```

执行样例：查询

CMSInitiatingOccupancyFraction参数值。

```
C: \>jinfo -flag  
CMSInitiatingOccupancyFraction 1444  
-XX: CMSInitiatingOccupancyFraction=85
```

4.2.4 jmap: Java内存映像工具

jmap (Memory Map for Java) 命令用于生成堆转储快照（一般称为heapdump或dump文件）。如果不使用jmap命令，要想获取Java堆转储快照，还有一些比较“暴力”的手段：譬如在第2章中用过的-XX: +HeapDumpOnOutOfMemoryError参数，可以让虚拟机在OOM异常出现之后自动生成dump文件，通过-XX: +HeapDumpOnCtrlBreak参数则可以使用[Ctrl]+[Break]键让虚拟机生成dump文件，又或者在Linux系统下通过Kill-3命令发送进程退出信号“吓唬”一下虚拟机，也能拿到dump文件。

jmap的作用并不仅仅是为了获取dump文件，

它还可以查询finalize执行队列、Java堆和永久代的详细信息，如空间使用率、当前用的是哪种收集器等。

和jinfo命令一样，jmap有不少功能在Windows平台下都是受限的，除了生成dump文件的-dump选项和用于查看每个类的实例、空间占用统计的-histo选项在所有操作系统都提供之外，其余选项都只能在Linux/Solaris下使用。

jmap命令格式：

```
jmap [option] vmid
```

option选项的合法值与具体含义见表4-4。

表 4-4 jmap 工具主要选项

| 选 项 | 作 用 |
|----------------|--|
| -dump | 生成 Java 堆转储快照。格式为：-dump[!live,]format=b, file=<filename>，其中 live 子参数说明是否只 dump 出存活的对象 |
| -finalizerinfo | 显示在 F-Queue 中等待 Finalizer 线程执行 finalize 方法的对象。只在 Linux / Solaris 平台下有效 |
| -heap | 显示 Java 堆详细信息，如使用哪种回收器、参数配置、分代状况等。只在 Linux / Solaris 平台下有效 |
| -histo | 显示堆中对象统计信息，包括类、实例数量、合计容量 |
| -permstat | 以 ClassLoader 为统计口径显示永久代内存状态。只在 Linux / Solaris 平台下有效 |
| -F | 当虚拟机进程对 -dump 选项没有响应时，可使用这个选项强制生成 dump 快照。只在 Linux / Solaris 平台下有效 |

代码清单4-2是使用jmap生成一个正在运行的Eclipse的dump快照文件的例子，例子中的3500是通过jps命令查询到的LVMID。

代码清单4-2 使用jmap生成dump文件

```
C:\Users\IcyFenix>jmap-dump:  
format=b,file=eclipse.bin 3500  
Dumping heap to C:  
\Users\IcyFenix\eclipse.bin.....  
Heap dump file created
```

4.2.5 jhat：虚拟机堆转储快照分析工具

Sun JDK提供jhat（JVM Heap Analysis Tool）

命令与jmap搭配使用，来分析jmap生成的堆转储快照。jhat内置了一个微型的HTTP/HTML服务器，生成dump文件的分析结果后，可以在浏览器中查看。不过实事求是地说，在实际工作中，除非笔者手上真的没有别的工具可用，否则一般都不会去直接使用jhat命令来分析dump文件，主要原因有二：一是一般不会在部署应用程序的服务器上直接分析dump文件，即使可以这样做，也会尽量将dump文件复制到其他机器^[1]上进行分析，因为分析工作是一个耗时而且消耗硬件资源的过程，既然都要在其他机器进行，就没有必要受到

命令行工具的限制了；另一个原因是jhat的分析功能相对来说比较简陋，后文将会介绍到的VisualVM，以及专业用于分析dump文件的Eclipse Memory Analyzer、IBM HeapAnalyzer^[2]等工具，都能实现比jhat更强大更专业的分析功能。代码清单4-3演示了使用jhat分析4.2.4节中采用jmap生成的Eclipse IDE的内存快照文件。

代码清单4-3 使用jhat分析dump文件

```
C:\Users\IcyFenix>jhat eclipse.bin
Reading from eclipse.bin.....
Dump file created Fri Nov 19 22:07:21 CST
2010
Snapshot read, resolving.....
Resolving 1225951 objects.....
Chasing references, expect 245 dots.....
Eliminating duplicate references.....
Snapshot resolved.
Started HTTP server on port 7000
Server is ready.
```

屏幕显示“Server is ready.”的提示后，用户在浏览器中键入http://localhost: 7000/就可以看到分析结果，如图4-3所示。

The screenshot shows a Windows Internet Explorer window with the title bar "All Classes (excluding platform) - Windows Internet Explorer". The address bar contains the URL "http://localhost:7000/". The main content area displays memory dump analysis results grouped by package:

- Package org.osgi.service.url**

```
class org.osgi.service.url.AbstractURLStreamHandlerService [0x5fde8a8]
class org.osgi.service.url.URLStreamHandlerService [0x5fdd868]
class org.osgi.service.url.URLStreamHandlerSetter [0x716f858]
```
- Package org.osgi.util.tracker**

```
class org.osgi.util.tracker.AbstractTracked [0x5e73888]
class org.osgi.util.tracker.ServiceTracker [0x5e702a0]
class org.osgi.util.tracker.ServiceTracker$1 [0x5fb3a50]
class org.osgi.util.tracker.ServiceTracker$AllTracked [0x5e74090]
class org.osgi.util.tracker.ServiceTracker$Tracked [0x5e73c58]
class org.osgi.util.tracker.ServiceTrackerCustomizer [0x5d2a428]
```
- Other Queries**
 - All classes including platform
 - Show all members of the rootset
 - Show instance counts for all classes (including platform)
 - Show instance counts for all classes (excluding platform)
 - Show heap histogram
 - Show finalizer summary
 - Execute Object Query Language (OQL) query

At the bottom of the browser window, there is a status bar with the text "Internet | 保护模式: 禁用" and "100%".

图 4-3 jhat的分析结果

分析结果默认是以包为单位进行分组显示，

分析内存泄漏问题主要会使用到其中的“Heap Histogram”（与jmap-histo功能一样）与OQL页签的功能，前者可以找到内存中总容量最大的对象，后者是标准的对象查询语言，使用类似SQL的语法对内存中的对象进行查询统计，读者若对OQL有兴趣的话，可以参考本书附录D的介绍。

- [1]用于分析的机器一般也是服务器，由于加载dump快照文件需要比生成dump更大的内存，所以一般在64位JDK、大内存的服务器上进行。
- [2]IBM HeapAnalyzer用于分析IBM J9虚拟机生成的映像文件，各个虚拟机产生的映像文件格式并不一致，所以分析工具也不能通用。

4.2.6 jstack：Java堆栈跟踪工具

jstack（Stack Trace for Java）命令用于生成虚拟机当前时刻的线程快照（一般称为threaddump或者javacore文件）。线程快照就是当前虚拟机内每一条线程正在执行的方法堆栈的集合，生成线程快照的主要目的是定位线程出现长时间停顿的原因，如线程间死锁、死循环、请求外部资源导致的长时间等待等都是导致线程长时间停顿的常见原因。线程出现停顿的时候通过jstack来查看各个线程的调用堆栈，就可以知道没有响应的线程到底在后台做些什么事情，或者等待着什么资源。

jstack命令格式：

```
jstack[option]vmid
```

option选项的合法值与具体含义见表4-5。

表 4-5 jstack 工具主要选项

| 选 项 | 作 用 |
|-----|----------------------------|
| -F | 当正常输出的请求不被响应时，强制输出线程堆栈 |
| -l | 除堆栈外，显示关于锁的附加信息 |
| -m | 如果调用到本地方法的话，可以显示 C/C++ 的堆栈 |

代码清单4-4是使用jstack查看Eclipse线程堆栈的例子，例子中的3500是通过jps命令查询到的LVMID。

代码清单4-4 使用jstack查看线程堆栈（部分结果）

```
C:\Users\IcyFenix>jstack -l 3500
2010-11-19 23:11:26
Full thread dump Java HotSpot(TM) 64-Bit
Server VM (17.1-b03 mixed mode):
  "[ThreadPool Manager]-Idle Thread" daemon
prio=6 tid=0x0000000039dd4000 nid=0xf50 in
Object.wait () [0x000000003c96f000]
    java.lang.Thread.State: WAITING (on object
```

```
monitor)
    at java.lang.Object.wait (Native Method)
    -waiting on<0x0000000016bdcc60> (a
org.eclipse.equinox.internal.util.impl.tpt.threa
    at java.lang.Object.wait (Object.java: 485)
    at
org.eclipse.equinox.internal.util.impl.tpt.threa
106)
    -locked<0x0000000016bdcc60> (a
org.eclipse.equinox.internal.util.impl.tpt.threa
Locked ownable synchronizers:
-None
```

在JDK 1.5中，`java.lang.Thread`类新增了一个`getAllStackTraces()`方法用于获取虚拟机中所有线程的`StackTraceElement`对象。使用这个方法可以通过简单的几行代码就完成`jstack`的大部分功能，在实际项目中不妨调用这个方法做个管理员页面，可以随时使用浏览器来查看线程堆栈，如代码清单4-5所示，这是笔者的一个小经验。

代码清单4-5 查看线程状况的JSP页面

```
<%@page import="java.util.Map"%>
<html>
<head>
<title>服务器线程信息</title>
</head>
<body>
<pre>
<%
for (Map.Entry<Thread, StackTraceElement[]>
stackTrace: Thread.
    getAllStackTraces () .entrySet () ) {
    Thread thread= (Thread)
stackTrace.getKey () ;
    StackTraceElement[] stack= (StackTraceElement|
stackTrace.getValue () ;
    if (thread.equals (Thread.currentThread () ) )
{
    continue;
}
    out.print ("\n线程: "+thread.getName ())
+"\\n") ;
    for (StackTraceElement element: stack) {
        out.print ("\t"+element+"\n") ;
    }
}
%>
</pre>
</body>
</html>
```

4.2.7 HSDIS：JIT生成代码反汇编

在Java虚拟机规范中，详细描述了虚拟机指令集中每条指令的执行过程、执行前后对操作数栈、局部变量表的影响等细节。这些细节描述与Sun的早期虚拟机（Sun Classic VM）高度吻合，但随着技术的发展，高性能虚拟机真正的细节实现方式已经渐渐与虚拟机规范所描述的内容产生了越来越大的差距，虚拟机规范中的描述逐渐成了虚拟机实现的“概念模型”——即实现只能保证规范描述等效。基于这个原因，我们分析程序的执行语义问题（虚拟机做了什么）时，在字节码层面上分析完全可行，但分析程序的执行行为问题（虚拟机是怎样做的、性能如何）时，在字节

码层面上分析就没有什么意义了，需要通过其他方式解决。

分析程序如何执行，通过软件调试工具（GDB、Windbg等）来断点调试是最常见的手段，但是这样的调试方式在Java虚拟机中会遇到很大困难，因为大量执行代码是通过JIT编译器动态生成到CodeBuffer中的，没有很简单的手段来处理这种混合模式的调试（不过相信虚拟机开发团队内部肯定是有内部工具的）。因此，不得不通过一些特别的手段来解决问题，基于这种背景，本节的主角——HSDIS插件就正式登场了。

HSDIS是一个Sun官方推荐的HotSpot虚拟机JIT编译代码的反汇编插件，它包含在HotSpot虚拟机的源码之中，但没有提供编译后的程序。在

Project Kenai的网站^[1]也可以下载到单独的源码。它的作用是让HotSpot的-XX: +PrintAssembly指令调用它来把动态生成的本地代码还原为汇编代码输出，同时还生成了大量非常有价值的注释，这样我们就可以通过输出的代码来分析问题。读者可以根据自己的操作系统和CPU类型从Project Kenai的网站上下载编译好的插件，直接放到JDK_HOME/jre/bin/client和JDK_HOME/jre/bin/server目录中即可。如果没有找到所需操作系统（譬如Windows的就没有）的成品，那就得自己使用源码编译一下^[2]。

还需要注意的是，如果读者使用的是Debug或者FastDebug版的HotSpot，那可以直接通过-XX: +PrintAssembly指令使用插件；如果使用的是Product版的HotSpot，那还要额外加入一个-

XX: +UnlockDiagnosticVMOptions参数。笔者以代码清单4-6中的简单测试代码为例演示一下这个插件的使用。

代码清单4-6 测试代码

```
public class Bar{
    int a=1;
    static int b=2;
    public int sum (int c) {
        return a+b+c;
    }
    public static void main (String[]args) {
        new Bar () .sum (3);
    }
}
```

编译这段代码，并使用以下命令执行。

```
java -XX: +PrintAssembly -Xcomp -XX:
CompileCommand=dontinline, *Bar.sum -XX: Compi
leCommand=compileonly, *Bar.sum test.Bar
```

其中，参数-Xcomp是让虚拟机以编译模式执行代码，这样代码可以“偷懒”，不需要执行足够次数来预热就能触发JIT编译^[3]。两个-XX：CompileCommand意思是让编译器不要内联sum（）并且只编译sum（），-XX：+PrintAssembly就是输出反汇编内容。如果一切顺利的话，那么屏幕上会出现类似下面代码清单4-7所示的内容。

代码清单4-7 测试代码

```
[Disassembling for mach='i386']
[Entry Point]
[Constants]
#{method}'sum'' (I) I'in'test/Bar'
#this: ecx='test/Bar'
#parm0: edx=int
#[sp+0x20] (sp of caller)
.....
0x01cac407: cmp 0x4 (%ecx), %eax
0x01cac40a: jne 0x01c6b050; {runtime_call}
[Verified Entry Point]
```

```
0x01cac410: mov%eax, -0x8000 (%esp)
0x01cac417: push%ebp
0x01cac418: sub$0x18, %esp; *aload_0
; -test.Bar: sum@0 (line 8)
; block B0[0, 10]
0x01cac41b: mov 0x8 (%ecx), %eax; *getfield
a
; -test.Bar: sum@1 (line 8)
0x01cac41e: mov$0x3d2fad8, %esi; {oop (a
'java/lang/Class'='test/Bar') }
0x01cac423: mov 0x68 (%esi), %esi;
*getstatic b
; -test.Bar: sum@4 (line 8)
0x01cac426: add%esi, %eax
0x01cac428: add%edx, %eax
0x01cac42a: add$0x18, %esp
0x01cac42d: pop%ebp
0x01cac42e: test%eax, 0x2b0100; {poll_return}
0x01cac434: ret
```

上段代码并不多，下面一句句进行说明。

- 1) `mov%eax, -0x8000 (%esp)`： 检查栈溢。
- 2) `push%ebp`： 保存上一栈帧基址。

3) sub\$0x18, %esp: 给新帧分配空间。

4) mov 0x8 (%ecx), %eax: 取实例变量a, 这里0x8 (%ecx) 就是ecx+0x8的意思, 前面 “[Constants]” 节中提示了 “this: ecx='test/Bar'”, 即ecx寄存器中放的就是this对象的地址。偏移0x8是越过this对象的对象头, 之后就是实例变量a的内存位置。这次是访问“Java堆”中的数据。

5) mov\$0x3d2fad8, %esi: 取test.Bar在方法区的指针。

6) mov 0x68 (%esi), %esi: 取类变量b, 这次是访问“方法区”中的数据。

7) add%esi, %eax和add%edx, %eax: 做两次加法, 求a+b+c的值, 前面的代码把a放在eax

中，把b放在esi中，而c在[Constants]中提示了，“parm0: edx=int”，说明c在edx中。

8) add\$0x18, %esp: 撤销栈帧。

9) pop%ebp: 恢复上一栈帧。

10) test%eax, 0x2b0100: 轮询方法返回处的SafePoint。

11) ret: 方法返回。

[1]Project Kenai: <http://kenai.com/projects/base-hsdis>。

[2]HLLVM圈子中有已编译好的：

[http://hllvm.group.iteye.com/。](http://hllvm.group.iteye.com/)

[3]-Xcomp在较新的HotSpot中被移除了，如果读者的虚拟机无法使用这个参数，请加个循环预热

代码，触发JIT编译。

4.3 JDK的可视化工具

JDK中除了提供大量的命令行工具外，还有两个功能强大的可视化工具：JConsole和VisualVM，这两个工具是JDK的正式成员，没有被贴上“unsupported and experimental”的标签。

其中JConsole是在JDK 1.5时期就已经提供的虚拟机监控工具，而VisualVM在JDK 1.6 Update7中才首次发布，现在已经成为Sun（Oracle）主力推动的多合一故障处理工具^[1]，并且已经从JDK中分离出来成为可以独立发展的开源项目。

为了避免本节的讲解成为对软件说明文档的简单翻译，笔者准备了一些代码样例，都是笔者特意编写的“反面教材”。后面将会使用这两款工

具去监控、分析这几段代码存在的问题，算是本节简单的实战分析。读者可以把在可视化工具观察到的数据、现象，与前面两章中讲解的理论知识互相印证。

4.3.1 JConsole：Java监视与管理控制台

JConsole（Java Monitoring and Management Console）是一种基于JMX的可视化监视、管理工具。它管理部分的功能是针对JMX MBean进行管理，由于MBean可以使用代码、中间件服务器的管理控制台或者所有符合JMX规范的软件进行访问，所以本节将会着重介绍JConsole监视部分的功能。

1. 启动JConsole

通过JDK/bin目录下的“jconsole.exe”启动

JConsole后，将自动搜索出本机运行的所有虚拟机进程，不需要用户自己再使用jps来查询了，如图4-4所示。双击选择其中一个进程即可开始监控，也可以使用下面的“远程进程”功能来连接远程服务器，对远程虚拟机进行监控。



图 4-4 JConsole连接页面

从图4-4可以看出，笔者的机器现在运行了Eclipse、JConsole和MonitoringTest三个本地虚拟机。

机进程，其中MonitoringTest就是笔者准备的“反面教材”代码之一。双击它进入JConsole主界面，可以看到主界面里共包括“概述”、“内存”、“线程”、“类”、“VM摘要”、“MBean”6个页签，如图4-5所示。




图 4-5 JConsole 主界面

“概述”页签显示的是整个虚拟机主要运行数据的概览，其中包括“堆内存使用情况”、“线程”、“类”、“CPU使用情况”4种信息的曲线图，这些曲线图是后面“内存”、“线程”、“类”页签的信息汇总，具体内容将在后面介绍。

2. 内存监控

“内存”页签相当于可视化的jstat命令，用于监视受收集器管理的虚拟机内存（Java堆和永久代）的变化趋势。我们通过运行代码清单4-8中的代码来体验一下它的监视功能。运行时设置的虚拟机参数为：-Xms100m-Xmx100m-XX:+UseSerialGC，这段代码的作用是以64KB/50毫秒的速度往Java堆中填充数据，一共填充1000次，使用JConsole的“内存”页签进行监视，观察曲线和柱状指示图的变化。

代码清单4-8 JConsole监视代码

```
/**  
 * 内存占位符对象，一个OOMObject大约占64KB  
 */  
static class OOMObject{  
    public byte[] placeholder=new byte[64*1024];
```

```
}

public static void fillHeap (int num) throws
InterruptedException{
    List<OOMObject>list=new ArrayList<
OOMObject> () ;
    for (int i=0; i<num; i++) {
        //稍作延时，令监视曲线的变化更加明显
        Thread.sleep (50) ;
        list.add (new OOMObject () ) ;
    }
    System.gc () ;
}

public static void main (String[]args)
throws Exception{
    fillHeap (1000) ;
}
```

程序运行后，在“内存”页签中可以看到内存池Eden区的运行趋势呈现折线状，如图4-6所示。而监视范围扩大至整个堆后，会发现曲线是一条向上增长的平滑曲线。并且从柱状图可以看出，在1000次循环执行结束，运行了System.gc（）后，虽然整个新生代Eden和Survivor区都基本被清空了，但是代表老年代的柱状图仍然保持峰值

状态，说明被填充进堆中的数据在System.gc（）方法执行之后仍然存活。笔者的分析到此为止，现提两个小问题供读者思考一下，答案稍后给出。

1) 虚拟机启动参数只限制了Java堆为100MB，没有指定-Xmn参数，能否从监控图中估计出新生代有多大？

2) 为何执行了System.gc（）之后，图4-6中代表老年代的柱状图仍然显示峰值状态，代码需要如何调整才能让System.gc（）回收掉填充到堆中的对象？




图 4-6 Eden区内存变化状况

问题1答案：图4-6显示Eden空间为27328KB，因为没有设置-XX: SurvivorRatio参数，所以Eden与Survivor空间比例为默认值8:1，整个新生代空间大约为 $27\ 328\text{KB} \times 125\% = 34\ 160\text{KB}$ 。

问题2答案：执行完System.gc（）之后，空间未能回收是因为List<OOMObject>list对象仍然存活，fillHeap（）方法仍然没有退出，因此list对象在System.gc（）执行时仍然处于作用域之内^[2]。如果把System.gc（）移动到fillHeap（）方法外调用就可以回收掉全部内存。

3.线程监控

如果上面的“内存”页签相当于可视化的jstat命令的话，“线程”页签的功能相当于可视化的jstack命令，遇到线程停顿时可以使用这个页签进行监控分析。前面讲解jstack命令的时候提到过线程长时间停顿的主要原因主要有：等待外部资源（数据库连接、网络资源、设备资源等）、死循环、锁等待（活锁和死锁）。通过代码清单4-9分

别演示一下这几种情况。

代码清单4-9 线程等待演示代码

```
/*
*线程死循环演示
*/
public static void createBusyThread () {
    Thread thread=new Thread (new Runnable () {
        @Override
        public void run () {
            while (true) //第41行
            ;
        }
    }, "testBusyThread") ;
    thread.start () ;
}
/***
*线程锁等待演示
*/
public static void createLockThread (final
Object lock) {
    Thread thread=new Thread (new Runnable () {
        @Override
        public void run () {
            synchronized (lock) {
                try{
                    lock.wait () ;
                }catch (InterruptedException e) {
                    e.printStackTrace () ;
                }
            }
        }
    })
}
```

```
    }
}
}, "testLockThread") ;
thread.start () ;
}
public static void main (String[]args)
throws Exception{
    BufferedReader br=new BufferedReader (new
InputStreamReader (System.in) ) ;
    br.readLine () ;
    createBusyThread () ;
    br.readLine () ;
    Object obj=new Object () ;
    createLockThread (obj) ;
}
```

程序运行后，首先在“线程”页签中选择main线程，如图4-7所示。堆栈追踪显示BufferedReader在readBytes方法中等待System.in的键盘输入，这时线程为Runnable状态，Runnable状态的线程会被分配运行时间，但readBytes方法检查到流没有更新时会立刻归还执行令牌，这种等待只消耗很小的CPU资源。



图 4-7 main线程

接着监控testBusyThread线程，如图4-8所示，testBusyThread线程一直在执行空循环，从堆栈追踪中看到一直在MonitoringTest.java代码的41行停留，41行为：while（true）。这时候线程为Runnable状态，而且没有归还线程执行令牌的动作，会在空循环上用尽全部执行时间直到线程切换，这种等待会消耗较多的CPU资源。



图 4-8 testBusyThread线程

图4-9显示testLockThread线程在等待着lock对象的notify或notifyAll方法的出现，线程这时候处于WAITING状态，在被唤醒前不会被分配执行时间。



图 4-9 testLockThread线程

testLockThread线程正在处于正常的活锁等待，只要lock对象的notify（）或notifyAll（）方法被调用，这个线程便能激活以继续执行。代码清单4-10演示了一个无法再被激活的死锁等待。

代码清单4-10 死锁代码样例

```
/*
 *线程死锁等待演示
 */
static class SynAddRunalbe implements
Runnable{
    int a,b;
    public SynAddRunalbe (int a,int b) {
        this.a=a;
        this.b=b;
    }
    @Override
    public void run () {
        synchronized (Integer.valueOf (a) ) {
            synchronized (Integer.valueOf (b) ) {
                System.out.println (a+b) ;
            }
        }
    }
}
public static void main (String[]args) {
```

```
for (int i=0; i<100; i++) {  
    new Thread (new SynAddRunalbe (1,  
2) ) .start () ;  
    new Thread (new SynAddRunalbe (2,  
1) ) .start () ;  
}  
}
```

这段代码开了200个线程去分别计算 $1+2$ 以及 $2+1$ 的值，其实for循环是可省略的，两个线程也可能会导致死锁，不过那样概率太小，需要尝试运行很多次才能看到效果。一般的话，带for循环的版本最多运行2~3次就会遇到线程死锁，程序无法结束。造成死锁的原因是Integer.valueOf()方法基于减少对象创建次数和节省内存的考虑，[-128, 127]之间的数字会被缓存^[3]，当valueOf()方法传入参数在这个范围之内，将直接返回缓存中的对象。也就是说，代码中调用了200次Integer.valueOf()方法一共就只返回了两

个不同的对象。假如在某个线程的两个 synchronized 块之间发生了一次线程切换，那就会出现线程 A 等着被线程 B 持有的 Integer.valueOf(1)，线程 B 又等着被线程 A 持有的 Integer.valueOf(2)，结果出现大家都跑不下去的情景。

出现线程死锁之后，点击 JConsole 线程面板的“检测到死锁”按钮，将出现一个新的“死锁”页签，如图 4-10 所示。



图 4-10 线程死锁

图4-10中很清晰地显示了线程Thread-43在等待一个被线程Thread-12持有Integer对象，而点击线程Thread-12则显示它也在等待一个Integer对象，被线程Thread-43持有，这样两个线程就互相卡住，都不存在等到锁释放的希望了。

[1]VisualVM官方站点：

<https://visualvm.dev.java.net/>。

[2]准确地说，只有在虚拟机使用解释器执行的时候，“在作用域之内”才能保证它不会被回收，因为这里的回收还涉及局部变量表Slot复用、即时编译器介入时机等问题，具体读者可参考第8章中关于局部变量表内存回收的例子。

[3]默认值，实际值取决于

`java.lang.Integer.IntegerCache.high`参数的设置。

4.3.2 VisualVM：多合一故障处理工具

VisualVM（All-in-One Java Troubleshooting Tool）是到目前为止随JDK发布的功能最强大的运行监视和故障处理程序，并且可以预见在未来一段时间内都是官方主力发展的虚拟机故障处理工具。官方在VisualVM的软件说明中写上了“All-in-One”的描述字样，预示着它除了运行监视、故障处理外，还提供了很多其他方面的功能。如性能分析（Profiling），VisualVM的性能分析功能甚至比起JProfiler、YourKit等专业且收费的Profiling工具都不会逊色多少，而且VisualVM的还有一个很大的优点：不需要被监视的程序基于特殊Agent运行，因此它对应用程序的实际性能的

影响很小，使得它可以直接应用在生产环境中。这个优点是JProfiler、YourKit等工具无法与之媲美的。

1. VisualVM兼容范围与插件安装

VisualVM基于NetBeans平台开发，因此它一开始就具备了插件扩展功能的特性，通过插件扩展支持，VisualVM可以做到：

显示虚拟机进程以及进程的配置、环境信息（jps、jinfo）。

监视应用程序的CPU、GC、堆、方法区以及线程的信息（jstat、jstack）。

dump以及分析堆转储快照（jmap、jhat）。

方法级的程序运行性能分析，找出被调用最多、运行时间最长的方法。

离线程序快照：收集程序的运行时配置、线程dump、内存dump等信息建立一个快照，可以将快照发送开发者处进行Bug反馈。

其他plugins的无限的可能性.....

VisualVM在JDK 1.6 update 7中才首次出现，但并不意味着它只能监控运行于JDK 1.6上的程序，它具备很强的向下兼容能力，甚至能向下兼容至近10年前发布的JDK 1.4.2平台^[1]，这对无数已经处于实施、维护的项目很有意义。当然，并非所有功能都能完美地向下兼容，主要特性的兼容性见表4-6。

表 4-6 VisualVM 主要特性的兼容性列表

| 特性 | JDK 1.4.2 | JDK 1.5 | JDK 1.6 local | JDK 1.6 remote |
|-------------|-----------|---------|---------------|----------------|
| 运行环境信息 | √ | √ | √ | √ |
| 系统属性 | | | √ | |
| 监视面板 | √ | √ | √ | √ |
| 线程面板 | | √ | √ | √ |
| 性能监控 | | | √ | |
| 堆、线程 Dump | | | √ | |
| MBean 管理 | | √ | √ | √ |
| JConsole 插件 | | √ | √ | √ |

首次启动VisualVM后，读者先不必着急找应用程序进行监测，因为现在VisualVM还没有加载任何插件，虽然基本的监视、线程面板的功能主程序都以默认插件的形式提供了，但是不给VisualVM装任何扩展插件，就相当于放弃了它最精华的功能，和没有安装任何应用软件操作系统差不多。

插件可以进行手工安装，在相关网站[\[2\]](#)上下载*.nbm包后，点击“工具”→“插件”→“已下载”菜单，然后在弹出的对话框中指定nbm包路径便可

进行安装，插件安装后存放在
JDK_HOME/lib/visualvm/visualvm中。不过手工安
装并不常用，使用VisualVM的自动安装功能已经
可以找到大多数所需的插件，在有网络连接的环
境下，点击“工具”→“插件菜单”，弹出如图4-11
所示的插件页签，在页签的“可用插件”中列举了
当前版本VisualVM可以使用的插件，选中插件后
在右边窗口将显示这个插件的基本信息，如开发
者、版本、功能描述等。



图 4-11 VisualVM插件页签

大家可以根据自己的工作需要和兴趣选择合适的插件，然后点击安装按钮，弹出如图4-12所示的下载进度窗口，跟着提示操作即可完成安装。




图 4-12 VisualVM 插件安装过程

安装完插件，选择一个需要监视的程序就进入程序的主界面了，如图4-13所示。根据读者选择安装插件数量的不同，看到的页签可能和图4-13中的有所不同。



图 4-13 VisualVM 主界面

VisualVM中“概述”、“监视”、“线程”、“MBeans”的功能与前面介绍的JConsole差别不大，读者根据上文内容类比使用即可，下面挑选几个特色功能、插件进行介绍。

2.生成、浏览堆转储快照

在VisualVM中生成dump文件有两种方式，可以执行下列任一操作：

在“应用程序”窗口中右键单击应用程序节点，然后选择“堆Dump”。

在“应用程序”窗口中双击应用程序节点以打开应用程序标签，然后在“监视”标签中单击“堆Dump”。

生成了dump文件之后，应用程序页签将在该堆的应用程序下增加一个以[heapdump]开头的子节点，并且在主页签中打开了该转储快照，如图4-14所示。如果需要把dump文件保存或发送出去，要在heapdump节点上右键选择“另存为”菜单，否则当VisualVM关闭时，生成的dump文件会被当做临时文件删除掉。要打开一个已经存在的

dump文件，通过文件菜单中的“装入”功能，选择硬盘上的dump文件即可。




图 4-14 浏览dump文件

从堆页签中的“摘要”面板可以看到应用程序dump时的运行时参数、System.getProperties() 的内容、线程堆栈等信息，“类”面板则是以类为

统计口径统计类的实例数量、容量信息，“实例”面板不能直接使用，因为不能确定用户想查看哪个类的实例，所以需要通过“类”面板进入，在“类”中选择一个关心的类后双击鼠标，即可在“实例”里面看见此类中500个实例的具体属性信息。“OQL控制台”面板中就是运行OQL查询语句的，同jhat中介绍的OQL功能一样。如果需要了解具体OQL语法和使用，可参见本书附录D的内容。

3. 分析程序性能

在Profiler页签中，VisualVM提供了程序运行期间方法级的CPU执行时间分析以及内存分析，做Profiling分析肯定会对程序运行性能有比较大的影响，所以一般不在生产环境中使用这项功

能。

要开始分析，先选择“CPU”和“内存”按钮中的一个，然后切换到应用程序中对程序进行操作，VisualVM会记录到这段时间中应用程序执行过的方法。如果是CPU分析，将会统计每个方法的执行次数、执行耗时；如果是内存分析，则会统计每个方法关联的对象数以及这些对象所占的空间。分析结束后，点击“停止”按钮结束监控过程，如图4-15所示。




图 4-15 对应用程序进行CPU执行时间分析

注意 在JDK 1.5之后，在Client模式下的虚拟机加入并且自动开启了类共享——这是一个在多虚拟机进程中共享rt.jar中类数据以提高加载速度和节省内存的优化，而根据相关Bug报告的反映，VisualVM的Profiler功能可能会因为类共享而导致被监视的应用程序崩溃，所以读者进行

Profiling前，最好在被监视程序中使用-Xshare:
off参数来关闭类共享优化。

图4-15中是对Eclipse IDE一段操作的录制和分析结果，读者分析自己的应用程序时，可以根据实际业务的复杂程度与方法的时间、调用次数做比较，找到最有优化价值的方法。

4.BTrace动态日志跟踪

BTrace^[3]是一个很“有趣”的VisualVM插件，本身也是可以独立运行的程序。它的作用是在不停止目标程序运行的前提下，通过HotSpot虚拟机的HotSwap技术^[4]动态加入原本并不存在的调试代码。这项功能对实际生产中的程序很有意义：经常遇到程序出现问题，但排查错误的一些必要信息，譬如方法参数、返回值等，在开发时并没

有打印到日志之中，以至于不得不停掉服务，通过调试增量来加入日志代码以解决问题。当遇到生产环境服务无法随便停止时，缺一两句日志导致排错进行不下去是一件非常郁闷的事情。

在VisualVM中安装了BTrace插件后，在应用程序面板中右键点击要调试的程序，会出现“Trace Application.....”菜单，点击将进入BTrace面板。这个面板里面看起来就像一个简单的Java程序开发环境，里面还有一小段Java代码，如图4-16所示。




图 4-16 BTrace动态跟踪

笔者准备了一段很简单的Java代码来演示BTrace的功能：产生两个1000以内的随机整数，输出这两个数字相加的结果，如代码清单4-11所示。

代码清单4-11 BTrace跟踪演示

```
public class BTraceTest{  
    public int add (int a,int b) {  
        return a+b;  
    }  
    public static void main (String[]args)  
throws IOException{  
    BTraceTest test=new BTraceTest () ;  
    BufferedReader reader=new  
BufferedReader (new  
InputStreamReader (System.in) ) ;  
    for (int i=0; i<10; i++) {  
        reader.readLine () ;  
        int a= (int) Math.round (Math.random ()  
*1000) ;  
        int b= (int) Math.round (Math.random ()  
*1000) ;  
        System.out.println (test.add (a,b) ) ;  
    }  
}
```

程序运行后，在VisualVM中打开该程序的监视，在BTrace页签填充TracingScript的内容，输入的调试代码如代码清单4-12所示。

代码清单4-12 BTrace调试代码

```
/*BTrace Script Template*/
import com.sun.btrace.annotations.*;
import static com.sun.btrace.BTraceUtils.*;
@BTrace
public class TracingScript{
@OnMethod (
clazz="org.fenixsoft.monitoring.BTraceTest",
method="add",
location=@Location (Kind.RETURN)
)
public static void func (@Self
org.fenixsoft.monitoring.BTraceTest
instance,int a,int b, @Return int result) {
println ("调用堆栈: ");
jstack ();
println (strcat ("方法参数A: ", str (a) ) );
println (strcat ("方法参数B: ", str (b) ) );
println (strcat ("方法结果: ",
str (result) ) );
}
}
```

点击“Start”按钮后稍等片刻，编译完成后，可见Output面板中出现“BTrace code successfully deployed”的字样。程序运行的时候在Output面板将会输出如图4-17所示的调试信息。




图 4-17 BTrace跟踪结果

BTrace的用法还有许多，打印调用堆栈、参数、返回值只是最基本的应用，在它的网站上有使用BTrace进行性能监视、定位连接泄漏和内存泄漏、解决多线程竞争问题等例子，有兴趣的读者可以去相关网站了解一下。

- [1]早于JDK1.6的平台，需要打开-Dcom.sun.management.jmxremote参数才能被VisualVM管理。
- [2]插件中心地址：<http://Visualvm.java.net/pluginscenters.html>。
- [3]官方主页：<http://kenai.com/projects/btrace/>。
- [4]HotSwap技术：代码热替换技术，HotSpot虚拟机允许在不停止运行的情况下，更新已经加载的类的代码。

4.4 本章小结

本章介绍了随JDK发布的6个命令行工具及两个可视化的故障处理工具，灵活使用这些工具可以给问题处理带来很大的便利。

除了JDK自带的工具之外，常用的故障处理工具还有很多，如果读者使用的是非Sun系列的JDK、非HotSpot的虚拟机，就需要使用对应的工具进行分析，如：

IBM的Support Assistant^[1]、Heap Analyzer^[2]、Javacore Analyzer^[3]、Garbage Collector Analyzer^[4]适用于IBM J9 VM。

HP的HPjmeter^[5]、HPjtune适用于HP-UX、

SAP、HotSpot VM。

Eclipse的Memory Analyzer Tool^[6]（MAT）适用于HP-UX、SAP、HotSpot VM，安装IBM DTFJ插件后可支持IBM J9 VM。

BEA的JRockit Mission Control^[7]适用于JRockit VM。

[1]<http://www.alphaworks.ibm.com/tech/heapanalyzer>

[2]<http://www.alphaworks.ibm.com/tech/jca/download>

[3]<http://www.alphaworks.ibm.com/tech/pmat/download>

[4]<https://h20392.www2.hp.com/portal/swdepot/display.html?productNumber=HPJMETER>。

[5]<http://www.eclipse.org/mat/>。

[6]<http://www.ibm.com/developerworks/java/jdk/tools/memory-analyzer/>

[7]http://download.oracle.com/docs/cd/E13150_01/jrockit_missioncontrol/index.html

第5章 调优案例分析与实战

Java与C++之间有一堵由内存动态分配和垃圾收集技术所围成的“高墙”，墙外面的人想进去，墙里面的人却想出来。

5.1 概述

上文介绍了处理Java虚拟机内存问题的知识与工具，在处理实际项目的问题时，除了知识与工具外，经验同样是一个很重要的因素。因此本章将与读者分享几个比较有代表性的实际案例。考虑到虚拟机故障处理和调优主要面向各类服务端应用，而大部分Java程序员较少有机会直接接触生产环境的服务器，因此本章还准备了一个所

有开发人员都能够进行“亲身实战”的练习，希望通过实践使读者获得故障处理和调优的经验。

5.2 案例分析

本章中的案例大部分来源于笔者处理过的一些问题，还有一小部分来源于网络上比较有特色和代表性的案例总结。出于对客户商业信息保护的目的，在不影响前后逻辑的前提下，笔者对实际环境和用户业务做了一些屏蔽和精简。

5.2.1 高性能硬件上的程序部署策略

例如，一个15万PV/天左右的在线文档类型网站最近更换了硬件系统，新的硬件为4个CPU、16GB物理内存，操作系统为64位CentOS 5.4，Resin作为Web服务器。整个服务器暂时没有部署别的应用，所有硬件资源都可以提供给这访问量

并不算太大的网站使用。管理员为了尽量利用硬件资源选用了64位的JDK 1.5，并通过-Xmx和-Xms参数将Java堆固定在12GB。使用一段时间后发现使用效果并不理想，网站经常不定期出现长时间失去响应的情况。

监控服务器运行状况后发现网站失去响应是由GC停顿导致的，虚拟机运行在Server模式，默认使用吞吐量优先收集器，回收12GB的堆，一次Full GC的停顿时间高达14秒。并且由于程序设计的关系，访问文档时要把文档从磁盘提取到内存中，导致内存中出现很多由文档序列化产生的大对象，这些大对象很多都进入了老年代，没有在Minor GC中清理掉。这种情况下即使有12GB的堆，内存也很快被消耗殆尽，由此导致每隔十几分钟出现十几秒的停顿，令网站开发人员和管理

员感到很沮丧。

这里先不延伸讨论程序代码问题，程序部署上的主要问题是过大的堆内存进行回收时带来的长时间的停顿。硬件升级前使用32位系统1.5GB的堆，用户只感觉到使用网站比较缓慢，但不会发生十分明显的停顿，因此才考虑升级硬件以提升程序效能，如果重新缩小给Java堆分配的内存，那么硬件上的投资就显得很浪费。

在高性能硬件上部署程序，目前主要有两种方式：

通过64位JDK来使用大内存。

使用若干个32位虚拟机建立逻辑集群来利用硬件资源。

此案例中的管理员采用了第一种部署方式。

对于用户交互性强、对停顿时间敏感的系统，可以给Java虚拟机分配超大堆的前提是有把握把应用程序的Full GC频率控制得足够低，至少要低到不会影响用户使用，譬如十几个小时乃至一天才出现一次Full GC，这样可以通过在深夜执行定时任务的方式触发Full GC甚至自动重启应用服务器来保持内存可用空间在一个稳定的水平。

控制Full GC频率的关键是看应用中绝大多数对象能否符合“朝生夕灭”的原则，即大多数对象的生存时间不应太长，尤其是不能有成批量的、长生存时间的大对象产生，这样才能保障老年代空间的稳定。

在大多数网站形式的应用里，主要对象的生

存周期都应该是请求级或者页面级的，会话级和全局级的长生命对象相对很少。只要代码写得合理，应当都能实现在超大堆中正常使用而没有Full GC，这样的话，使用超大堆内存时，网站响应速度才会比较有保证。除此之外，如果读者计划使用64位JDK来管理大内存，还需要考虑下面可能面临的问题：

内存回收导致的长时间停顿。

现阶段，64位JDK的性能测试结果普遍低于32位JDK。

需要保证程序足够稳定，因为这种应用要是产生堆溢出几乎就无法产生堆转储快照（因为要产生十几GB乃至更大的Dump文件），哪怕产生了快照也几乎无法进行分析。

相同程序在64位JDK消耗的内存一般比32位JDK大，这是由于指针膨胀，以及数据类型对齐补白等因素导致的。

上面的问题听起来有点吓人，所以现阶段不少管理员还是选择第二种方式：使用若干个32位虚拟机建立逻辑集群来利用硬件资源。具体做法是在一台物理机器上启动多个应用服务器进程，每个服务器进程分配不同端口，然后在前端搭建一个负载均衡器，以反向代理的方式来分配访问请求。读者不需要太过在意均衡器转发所消耗的性能，即使使用64位JDK，许多应用也不止有一台服务器，因此在许多应用中前端的均衡器总是要存在的。

考虑到在一台物理机器上建立逻辑集群的目

的仅仅是为了尽可能利用硬件资源，并不需要关心状态保留、热转移之类的高可用性需求，也不需要保证每个虚拟机进程有绝对准确的均衡负载，因此使用无Session复制的亲合式集群是一个相当不错的选择。我们仅仅需要保障集群具备亲合性，也就是均衡器按一定的规则算法（一般根据SessionID分配）将一个固定的用户请求永远分配到固定的一个集群节点进行处理即可，这样程序开发阶段就基本不用为集群环境做什么特别的考虑了。

当然，很少有没有缺点的方案，如果读者计划使用逻辑集群的方式来部署程序，可能会遇到下面一些问题：

尽量避免节点竞争全局的资源，最典型的就

是磁盘竞争，各个节点如果同时访问某个磁盘文件的话（尤其是并发写操作容易出现问题），很容易导致IO异常。

很难最高效率地利用某些资源池，譬如连接池，一般都是在各个节点建立自己独立的连接池，这样有可能导致一些节点池满了而另外一些节点仍有较多空余。尽管可以使用集中式的JNDI，但这个有一定复杂性并且可能带来额外的性能开销。

各个节点仍然不可避免地受到32位的内存限制，在32位Windows平台中每个进程只能使用2GB的内存，考虑到堆以外的内存开销，堆一般最多只能开到1.5GB。在某些Linux或UNIX系统（如Solaris）中，可以提升到3GB乃至接近4GB

的内存，但32位中仍然受最高4GB（ 2^{32} ）内存的限制。

大量使用本地缓存（如大量使用HashMap作为K/V缓存）的应用，在逻辑集群中会造成较大的内存浪费，因为每个逻辑节点上都有一份缓存，这时候可以考虑把本地缓存改为集中式缓存。

介绍完这两种部署方式，再重新回到这个案例之中，最后的部署方案调整为建立5个32位JDK的逻辑集群，每个进程按2GB内存计算（其中堆固定为1.5GB），占用了10GB内存。另外建立一个Apache服务作为前端均衡代理访问门户。考虑到用户对响应速度比较关心，并且文档服务的主要压力集中在磁盘和内存访问，CPU资源敏感度

较低，因此改为CMS收集器进行垃圾回收。部署方式调整后，服务再没有出现长时间停顿，速度比硬件升级前有较大提升。

5.2.2 集群间同步导致的内存溢出

例如，有一个基于B/S的MIS系统，硬件为两台2个CPU、8GB内存的HP小型机，服务器是WebLogic 9.2，每台机器启动了3个WebLogic实例，构成一个6个节点的亲合式集群。由于是亲合式集群，节点之间没有进行Session同步，但是有一些需求要实现部分数据在各个节点间共享。开始这些数据存放在数据库中，但由于读写频繁竞争很激烈，性能影响较大，后面使用JBossCache构建了一个全局缓存。全局缓存启用后，服务正常使用了一段较长的时间，但最近却不定期地出现了多次的内存溢出问题。

在内存溢出异常不出现的时候，服务内存回

收状况一直正常，每次内存回收后都能恢复到一个稳定的可用空间，开始怀疑是程序某些不常用的代码路径中存在内存泄漏，但管理员反映最近程序并未更新、升级过，也没有进行什么特别操作。只好让服务带着-XX:

+HeapDumpOnOutOfMemoryError参数运行了一段时间。在最近一次溢出之后，管理员发回了heapdump文件，发现里面存在着大量的org.jgroups.protocols.pbcast.NAKACK对象。

JBossCache是基于自家的JGroups进行集群间的数据通信，JGroups使用协议栈的方式来实现收发数据包的各种所需特性自由组合，数据包接收和发送时要经过每层协议栈的up（）和down（）方法，其中的NAKACK栈用于保障各个包的有效顺序及重发。JBossCache协议栈如图5-1所示。

```
Daemon Thread [DownHandler (VIEW_SYNC)] (Suspended breakpoint at line 401 in NAKACK)
=====  
    NAKACK.down(Event) line: 401  
    NAKACK(Protocol).receiveDownEvent(Event) line: 517  
    UNICAST(Protocol).passDown(Event) line: 551  
    UNICAST.down(Event) line: 355  
    UNICAST(Protocol).receiveDownEvent(Event) line: 517  
    STABLE(Protocol).passDown(Event) line: 551  
    STABLE.down(Event) line: 283  
    STABLE(Protocol).receiveDownEvent(Event) line: 517  
    FRAG(Protocol).passDown(Event) line: 551  
    FRAG.down(Event) line: 139  
    FRAG(Protocol).receiveDownEvent(Event) line: 517  
    VIEW_SYNC(Protocol).passDown(Event) line: 551  
    VIEW_SYNC.down(Event) line: 166  
    DownHandler.run() line: 121
```

图 5-1 JBossCache 协议栈

由于信息有传输失败需要重发的可能性，在确认所有注册在GMS（Group Membership Service）的节点都收到正确的信息前，发送的信息必须在内存中保留。而此MIS的服务端中有一个负责安全校验的全局Filter，每当接收到请求时，均会更新一次最后操作时间，并且将这个时间同步到所有的节点去，使得一个用户在一段时间内不能在多台机器上登录。在服务使用过程

中，往往一个页面会产生数次乃至数十次的请求，因此这个过滤器导致集群各个节点之间网络交互非常频繁。当网络情况不能满足传输要求时，重发数据在内存中不断堆积，很快就产生了内存溢出。

这个案例中的问题，既有JBossCache的缺陷，也有MIS系统实现方式上缺陷。JBossCache官方的maillist中讨论过很多次类似的内存溢出异常问题，据说后续版本也有了改进。而更重要的缺陷是这一类被集群共享的数据要使用类似JBossCache这种集群缓存来同步的话，可以允许读操作频繁，因为数据在本地内存有一份副本，读取的动作不会耗费多少资源，但不应当有过于频繁的写操作，那样会带来很大的网络同步的开销。

5.2.3 堆外内存导致的溢出错误

例如，一个学校的小型项目：基于B/S的电子考试系统，为了实现客户端能实时地从服务器端接收考试数据，系统使用了逆向AJAX技术（也称为Comet或者Server Side Push），选用CometD 1.1.1作为服务端推送框架，服务器是Jetty 7.1.4，硬件为一台普通PC机，Core i5 CPU，4GB内存，运行32位Windows操作系统。

测试期间发现服务端不定时抛出内存溢出异常，服务器不一定每次都会出现异常，但假如正式考试时崩溃一次，那估计整场电子考试都会乱套，网站管理员尝试过把堆开到最大，而32位系统最多到1.6GB就基本无法再加大了，而且开大

了基本没效果，抛出内存溢出异常好像还更加频繁了。加入-XX:

+HeapDumpOnOutOfMemoryError，居然也没有任何反应，抛出内存溢出异常时什么文件都没有产生。无奈之下只好挂着jstat并一直紧盯屏幕，发现GC并不频繁，Eden区、Survivor区、老年代以及永久代内存全部都表示“情绪稳定，压力不大”，但就是照样不停地抛出内存溢出异常，管理员压力很大。最后，在内存溢出后从系统日志中找到异常堆栈，如代码清单5-1所示。

代码清单5-1 异常堆栈

```
[org.eclipse.jetty.util.log]handle failed  
java.lang.OutOfMemoryError: null  
    at sun.misc.Unsafe.allocateMemory (Native  
Method)  
    at java.nio.DirectByteBuffer.<init>  
(DirectByteBuffer.java: 99)  
    at
```

```
java.nio.ByteBuffer.allocateDirect (ByteBuffer.j  
288)  
    at org.eclipse.jetty.io.nio.DirectNIOBuffer.  
<init>  
.....
```

如果认真阅读过本书的第2章，看到异常堆栈就应该清楚这个抛出内存溢出异常是怎么回事了。大家知道操作系统对每个进程能管理的内存是有限制的，这台服务器使用的32位Windows平台的限制是2GB，其中划了1.6GB给Java堆，而Direct Memory内存并不算入1.6GB的堆之内，因此它最大也只能在剩余的0.4GB空间中分出一部分。在此应用中导致溢出的关键是：垃圾收集进行时，虚拟机虽然会对Direct Memory进行回收，但是Direct Memory却不能像新生代、老年代那样，发现空间不足了就通知收集器进行垃圾回收，它只能等待老年代满了后Full GC，然后“顺

便地”帮它清理掉内存的废弃对象。否则它只能一直等到抛出内存溢出异常时，先catch掉，再在catch块里面“大喊”一声：“System.gc（）！””。要是虚拟机还是不听（譬如打开了-XX:+DisableExplicitGC开关），那就只能眼睁睁地看着堆中还有许多空闲内存，自己却不得不抛出内存溢出异常了。而本案例中使用的CometD 1.1.1 框架，正好有大量的NIO操作需要使用到Direct Memory内存。

从实践经验的角度出发，除了Java堆和永久代之外，我们注意到下面这些区域还会占用较多的内存，这里所有的内存总和受到操作系统进程最大内存的限制。

Direct Memory： 可通过-XX:

MaxDirectMemorySize调整大小，内存不足时抛出
OutOfMemoryError或者OutOfMemoryError: Direct
buffer memory。

线程堆栈：可通过-Xss调整大小，内存不足
时抛出StackOverflowError（纵向无法分配，即无
法分配新的栈帧）或者OutOfMemoryError:
unable to create new native thread（横向无法分
配，即无法建立新的线程）。

Socket缓存区：每个Socket连接都Receive和
Send两个缓存区，分别占大约37KB和25KB内
存，连接多的话这块内存占用也比较可观。如果
无法分配，则可能会抛出IOException: Too many
open files异常。

JNI代码：如果代码中使用JNI调用本地库，

那本地库使用的内存也不在堆中。

虚拟机和GC： 虚拟机、GC的代码执行也要消耗一定的内存。

5.2.4 外部命令导致系统缓慢

这是一个来自网络的案例：一个数字校园应用系统，运行在一台4个CPU的Solaris 10操作系统上，中间件为GlassFish服务器。系统在做大并发压力测试的时候，发现请求响应时间比较慢，通过操作系统的mpstat工具发现CPU使用率很高，并且系统占用绝大多数的CPU资源的程序并不是应用系统本身。这是个不正常的现象，通常情况下用户应用的CPU占用率应该占主要地位，才能说明系统是正常工作的。

通过Solaris 10的Dtrace脚本可以查看当前情况下哪些系统调用花费了最多的CPU资源，Dtrace运行后发现最消耗CPU资源的竟然

是“fork”系统调用。众所周知，“fork”系统调用是Linux用来产生新进程的，在Java虚拟机中，用户编写的Java代码最多只有线程的概念，不应当有进程的产生。

这是个非常异常的现象。通过本系统的开发人员，最终找到了答案：每个用户请求的处理都需要执行一个外部shell脚本来获得系统的一些信息。执行这个shell脚本是通过Java的Runtime.getRuntime（）.exec（）方法来调用的。这种调用方式可以达到目的，但是它在Java虚拟机中是非常消耗资源的操作，即使外部命令本身能很快执行完毕，频繁调用时创建进程的开销也非常可观。Java虚拟机执行这个命令的过程是：首先克隆一个和当前虚拟机拥有一样环境变量的进程，再用这个新的进程去执行外部命令，最后

再退出这个进程。如果频繁执行这个操作，系统的消耗会很大，不仅是CPU，内存负担也很重。

用户根据建议去掉这个Shell脚本执行的语句，改为使用Java的API去获取这些信息后，系统很快恢复了正常。

5.2.5 服务器JVM进程崩溃

例如，一个基于B/S的MIS系统，硬件为两台2个CPU、8GB内存的HP系统，服务器是WebLogic 9.2（就是5.2.2节中的那套系统）。正常运行一段时间后，最近发现在运行期间频繁出现集群节点的虚拟机进程自动关闭的现象，留下了一个hs_err_pid##.log文件后，进程就消失了，两台物理机器里的每个节点都出现过进程崩溃的现象。从系统日志中可以看出，每个节点的虚拟机进程在崩溃前不久，都发生过大量相同的异常，见代码清单5-2。

代码清单5-2 异常堆栈2

```
java.net.SocketException: Connection reset
```

```
at  
java.net.SocketInputStream.read (SocketInputStre  
168)  
    at  
java.io.BufferedInputStream.fill (BufferedInputs  
218)  
    at  
java.io.BufferedInputStream.read (BufferedInputs  
235)  
    at  
org.apache.axis.transport.http.HTTPSender.readHe  
583)  
    at  
org.apache.axis.transport.http.HTTPSender.invoke  
143) .....99 more
```

这是一个远端断开连接的异常，通过系统管理员了解到系统最近与一个OA门户做了集成，在MIS系统工作流的待办事项变化时，要通过Web服务通知OA门户系统，把待办事项的变化同步到OA门户之中。通过SoapUI测试了一下同步待办事项的几个Web服务，发现调用后竟然需要长达3分钟才能返回，并且返回结果都是连接中

断。

由于MIS系统的用户多，待办事项变化很快，为了不被OA系统速度拖累，使用了异步的方式调用Web服务，但由于两边服务速度的完全不对等，时间越长就累积了越多Web服务没有调用完成，导致在等待的线程和Socket连接越来越多，最终在超过虚拟机的承受能力后使得虚拟机进程崩溃。解决方法：通知OA门户方修复无法使用的集成接口，并将异步调用改为生产者/消费者模式的消息队列实现后，系统恢复正常。

5.2.6 不恰当数据结构导致内存占用过大

例如，有一个后台RPC服务器，使用64位虚拟机，内存配置为-Xms4g-Xmx8g-Xmn1g，使用ParNew+CMS的收集器组合。平时对外服务的Minor GC时间约在30毫秒以内，完全可以接受。但业务上需要每10分钟加载一个约80MB的数据文件到内存进行数据分析，这些数据会在内存中形成超过100万个HashMap<Long,Long>Entry，在这段时间里面Minor GC就会造成超过500毫秒的停顿，对于这个停顿时间就受不了了，具体情况如下面GC日志所示。

```
{Heap before GC invocations=95 (full 4):
  par new generation total 903168K, used
803142K[0x00002aaaae770000, 0x00002aaaebb70000,
0x00002aaaebb70000)
```

eden space 802816K,
100%used[0x00002aaaae770000,
0x00002aaadf770000, 0x00002aaadf770000)
 from space 100352K,
0%used[0x00002aaaae5970000, 0x00002aaaae59c1910,
0x00002aaaebb70000)
 to space 100352K,
0%used[0x00002aaadf770000, 0x00002aaadf770000,
0x00002aaaae5970000)
 concurrent mark-sweep generation total
5845540K, used 3898978K[0x00002aaaebb70000,
0x00002aac507f9000, 0x00002aacae770000)
 concurrent-mark-sweep perm gen total
65536K, used 40333K[0x00002aacae770000,
0x00002aacb2770000, 0x00002aacb2770000)
2 0 1 1-1 0-2 8 T 1 1: 4 0: 4 5.1 6 2+0 8 0
0: 2 2 6.5 0 4: [G C 2 2 6.5 0 4: [P a r N e w:
803142K->100352K (903168K), 0.5995670
secs] 4702120K->4056332K (6748708K), 0.5997560
secs] [Times: user=1.46 sys=0.04, real=0.60
secs]
 Heap after GC invocations=96 (full 4):
 par new generation total 903168K, used
100352K[0x00002aaaae770000, 0x00002aaaebb70000,
0x00002aaaebb70000)
 eden space 802816K,
0%used[0x00002aaaae770000, 0x00002aaaae770000,
0x00002aaadf770000)
 from space 100352K,
100%used[0x00002aaadf770000,
0x00002aaaae5970000,
0x00002aaaae5970000)
 to space 100352K, 0x00002aaaebb70000)
0%used[0x00002aaaae5970000, 0x00002aaaae5970000,

```
concurrent mark-sweep generation total  
5845540K, used 3955980K[0x00002aaaebb70000,  
0x00002aac507f9000, 0x00002aacae770000)  
concurrent-mark-sweep perm gen total  
65536K, used 40333K[0x00002aacae770000,  
0x00002aacb2770000, 0x00002aacb2770000)  
}  
Total time for which application threads  
were stopped: 0.6070570 seconds
```

观察这个案例，发现平时的Minor GC时间很短，原因是新生代的绝大部分对象都是可清除的，在Minor GC之后Eden和Survivor基本上处于完全空闲的状态。而在分析数据文件期间，800MB的Eden空间很快被填满从而引发GC，但Minor GC之后，新生代中绝大部分对象依然是存活的。我们知道ParNew收集器使用的是复制算法，这个算法的高效是建立在大部分对象都“朝生夕灭”的特性上的，如果存活对象过多，把这些对象复制到Survivor并维持这些对象引用的正

确就成为一个沉重的负担，因此导致GC暂停时间明显变长。

如果不修改程序，仅从GC调优的角度去解决这个问题，可以考虑将Survivor空间去掉（加入参数-XX: SurvivorRatio=65536、-XX: MaxTenuringThreshold=0或者-XX: +AlwaysTenure），让新生代中存活的对象在第一次Minor GC后立即进入老年带，等到Major GC的时候再清理它们。这种措施可以治标，但也有很大副作用，治本的方案需要修改程序，因为这里的问题产生的根本原因是用HashMap<Long, Long>结构来存储数据文件空间效率太低。

下面具体分析一下空间效率。在HashMap<Long, Long>结构中，只有Key和Value所存放的两

个长整型数据是有效数据，共16B（ $2 \times 8B$ ）。这两个长整型数据包装成java.lang.Long对象之后，就分别具有8B的MarkWord、8B的Klass指针，在加8B存储数据的long值。在这两个Long对象组成Map.Entry之后，又多了16B的对象头，然后一个8B的next字段和4B的int型的hash字段，为了对齐，还必须添加4B的空白填充，最后还有HashMap中对这个Entry的8B的引用，这样增加两个长整型数字，实际耗费的内存为

$(\text{Long } (24B) \times 2 + \text{Entry } (32B) + \text{HashMap Ref } (8B)) = 88B$ ，空间效率为 $16B / 88B = 18\%$ ，实在太低了。

5.2.7 由Windows虚拟内存导致的长时间停顿[1]

例如，有一个带心跳检测功能的GUI桌面程序，每15秒会发送一次心跳检测信号，如果对方30秒以内都没有信号返回，那就认为和对方程序的连接已经断开。程序上线后发现心跳检测有误报的概率，查询日志发现误报的原因是程序会偶尔出现间隔约一分钟左右的时间完全无日志输出，处于停顿状态。

因为是桌面程序，所需的内存并不大（-Xmx256m），所以开始并没有想到是GC导致的程序停顿，但是加入参数-XX:
+PrintGCAapplicationStoppedTime-XX:

+PrintGCDateStamps-Xloggc: gclog.log后，从GC日志文件中确认了停顿确实是由GC导致的，大部分GC时间都控制在100毫秒以内，但偶尔就会出现一次接近1分钟的GC。

```
Total time for which application threads  
were stopped: 0.0112389 seconds
```

```
Total time for which application threads  
were stopped: 0.0001335 seconds
```

```
Total time for which application threads  
were stopped: 0.0003246 seconds
```

```
Total time for which application threads  
were stopped: 41.4731411 seconds
```

```
Total time for which application threads  
were stopped: 0.0489481 seconds
```

```
Total time for which application threads  
were stopped: 0.1110761 seconds
```

```
Total time for which application threads  
were stopped: 0.0007286 seconds
```

```
Total time for which application threads  
were stopped: 0.0001268 seconds
```

从GC日志中找到长时间停顿的具体日志信息（添加了-XX: +PrintReferenceGC参数），找到

的日志片段如下所示。从日志中可以看出，真正执行GC动作的时间不是很长，但从准备开始GC，到真正开始GC之间所消耗的时间却占了绝大部分。

```
2012-08-29T19:14:30.968+0800: 10069.800:  
[GC10099.225: [SoftReference, 0 refs, 0.0000109  
secs]10099.226: [WeakReference, 4072 refs,  
0.0012099 secs]10099.227: [FinalReference, 984  
refs, 1.5822450 secs]10100.809:  
[PhantomReference, 251 refs, 0.0001394  
secs]10100.809: [JNI Weak Reference, 0.0994015  
secs] [PSYoungGen: 175672K->  
8528K (167360K) ]251523K->100182K (353152K),  
31.1580402 secs] [Times: user=0.61 sys=0.52,  
real=31.16 secs]
```

除GC日志之外，还观察到这个GUI程序内存变化的一个特点，当它最小化的时候，资源管理中显示的占用内存大幅度减小，但是虚拟内存则没有变化，因此怀疑程序在最小化时它的工作内

存被自动交换到磁盘的页面文件之中了，这样发生GC时就有可能因为恢复页面文件的操作而导致不正常的GC停顿。

在MSDN上查证^[2]后确认了这种猜想，因此，在Java的GUI程序中要避免这种现象，可以加入参数“-

Dsun.awt.keepWorkingSetOnMinimize=true”来解决。这个参数在许多AWT的程序上都有应用，例如JDK自带的Visual VM，用于保证程序在恢复最小化时能够立即响应。在这个案例中加入该参数后，问题得到解决。

[1] 本案例来源于HLLVM组群的讨论：

<http://hllvm.group.iteye.com/group/topic/28745>。

[2]<http://support.microsoft.com/default.aspx?>

scid=kb; en-us; 293215。

5.3 实战：Eclipse运行速度调优

很多Java开发人员都有这样一种观念：系统调优的工作都是针对服务端应用而言，规模越大的系统，就越需要专业的调优运维团队参与。这个观点不能说不对，5.2节中笔者所列举的案例确实都是服务端运维、调优的例子，但服务端应用需要调优，并不说明其他应用就不需要了，作为一个普通的Java开发人员，前面讲的各种虚拟机的原理和最佳实践方法距离我们并不遥远，开发者身边很多场景都可以使用上面这些知识。下面通过一个普通程序员日常工作中可以随时接触到的开发工具开始这次实战。

5.3.1 调优前的程序运行状态

笔者使用Eclipse作为日常工作中的主要IDE工具，由于安装的插件比较大（如Klocwork、ClearCase LT等）、代码也很多，启动Eclipse直到所有项目编译完成需要四五分钟。一直对开发环境的速度感觉不满意，趁着编写这本书的机会，决定对Eclipse进行“动刀”调优。

笔者机器的Eclipse运行平台是32位Windows 7系统，虚拟机为HotSpot VM 1.5 b64。硬件为ThinkPad X201，Intel i5 CPU，4GB物理内存。在初始的配置文件eclipse.ini中，除了指定JDK的路径、设置最大堆为512MB以及开启了JMX管理（需要在VisualVM中收集原始数据）外，未做其他任何改动，原始配置内容如代码清单5-3所示。

代码清单5-3 Eclipse 3.5初始配置

```
-vm  
D: /_DevSpace/jdk1.5.0/bin/javaw.exe  
-startup  
plugins/org.eclipse.equinox.launcher_1.0.201  
--launcher.library  
plugins/org.eclipse.equinox.launcher.win32.w  
-product  
org.eclipse.epp.package.jee.product  
--launcher.XXMaxPermSize  
256M  
-showsplash  
org.eclipse.platform  
-vmargs  
-Dosgi.requiredJavaVersion=1.5  
-Xmx512m  
-Dcom.sun.management.jmxremote
```

为了要与调优后的结果进行量化对比，调优开始前笔者先做了一次初始数据测试。测试用例很简单，就是收集从Eclipse启动开始，直到所有插件加载完成为止的总耗时以及运行状态数据，虚拟机的运行数据通过VisualVM及其扩展插件VisualGC进行采集。测试过程中反复启动数次Eclipse直到测试结果稳定后，取最后一次运行的

结果作为数据样本（为了避免操作系统未能及时进行磁盘缓存而产生的影响），数据样本如图5-2所示。




图 5-2 Eclipse原始运行数据

Eclipse启动的总耗时没有办法从监控工具中直接获得，因为VisualVM不可能知道Eclipse运行到什么阶段算是启动完成。为了测试的准确性，

笔者写了一个简单的Eclipse插件，用于统计Eclipse的启动耗时。由于代码很简单，并且本书不是Eclipse RCP开发的教程，所以只列出代码清单5-4供读者参考，不再延伸讲解。如果读者需要这个插件，可以使用下面代码自行编译或者发电子邮件向笔者索取。

代码清单5-4 Eclipse启动耗时统计插件

```
ShowTime.java代码:  
import  
org.eclipse.jface.dialogs.MessageDialog;  
import org.eclipse.swt.widgets.Display;  
import org.eclipse.swt.widgets.Shell;  
import org.eclipse.ui.IStartup;  
/**  
 * 统计Eclipse启动耗时  
 * @author zzm  
 */  
public class ShowTime implements IStartup{  
    public void earlyStartup () {  
        Display.getDefault () .syncExec (new  
Runnable () {  
            public void run () {
```

```
long
eclipseStartTime=Long.parseLong (System.getProperty("eclipse.startTime"));
long costTime=System.currentTimeMillis () - eclipseStartTime;
Shell
shell=Display.getDefault ().getActiveShell ();
String message="Eclipse启动耗时: "+costTime+"ms";
MessageDialog.openInformation (shell, "Information", message);
}
})
}
}
}

plugin.xml代码:
<?xml version="1.0" encoding="UTF-8"?>
<?eclipse version="3.4"?>
<plugin>
<extension
point="org.eclipse.ui.startup">
<startup
class="eclipsesstarttime.actions.ShowTime"/>
</extension>
</plugin>
```

上述代码打包成jar后放到Eclipse的plugins目录，反复启动几次后，插件显示的平均时间稳定在15秒左右，如图5-3所示。




图 5-3 耗时统计插件运行效果

根据VisualGC和Eclipse插件收集到的信息，总结原始配置下的测试结果如下。

整个启动过程平均耗时约15秒。

最后一次启动的数据样本中，垃圾收集总耗时4.149秒，其中：

- Full GC被触发了19次，共耗时3.166秒。

- Minor GC被触发了378次，共耗时0.983

秒。

加载类9115个，耗时4.114秒。

JIT编译时间为1.999秒。

虚拟机512MB的堆内存被分配为40MB的新生代（31.5的Eden空间和两个4MB的Surviver空间）以及472MB的老年代。

客观地说，由于机器硬件还不错（请读者以2010年普通PC机的标准来衡量），15秒的启动时间其实还在可接受范围以内，但是从VisualGC中反映的数据来看，主要问题是非用户程序时间（图5-2中的Compile Time、Class Load Time、GC Time）非常之高，占了整个启动过程耗时的一半以上（这里存在少许夸张成分，因为如JIT编译等动作是在后台线程完成的，用户程序在此期间也正常执行，所以并没有占用了一半以上的绝对时

间）。虚拟机后台占用太多时间也直接导致 Eclipse 在启动后的使用过程中经常有不时停顿的感觉，所以进行调优有较大的价值。

5.3.2 升级JDK 1.6的性能变化及兼容问题

对Eclipse进行调优的第一步就是先把虚拟机的版本进行升级，希望能先从虚拟机版本身上得到一些“免费的”性能提升。

每次JDK的大版本发布时，开发商肯定都会宣称虚拟机的运行速度比上一版本有了很大的提高，这虽然是个广告性质的宣言，经常被人从升级列表或者技术白皮书中直接忽略过去，但从国内外的第三方评测数据来看，版本升级至少某些方面确实带来了一定的性能改善^[1]，以下是一个第三方网站对JDK 1.5、1.6、1.7三个版本做的性能评测，分别测试了以下4个用例^[2]：

生成500万个的字符串。

500万次ArrayList<String>数据插入，使用
第一点生成的数据。

生成500万个HashMap<String, Integer>，每
个键-值对通过并发线程计算，测试并发能力。

打印500万个ArrayList<String>中的值到文
件，并重读回内存。

三个版本的JDK分别运行这3个用例的测试程
序，测试结果如图5-4所示。




图 5-4 JDK横向性能对比

从这4个用例的测试结果来看，JDK 1.6比JDK 1.5有大约15%的性能提升，尽管对JDK仅测试这4个用例并不能说明什么问题，需要通过测试数据来量化描述一个JDK比旧版提升了多少是很难做到非常科学和准确的（要做稍微靠谱一点的测试，可以使用SPECjvm2008^[3]来完成，或者

把相应版本的TCK^[4]中数万个测试用例的性能数据对比一下可能更有说服力），但我还是选择相信这次“软广告”性质的测试，把JDK版本升级到1.6 Update 21。

与所有小说作者设计的故事情节一样，获得最后的胜利之前总是要经历各种各样的挫折，这次升级到JDK 1.6之后，性能有什么变化先暂且不谈，在使用几分钟之后，笔者的Eclipse就和前面几个服务端的案例一样非常“不负众望”地发生了内存溢出，如图5-5所示。




图 5-5 Eclipse OutOfMemoryError

这次内存溢出完全出乎笔者的意料之外：决定对Eclipse做调优是因为速度慢，但开发环境一直都很稳定，至少没有出现过内存溢出的问题，而这次升级除了eclipse.ini中的JVM路径改变了之外，还未进行任何运行参数的调整，进到Eclipse主界面之后随便打开了几个文件就抛出内存溢出异常了，难道JDK 1.6 Update 21有哪个API出现了严重的泄漏问题吗？

事实上，并不是JDK 1.6出现了什么问题，根据前面章节中介绍的相关原理和工具，我们要查明这个异常的原因并且解决它一点也不困难。打开VisualVM，监视页签中的内存曲线部分如图5-6和图5-7所示。




图 5-6 Java堆监视曲线




图 5-7 永久代监视曲线

在Java堆中监视曲线中，“堆大小”的曲线与“使用的堆”的曲线一直都有很大的间隔距离，每当两条曲线开始有互相靠近的趋势时，“最大堆”的曲线就会快速向上转向，而“使用的堆”的曲线会向下转向。“最大堆”的曲线向上是虚拟机内部在进行堆扩容，运行参数中并没有指定最小堆

(`-Xms`) 的值与最大堆 (`-Xmx`) 相等，所以堆容量一开始并没有扩展到最大值，而是根据使用情况进行伸缩扩展。“使用的堆”的曲线向下是因为虚拟机内部触发了一次垃圾收集，一些废弃对象的空间被回收后，内存用量相应减少，从图形上看，Java堆运作是完全正常的。但永久代的监视曲线就有问题了，“PermGen大小”的曲线与“使用的PermGen”的曲线几乎完全重合在一起，这说明永久代中没有可回收的资源，所以“使用的PermGen”的曲线不会向下发展，永久代中也没有空间可以扩展，所以“PermGen大小”的曲线不能向上扩展。这次内存溢出很明显是永久代导致的内存溢出。

再注意到图5-7中永久代的最大容量：“67,108, 864个字节”，也就是64MB，这恰好是JDK

在未使用-XX: MaxPermSize参数明确指定永久代最大容量时的默认值，无论JDK 1.5还是JDK 1.6，这个默认值都是64MB。对于Eclipse这种规模的Java程序来说，64MB的永久代内存空间显然是不够的，溢出很正常，那为何在JDK 1.5中没有发生过溢出呢？

在VisualVM的“概述-JVM参数”页签中，分别检查使用JDK 1.5和JDK 1.6运行Eclipse时的JVM参数，发现使用JDK 1.6时，只有以下3个JVM参数，如代码清单5-5所示。

代码清单5-5 JDK 1.6的Eclipse运行期参数

```
-Dcom.sun.management.jmxremote  
-Dosgi.requiredJavaVersion=1.5  
-Xmx512m
```

而使用JDK 1.5运行时，就有4条JVM参数，其中多出来的一条正好就是设置永久代最大容量的-XX: MaxPermSize=256M，如代码清单5-6所示。

代码清单5-6 JDK 1.5的Eclipse运行期参数

```
-Dcom.sun.management.jmxremote  
-Dosgi.requiredJavaVersion=1.5  
-Xmx512m  
-XX: MaxPermSize=256M
```

为什么会这样呢？笔者从Eclipse的Bug List网站^[5]上找到了答案：使用JDK 1.5时之所以有永久代容量这个参数，是因为在eclipse.ini中存在“--launcher.XXMaxPermSize 256M”这项设置，当launcher——也就是Windows下的可执行程序eclipse.exe，检测到假如是Eclipse运行在Sun公司

的虚拟机上的话，就会把参数值转化为-XX:
MaxPermSize传递给虚拟机进程，因为三大商用
虚拟机中只有Sun系列的虚拟机才有永久代的概
念，也就是只有HotSpot虚拟机需要设置这个参
数，JRockit虚拟机和IBM J9虚拟机都不需要设
置。

在2009年4月20日，Oracle公司正式完成了对
Sun公司的收购，此后无论是网页还是具体程序
产品，提供商都从Sun变为了Oracle，而
eclipse.exe就是根据程序提供商判断是否为Sun的
虚拟机，当JDK 1.6 Update 21中java.exe、
javaw.exe的“Company”属性从“Sun Microsystems
Inc.”变为“Oracle Corporation”之后，Eclipse就完
全不认识这个虚拟机了，因此没有把最大永久代
的参数传递过去。

了解原因之后，解决方法就简单了，launcher不认识就只好由人来告诉它，即在eclipse.ini中明确指定-XX: MaxPermSize=256M这个参数就可以了。

[1] 版本升级也有不少性能倒退的案例，受程序、第三方包兼容性以及中间件限制，在企业应用中升级JDK版本是一件需要慎重考虑的事情。

[2] 测试用例、数据及图片来自：

<http://geeknizer.com/java-7-whats-new-performance-benchmark-1-5-1-6-1-7>

[3] 官方网站：

<http://www.spec.org/jvm2008/docs/UserGuide.html>

[4] TCK (Technology Compatibility Kit) 是一套由一组测试用例和相应的测试工具组成的工具包，

用于保证一个使用Java技术的实现能够完全遵守其适用的Java平台规范，并且符合相应的参考实现。

[5]https://bugs.eclipse.org/bugs/show_bug.cgi?id=319514。

5.3.3 编译时间和类加载时间的优化

从Eclipse启动时间上来看，升级到JDK 1.6所带来的性能提升是……嗯？基本上没有提升？多次测试的平均值与JDK 1.5的差距完全在实验误差范围之内。

各位读者不必失望，Sun JDK 1.6性能白皮书^[1]描述的众多相对于JDK 1.5的提升不至于全部是广告，虽然总启动时间没有减少，但在查看运行细节的时候，却发现了一件很值得注意的事情：在JDK 1.6中启动完Eclipse所消耗的类加载时间比JDK 1.5长了接近一倍，不要看反了，这里写的是JDK 1.6的类加载比JDK 1.5慢一倍，测试结果如代码清单5-7所示，反复测试多次仍然是相似

的结果。

代码清单5-7 JDK 1.5和JDK 1.6中的类加载时间对比

使用JDK 1.6的类加载时间：

```
C:\Users\IcyFenix>jps  
3552  
6372
```

```
org.eclipse.equinox.launcher_1.0.201.R35x_v20090609-0818  
6900 Jps
```

```
C:\Users\IcyFenix>jstat-class 6372  
Loaded Bytes Unloaded Bytes Time  
7917 10190.3 0 0.0 8.18
```

使用JDK 1.5的类加载时间：

```
C:\Users\IcyFenix>jps  
3552  
7272 Jps  
7216
```

```
org.eclipse.equinox.launcher_1.0.201.R35x_v20090609-0818  
C:\Users\IcyFenix>jstat-class 7216
```

```
Loaded Bytes Unloaded Bytes Time  
7902 9691.2 3 2.6 4.34
```

在本例中，类加载时间上的差距并不能作为一个具有普遍性的测试结果去说明JDK 1.6的类加

载必然比JDK 1.5慢，笔者测试了自己机器上的Tomcat和GlassFish启动过程，并未没有出现类似的差距。在国内最大的Java社区中，笔者发起过关于此问题的讨论^[2]，从参与者反馈的测试结果来看，此问题只在一部分机器上存在，而且JDK 1.6的各个Update版之间也存在很大差异。

多次试验后，笔者发现在机器上两个JDK进行类加载时，字节码验证部分耗时差距尤其严重。考虑到实际情况：Eclipse使用者甚多，它的编译代码我们可以认为是可靠的，不需要在加载的时候再进行字节码验证，因此通过参数-Xverify: none禁止掉字节码验证过程也可作为一项优化措施。加入这个参数后，两个版本的JDK类加载速度都有所提高，JDK 1.6的类加载速度仍然比JDK 1.5慢，但是两者的耗时已经接近了许

多，测试数据如代码清单5-8所示。关于类与类加载的话题，譬如刚刚提到的字节码验证是怎么回事，本书专门规划了两个章节进行详细讲解，在此不再延伸讨论。

代码清单5-8 JDK 1.5和JDK 1.6中取消字节码验证后的类加载时间对比

使用JDK 1.6的类加载时间：

```
C: \Users\IcyFenix>jps
5512
org.eclipse.equinox.launcher_1.0.201.R35x_v2009(
    5596 Jps
C: \Users\IcyFenix>jstat-class 5512
Loaded Bytes Unloaded Bytes Time
6749 8837.0 0 0.0 3.94
```

使用JDK 1.5的类加载时间：

```
C: \Users\IcyFenix>jps
4724
org.eclipse.equinox.launcher_1.0.201.R35x_v2009(
    5412 Jps
C: \Users\IcyFenix>jstat-class 4724
Loaded Bytes Unloaded Bytes Time
6885 9109.7 3 2.6 3.10
```

在取消字节码验证之后，JDK 1.5的平均启动下降到了13秒，而JDK 1.6的测试数据平均比JDK 1.5快1秒，下降到平均12秒左右，如图5-8所示。在类加载时间仍然落后的情况下，依然可以看到JDK 1.6在性能上比JDK 1.5稍有优势，说明至少在Eclipse启动这个测试用例上，升级JDK版本确实能带来一些“免费的”性能提升。



图 5-8 运行在JDK 1.6下取消字节码验证的启动时间

前面说过，除了类加载时间以外，在VisualGC的监视曲线中显示了两项很大的非用户

程序耗时：编译时间（Compile Time）和垃圾收集时间（GC Time）。垃圾收集时间读者应该非常清楚了，而编译时间是什么呢？程序在运行之前不是已经编译了吗？虚拟机的JIT编译与垃圾收集一样，是本书的一个重要部分，后面有专门章节讲解，这里先简单介绍一下：编译时间是指虚拟机的JIT编译器（Just In Time Compiler）编译热点代码（Hot Spot Code）的耗时。我们知道Java语言为了实现跨平台的特性，Java代码编译出来后形成的Class文件中存储的是字节码

（ByteCode），虚拟机通过解释方式执行字节码命令，比起C/C++编译成本地二进制代码来说，速度要慢不少。为了解决程序解释执行的速度问题，JDK 1.2以后，虚拟机内置了两个运行时编译器^[3]，如果一段Java方法被调用次数达到一定程

度，就会被判定为热代码交给JIT编译器即时编译为本地代码，提高运行速度（这就是HotSpot虚拟机名字的由来）。甚至有可能在运行期动态编译比C/C++的编译期静态译编出来的代码更优秀，因为运行期可以收集很多编译器无法知道的信息，甚至可以采用一些很激进的优化手段，在优化条件不成立的时候再逆优化退回来。所以Java程序只要代码没有问题（主要是泄漏问题，如内存泄漏、连接泄漏），随着代码被编译得越来越彻底，运行速度应当是越运行越快的。Java的运行期编译最大的缺点就是它进行编译需要消耗程序正常的运行时间，这也就是上面所说的“编译时间”。

虚拟机提供了一个参数-Xint禁止编译器运作，强制虚拟机对字节码采用纯解释方式执行。

如果读者想使用这个参数省下Eclipse启动中那2秒的编译时间获得一个“更好看”的成绩的话，那恐怕要失望了，加上这个参数之后，虽然编译时间确实下降到0，但Eclipse启动的总时间剧增到27秒。看来这个参数现在最大的作用似乎就是让用户怀念一下JDK 1.2之前那令人心酸和心碎的运行速度。

与解释执行相对应的另一方面，虚拟机还有力度更强的编译器：当虚拟机运行在-client模式的时候，使用的是一个代号为C1的轻量级编译器，另外还有一个代号为C2的相对重量级的编译器能提供更多的优化措施，如果使用-server模式的虚拟机启动Eclipse将会使用到C2编译器，这时从VisualGC可以看到启动过程中虚拟机使用了超过15秒的时间去进行代码编译。如果读者的工作

习惯是长时间不关闭Eclipse的话，C2编译器所消耗的额外编译时间最终还是会在运行速度的提升之中赚回来，这样使用-server模式也是一个不错的选择。不过至少在本次实战中，我们还是继续选用-client虚拟机来运行Eclipse。

[1]<http://www.oracle.com/technetwork/java/6-performance-137236.html>。

[2]关于JDK 1.6与JDK 1.5在Eclipse启动时类加载速度差异的讨论：

<http://www.iteye.com/topic/826542>。

[3]JDK 1.2之前也可以使用外挂JIT编译器进行本地编译，但只能与解释器二选其一，不能同时工作。

5.3.4 调整内存设置控制垃圾收集频率

三大块非用户程序时间中，还剩下GC时间没有调整，而GC时间却又是其中最重要的一块，并不只是因为它是耗时最长的一块，更因为它是一个稳定持续的过程。由于我们做的测试是在测程序的启动时间，所以类加载和编译时间在这项测试中的影响力被大幅度放大了。在绝大多数的应用中，不可能出现持续不断的类被加载和卸载。在程序运行一段时间后，热点方法被不断编译，新的热点方法数量也总会下降，但是垃圾收集则是随着程序运行而不断运作的，所以它对性能的影响才显得尤为重要。

在Eclipse启动的原始数据样本中，短短15

秒，类共发生了19次Full GC和378次Minor GC，一共397次GC共造成了超过4秒的停顿，也就是超过1/4的时间都是在做垃圾收集，这个运行数据看起来实在太糟糕了。

首先来解决新生代中的Minor GC，虽然GC的总时间只有不到1秒，但却发生了378次之多。从VisualGC的线程监视中看到，Eclipse启动期间一共发起了超过70条线程，同时在运行的线程数超过25条，每当发生一次垃圾收集动作，所有用户线程^[1]都必须跑到最近的一个安全点（SafePoint）然后挂起线程等待垃圾回收。这样过于频繁的GC就会导致很多没有必要的安全点检测、线程挂起及恢复操作。

新生代GC频繁发生，很明显是由于虚拟机分

配给新生代的空间太小而导致的，Eden区加上一个Survivor区还不到35MB。因此很有必要使用-Xmn参数调整新生代的大小。

再来看一看那19次Full GC，看起来19次并“不多”（相对于378次Minor GC来说），但总耗时为3.166秒，占了GC时间的绝大部分，降低GC时间的主要目标就要降低这部分时间。从VisualGC的曲线图上可能看得不够精确，这次直接从GC日志^[2]中分析一下这些Full GC是如何产生的，代码清单5-9中是启动最开始的2.5秒内发生的10次Full GC记录。

代码清单5-9 Full GC记录

```
0.278: [GC 0.278: [DefNew: 574K->
33K (576K), 0.0012562 secs]0.279: [Tenured:
1467K->997K (1536K), 0.0181775 secs]1920K->
```

997K (2112K) , 0.0195257 secs]
0.312: [GC 0.312: [DefNew: 575K->
64K (576K) , 0.0004974 secs] 0.312: [Tenured:
1544K->1608K (1664K) , 0.0191592 secs] 1980K->
1608K (2240K) , 0.0197396 secs]
0.590: [GC 0.590: [DefNew: 576K->
64K (576K) , 0.0006360 secs] 0.590: [Tenured:
2675K->2219K (2684K) , 0.0256020 secs] 3090K->
2219K (3260K) , 0.0263501 secs]
0.958: [GC 0.958: [DefNew: 551K->
64K (576K) , 0.0011433 secs] 0.959: [Tenured:
3979K->3470K (4084K) , 0.0419335 secs] 4222K->
3470K (4660K) , 0.0431992 secs]
1.575: [Full GC 1.575: [Tenured: 4800K->
5046K (5784K) , 0.0543136 secs] 5189K->
5046K (6360K) , [Perm: 12287K->
12287K (12288K)] , 0.0544163 secs]
1.703: [GC 1.703: [DefNew: 703K->
63K (704K) , 0.0012609 secs] 1.705: [Tenured:
8441K->8505K (8540K) , 0.0607638 secs] 8691K->
8505K (9244K) , 0.0621470 secs]
1.837: [GC 1.837: [DefNew: 1151K->
64K (1152K) , 0.0020698 secs] 1.839: [Tenured:
14616K->14680K (14688K) , 0.0708748
secs] 15035K->14680K (15840K) , 0.0730947 secs]
2.144: [GC 2.144: [DefNew: 1856K->
191K (1856K) , 0.0026810 secs] 2.147: [Tenured:
25092K->24656K (25108K) , 0.1112429
secs] 26172K->24656K (26964K) , 0.1141099 secs]
2.337: [GC 2.337: [DefNew: 1914K->
0K (3136K) , 0.0009697 secs] 2.338: [Tenured:
41779K->27347K (42056K) , 0.0954341
secs] 42733K->27347K (45192K) , 0.0965513 secs]
2.465: [GC 2.465: [DefNew: 2490K->

```
0K (3456K), 0.0011044 secs]2.466: [Tenured:  
46379K->27635K (46828K), 0.0956937  
secs]47621K->27635K (50284K), 0.0969918 secs]
```

括号中加粗的数字代表老年代的容量，这组GC日志显示了10次Full GC发生的原因全部都是老年代空间耗尽，每发生一次Full GC都伴随着一次老年代空间扩容：1536KB->1664KB->2684KB.....42056KB->46828KB，10次GC以后老年代容量从起始的1536KB扩大到46828KB，当15秒后Eclipse启动完成时，老年代容量扩大到了103428KB，代码编译开始后，老年代容量到达顶峰473MB，整个Java堆到达最大容量512MB。

日志还显示有些时候内存回收状况很不理想，空间扩容成为获取可用内存的最主要手段，譬如语句“Tenured: 25092K->

24656K (25108K) , 0.1112429 secs”，代表老年代当前容量为25108KB，内存使用到25092KB的时候发生Full GC，花费0.11秒把内存使用降低到24656KB，只回收了不到500KB的内存，这次GC基本没有什么回收效果，仅仅做了扩容，扩容过程相比起回收过程可以看做是基本不需要花费时间的，所以说这0.11秒几乎是白白浪费了。

由上述分析可以得出结论：Eclipse启动时，Full GC大多数是由于老年代容量扩展而导致的，由永久代空间扩展而导致的也有一部分。为了避免这些扩展所带来的性能浪费，我们可以把-Xms和-XX: PermSize参数值设置为-Xmx和-XX: MaxPermSize参数值一样，这样就强制虚拟机在启动的时候就把老年代和永久代的容量固定下来，避免运行时自动扩展^[3]。

根据分析，优化计划确定为：把新生代容量提升到128MB，避免新生代频繁GC；把Java堆、永久代的容量分别固定为512MB和96MB^[4]，避免内存扩展。这几个数值都是根据机器硬件、Eclipse插件和工程数量来决定的，读者实践的时候应根据VisualGC中收集到的实际数据进行设置。改动后的eclipse.ini配置如代码清单5-10所示。

代码清单5-10 内存调整后的Eclipse配置文件

```
-vm
D: /_DevSpace/jdk1.6.0_21/bin/javaw.exe
-startup
plugins/org.eclipse.equinox.launcher_1.0.201
--launcher.library
plugins/org.eclipse.equinox.launcher.win32.w_
-product
org.eclipse.epp.package.jee.product
```

```
-showsplash  
org.eclipse.platform  
-vmargs  
-Dosgi.requiredJavaVersion=1.5  
-Xverify: none  
-Xmx512m  
-Xms512m  
-Xmn128m  
-XX: PermSize=96m  
-XX: MaxPermSize=96m
```

现在这个配置之下，GC次数已经大幅度降低，图5-9是Eclipse启动后1分钟的监视曲线，只发生了8次Minor GC和4次Full GC，总耗时为1.928秒。




图 5-9 GC调整后的运行数据

这个结果已经算是基本正常，但是还存在一点瑕疵：从Old Gen的曲线上看，老年代直接固定在384MB，而内存使用量只有66MB，并且一直很平滑，完全不应该发生Full GC才对，那4次Full GC是怎么来的？使用jstat-gccause查询一下最近一次GC的原因，见代码清单5-11。

代码清单5-11 查询GC原因

```
C: \Users\IcyFenix>jps
9772 Jps
4068
org.eclipse.equinox.launcher_1.0.201.R35x_v20090
C: \Users\IcyFenix>jstat-gccause 4068
S0 S1 E O P YGC YGCT FGC FGCT GCT LGCC GCC
0.00 0.00 1.00 14.81 39.29 6 0.422 20 5.992
6.414
System.gc () No GC
```

从LGCC（Last GC Cause）中看到，原来是代码调用System.gc（）显式触发的GC，在内存设置调整后，这种显式GC已不符合我们的期望，因此在eclipse.ini中加入参数-XX:
+DisableExplicitGC屏蔽掉System.gc（）。再次测试发现启动期间的Full GC已经完全没有了，只有6次Minor GC，耗时417毫秒，与调优前4.149秒的测试样本相比，正好是十分之一。进行GC调优后

Eclipse的启动时间下降非常明显，比整个GC时间降低的绝对值还大，现在启动只需要7秒多，如图5-10所示。



图 5-10 Eclipse启动时间

[1]严格来说，不包括正在执行native代码的用户线程，因为native代码一般不会改变Java对象的引用关系，所以没有必要挂起它们来等待垃圾回收。

[2]可以通过以下几个参数要求虚拟机生成GC日志：`-XX: +PrintGCTimeStamps`（打印GC停顿时间）、`-XX: +PrintGCDetails`（打印GC详细信息）、`-verbose: gc`（打印GC信息，输出内容已

被前一个参数包括，可以不写）、-Xloggc:
gc.log。

[3]需要说明一点，虚拟机启动的时候就会把参数中所设定的内存全部划为私有，即使扩容前有一部分内存不会被用户代码用到，这部分内存也不会交给其他进程使用。这部分内存在虚拟机中被标识为“Virtual”内存。

[4]512MB和96MB两个数值对于笔者的应用情况来说依然偏少，但由于笔者需要同时开启VMWare工作，所以需要预留较多内存，读者在实际调优时不妨再设置大一些。

5.3.5 选择收集器降低延迟

现在Eclipse启动已经比较迅速了，但我们的调优实战还没有结束，毕竟Eclipse是拿来写程序的，不是拿来测试启动速度的。我们不妨再在Eclipse中测试一个非常常用但又比较耗时的操作：代码编译。图5-11是当前配置下Eclipse进行代码编译时的运行数据，从图中可以看出，新生代每次回收耗时约65毫秒，老年代每次回收耗时约725毫秒。对于用户来说，新生代GC的耗时还好，65毫秒在使用中无法察觉到，而老年代每次GC停顿接近1秒钟，虽然比较长时间才会出现一次，但停顿还是显得太长了一些。




图 5-11 编译期间运行数据

再注意看一下编译期间的CPU资源使用状况。图5-12是Eclipse在编译期间的CPU使用率曲线图，整个编译过程中平均只使用了不到30%的CPU资源，垃圾收集的CPU使用率曲线更是几乎与坐标横轴紧贴在一起，这说明CPU资源还有很多可利用的余地。



图 5-12 编译期间CPU曲线

列举GC停顿时间、CPU资源富余的目的，都是为了接下来替换掉Client模式的虚拟机中默认的新生代、老年代串行收集器做铺垫。

Eclipse应当算是与使用者交互非常频繁的应用程序，由于代码太多，笔者习惯在做全量编译

或者清理动作的时候，使用“Run in Background”功能一边编译一边继续工作。回顾一下在第3章提到的几种收集器，很容易想到CMS是最符合这类场景的收集器。因此尝试在eclipse.ini中再加入这两个参数-XX: +UseConcMarkSweepGC、-XX: +UseParNewGC（ParNew收集器是使用CMS收集器后的默认新生代收集器，写上仅是为了配置更加清晰），要求虚拟机在新生代和老年代分别使用ParNew和CMS收集器进行垃圾回收。指定收集器之后，再次测试的结果如图5-13所示，与原来使用串行收集器对比，新生代停顿从每次65毫秒下降到了每次53毫秒，而老年代的停顿时间更是从725毫秒大幅下降到了36毫秒。




图 5-13 指定ParNew和CMS收集器后的GC数据

当然，CMS的停顿阶段只是收集过程中的一小部分，并不是真的把垃圾收集时间从725毫秒变成36毫秒了。在GC日志中可以看到CMS与程序并发的时间约为400毫秒，这样收集器的运作结果就比较令人满意了。

到此，对于虚拟机内存的调优基本就结束

了，这次实战可以看做是一次简化的服务端调优过程，因为服务端调优有可能还会存在于更多方面，如数据库、资源池、磁盘I/O等，但对于虚拟机内存部分的优化，与这次实战中的思路没有什么太大差别。即使读者实际工作中接触不到服务器，根据自己工作环境做一些试验，总结几个参数让自己日常工作环境速度有较大幅度提升也是很划算的。最终eclipse.ini的配置如代码清单5-12所示。

代码清单5-12 修改收集器配置后的Eclipse配置

```
-vm
D: /_DevSpace/jdk1.6.0_21/bin/javaw.exe
-startup
plugins/org.eclipse.equinox.launcher_1.0.201
--launcher.library
plugins/org.eclipse.equinox.launcher.win32.w
-product
```

```
org.eclipse.epp.package.jee.product
-showsplash
org.eclipse.platform
-vmargs
-Dcom.sun.management.jmxremote
-Dosgi.requiredJavaVersion=1.5
-Xverify: none
-Xmx512m
-Xms512m
-Xmn128m
-XX: PermSize=96m
-XX: MaxPermSize=96m
-XX: +DisableExplicitGC
-Xnoclassgc
-XX: +UseParNewGC
-XX: +UseConcMarkSweepGC
-XX: CMSInitiatingOccupancyFraction=85
```

5.4 本章小结

Java虚拟机的内存管理与垃圾收集是虚拟机结构体系中最重要的组成部分，对程序的性能和稳定性有非常大的影响，在本书的第2~5章中，笔者从理论知识、异常现象、代码、工具、案例、实战等几个方面对其进行了讲解，希望读者有所收获。

本书关于虚拟机内存管理部分到此为止就结束了，后面将开始介绍Class文件与虚拟机执行子系统方面的知识。

第三部分 虚拟机执行子系统

第6章 类文件结构

第7章 虚拟机类加载机制

第8章 虚拟机字节码执行引擎

第9章 类加载及执行子系统的案例与实战

第6章 类文件结构

代码编译的结果从本地机器码转变为字节码，是存储格式发展的一小步，却是编程语言发展的一大步。

6.1 概述

记得在第一节计算机程序课上我的老师就讲过：“计算机只认识0和1，所以我们写的程序需要经编译器翻译成由0和1构成的二进制格式才能由计算机执行”。10多年时间过去了，今天的计算机仍然只能识别0和1，但由于最近10年内虚拟机以及大量建立在虚拟机之上的程序语言如雨后春笋般出现并蓬勃发展，将我们编写的程序编译成二进制本地机器码（Native Code）已不再是唯

一的选择，越来越多的程序语言选择了与操作系统和机器指令集无关的、平台中立的格式作为程序编译后的存储格式。

6.2 无关性的基石

如果计算机的CPU指令集只有x86一种，操作系统也只有Windows一种，那也许Java语言就不会出现。Java在刚刚诞生之时曾经提出过一个非常著名的宣传口号：“一次编写，到处运行（Write Once, Run Anywhere）”，这句话充分表达了软件开发人员对冲破平台界限的渴求。在无时无刻不充满竞争的IT领域，不可能只有Wintel^[1]存在，我们也不希望只有Wintel存在，各种不同的硬件体系结构和不同的操作系统肯定会长期并存发展。“与平台无关”的理想最终实现在操作系统的应用层上：Sun公司以及其他虚拟机提供商发布了许多可以运行在各种不同平台上的虚拟机，这些虚拟机都可以载入和执行同一种平台无关的

字节码，从而实现了程序的“一次编写，到处运行”。

各种不同平台的虚拟机与所有平台都统一使用的程序存储格式——字节码（ByteCode）是构成平台无关性的基石，但本节标题中刻意省略了“平台”二字，那是因为笔者注意到虚拟机的另外一种中立特性——语言无关性正越来越被开发者所重视。到目前为止，或许大部分程序员都还认为Java虚拟机执行Java程序是一件理所当然和天经地义的事情。但在Java发展之初，设计者就曾经考虑过并实现了让其他语言运行在Java虚拟机之上的可能性，他们在发布规范文档的时候，也刻意把Java的规范拆分成了Java语言规范《The Java Language Specification》及Java虚拟机规范《The Java Virtual Machine Specification》。并且

在1997年发布的第一版Java虚拟机规范中就曾经承诺过：“In the future, we will consider bounded extensions to the Java virtual machine to provide better support for other languages”（在未来，我们会对Java虚拟机进行适当的扩展，以便更好地支持其他语言运行于JVM之上），当Java虚拟机发展到JDK 1.7~1.8的时候，JVM设计者通过JSR-292基本兑现了这个承诺。

时至今日，商业机构和开源机构已经在Java语言之外发展出一大批在Java虚拟机之上运行的语言，如Clojure、Groovy、JRuby、Jython、Scala等。使用过这些语言的开发者可能还不是非常多，但是听说过的人肯定已经不少，随着时间的推移，谁能保证日后Java虚拟机在语言无关性上的优势不会赶上甚至超越它在平台无关性上的优

势呢？

实现语言无关性的基础仍然是虚拟机和字节码存储格式。Java虚拟机不和包括Java在内的任何语言绑定，它只与“Class文件”这种特定的二进制文件格式所关联，Class文件中包含了Java虚拟机指令集和符号表以及若干其他辅助信息。基于安全方面的考虑，Java虚拟机规范要求在Class文件中使用许多强制性的语法和结构化约束，但任一门功能性语言都可以表示为一个能被Java虚拟机所接受的有效Class文件。作为一个通用的、机器无关的执行平台，任何其他语言的实现者都可以将Java虚拟机作为语言的产品交付媒介。例如，使用Java编译器可以把Java代码编译为存储字节码的Class文件，使用JRuby等其他语言的编译器一样可以把程序代码编译成Class文件，虚拟

机并不关心Class的来源是何种语言，如图6-1所示。




图 6-1 Java虚拟机提供的语言无关性

Java语言中的各种变量、关键字和运算符号的语义最终都是由多条字节码命令组合而成的，因此字节码命令所能提供的语义描述能力肯定会被比Java语言本身更加强大。因此，有一些Java语言本身无法有效支持的语言特性不代表字节码本

身无法有效支持，这也为其他语言实现一些有别于Java的语言特性提供了基础。

[1]Wintel：微软公司的Windows与Intel公司的芯片相结合，曾经是业界最强大的联盟。

6.3 Class类文件的结构

解析Class文件的数据结构是本章的最主要內容。笔者曾经在前言中阐述过本书的写作风格：力求在保证逻辑准确的前提下，用尽量通俗的语言和案例去讲述虚拟机中与开发关系最为密切的內容。但是，对数据结构方面的讲解不可避免地会比较枯燥，而这部分内容又是了解虚拟机的重要基础之一。如果想比较深入地了解虚拟机，那么这部分是不能不接触的。

在本章关于Class文件结构的讲解中，我们将以《Java虚拟机规范（第2版）》（1999年发布，对应于JDK 1.4时代的Java虚拟机）中的定义为主线，这部分内容虽然古老，但它所包含的指令、

属性是Class文件中最重要和最基础的。同时，我们也会以后续JDK 1.5~JDK 1.7中添加的内容为支线进行较为简略的、介绍性的讲解，如果读者对这部分内容特别感兴趣，建议参考笔者所翻译的《Java虚拟机规范（Java SE 7）》中文版，可以在笔者的网站（<http://icyfenix.iteye.com/>）上下载到这本书的全文PDF。

注意 任何一个Class文件都对应着唯一一个类或接口的定义信息，但反过来说，类或接口并不一定都得定义在文件里（譬如类或接口也可以通过类加载器直接生成）。本章中，笔者只是通俗地将任意一个有效的类或接口所应当满足的格式称为“Class文件格式”，实际上它并不一定以磁盘文件的形式存在。

Class文件是一组以8位字节为基础单位的二进制流，各个数据项目严格按照顺序紧凑地排列在Class文件之中，中间没有添加任何分隔符，这使得整个Class文件中存储的内容几乎全部是程序运行的必要数据，没有空隙存在。当遇到需要占用8位字节以上空间的数据项时，则会按照高位在前^[1]的方式分割成若干个8位字节进行存储。

根据Java虚拟机规范的规定，Class文件格式采用一种类似于C语言结构体的伪结构来存储数据，这种伪结构中只有两种数据类型：无符号数和表，后面的解析都要以这两种数据类型为基础，所以这里要先介绍这两个概念。

无符号数属于基本的数据类型，以u1、u2、u4、u8来分别代表1个字节、2个字节、4个字节

和8个字节的无符号数，无符号数可以用来描述数字、索引引用、数量值或者按照UTF-8编码构成字符串值。

表是由多个无符号数或者其他表作为数据项构成的复合数据类型，所有表都习惯性地以“_info”结尾。表用于描述有层次关系的复合结构的数据，整个Class文件本质上就是一张表，它由表6-1所示的数据项构成。

表 6-1 Class 文件格式

| 类 型 | 名 称 | 数 量 |
|----------------|---------------------|-----------------------|
| u4 | magic | 1 |
| u2 | minor_version | 1 |
| u2 | major_version | 1 |
| u2 | constant_pool_count | 1 |
| cp_info | constant_pool | constant_pool_count-1 |
| u2 | access_flags | 1 |
| u2 | this_class | 1 |
| u2 | super_class | 1 |
| u2 | interfaces_count | 1 |
| u2 | interfaces | interfaces_count |
| u2 | fields_count | 1 |
| field_info | fields | fields_count |
| u2 | methods_count | 1 |
| method_info | methods | methods_count |
| u2 | attributes_count | 1 |
| attribute_info | attributes | attributes_count |

无论是无符号数还是表，当需要描述同一类型但数量不定的多个数据时，经常会使用一个前置的容量计数器加若干个连续的数据项的形式，这时称这一系列连续的某一类型的数据为某一类型的集合。

本节结束之前，笔者需要再重复讲一下，Class的结构不像XML等描述语言，由于它没有任

何分隔符号，所以在表6-1中的数据项，无论是顺序还是数量，甚至于数据存储的字节序（Byte Ordering, Class文件中字节序为Big-Endian）这样的细节，都是被严格限定的，哪个字节代表什么含义，长度是多少，先后顺序如何，都不允许改变。接下来我们将一起看看这个表中各个数据项的具体含义。

6.3.1 魔数与Class文件的版本

每个Class文件的头4个字节称为魔数（Magic Number），它的唯一作用是确定这个文件是否为一个能被虚拟机接受的Class文件。很多文件存储标准中都使用魔数来进行身份识别，譬如图片格式，如gif或者jpeg等在文件头中都存有魔数。使

用魔数而不是扩展名来进行识别主要是基于安全方面的考虑，因为文件扩展名可以随意地改动。文件格式的制定者可以自由地选择魔数值，只要这个魔数值还没有被广泛采用过同时又不会引起混淆即可。Class文件的魔数的获得很有“浪漫气息”，值为：0xCAFEBAE（咖啡宝贝？），这个魔数值在Java还称做“Oak”语言的时候（大约是1991年前后）就已经确定下来了。它还有一段很有趣的历史，据Java开发小组最初的关键成员Patrick Naughton所说：“我们一直在寻找一些好玩的、容易记忆的东西，选择0xCAFEBAE是因为它象征着著名咖啡品牌Peet's Coffee中深受欢迎的Baristas咖啡”，这个魔数似乎也预示着日后“Java”这个商标名称的出现。

紧接着魔数的4个字节存储的是Class文件的

版本号：第5和第6个字节是次版本号（Minor Version），第7和第8个字节是主版本号（Major Version）。Java的版本号是从45开始的，JDK 1.1之后的每个JDK大版本发布主版本号向上加1（JDK 1.0~1.1使用了45.0~45.3的版本号），高版本的JDK能向下兼容以前版本的Class文件，但不能运行以后版本的Class文件，即使文件格式并未发生任何变化，虚拟机也必须拒绝执行超过其版本号的Class文件。

例如，JDK 1.1能支持版本号为45.0~45.65535的Class文件，无法执行版本号为46.0以上的Class文件，而JDK 1.2则能支持45.0~46.65535的Class文件。现在，最新的JDK版本为1.7，可生成的Class文件主版本号最大值为51.0。

为了讲解方便，笔者准备了一段最简单的Java代码（见代码清单6-1），本章后面的内容都将以这段小程序使用JDK 1.6编译输出的Class文件为基础来进行讲解。

代码清单6-1 简单的Java代码

```
package org.fenixsoft.clazz;
public class TestClass{
private int m;
public int inc () {
return m+1;
}
}
```

图6-2显示的是使用十六进制编辑器WinHex打开这个Class文件的结果，可以清楚地看见开头4个字节的十六进制表示是0xCAFEBAE，代表次版本号的第5个和第6个字节值为0x0000，而主版本号的值为0x0032，也即是十进制的50，该版

本号说明这个文件是可以被JDK 1.6或以上版本虚拟机执行的Class文件。

| Offset | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | A | B | C | D | E | F |
|----------|----|----|----|----|----|----|----|----|---------------|----|----|----|----|----|------------------|------------------|
| 00000000 | CA | FE | BA | BE | 00 | 00 | 00 | 32 | 00 | 16 | 07 | 00 | 02 | 01 | 00 | 1D |
| 00000010 | 6F | 72 | 67 | 2F | 66 | 65 | 6E | 69 | 数据解码器 | | | | 2F | 63 | 6C | org/fenixsoft/cl |
| 00000020 | 61 | 7A | 7A | 2F | 54 | 65 | 73 | 74 | 8 Bit (+): 50 | | | | 07 | 00 | 04 | azz/TestClass... |
| 00000030 | 01 | 00 | 10 | 6A | 61 | 76 | 61 | 2F | 4F | | | | 62 | 6A | ...java/lang/Obj | |

图 6-2 Java Class文件的结构

表6-2列出了从JDK 1.1到JDK 1.7，主流JDK版本编译器输出的默认和可支持的Class文件版本号。

表 6-2 Class 文件版本号

| 编译器版本 | -target 参数 | 十六进制版本号 | 十进制版本号 |
|--------------|-------------------------|-------------|--------|
| JDK 1.1.8 | 不能带 target 参数 | 00 03 00 2D | 45.3 |
| JDK 1.2.2 | 不带（默认为 -target 1.1） | 00 03 00 2D | 45.3 |
| JDK 1.2.2 | -target 1.2 | 00 00 00 2E | 46.0 |
| JDK 1.3.1_19 | 不带（默认为 -target 1.1） | 00 03 00 2D | 45.3 |
| JDK 1.3.1_19 | -target 1.3 | 00 00 00 2F | 47.0 |
| JDK 1.4.2_10 | 不带（默认为 -target 1.2） | 00 00 00 2E | 46.0 |
| JDK 1.4.2_10 | -target 1.4 | 00 00 00 30 | 48.0 |
| JDK 1.5.0_11 | 不带（默认为 -target 1.5） | 00 00 00 31 | 49.0 |
| JDK 1.5.0_11 | -target 1.4 -source 1.4 | 00 00 00 30 | 48.0 |
| JDK 1.6.0_01 | 不带（默认为 -target 1.6） | 00 00 00 32 | 50.0 |
| JDK 1.6.0_01 | -target 1.5 | 00 00 00 31 | 49.0 |
| JDK 1.6.0_01 | -target 1.4 -source 1.4 | 00 00 00 30 | 48.0 |
| JDK 1.7.0 | 不带（默认为 -target 1.7） | 00 00 00 33 | 51.0 |
| JDK 1.7.0 | -target 1.6 | 00 00 00 32 | 50.0 |
| JDK 1.7.0 | -target 1.4 -source 1.4 | 00 00 00 30 | 48.0 |

[1]这种顺序称为“Big-Endian”，具体是指最高位字节在地址最低位、最低位字节在地址最高位的顺序来存储数据，它是SPARC、PowerPC等处理器的默认多字节存储顺序，而x86等处理器则是使用了相反的“Little-Endian”顺序来存储数据。

6.3.2 常量池

紧接着主次版本号之后的是常量池入口，常量池可以理解为Class文件之中的资源仓库，它是Class文件结构中与其他项目关联最多的数据类型，也是占用Class文件空间最大的数据项目之一，同时它还是在Class文件中第一个出现的表类型数据项目。

由于常量池中常量的数量是不固定的，所以在常量池的入口需要放置一项u2类型的数据，代表常量池容量计数值（constant_pool_count）。与Java中语言习惯不一样的是，这个容量计数是从1而不是0开始的，如图6-3所示，常量池容量（偏移地址：0x00000008）为十六进制数0x0016，即

十进制的22，这就代表常量池中有21项常量，索引值范围为1~21。在Class文件格式规范制定之时，设计者将第0项常量空出来是有特殊考虑的，这样做的目的在于满足后面某些指向常量池的索引值的数据在特定情况下需要表达“不引用任何一个常量池项目”的含义，这种情况就可以把索引值置为0来表示。Class文件结构中只有常量池的容量计数是从1开始，对于其他集合类型，包括接口索引集合、字段表集合、方法表集合等的容量计数都与一般习惯相同，是从0开始的。

| Offset | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | A | B | C | D | E | F | |
|----------|----|----|----|----|----|----|----|----|----|-------------|----|----|----|--------------------|---------------|----|------------------|
| 00000000 | CA | FE | BA | BE | 00 | 00 | 00 | 32 | 00 | 10 | 07 | 00 | 02 | 01 | 00 | 1D |2..... |
| 00000010 | 6F | 72 | 67 | 2F | 66 | 65 | 6E | 69 | 78 | 73 | 6F | 66 | 74 | 2F | 63 | 6C | org/fenixsoft/cl |
| 00000020 | 61 | 7A | 7A | 2F | 54 | 65 | 73 | 74 | 43 | 6C | 61 | 73 | 73 | 07 | 00 | 04 | azz/TestClass... |
| 00000030 | D1 | 00 | 10 | 6A | 61 | 76 | 61 | 2F | 6 | 数据解释器 | 回 | 62 | 6A | ... | java/lang/Obj | | |
| 00000040 | 65 | 63 | 74 | 01 | 00 | 01 | 6D | 01 | 0 | 8Bit(+): 22 | | 3C | 69 | ect....m....I...<i | | | |
| 00000050 | 6E | 69 | 74 | 3E | 01 | 00 | 03 | 28 | 2 | | | 6F | 64 | nit>...IV...Cod | | | |

图 6-3 常量池结构

常量池中主要存放两大类常量：字面量

（Literal）和符号引用（Symbolic References）。

字面量比较接近于Java语言层面的常量概念，如文本字符串、声明为final的常量值等。而符号引用则属于编译原理方面的概念，包括了下面三类常量：

类和接口的全限定名（Fully Qualified

Name）

字段的名称和描述符（Descriptor）

方法的名称和描述符

Java代码在进行Javac编译的时候，并不像C和C++那样有“连接”这一步骤，而是在虚拟机加载Class文件的时候进行动态连接。也就是说，在

Class文件中不会保存各个方法、字段的最终内存布局信息，因此这些字段、方法的符号引用不经过运行期转换的话无法得到真正的内存入口地址，也就无法直接被虚拟机使用。当虚拟机运行时，需要从常量池获得对应的符号引用，再在类创建时或运行时解析、翻译到具体的内存地址之中。关于类的创建和动态连接的内容，在下一章介绍虚拟机类加载过程时再进行详细讲解。

常量池中每一项常量都是一个表，在JDK 1.7之前共有11种结构各不相同的表结构数据，在JDK 1.7中为了更好地支持动态语言调用，又额外增加了3种（CONSTANT_MethodHandle_info、CONSTANT_MethodType_info和CONSTANT_InvokeDynamic_info，本章不会涉及这3种新增的类型，在第8章介绍字节码执行和方

法调用时，将会详细讲解）。

这14种表都有一个共同的特点，就是表开始的第一位是一个u1类型的标志位（tag，取值见表6-3中标志列），代表当前这个常量属于哪种常量类型。这14种常量类型所代表的具体含义见表6-3。

表 6-3 常量池的项目类型

| 类 型 | 标 志 | 描 述 |
|----------------------------------|-----|--------------|
| CONSTANT_Utf8_info | 1 | UTF-8 编码的字符串 |
| CONSTANT_Integer_info | 3 | 整型字面量 |
| CONSTANT_Float_info | 4 | 浮点型字面量 |
| CONSTANT_Long_info | 5 | 长整型字面量 |
| CONSTANT_Double_info | 6 | 双精度浮点型字面量 |
| CONSTANT_Class_info | 7 | 类或接口的符号引用 |
| CONSTANT_String_info | 8 | 字符串类型字面量 |
| CONSTANT_Fieldref_info | 9 | 字段的符号引用 |
| CONSTANT_Methodref_info | 10 | 类中方法的符号引用 |
| CONSTANT_InterfaceMethodref_info | 11 | 接口中方法的符号引用 |
| CONSTANT_NameAndType_info | 12 | 字段或方法的部分符号引用 |
| CONSTANT_MethodHandle_info | 15 | 表示方法句柄 |
| CONSTANT_MethodType_info | 16 | 标识方法类型 |
| CONSTANT_InvokeDynamic_info | 18 | 表示一个动态方法调用点 |

之所以说常量池是最烦琐的数据，是因为这14种常量类型各自均有自己的结构。回头看看图

6-3中常量池的第一项常量，它的标志位（偏移地址：0x0000000A）是0x07，查表6-3的标志列发现这个常量属于CONSTANT_Class_info类型，此类型的常量代表一个类或者接口的符号引用。

CONSTANT_Class_info的结构比较简单，见表6-4。

表 6-4 CONSTANT_Class_info 型常量的结构

| 类 型 | 名 称 | 数 量 |
|--------|------------|--------|
| u1 | tag | 1 |
| u2 | name_index | 1 |

tag是标志位，上面已经讲过了，它用于区分常量类型；name_index是一个索引值，它指向常量池中一个CONSTANT_Utf8_info类型常量，此常量代表了这个类（或者接口）的全限定名，这里name_index值（偏移地址：0x0000000B）为0x0002，也即是指向了常量池中的第二项常量。

继续从图6-3中查找第二项常量，它的标志位（地址：0x0000000D）是0x01，查表6-3可知确实是一个CONSTANT_Utf8_info类型的常量。

CONSTANT_Utf8_info类型的结构见表6-5。

表 6-5 CONSTANT_Utf8_info 型常量的结构

| 类 型 | 名 称 | 数 量 |
|-----|--------|--------|
| u1 | tag | 1 |
| u2 | length | 1 |
| u1 | bytes | length |

length值说明了这个UTF-8编码的字符串长度是多少字节，它后面紧跟着的长度为length字节的连续数据是一个使用UTF-8缩略编码表示的字符串。UTF-8缩略编码与普通UTF-8编码的区别是：从'\u0001'到'\u007f'之间的字符（相当于1~127的ASCII码）的缩略编码使用一个字节表示，从'\u0080'到'\u07ff'之间的所有字符的缩略编码用两个字节表示，从'\u0800'到'\uffff'之间的所有字

符的缩略编码就按照普通UTF-8编码规则使用三个字节表示。

顺便提一下，由于Class文件中方法、字段等都需要引用CONSTANT_Utf8_info型常量来描述名称，所以CONSTANT_Utf8_info型常量的最大长度也就是Java中方法、字段名的最大长度。而这里的最大长度就是length的最大值，既u2类型能表达的最大值65535。所以Java程序中如果定义了超过64KB英文字符的变量或方法名，将会无法编译。

本例中这个字符串的length值（偏移地址：0x0000000E）为0x001D，也就是长29字节，往后29字节正好都在1~127的ASCII码范围以内，内容为“org/fenixsoft/clazz/TestClass”，有兴趣的读者可以自己逐个字节换算一下，换算结果如图6-4选

中的部分所示。

| Offset | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | A | B | C | D | E | F |
|----------|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| 00000000 | CA | FE | BA | BE | 00 | 00 | 00 | 32 | 00 | 16 | 07 | 00 | 02 | 01 | 00 | 1D |
| 00000010 | 6F | 72 | 57 | 2F | 66 | 65 | 6E | 69 | 78 | 73 | 6F | 66 | 74 | 2F | 63 | 6C |
| 00000020 | 61 | 7A | 7A | 2F | 54 | 65 | 73 | 74 | 43 | 6C | 61 | 73 | 7E | 07 | 00 | 04 |
| 00000030 | 01 | 00 | 10 | 6A | 61 | 76 | 61 | 2F | 6C | 61 | 6E | 67 | 2F | 4F | 62 | 6A |

图 6-4 常量池UTF-8字符串结构

到此为止，我们分析了TestClass.class常量池中21个常量中的两个，其余的19个常量都可以通过类似的方法计算出来。为了避免计算过程占用过多的版面，后续的19个常量的计算过程可以借助计算机来帮我们完成。在JDK的bin目录中，Oracle公司已经为我们准备好一个专门用于分析Class文件字节码的工具：javap，代码清单6-2中列出了使用javap工具的-verbose参数输出的TestClass.class文件字节码内容（此清单中省略了常量池以外的信息）。前面我们曾经提到过，

Class文件中还有很多数据项都要引用常量池中的常量，所以代码清单6-2中的内容在后续的讲解过程中还要经常使用到。

代码清单6-2 使用Javap命令输出常量表

```
C: \>javap-verbose TestClass
Compiled from "TestClass.java"
public class org.fenixsoft.clazz.TestClass
extends java.lang.Object
SourceFile: "TestClass.java"
minor version: 0
major version: 50
Constant pool:
const#1=class#2; //org/fenixsoft/clazz/TestC]
const#2=Asciz
org/fenixsoft/clazz/TestClass;
const#3=class#4; //java/lang/Object
const#4=Asciz java/lang/Object;
const#5=Asciz m;
const#6=Asciz I;
const#7=Asciz<init>;
const#8=Asciz () V;
const#9=Asciz Code;
const#10=Method#3.#11; //java/lang/Object."<
init>": () V
const#11=NameAndType#7: #8; //"<init>": ()
```

```
const#12=Asciz LineNumberTable;
const#13=Asciz LocalVariableTable;
const#14=Asciz this;
const#15=Asciz
Lorg/fenixsoft/clazz/TestClass;
const#16=Asciz inc;
const#17=Asciz () I;
const#18=Field#1.#19; //org/fenixsoft/clazz/I
I
const#19=NameAndType#5: #6; //m: I
const#20=Asciz SourceFile;
const#21=Asciz TestClass.java;
```

从代码清单6-2中可以看出，计算机已经帮我们把整个常量池的21项常量都计算了出来，并且第1、2项常量的计算结果与我们手工计算的结果一致。仔细看一下会发现，其中有一些常量似乎从来没有在代码中出现过，如“T”、“V”、“<init>”、“LineNumberTable”、“LocalVariableTable”等，这些看起来在代码任何一处都没有出现过的常量是哪里来的呢？

这部分自动生成的常量的确没有在Java代码里面直接出现过，但它们会被后面即将讲到的字段表（field_info）、方法表（method_info）、属性表（attribute_info）引用到，它们会用来描述一些不方便使用“固定字节”进行表达的内容。譬如描述方法的返回值是什么？有几个参数？每个参数的类型是什么？因为Java中的“类”是无穷无尽的，无法通过简单的无符号字节来描述一个方法用到了什么类，因此在描述方法的这些信息时，需要引用常量表中的符号引用进行表达。这部分内容将在后面进一步阐述。最后，笔者将这14种常量项的结构定义总结为表6-6以供读者参考。

表 6-6 常量池中的 14 种常量项的结构总表

| 常量 | 项目 | 类型 | 描述 |
|----------------------------------|--------|----|--|
| CONSTANT_Utf8_info | tag | u1 | 值为 1 |
| | length | u2 | UTF-8 编码的字符串占用的字节数 |
| | bytes | u1 | 长度为 length 的 UTF-8 编码的字符串 |
| CONSTANT_Integer_info | tag | u1 | 值为 3 |
| | bytes | u4 | 按照高位在前存储的 int 值 |
| CONSTANT_Float_info | tag | u1 | 值为 4 |
| | bytes | u4 | 按照高位在前存储的 float 值 |
| CONSTANT_Long_info | tag | u1 | 值为 5 |
| | bytes | u8 | 按照高位在前存储的 long 值 |
| CONSTANT_Double_info | tag | u1 | 值为 6 |
| | bytes | u8 | 按照高位在前存储的 double 值 |
| CONSTANT_Class_info | tag | u1 | 值为 7 |
| | index | u2 | 指向全限定名常量项的索引 |
| CONSTANT_String_info | tag | u1 | 值为 8 |
| | index | u2 | 指向字符串字面量的索引 |
| CONSTANT_Fieldref_info | tag | u1 | 值为 9 |
| | index | u2 | 指向声明字段的类或者接口描述符 CONSTANT_Class_info 的索引项 |
| | index | u2 | 指向字段描述符 CONSTANT_NameAndType 的索引项 |
| CONSTANT_Methodref_info | tag | u1 | 值为 10 |
| | index | u2 | 指向声明方法的类描述符 CONSTANT_Class_info 的索引项 |
| | index | u2 | 指向名称及类型描述符 CONSTANT_NameAndType 的索引项 |
| CONSTANT_InterfaceMethodref_info | tag | u1 | 值为 11 |
| | index | u2 | 指向声明方法的接口描述符 CONSTANT_Class_info 的索引项 |
| | index | u2 | 指向名称及类型描述符 CONSTANT_NameAndType 的索引项 |

| 常量 | 项目 | 类型 | 描述 |
|-----------------------------|-----------------------------|----|--|
| CONSTANT_NameAndType_info | tag | u1 | 值为 12 |
| | index | u2 | 指向该字段或方法名称常量项的索引 |
| | index | u2 | 指向该字段或方法描述符常量项的索引 |
| CONSTANT_MethodHandle_info | tag | u1 | 值为 15 |
| | reference_kind | u1 | 值必须在 1 ~ 9 之间（包括 1 和 9），它决定了方法句柄的类型。方法句柄类型的值表示方法句柄的字节码行为 |
| | reference_index | u2 | 值必须是对常量池的有效索引 |
| CONSTANT_MethodType_info | tag | u1 | 值为 16 |
| | descriptor_index | u2 | 值必须是对常量池的有效索引，常量池在该索引处的项必须是 CONSTANT_Utf8_info 结构，表示方法的描述符 |
| CONSTANT_InvokeDynamic_info | tag | u1 | 值为 18 |
| | bootstrap_method_attr_index | u2 | 值必须是对当前 Class 文件中引导方法表的 bootstrap_methods[] 数组的有效索引 |
| | name_and_type_index | u2 | 值必须是对当前常量池的有效索引，常量池在该索引处的项必须是 CONSTANT_NameAndType_info 结构，表示方法名和方法描述符 |

6.3.3 访问标志

在常量池结束之后，紧接着的两个字节代表访问标志（access_flags），这个标志用于识别一些类或者接口层次的访问信息，包括：这个Class是类还是接口；是否定义为public类型；是否定义为abstract类型；如果是类的话，是否被声明为final等。具体的标志位以及标志的含义见表6-7。

表 6-7 访问标志

| 标志名称 | 标志值 | 含 义 |
|----------------|--------|---|
| ACC_PUBLIC | 0x0001 | 是否为 public 类型 |
| ACC_FINAL | 0x0010 | 是否被声明为 final，只有类可设置 |
| ACC_SUPER | 0x0020 | 是否允许使用 invokespecial 字节码指令的新语意，invokespecial 指令的语意在 JDK 1.0.2 发生过改变，为了区别这条指令使用哪种语意，JDK 1.0.2 之后编译出来的类的这个标志都必须为真 |
| ACC_INTERFACE | 0x0200 | 标识这是一个接口 |
| ACC_ABSTRACT | 0x0400 | 是否为 abstract 类型，对于接口或者抽象类来说，此标志值为真，其他类值为假 |
| ACC_SYNTHETIC | 0x1000 | 标识这个类并非由用户代码产生的 |
| ACC_ANNOTATION | 0x2000 | 标识这是一个注解 |
| ACC_ENUM | 0x4000 | 标识这是一个枚举 |

access_flags中一共有16个标志位可以使用，当前只定义了其中8个^[1]，没有使用到的标志位要求一律为0。以代码清单6-1中的代码为例，TestClass是一个普通Java类，不是接口、枚举或者注解，被public关键字修饰但没有被声明为final和abstract，并且它使用了JDK 1.2之后的编译器进行编译，因此它的ACC_PUBLIC、ACC_SUPER标志应当为真，而ACC_FINAL、ACC_INTERFACE、ACC_ABSTRACT、ACC_SYNTHETIC、ACC_ANNOTATION、ACC_ENUM这6个标志应当为假，因此它的access_flags的值应为：0x0001|0x0020=0x0021。从图6-5中可以看出，access_flags标志（偏移地址：0x000000EF）的确为0x0021。

| | | |
|----------|---|------------------|
| 000000D0 | 06 01 00 0A 53 6F 75 72 63 65 46 69 6C 65 01 00 |SourceFile.. |
| 000000E0 | 0E 54 65 73 74 43 6C 61 73 73 2E 6A 61 76 61 00 | .TestClass.java. |
| 000000F0 | 21 00 01 00 03 00 00 00 01 00 02 00 05 00 06 00 | |
| 00000100 | 00 00 02 00 01 00 07 00 08 00 01 00 09 00 00 00 | |

图 6-5 access_flags标志

[1]在Java虚拟机规范中，只定义了开头5种标志。JDK 1.5中增加了后面3种。这些标志为在JSR-202规范中声明，是对《Java虚拟机规范（第2版）》的补充。本书介绍的访问标志以JSR-202规范为准。

6.3.4 类索引、父类索引与接口索引集合

类索引（this_class）和父类索引

（super_class）都是一个u2类型的数据，而接口索引集合（interfaces）是一组u2类型的数据的集合，Class文件中由这三项数据来确定这个类的继承关系。类索引用于确定这个类的全限定名，父类索引用于确定这个类的父类的全限定名。由于Java语言不允许多重继承，所以父类索引只有一个，除了java.lang.Object之外，所有的Java类都有父类，因此除了java.lang.Object外，所有Java类的父类索引都不为0。接口索引集合就用来描述这个类实现了哪些接口，这些被实现的接口将按implements语句（如果这个类本身是一个接口，

则应当是extends语句)后的接口顺序从左到右排列在接口索引集合中。

类索引、父类索引和接口索引集合都按顺序排列在访问标志之后，类索引和父类索引用两个u2类型的索引值表示，它们各自指向一个类型为CONSTANT_Class_info的类描述符常量，通过CONSTANT_Class_info类型的常量中的索引值可以找到定义在CONSTANT_Utf8_info类型的常量中的全限定名字符串。图6-6演示了代码清单6-1的代码的类索引查找过程。

对于接口索引集合，入口的第一项——u2类型的数据为接口计数器(interfaces_count)，表示索引表的容量。如果该类没有实现任何接口，则该计数器值为0，后面接口的索引表不再占用

任何字节。代码清单6-1中的代码的类索引、父类索引与接口表索引的内容如图6-7所示。




图 6-6 类索引查找全限定名的过程

| | | |
|-----------|---|------------------|
| 0000000D0 | 06 01 00 0A 53 6F 75 72 63 65 46 69 6C 65 01 00 |SourceFile.. |
| 0000000E0 | 0E 54 65 73 74 43 6C 61 73 73 2E 6A 61 76 61 00 | .TestClass.java. |
| 0000000F0 | 21 00 01 00 03 00 00 00 01 00 02 00 05 00 06 00 | !..... |
| 000000100 | 00 00 02 00 01 00 07 00 08 00 01 00 09 00 00 00 | |

图 6-7 类索引、父类索引、接口索引集合

从偏移地址0x000000F1开始的3个u2类型的值分别为0x0001、0x0003、0x0000，也就是类索引为1，父类索引为3，接口索引集合大小为0，查询前面代码清单6-2中javap命令计算出来的常量池，找出对应的类和父类的常量，结果如代码

清单6-3所示。

代码清单6-3 部分常量池内容

```
const#1=class#2; //org/fenixsoft/clazz/TestC1
const#2=Asciz
org/fenixsoft/clazz/TestClass;
const#3=class#4; //java/lang/Object
const#4=Asciz java/lang/Object;
```

6.3.5 字段表集合

字段表（`field_info`）用于描述接口或者类中声明的变量。字段（`field`）包括类级变量以及实例级变量，但不包括在方法内部声明的局部变量。我们可以想一想在Java中描述一个字段可以包含什么信息？可以包括的信息有：字段的作用域（`public`、`private`、`protected`修饰符）、是实例变量还是类变量（`static`修饰符）、可变性（`final`）、并发可见性（`volatile`修饰符，是否强制从主内存读写）、可否被序列化（`transient`修饰符）、字段数据类型（基本类型、对象、数组）、字段名称。上述这些信息中，各个修饰符都是布尔值，要么有某个修饰符，要么没有，很

适合使用标志位来表示。而字段叫什么名字、字段被定义为什么数据类型，这些都是无法固定的，只能引用常量池中的常量来描述。表6-8中列出了字段表的最终格式。

表 6-8 字段表结构

| 类 型 | 名 称 | 数 量 | 类 型 | 名 称 | 数 量 |
|-----|------------------|-----|----------------|------------------|------------------|
| u2 | access_flags | 1 | u2 | attributes_count | 1 |
| u2 | name_index | 1 | attribute_info | attributes | attributes_count |
| u2 | descriptor_index | 1 | | | |

字段修饰符放在access_flags项目中，它与类中的access_flags项目是非常类似的，都是一个u2的数据类型，其中可以设置的标志位和含义见表6-9。

表 6-9 字段访问标志

| 标志名称 | 标志值 | 含义 |
|---------------|--------|----------------|
| ACC_PUBLIC | 0x0001 | 字段是否 public |
| ACC_PRIVATE | 0x0002 | 字段是否 private |
| ACC_PROTECTED | 0x0004 | 字段是否 protected |
| ACC_STATIC | 0x0008 | 字段是否 static |
| ACC_FINAL | 0x0010 | 字段是否 final |
| ACC_VOLATILE | 0x0040 | 字段是否 volatile |
| ACC_TRANSIENT | 0x0080 | 字段是否 transient |
| ACC_SYNTHETIC | 0x1000 | 字段是否由编译器自动产生的 |
| ACC_ENUM | 0x4000 | 字段是否 enum |

很明显，在实际情况中，ACC_PUBLIC、ACC_PRIVATE、ACC_PROTECTED三个标志最多只能选择其一，ACC_FINAL、ACC_VOLATILE不能同时选择。接口之中的字段必须有ACC_PUBLIC、ACC_STATIC、ACC_FINAL标志，这些都是由Java本身的语言规则所决定的。

跟随access_flags标志的是两项索引值：name_index和descriptor_index。它们都是对常量池的引用，分别代表着字段的简单名称以及字段和方法的描述符。现在需要解释一下“简单名

称”、“描述符”以及前面出现过多次的“全限定名”这三种特殊字符串的概念。

全限定名和简单名称很好理解，以代码清单6-1中的代码为例

例，“org/fenixsoft/clazz/TestClass”是这个类的全限定名，仅仅是把类全名中的“.”替换成了“/”而已，为了使连续的多个全限定名之间不产生混淆，在使用时最后一般会加入一个“；”表示全限定名结束。简单名称是指没有类型和参数修饰的方法或者字段名称，这个类中的inc（）方法和m字段的简单名称分别是“inc”和“m”。

相对于全限定名和简单名称来说，方法和字段的描述符就要复杂一些。描述符的作用是用来描述字段的数据类型、方法的参数列表（包括数

量、类型以及顺序) 和返回值。根据描述符规则, 基本数据类型 (byte、char、double、float、int、long、short、boolean) 以及代表无返回值的 void 类型都用一个大写字符来表示, 而对象类型则用字符 L 加对象的全限定名来表示, 详见表 6-10。

表 6-10 描述符标识字符含义

| 标识字符 | 含 义 | 标识字符 | 含 义 |
|------|-------------|----------------|---------------------------|
| B | 基本类型 byte | J | 基本类型 long |
| C | 基本类型 char | S | 基本类型 short |
| D | 基本类型 double | Z | 基本类型 boolean |
| F | 基本类型 float | V [≡] | 特殊类型 void |
| I | 基本类型 int | L | 对象类型, 如 Ljava/lang/Object |

[1]

对于数组类型, 每一维度将使用一个前置的 “[” 字符来描述, 如一个定义为 “java.lang.String[][]” 类型的二维数组, 将被记录为: “[[Ljava/lang/String; ”, 一个整型数

组“int[]”将被记录为“[I”。

用描述符来描述方法时，按照先参数列表，后返回值的顺序描述，参数列表按照参数的严格顺序放在一组小括号“（）”之内。如方法void inc（）的描述符为“（）V”，方法java.lang.String toString（）的描述符为“（）Ljava/lang/String; ”，方法int indexOf（char[]source,int sourceOffset,int sourceCount,char[]target,int targetOffset,int targetCount,int fromIndex）的描述符为“([CII[CIII）I”。

对于代码清单6-1中的TestClass.class文件来说，字段表集合从地址0x000000F8开始，第一个u2类型的数据为容量计数器fields_count，如图6-8

所示，其值为0x0001，说明这个类只有一个字段表数据。接下来紧跟着容量计数器的是access_flags标志，值为0x0002，代表private修饰符的ACC_PRIVATE标志位为真（ACC_PRIVATE标志的值为0x0002），其他修饰符为假。代表字段名称的name_index的值为0x0005，从代码清单6-2列出的常量表中可查得第5项常量是一个CONSTANT_Utf8_info类型的字符串，其值为“m”，代表字段描述符的descriptor_index的值为0x0006，指向常量池的字符串“I”，根据这些信息，我们可以推断出原代码定义的字段为：“private int m; ”。

字段表都包含的固定数据项目到descriptor_index为止就结束了，不过在descriptor_index之后跟随着一个属性表集合用于

存储一些额外的信息，字段都可以在属性表中描述零至多项的额外信息。对于本例中的字段m，它的属性表计数器为0，也就是没有需要额外描述的信息，但是，如果将字段m的声明改为“final static int m=123; ”，那就可能会存在一项名称为ConstantValue的属性，其值指向常量123。关于attribute_info的其他内容，将在6.3.7节介绍属性表的数据项目时再进一步讲解。

| | | |
|-----------|---|------------------|
| 0000000D0 | 06 01 00 0A 53 6F 75 72 63 65 46 69 6C 65 01 00 | ...SourceFile.. |
| 0000000E0 | 0E 54 65 73 74 43 6C 61 73 73 2E 6A 61 76 61 00 | .TestClass.java. |
| 0000000F0 | 21 00 01 00 03 00 00 00 01 02 00 05 00 06 00 00 | !..... |
| 000000100 | 00 00 02 00 01 00 07 00 08 00 01 00 09 00 00 00 | |

fields_count name_index
access_flags descriptor_index

The diagram shows a memory dump of a Java field attribute info table. The first four bytes (0000000D0) represent the attribute's offset and size. The next four bytes (0000000E0) are the attribute's name. The following four bytes (0000000F0) are the attribute's value. The last four bytes (000000100) are the attribute's descriptor. Annotations below the table point to specific fields: 'fields_count' points to the first byte of the value section; 'access_flags' points to the second byte of the value section; 'name_index' points to the third byte of the name section; and 'descriptor_index' points to the fourth byte of the value section.

图 6-8 字段表结构实例

字段表集合中不会列出从超类或者父接口中继承而来的字段，但有可能列出原本Java代码之

中不存在的字段，譬如在内部类中为了保持对外部类的访问性，会自动添加指向外部类实例的字段。另外，在Java语言中字段是无法重载的，两个字段的数据类型、修饰符不管是否相同，都必须使用不一样的名称，但是对于字节码来讲，如果两个字段的描述符不一致，那字段重名就是合法的。

[1]void类型在虚拟机规范之中单独列出为“VoidDescriptor”，笔者为了结构统一，将其列在基本数据类型中一起描述。

6.3.6 方法表集合

如果理解了上一节关于字段表的内容，那本节关于方法表的内容将会变得很简单。Class文件存储格式中对方法的描述与对字段的描述几乎采用了完全一致的方式，方法表的结构如同字段表一样，依次包括了访问标志（access_flags）、名称索引（name_index）、描述符索引（descriptor_index）、属性表集合（attributes）几项，见表6-11。这些数据项目的含义也非常类似，仅在访问标志和属性表集合的可选项中有所区别。

表 6-11 方法表结构

| 类 型 | 名 称 | 数 量 | 类 型 | 名 称 | 数 量 |
|-----|------------------|-----|----------------|------------------|------------------|
| u2 | access_flags | 1 | u2 | attributes_count | 1 |
| u2 | name_index | 1 | attribute_info | attributes | attributes_count |
| u2 | descriptor_index | 1 | | | |

因为volatile关键字和transient关键字不能修饰方法，所以方法表的访问标志中没有了ACC_VOLATILE标志和ACC_TRANSIENT标志。与之相对的，synchronized、native、strictfp和abstract关键字可以修饰方法，所以方法表的访问标志中增加了ACC_SYNCHRONIZED、ACC_NATIVE、ACC_STRICTFP和ACC_ABSTRACT标志。对于方法表，所有标志位及其取值可参见表6-12。

表 6-12 方法访问标志

| 标志名称 | 标志值 | 含义 |
|------------------|--------|--------------------|
| ACC_PUBLIC | 0x0001 | 方法是否为 public |
| ACC_PRIVATE | 0x0002 | 方法是否为 private |
| ACC_PROTECTED | 0x0004 | 方法是否为 protected |
| ACC_STATIC | 0x0008 | 方法是否为 static |
| ACC_FINAL | 0x0010 | 方法是否为 final |
| ACC_SYNCHRONIZED | 0x0020 | 方法是否为 synchronized |
| ACC_BRIDGE | 0x0040 | 方法是否是由编译器产生的桥接方法 |
| ACC_VARARGS | 0x0080 | 方法是否接受不定参数 |
| ACC_NATIVE | 0x0100 | 方法是否为 native |
| ACC_ABSTRACT | 0x0400 | 方法是否为 abstract |
| ACC_STRICTFP | 0x0800 | 方法是否为 strictfp |
| ACC_SYNTHETIC | 0x1000 | 方法是否是由编译器自动产生的 |

行文至此，也许有的读者会产生疑问，方法的定义可以通过访问标志、名称索引、描述符索引表达清楚，但方法里面的代码去哪里了？方法里的Java代码，经过编译器编译成字节码指令后，存放在方法属性表集合中一个名为“Code”的属性里面，属性表作为Class文件格式中最具扩展性的一种数据项目，将在6.3.7节中详细讲解。

我们继续以代码清单6-1中的Class文件为例对方法表集合进行分析，如图6-9所示，方法表集合的入口地址为：0x00000101，第一个u2类型的数据（即是计数器容量）的值为0x0002，代表集合中有两个方法（这两个方法为编译器添加的实例构造器<init>和源码中的方法inc（））。第一个方法的访问标志值为0x001，也就是只有ACC_PUBLIC标志为真，名称索引值为0x0007，

查代码清单6-2的常量池得方法名为“<init>”，描述符索引值为0x0008，对应常量为“()V”，属性表计数器attributes_count的值为0x0001就表示此方法的属性表集合有一项属性，属性名称索引为0x0009，对应常量为“Code”，说明此属性是方法的字节码描述。

| | | |
|-----------|---|-------------|
| 0000000F0 | 21 00 01 00 03 00 00 00 01 00 02 00 05 00 06 00 | !..... |
| 000000100 | 00 00 02 00 01 00 07 00 08 00 01 00 09 00 00 00 | |
| 000000110 | 2F 00 01 00 01 00 00 00 05 2A B7 00 0A B1 00 00 | /.....*?.?. |

methods_count name_index attributes_count
access_flags descriptor_index attribute_name_index

图 6-9 方法表结构实例

与字段表集合相对应的，如果父类方法在子类中没有被重写（Override），方法表集合中就不会出现来自父类的方法信息。但同样的，有可能会出现由编译器自动添加的方法，最典型的便是类构造器“<clinit>”方法和实例构造器“<init>

>”^[1]方法。

在Java语言中，要重载（Overload）一个方法，除了要与原方法具有相同的简单名称之外，还要求必须拥有一个与原方法不同的特征签名^[2]，特征签名就是一个方法中各个参数在常量池中的字段符号引用的集合，也就是因为返回值不会包含在特征签名中，因此Java语言里面是无法仅仅依靠返回值的不同来对一个已有方法进行重载的。但是在Class文件格式中，特征签名的范围更大一些，只要描述符不是完全一致的两个方法也可以共存。也就是说，如果两个方法有相同的名称和特征签名，但返回值不同，那么也是可以合法共存于同一个Class文件中的。

[1]<init>和<clinit>的详细内容见本书的第10

章。

[2]在《Java虚拟机规范（第2版）》的“§ 4.4.4 Signatures”章节及《Java语言规范（第3版）》的“§ 8.4.2 Method Signature”章节中都分别定义了字节码层面的方法特征签名以及Java代码层面的方法特征签名，Java代码的方法特征签名只包括了方法名称、参数顺序及参数类型，而字节码的特征签名还包括方法返回值以及受查异常表，请读者根据上下文语境注意区分。

6.3.7 属性表集合

属性表（attribute_info）在前面的讲解之中已经出现过数次，在Class文件、字段表、方法表都可以携带自己的属性表集合，以用于描述某些场景专有的信息。

与Class文件中其他的数据项目要求严格的顺序、长度和内容不同，属性表集合的限制稍微宽松了一些，不再要求各个属性表具有严格顺序，并且只要不与已有属性名重复，任何人实现的编译器都可以向属性表中写入自己定义的属性信息，Java虚拟机运行时会忽略掉它不认识的属性。为了能正确解析Class文件，《Java虚拟机规范（第2版）》中预定义了9项虚拟机实现应当能

识别的属性，而在最新的《Java虚拟机规范（Java SE 7）》版中，预定义属性已经增加到21项，具体内容见表6-13。下文中将对其中一些属性中的关键常用的部分进行讲解。

表 6-13 虚拟机规范预定义的属性

| 属性名称 | 使用位置 | 含 义 |
|-----------------|-----------|--|
| Code | 方法表 | Java 代码编译成的字节码指令 |
| ConstantValue | 字段表 | final 关键字定义的常量值 |
| Deprecated | 类、方法表、字段表 | 被声明为 deprecated 的方法和字段 |
| Exceptions | 方法表 | 方法抛出的异常 |
| EnclosingMethod | 类文件 | 仅当一个类为局部类或者匿名类时才能拥有这个属性，这个属性用于标识这个类所在的外围方法 |

| 属性名称 | 使用位置 | 含 义 |
|--------------------------------------|-----------|--|
| InnerClasses | 类文件 | 内部类列表 |
| LineNumberTable | Code 属性 | Java 源码的行号与字节码指令的对应关系 |
| LocalVariableTable | Code 属性 | 方法的局部变量描述 |
| StackMapTable | Code 属性 | JDK 1.6 中新增的属性，供新的类型检查验证器（Type Checker）检查和处理目标方法的局部变量和操作数栈所需要的类型是否匹配 |
| Signature | 类、方法表、字段表 | JDK 1.5 中新增的属性，这个属性用于支持泛型情况下方法的签名，在 Java 语言中，任何类、接口、初始化方法或成员的泛型签名如果包含了类型变量（Type Variables）或参数化类型（Parameterized Types），则 Signature 属性会为它记录泛型签名信息。由于 Java 的泛型采用擦除法实现，在为了避免类型信息被擦除后导致签名混乱，需要这个属性记录泛型中的相关信息 |
| SourceFile | 类文件 | 记录源文件名称 |
| SourceDebugExtension | 类文件 | JDK 1.6 中新增的属性，SourceDebugExtension 属性用于存储额外的调试信息。譬如在进行 JSP 文件调试时，无法通过 Java 堆栈来定位到 JSP 文件的行号，JSR-45 规范为这些非 Java 语言编写，却需要编译成字节码并运行在 Java 虚拟机中的程序提供了一个进行调试的标准机制，使用 SourceDebugExtension 属性就可以用于存储这个标准所新加入的调试信息 |
| Synthetic | 类、方法表、字段表 | 标记方法或字段为编译器自动生成的 |
| LocalVariableTypeTable | 类 | JDK 1.5 中新增的属性，它使用特征签名代替描述符，是为了引入泛型语法之后能描述泛型参数化类型而添加 |
| RuntimeVisibleAnnotations | 类、方法表、字段表 | JDK 1.5 中新增的属性，为动态注解提供支持。RuntimeVisibleAnnotations 属性用于指明哪些注解是运行时（实际上运行时就是进行反射调用）可见的 |
| RuntimeInvisibleAnnotations | 类、方法表、字段表 | JDK 1.5 中新增的属性，与 RuntimeVisibleAnnotations 属性作用刚好相反，用于指明哪些注解是运行时不可见的 |
| RuntimeVisibleParameterAnnotations | 方法表 | JDK 1.5 中新增的属性，作用与 RuntimeVisibleAnnotations 属性类似，只不过作用对象为方法参数 |
| RuntimeInvisibleParameterAnnotations | 方法表 | JDK 1.5 中新增的属性，作用与 RuntimeInvisibleAnnotations 属性类似，只不过作用对象为方法参数 |
| AnnotationDefault | 方法表 | JDK 1.5 中新增的属性，用于记录注解类元素的默认值 |
| BootstrapMethods | 类文件 | JDK 1.7 中新增的属性，用于保存 invokedynamic 指令引用的引导方法限定符 |

对于每个属性，它的名称需要从常量池中引用一个CONSTANT_Utf8_info类型的常量来表示，而属性值的结构则是完全自定义的，只需要通过一个u4的长度属性去说明属性值所占用的位数即可。一个符合规则的属性表应该满足表6-14中所定义的结构。

表 6-14 属性表结构

| 类 型 | 名 称 | 数 量 |
|-----|----------------------|------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u1 | info | attribute_length |

1.Code属性

Java程序方法体中的代码经过Javac编译器处理后，最终变为字节码指令存储在Code属性内。Code属性出现在方法表的属性集合之中，但并非所有的方法表都必须存在这个属性，譬如接口或

者抽象类中的方法就不存在Code属性，如果方法表有Code属性存在，那么它的结构将如表6-15所示。

表 6-15 Code 属性表的结构

| 类 型 | 名 称 | 数 量 |
|----------------|------------------------|------------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | max_stack | 1 |
| u2 | max_locals | 1 |
| u4 | code_length | 1 |
| u1 | code | code_length |
| u2 | exception_table_length | 1 |
| exception_info | exception_table | exception_table_length |
| u2 | attributes_count | 1 |
| attribute_info | attributes | attributes_count |

attribute_name_index是一项指向CONSTANT_Utf8_info型常量的索引，常量值固定为“Code”，它代表了该属性的属性名称，attribute_length指示了属性值的长度，由于属性名称索引与属性长度一共为6字节，所以属性值的长度固定为整个属性表长度减去6个字节。

`max_stack`代表了操作数栈（Operand Stacks）深度的最大值。在方法执行的任意时刻，操作数栈都不会超过这个深度。虚拟机运行的时候需要根据这个值来分配栈帧（Stack Frame）中的操作栈深度。

`max_locals`代表了局部变量表所需的存储空间。在这里，`max_locals`的单位是Slot, Slot是虚拟机为局部变量分配内存所使用的最小单位。对于`byte`、`char`、`float`、`int`、`short`、`boolean`和`returnAddress`等长度不超过32位的数据类型，每个局部变量占用1个Slot，而`double`和`long`这两种64位的数据类型则需要两个Slot来存放。方法参数（包括实例方法中的隐藏参数“`this`”）、显式异常处理器的参数（Exception Handler Parameter，就是`try-catch`语句中`catch`块所定义的异常）、方

法体中定义的局部变量都需要使用局部变量表来存放。另外，并不是在方法中用到了多少个局部变量，就把这些局部变量所占Slot之和作为max_locals的值，原因是局部变量表中的Slot可以重用，当代码执行超出一个局部变量的作用域时，这个局部变量所占的Slot可以被其他局部变量所使用，Javac编译器会根据变量的作用域来分配Slot给各个变量使用，然后计算出max_locals的大小。

code_length和code用来存储Java源程序编译后生成的字节码指令。code_length代表字节码长度，code是用于存储字节码指令的一系列字节流。既然叫字节码指令，那么每个指令就是一个u1类型的单字节，当虚拟机读取到code中的一个字节码时，就可以对应找出这个字节码代表的是

什么指令，并且可以知道这条指令后面是否需要跟随参数，以及参数应当如何理解。我们知道一个u1数据类型的取值范围为0x00~0xFF，对应十进制的0~255，也就是一共可以表达256条指令，目前，Java虚拟机规范已经定义了其中约200条编码值对应的指令含义，编码与指令之间的对应关系可查阅本书的附录B“虚拟机字节码指令表”。

关于code_length，有一件值得注意的事情，虽然它是一个u4类型的长度值，理论上最大值可以达到 $2^{32}-1$ ，但是虚拟机规范中明确限制了一个方法不允许超过65535条字节码指令，即它实际只使用了u2的长度，如果超过这个限制，Javac编译器也会拒绝编译。一般来讲，编写Java代码时只要不是刻意去编写一个超长的方法来为难编译

器，是不太可能超过这个最大值的限制。但是，某些特殊情况，例如在编译一个很复杂的JSP文件时，某些JSP编译器会把JSP内容和页面输出的信息归并于一个方法之中，就可能因为方法生成字节码超长的原因而导致编译失败。

Code属性是Class文件中最重要的一个属性，如果把一个Java程序中的信息分为代码（Code，方法体里面的Java代码）和元数据（Metadata，包括类、字段、方法定义及其他信息）两部分，那么在整个Class文件中，Code属性用于描述代码，所有的其他数据项目都用于描述元数据。了解Code属性是学习后面关于字节码执行引擎内容的必要基础，能直接阅读字节码也是工作中分析Java代码语义问题的必要工具和基本技能，因此笔者准备了一个比较详细的实例来讲解虚拟机是

如何使用这个属性的。

继续以代码清单6-1的TestClass.class文件为例，如图6-10所示，这是上一节分析过的实例构造器“<init>”方法的Code属性。它的操作数栈的最大深度和本地变量表的容量都为0x0001，字节码区域所占空间的长度为0x0005。虚拟机读取到字节码区域的长度后，按照顺序依次读入紧随的5个字节，并根据字节码指令表翻译出所对应的字节码指令。翻译“2A B7 00 0A B1”的过程为：

1) 读入2A，查表得0x2A对应的指令为aload_0，这个指令的含义是将第0个Slot中为reference类型的本地变量推送到操作数栈顶。

2) 读入B7，查表得0xB7对应的指令为invokespecial，这条指令的作用是以栈顶的

reference类型的数据所指向的对象作为方法接收者，调用此对象的实例构造器方法、private方法或者它的父类的方法。这个方法有一个u2类型的参数说明具体调用哪一个方法，它指向常量池中的一个CONSTANT_Methodref_info类型常量，即此方法的方法符号引用。

3) 读入00 0A，这是invokespecial的参数，查常量池得0x000A对应的常量为实例构造器“<init>”方法的符号引用。

4) 读入B1，查表得0xB1对应的指令为return，含义是返回此方法，并且返回值为void。这条指令执行后，当前方法结束。

| | | | |
|----------|-------------------------|-------------------------|---------------|
| 000000F0 | 21 00 01 00 03 00 00 00 | 01 00 02 00 05 00 06 00 | !..... |
| 00000100 | 00 00 02 00 01 00 07 00 | 08 00 01 00 09 00 00 00 | |
| 00000110 | 2F 00 01 00 01 00 00 00 | 05 2A B7 00 0A B1 00 00 | /.....*?..±.. |
| 00000120 | 00 02 00 0C 00 00 00 06 | 00 01 00 00 00 03 00 0D | |

max_stack code_length code
 max_locals

图 6-10 Code属性结构实例

这段字节码虽然很短，但是至少可以看出它的执行过程中的数据交换、方法调用等操作都是基于栈（操作栈）的。我们可以初步猜测：Java虚拟机执行字节码是基于栈的体系结构。但是与一般基于堆栈的零字节指令又不太一样，某些指令（如invokespecial）后面还会带有参数，关于虚拟机字节码执行的讲解是后面两章的重点，我们不妨把这里的疑问放到第8章去解决。

我们再次使用javap命令把此Class文件中的另外一个方法的字节码指令也计算出来，结果如

代码清单6-4所示。

代码清单6-4 用javap命令计算字节码指令

```
//原始Java代码
public class TestClass{
private int m;
public int inc () {
return m+1;
}
}
C: \>javap-verbose TestClass
//常量表部分的输出见代码清单6-1，因版面原因这里省略
掉
{
public org.fenixsoft.clazz.TestClass ();
Code:
Stack=1, Locals=1, Args_size=1
0: aload_0
1: invokespecial#10; //Method
java/lang/Object."<init>": () V
4: return
LineNumberTable:
line 3: 0
LocalVariableTable:
Start Length Slot Name Signature
0 5 0 this Lorg/fenixsoft/clazz/TestClass;
public int inc ();
Code:
Stack=2, Locals=1, Args_size=1
0: aload_0
```

```
1: getfield#18; //Field m: I
4:  iconst_1
5:  iadd
6:  ireturn
LineNumberTable:
line 8: 0
LocalVariableTable:
Start Length Slot Name Signature
0 7 0 this Lorg/fenixsoft/clazz/TestClass;
}
```

如果大家注意到javap中输出的“Args_size”的值，可能会有疑问：这个类有两个方法——实例构造器<init>（）和inc（），这两个方法很明显都是没有参数的，为什么Args_size会为1？而且无论是在参数列表里还是方法体内，都没有定义任何局部变量，那Locals又为什么会等于1？如果有这样的疑问，大家可能是忽略了一点：在任何实例方法里面，都可以通过“this”关键字访问到此方法所属的对象。这个访问机制对Java程序的编写很重要，而它的实现却非常简单，仅仅是通

过Javac编译器编译的时候把对this关键字的访问转变为对一个普通方法参数的访问，然后在虚拟机调用实例方法时自动传入此参数而已。因此在实例方法的局部变量表中至少会存在一个指向当前对象实例的局部变量，局部变量表中也会预留出第一个Slot位来存放对象实例的引用，方法参数值从1开始计算。这个处理只对实例方法有效，如果代码清单6-1中的inc（）方法声明为static，那Args_size就不会等于1而是等于0了。

在字节码指令之后的是这个方法的显式异常处理表（下文简称异常表）集合，异常表对于Code属性来说并不是必须存在的，如代码清单6-4中就没有异常表生成。

异常表的格式如表6-16所示，它包含4个字

段，这些字段的含义为：如果当字节码在第start_pc行^[1]到第end_pc行之间（不含第end_pc行）出现了类型为catch_type或者其子类的异常（catch_type为指向一个CONSTANT_Class_info型常量的索引），则转到第handler_pc行继续处理。当catch_type的值为0时，代表任意异常情况都需要转向到handler_pc处进行处理。

表 6-16 属性表结构

| 类 型 | 名 称 | 数 量 | 类 型 | 名 称 | 数 量 |
|-----|----------|-----|-----|------------|-----|
| u2 | start_pc | 1 | u2 | handler_pc | 1 |
| u2 | end_pc | 1 | u2 | catch_type | 1 |

异常表实际上是Java代码的一部分，编译器使用异常表而不是简单的跳转命令来实现Java异常及finally处理机制^[2]。

代码清单6-5是一段演示异常表如何运作的例子，这段代码主要演示了在字节码层面中try-

catch-finally是如何实现的。在阅读字节码之前，大家不妨先看看下面的Java源码，想一下这段代码的返回值在出现异常和不出现异常的情况下分别应该是多少？

代码清单6-5 异常表达作演示

```
//Java源码
public int inc () {
    int x;
    try{
        x=1;
        return x;
    }catch (Exception e) {
        x=2;
        return x;
    }finally{
        x=3;
    }
}
//编译后的ByteCode字节码及异常表
public int inc ();
Code:
Stack=1, Locals=5, Args_size=1
0:  iconst_1 //try块中的x=1
1:  istore_1
2:  iload_1 //保存x到returnValue中, 此时x=1
```

```
3: istore 4
5: iconst_3//finally块中的x=3
6: istore_1
7: iload 4//将returnValue中的值放到栈顶，准备给
ireturn返回
9: ireturn
10: astore_2//给catch中定义的Exception e赋值,
存储在Slot 2中
11: iconst_2//catch块中的x=2
12: istore_1
13: iload_1//保存x到returnValue中，此时x=2
14: istore 4
16: iconst_3//finally块中的x=3
17: istore_1
18: iload 4//将returnValue中的值放到栈顶，准备给
ireturn返回
20: ireturn
21: astore_3//如果出现了不属于
java.lang.Exception及其子类的异常才会走到这里
22: iconst_3//finally块中的x=3
23: istore_1
24: aload_3//将异常放置到栈顶，并抛出
25: athrow
Exception table:
from to target type
0 5 10 Class java/lang/Exception
0 5 21 any
10 16 21 any
```

编译器为这段Java源码生成了3条异常表记录，对应3条可能出现的代码执行路径。从Java代

码的语义上讲，这3条执行路径分别为：

如果try语句块中出现属于Exception或其子类的异常，则转到catch语句块处理。

如果try语句块中出现不属于Exception或其子类的异常，则转到finally语句块处理。

如果catch语句块中出现任何异常，则转到finally语句块处理。

返回到我们上面提出的问题，这段代码的返回值应该是多少？对Java语言熟悉的读者应该很容易说出答案：如果没有出现异常，返回值是1；如果出现了Exception异常，返回值是2；如果出现了Exception以外的异常，方法非正常退出，没有返回值。我们一起来分析一下字节码的执行

过程，从字节码的层面上看看为何会有这样的返回结果。

字节码中第0~4行所做的操作就是将整数1赋值给变量x，并且将此时x的值复制一份副本到最后一个本地变量表的Slot中（这个Slot里面的值在ireturn指令执行前将会被重新读到操作栈顶，作为方法返回值使用。为了讲解方便，笔者给这个Slot起了个名字：returnValue）。如果这时没有出现异常，则会继续走到第5~9行，将变量x赋值为3，然后将之前保存在returnValue中的整数1读入到操作栈顶，最后ireturn指令会以int形式返回操作栈顶中的值，方法结束。如果出现了异常，PC寄存器指针转到第10行，第10~20行所做的事情是将2赋值给变量x，然后将变量x此时的值赋给returnValue，最后再将变量x的值改为3。

方法返回前同样将returnValue中保留的整数2读到了操作栈顶。从第21行开始的代码，作用是变量x的值赋为3，并将栈顶的异常抛出，方法结束。

尽管大家都知道这段代码出现异常的概率非常小，但并不影响它为我们演示异常表的作用。如果大家到这里仍然对字节码的运作过程比较模糊，其实也不要紧，关于虚拟机执行字节码的过程，本书第8章中将会有更详细的讲解。

2.Exceptions属性

这里的Exceptions属性是在方法表中与Code属性平级的一项属性，读者不要与前面刚刚讲解完的异常表产生混淆。Exceptions属性的作用是列举出方法中可能抛出的受查异常（Checked Exceptions），也就是方法描述时在throws关键字

后面列举的异常。它的结构见表6-17。

表 6-17 属性表结构

| 类 型 | 名 称 | 数 量 | 类 型 | 名 称 | 数 量 |
|-----|----------------------|-----|-----|-----------------------|----------------------|
| u2 | attribute_name_index | 1 | u2 | number_of_exceptions | 1 |
| u4 | attribute_length | 1 | u2 | exception_index_table | number_of_exceptions |

Exceptions属性中的number_of_exceptions项表示方法可能抛出number_of_exceptions种受查异常，每一种受查异常使用一个exception_index_table项表示，exception_index_table是一个指向常量池中CONSTANT_Class_info型常量的索引，代表了该受查异常的类型。

3.LineNumberTable属性

LineNumberTable属性用于描述Java源码行号与字节码行号（字节码的偏移量）之间的对应关

系。它并不是运行时必需的属性，但默认会生成到Class文件之中，可以在Javac中分别使用-g:none或-g: lines选项来取消或要求生成这项信息。如果选择不生成LineNumberTable属性，对程序运行产生的最主要的影响就是当抛出异常时，堆栈中将不会显示出错的行号，并且在调试程序的时候，也无法按照源码行来设置断点。

LineNumberTable属性的结构见表6-18。

表 6-18 LineNumberTable 属性结构

| 类 型 | 名 称 | 数 量 |
|------------------|--------------------------|--------------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | line_number_table_length | 1 |
| line_number_info | line_number_table | line_number_table_length |

line_number_table是一个数量为line_number_table_length、类型为line_number_info的集合，line_number_info表包括了start_pc和line_number两个u2类型的数据项，前者是字节码

行号，后者是Java源码行号。

4.LocalVariableTable属性

LocalVariableTable属性用于描述栈帧中局部变量表中的变量与Java源码中定义的变量之间的关系，它也不是运行时必需的属性，但默认会生成到Class文件之中，可以在Javac中分别使用-g:none或-g: vars选项来取消或要求生成这项信息。如果没有生成这项属性，最大的影响就是当其他人引用这个方法时，所有的参数名称都将会丢失，IDE将会使用诸如arg0、arg1之类的占位符代替原有的参数名，这对程序运行没有影响，但是会对代码编写带来较大不便，而且在调试期间无法根据参数名称从上下文中获得参数值。

LocalVariableTable属性的结构见表6-19。

表 6-19 LocalVariableTable 属性结构

| 类 型 | 名 称 | 数 量 |
|---------------------|-----------------------------|-----------------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | local_variable_table_length | 1 |
| local_variable_info | local_variable_table | local_variable_table_length |

其中，local_variable_info项目代表了一个栈帧与源码中的局部变量的关联，结构见表6-20。

表 6-20 local_variable_info 项目结构

| 类 型 | 名 称 | 数 量 |
|-----|------------------|-----|
| u2 | start_pc | 1 |
| u2 | length | 1 |
| u2 | name_index | 1 |
| u2 | descriptor_index | 1 |
| u2 | index | 1 |

start_pc和length属性分别代表了这个局部变量的生命周期开始的字节码偏移量及其作用范围覆盖的长度，两者结合起来就是这个局部变量在字节码之中的作用域范围。

name_index和descriptor_index都是指向常量池中CONSTANT_Utf8_info型常量的索引，分别代

表了局部变量的名称以及这个局部变量的描述符。

index是这个局部变量在栈帧局部变量表中Slot的位置。当这个变量数据类型是64位类型时（double和long），它占用的Slot为index和index+1两个。

顺便提一下，在JDK 1.5引入泛型之后，LocalVariableTable属性增加了一个“姐妹属性”：LocalVariableTypeTable，这个新增的属性结构与LocalVariableTable非常相似，仅仅是把记录的字段描述符的descriptor_index替换成了字段的特征签名（Signature），对于非泛型类型来说，描述符和特征签名能描述的信息是基本一致的，但是泛型引入之后，由于描述符中泛型的参数化类型

被擦除掉^[3]，描述符就不能准确地描述泛型类型了，因此出现了LocalVariableTypeTable。

5.SourceFile属性

SourceFile属性用于记录生成这个Class文件的源码文件名称。这个属性也是可选的，可以分别使用Javac的-g: none或-g: source选项来关闭或要求生成这项信息。在Java中，对于大多数的类来说，类名和文件名是一致的，但是有一些特殊情况（如内部类）例外。如果不生成这项属性，当抛出异常时，堆栈中将不会显示出错代码所属的文件名。这个属性是一个定长的属性，其结构见表6-21。

表 6-21 SourceFile 属性结构

| 类 型 | 名 称 | 数 量 |
|-----|----------------------|-----|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | sourcefile_index | 1 |

sourcefile_index数据项是指向常量池中CONSTANT_Utf8_info型常量的索引，常量值是源码文件的文件名。

6.ConstantValue属性

ConstantValue属性的作用是通知虚拟机自动为静态变量赋值。只有被static关键字修饰的变量（类变量）才可以使用这项属性。类似“int x=123”和“static int x=123”这样的变量定义在Java程序中是非常常见的事情，但虚拟机对这两种变量赋值的方式和时刻都有所不同。对于非static类型的变量（也就是实例变量）的赋值是在实例构

造器<init>方法中进行的；而对于类变量，则有两种方式可以选择：在类构造器<clinit>方法中或者使用ConstantValue属性。目前Sun Javac编译器的选择是：如果同时使用final和static来修饰一个变量（按照习惯，这里称“常量”更贴切），并且这个变量的数据类型是基本类型或者java.lang.String的话，就生成ConstantValue属性来进行初始化，如果这个变量没有被final修饰，或者并非基本类型及字符串，则将会选择在<clinit>方法中进行初始化。

虽然有final关键字才更符合“ConstantValue”的语义，但虚拟机规范中并没有强制要求字段必须设置了ACC_FINAL标志，只要求了有ConstantValue属性的字段必须设置ACC_STATIC标志而已，对final关键字的要求是Javac编译器自己

加入的限制。而对ConstantValue的属性值只能限于基本类型和String，不过笔者不认为这是什么限制，因为此属性的属性值只是一个常量池的索引号，由于Class文件格式的常量类型中只有与基本属性和字符串相对应的字面量，所以就算ConstantValue属性想支持别的类型也无能为力。ConstantValue属性的结构见表6-22。

表 6-22 ConstantValue 属性结构

| 类 型 | 名 称 | 数 量 |
|-----|----------------------|-----|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | constantvalue_index | 1 |

从数据结构中可以看出，ConstantValue属性是一个定长属性，它的attribute_length数据项值必须固定为2。constantvalue_index数据项代表了常量池中一个字面量常量的引用，根据字段类型的不同，字面量可以是CONSTANT_Long_info、

CONSTANT_Float_info、
CONSTANT_Double_info、
CONSTANT_Integer_info、CONSTANT_String_info
常量中的一种。

7.InnerClasses属性

InnerClasses属性用于记录内部类与宿主类之间的关联。如果一个类中定义了内部类，那编译器将会为它以及它所包含的内部类生成
InnerClasses属性。该属性的结构见表6-23。

表 6-23 InnerClasses 属性结构

| 类 型 | 名 称 | 数 量 |
|--------------------|----------------------|-------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | number_of_classes | 1 |
| inner_classes_info | inner_classes | number_of_classes |

数据项number_of_classes代表需要记录多少个内部类信息，每一个内部类的信息都由一个

inner_classes_info表进行描述。inner_classes_info表的结构见表6-24。

表 6-24 inner_classes_info 表的结构

| 类 型 | 名 称 | 数 量 |
|-----|--------------------------|-----|
| u2 | inner_class_info_index | 1 |
| u2 | outer_class_info_index | 1 |
| u2 | inner_name_index | 1 |
| u2 | inner_class_access_flags | 1 |

inner_class_info_index和outer_class_info_index都是指向常量池中CONSTANT_Class_info型常量的索引，分别代表了内部类和宿主类的符号引用。

inner_name_index是指向常量池中CONSTANT_Utf8_info型常量的索引，代表这个内部类的名称，如果是匿名内部类，那么这项值为0。

inner_class_access_flags是内部类的访问标

志，类似于类的access_flags，它的取值范围见表6-25。

表 6-25 inner_class_access_flags 标志

| 标志名称 | 标 志 值 | 含 义 |
|----------------|--------|---------------------|
| ACC_PUBLIC | 0x0001 | 内部类是否为 public |
| ACC_PRIVATE | 0x0002 | 内部类是否为 private |
| ACC_PROTECTED | 0x0004 | 内部类是否为 protected |
| ACC_STATIC | 0x0008 | 内部类是否为 static |
| ACC_FINAL | 0x0010 | 内部类是否为 final |
| ACC_INTERFACE | 0x0020 | 内部类是否为 synchronized |
| ACC_ABSTRACT | 0x0400 | 内部类是否为 abstract |
| ACC_SYNTHETIC | 0x1000 | 内部类是否并非由用户代码产生的 |
| ACC_ANNOTATION | 0x2000 | 内部类是否是一个注解 |
| ACC_ENUM | 0x4000 | 内部类是否是一个枚举 |

8.Deprecated及Synthetic属性

Deprecated和Synthetic两个属性都属于标志类型的布尔属性，只存在有和没有的区别，没有属性值的概念。

Deprecated属性用于表示某个类、字段或者方法，已经被程序作者定为不再推荐使用，它可以通过在代码中使用@deprecated注释进行设置。

Synthetic属性代表此字段或者方法并不是由Java源码直接产生的，而是由编译器自行添加的，在JDK 1.5之后，标识一个类、字段或者方法是编译器自动产生的，也可以设置它们访问标志中的ACC_SYNTHETIC标志位，其中最典型的例子就是Bridge Method。所有由非用户代码产生的类、方法及字段都应当至少设置Synthetic属性和ACC_SYNTHETIC标志位中的一项，唯一的例外是实例构造器“<init>”方法和类构造器“<clinit>”方法。

Deprecated和Synthetic属性的结构非常简单，见表6-26。

表 6-26 Deprecated 及 Synthetic 属性的结构

| 类 型 | 名 称 | 数 量 |
|-----|----------------------|-----|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |

其中attribute_length数据项的值必须为0x00000000，因为没有任何属性值需要设置。

9.StackMapTable属性

StackMapTable属性在JDK 1.6发布后增加到了Class文件规范中，它是一个复杂的变长属性，位于Code属性的属性表中。这个属性会在虚拟机类加载的字节码验证阶段被新类型检查验证器（Type Checker）使用（见7.3.2节），目的在于代替以前比较消耗性能的基于数据流分析的类型推导验证器。

这个类型检查验证器最初来源于Sheng Liang（听名字似乎是虚拟机团队中的华裔成员）为Java ME CLDC实现的字节码验证器。新的验证器在同样能保证Class文件合法性的前提下，省略

了在运行期通过数据流分析去确认字节码的行为逻辑合法性的步骤，而是在编译阶段将一系列的验证类型（Verification Types）直接记录在Class文件之中，通过检查这些验证类型代替了类型推导过程，从而大幅提升了字节码验证的性能。这个验证器在JDK 1.6中首次提供，并在JDK 1.7中强制代替原本基于类型推断的字节码验证器。关于这个验证器的工作原理，《Java虚拟机规范（Java SE 7版）》花费了整整120页的篇幅来讲解描述，并且分析证明新验证方法的严谨性，笔者在此不再赘述。

StackMapTable属性中包含零至多个栈映射帧（Stack Map Frames），每个栈映射帧都显式或隐式地代表了一个字节码偏移量，用于表示该执行到该字节码时局部变量表和操作数栈的验证类

型。类型检查验证器会通过检查目标方法的局部变量和操作数栈所需要的类型来确定一段字节码指令是否符合逻辑约束。StackMapTable属性的结构见表6-27。

表 6-27 StackMapTable 属性的结构

| 类 型 | 名 称 | 数 量 |
|-----------------|-------------------------|-------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | number_of_entries | 1 |
| stack_map_frame | stack_map_frame_entries | number_of_entries |

《Java虚拟机规范（Java SE 7版）》明确规定：在版本号大于或等于50.0的Class文件中，如果方法的Code属性中没有附带StackMapTable属性，那就意味着它带有一个隐式的StackMap属性。这个StackMap属性的作用等同于number_of_entries值为0的StackMapTable属性。一个方法的Code属性最多只能有一个StackMapTable属性，否则将抛出ClassFormatError异常。

10.Signature属性

Signature属性在JDK 1.5发布后增加到了Class文件规范之中，它是一个可选的定长属性，可以出现于类、属性表和方法表结构的属性表中。在JDK 1.5中大幅增强了Java语言的语法，在此之后，任何类、接口、初始化方法或成员的泛型签名如果包含了类型变量（Type Variables）或参数化类型（Parameterized Types），则Signature属性会为它记录泛型签名信息。之所以要专门使用这样一个属性去记录泛型类型，是因为Java语言的泛型采用的是擦除法实现的伪泛型，在字节码（Code属性）中，泛型信息编译（类型变量、参数化类型）之后都通通被擦除掉。使用擦除法的好处是实现简单（主要修改Javac编译器，虚拟机内部只做了很少的改动）、非常容易实现。

Backport，运行期也能够节省一些类型所占的内存空间。但坏处是运行期就无法像C#等有真泛型支持的语言那样，将泛型类型与用户定义的普通类型同等对待，例如运行期做反射时无法获得到泛型信息。Signature属性就是为了弥补这个缺陷而增设的，现在Java的反射API能够获取泛型类型，最终的数据来源也就是这个属性。关于Java泛型、Signature属性和类型擦除，在第10章介绍编译器优化的时候会通过一个具体的例子来讲解。Signature属性的结构见表6-28。

表 6-28 Signature 属性的结构

| 类 型 | 名 称 | 数 量 |
|-----|----------------------|-----|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | signature_index | 1 |

其中signature_index项的值必须是一个对常量池的有效索引。常量池在该索引处的项必须是

CONSTANT_Utf8_info结构，表示类签名、方法类型签名或字段类型签名。如果当前的Signature属性是类文件的属性，则这个结构表示类签名，如果当前的Signature属性是方法表的属性，则这个结构表示方法类型签名，如果当前Signature属性是字段表的属性，则这个结构表示字段类型签名。

11.BootstrapMethods属性

BootstrapMethods属性在JDK 1.7发布后增加到了Class文件规范之中，它是一个复杂的变长属性，位于类文件的属性表中。这个属性用于保存invokedynamic指令引用的引导方法限定符。

《Java虚拟机规范（Java SE 7版）》规定，如果某个类文件结构的常量池中曾经出现过

CONSTANT_InvokeDynamic_info类型的常量，那么这个类文件的属性表中必须存在一个明确的BootstrapMethods属性，另外，即使CONSTANT_InvokeDynamic_info类型的常量在常量池中出现过多次，类文件的属性表中最多也只能有一个BootstrapMethods属性。

BootstrapMethods属性与JSR-292中的InvokeDynamic指令和java.lang.Invoke包关系非常密切，要介绍这个属性的作用，必须先弄清楚InvokeDynamic指令的运作原理，笔者将在第8章专门用1节篇幅去介绍它们，在此先暂时略过。

目前的Javac暂时无法生成InvokeDynamic指令和BootstrapMethods属性，必须通过一些非常规的手段才能使用到它们，也许在不久的将来，等JSR-292更加成熟一些，这种状况就会改变。

BootstrapMethods属性的结构见表6-29。

表 6-29 BootstrapMethods 属性的结构

| 类 型 | 名 称 | 数 量 |
|------------------|-----------------------|-----------------------|
| u2 | attribute_name_index | 1 |
| u4 | attribute_length | 1 |
| u2 | num_bootstrap_methods | 1 |
| bootstrap_method | bootstrap_methods | num_bootstrap_methods |

其中引用到的bootstrap_method结构见表6-30。

表 6-30 bootstrap_method 属性的结构

| 类 型 | 名 称 | 数 量 |
|-----|-------------------------|-------------------------|
| u2 | bootstrap_method_ref | 1 |
| u2 | num_bootstrap_arguments | 1 |
| u2 | bootstrap_arguments | num_bootstrap_arguments |

BootstrapMethods属性中，
num_bootstrap_methods项的值给出了
bootstrap_methods[]数组中的引导方法限定符的数
量。而bootstrap_methods[]数组的每个成员包含了一
个指向常量池CONSTANT_MethodHandle结构
的索引值，它代表了一个引导方法，还包含了这

个引导方法静态参数的序列（可能为空）。

bootstrap_methods[]数组中的每个成员必须包含以下3项内容。

bootstrap_method_ref: bootstrap_method_ref项的值必须是一个对常量池的有效索引。常量池在该索引处的值必须是一个CONSTANT_MethodHandle_info结构。

num_bootstrap_arguments:
num_bootstrap_arguments项的值给出了bootstrap_arguments[]数组成员的数量。

bootstrap_arguments[]: bootstrap_arguments[]数组的每个成员必须是一个对常量池的有效索引。常量池在该索引处必须是下列结构之一：
CONSTANT_String_info、

CONSTANT_Class_info、
CONSTANT_Integer_info、
CONSTANT_Long_info、CONSTANT_Float_info、
CONSTANT_Double_info、
CONSTANT_MethodHandle_info或
CONSTANT_MethodType_info。

[1]此处字节码的“行”是一种形象的描述，指的是字节码相对于方法体开始的偏移量，而不是Java源码的行号，下同。

[2]在JDK1.4.2之前的Javac编译器采用了jsr和ret指令实现finally语句，但1.4.2之后已经改为编译器自动在每段可能的分支路径之后都将finally语句块的内容冗余生成一遍来实现finally语义。在JDK 1.7中，已经完全禁止Class文件中出现jsr和ret指令，如果遇到这两条指令，虚拟机会在类加载的字节

码校验阶段抛出异常。

[3]详见第10章中关于语法糖部分的内容。

6.4 字节码指令简介

Java虚拟机的指令由一个字节长度的、代表着某种特定操作含义的数字（称为操作码，Opcode）以及跟随其后的零至多个代表此操作所需参数（称为操作数，Operands）而构成。由于Java虚拟机采用面向操作数栈而不是寄存器的架构（这两种架构的区别和影响将在第8章中探讨），所以大多数的指令都不包含操作数，只有一个操作码。

字节码指令集是一种具有鲜明特点、优劣势都很突出的指令集架构，由于限制了Java虚拟机操作码的长度为一个字节（即0~255），这意味着指令集的操作码总数不可能超过256条；又由

于Class文件格式放弃了编译后代码的操作数长度对齐，这就意味着虚拟机处理那些超过一个字节数据的时候，不得不在运行时从字节中重建出具体数据的结构，如果要将一个16位长度的无符号整数使用两个无符号字节存储起来（将它们命名为byte1和byte2），那它们的值应该是这样的：

(byte1<<8) | byte2

这种操作在某种程度上会导致解释执行字节码时损失一些性能。但这样做的优势也非常明显，放弃了操作数长度对齐^[1]，就意味着可以省略很多填充和间隔符号；用一个字节来代表操作码，也是为了尽可能获得短小精干的编译代码。这种追求尽可能小数据量、高传输效率的设计是由Java语言设计之初面向网络、智能家电的技术

背景所决定的，并一直沿用至今。

如果不考虑异常处理的话，那么Java虚拟机的解释器可以使用下面这个伪代码当做最基本的执行模型来理解，这个执行模型虽然很简单，但依然可以有效地工作：

```
do {
    自动计算PC寄存器的值加1;
    根据PC寄存器的指示位置，从字节码流中取出操作码;
    if (字节码存在操作数) 从字节码流中取出操作数;
    执行操作码所定义的操作;
} while (字节码流长度>0);
```

6.4.1 字节码与数据类型

在Java虚拟机的指令集中，大多数的指令都包含了其操作所对应的数据类型信息。例如，`iload`指令用于从局部变量表中加载int型的数据到

操作数栈中，而float指令加载的则是float类型的数据。这两条指令的操作在虚拟机内部可能会是由同一段代码来实现的，但在Class文件中它们必须拥有各自独立的操作码。

对于大部分与数据类型相关的字节码指令，它们的操作码助记符中都有特殊的字符来表明专门为哪种数据类型服务：i代表对int类型的数据操作，l代表long,s代表short,b代表byte,c代表char,f代表float,d代表double,a代表reference。也有一些指令的助记符中没有明确地指明操作类型的字母，如arraylength指令，它没有代表数据类型的特殊字符，但操作数永远只能是一个数组类型的对象。还有另外一些指令，如无条件跳转指令goto则是与数据类型无关的。

由于Java虚拟机的操作码长度只有一个字节，所以包含了数据类型的操作码就为指令集的设计带来了很大的压力：如果每一种与数据类型相关的指令都支持Java虚拟机所有运行时数据类型的话，那指令的数量恐怕就会超出一个字节所能表示的数量范围了。因此，Java虚拟机的指令集对于特定的操作只提供了有限的类型相关指令去支持它，换句话说，指令集将会故意被设计成非完全独立的（Java虚拟机规范中把这种特性称为“Not Orthogonal”，即并非每种数据类型和每一种操作都有对应的指令）。有一些单独的指令可以在必要的时候用来将一些不支持的类型转换为可被支持的类型。

表6-31列举了Java虚拟机所支持的与数据类型相关的字节码指令，通过使用数据类型列所代

表的特殊字符替换opcode列的指令模板中的T，就可以得到一个具体的字节码指令。如果在表中指令模板与数据类型两列共同确定的格为空，则说明虚拟机不支持对这种数据类型执行这项操作。例如，load指令有操作int类型的iload，但是没有操作byte类型的同类指令。

注意，从表6-31中可以看出，大部分的指令都没有支持整数类型byte、char和short，甚至没有任何指令支持boolean类型。编译器会在编译期或运行期将byte和short类型的数据带符号扩展（Sign-Extend）为相应的int类型数据，将boolean和char类型数据零位扩展（Zero-Extend）为相应的int类型数据。与之类似，在处理boolean、byte、short和char类型的数组时，也会转换为使用对应的int类型的字节码指令来处理。因此，大多

数对于boolean、byte、short和char类型数据的操作，实际上都是使用相应的int类型作为运算类型（Computational Type）。

表 6-31 Java 虚拟机指令集所支持的数据类型

| opcode | byte | short | int | long | float | double | char | reference |
|--------|--------|--------|--------|--------|--------|--------|------|-----------|
| Tpush | bipush | sipush | | | | | | |
| Tconst | | | iconst | lconst | fconst | dconst | | aconst |
| Tload | | | iload | lload | fload | dload | | aload |

| opcode | byte | short | int | long | float | double | char | reference |
|-----------|---------|---------|-----------|---------|---------|---------|---------|-----------|
| Tstore | | | istore | lstore | fstore | dstore | | astore |
| Tinc | | | iinc | | | | | |
| Taload | baload | saload | iaload | laload | faload | daload | caload | aaload |
| Tastore | bastore | sastore | iastore | lastore | fastore | dastore | castore | aastore |
| Tadd | | | iadd | ladd | fadd | dadd | | |
| Tsub | | | isub | lsub | fsub | dsub | | |
| Tmul | | | imul | lmul | fmul | dmul | | |
| Tdiv | | | idiv | ldiv | fdiv | ddiv | | |
| Trem | | | irem | lrem | frem | drem | | |
| Tneg | | | ineg | lneg | fneg | dneg | | |
| Tshl | | | ishl | lshl | | | | |
| Tshr | | | ishr | lshr | | | | |
| Tushr | | | iushr | lushr | | | | |
| Tand | | | iand | land | | | | |
| Tor | | | ior | lor | | | | |
| Txor | | | ixor | lxor | | | | |
| i2T | i2b | i2s | | i2l | i2f | i2d | | |
| l2T | | | l2i | | l2f | l2d | | |
| f2T | | | f2i | f2l | | f2d | | |
| d2T | | | d2i | d2l | d2f | | | |
| Tcmp | | | | lcmp | | | | |
| Templ | | | | | fcmpl | dcmpl | | |
| Tcmpg | | | | | fcmpg | dcmpg | | |
| if_TempOP | | | if_icmpOP | | | | | if_acmpOP |
| Treturn | | | ireturn | lreturn | freturn | dreturn | | areturn |

在本章中，受篇幅所限，无法对字节码指令集中每条指令进行逐一讲解，但阅读字节码作为了解Java虚拟机的基础技能，是一项应当熟练掌握的能力。笔者将字节码操作按用途大致分为9

类，按照分类来为读者概略介绍一下这些指令的用法。如果读者需要了解更详细的信息，可以参考阅读笔者翻译的《Java虚拟机规范（Java SE 7 版）》的第6章。

[1]字节码指令流基本上都是单字节对齐的，只有“tableswitch”和“lookupswitch”两条指令例外，由于它们的操作数比较特殊，是以4字节为界划分开的，所以这两条指令也需要预留出相应的空位进行填充来实现对齐。

6.4.2 加载和存储指令

加载和存储指令用于将数据在栈帧中的局部变量表和操作数栈（见第2章关于内存区域的介绍）之间来回传输，这类指令包括如下内容。

将一个局部变量加载到操作栈：`iload`、`iload_<n>`、`lload`、`lload_<n>`、`float`、`float_<n>`、`dload`、`dload_<n>`、`aload`、`aload_<n>`。

将一个数值从操作数栈存储到局部变量表：`istore`、`istore_<n>`、`lstore`、`lstore_<n>`、`fstore`、`fstore_<n>`、`dstore`、`dstore_<n>`、`astore`、`astore_<n>`。

将一个常量加载到操作数栈： bipush、
sipush、 ldc、 ldc_w、 ldc2_w、 aconst_null、
iconst_m1、 iconst_{i}、 lconst_{l}、 fconst_{f}、 dconst_{d}。

扩充局部变量表的访问索引的指令： wide。

存储数据的操作数栈和局部变量表主要就是由加载和存储指令进行操作，除此之外，还有少量指令，如访问对象的字段或数组元素的指令也会向操作数栈传输数据。

上面所列举的指令助记符中，有一部分是以尖括号结尾的（例如 iload_{n}），这些指令助记符实际上是代表了一组指令（例如 iload_{n}，它代表了 iload_0、 iload_1、 iload_2 和 iload_3 这几条指令）。这几组指令都是某个带有一个操

操作数的通用指令（例如`iload`）的特殊形式，对于这若干组特殊指令来说，它们省略掉了显式的操作数，不需要进行取操作数的动作，实际上操作数就隐含在指令中。除了这点之外，它们的语义与原生的通用指令完全一致（例如`iload_0`的语义与操作数为0时的`iload`指令语义完全一致）。这种指令表示方法在本书以及《Java虚拟机规范》中都是通用的。

6.4.3 运算指令

运算或算术指令用于对两个操作数栈上的值进行某种特定运算，并把结果重新存入到操作栈顶。大体上算术指令可以分为两种：对整型数据进行运算的指令与对浮点型数据进行运算的指令，无论是哪种算术指令，都使用Java虚拟机的数据类型，由于没有直接支持byte、short、char和boolean类型的算术指令，对于这类数据的运算，应使用操作int类型的指令代替。整数与浮点数的算术指令在溢出和被零除的时候也有各自不同的行为表现，所有的算术指令如下。

加法指令：iadd、ladd、fadd、dadd。

减法指令： isub、 lsub、 fsub、 dsub。

乘法指令： imul、 lmul、 fmul、 dmul。

除法指令： idiv、 ldiv、 fdiv、 ddiv。

求余指令： irem、 lrem、 frem、 drem。

取反指令： ineg、 lneg、 fneg、 dneg。

位移指令： ishl、 ishr、 iushr、 lshl、 lshr、 lushr。

按位或指令： ior、 lor。

按位与指令： iand、 land。

按位异或指令： ixor、 lxor。

局部变量自增指令： iiinc。

比较指令：dcmpg、dcmpl、fcmpg、fcmpl、lcmp。

Java虚拟机的指令集直接支持了在《Java语言规范》中描述的各种对整数及浮点数操作（参见《Java语言规范（第3版）》中的4.2.2节和4.2.4节）的语义。数据运算可能会导致溢出，例如两个很大的正整数相加，结果可能会是一个负数，这种数学上不可能出现的溢出现象，对于程序员来说是很容易理解的，但其实Java虚拟机规范没有明确定义过整型数据溢出的具体运算结果，仅规定了在处理整型数据时，只有除法指令（idiv和ldiv）以及求余指令（irem和lrem）中当出现除数为零时会导致虚拟机抛出ArithmeticException异常，其余任何整型数运算场景都不应该抛出运行

时异常。

Java虚拟机规范要求虚拟机实现在处理浮点数时，必须严格遵循IEEE 754规范中所规定的行为和限制。也就是说，Java虚拟机必须完全支持IEEE 754中定义的非正规浮点数值

（Denormalized Floating-Point Numbers）和逐级下溢（Gradual Underflow）的运算规则。这些特征将会使某些数值算法处理起来变得相对容易一些。

Java虚拟机要求在进行浮点数运算时，所有的运算结果都必须舍入到适当的精度，非精确的结果必须舍入为可被表示的最接近的精确值，如果有两种可表示的形式与该值一样接近，将优先选择最低有效位为零的。这种舍入模式也是IEEE

754规范中的默认舍入模式，称为向最接近数舍入模式。

在把浮点数转换为整数时，Java虚拟机使用IEEE 754标准中的向零舍入模式，这种模式的舍入结果会导致数字被截断，所有小数部分的有效字节都会被丢弃掉。向零舍入模式将在目标数值类型中选择一个最接近但是不大于原值的数字来作为最精确的舍入结果。

另外，Java虚拟机在处理浮点数运算时，不会抛出任何运行时异常（这里所讲的是Java语言中的异常，请读者勿与IEEE 754规范中的浮点异常互相混淆，IEEE 754的浮点异常是一种运算信号），当一个操作产生溢出时，将会使用有符号的无穷大来表示，如果某个操作结果没有明确的

数学定义的话，将会使用NaN值来表示。所有使用NaN值作为操作数的算术操作，结果都会返回NaN。

在对long类型数值进行比较时，虚拟机采用带符号的比较方式，而对浮点数值进行比较时（`dcmpg`、`dcmpl`、`fcmpg`、`fcmpl`），虚拟机会采用IEEE 754规范所定义的无信号比较（Nonsignaling Comparisons）方式。

6.4.4 类型转换指令

类型转换指令可以将两种不同的数值类型进行相互转换，这些转换操作一般用于实现用户代码中的显式类型转换操作，或者用来处理本节开篇所提到的字节码指令集中数据类型相关指令无法与数据类型一一对应的问题。

Java虚拟机直接支持（即转换时无需显式的转换指令）以下数值类型的宽化类型转换（Widening Numeric Conversions，即小范围类型向大范围类型的安全转换）：

int类型到long、float或者double类型。

long类型到float、double类型。

float类型到double类型。

相对的，处理窄化类型转换（Narrowing Numeric Conversions）时，必须显式地使用转换指令来完成，这些转换指令包括：i2b、i2c、i2s、l2i、f2i、f2l、d2i、d2l和d2f。窄化类型转换可能会导致转换结果产生不同的正负号、不同的数量级的情况，转换过程很可能会导致数值的精度丢失。

在将int或long类型窄化转换为整数类型T的时候，转换过程仅仅是简单地丢弃除最低位N个字节以外的内容，N是类型T的数据类型长度，这将可能导致转换结果与输入值有不同的正负号。这点很容易理解，因为原来符号位处于数值的最高位，高位被丢弃之后，转换结果的符号就取决于

低N个字节的首位了。

在将一个浮点值窄化转换为整数类型T（T限于int或long类型之一）的时候，将遵循以下转换规则：

如果浮点值是NaN，那转换结果就是int或long类型的0。

如果浮点值不是无穷大的话，浮点值使用IEEE 754的向零舍入模式取整，获得整数值v，如果v在目标类型T（int或long）的表示范围之内，那转换结果就是v。

否则，将根据v的符号，转换为T所能表示的最大或者最小正数。

从double类型到float类型的窄化转换过程与

IEEE 754中定义的一致，通过IEEE 754向最接近数舍入模式舍入得到一个可以使用float类型表示的数字。如果转换结果的绝对值太小而无法使用float来表示的话，将返回float类型的正负零。如果转换结果的绝对值太大而无法使用float来表示的话，将返回float类型的正负无穷大，对于double类型的NaN值将按规定转换为float类型的NaN值。

尽管数据类型窄化转换可能会发生上限溢出、下限溢出和精度丢失等情况，但是Java虚拟机规范中明确规定数值类型的窄化转换指令永远不可能导致虚拟机抛出运行时异常。

6.4.5 对象创建与访问指令

虽然类实例和数组都是对象，但Java虚拟机对类实例和数组的创建与操作使用了不同的字节码指令（在第7章会讲到数组和普通类的类型创建过程是不同的）。对象创建后，就可以通过对对象访问指令获取对象实例或者数组实例中的字段或者数组元素，这些指令如下。

创建类实例的指令：new。

创建数组的指令：newarray、anewarray、multianewarray。

访问类字段（static字段，或者称为类变量）和实例字段（非static字段，或者称为实例变量）

的指令：getfield、putfield、getstatic、putstatic。

把一个数组元素加载到操作数栈的指令：

bload、caload、saload、iaload、laload、
faload、daload、aaload。

将一个操作数栈的值存储到数组元素中的指令：
bastore、castore、sastore、iastore、fastore、
dastore、aastore。

取数组长度的指令：arraylength。

检查类实例类型的指令：instanceof、
checkcast。

6.4.6 操作数栈管理指令

如同操作一个普通数据结构中的堆栈那样，Java虚拟机提供了一些用于直接操作操作数栈的指令，包括：

将操作数栈的栈顶一个或两个元素出栈：

pop、pop2。

复制栈顶一个或两个数值并将复制值或双份的复制值重新压入栈顶：dup、dup2、dup_x1、dup2_x1、dup_x2、dup2_x2。

将栈最顶端的两个数值互换：swap。

6.4.7 控制转移指令

控制转移指令可以让Java虚拟机有条件或无条件地从指定的位置指令而不是控制转移指令的下一条指令继续执行程序，从概念模型上理解，可以认为控制转移指令就是在有条件或无条件地修改PC寄存器的值。控制转移指令如下。

条件分支：ifeq、iflt、ifle、ifne、ifgt、ifge、ifnull、ifnonnull、if_icmpeq、if_icmpne、if_icmplt、if_icmpgt、if_icmple、if_icmpge、if_acmpeq和if_acmpne。

复合条件分支：tableswitch、lookupswitch。

无条件分支：goto、goto_w、jsr、jsr_w、

ret。

在Java虚拟机中有专门的指令集用来处理int和reference类型的条件分支比较操作，为了可以无须明显标识一个实体值是否null，也有专门的指令用来检测null值。

与前面算术运算时的规则一致，对于boolean类型、byte类型、char类型和short类型的条件分支比较操作，都是使用int类型的比较指令来完成，而对于long类型、float类型和double类型的条件分支比较操作，则会先执行相应类型的比较运算指令（dcmpg、dcmpl、fcmpg、fcmpl、lcmp，见6.4.3节），运算指令会返回一个整型值到操作数栈中，随后再执行int类型的条件分支比较操作来完成整个分支跳转。由于各种类型的比较最终都

会转化为int类型的比较操作，int类型比较是否方便完善就显得尤为重要，所以Java虚拟机提供的int类型的条件分支指令是最为丰富和强大的。

6.4.8 方法调用和返回指令

方法调用（分派、执行过程）将在第8章具体讲解，这里仅列举以下5条用于方法调用的指令。

`invokevirtual`指令用于调用对象的实例方法，根据对象的实际类型进行分派（虚方法分派），这也是Java语言中最常见的方法分派方式。

`invokeinterface`指令用于调用接口方法，它会在运行时搜索一个实现了这个接口方法的对象，找出适合的方法进行调用。

`invokespecial`指令用于调用一些需要特殊处理的实例方法，包括实例初始化方法、私有方法

和父类方法。

invokestatic指令用于调用类方法（static方法）。

invokedynamic指令用于在运行时动态解析出调用点限定符所引用的方法，并执行该方法，前面4条调用指令的分派逻辑都固化在Java虚拟机内部，而invokedynamic指令的分派逻辑是由用户所设定的引导方法决定的。

方法调用指令与数据类型无关，而方法返回指令是根据返回值的类型区分的，包括ireturn（当返回值是boolean、byte、char、short和int类型时使用）、lreturn、freturn、dreturn和areturn，另外还有一条return指令供声明为void的方法、实例初始化方法以及类和接口的类初始化

方法使用。

6.4.9 异常处理指令

在Java程序中显式抛出异常的操作（`throw`语句）都由`athrow`指令来实现，除了用`throw`语句显式抛出异常情况之外，Java虚拟机规范还规定了许多运行时异常会在其他Java虚拟机指令检测到异常状况时自动抛出。例如，在前面介绍的整数运算中，当除数为零时，虚拟机会在`idiv`或`ldiv`指令中抛出`ArithmaticException`异常。

而在Java虚拟机中，处理异常（`catch`语句）不是由字节码指令来实现的（很久之前曾经使用`jsr`和`ret`指令来实现，现在已经不用了），而是采用异常表来完成的。

6.4.10 同步指令

Java虚拟机可以支持方法级的同步和方法内部一段指令序列的同步，这两种同步结构都是使用管程（Monitor）来支持的。

方法级的同步是隐式的，即无须通过字节码指令来控制，它实现在方法调用和返回操作之中。虚拟机可以从方法常量池的方法表结构中的ACC_SYNCHRONIZED访问标志得知一个方法是否声明为同步方法。当方法调用时，调用指令将会检查方法的ACC_SYNCHRONIZED访问标志是否被设置，如果设置了，执行线程就要求先成功持有管程，然后才能执行方法，最后当方法完成（无论是正常完成还是非正常完成）时释放管

程。在方法执行期间，执行线程持有了管程，其他任何线程都无法再获取到同一个管程。如果一个同步方法执行期间抛出了异常，并且在方法内部无法处理此异常，那么这个同步方法所持有的管程将在异常抛到同步方法之外时自动释放。

同步一段指令集序列通常是由Java语言中的synchronized语句块来表示的，Java虚拟机的指令集中有monitorenter和monitorexit两条指令来支持synchronized关键字的语义，正确实现synchronized关键字需要Javac编译器与Java虚拟机两者共同协作支持，譬如代码清单6-6中所示的代码。

代码清单6-6 代码同步演示

```
void onlyMe (Foo f) {  
    synchronized (f) {  
        doSomething () ;  
    }  
}
```

```
}
```

```
}
```

编译后，这段代码生成的字节码序列如下：

Method void onlyMe (Foo)

0 aload_1//将对象f入栈

1 dup//复制栈顶元素（即f的引用）

2 astore_2//将栈顶元素存储到局部变量表slot 2中

3 monitorenter//以栈顶元素（即f）作为锁，开始同步

4 aload_0//将局部变量slot 0（即this指针）的元素

入栈

5 invokevirtual#5//调用doSomething () 方法

8 aload_2//将局部变量Slow 2的元素（即f）入栈

9 monitorexit//退出同步

10 goto 18//方法正常结束，跳转到18返回

13 astore_3//从这步开始是异常路径，见下面异常表的
Taget 13

14 aload_2//将局部变量Slow 2的元素（即f）入栈

15 monitorexit//退出同步

16 aload_3//将局部变量Slow 3的元素（即异常对象）

入栈

17 athrow//把异常对象重新抛出给onlyMe () 方法的调
用者

18 return//方法正常返回

Exception table:

FromTo Target Type

4 10 13 any

13 16 13 any

编译器必须确保无论方法通过何种方式完成，方法中调用过的每条monitorenter指令都必须执行其对应的monitorexit指令，而无论这个方法是正常结束还是异常结束。

从代码清单6-6的字节码序列中可以看到，为了保证在方法异常完成时monitorenter和monitorexit指令依然可以正确配对执行，编译器会自动产生一个异常处理器，这个异常处理器声明可处理所有的异常，它的目的就是用来执行monitorexit指令。

6.5 公有设计和私有实现

Java虚拟机规范描绘了Java虚拟机应有的共同程序存储格式：Class文件格式以及字节码指令集。这些内容与硬件、操作系统及具体的Java虚拟机实现之间是完全独立的，虚拟机实现者可能更愿意把它们看做是程序在各种Java平台实现之间互相安全地交互的手段。

理解公有设计与私有实现之间的分界线是非常有必要的，Java虚拟机实现必须能够读取Class文件并精确实现包含在其中的Java虚拟机代码的语义。拿着Java虚拟机规范一成不变地逐字实现其中要求的内容当然是一种可行的途径，但一个优秀的虚拟机实现，在满足虚拟机规范的约束下

对具体实现做出修改和优化也是完全可行的，并且虚拟机规范中明确鼓励实现者这样做。只要优化后Class文件依然可以被正确读取，并且包含在其中的语义能得到完整的保持，那实现者就可以选择任何方式去实现这些语义，虚拟机后台如何处理Class文件完全是实现者自己的事情，只要它在外部接口上看起来与规范描述的一致即可^[1]。

虚拟机实现者可以使用这种伸缩性来让Java虚拟机获得更高的性能、更低的内存消耗或者更好的可移植性，选择哪种特性取决于Java虚拟机实现的目标和关注点是什么。虚拟机实现的方式主要有以下两种：

将输入的Java虚拟机代码在加载或执行时翻译成另外一种虚拟机的指令集。

将输入的Java虚拟机代码在加载或执行时翻译成宿主机CPU的本地指令集（即JIT代码生成技术）。

精确定义的虚拟机和目标文件格式不应当对虚拟机实现者的创造性产生太多的限制，Java虚拟机应被设计成可以允许有众多不同的实现，并且各种实现可以在保持兼容性的同时提供不同的、新的、有趣的解决方案。

[1]这里其实多少存在一些例外：譬如调试器（Debuggers）、性能监视器（Profilers）和即时编译器（Just-In-Time Code Generator）等都可能需要访问一些通常认为是“虚拟机后台”的元素。

6.6 Class文件结构的发展

Class文件结构自Java虚拟机规范第1版订立以来，已经有十多年的历史。这十多年间，Java技术体系有了翻天覆地的改变，JDK的版本号已经从1.0提升到了1.7。相对于语言、API以及Java技术体系中其他方面的变化，Class文件结构一直处于比较稳定的状态，Class文件的主体结构、字节码指令的语义和数量几乎没有出现过变动^[1]，所有对Class文件格式的改进，都集中在向访问标志、属性表这些在设计上就可扩展的数据结构中添加内容。

如果以《Java虚拟机规范（第2版）》为基准进行比较的话，那么在后续Class文件格式的发展

过程中，访问标志里新加入了ACC_SYNTHETIC、ACC_ANNOTATION、ACC_ENUM、ACC_BRIDGE、ACC_VARARGS共5个标志。而属性表集合中，在JDK 1.5到JDK 1.7版本之间一共增加了12项新的属性，这些属性大部分用于支持Java中许多新出现的语言特性，如枚举、变长参数、泛型、动态注解等。还有一些是为了支持性能改进和调试信息，譬如JDK 1.6的新类型校验器的StackMapTable属性和对非Java代码调试中用到的SourceDebugExtension属性。

Class文件格式所具备的平台中立（不依赖于特定硬件及操作系统）、紧凑、稳定和可扩展的特点，是Java技术体系实现平台无关、语言无关两项特性的重要支柱。

[1]十余年间，字节码的数量和语义只发生过屈指可数的几次变动，例如，JDK1.0.2时改动过invokespecial指令的语义；JDK 1.7增加了invokedynamic指令，禁止了ret和jsr指令。

6.7 本章小结

Class文件是Java虚拟机执行引擎的数据入口，也是Java技术体系的基础构成之一。了解Class文件的结构对后面进一步了解虚拟机执行引擎有很重要的意义。

本章详细讲解了Class文件结构中的各个组成部分，以及每个部分的定义、数据结构和使用方法。通过代码清单6-1的Java代码与它的Class文件样例，以实战的方式演示了Class的数据是如何存储和访问的。从第7章开始，我们将以动态的、运行时的角度去看看字节码流在虚拟机执行引擎中是怎样被解释执行的。

第7章 虚拟机类加载机制

代码编译的结果从本地机器码转变为字节码，是存储格式发展的一小步，却是编程语言发展的一大步。

7.1 概述

上一章我们了解了Class文件存储格式的具体细节，在Class文件中描述的各种信息，最终都需要加载到虚拟机中之后才能运行和使用。而虚拟机如何加载这些Class文件？Class文件中的信息进入到虚拟机后会发生什么变化？这些都是本章将要讲解的内容。

虚拟机把描述类的数据从Class文件加载到内

存，并对数据进行校验、转换解析和初始化，最终形成可以被虚拟机直接使用的Java类型，这就是虚拟机的类加载机制。

与那些在编译时需要进行连接工作的语言不同，在Java语言里面，类型的加载、连接和初始化过程都是在程序运行期间完成的，这种策略虽然会令类加载时稍微增加一些性能开销，但是会为Java应用程序提供高度的灵活性，Java里天生可以动态扩展的语言特性就是依赖运行期动态加载和动态连接这个特点实现的。例如，如果编写一个面向接口的应用程序，可以等到运行时再指定其实际的实现类；用户可以通过Java预定义的和自定义类加载器，让一个本地的应用程序可以在运行时从网络或其他地方加载一个二进制流作为程序代码的一部分，这种组装应用程序的方式

目前已广泛应用于Java程序之中。从最基础的Applet、JSP到相对复杂的OSGi技术，都使用了Java语言运行期类加载的特性。

为了避免语言表达中可能产生的偏差，在本章正式开始之前，笔者先设立两个语言上的约定：第一，在实际情况中，每个Class文件都有可能代表着Java语言中的一个类或接口，后文中直接对“类”的描述都包括了类和接口的可能性，而对于类和接口需要分开描述的场景会特别指明；第二，与前面介绍Class文件格式时的约定一致，笔者本章所提到的“Class文件”并非特指某个存在于具体磁盘中的文件，这里所说的“Class文件”应当是一串二进制的字节流，无论以何种形式存在都可以。

7.2 类加载的时机

类从被加载到虚拟机内存中开始，到卸载出内存为止，它的整个生命周期包括：加载（Loading）、验证（Verification）、准备（Preparation）、解析（Resolution）、初始化（Initialization）、使用（Using）和卸载（Unloading）7个阶段。其中验证、准备、解析3个部分统称为连接（Linking），这7个阶段的发生顺序如图7-1所示。



图 7-1 类的生命周期

图7-1中，加载、验证、准备、初始化和卸载这5个阶段的顺序是确定的，类的加载过程必须按照这种顺序按部就班地开始，而解析阶段则不一定：它在某些情况下可以在初始化阶段之后再开始，这是为了支持Java语言的运行时绑定（也称为动态绑定或晚期绑定）。注意，这里笔者写的是按部就班地“开始”，而不是按部就班地“进行”或“完成”，强调这点是因为这些阶段通常都是互相交叉地混合式进行的，通常会在一个阶段执行的过程中调用、激活另外一个阶段。

什么情况下需要开始类加载过程的第一个阶段：加载？Java虚拟机规范中并没有进行强制约束，这点可以交给虚拟机的具体实现来自由把

握。但是对于初始化阶段，虚拟机规范则是严格规定了有且只有5种情况必须立即对类进行“初始化”（而加载、验证、准备自然需要在此之前开始）：

1) 遇到new、getstatic、putstatic或

invokestatic这4条字节码指令时，如果类没有进行过初始化，则需要先触发其初始化。生成这4条指令的最常见的Java代码场景是：使用new关键字实例化对象的时候、读取或设置一个类的静态字段（被final修饰、已在编译期把结果放入常量池的静态字段除外）的时候，以及调用一个类的静态方法的时候。

2) 使用java.lang.reflect包的方法对类进行反射调用的时候，如果类没有进行过初始化，则需

要先触发其初始化。

3) 当初始化一个类的时候，如果发现其父类还没有进行过初始化，则需要先触发其父类的初始化。

4) 当虚拟机启动时，用户需要指定一个要执行的主类（包含main（）方法的那个类），虚拟机会先初始化这个主类。

5) 当使用JDK 1.7的动态语言支持时，如果一个java.lang.invoke.MethodHandle实例最后的解析结果REF_getStatic、REF_putStatic、REF_invokeStatic的方法句柄，并且这个方法句柄所对应的类没有进行过初始化，则需要先触发其初始化。

对于这5种会触发类进行初始化的场景，虚拟机规范中使用了一个很强烈的限定语：“有且只有”，这5种场景中的行为称为对一个类进行主动引用。除此之外，所有引用类的方式都不会触发初始化，称为被动引用。下面举3个例子来说明何为被动引用，分别见代码清单7-1～代码清单7-3。

代码清单7-1 被动引用的例子之一

```
package org.fenixsoft.classloading;
/**
 * 被动使用类字段演示一：
 * 通过子类引用父类的静态字段，不会导致子类初始化
 */
public class SuperClass{
    static{
        System.out.println ("SuperClass init! ");
    }
    public static int value=123;
}
public class SubClass extends SuperClass{
    static{
```

```
System.out.println ("SubClass init! ");
}
}
/**
*非主动使用类字段演示
*/
public class NotInitialization{
public static void main (String[]args) {
System.out.println (SubClass.value);
}
}
```

上述代码运行之后，只会输出“SuperClass init! ”，而不会输出“SubClass init! ”。对于静态字段，只有直接定义这个字段的类才会被初始化，因此通过其子类来引用父类中定义的静态字段，只会触发父类的初始化而不会触发子类的初始化。至于是否要触发子类的加载和验证，在虚拟机规范中并未明确规定，这点取决于虚拟机的具体实现。对于Sun HotSpot虚拟机来说，可通过-XX: +TraceClassLoading参数观察到此操作会导

致子类的加载。

代码清单7-2 被动引用的例子之二

```
package org.fenixsoft.classloading;
/**
 *被动使用类字段演示二：
 *通过数组定义来引用类，不会触发此类的初始化
 */
public class NotInitialization{
    public static void main (String[] args) {
        SuperClass []sca=new SuperClass[10];
    }
}
```

为了节省版面，这段代码复用了代码清单7-1中的SuperClass，运行之后发现没有输出“SuperClass init！”，说明并没有触发类org.fenixsoft.classloading.SuperClass的初始化阶段。但是这段代码里面触发了另外一个是为“[org.fenixsoft.classloading.SuperClass”的类的

初始化阶段，对于用户代码来说，这并不是一个合法的类名称，它是一个由虚拟机自动生成的、直接继承于java.lang.Object的子类，创建动作由字节码指令newarray触发。

这个类代表了一个元素类型为org.fenixsoft.classloading.SuperClass的一维数组，数组中应有的属性和方法（用户可直接使用的只有被修饰为public的length属性和clone（）方法）都实现在这个类里。Java语言中对数组的访问比C/C++相对安全是因为这个类封装了数组元素的访问方法^[1]，而C/C++直接翻译为对数组指针的移动。在Java语言中，当检查到发生数组越界时会抛出java.lang.ArrayIndexOutOfBoundsException异常。

代码清单7-3 被动引用的例子之三

```
package org.fenixsoft.classloading;
/**
 * 被动使用类字段演示三：
 * 常量在编译阶段会存入调用类的常量池中，本质上并没有
直接引用到定义常量的类，因此不会触发定义常量的类的初始
化。
 */
public class ConstClass{
    static{
        System.out.println ("ConstClass init! ");
    }
    public static final String HELLOWORLD="hello
world";
}
/**
 * 非主动使用类字段演示
 */
public class NotInitialization{
    public static void main (String[]args) {
        System.out.println (ConstClass.HELLOWORLD);
    }
}
```

上述代码运行之后，也没有输出“ConstClass init! ”，这是因为虽然在Java源码中引用了

ConstClass类中的常量HELLOWORLD，但其实在编译阶段通过常量传播优化，已经将此常量的值“hello world”存储到了NotInitialization类的常量池中，以后NotInitialization对常量

ConstClass.HELLOWORLD的引用实际都被转化为NotInitialization类对自身常量池的引用了。也就是说，实际上NotInitialization的Class文件之中并没有ConstClass类的符号引用入口，这两个类在编译成Class之后就不存在任何联系了。

接口的加载过程与类加载过程稍有一些不同，针对接口需要做一些特殊说明：接口也有初始化过程，这点与类是一致的，上面的代码都是用静态语句块“static {}”来输出初始化信息的，而接口中不能使用“static {}”语句块，但编译器仍然会为接口生成“<clinit> ()”类构造器^[2]，用于

初始化接口中所定义的成员变量。接口与类真正有所区别的是前面讲述的5种“有且仅有”需要开始初始化场景中的第3种：当一个类在初始化时，要求其父类全部都已经初始化过了，但是一个接口在初始化时，并不要求其父接口全部都完成了初始化，只有在真正使用到父接口的时候（如引用接口中定义的常量）才会初始化。

[1]准确地说，越界检查不是封装在数组元素访问的类中，而是封装在数组访问的xaload、xastore字节码指令中。

[2]关于类构造器<clinit>和方法构造器<init>的生成过程和作用，可参见第10章的相关内容。

7.3 类加载的过程

接下来我们详细讲解一下Java虚拟机中类加载的全过程，也就是加载、验证、准备、解析和初始化这5个阶段所执行的具体动作。

7.3.1 加载

“加载”是“类加载”（Class Loading）过程的一个阶段，希望读者没有混淆这两个看起来很相似的名词。在加载阶段，虚拟机需要完成以下3件事情：

- 1) 通过一个类的全限定名来获取定义此类的二进制字节流。

- 2) 将这个字节流所代表的静态存储结构转化为方法区的运行时数据结构。
- 3) 在内存中生成一个代表这个类的 `java.lang.Class` 对象，作为方法区这个类的各种数据的访问入口。

虚拟机规范的这3点要求其实并不算具体，因此虚拟机实现与具体应用的灵活度都是相当大的。例如“通过一个类的全限定名来获取定义此类的二进制字节流”这条，它没有指明二进制字节流要从一个Class文件中获取，准确地说是根本没有指明要从哪里获取、怎样获取。虚拟机设计团队在加载阶段搭建了一个相当开放的、广阔的“舞台”，Java发展历程中，充满创造力的开发人员则在这个“舞台”上玩出了各种花样，许多举

足轻重的Java技术都建立在这一基础之上，例如：

从ZIP包中读取，这很常见，最终成为日后JAR、EAR、WAR格式的基础。

从网络中获取，这种场景最典型的应用就是Applet。

运行时计算生成，这种场景使用得最多的就是动态代理技术，在`java.lang.reflect.Proxy`中，就是用了`ProxyGenerator.generateProxyClass`来为特定接口生成形式为“`*$Proxy`”的代理类的二进制字节流。

由其他文件生成，典型场景是JSP应用，即由JSP文件生成对应的Class类。

从数据库中读取，这种场景相对少见些，例如有些中间件服务器（如SAP Netweaver）可以选择把程序安装到数据库中来完成程序代码在集群间的分发。

.....

相对于类加载过程的其他阶段，一个非数组类的加载阶段（准确地说，是加载阶段中获取类的二进制字节流的动作）是开发人员可控性最强的，因为加载阶段既可以使用系统提供的引导类加载器来完成，也可以由用户自定义的类加载器去完成，开发人员可以通过定义自己的类加载器去控制字节流的获取方式（即重写一个类加载器的loadClass（）方法）。

对于数组类而言，情况就有所不同，数组类

本身不通过类加载器创建，它是由Java虚拟机直接创建的。但数组类与类加载器仍然有很密切的关系，因为数组类的元素类型（Element Type，指的是数组去掉所有维度的类型）最终是要靠类加载器去创建，一个数组类（下面简称为C）创建过程就遵循以下规则：

如果数组的组件类型（Component Type，指的是数组去掉一个维度的类型）是引用类型，那就递归采用本节中定义的加载过程去加载这个组件类型，数组C将在加载该组件类型的类加载器的类名称空间上被标识（这点很重要，在7.4节会介绍到，一个类必须与类加载器一起确定唯一性）。

如果数组的组件类型不是引用类型（例如

`int[]`数组），Java虚拟机将会把数组C标记为与引导类加载器关联。

数组类的可见性与它的组件类型的可见性一致，如果组件类型不是引用类型，那数组类的可见性将默认为`public`。

关于类加载器的话题，笔者将在本章的7.4节专门讲述。

加载阶段完成后，虚拟机外部的二进制字节流就按照虚拟机所需的格式存储在方法区之中，方法区中的数据存储格式由虚拟机实现自行定义，虚拟机规范未规定此区域的具体数据结构。然后在内存中实例化一个`java.lang.Class`类的对象（并没有明确规定是在Java堆中，对于HotSpot虚拟机而言，`Class`对象比较特殊，它虽然是对象，

但是存放在方法区里面），这个对象将作为程序访问方法区中的这些类型数据的外部接口。

加载阶段与连接阶段的部分内容（如一部分字节码文件格式验证动作）是交叉进行的，加载阶段尚未完成，连接阶段可能已经开始，但这些夹在加载阶段之中进行的动作，仍然属于连接阶段的内容，这两个阶段的开始时间仍然保持着固定的先后顺序。

7.3.2 验证

验证是连接阶段的第一步，这一阶段的目的是为了确保Class文件的字节流中包含的信息符合当前虚拟机的要求，并且不会危害虚拟机自身的安全。

Java语言本身是相对安全的语言（依然是相对于C/C++来说），使用纯粹的Java代码无法做到诸如访问数组边界以外的数据、将一个对象转型为它并未实现的类型、跳转到不存在的代码行之类的事情，如果这样做了，编译器将拒绝编译。但前面已经说过，Class文件并不一定要求用Java源码编译而来，可以使用任何途径产生，甚至包括用十六进制编辑器直接编写来产生Class文

件。在字节码语言层面上，上述Java代码无法做到的事情都是可以实现的，至少语义上是可以表达出来的。虚拟机如果不检查输入的字节流，对其完全信任的话，很可能因为载入了有害的字节流而导致系统崩溃，所以验证是虚拟机对自身保护的一项重要工作。

验证阶段是非常重要的，这个阶段是否严谨，直接决定了Java虚拟机是否能承受恶意代码的攻击，从执行性能的角度上讲，验证阶段的工作量在虚拟机的类加载子系统中又占了相当大的一部分。《Java虚拟机规范（第2版）》对这个阶段的限制、指导还是比较笼统的，规范中列举了一些Class文件格式中的静态和结构化约束，如果验证到输入的字节流不符合Class文件格式的约束，虚拟机就应抛出一个java.lang.VerifyError异常。

常或其子类异常，但具体应当检查哪些方面，如何检查，何时检查，都没有足够具体的要求和明确的说明。直到2011年发布的《Java虚拟机规范（Java SE 7版）》，大幅增加了描述验证过程的篇幅（从不到10页增加到130页），这时约束和验证规则才变得具体起来。受篇幅所限，本书无法逐条规则去讲解，但从整体上看，验证阶段大致上会完成下面4个阶段的检验动作：文件格式验证、元数据验证、字节码验证、符号引用验证。

1. 文件格式验证

第一阶段要验证字节流是否符合Class文件格式的规范，并且能被当前版本的虚拟机处理。这一阶段可能包括下面这些验证点：

是否以魔数0xCAFEBAE开头。

主、次版本号是否在当前虚拟机处理范围之内。

常量池的常量中是否有不被支持的常量类型（检查常量tag标志）。

指向常量的各种索引值中是否有指向不存在的常量或不符合类型的常量。

CONSTANT_Utf8_info型的常量中是否有不符合UTF8编码的数据。

Class文件中各个部分及文件本身是否有被删除的或附加的其他信息。

.....

实际上，第一阶段的验证点还远不止这些，上面这些只是从HotSpot虚拟机源码[1]中摘抄的一小部分内容，该验证阶段的主要目的是保证输入的字节流能正确地解析并存储于方法区之内，格式上符合描述一个Java类型信息的要求。这阶段的验证是基于二进制字节流进行的，只有通过了这个阶段的验证后，字节流才会进入内存的方法区中进行存储，所以后面的3个验证阶段全部是基于方法区的存储结构进行的，不会再直接操作字节流。

2. 元数据验证

第二阶段是对字节码描述的信息进行语义分析，以保证其描述的信息符合Java语言规范的要求，这个阶段可能包括的验证点如下：

这个类是否有父类（除了java.lang.Object之外，所有的类都应当有父类）。

这个类的父类是否继承了不允许被继承的类（被final修饰的类）。

如果这个类不是抽象类，是否实现了其父类或接口之中要求实现的所有方法。

类中的字段、方法是否与父类产生矛盾（例如覆盖了父类的final字段，或者出现不符合规则的方法重载，例如方法参数都一致，但返回值类型却不同等）。

.....

第二阶段的主要目的是对类的元数据信息进行语义校验，保证不存在不符合Java语言规范的

元数据信息。

3. 字节码验证

第三阶段是整个验证过程中最复杂的一个阶段，主要目的是通过数据流和控制流分析，确定程序语义是合法的、符合逻辑的。在第二阶段对元数据信息中的数据类型做完校验后，这个阶段将对类的方法体进行校验分析，保证被校验类的方法在运行时不会做出危害虚拟机安全的事件，例如：

保证任意时刻操作数栈的数据类型与指令代码序列都能配合工作，例如不会出现类似这样的情况：在操作栈放置了一个int类型的数据，使用时却按long类型来加载入本地变量表中。

保证跳转指令不会跳转到方法体以外的字节码指令上。

保证方法体中的类型转换是有效的，例如可以把一个子类对象赋值给父类数据类型，这是安全的，但是把父类对象赋值给子类数据类型，甚至把对象赋值给与它毫无继承关系、完全不相干的一个数据类型，则是危险和不合法的。

.....

如果一个类方法体的字节码没有通过字节码验证，那肯定是有问题的；但如果一个方法体通过了字节码验证，也不能说明其一定就是安全的。即使字节码验证之中进行了大量的检查，也不能保证这一点。这里涉及了离散数学中一个很著名的问题“Halting Problem”^[2]：通俗一点的说法

就是，通过程序去校验程序逻辑是无法做到绝对准确的——不能通过程序准确地检查出程序是否能在有限的时间之内结束运行。

由于数据流验证的高复杂性，虚拟机设计团队为了避免过多的时间消耗在字节码验证阶段，在JDK 1.6之后的Javac编译器和Java虚拟机中进行了一项优化，给方法体的Code属性的属性表中增加了一项名为“StackMapTable”的属性，这项属性描述了方法体中所有的基本块（Basic Block，按照控制流拆分的代码块）开始时本地变量表和操作栈应有的状态，在字节码验证期间，就不需要根据程序推导这些状态的合法性，只需要检查StackMapTable属性中的记录是否合法即可。这样将字节码验证的类型推导转变为类型检查从而节省一些时间。

理论上StackMapTable属性也存在错误或被篡改的可能，所以是否有可能在恶意篡改了Code属性的同时，也生成相应的StackMapTable属性来骗过虚拟机的类型校验则是虚拟机设计者值得思考的问题。

在JDK 1.6的HotSpot虚拟机中提供了-XX: -UseSplitVerifier选项来关闭这项优化，或者使用参数-XX: +FailOverToOldVerifier要求在类型校验失败的时候退回到旧的类型推导方式进行校验。而在JDK 1.7之后，对于主版本号大于50的Class文件，使用类型检查来完成数据流分析校验则是唯一的选择，不允许再退回到类型推导的校验方式。

4. 符号引用验证

最后一个阶段的校验发生在虚拟机将符号引用转化为直接引用的时候，这个转化动作将在连接的第三阶段——解析阶段中发生。符号引用验证可以看做是对类自身以外（常量池中的各种符号引用）的信息进行匹配性校验，通常需要校验下列内容：

符号引用中通过字符串描述的全限定名是否能找到对应的类。

在指定类中是否存在符合方法的字段描述符以及简单名称所描述的方法和字段。

符号引用中的类、字段、方法的访问性（private、protected、public、default）是否可被当前类访问。

.....

符号引用验证的目的是确保解析动作能正常执行，如果无法通过符号引用验证，那么将会抛出一个java.lang.IncompatibleClassChangeError异常的子类，如java.lang.IllegalAccessError、java.lang.NoSuchFieldError、java.lang.NoSuchMethodError等。

对于虚拟机的类加载机制来说，验证阶段是一个非常重要的、但不是一定必要（因为对程序运行期没有影响）的阶段。如果所运行的全部代码（包括自己编写的及第三方包中的代码）都已经被反复使用和验证过，那么在实施阶段就可以考虑使用-Xverify: none参数来关闭大部分的类验证措施，以缩短虚拟机类加载的时间。

[1]源码位置：

hotspot\src\share\vm\classfile\classFileParser.cpp。

[2]停机问题就是判断任意一个程序是否会在有限的时间之内结束运行的问题。如果这个问题可以在有限的时间之内解决，可以有一个程序判断其本身是否会停机并做出相反的行为。这时候显然不管停机问题的结果是什么都不会符合要求，所以这是一个不可解的问题。具体的证明过程可参考：<http://zh.wikipedia.org/zh/停机问题>。

7.3.3 准备

准备阶段是正式为类变量分配内存并设置类变量初始值的阶段，这些变量所使用的内存都将在方法区中进行分配。这个阶段中有两个容易产生混淆的概念需要强调一下，首先，这时候进行内存分配的仅包括类变量（被static修饰的变量），而不包括实例变量，实例变量将会在对象实例化时随着对象一起分配在Java堆中。其次，这里所说的初始值“通常情况”下是数据类型的零值，假设一个类变量的定义为：

```
public static int value=123;
```

那变量value在准备阶段过后的初始值为0而

不是123，因为这时候尚未开始执行任何Java方法，而把value赋值为123的putstatic指令是程序被编译后，存放于类构造器<clinit>（）方法之中，所以把value赋值为123的动作将在初始化阶段才会执行。表7-1列出了Java中所有基本数据类型的零值。

表 7-1 基本数据类型的零值

| 数据类型 | 零 值 | 数据类型 | 零 值 |
|-------|-----------|-----------|-------|
| int | 0 | boolean | false |
| long | 0L | float | 0.0f |
| short | (short) 0 | double | 0.0d |
| char | '\u0000' | reference | null |
| byte | (byte) 0 | | |

上面提到，在“通常情况”下初始值是零值，那相对的会有一些“特殊情况”：如果类字段的字段属性表中存在ConstantValue属性，那在准备阶段变量value就会被初始化为ConstantValue属性所指定的值，假设上面类变量value的定义变为：

```
public static final int value=123;
```

编译时Javac将会为value生成ConstantValue属性，在准备阶段虚拟机就会根据ConstantValue的设置将value赋值为123。

7.3.4 解析

解析阶段是虚拟机将常量池内的符号引用替换为直接引用的过程，符号引用在前一章讲解Class文件格式的时候已经出现过多次，在Class文件中它以CONSTANT_Class_info、CONSTANT_Fieldref_info、CONSTANT_Methodref_info等类型的常量出现，那解析阶段中所说的直接引用与符号引用又有什么关联呢？

符号引用（Symbolic References）：符号引用以一组符号来描述所引用的目标，符号可以是以任何形式的字面量，只要使用时能无歧义地定位到目标即可。符号引用与虚拟机实现的内存布局

无关，引用的目标并不一定已经加载到内存中。各种虚拟机实现的内存布局可以各不相同，但是它们能接受的符号引用必须都是一致的，因为符号引用的字面量形式明确定义在Java虚拟机规范的Class文件格式中。

直接引用（Direct References）：直接引用可以是直接指向目标的指针、相对偏移量或是一个能间接定位到目标的句柄。直接引用是和虚拟机实现的内存布局相关的，同一个符号引用在不同虚拟机实例上翻译出来的直接引用一般不会相同。如果有了直接引用，那引用的目标必定已经在内存中存在。

虚拟机规范之中并未规定解析阶段发生的具体时间，只要求了在执行anewarray、checkcast、

getfield、getstatic、instanceof、invokedynamic、invokeinterface、invokespecial、invokestatic、invokevirtual、ldc、ldc_w、multianewarray、new、putfield和putstatic这16个用于操作符号引用的字节码指令之前，先对它们所使用的符号引用进行解析。所以虚拟机实现可以根据需要来判断到底是在类被加载器加载时就对常量池中的符号引用进行解析，还是等到一个符号引用将要被使用前才去解析它。

对同一个符号引用进行多次解析请求是很常见的事情，除invokedynamic指令以外，虚拟机实现可以对第一次解析的结果进行缓存（在运行时常量池中记录直接引用，并把常量标识为已解析状态）从而避免解析动作重复进行。无论是否真正执行了多次解析动作，虚拟机需要保证的是在

同一个实体中，如果一个符号引用之前已经被成功解析过，那么后续的引用解析请求就应当一直成功；同样的，如果第一次解析失败了，那么其他指令对这个符号的解析请求也应该收到相同的异常。

对于invokedynamic指令，上面规则则不成立。当碰到某个前面已经由invokedynamic指令触发过解析的符号引用时，并不意味着这个解析结果对于其他invokedynamic指令也同样生效。因为invokedynamic指令的目的本来就是用于动态语言支持（目前仅使用Java语言不会生成这条字节码指令），它所对应的引用称为“动态调用点限定符”（Dynamic Call Site Specifier），这里“动态”的含义就是必须等到程序实际运行到这条指令的时候，解析动作才能进行。相对的，其余可

触发解析的指令都是“静态”的，可以在刚刚完成加载阶段，还没有开始执行代码时就进行解析。

解析动作主要针对类或接口、字段、类方法、接口方法、方法类型、方法句柄和调用点限定符7类符号引用进行，分别对应于常量池的
CONSTANT_Class_info、
CONSTANT_Fieldref_info、
CONSTANT_Methodref_info、
CONSTANT_InterfaceMethodref_info、
CONSTANT_MethodType_info、
CONSTANT_MethodHandle_info和
CONSTANT_InvokeDynamic_info 7种常量类型

[1]。下面将讲解前面4种引用的解析过程，对于后面3种，与JDK 1.7新增的动态语言支持息息相关，由于Java语言是一门静态类型语言，因此在

没有介绍invokedynamic指令的语义之前，没有办法将它们和现在的Java语言对应上，笔者将在第8章介绍动态语言调用时一起分析讲解。

1.类或接口的解析

假设当前代码所处的类为D，如果要把一个从未解析过的符号引用N解析为一个类或接口C的直接引用，那虚拟机完成整个解析的过程需要以下3个步骤：

1) 如果C不是一个数组类型，那虚拟机将会把代表N的全限定名传递给D的类加载器去加载这个类C。在加载过程中，由于元数据验证、字节码验证的需要，又可能触发其他相关类的加载动作，例如加载这个类的父类或实现的接口。一旦这个加载过程出现了任何异常，解析过程就宣

告失败。

2) 如果C是一个数组类型，并且数组的元素类型为对象，也就是N的描述符会是类似“[Ljava/lang/Integer”的形式，那将会按照第1点的规则加载数组元素类型。如果N的描述符如前面所假设的形式，需要加载的元素类型就是“java.lang.Integer”，接着由虚拟机生成一个代表此数组维度和元素的数组对象。

3) 如果上面的步骤没有出现任何异常，那么C在虚拟机中实际上已经成为一个有效的类或接口了，但在解析完成之前还要进行符号引用验证，确认D是否具备对C的访问权限。如果发现不具备访问权限，将抛出
java.lang.IllegalAccessError异常。

2. 字段解析

要解析一个未被解析过的字段符号引用，首先将会对字段表内class_index^[2]项中索引的CONSTANT_Class_info符号引用进行解析，也就是字段所属的类或接口的符号引用。如果在解析这个类或接口符号引用的过程中出现了任何异常，都会导致字段符号引用解析的失败。如果解析成功完成，那将这个字段所属的类或接口用C表示，虚拟机规范要求按照如下步骤对C进行后续字段的搜索。

- 1) 如果C本身就包含了简单名称和字段描述符都与目标相匹配的字段，则返回这个字段的直接引用，查找结束。
- 2) 否则，如果在C中实现了接口，将会按照

继承关系从下往上递归搜索各个接口和它的父接口，如果接口中包含了简单名称和字段描述符都与目标相匹配的字段，则返回这个字段的直接引用，查找结束。

3) 否则，如果C不是java.lang.Object的话，将会按照继承关系从下往上递归搜索其父类，如果在父类中包含了简单名称和字段描述符都与目标相匹配的字段，则返回这个字段的直接引用，查找结束。

4) 否则，查找失败，抛出
java.lang.NoSuchFieldError异常。

如果查找过程成功返回了引用，将会对这个字段进行权限验证，如果发现不具备对字段的访问权限，将抛出java.lang.IllegalAccessError异

常。

在实际应用中，虚拟机的编译器实现可能会比上述规范要求得更加严格一些，如果有一个同名字段同时出现在C的接口和父类中，或者同时在自己或父类的多个接口中出现，那编译器将可能拒绝编译。在代码清单7-4中，如果注释了Sub类中的“public static int A=4; ”，接口与父类同时存在字段A，那编译器将提示“The field Sub.A is ambiguous”，并且拒绝编译这段代码。

代码清单7-4 字段解析

```
package org.fenixsoft.classloading;
public class FieldResolution{
    interface Interface0{
        int A=0;
    }
    interface Interface1 extends Interface0{
        int A=1;
    }
}
```

```
interface Interface2{  
    int A=2;  
}  
static class Parent implements Interface1{  
    public static int A=3;  
}  
static class Sub extends Parent implements  
Interface2{  
    public static int A=4;  
}  
public static void main (String[]args) {  
    System.out.println (Sub.A) ;  
}
```

3.类方法解析

类方法解析的第一个步骤与字段解析一样，也需要先解析出类方法表的class_index^[3]项中索引的方法所属的类或接口的符号引用，如果解析成功，我们依然用C表示这个类，接下来虚拟机将会按照如下步骤进行后续的类方法搜索。

1) 类方法和接口方法符号引用的常量类型

定义是分开的，如果在类方法表中发现
class_index中索引的C是个接口，那就直接抛出
java.lang.IncompatibleClassChangeError异常。

- 2) 如果通过了第1步，在类C中查找是否有简单名称和描述符都与目标相匹配的方法，如果有则返回这个方法的直接引用，查找结束。
- 3) 否则，在类C的父类中递归查找是否有简单名称和描述符都与目标相匹配的方法，如果有则返回这个方法的直接引用，查找结束。
- 4) 否则，在类C实现的接口列表及它们的父接口之中递归查找是否有简单名称和描述符都与目标相匹配的方法，如果存在匹配的方法，说明类C是一个抽象类，这时查找结束，抛出
java.lang.AbstractMethodError异常。

5) 否则，宣告方法查找失败，抛出
java.lang.NoSuchMethodError。

最后，如果查找过程成功返回了直接引用，
将会对这个方法进行权限验证，如果发现不具备
对此方法的访问权限，将抛出
java.lang.IllegalAccessError异常。

4. 接口方法解析

接口方法也需要先解析出接口方法表的
class_index^[4]项中索引的方法所属的类或接口的
符号引用，如果解析成功，依然用C表示这个接
口，接下来虚拟机将会按照如下步骤进行后续的
接口方法搜索。

1) 与类方法解析不同，如果在接口方法表

中发现class_index中的索引C是个类而不是接口，那就直接抛出

java.lang.IncompatibleClassChangeError异常。

2) 否则，在接口C中查找是否有简单名称和描述符都与目标相匹配的方法，如果有则返回这个方法的直接引用，查找结束。

3) 否则，在接口C的父接口中递归查找，直到java.lang.Object类（查找范围会包括Object类）为止，看是否有简单名称和描述符都与目标相匹配的方法，如果有则返回这个方法的直接引用，查找结束。

4) 否则，宣告方法查找失败，抛出java.lang.NoSuchMethodError异常。

由于接口中的所有方法默认都是public的，所以不存在访问权限的问题，因此接口方法的符号解析应当不会抛出java.lang.IllegalAccessError异常。

[1]严格来说，CONSTANT_String_info和CONSTANT_InterfaceMethodref_info这两种类型的常量也有解析过程，但很简单、直观，不再做单独介绍。

[2]参见第6章中关于CONSTANT_Fieldref_info常量的内容。

[3]参见第6章关于CONSTANT_Methodref_info常量的内容。

[4]参见第6章中关于CONSTANT_InterfaceMethodref_info常量的内容。

7.3.5 初始化

类初始化阶段是类加载过程的最后一步，前面的类加载过程中，除了在加载阶段用户应用程序可以通过自定义类加载器参与之外，其余动作完全由虚拟机主导和控制。到了初始化阶段，才真正开始执行类中定义的Java程序代码（或者说 是字节码）。

在准备阶段，变量已经赋过一次系统要求的初始值，而在初始化阶段，则根据程序员通过程序制定的主观计划去初始化类变量和其他资源，或者可以从另外一个角度来表达：初始化阶段是执行类构造器`<clinit> ()`方法的过程。我们在下文会讲解`<clinit> ()`方法是怎么生成的，在

这里，我们先看一下<clinit>（）方法执行过程中一些可能会影响程序运行行为的特点和细节，这部分相对更贴近于普通的程序开发人员^[1]。

<clinit>（）方法是由编译器自动收集类中的所有类变量的赋值动作和静态语句块（static{}块）中的语句合并产生的，编译器收集的顺序是由语句在源文件中出现的顺序所决定的，静态语句块中只能访问到定义在静态语句块之前的变量，定义在它之后的变量，在前面的静态语句块可以赋值，但是不能访问，如代码清单7-5中的例子所示。

代码清单7-5 非法向前引用变量

```
public class Test{  
    static{  
        i=0; //给变量赋值可以正常编译通过  
    }  
}
```

```
System.out.print(i); //这句编译器会提示"非法向  
前引用"  
}  
static int i=1;  
}
```

<clinit>（）方法与类的构造函数（或者说实例构造器<init>（）方法）不同，它不需要显式地调用父类构造器，虚拟机会保证在子类的<clinit>（）方法执行之前，父类的<clinit>（）方法已经执行完毕。因此在虚拟机中第一个被执行的<clinit>（）方法的类肯定是java.lang.Object。

由于父类的<clinit>（）方法先执行，也就意味着父类中定义的静态语句块要优先于子类的变量赋值操作，如在代码清单7-6中，字段B的值将会是2而不是1。

代码清单7-6<clinit>（）方法执行顺序

```
static class Parent{  
    public static int A=1;  
    static{  
        A=2;  
    }  
}  
  
static class Sub extends Parent{  
    public static int B=A;  
}  
  
public static void main (String[]args) {  
    System.out.println (Sub.B) ;  
}
```

<clinit>（）方法对于类或接口来说并不是必需的，如果一个类中没有静态语句块，也没有对变量的赋值操作，那么编译器可以不为这个类生成<clinit>（）方法。

接口中不能使用静态语句块，但仍然有变量初始化的赋值操作，因此接口与类一样都会生成

<clinit> () 方法。但接口与类不同的是，执行接口的<clinit> () 方法不需要先执行父接口的<clinit> () 方法。只有当父接口中定义的变量使用时，父接口才会初始化。另外，接口的实现类在初始化时也一样不会执行接口的<clinit> () 方法。

虚拟机会保证一个类的<clinit> () 方法在多线程环境中被正确地加锁、同步，如果多个线程同时去初始化一个类，那么只会有一个线程去执行这个类的<clinit> () 方法，其他线程都需要阻塞等待，直到活动线程执行<clinit> () 方法完毕。如果在一个类的<clinit> () 方法中有耗时很长的操作，就可能造成多个进程阻塞^[2]，在实际应用中这种阻塞往往是很隐蔽的。代码清单7-7演示了这种场景。

代码清单7-7 字段解析

```
static class DeadLoopClass{
    static{
        /*如果不加上这个if语句，编译器将提示"Initializer
does not complete normally"并拒绝编译*/
        if (true) {
            System.out.println (Thread.currentThread () +
"init DeadLoopClass") ;
        while (true) {
            }
        }
    }
    public static void main (String[]args) {
        Runnable script=new Runnable () {
            public void run () {
                System.out.println (Thread.currentThread () +
"start") ;
                DeadLoopClass dlc=new DeadLoopClass () ;
                System.out.println (Thread.currentThread () +
"run over") ;
            }
        };
        Thread thread1=new Thread (script) ;
        Thread thread2=new Thread (script) ;
        thread1.start () ;
        thread2.start () ;
    }
}
```

运行结果如下，即一条线程在死循环以模拟长时间操作，另外一条线程在阻塞等待。

```
Thread[Thread-0, 5, main] start  
Thread[Thread-1, 5, main] start  
Thread[Thread-0, 5, main] init DeadLoopClass
```

- [1]这里只限于Java语言编译产生的Class文件，并不包括其他JVM语言。
- [2]需要注意的是，其他线程虽然会被阻塞，但如果执行<clinit> () 方法的那条线程退出<clinit> () 方法后，其他线程唤醒之后不会再次进入<clinit> () 方法。同一个类加载器下，一个类型只会初始化一次。

7.4 类加载器

虚拟机设计团队把类加载阶段中的“通过一个类的全限定名来获取描述此类的二进制字节流”这个动作放到Java虚拟机外部去实现，以便让应用程序自己决定如何去获取所需要的类。实现这个动作的代码模块称为“类加载器”。

类加载器可以说是Java语言的一项创新，也是Java语言流行的重要原因之一，它最初是为了满足Java Applet的需求而开发出来的。虽然目前Java Applet技术基本上已经“死掉”^[1]，但类加载器却在类层次划分、OSGi、热部署、代码加密等领域大放异彩，成为了Java技术体系中一块重要的基石，可谓是失之桑榆，收之东隅。

7.4.1 类与类加载器

类加载器虽然只用于实现类的加载动作，但它在Java程序中起到的作用却远远不限于类加载阶段。对于任意一个类，都需要由加载它的类加载器和这个类本身一同确立其在Java虚拟机中的唯一性，每一个类加载器，都拥有一个独立的类名称空间。这句话可以表达得更通俗一些：比较两个类是否“相等”，只有在这两个类是由同一个类加载器加载的前提下才有意义，否则，即使这两个类来源于同一个Class文件，被同一个虚拟机加载，只要加载它们的类加载器不同，那这两个类就必定不相等。

这里所指的“相等”，包括代表类的Class对象的equals（）方法、isAssignableFrom（）方法、

`isInstance()`方法的返回结果，也包括使用`instanceof`关键字做对象所属关系判定等情况。如果没有注意到类加载器的影响，在某些情况下可能会产生具有迷惑性的结果，代码清单7-8中演示了不同的类加载器对`instanceof`关键字运算的结果的影响。

代码清单7-8 不同的类加载器对`instanceof`关键字运算的结果的影响

```
/*
 *类加载器与instanceof关键字演示
 *
 *@author zzm
 */
public class ClassLoaderTest{
    public static void main (String[]args)
throws Exception{
    ClassLoader myLoader=new ClassLoader () {
        @Override
        public Class<?>loadClass (String name)
throws ClassNotFoundException{
        try{
```

```
String  
fileName=name.substring (name.lastIndexOf (".")  
+1) +".class";  
InputStream  
is=getClass () .getResourceAsStream (fileName) ;  
if (is==null) {  
return super.loadClass (name) ;  
}  
byte[]b=new byte[is.available () ];  
is.read (b) ;  
return defineClass (name,b, 0, b.length) ;  
}catch (IOException e) {  
throw new ClassNotFoundException (name) ;  
}  
}  
};  
Object  
obj=myLoader.loadClass ("org.fenixsoft.classload  
System.out.println (obj.getClass () ) ;  
System.out.println (obj instanceof  
org.fenixsoft.classloading.ClassLoaderTest) ;  
}  
}
```

运行结果：

```
class  
org.fenixsoft.classloading.ClassLoaderTest  
false
```

代码清单7-8中构造了一个简单的类加载器，尽管很简单，但是对于这个演示来说还是够用了。它可以加载与自己在同一路径下的Class文件。我们使用这个类加载器去加载了一个名为“org.fenixsoft.classloading.ClassLoaderTest”的类，并实例化了这个类的对象。两行输出结果中，从第一句可以看出，这个对象确实是类org.fenixsoft.classloading.ClassLoaderTest实例化出来的对象，但从第二句可以发现，这个对象与类org.fenixsoft.classloading.ClassLoaderTest做所属类型检查的时候却返回了false，这是因为虚拟机中存在了两个ClassLoaderTest类，一个是由系统应用程序类加载器加载的，另外一个是由我们自定义的类加载器加载的，虽然都来自同一个Class文件，但依然是两个独立的类，做对象所属类型检

查时结果自然为false。

[1]特指浏览器上的Java Applets，在其他领域，如智能卡上，Java Applets仍然有广阔的市场。

7.4.2 双亲委派模型

从Java虚拟机的角度来讲，只存在两种不同的类加载器：一种是启动类加载器（Bootstrap ClassLoader），这个类加载器使用C++语言实现 [1]，是虚拟机自身的一部分；另一种就是所有其他的类加载器，这些类加载器都由Java语言实现，独立于虚拟机外部，并且全都继承自抽象类 `java.lang.ClassLoader`。

从Java开发人员的角度来看，类加载器还可以划分得更细致一些，绝大部分Java程序都会使用到以下3种系统提供的类加载器。

启动类加载器（Bootstrap ClassLoader）：前

面已经介绍过，这个类将器负责将存放在<JAVA_HOME>\lib目录中的，或者被-Xbootclasspath参数所指定的路径中的，并且是虚拟机识别的（仅按照文件名识别，如rt.jar，名字不符合的类库即使放在lib目录中也不会被加载）类库加载到虚拟机内存中。启动类加载器无法被Java程序直接引用，用户在编写自定义类加载器时，如果需要把加载请求委派给引导类加载器，那直接使用null代替即可，如代码清单7-9所示为java.lang.ClassLoader.getClassLoader（）方法的代码片段。

代码清单7-9

ClassLoader.getClassLoader（）方法的代码片段

```
/**  
 * Returns the class loader for the class. Some  
 *
```

implementations may use null to represent the bootstrap class loader. This method will return null in such implementations if this class was loaded by the bootstrap class loader.

```
*/
```

```
public ClassLoader getClassLoader () {  
    ClassLoader cl=getClassLoader0 () ;  
    if (cl==null)  
        return null;  
    SecurityManager  
    sm=System.getSecurityManager () ;  
    if (sm! =null) {  
        ClassLoader  
        ccl=ClassLoader.getCallerClassLoader () ;  
        if (ccl! =null&&ccl! =cl&&!  
        cl.isAncestor (ccl) ) {  
            sm.checkPermission (SecurityConstants.GET_CLASSIFIER)  
        }  
    }  
    return cl;  
}
```

扩展类加载器（Extension ClassLoader）：这个加载器由sun.misc.Launcher \$ExtClassLoader实现，它负责加载<JAVA_HOME>\lib\ext目录中的，或者被java.ext.dirs系统变量所指定的路径中的所有类库，开发者可以直接使用扩展类加载

器。

应用程序类加载器（Application ClassLoader）：这个类加载器由sun.misc.Launcher \$App-ClassLoader实现。由于这个类加载器是 ClassLoader中的getSystemClassLoader（）方法的返回值，所以一般也称它为系统类加载器。它负责加载用户类路径（ClassPath）上所指定的类库，开发者可以直接使用这个类加载器，如果应用程序中没有自定义过自己的类加载器，一般情况下这个就是程序中默认的类加载器。

我们的应用程序都是由这3种类加载器互相配合进行加载的，如果有必要，还可以加入自己定义的类加载器。这些类加载器之间的关系一般如图7-2所示。




图 7-2 类加载器双亲委派模型

图7-2中展示的类加载器之间的这种层次关系，称为类加载器的双亲委派模型（Parents Delegation Model）。双亲委派模型要求除了顶层

的启动类加载器外，其余的类加载器都应当有自己的父类加载器。这里类加载器之间的父子关系一般不会以继承（Inheritance）的关系来实现，而是都使用组合（Composition）关系来复用父加载器的代码。

类加载器的双亲委派模型在JDK 1.2期间被引入并被广泛应用于之后几乎所有的Java程序中，但它并不是一个强制性的约束模型，而是Java设计者推荐给开发者的一种类加载器实现方式。

双亲委派模型的工作过程是：如果一个类加载器收到了类加载的请求，它首先不会自己去尝试加载这个类，而是把这个请求委派给父类加载器去完成，每一个层次的类加载器都是如此，因此所有的加载请求最终都应该传送到顶层的启动

类加载器中，只有当父加载器反馈自己无法完成这个加载请求（它的搜索范围中没有找到所需的类）时，子加载器才会尝试自己去加载。

使用双亲委派模型来组织类加载器之间的关系，有一个显而易见的好处就是Java类随着它的类加载器一起具备了一种带有优先级的层次关系。例如类java.lang.Object，它存放在rt.jar之中，无论哪一个类加载器要加载这个类，最终都是委派给处于模型最顶端的启动类加载器进行加载，因此Object类在程序的各种类加载器环境中都是同一个类。相反，如果没有使用双亲委派模型，由各个类加载器自行去加载的话，如果用户自己编写了一个称为java.lang.Object的类，并放在程序的ClassPath中，那系统中将会出现多个不同的Object类，Java类型体系中最基础的行为也

就无法保证，应用程序也将变得一片混乱。如果读者有兴趣的话，可以尝试去编写一个与rt.jar类库中已有类重名的Java类，将会发现可以正常编译，但永远无法被加载运行^[2]。

双亲委派模型对于保证Java程序的稳定运作很重要，但它的实现却非常简单，实现双亲委派的代码都集中在java.lang.ClassLoader的loadClass（）方法之中，如代码清单7-10所示，逻辑清晰易懂：先检查是否已经被加载过，若没有加载则调用父加载器的loadClass（）方法，若父加载器为空则默认使用启动类加载器作为父加载器。如果父类加载失败，抛出ClassNotFoundException异常后，再调用自己的findClass（）方法进行加载。

代码清单7-10 双亲委派模型的实现

```
protected synchronized Class<?>
loadClass (String name,boolean resolve) throws
ClassNotFoundException
{
    //首先，检查请求的类是否已经被加载过了
    Class c=findLoadedClass (name) ;
    if (c==null) {
        try{
            if (parent!=null) {
                c=parent.loadClass (name, false) ;
            }else{
                c=findBootstrapClassOrNull (name) ;
            }
        }catch (ClassNotFoundException e) {
            //如果父类加载器抛出ClassNotFoundException
            //说明父类加载器无法完成加载请求
        }
        if (c==null) {
            //在父类加载器无法加载的时候
            //再调用本身的findClass方法来进行类加载
            c=findClass (name) ;
        }
    }
    if (resolve) {
        resolveClass (c) ;
    }
    return c;
}
```

[1]这里只限于HotSpot，像MRP、Maxine等虚拟机，整个虚拟机本身都是由Java编写的，自然Bootstrap ClassLoader也是由Java语言而不是C++实现的。退一步讲，除了HotSpot以外的其他两个高性能虚拟机JRockit和J9都有一个代表Bootstrap ClassLoader的Java类存在，但是关键方法的实现仍然是使用JNI回调到C（注意不是C++）的实现上，这个Bootstrap ClassLoader的实例也无法被用户获取到。

[2]即使自定义了自己的类加载器，强行用defineClass（）方法去加载一个以“java.lang”开头的类也不会成功。如果尝试这样做的话，将会收到一个由虚拟机自己抛出的“java.lang.SecurityException：Prohibited package name：java.lang”异常。

7.4.3 破坏双亲委派模型

上文提到过双亲委派模型并不是一个强制性的约束模型，而是Java设计者推荐给开发者的类加载器实现方式。在Java的世界中大部分的类加载器都遵循这个模型，但也有例外，到目前为止，双亲委派模型主要出现过3较大规模的“被破坏”情况。

双亲委派模型的第一次“被破坏”其实发生在双亲委派模型出现之前——即JDK 1.2发布之前。由于双亲委派模型在JDK 1.2之后才被引入，而类加载器和抽象类java.lang.ClassLoader则在JDK 1.0时代就已经存在，面对已经存在的用户自定义类加载器的实现代码，Java设计者引入双亲委派模

型时不得不做出一些妥协。为了向前兼容，JDK 1.2之后的java.lang.ClassLoader添加了一个新的protected方法findClass（），在此之前，用户去继承java.lang.ClassLoader的唯一目的就是为了重写loadClass（）方法，因为虚拟机在进行类加载的时候会调用加载器的私有方法loadClassInternal（），而这个方法的唯一逻辑就是去调用自己的loadClass（）。

上一节我们已经看过loadClass（）方法的代码，双亲委派的具体逻辑就实现在这个方法之中，JDK 1.2之后已不提倡用户再去覆盖loadClass（）方法，而应当把自己的类加载逻辑写到findClass（）方法中，在loadClass（）方法的逻辑里如果父类加载失败，则会调用自己的findClass（）方法来完成加载，这样就可以保证

新写出来的类加载器是符合双亲委派规则的。

双亲委派模型的第二次“被破坏”是由这个模型自身的缺陷所导致的，双亲委派很好地解决了各个类加载器的基础类的统一问题（越基础的类由越上层的加载器进行加载），基础类之所以称为“基础”，是因为它们总是作为被用户代码调用的API，但世事往往没有绝对的完美，如果基础类又要调用回用户的代码，那该怎么办？

这并非是不可能的事情，一个典型的例子便是JNDI服务，JNDI现在已经是Java的标准服务，它的代码由启动类加载器去加载（在JDK 1.3时放进去的rt.jar），但JNDI的目的就是对资源进行集中管理和查找，它需要调用由独立厂商实现并部署在应用程序的ClassPath下的JNDI接口提供者

(SPI,Service Provider Interface) 的代码，但启动类加载器不可能“认识”这些代码啊！那该怎么办？

为了解决这个问题，Java设计团队只好引入了一个不太优雅的设计：线程上下文类加载器（Thread Context ClassLoader）。这个类加载器可以通过`java.lang.Thread`类的`setContextClassLoaser()`方法进行设置，如果创建线程时还未设置，它将会从父线程中继承一个，如果在应用程序的全局范围内都没有设置过的话，那这个类加载器默认就是应用程序类加载器。

有了线程上下文类加载器，就可以做一些“舞弊”的事情了，JNDI服务使用这个线程上下

父类加载器去加载所需要的SPI代码，也就是父类加载器请求子类加载器去完成类加载的动作，这种行为实际上就是打通了双亲委派模型的层次结构来逆向使用类加载器，实际上已经违背了双亲委派模型的一般性原则，但这也是无可奈何的事情。Java中所有涉及SPI的加载动作基本上都采用这种方式，例如JNDI、JDBC、JCE、JAXB和JBI等。

双亲委派模型的第三次“被破坏”是由于用户对程序动态性的追求而导致的，这里所说的“动态性”指的是当前一些非常“热门”的名词：代码热替换（HotSwap）、模块热部署（Hot Deployment）等，说白了就是希望应用程序能像我们的计算机外设那样，接上鼠标、U盘，不用重启机器就能立即使用，鼠标有问题或要升级就

换个鼠标，不用停机也不用重启。对于个人计算机来说，重启一次其实没有什么大不了的，但对于一些生产系统来说，关机重启一次可能就要被列为生产事故，这种情况下热部署就对软件开发者，尤其是企业级软件开发者具有很大的吸引力。

Sun公司所提出的JSR-294^[1]、JSR-277^[2]规范在与JCP组织的模块化规范之争中落败给JSR-291（即OSGi R4.2），虽然Sun不甘失去Java模块化的主导权，独立在发展Jigsaw项目，但目前OSGi已经成为了业界“事实上”的Java模块化标准^[3]，而OSGi实现模块化热部署的关键则是它自定义的类加载器机制的实现。每一个程序模块（OSGi中称为Bundle）都有一个自己的类加载器，当需要更换一个Bundle时，就把Bundle连同

类加载器一起换掉以实现代码的热替换。

在OSGi环境下，类加载器不再是双亲委派模型中的树状结构，而是进一步发展为更加复杂的网状结构，当收到类加载请求时，OSGi将按照下面的顺序进行类搜索：

- 1) 将以java.*开头的类委派给父类加载器加载。
- 2) 否则，将委派列表名单内的类委派给父类加载器加载。
- 3) 否则，将Import列表中的类委派给Export这个类的Bundle的类加载器加载。
- 4) 否则，查找当前Bundle的ClassPath，使用自己的类加载器加载。

5) 否则，查找类是否在自己的Fragment Bundle中，如果在，则委派给Fragment Bundle的类加载器加载。

6) 否则，查找Dynamic Import列表的Bundle，委派给对应Bundle的类加载器加载。

7) 否则，类查找失败。

上面的查找顺序中只有开头两点仍然符合双亲委派规则，其余的类查找都是在平级的类加载器中进行的。

笔者虽然使用了“被破坏”这个词来形容上述不符合双亲委派模型原则的行为，但这里“被破坏”并不带有贬义的感情色彩。只要有足够意义和理由，突破已有的原则就可认为是一种创新。

正如OSGi中的类加载器并不符合传统的双亲委派的类加载器，并且业界对其为了实现热部署而带来的额外的高复杂度还存在不少争议，但在Java程序员中基本有一个共识：OSGi中对类加载器的使用是很值得学习的，弄懂了OSGi的实现，就可以算是掌握了类加载器的精髓。

[1]JSR-294: Improved Modularity Support in the Java Programming Language (Java编程语言中的改进模块性支持)。

[2]JSR-277: Java Module System (Java模块系统)。

[3]如果读者对Java模块化之争或者OSGi本身感兴趣，可以阅读笔者的另一本书《深入理解OSGi：Equinox原理、应用与最佳实践》。

7.5 本章小结

本章介绍了类加载过程的“加载”、“验证”、“准备”、“解析”和“初始化”5个阶段中虚拟机进行了哪些动作，还介绍了类加载器的工作原理及其对虚拟机的意义。

经过第6和第7两章的讲解，相信读者已经对如何在Class文件中定义类，如何将类加载到虚拟机中这两个问题有了比较系统的了解，第8章我们将一起来看看虚拟机如何执行定义在Class文件里的字节码。

第8章 虚拟机字节码执行引擎

代码编译的结果从本地机器码转变为字节码，是存储格式发展的一小步，却是编程语言发展的一大步。

8.1 概述

执行引擎是Java虚拟机最核心的组成部分之一。“虚拟机”是一个相对于“物理机”的概念，这两种机器都有代码执行能力，其区别是物理机的执行引擎是直接建立在处理器、硬件、指令集和操作系统层面上的，而虚拟机的执行引擎则是由自己实现的，因此可以自行制定指令集与执行引擎的结构体系，并且能够执行那些不被硬件直接

支持的指令集格式。

在Java虚拟机规范中制定了虚拟机字节码执行引擎的概念模型，这个概念模型成为各种虚拟机执行引擎的统一外观（Facade）。在不同的虚拟机实现里面，执行引擎在执行Java代码的时候可能会有解释执行（通过解释器执行）和编译执行（通过即时编译器产生本地代码执行）两种选择^[1]，也可能两者兼备，甚至还可能会包含几个不同级别的编译器执行引擎。但从外观上看起来，所有的Java虚拟机的执行引擎都是一致的：输入的是字节码文件，处理过程是字节码解析的等效过程，输出的是执行结果，本章将主要从概念模型的角度来讲解虚拟机的方法调用和字节码执行。

[1]有一些虚拟机（如Sun Classic VM）的内部只存在解释器，只能解释执行，而另外一些虚拟机（如BEA JRockit）的内部只存在即时编译器，只能编译执行。

8.2 运行时栈帧结构

栈帧（Stack Frame）是用于支持虚拟机进行方法调用和方法执行的数据结构，它是虚拟机运行时数据区中的虚拟机栈（Virtual Machine Stack）^[1]的栈元素。栈帧存储了方法的局部变量表、操作数栈、动态连接和方法返回地址等信息。每一个方法从调用开始至执行完成的过程，都对应着一个栈帧在虚拟机栈里面从入栈到出栈的过程。

每一个栈帧都包括了局部变量表、操作数栈、动态连接、方法返回地址和一些额外的附加信息。在编译程序代码的时候，栈帧中需要多大的局部变量表，多深的操作数栈都已经完全确定

了，并且写入到方法表的Code属性之中^[2]，因此一个栈帧需要分配多少内存，不会受到程序运行期变量数据的影响，而仅仅取决于具体的虚拟机实现。

一个线程中的方法调用链可能会很长，很多方法都同时处于执行状态。对于执行引擎来说，在活动线程中，只有位于栈顶的栈帧才是有效的，称为当前栈帧（Current Stack Frame），与这个栈帧相关联的方法称为当前方法（Current Method）。执行引擎运行的所有字节码指令都只针对当前栈帧进行操作，在概念模型上，典型的栈帧结构如图8-1所示。




图 8-1 栈帧的概念结构

接下来详细讲解一下栈帧中的局部变量表、操作数栈、动态连接、方法返回地址等各个部分

的作用和数据结构。

8.2.1 局部变量表

局部变量表（Local Variable Table）是一组变量值存储空间，用于存放方法参数和方法内部定义的局部变量。在Java程序编译为Class文件时，就在方法的Code属性的max_locals数据项中确定了该方法所需要分配的局部变量表的最大容量。

局部变量表的容量以变量槽（Variable Slot，下称Slot）为最小单位，虚拟机规范中并没有明确指明一个Slot应占用的内存空间大小，只是很有导向性地说到每个Slot都应该能存放一个boolean、byte、char、short、int、float、reference或returnAddress类型的数据，这8种数据类型，都

可以使用32位或更小的物理内存来存放，但这种描述与明确指出“每个Slot占用32位长度的内存空间”是有一些差别的，它允许Slot的长度可以随着处理器、操作系统或虚拟机的不同而发生变化。只要保证即使在64位虚拟机中使用了64位的物理内存空间去实现一个Slot，虚拟机仍要使用对齐和补白的手段让Slot在外观上看起来与32位虚拟机中的一致。

既然前面提到了Java虚拟机的数据类型，在此再简单介绍一下它们。一个Slot可以存放一个32位以内的数据类型，Java中占用32位以内的数据类型有boolean、byte、char、short、int、float、reference^[3]和returnAddress 8种类型。前面6种不需要多加解释，读者可以按照Java语言中对应数据类型的概念去理解它们（仅是这样理解而已，

Java语言与Java虚拟机中的基本数据类型是存在本质差别的），而第7种reference类型表示对一个对象实例的引用，虚拟机规范既没有说明它的长度，也没有明确指出这种引用应有怎样的结构。但一般来说，虚拟机实现至少都应当能通过这个引用做到两点，一是从此引用中直接或间接地查找到对象在Java堆中的数据存放的起始地址索引，二是此引用中直接或间接地查找到对象所属数据类型在方法区中的存储的类型信息，否则无法实现Java语言规范中定义的语法约束约束^[4]。第8种即returnAddress类型目前已经很少见了，它是为字节码指令jsr、jsr_w和ret服务的，指向了一条字节码指令的地址，很古老的Java虚拟机曾经使用这几条指令来实现异常处理，现在已经由异常表代替。

对于64位的数据类型，虚拟机会以高位对齐的方式为其分配两个连续的Slot空间。Java语言中明确的（reference类型则可能是32位也可能是64位）64位的数据类型只有long和double两种。值得一提的是，这里把long和double数据类型分割存储的做法与“long和double的非原子性协定”中把一次long和double数据类型读写分割为两次32位读写的做法有些类似，读者阅读到Java内存模型时可以互相对比一下。不过，由于局部变量表建立在线程的堆栈上，是线程私有的数据，无论读写两个连续的Slot是否为原子操作，都不会引起数据安全问题^[5]。

虚拟机通过索引定位的方式使用局部变量表，索引值的范围是从0开始至局部变量表最大的Slot数量。如果访问的是32位数据类型的变

量，索引n就代表了使用第n个Slot，如果是64位数据类型的变量，则说明会同时使用n和n+1两个Slot。对于两个相邻的共同存放一个64位数据的两个Slot，不允许采用任何方式单独访问其中的某一个，Java虚拟机规范中明确要求了如果遇到进行这种操作的字节码序列，虚拟机应该在类加载的校验阶段抛出异常。

在方法执行时，虚拟机是使用局部变量表完成参数值到参数变量列表的传递过程的，如果执行的是实例方法（非static的方法），那局部变量表中第0位索引的Slot默认是用于传递方法所属对象实例的引用，在方法中可以通过关键字“this”来访问到这个隐含的参数。其余参数则按照参数表顺序排列，占用从1开始的局部变量Slot，参数表分配完毕后，再根据方法体内部定义的变量顺序

和作用域分配其余的Slot。

为了尽可能节省栈帧空间，局部变量表中的Slot是可以重用的，方法体中定义的变量，其作用域并不一定会覆盖整个方法体，如果当前字节码PC计数器的值已经超出了某个变量的作用域，那这个变量对应的Slot就可以交给其他变量使用。不过，这样的设计除了节省栈帧空间以外，还会伴随一些额外的副作用，例如，在某些情况下，Slot的复用会直接影响到系统的垃圾收集行为，请看代码清单8-1~代码清单8-3的3个演示。

代码清单8-1 局部变量表Slot复用对垃圾收集的影响之一

```
public static void main (String[] args) () {  
byte[] placeholder=new byte[64*1024*1024];  
System.gc () ;
```

}

代码清单8-1中的代码很简单，即向内存填充了64MB的数据，然后通知虚拟机进行垃圾收集。我们在虚拟机运行参数中加上“-verbose:gc”来看看垃圾收集的过程，发现在System.gc（）运行后并没有回收这64MB的内存，下面是运行的结果：

```
[GC 66846K->65824K (125632K), 0.0032678  
secs]  
[Full GC 65824K->65746K (125632K),  
0.0064131 secs]
```

没有回收placeholder所占的内存能说得过去，因为在执行System.gc（）时，变量placeholder还处于作用域之内，虚拟机自然不敢回收placeholder的内存。那我们把代码修改一

下，变成代码清单8-2中的样子。

代码清单8-2 局部变量表Slot复用对垃圾收集的影响之二

```
public static void main (String[]args) () {  
{  
byte[]placeholder=new byte[64*1024*1024];  
}  
System.gc ();  
}
```

加入了花括号之后，placeholder的作用域被限制在花括号之内，从代码逻辑上讲，在执行System.gc () 的时候，placeholder已经不可能再被访问了，但执行一下这段程序，会发现运行结果如下，还是有64MB的内存没有被回收，这又是为什么呢？

[GC 66846K->65888K (125632K), 0.0009397

```
secs]  
[Full GC 65888K->65746K (125632K),  
0.0051574 secs]
```

在解释为什么之前，我们先对这段代码进行第二次修改，在调用System.gc（）之前加入一行“int a=0; ”，变成代码清单8-3的样子。

代码清单8-3 局部变量表Slot复用对垃圾收集的影响之三

```
public static void main (String [] args) {  
{  
byte [] placeholder = new byte [64 * 1024 * 1024];  
}  
int a = 0;  
System.gc ();  
}
```

这个修改看起来很莫名其妙，但运行一下程序，却发现这次内存真的被正确回收了。

```
[GC 66401K->65778K (125632K), 0.0035471  
secs]  
[Full GC 65778K->218K (125632K), 0.0140596  
secs]
```

在代码清单8-1~代码清单8-3中，placeholder能否被回收的根本原因是：局部变量表中的Slot是否还存有关于placeholder数组对象的引用。第一次修改中，代码虽然已经离开了placeholder的作用域，但在此之后，没有任何对局部变量表的读写操作，placeholder原本所占用的Slot还没有被其他变量所复用，所以作为GC Roots一部分的局部变量表仍然保持着对它的关联。这种关联没有被及时打断，在绝大部分情况下影响都很轻微。但如果遇到一个方法，其后面的代码有一些耗时很长的操作，而前面又定义了占用了大量内存、实际上已经不会再使用的变

量，手动将其设置为null值（用来代替那句int a=0，把变量对应的局部变量表Slot清空）便不见得是一个绝对无意义的操作，这种操作可以作为一种在极特殊情形（对象占用内存大、此方法的栈帧长时间不能被回收、方法调用次数达不到JIT的编译条件）下的“奇技”来使用。Java语言的一本非常著名的书籍《Practical Java》中把“不使用的对象应手动赋值为null”作为一条推荐的编码规则，但是并没有解释具体的原因，很长时间之内都有读者对这条规则感到疑惑。

虽然代码清单8-1～代码清单8-3的代码示例说明了赋null值的操作在某些情况下确实是有用的，但笔者的观点是不应当对赋null值的操作有过多的依赖，更没有必要把它当做一个普遍的编码规则来推广。原因有两点，从编码角度讲，以

恰当的变量作用域来控制变量回收时间才是最优雅的解决方法，如代码清单8-3那样的场景并不多见。更关键的是，从执行角度讲，使用赋null值的操作来优化内存回收是建立在对字节码执行引擎概念模型的理解之上的，在第6章介绍完字节码后，笔者专门增加了一个6.5节“公有设计、私有实现”来强调概念模型与实际执行过程是外部看起来等效，内部看上去则可以完全不同。在虚拟机使用解释器执行时，通常与概念模型还比较接近，但经过JIT编译器后，才是虚拟机执行代码的主要方式，赋null值的操作在经过JIT编译优化后就会被消除掉，这时候将变量设置为null就是没有意义的。字节码被编译为本地代码后，对GC Roots的枚举也与解释执行时期有巨大差别，以前面例子来看，代码清单8-2在经过JIT编译后，

System.gc() 执行时就可以正确地回收掉内存，无须写成代码清单8-3的样子。

关于局部变量表，还有一点可能会对实际开发产生影响，就是局部变量不像前面介绍的类变量那样存在“准备阶段”。通过第7章的讲解，我们已经知道类变量有两次赋初始值的过程，一次在准备阶段，赋予系统初始值；另外一次在初始化阶段，赋予程序员定义的初始值。因此，即使在初始化阶段程序员没有为类变量赋值也没有关系，类变量仍然具有一个确定的初始值。但局部变量就不一样，如果一个局部变量定义了但没有赋初始值是不能使用的，不要认为Java中任何情况下都存在诸如整型变量默认为0，布尔型变量默认为false等这样的默认值。如代码清单8-4所示，这段代码其实并不能运行，还好编译器能在

编译期间就检查到并提示这一点，即便编译能通过或者手动生成字节码的方式制造出下面代码的效果，字节码校验的时候也会被虚拟机发现而导致类加载失败。

代码清单8-4 未赋值的局部变量

```
public static void main (String[]args) {  
    int a;  
    System.out.println (a) ;  
}
```

[1]详细内容请参见2.2节的相关内容。

[2]详细内容请参见6.3.7节的相关内容。

[3]Java虚拟机规范中没有明确规定reference类型的长度，它的长度与实际使用32还是64位虚拟机有关，如果是64位虚拟机，还与是否开启某些对象指针压缩的优化有关，这里暂且只取32位虚拟机

的reference长度。

[4]并不是所有语言的对象引用都能满足这两点，例如C++语言，默认情况下（不开启RTTI支持的情况），就只能满足第一点，而不满足第二点。这也是为何C++中提供Java语言里很常见的反射的根本原因。

[5]这是Java内存模型中定义的内容，关于原子操作与“long和double的非原子性协定”等问题，将在本书第12章中详细讲解。

8.2.2 操作数栈

操作数栈（Operand Stack）也常称为操作栈，它是一个后入先出（Last In First Out,LIFO）栈。同局部变量表一样，操作数栈的最大深度也在编译的时候写入到Code属性的max_stacks数据项中。操作数栈的每一个元素可以是任意的Java数据类型，包括long和double。32位数据类型所占的栈容量为1，64位数据类型所占的栈容量为2。在方法执行的任何时候，操作数栈的深度都不会超过在max_stacks数据项中设定的最大值。

当一个方法刚刚开始执行的时候，这个方法的操作数栈是空的，在方法的执行过程中，会有各种字节码指令往操作数栈中写入和提取内容，

也就是出栈/入栈操作。例如，在做算术运算的时候是通过操作数栈来进行的，又或者在调用其他方法的时候是通过操作数栈来进行参数传递的。

举个例子，整数加法的字节码指令iadd在运行的时候操作数栈中最接近栈顶的两个元素已经存入了两个int型的数值，当执行这个指令时，会将这两个int值出栈并相加，然后将相加的结果入栈。

操作数栈中元素的数据类型必须与字节码指令的序列严格匹配，在编译程序代码的时候，编译器要严格保证这一点，在类校验阶段的数据流分析中还要再次验证这一点。再以上面的iadd指令为例，这个指令用于整型数加法，它在执行时，最接近栈顶的两个元素的数据类型必须为int

型，不能出现一个long和一个float使用iadd命令相加的情况。

另外，在概念模型中，两个栈帧作为虚拟机栈的元素，是完全相互独立的。但在大多虚拟机的实现里都会做一些优化处理，令两个栈帧出现一部分重叠。让下面栈帧的部分操作数栈与上面栈帧的部分局部变量表重叠在一起，这样在进行方法调用时就可以共用一部分数据，无须进行额外的参数复制传递，重叠的过程如图8-2所示。




图 8-2 两个栈帧之间的数据共享

Java虚拟机的解释执行引擎称为“基于栈的执行引擎”，其中所指的“栈”就是操作数栈。本章稍后会对基于栈的代码过程进行更详细的讲解。

8.2.3 动态连接

每个栈帧都包含一个指向运行时常量池^[1]中该栈帧所属方法的引用，持有这个引用是为了支持方法调用过程中的动态连接（Dynamic Linking）。通过第6章的讲解，我们知道Class文件的常量池中存有大量的符号引用，字节码中的方法调用指令就以常量池中指向方法的符号引用作为参数。这些符号引用一部分会在类加载阶段或者第一次使用的时候就转化为直接引用，这种转化称为静态解析。另外一部分将在每一次运行期间转化为直接引用，这部分称为动态连接。关于这两个转化过程的详细信息，将在8.3节中详细讲解。

[1]运行时常量池可参考第2章。

8.2.4 方法返回地址

当一个方法开始执行后，只有两种方式可以退出这个方法。第一种方式是执行引擎遇到任意一个方法返回的字节码指令，这时候可能会有返回值传递给上层的方法调用者（调用当前方法的方法称为调用者），是否有返回值和返回值的类型将根据遇到何种方法返回指令来决定，这种退出方法的方式称为正常完成出口（Normal Method Invocation Completion）。

另外一种退出方式是，在方法执行过程中遇到了异常，并且这个异常没有在方法体内得到处理，无论是Java虚拟机内部产生的异常，还是代码中使用`athrow`字节码指令产生的异常，只要在

本方法的异常表中没有搜索到匹配的异常处理器，就会导致方法退出，这种退出方法的方式称为异常完成出口（Abrupt Method Invocation Completion）。一个方法使用异常完成出口的方式退出，是不会给它的上层调用者产生任何返回值的。

无论采用何种退出方式，在方法退出之后，都需要返回到方法被调用的位置，程序才能继续执行，方法返回时可能需要在栈帧中保存一些信息，用来帮助恢复它的上层方法的执行状态。一般来说，方法正常退出时，调用者的PC计数器的值可以作为返回地址，栈帧中很可能会保存这个计数器值。而方法异常退出时，返回地址是要通过异常处理器表来确定的，栈帧中一般不会保存这部分信息。

方法退出的过程实际上就等同于把当前栈帧出栈，因此退出时可能执行的操作有：恢复上层方法的局部变量表和操作数栈，把返回值（如果有的话）压入调用者栈帧的操作数栈中，调整PC计数器的值以指向方法调用指令后面的一条指令等。

8.2.5 附加信息

虚拟机规范允许具体的虚拟机实现增加一些规范里没有描述的信息到栈帧之中，例如与调试相关的信息，这部分信息完全取决于具体的虚拟机实现，这里不再详述。在实际开发中，一般会把动态连接、方法返回地址与其他附加信息全部归为一类，称为栈帧信息。

8.3 方法调用

方法调用并不等同于方法执行，方法调用阶段唯一的任务就是确定被调用方法的版本（即调用哪一个方法），暂时还不涉及方法内部的具体运行过程。在程序运行时，进行方法调用是最普遍、最频繁的操作，但前面已经讲过，Class文件的编译过程中不包含传统编译中的连接步骤，一切方法调用在Class文件里面存储的都只是符号引用，而不是方法在实际运行时内存布局中的入口地址（相当于之前说的直接引用）。这个特性给Java带来了更强大的动态扩展能力，但也使得Java方法调用过程变得相对复杂起来，需要在类加载期间，甚至到运行期间才能确定目标方法的直接引用。

8.3.1 解析

继续前面关于方法调用的话题，所有方法调用中的目标方法在Class文件里面都是一个常量池中的符号引用，在类加载的解析阶段，会将其中的一部分符号引用转化为直接引用，这种解析能成立的前提是：方法在程序真正运行之前就有一个可确定的调用版本，并且这个方法的调用版本在运行期是不可改变的。换句话说，调用目标在程序代码写好、编译器进行编译时就必须确定下来。这类方法的调用称为解析（Resolution）。

在Java语言中符合“编译期可知，运行期不可变”这个要求的方法，主要包括静态方法和私有方法两大类，前者与类型直接关联，后者在外部

不可被访问，这两种方法各自的特点决定了它们都不可能通过继承或别的方式重写其他版本，因此它们都适合在类加载阶段进行解析。

与之相对应的是，在Java虚拟机里面提供了5条方法调用字节码指令，分别如下。

invokestatic: 调用静态方法。

invokespecial: 调用实例构造器<init>方法、私有方法和父类方法。

invokevirtual: 调用所有的虚方法。

invokeinterface: 调用接口方法，会在运行时再确定一个实现此接口的对象。

invokedynamic: 先在运行时动态解析出调用

点限定符所引用的方法，然后再执行该方法，在此之前的4条调用指令，分派逻辑是固化在Java虚拟机内部的，而invokedynamic指令的分派逻辑是由用户所设定的引导方法决定的。

只要能被invokestatic和invokespecial指令调用的方法，都可以在解析阶段中确定唯一的调用版本，符合这个条件的有静态方法、私有方法、实例构造器、父类方法4类，它们在类加载的时候就会把符号引用解析为该方法的直接引用。这些方法可以称为非虚方法，与之相反，其他方法称为虚方法（除去final方法，后文会提到）。代码清单8-5演示了一个最常见的解析调用的例子，此样例中，静态方法sayHello（）只可能属于类型StaticResolution，没有任何手段可以覆盖或隐藏这个方法。

代码清单8-5 方法静态解析演示

```
/**  
 *方法静态解析演示  
 *  
 *@author zzm  
 */  
public class StaticResolution{  
    public static void sayHello () {  
        System.out.println ("hello world");  
    }  
    public static void main (String[]args) {  
        StaticResolution.sayHello ();  
    }  
}
```

使用javap命令查看这段程序的字节码，会发现的确是通过invokestatic命令来调用sayHello（）方法的。

```
D: \Develop\>javap -verbose StaticResolution  
public static void  
main (java.lang.String[]);  
Code:  
Stack=0, Locals=1, Args_size=1
```

```
0: invokestatic#31; //Method sayHello: () V
3: return
LineNumberTable:
line 15: 0
line 16: 3
```

Java中的非虚方法除了使用invokestatic、invokespecial调用的方法之外还有一种，就是被final修饰的方法。虽然final方法是使用invokevirtual指令来调用的，但是由于它无法被覆盖，没有其他版本，所以也无须对方法接收者进行多态选择，又或者说多态选择的结果肯定是唯一的。在Java语言规范中明确说明了final方法是一种非虚方法。

解析调用一定是个静态的过程，在编译期间就完全确定，在类装载的解析阶段就会把涉及的符号引用全部转变为可确定的直接引用，不会延

迟到运行期再去完成。而分派（Dispatch）调用则可能是静态的也可能是动态的，根据分派依据的宗量数^[1]可分为单分派和多分派。这两类分派方式的两两组合就构成了静态单分派、静态多分派、动态单分派、动态多分派4种分派组合情况，下面我们再看看虚拟机中的方法分派是如何进行的。

[1]这里涉及的分派的相关概念（如“宗量”等）在后文中都会有所解释。

8.3.2 分派

众所周知，Java是一门面向对象的程序语言，因为Java具备面向对象的3个基本特征：继承、封装和多态。本节讲解的分派调用过程将会揭示多态性特征的一些最基本的体现，如“重载”和“重写”在Java虚拟机之中是如何实现的，这里的实现当然不是语法上该如何写，我们关心的依然是虚拟机如何确定正确的目标方法。

1. 静态分派

在开始讲解静态分派^[1]前，笔者准备了一段经常出现在面试题中的程序代码，读者不妨先看一遍，想一下程序的输出结果是什么。后面我们

的话题将围绕这个类的方法来重载（Overload）代码，以分析虚拟机和编译器确定方法版本的过程。方法静态分派如代码清单8-6所示。

代码清单8-6 方法静态分派演示

```
package org.fenixsoft.polymorphic;
/**
 *方法静态分派演示
 *@author zzm
 */
public class StaticDispatch{
    static abstract class Human{
    }
    static class Man extends Human{
    }
    static class Woman extends Human{
    }
    public void sayHello (Human guy) {
        System.out.println ("hello,guy! ");
    }
    public void sayHello (Man guy) {
        System.out.println ("hello,gentleman! ");
    }
    public void sayHello (Woman guy) {
        System.out.println ("hello,lady! ");
    }
    public static void main (String[]args) {
```

```
Human man=new Man () ;  
Human woman=new Woman () ;  
StaticDispatch sr=new StaticDispatch () ;  
sr.sayHello (man) ;  
sr.sayHello (woman) ;  
}  
}
```

运行结果：

```
hello,guy!  
hello,guy!
```

代码清单8-6中的代码实际上是在考验阅读者对重载的理解程度，相信对Java编程稍有经验的程序员看完程序后都能得出正确的运行结果，但为什么会选择执行参数类型为Human的重载呢？在解决这个问题之前，我们先按如下代码定义两个重要的概念。

```
Human man=new Man () ;
```

我们把上面代码中的“Human”称为变量的静态类型（Static Type），或者叫做的外观类型（Apparent Type），后面的“Man”则称为变量的实际类型（Actual Type），静态类型和实际类型在程序中都可以发生一些变化，区别是静态类型的变化仅仅在使用时发生，变量本身的静态类型不会被改变，并且最终的静态类型是在编译期可知的；而实际类型变化的结果在运行期才可确定，编译器在编译程序的时候并不知道一个对象的实际类型是什么。例如下面的代码：

```
//实际类型变化
Human man=new Man();
man=new Woman();
//静态类型变化
sr.sayHello( (Man) man)
sr.sayHello( (Woman) man)
```

解释了这两个概念，再回到代码清单8-6的样

例代码中。`main()` 里面的两次`sayHello()` 方法调用，在方法接收者已经确定是对象“sr”的前提下，使用哪个重载版本，就完全取决于传入参数的数量和数据类型。代码中刻意地定义了两个静态类型相同但实际类型不同的变量，但虚拟机（准确地说是编译器）在重载时是通过参数的静态类型而不是实际类型作为判定依据的。并且静态类型是编译期可知的，因此，在编译阶段，Javac编译器会根据参数的静态类型决定使用哪个重载版本，所以选择了`sayHello(Human)` 作为调用目标，并把这个方法的符号引用写到`main()` 方法里的两条`invokevirtual` 指令的参数中。

所有依赖静态类型来定位方法执行版本的分派动作称为静态分派。静态分派的典型应用是方法重载。静态分派发生在编译阶段，因此确定静

态分派的动作实际上不是由虚拟机来执行的。另外，编译器虽然能确定出方法的重载版本，但在很多情况下这个重载版本并不是“唯一的”，往往只能确定一个“更加合适的”版本。这种模糊的结论在由0和1构成的计算机世界中算是比较“稀罕”的事情，产生这种模糊结论的主要原因是字面量不需要定义，所以字面量没有显式的静态类型，它的静态类型只能通过语言上的规则去理解和推断。代码清单8-7演示了何为“更加合适的”版本。

代码清单8-7 重载方法匹配优先级

```
package org.fenixsoft.polymorphic;
public class Overload{
    public static void sayHello (Object arg) {
        System.out.println ("hello Object");
    }
    public static void sayHello (int arg) {
        System.out.println ("hello int");
    }
}
```

```
}

public static void sayHello (long arg) {
System.out.println ("hello long") ;
}

public static void sayHello (Character arg)
{
System.out.println ("hello Character") ;
}

public static void sayHello (char arg) {
System.out.println ("hello char") ;
}

public static void sayHello (char.....arg) {
System.out.println ("hello char.....") ;
}

public static void sayHello (Serializable
arg) {
System.out.println ("hello Serializable") ;
}

public static void main (String[]args) {
sayHello ('a') ;
}
}
```

上面的代码运行后会输出：

hello char

这很好理解，'a'是一个char类型的数据，自

然会寻找参数类型为char的重载方法，如果注释掉sayHello (char arg) 方法，那输出会变为：

```
hello int
```

这时发生了一次自动类型转换，'a'除了可以代表一个字符串，还可以代表数字97（字符'a'的Unicode数值为十进制数字97），因此参数类型为int的重载也是合适的。我们继续注释掉sayHello (int arg) 方法，那输出会变为：

```
hello long
```

这时发生了两次自动类型转换，'a'转型为整数97之后，进一步转型为长整数97L，匹配了参数类型为long的重载。笔者在代码中没有写其他的类型如float、double等的重载，不过实际上自

动转型还能继续发生多次，按照char->int->long->float->double的顺序转型进行匹配。但不会匹配到byte和short类型的重载，因为char到byte或short的转型是不安全的。我们继续注释掉sayHello（long arg）方法，那输出会变为：

```
hello Character
```

这时发生了一次自动装箱，'a'被包装为它的封装类型java.lang.Character，所以匹配到了参数类型为Character的重载，继续注释掉sayHello（Character arg）方法，那输出会变为：

```
hello Serializable
```

这个输出可能会让人感觉摸不着头脑，一个字符或数字与序列化有什么关系？出现hello

Serializable，是因为java.lang.Serializable是java.lang.Character类实现的一个接口，当自动装箱之后发现还是找不到装箱类，但是找到了装箱类实现了的接口类型，所以紧接着又发生一次自动转型。char可以转型成int，但是Character是绝对不会转型为Integer的，它只能安全地转型为它实现的接口或父类。Character还实现了另外一个接口java.lang.Comparable<Character>，如果同时出现两个参数分别为Serializable和Comparable<Character>的重载方法，那它们在此时的优先级是一样的。编译器无法确定要自动转型为哪种类型，会提示类型模糊，拒绝编译。程序必须在调用时显式地指定字面量的静态类型，如：

sayHello ((Comparable<Character>) 'a')，才能编译通过。下面继续注释掉

sayHello (Serializable arg) 方法，输出会变为：

hello Object

这时是char装箱后转型为父类了，如果有多个父类，那将在继承关系中从下往上开始搜索，越接近上层的优先级越低。即使方法调用传入的参数值为null时，这个规则仍然适用。我们把sayHello (Object arg) 也注释掉，输出将会变为：

hello char.....

7个重载方法已经被注释得只剩一个了，可见变长参数的重载优先级是最低的，这时候字符'a'被当做了数组元素。笔者使用的是char类型的变长参数，读者在验证时还可以选择int类

型、Character类型、Object类型等的变长参数重载来把上面的过程重新演示一遍。但要注意的是，有一些在单个参数中能成立的自动转型，如char转型为int，在变长参数中是不成立的^[2]。

代码清单8-7演示了编译期间选择静态分派目标的过程，这个过程也是Java语言实现方法重载的本质。演示所用的这段程序属于很极端的例子，除了用做面试题为难求职者以外，在实际工作中几乎不可能有实际用途。笔者拿来做演示仅仅是用于讲解重载时目标方法选择的过程，大部分情况下进行这样极端的重载都可算是真正的“关于茴香豆的茴有几种写法的研究”。无论对重载的认识有多么深刻，一个合格的程序员都不应该在实际应用中写出如此极端的重载代码。

另外还有一点读者可能比较容易混淆：笔者讲述的解析与分派这两者之间的关系并不是二选一的排他关系，它们是在不同层次上去筛选、确定目标方法的过程。例如，前面说过，静态方法会在类加载期就进行解析，而静态方法显然也是可以拥有重载版本的，选择重载版本的过程也是通过静态分派完成的。

2. 动态分派

了解了静态分派，我们接下来看一下动态分派的过程，它和多态性的另外一个重要体现^[3]——重写（Override）有着很密切的关联。我们还是用前面的Man和Woman一起sayHello的例子来讲解动态分派，请看代码清单8-8中所示的代码。

代码清单8-8 方法动态分派演示

```
package org.fenixsoft.polymorphic;
/**
 *方法动态分派演示
 *@author zzm
 */
public class DynamicDispatch{
    static abstract class Human{
        protected abstract void sayHello () ;
    }
    static class Man extends Human{
        @Override
        protected void sayHello () {
            System.out.println ("man say hello") ;
        }
    }
    static class Woman extends Human{
        @Override
        protected void sayHello () {
            System.out.println ("woman say hello") ;
        }
    }
    public static void main (String[]args) {
        Human man=new Man () ;
        Human woman=new Woman () ;
        man.sayHello () ;
        woman.sayHello () ;
        man=new Woman () ;
        man.sayHello () ;
    }
}
```

运行结果：

```
man say hello  
woman say hello  
woman say hello
```

这个运行结果相信不会出乎任何人的意料，对于习惯了面向对象思维的Java程序员会觉得这是完全理所当然的。现在的问题还是和前面的一样，虚拟机是如何知道要调用哪个方法的？

显然这里不可能再根据静态类型来决定，因为静态类型同样都是Human的两个变量man和woman在调用sayHello（）方法时执行了不同的行为，并且变量man在两次调用中执行了不同的方法。导致这个现象的原因很明显，是这两个变量的实际类型不同，Java虚拟机是如何根据实际

类型来分派方法执行版本的呢？我们使用javap命令输出这段代码的字节码，尝试从中寻找答案，输出结果如代码清单8-9所示。

代码清单8-9 main（）方法的字节码

```
public static void
main (java.lang.String[]) ;
Code:
Stack=2, Locals=3, Args_size=1
0: new#16; //class
org/fenixsoft/polymorphic/Dynamic-
Dispatch $Man
3: dup
4: invokespecial#18; //Method
org/fenixsoft/polymorphic/Dynamic-
Dispatch $Man."<init>": () V
7: astore_1
8: new#19; //class
org/fenixsoft/polymorphic/Dynamic-
Dispatch $Woman
11: dup
12: invokespecial#21; //Method
org/fenixsoft/polymorphic/DynamicDispa-
tch $Woman."<init>": () V
15: astore_2
16: aload_1
17: invokevirtual#22; //Method
```

```
org/fenixsoft/polymorphic/Dynamic-
    Dispatch $Human.sayHello: () V
20: aload_2
21: invokevirtual#22; //Method
org/fenixsoft/polymorphic/Dynamic-
    Dispatch $Human.sayHello: () V
24: new#19; //class
org/fenixsoft/polymorphic/Dynamic-
    Dispatch $Woman
27: dup
28: invokespecial#21; //Method
org/fenixsoft/polymorphic/Dynam
    icDispatch $Woman."<init>": () V
31: astore_1
32: aload_1
33: invokevirtual#22; //Method
org/fenixsoft/polymorphic/
    DynamicDispatch $Human.sayHello: () V
36: return
```

0~15行的字节码是准备动作，作用是建立man和woman的内存空间、调用Man和Woman类型的实例构造器，将这两个实例的引用存放在第1、2个局部变量表Slot之中，这个动作也就对应了代码中的这两句：

```
Human man=new Man();  
Human woman=new Woman();
```

接下来的16~21句是关键部分，16、20两句分别把刚刚创建的两个对象的引用压到栈顶，这两个对象是将要执行的sayHello（）方法的所有者，称为接收者（Receiver）；17和21句是方法调用指令，这两条调用指令单从字节码角度来看，无论是指令（都是invokevirtual）还是参数（都是常量池中第22项的常量，注释显示了这个常量是Human.sayHello（）的符号引用）完全一样的，但是这两句指令最终执行的目标方法并不相同。原因就需要从invokevirtual指令的多态查找过程开始说起，invokevirtual指令的运行时解析过程大致分为以下几个步骤：

- 1) 找到操作数栈顶的第一个元素所指向的

对象的实际类型，记作C。

2) 如果在类型C中找到与常量中的描述符和简单名称都相符的方法，则进行访问权限校验，如果通过则返回这个方法的直接引用，查找过程结束；如果不通过，则返回
`java.lang.IllegalAccessError`异常。

3) 否则，按照继承关系从下往上依次对C的各个父类进行第2步的搜索和验证过程。

4) 如果始终没有找到合适的方法，则抛出
`java.lang.AbstractMethodError`异常。

由于`invokevirtual`指令执行的第一步就是在运行期确定接收者的实际类型，所以两次调用中的`invokevirtual`指令把常量池中的类方法符号引用解

析到了不同的直接引用上，这个过程就是Java语言中方法重写的本质。我们把这种在运行期根据实际类型确定方法执行版本的分派过程称为动态分派。

3. 单分派与多分派

方法的接收者与方法的参数统称为方法的宗量，这个定义最早应该来源于《Java与模式》一书。根据分派基于多少种宗量，可以将分派划分为单分派和多分派两种。单分派是根据一个宗量对目标方法进行选择，多分派则是根据多个宗量对目标方法进行选择。

单分派和多分派的定义读起来拗口，从字面上看也比较抽象，不过对照着实例看就不难理解了。代码清单8-10中列举了一个Father和Son一起

来做出“一个艰难的决定”的例子。

代码清单8-10 单分派和多分派

```
/*
 *单分派、多分派演示
 *@author zzm
 */
public class Dispatch{
    static class QQ{}
    static class _360{}
    public static class Father{
        public void hardChoice (QQ arg) {
            System.out.println ("father choose qq") ;
        }
        public void hardChoice (_360 arg) {
            System.out.println ("father choose 360") ;
        }
    }
    public static class Son extends Father{
        public void hardChoice (QQ arg) {
            System.out.println ("son choose qq") ;
        }
        public void hardChoice (_360 arg) {
            System.out.println ("son choose 360") ;
        }
    }
    public static void main (String[]args) {
        Father father=new Father () ;
        Father son=new Son () ;
        father.hardChoice (new _360 ()) ;
```

```
son.hardChoice (new QQ () ) ;  
}  
}
```

运行结果：

```
father choose 360  
son choose qq
```

在main函数中调用了两次hardChoice（）方法，这两次hardChoice（）方法的选择结果在程序输出中已经显示得很清楚了。

我们来看看编译阶段编译器的选择过程，也就是静态分派的过程。这时选择目标方法的依据有两点：一是静态类型是Father还是Son，二是方法参数是QQ还是360。这次选择结果的最终产物是产生了两条invokevirtual指令，两条指令的参数分别为常量池中指向Father.hardChoice（360）及

Father.hardChoice (QQ) 方法的符号引用。因为是根据两个宗量进行选择，所以Java语言的静态分派属于多分派类型。

再看看运行阶段虚拟机的选择，也就是动态分派的过程。在执行“son.hardChoice (new QQ ())”这句代码时，更准确地说，是在执行这句代码所对应的invokevirtual指令时，由于编译期已经决定目标方法的签名必须为hardChoice (QQ)，虚拟机此时不会关心传递过来的参数“QQ”到底是“腾讯QQ”还是“奇瑞QQ”，因为这时参数的静态类型、实际类型都对方法的选择不会构成任何影响，唯一可以影响虚拟机选择的因素只有此方法的接受者的实际类型是Father还是Son。因为只有一个宗量作为选择依据，所以Java语言的动态分派属于单分派类型。

根据上述论证的结果，我们可以总结一句：今天（直至还未发布的Java 1.8）的Java语言是一门静态多分派、动态单分派的语言。强调“今天的Java语言”是因为这个结论未必会恒久不变，C#在3.0及之前的版本与Java一样是动态单分派语言，但在C#4.0中引入了dynamic类型后，就可以很方便地实现动态多分派。

按照目前Java语言的发展趋势，它并没有直接变为动态语言的迹象，而是通过内置动态语言（如JavaScript）执行引擎的方式来满足动态性的需求。但是Java虚拟机层面上则不是如此，在JDK 1.7中实现的JSR-292^[4]里面就已经开始提供对动态语言的支持了，JDK 1.7中新增的invokedynamic指令也成为了最复杂的一条方法调

用的字节码指令，稍后笔者将专门讲解这个JDK 1.7的新特性。

4. 虚拟机动态分派的实现

前面介绍的分派过程，作为对虚拟机概念模型的解析基本上已经足够了，它已经解决了虚拟机在分派中“会做什么”这个问题。但是虚拟机“具体是如何做到的”，可能各种虚拟机的实现都会有些差别。

由于动态分派是非常频繁的动作，而且动态分派的方法版本选择过程需要运行时在类的方法元数据中搜索合适的目标方法，因此在虚拟机的实际实现中基于性能的考虑，大部分实现都不会真正地进行如此频繁的搜索。面对这种情况，最常用的“稳定优化”手段就是为类在方法区中建立

一个虚方法表（Virtual Method Table，也称为vtable，与此对应的，在invokeinterface执行时也会用到接口方法表——Interface Method Table，简称itable），使用虚方法表索引来代替元数据查找以提高性能。我们先看看代码清单8-10所对应的虚方法表结构示例，如图8-3所示。




图 8-3 方法表结构

虚方法表中存放着各个方法的实际入口地址。如果某个方法在子类中没有被重写，那子类的虚方法表里面的地址入口和父类相同方法的地址入口是一致的，都指向父类的实现入口。如果子类中重写了这个方法，子类方法表中的地址将会替换为指向子类实现版本的入口地址。图8-3中，Son重写了来自Father的全部方法，因此Son的方法表没有指向Father类型数据的箭头。但是Son和Father都没有重写来自Object的方法，所以它们的方法表中所有从Object继承来的方法都指向了Object的数据类型。

为了程序实现上的方便，具有相同签名的方法，在父类、子类的虚方法表中都应当具有一样的索引序号，这样当类型变换时，仅需要变更查找的方法表，就可以从不同的虚方法表中按索引

转换出所需的入口地址。

方法表一般在类加载的连接阶段进行初始化，准备了类的变量初始值后，虚拟机会把该类的方法表也初始化完毕。

上文中笔者说方法表是分派调用的“稳定优化”手段，虚拟机除了使用方法表之外，在条件允许的情况下，还会使用内联缓存（Inline Cache）和基于“类型继承关系分析”（Class Hierarchy Analysis,CHA）技术的守护内联（Guarded Inlining）两种非稳定的“激进优化”手段来获得更高的性能，关于这两种优化技术的原理和运作过程，读者可以参考本书第11章中的相关内容。

[1]严格来说，Dispatch这个词一般不用在静态环

境之中，英文技术文档的称呼是“Method Overload Resolution”，但国内的各种资料都普遍将这种行为翻译成“静态分派”，特此说明。

[2]重载中选择最合适方法的过程，可参见Java语言规范的§ 15.12.2.5 Choosing the Most Specific Method章节。

[3]有一种观点认为：因为重载是静态的，重写是动态的，所以只有重写算是多态性的体现，重载不算多态。笔者认为这种争论没有意义，概念仅仅是说明问题的一种工具而已。

[4]JSR-292: Supporting Dynamically Typed Languages on the Java Platform (Java平台的动态语言支持)。

8.3.3 动态类型语言支持

Java虚拟机的字节码指令集的数量从Sun公司第一款Java虚拟机问世至JDK 7来临之前的十余年时间里，一直没有发生任何变化。随着JDK 7的发布，字节码指令集终于迎来了第一位新成员——invokedynamic指令。这条新增加的指令是JDK 7实现“动态类型语言”（Dynamically Typed Language）支持而进行的改进之一，也是为JDK 8可以顺利实现Lambda表达式做技术准备。在本节中，我们将详细讲解JDK 7这项新特性出现的前因后果和它的深远意义。

1. 动态类型语言

在介绍Java虚拟机的动态类型语言支持之前，我们要先弄明白动态类型语言是什么？它与Java语言、Java虚拟机有什么关系？了解JDK 1.7提供动态类型语言支持的技术背景，对理解这个语言特性是很有必要的。

什么是动态类型语言^[1]？动态类型语言的关键特征是它的类型检查的主体过程是在运行期而不是编译期，满足这个特征的语言有很多，常用的包括：APL、Clojure、Erlang、Groovy、JavaScript、Jython、Lisp、Lua、PHP、Prolog、Python、Ruby、Smalltalk和Tcl等。相对的，在编译期就进行类型检查过程的语言（如C++和Java等）就是最常用的静态类型语言。

觉得上面定义过于概念化？那我们不妨通过

两个例子以最浅显的方式来说明什么是“在编译期/运行期进行”和什么是“类型检查”。首先看下面这段简单的Java代码，它是否能正常编译和运行？

```
public static void main (String[]args) {  
    int[][][]array=new int[1][0][-1];  
}
```

这段代码能够正常编译，但运行的时候会报NegativeArraySizeException异常。在Java虚拟机规范中明确规定了NegativeArraySizeException是一个运行时异常，通俗一点来说，运行时异常就是只要代码不运行到这一行就不会有问题。与运行时异常相对应的是连接时异常，例如很常见的NoClassDefFoundError便属于连接时异常，即使会导致连接时异常的代码放在一条无法执行到的

分支路径上，类加载时（Java的连接过程不在编译阶段，而在类加载阶段）也照样会抛出异常。

不过，在C语言中，含义相同的代码会在编译期报错：

```
int main (void) {
    int i[1][0][-1]; //GCC拒绝编译，报“size of
array is negative”
    return 0;
}
```

由此看来，一门语言的哪一种检查行为要在运行期进行，哪一种检查要在编译期进行并没有必然的因果逻辑关系，关键是语言规范中人为规定的。再举一个例子来解释“类型检查”，例如下面这一句非常简单的代码：

```
obj.println ("hello world") ;
```

虽然每个人都能看懂这行代码要做什么，但对于计算机来说，这一行代码“没头没尾”是无法执行的，它需要一个具体的上下文才有讨论的意义。

现在假设这行代码是在Java语言中，并且变量obj的静态类型为java.io.PrintStream，那变量obj的实际类型就必须是PrintStream的子类（实现了PrintStream接口的类）才是合法的。否则，哪怕obj属于一个确实有用println（String）方法，但与PrintStream接口没有继承关系，代码依然不可能运行——因为类型检查不合法。

但是相同的代码在ECMAScript（JavaScript）中情况则不一样，无论obj具体是何种类型，只要这种类型的定义中确

实包含有println（String）方法，那方法调用便可成功。

这种差别产生的原因是Java语言在编译期间已将println（String）方法完整的符号引用（本例中为一个CONSTANT_InterfaceMethodref_info常量）生成出来，作为方法调用指令的参数存储到Class文件中，例如下面这段代码：

```
invokevirtual#4; //Method  
java/io/PrintStream.println:  
(Ljava/lang/String;)V
```

这个符号引用包含了此方法定义在哪个具体类型之中、方法的名字以及参数顺序、参数类型和方法返回值等信息，通过这个符号引用，虚拟机可以翻译出这个方法的直接引用。而在

ECMAScript等动态类型语言中，变量obj本身是没有类型的，变量obj的值才具有类型，编译时最多只能确定方法名称、参数、返回值这些信息，而不会去确定方法所在的具体类型（即方法接收者不固定）。“变量无类型而变量值才有类型”这个特点也是动态类型语言的一个重要特征。

了解了动态和静态类型语言的区别后，也许读者的下一个问题是动态、静态类型语言两者谁更好，或者谁更加先进？这种比较不会有确切答案，因为它们都有自己的优点，选择哪种语言是需要经过权衡的。静态类型语言在编译期确定类型，最显著的好处是编译器可以提供严谨的类型检查，这样与类型相关的问题能在编码的时候就及时发现，利于稳定性及代码达到更大规模。而动态类型语言在运行期确定类型，这可以为开

发人员提供更大的灵活性，某些在静态类型语言中需用大量“臃肿”代码来实现的功能，由动态类型语言来实现可能会更加清晰和简洁，清晰和简洁通常也就意味着开发效率的提升。

2.JDK 1.7与动态类型

回到本节的主题，来看看Java语言、虚拟机与动态类型语言之间有什么关系。Java虚拟机毫无疑问是Java语言的运行平台，但它的使命并不仅限于此，早在1997年出版的《Java虚拟机规范》中就规划了这样一个愿景：“在未来，我们会对Java虚拟机进行适当的扩展，以便更好地支持其他语言运行于Java虚拟机之上”。而目前确实已经有许多动态类型语言运行于Java虚拟机之上了，如Clojure、Groovy、Jython和JRuby等，能够

在同一个虚拟机上可以达到静态类型语言的严谨性与动态类型语言的灵活性，这是一件很美妙的事情。

但遗憾的是，Java虚拟机层面对动态类型语言的支持一直都有所欠缺，主要表现在方法调用方面：JDK 1.7以前的字节码指令集中，4条方法调用指令（`invokevirtual`、`invokespecial`、`invokestatic`、`invokeinterface`）的第一个参数都是被调用的方法的符号引用

（`CONSTANT_Methodref_info`或者
`CONSTANT_InterfaceMethodref_info`常量），前面已经提到过，方法的符号引用在编译时产生，而动态类型语言只有在运行期才能确定接收者类型。这样，在Java虚拟机上实现的动态类型语言就不得不使用其他方式（如编译时留个占位符类

型，运行时动态生成字节码实现具体类型到占位符类型的适配）来实现，这样势必让动态类型语言实现的复杂度增加，也可能带来额外的性能或者内存开销。尽管可以利用一些办法（如Call Site Caching）让这些开销尽量变小，但这种底层问题终归是应当在虚拟机层次上去解决才最合适，因此在Java虚拟机层面上提供动态类型的直接支持就成为了Java平台的发展趋势之一，这就是JDK 1.7（JSR-292）中invokedynamic指令以及java.lang.invoke包出现的技术背景。

3.java.lang.invoke包

JDK 1.7实现了JSR-292，新加入的java.lang.invoke包^[2]就是JSR-292的一个重要组成部分，这个包的主要目的是在之前单纯依靠符号

引用来确定调用的目标方法这种方式以外，提供一种新的动态确定目标方法的机制，称为 MethodHandle。这种表达方式也许不太好懂？那不妨把MethodHandle与C/C++中的Function Pointer，或者C#里面的Delegate类比一下。举个例子，如果我们要实现一个带谓词的排序函数，在C/C++中常用的做法是把谓词定义为函数，用函数指针把谓词传递到排序方法，如下：

```
void sort (int list[], const int size, int (*compare) (int, int))
```

但Java语言做不到这一点，即没有办法单独地把一个函数作为参数进行传递。普遍的做法是设计一个带有compare（）方法的Comparator接口，以实现了这个接口的对象作为参数，例如

Collections.sort() 就是这样定义的：

```
void sort (List list, Comparator c)
```

不过，在拥有Method Handle之后，Java语言也可以拥有类似于函数指针或者委托的方法别名的工具了。代码清单8-11演示了MethodHandle的基本用途，无论obj是何种类型（临时定义的ClassA抑或是实现PrintStream接口的实现类System.out），都可以正确地调用到println()方法。

代码清单8-11 MethodHandle演示

```
import static  
java.lang.invoke.MethodHandles.lookup;  
import java.lang.invoke.MethodHandle;  
import java.lang.invoke.MethodType;  
/**  
 * JSR-292 Method Handle基础用法演示
```

```
*@author zzm
*/
public class MethodHandleTest{
    static class ClassA{
        public void println (String s) {
            System.out.println (s) ;
        }
    }
    public static void main (String[]args)
throws Throwable{
    Object obj=System.currentTimeMillis ()
%2==0?System.out: new ClassA () ;
    /*无论obj最终是哪个实现类，下面这句都能正确调用到
println方法
    getPrintlnMH (obj) .invokeExact ("icyfenix") ;
}
    private static MethodHandle
getPrintlnMH (Object reveiver) throws Throwable{
    /*MethodType: 代表“方法类型”，包含了方法的返回值
(methodType () 的第一个参数) 和具体参数
(methodType () 第二个及以后的参数) */
    MethodType
mt=MethodType.methodType (void.class,String.clas
    /*lookup () 方法来自于MethodHandles.lookup，这
句的作用是在指定类中查找符合给定的方法名称、方法类型，并
且符合调用权限的方法句柄*/
    /*因为这里调用的是一个虚方法，按照Java语言的规则，
方法第一个参数是隐式的，代表该方法的接收者，也即是this指
向的对象，这个参数以前是放在参数列表中进行传递的，而现在
提供了bindTo () 方法来完成这件事情*/
    return
lookup () .findVirtual (reveiver.getClass () , "p
mt) .bindTo (reveiver) ;
}
```

}

实际上，方法getPrintlnMH（）中模拟了invokevirtual指令的执行过程，只不过它的分派逻辑并非固化在Class文件的字节码上，而是通过一个具体方法来实现。而这个方法本身的返回值（MethodHandle对象），可以视为对最终调用方法的一个“引用”。以此为基础，有了MethodHandle就可以写出类似于下面这样的函数声明：

```
void sort (List list, MethodHandle compare)
```

从上面的例子可以看出，使用MethodHandle并没有什么困难，不过看完它的用法之后，读者大概就会产生疑问，相同的事情，用反射不是早就可以实现了吗？

确实，仅站在Java语言的角度来看，MethodHandle的使用方法和效果与Reflection有众多相似之处，不过，它们还是有以下这些区别：

从本质上讲，Reflection和MethodHandle机制都是在模拟方法调用，但Reflection是在模拟Java代码层次的方法调用，而MethodHandle是在模拟字节码层次的方法调用。在MethodHandles.lookup中的3个方法——findStatic（）、findVirtual（）、findSpecial（）正是为了对应于invokestatic、invokevirtual&invokeinterface和invokespecial这几条字节码指令的执行权限校验行为，而这些底层细节在使用Reflection API时是不需要关心的。

Reflection中的java.lang.reflect.Method对象远

比MethodHandle机制中的
java.lang.invoke.MethodHandle对象所包含的信息
多。前者是方法在Java一端的全面映像，包含了
方法的签名、描述符以及方法属性表中各种属性
的Java端表示方式，还包含执行权限等的运行期
信息。而后者仅仅包含与执行该方法相关的信息。
用通俗的话来讲，Reflection是重量级，而
MethodHandle是轻量级。

由于MethodHandle是对字节码的方法指令调
用的模拟，所以理论上虚拟机在这方面做的各种
优化（如方法内联），在MethodHandle上也应当
可以采用类似思路去支持（但目前实现还不完
善）。而通过反射去调用方法则不行。

MethodHandle与Reflection除了上面列举的区

别外，最关键的一点还在于去掉前面讨论施加的前提“仅站在Java语言的角度来看”：Reflection API的设计目标是只为Java语言服务的，而MethodHandle则设计成可服务于所有Java虚拟机之上的语言，其中也包括Java语言。

4.invokedynamic指令

本节一开始就提到了JDK 1.7为了更好地支持动态类型语言，引入了第5条方法调用的字节码指令invokedynamic，之后一直没有再提到它，甚至把代码清单8-11中使用MethodHandle的示例代码反编译后也不会看见invokedynamic的身影，它的应用之处在哪里呢？

在某种程度上，invokedynamic指令与MethodHandle机制的作用是一样的，都是为了解

决原有4条“`invoke*`”指令方法分派规则固化在虚拟机之中的问题，把如何查找目标方法的决定权从虚拟机转嫁到具体用户代码之中，让用户（包含其他语言的设计者）有更高的自由度。而且，它们两者的思路也是可类比的，可以把它们想象成为了达成同一个目的，一个采用上层Java代码和API来实现，另一个用字节码和Class中其他属性、常量来完成。因此，如果理解了前面的 `MethodHandle` 例子，那么理解 `invokedynamic` 指令也并不困难。

每一处含有 `invokedynamic` 指令的位置都称做“动态调用点”（Dynamic Call Site），这条指令的第一个参数不再是代表方法符号引用的 `CONSTANT_Methodref_info` 常量，而是变为JDK 1.7新加入的 `CONSTANT_InvokeDynamic_info` 常

量，从这个新常量中可以得到3项信息：引导方法（Bootstrap Method，此方法存放在新增的BootstrapMethods属性中）、方法类型（MethodType）和名称。引导方法是有固定的参数，并且返回值是java.lang.invoke.CallSite对象，这个代表真正要执行的目标方法调用。根据CONSTANT_InvokeDynamic_info常量中提供的信息，虚拟机可以找到并且执行引导方法，从而获得一个CallSite对象，最终调用要执行的目标方法。我们还是举一个实际的例子来解释这个过程，如代码清单8-12所示。

代码清单8-12 invokedynamic指令演示

```
import static
java.lang.invoke.MethodHandles.lookup;
import java.lang.invoke.CallSite;
import java.lang.invoke.ConstantCallSite;
```

```
import java.lang.invoke.MethodHandle;
import java.lang.invoke.MethodHandles;
import java.lang.invoke.MethodType;
public class InvokeDynamicTest{
    public static void main (String[]args)
throws Throwable{
        INDY_BootstrapMethod () .invokeExact ("icyfen
    }
    public static void testMethod (String s) {
        System.out.println ("hello String: "+s);
    }
    public static CallSite
    BootstrapMethod (MethodHandles.Lookup
    lookup, String name, MethodType mt) throws
    Throwable{
        return new
        ConstantCallSite (lookup.findStatic (InvokeDynam
    }
    private static MethodType
    MT_BootstrapMethod () {
        return MethodType
            .fromMethodDescriptorString (
                "(Ljava/lang/invoke/MethodHandles $Lookup;
Ljava/lang/String;
Ljava/lang/invoke/MethodType; )
Ljava/lang/invoke/CallSite; ",
                null) ;
    }
    private static MethodHandle
    MH_BootstrapMethod () throws Throwable{
        return
        lookup () .findStatic (InvokeDynamicTest.class, "
MT_BootstrapMethod () );
    }
}
```

```
private static MethodHandle
INDY_BootstrapMethod () throws Throwable{
    CallSite cs= (CallSite)
MH_BootstrapMethod () .invokeWithArguments (looki
    MethodType.fromMethodDescriptorString ("(Ljava
V", null) );
    return cs.dynamicInvoker ();
}
}
```

这段代码与前面MethodHandleTest的作用基本上是一样的，虽然笔者没有加以注释，但是阅读起来应当不困难。本书前面提到过，由于invokedynamic指令所面向的使用者并非Java语言，而是其他Java虚拟机之上的动态语言，因此仅依靠Java语言的编译器Javac没有办法生成带有invokedynamic指令的字节码（曾经有一个java.dyn.InvokeDynamic的语法糖可以实现，但后来被取消了），所以要使用Java语言来演示invokedynamic指令只能用一些变通的办法。John

Rose (Da Vinci Machine Project的Leader) 编写了一个把程序的字节码转换为使用invokedynamic的简单工具INDY^[3]来完成这件事情，我们要使用这个工具来产生最终要的字节码，因此这个示例代码中的方法名称不能随意改动，更不能把几个方法合并到一起写，因为它们是要被INDY工具读取的。

把上面代码编译、再使用INDY转换后重新生成的字节码如代码清单8-13所示（结果使用javap输出，因版面原因，精简了许多无关的内容）。

代码清单8-13 invokedynamic指令演示（2）

```
Constant pool:  
#121=NameAndType#33: #30//testMethod:  
(Ljava/lang/String;)V
```

```
#123=InvokeDynamic#0: #121//#0: testMethod:  
(Ljava/lang/String; ) V  
    public static void  
main (java.lang.String[]) throws  
java.lang.Throwable;  
    Code:  
        stack=2, locals=1, args_size=1  
        0: ldc#23//String abc  
        2: invokedynamic#123, 0//InvokeDynamic#0:  
testMethod: (Ljava/lang/String; ) V  
        7: nop  
        8: return  
    public static java.lang.invoke.CallSite  
BootstrapMethod (java.lang.invoke.MethodHandles  
$Lookup,java.lang.String,java.lang.invoke.Method  
throws java.lang.Throwable;  
    Code:  
        stack=6, locals=3, args_size=3  
        0: new#63//class  
java/lang/invoke/ConstantCallSite  
        3: dup  
        4: aload_0  
        5: ldc#17//class  
org/fenixsoft/InvokeDynamicTest  
        7: aload_1  
        8: aload_2  
        9: invokevirtual#65//Method  
java/lang/invoke/MethodHandles  
$Lookup.findStatic: (Ljava/lang/Class;  
Ljava/lang/String;  
Ljava/lang/invoke/MethodType; )  
Ljava/lang/invoke/MethodHandle;  
        12: invokespecial#71//Method  
java/lang/invoke/ConstantCallSite."<in it>":
```

```
(Ljava/lang/invoke/MethodHandle; ) V  
15: areturn
```

从main（）方法的字节码可见，原本的方法调用指令已经替换为invokedynamic，它的参数为第123项常量（第二个值为0的参数在HotSpot中用不到，与invokeinterface指令那个值为0的参数一样都是占位的）。

```
2: invokedynamic#123, 0 //InvokeDynamic#0:  
testMethod: (Ljava/lang/String; ) V
```

从常量池中可见，第123项常量显示“#123=InvokeDynamic#0: #121”说明它是一项CONSTANT_InvokeDynamic_info类型常量，常量值中前面的“#0”代表引导方法取BootstrapMethods属性表的第0项（javap没有列出属性表的具体内容，不过示例中仅有一个引导方法，即

BootstrapMethod ())，而后面的“#121”代表引用第121项类型为CONSTANT_NameAndType_info的常量，从这个常量中可以获取方法名称和描述符，即后面输出的“testMethod:

(Ljava/lang/String;) V”。

再看一下BootstrapMethod ()，这个方法Java源码中没有，是INDY产生的，但是它的字节码很容易读懂，所有逻辑就是调用MethodHandles\$Lookup的findStatic () 方法，产生testMethod () 方法的MethodHandle，然后用它创建一个ConstantCallSite对象。最后，这个对象返回给invokedynamic指令实现对testMethod () 方法的调用，invokedynamic指令的调用过程到此就宣告完成了。

5. 掌控方法分派规则

invokedynamic指令与前面4条“invoke*”指令的最大差别就是它的分派逻辑不是由虚拟机决定的，而是由程序员决定。在介绍Java虚拟机动态语言支持的最后一个结语中，笔者通过一个简单例子（如代码清单8-14所示），帮助读者理解程序员在可以掌控方法分派规则之后，能做什么以前无法做到的事情。

代码清单8-14 方法调用问题

```
class GrandFather{
    void thinking () {
        System.out.println ("i am grandfather");
    }
}
class Father extends GrandFather{
    void thinking () {
        System.out.println ("i am father");
    }
}
```

```
class Son extends Father{  
    void thinking () {  
        //请读者在这里填入适当的代码（不能修改其他地方的代  
        码）  
        //实现调用祖父类的thinking () 方法，打印"i am  
        grandfather"  
    }  
}
```

在Java程序中，可以通过“super”关键字很方便地调用到父类中的方法，但如果要访问祖类的方法呢？读者在阅读本书下面提供的解决方案之前，不妨自己思考一下，在JDK 1.7之前有没有办法解决这个问题。

在JDK 1.7之前，使用纯粹的Java语言很难处理这个问题（直接生成字节码就很简单，如使用ASM等字节码工具），原因是在Son类的thinking () 方法中无法获取一个实际类型是GrandFather的对象引用，而invokevirtual指令的分

派逻辑就是按照方法接收者的实际类型进行分派，这个逻辑是固化在虚拟机中的，程序员无法改变。在JDK 1.7中，可以使用代码清单8-15中的程序来解决这个问题。

代码清单8-15 使用MethodHandle来解决相关问题

```
import static
java.lang.invoke.MethodHandles.lookup;
import java.lang.invoke.MethodHandle;
import java.lang.invoke.MethodType;
class Test{
    class GrandFather{
        void thinking () {
            System.out.println ("i am grandfather");
        }
    }
    class Father extends GrandFather{
        void thinking () {
            System.out.println ("i am father");
        }
    }
    class Son extends Father{
        void thinking () {
            try{
```

```
MethodType
mt=MethodType.methodType (void.class) ;
    MethodHandle
mh=lookup () .findSpecial (GrandFather.class, "th
mt,getClass () );
    mh.invoke (this) ;
}catch (Throwable e) {
}
}
}

public static void main (String[]args) {
(new Test () .new Son () ) .thinking () ;
}
}
```

运行结果：

```
i am grandfather
```

- [1]注意，动态类型语言与动态语言、弱类型语言并不是一个概念，需要区别对待。
- [2]这个包在很长一段时间里称为java.dyn，也曾经短暂更名为java.lang.mh，如果读者在其他资料上看到这两个包名，可以把它们理解为

java.lang.invoke。

[3]INDY下载地址：

http://blogs.oracle.com/jrose/entry/a_modest_tool_fc

8.4 基于栈的字节码解释执行引擎

虚拟机是如何调用方法的内容已经讲解完毕，从本节开始，我们来探讨虚拟机是如何执行方法中的字节码指令的。上文中提到过，许多Java虚拟机的执行引擎在执行Java代码的时候都有解释执行（通过解释器执行）和编译执行（通过即时编译器产生本地代码执行）两种选择，在本章中，我们先来探讨一下在解释执行时，虚拟机执行引擎是如何工作的。

8.4.1 解释执行

Java语言经常被人们定位为“解释执行”的语言，在Java初生的JDK 1.0时代，这种定义还算是

比较准确的，但当主流的虚拟机中都包含了即时编译器后，Class文件中的代码到底会被解释执行还是编译执行，就成了只有虚拟机自己才能准确判断的事情。再后来，Java也发展出了可以直接生成本地代码的编译器[如GCJ^[1]（GNU Compiler for the Java）]，而C/C++语言也出现了通过解释器执行的版本（如CINT^[2]），这时候再笼统地说“解释执行”，对于整个Java语言来说就成了几乎没有意义的概念，只有确定了谈论对象是某种具体的Java实现版本和执行引擎运行模式时，谈解释执行还是编译执行才会比较确切。

不论是解释还是编译，也不论是物理机还是虚拟机，对于应用程序，机器都不可能如人那样阅读、理解，然后就获得了执行能力。大部分的程序代码到物理机的目标代码或虚拟机能执行的

指令集之前，都需要经过图8-4中的各个步骤。如果读者对编译原理的相关课程还有印象的话，很容易就会发现图8-4中下面那条分支，就是传统编译原理中程序代码到目标机器代码的生成过程，而中间的那条分支，自然就是解释执行的过程。

如今，基于物理机、Java虚拟机，或者非Java的其他高级语言虚拟机（HLLVM）的语言，大多都会遵循这种基于现代经典编译原理的思路，在执行前先对程序源码进行词法分析和语法分析处理，把源码转化为抽象语法树（Abstract Syntax Tree,AST）。对于一门具体语言的实现来说，词法分析、语法分析以至后面的优化器和目标代码生成器都可以选择独立于执行引擎，形成一个完整意义的编译器去实现，这类代表是C/C++语言。也可以选择把其中一部分步骤（如

生成抽象语法树之前的步骤) 实现为一个半独立的编译器, 这类代表是Java语言。又或者把这些步骤和执行引擎全部集中封装在一个封闭的黑匣子之中, 如大多数的JavaScript执行器。




图 8-4 编译过程

Java语言中, Javac编译器完成了程序代码经过词法分析、语法分析到抽象语法树, 再遍历语法树生成线性的字节码指令流的过程。因为这一部分动作是在Java虚拟机之外进行的, 而解释器

在虚拟机的内部，所以Java程序的编译就是半独立的实现。

[1]GCJ：<http://gcc.gnu.org/java/>。

[2]CINT：<http://root.cern.ch/drupal/content/cint>。

8.4.2 基于栈的指令集与基于寄存器的指令集

Java编译器输出的指令流，基本上^[1]是一种基于栈的指令集架构（Instruction Set Architecture,ISA），指令流中的指令大部分都是零地址指令，它们依赖操作数栈进行工作。与之相对的另外一套常用的指令集架构是基于寄存器的指令集，最典型的就是x86的二地址指令集，说得通俗一些，就是现在我们主流PC机中直接支持的指令集架构，这些指令依赖寄存器进行工作。那么，基于栈的指令集与基于寄存器的指令集这两者之间有什么不同呢？

举个最简单的例子，分别使用这两种指令集

计算“1+1”的结果，基于栈的指令集会是这样子的：

```
iconst_1
iconst_1
iadd
istore_0
```

两条iconst_1指令连续把两个常量1压入栈后，iadd指令把栈顶的两个值出栈、相加，然后把结果放回栈顶，最后istore_0把栈顶的值放到局部变量表的第0个Slot中。

如果基于寄存器，那程序可能会是这个样子：

```
mov eax, 1
add eax, 1
```

mov指令把EAX寄存器的值设为1，然后add指令再把这个值加1，结果就保存在EAX寄存器里面。

了解了基于栈的指令集与基于寄存器的指令集的区别后，读者可能会有进一步的疑问，这两套指令集谁更好一些呢？

应该这么说，既然两套指令集会同时并存和发展，那肯定是各有优势的，如果有一套指令集全面优于另外一套的话，就不会存在选择的问题了。

基于栈的指令集主要的优点就是可移植，寄存器由硬件直接提供^[2]，程序直接依赖这些硬件寄存器则不可避免地要受到硬件的约束。例如，现在32位80x86体系的处理器中提供了8个32位的

寄存器，而ARM体系的CPU（在当前的手机、PDA中相当流行的一种处理器）则提供了16个32位的通用寄存器。如果使用栈架构的指令集，用户程序不会直接使用这些寄存器，就可以由虚拟机实现来自行决定把一些访问最频繁的数据（程序计数器、栈顶缓存等）放到寄存器中以获取尽量好的性能，这样实现起来也更加简单一些。栈架构的指令集还有一些其他的优点，如代码相对更加紧凑（字节码中每个字节就对应一条指令，而多地址指令集中还需要存放参数）、编译器实现更加简单（不需要考虑空间分配的问题，所需空间都在栈上操作）等。

栈架构指令集的主要缺点是执行速度相对来说会稍慢一些。所有主流物理机的指令集都是寄存器架构也从侧面印证了这一点。

虽然栈架构指令集的代码非常紧凑，但是完成相同功能所需的指令数量一般会比寄存器架构多，因为出栈、入栈操作本身就产生了相当多的指令数量。更重要的是，栈实现在内存之中，频繁的栈访问也就意味着频繁的内存访问，相对于处理器来说，内存始终是执行速度的瓶颈。尽管虚拟机可以采取栈顶缓存的手段，把最常用的操作映射到寄存器中避免直接内存访问，但这也只能是优化措施而不是解决本质问题的方法。由于指令数量和内存访问的原因，所以导致了栈架构指令集的执行速度会相对较慢。

[1] 使用“基本上”，是因为部分字节码指令会带有参数，而纯粹基于栈的指令集架构中应当全部都是零地址指令，也就是都不存在显式的参数。

Java这样实现主要是考虑了代码的可校验性。

[2]这里说的是物理机器上的寄存器，也有基于寄存器的虚拟机，如Google Android平台的Dalvik VM。即使是基于寄存器的虚拟机，也希望把虚拟机寄存器尽量映射到物理寄存器上以获取尽可能高的性能。

8.4.3 基于栈的解释器执行过程

初步的理论知识已经讲解过了，本节准备了一段Java代码，看看在虚拟机中实际是如何执行的。前面曾经举过一个计算“1+1”的例子，这样的算术题目显然太过简单了，笔者准备了四则运算的例子，请看代码清单8-16。

代码清单8-16 一段简单的算术代码

```
public int calc () {  
    int a=100;  
    int b=200;  
    int c=300;  
    return (a+b) *c;  
}
```

从Java语言的角度来看，这段代码没有任何

解释的必要，可以直接使用javap命令看看它的字节码指令，如代码清单8-17所示。

代码清单8-17 一段简单的算术代码的字节码表示

```
public int calc () ;  
Code:  
Stack=2, Locals=4, Args_size=1  
0: bipush 100  
2: istore_1  
3: sipush 200  
6: istore_2  
7: sipush 300  
10: istore_3  
11: iload_1  
12: iload_2  
13: iadd  
14: iload_3  
15: imul  
16: ireturn  
}
```

javap提示这段代码需要深度为2的操作数栈和4个Slot的局部变量空间，笔者根据这些信息画

了图8-5~图8-11共7张图，用它们来描述代码清单8-17执行过程中的代码、操作数栈和局部变量表的变化情况。






图 8-5 执行偏移地址为0的指令的情况



执行偏移地址为2的指令，
istore_1指令的作用是将操作数
栈顶的整型值出栈并存放到第1
个局部变量Slot中。后续4条指
令（直到偏移为11的指令为止）
都是做一样的事情，也就是在
对应代码中把变量a、b、c赋值
为100、200、300。这4条指令
的图示略过。

图 8-6 执行偏移地址为1的指令的情况



执行偏移地址为11的指令，
iload_1指令的作用是将局部变
量表第1个Slot中的整型值复制
到操作数栈顶。

图 8-7 执行偏移地址为11的指令的情况




图 8-8 执行偏移地址为12的指令的情况




图 8-9 执行偏移地址为13的指令的情况

执行偏移地址为12的指令，
iload_2指令的执行过程与iload_1
类似，把第2个Slot的整型值入
栈。画出这个指令的图示主要是
为了显示下一条iadd指令执行前
的堆栈状况。

执行偏移地址为13的指令，
iadd指令的作用是将操作数栈中
头两个栈顶元素出栈，做整型加
法，然后把结果重新入栈。在
iadd指令执行完毕后，栈中原有
的100和200出栈，它们和300重
新入栈。



图 8-10 执行偏移地址为14的指令的情况




图 8-11 执行偏移地址为16的指令的情况

上面的执行过程仅仅是一种概念模型，虚拟机最终会对执行过程做一些优化来提高性能，实际的运作过程不一定完全符合概念模型的描述……更准确地说，实际情况会和上面描述的概念模型差距非常大，这种差距产生的原因是虚拟机中解析器和即时编译器都会对输入的字节码进行优化，例如，在HotSpot虚拟机中，有很多以“fast_”开头的非标准字节码指令用于合并、替换输入的字节码以提升解释执行性能，而即时编译器的优化手段更加花样繁多^[1]。

不过，我们从这段程序的执行中也可以看出栈结构指令集的一般运行过程，整个运算过程的中间变量都以操作数栈的出栈、入栈为信息交换途径，符合我们在前面分析的特点。

[1]具体可以参考第11章中的相关内容。

8.5 本章小结

本章中，我们分析了虚拟机在执行代码时，如何找到正确的方法、如何执行方法内的字节码，以及执行代码时涉及的内存结构。在第6、7、8三章中，我们针对Java程序是如何存储的、如何载入（创建）的，以及如何执行的问题把相关知识进行了讲解，第9章我们将一起看看这些理论知识在具体开发之中的经典应用。

第9章 类加载及执行子系统的案例与实战

代码编译的结果从本地机器码转变为字节码，是存储格式发展的一小步，却是编程语言发展的一大步。

9.1 概述

在Class文件格式与执行引擎这部分中，用户的程序能直接影响的内容并不太多，Class文件以何种格式存储，类型何时加载、如何连接，以及虚拟机如何执行字节码指令等都是由虚拟机直接控制的行为，用户程序无法对其进行改变。能通过程序进行操作的，主要是字节码生成与类加载

器这两部分的功能，但仅仅在如何处理这两点上，就已经出现了许多值得欣赏和借鉴的思路，这些思路后来成为了许多常用功能和程序实现的基础。在本章中，我们将看一下前面所学的知识在实际开发之中是如何应用的。

9.2 案例分析

在案例分析部分，笔者准备了4个例子，关于类加载器和字节码的案例各有两个。并且这两个领域的案例中各有一个案例是大多数Java开发人员都使用过的工具或技术，另外一个案例虽然不一定每个人都使用过，但却特别精彩地演绎出这个领域中的技术特性。希望这些案例能引起读者的思考，并给读者的日常工作带来灵感。

9.2.1 Tomcat：正统的类加载器架构

主流的Java Web服务器，如Tomcat、Jetty、WebLogic、WebSphere或其他笔者没有列举的服务器，都实现了自己定义的类加载器（一般都不

止一个）。因为一个功能健全的Web服务器，要解决如下几个问题：

部署在同一个服务器上的两个Web应用程序所使用的Java类库可以实现相互隔离。这是最基本的需求，两个不同的应用程序可能会依赖同一个第三方类库的不同版本，不能要求一个类库在一个服务器中只有一份，服务器应当保证两个应用程序的类库可以互相独立使用。

部署在同一个服务器上的两个Web应用程序所使用的Java类库可以互相共享。这个需求也很常见，例如，用户可能有10个使用Spring组织的应用程序部署在同一台服务器上，如果把10份Spring分别存放在各个应用程序的隔离目录中，将会是很大的资源浪费——这主要倒不是浪费磁

盘空间的问题，而是指类库在使用时都要被加载到服务器内存，如果类库不能共享，虚拟机的方法区就会很容易出现过度膨胀的风险。

服务器需要尽可能地保证自身的安全不受部署的Web应用程序影响。目前，有许多主流的Java Web服务器自身也是使用Java语言来实现的。因此，服务器本身也有类库依赖的问题，一般来说，基于安全考虑，服务器所使用的类库应该与应用程序的类库互相独立。

支持JSP应用的Web服务器，大多数都需要支持HotSwap功能。我们知道，JSP文件最终要编译成Java Class才能由虚拟机执行，但JSP文件由于其纯文本存储的特性，运行时修改的概率远远大于第三方类库或程序自身的Class文件。而且

ASP、PHP和JSP这些网页应用也把修改后无须重启作为一个很大的“优势”来看待，因此“主流”的Web服务器都会支持JSP生成类的热替换，当然也有“非主流”的，如运行在生产模式（Production Mode）下的WebLogic服务器默认就不会处理JSP文件的变化。

由于存在上述问题，在部署Web应用时，单独的一个ClassPath就无法满足需求了，所以各种Web服务器都“不约而同”地提供了好几个ClassPath路径供用户存放第三方类库，这些路径一般都以“lib”或“classes”命名。被放置到不同路径中的类库，具备不同的访问范围和服务对象，通常，每一个目录都会有一个相应的自定义类加载器去加载放置在里面的Java类库。现在，笔者就以Tomcat服务器^[1]为例，看一看Tomcat具体是

如何规划用户类库结构和类加载器的。

在Tomcat目录结构中，有3组目录

(“/common/*”、“/server/*”和“/shared/*”）可以存放Java类库，另外还可以加上Web应用程序自身的目录“/WEB-INF/*”，一共4组，把Java类库放置在这些目录中的含义分别如下。

放置在/common目录中：类库可被Tomcat和所有的Web应用程序共同使用。

放置在/server目录中：类库可被Tomcat使用，对所有的Web应用程序都不可见。

放置在/shared目录中：类库可被所有的Web应用程序共同使用，但对Tomcat自己不可见。

放置在/WebApp/WEB-INF目录中：类库仅仅

可以被此Web应用程序使用，对Tomcat和其他Web应用程序都不可见。

为了支持这套目录结构，并对目录里面的类库进行加载和隔离，Tomcat自定义了多个类加载器，这些类加载器按照经典的双亲委派模型来实现，其关系如图9-1所示。




图 9-1 Tomcat服务器的类加载架构

灰色背景的3个类加载器是JDK默认提供的类加载器，这3个加载器的作用在第7章中已经介绍过了。而CommonClassLoader、 CatalinaClassLoader、 SharedClassLoader和 WebappClassLoader则是Tomcat自己定义的类加载器，它们分别加载/common/*、 /server/*、 /shared/* 和/WebApp/WEB-INF/*中的Java类库。其中 WebApp类加载器和Jsp类加载器通常会存在多个实例，每一个Web应用程序对应一个WebApp类加载器，每一个JSP文件对应一个Jsp类加载器。

从图9-1的委派关系中可以看出， CommonClassLoader能加载的类都可以被Catalina

ClassLoader和SharedClassLoader使用，而 CatalinaClassLoader和SharedClassLoader自己能加载的类则与对方相互隔离。WebAppClassLoader 可以使用SharedClassLoader加载到的类，但各个 WebAppClassLoader实例之间相互隔离。而 JasperLoader的加载范围仅仅是这个JSP文件所编译出来的那一个Class，它出现的目的就是为了被丢弃：当服务器检测到JSP文件被修改时，会替换掉目前的JasperLoader的实例，并通过再建立一个新的Jsp类加载器来实现JSP文件的HotSwap功能。

对于Tomcat的6.x版本，只有指定了 tomcat/conf/catalina.properties配置文件的 server.loader和share.loader项后才会真正建立 CatalinaClassLoader和SharedClassLoader的实例，

否则会用到这两个类加载器的地方都会用CommonClassLoader的实例代替，而默认的配置文件中没有设置这两个loader项，所以Tomcat 6.x顺理成章地把/common、/server和/shared三个目录默认合并到一起变成一个/lib目录，这个目录里的类库相当于以前/common目录中类库的作用。这是Tomcat设计团队为了简化大多数的部署场景所做的一项改进，如果默认设置不能满足需要，用户可以通过修改配置文件指定server.loader和share.loader的方式重新启用Tomcat 5.x的加载器架构。

Tomcat加载器的实现清晰易懂，并且采用了官方推荐的“正统”的使用类加载器的方式。如果读者阅读完上面的案例后，能完全理解Tomcat设计团队这样布置加载器架构的用意，那说明已经

大致掌握了类加载器“主流”的使用方式，那么笔者不妨再提一个问题让读者思考一下：前面曾经提到过一个场景，如果有10个Web应用程序都是用Spring来进行组织和管理的话，可以把Spring放到Common或Shared目录下让这些程序共享。

Spring要对用户程序的类进行管理，自然要能访问到用户程序的类，而用户的程序显然是放在/WebApp/WEB-INF目录中的，那么被CommonClassLoader或SharedClassLoader加载的Spring如何访问并不在其加载范围内的用户程序呢？如果读过本书第7章的相关内容，相信读者可以很容易地回答这个问题。

[1]Tomcat是Apache基金会中的一款开源的Java Web服务器，主页地址为：
<http://tomcat.apache.org>。本案例中选用的是

Tomcat 5.x服务器的目录和类加载器结构，在 Tomcat 6.x的默认配置下，/common、/server 和/shared三个目录已经合并到一起了。

9.2.2 OSGi：灵活的类加载器架构

Java程序社区中流传着这么一个观点：“学习JEE规范，去看JBoss源码；学习类加载器，就去看OSGi源码”。尽管“JEE规范”和“类加载器的知识”并不是一个对等的概念，不过，既然这个观点能在程序员中流传开来，也从侧面说明了OSGi对类加载器的运用确实有其独到之处。

OSGi^[1]（Open Service Gateway Initiative）是OSGi联盟（OSGi Alliance）制定的一个基于Java语言的动态模块化规范，这个规范最初由Sun、IBM、爱立信等公司联合发起，目的是使服务提供商通过住宅网关为各种家用智能设备提供各种服务，后来这个规范在Java的其他技术领域也有

相当不错的发展，现在已经成为Java世界中“事实上”的模块化标准，并且已经有了Equinox、Felix等成熟的实现。OSGi在Java程序员中最著名的应用案例就是Eclipse IDE，另外还有许多大型的软件平台和中间件服务器都基于或声明将会基于OSGi规范来实现，如IBM Jazz平台、GlassFish服务器、jBoss OSGi等。

OSGi中的每个模块（称为Bundle）与普通的Java类库区别并不太大，两者一般都以JAR格式进行封装，并且内部存储的都是Java Package和Class。但是一个Bundle可以声明它所依赖的Java Package（通过Import-Package描述），也可以声明它允许导出发布的Java Package（通过Export-Package描述）。在OSGi里面，Bundle之间的依赖关系从传统的上层模块依赖底层模块转变为平级

模块之间的依赖（至少外观上如此），而且类库的可见性能得到非常精确的控制，一个模块里只有被Export过的Package才可能由外界访问，其他的Package和Class将会隐藏起来。除了更精确的模块划分和可见性控制外，引入OSGi的另外一个重要理由是，基于OSGi的程序很可能（只是很可能，并不是一定会）可以实现模块级的热插拔功能，当程序升级更新或调试除错时，可以只停用、重新安装然后启用程序的其中一部分，这对企业级程序开发来说是一个非常有诱惑力的特性。

OSGi之所以能有上述“诱人”的特点，要归功于它灵活的类加载器架构。OSGi的Bundle类加载器之间只有规则，没有固定的委派关系。例如，某个Bundle声明了一个它依赖的Package，如果有

其他Bundle声明发布了这个Package，那么所有对这个Package的类加载动作都会委派给发布它的Bundle类加载器去完成。不涉及某个具体的Package时，各个Bundle加载器都是平级关系，只有具体使用某个Package和Class的时候，才会根据Package导入导出定义来构造Bundle间的委派和依赖。

另外，一个Bundle类加载器为其他Bundle提供服务时，会根据Export-Package列表严格控制访问范围。如果一个类存在于Bundle的类库中但是没有被Export，那么这个Bundle的类加载器能找到这个类，但不会提供给其他Bundle使用，而且OSGi平台也不会把其他Bundle的类加载请求分配给这个Bundle来处理。

我们可以举一个更具体一些的简单例子，假设存在Bundle A、Bundle B、Bundle C三个模块，并且这三个Bundle定义的依赖关系如下。

Bundle A： 声明发布了packageA， 依赖了java.*的包。

Bundle B： 声明依赖了packageA和packageC， 同时也依赖了java.*的包。

Bundle C： 声明发布了packageC， 依赖了packageA。

那么， 这三个Bundle之间的类加载器及父类加载器之间的关系如图9-2所示。




图 9-2 OSGi的类加载器架构

由于没有牵扯到具体的OSGi实现，所以图9-2中的类加载器都没有指明具体的加载器实现，只是一个体现了加载器之间关系的概念模型，并且只是体现了OSGi中最简单的加载器委派关系。一般来说，在OSGi中，加载一个类可能发生的查找行为和委派关系会比图9-2中显示的复杂得多，

类加载时可能进行的查找规则如下：

以java.*开头的类，委派给父类加载器加载。

否则，委派列表名单内的类，委派给父类加载器加载。

否则，Import列表中的类，委派给Export这个类的Bundle的类加载器加载。

否则，查找当前Bundle的Classpath，使用自己的类加载器加载。

否则，查找是否在自己的Fragment Bundle中，如果是，则委派给Fragment Bundle的类加载器加载。

否则，查找Dynamic Import列表的Bundle，委派给对应Bundle的类加载器加载。

否则，类查找失败。

从图9-2中还可以看出，在OSGi里面，加载器之间的关系不再是双亲委派模型的树形结构，而是已经进一步发展成了一种更为复杂的、运行时才能确定的网状结构。这种网状的类加载器架构在带来更好的灵活性的同时，也可能会产生许多新的隐患。笔者曾经参与过将一个非OSGi的大型系统向Equinox OSGi平台迁移的项目，由于历史原因，代码模块之间的依赖关系错综复杂，勉强分离出各个模块的Bundle后，发现在高并发环境下经常出现死锁。我们很容易就找到了死锁的原因：如果出现了Bundle A依赖Bundle B的

Package B，而Bundle B又依赖了Bundle A的Package A，这两个Bundle进行类加载时就很容易发生死锁。具体情况是当Bundle A加载Package B的类时，首先需要锁定当前类加载器的实例对象（`java.lang.ClassLoader.loadClass()`是一个`synchronized`方法），然后把请求委派给Bundle B的加载器处理，但如果这时候Bundle B也正好想加载Package A的类，它也先锁定自己的加载器再去请求Bundle A的加载器处理，这样，两个加载器都在等待对方处理自己的请求，而对方处理完之前自己又一直处于同步锁定的状态，因此它们就互相死锁，永远无法完成加载请求了。Equinox的Bug List中有关于这类问题的Bug^[2]，也提供了一个以牺牲性能为代价的解决方案——用户可以启用`osgi.classloader.singleThreadLoads`参数来按单

线程串行化的方式强制进行类加载动作。在JDK 1.7中，为非树状继承关系下的类加载器架构进行了一次专门的升级^[3]，目的是从底层避免这类死锁出现的可能。

总体来说，OSGi描绘了一个很美好的模块化开发的目标，而且定义了实现这个目标所需要的各种服务，同时也有成熟框架对其提供实现支持。对于单个虚拟机下的应用，从开发初期就建立在OSGi上是一个很不错的选择，这样便于约束依赖。但并非所有的应用都适合采用OSGi作为基础架构，OSGi在提供强大功能的同时，也引入了额外的复杂度，带来了线程死锁和内存泄漏的风险。

[1]OSGi官方站点：

<http://www.osgi.org/Main/HomePage>。

[2]Bug-121737:

https://bugs.eclipse.org/bugs/show_bug.cgi?id=121737。

[3]JDK 1.7-Upgrade class-loader architecture:

<http://openjdk.java.net/projects/jdk7/features/#f352>.

9.2.3 字节码生成技术与动态代理的实现

“字节码生成”并不是什么高深的技术，读者在看到“字节码生成”这个标题时也先不必去想诸如Javassist、CGLib、ASM之类的字节码类库，因为JDK里面的javac命令就是字节码生成技术的“老祖宗”，并且javac也是一个由Java语言写成的程序，它的代码存放在OpenJDK的 langtools/src/share/classes/com/sun/tools/javac 目录中^[1]。要深入了解字节码生成，阅读javac的源码是个很好的途径，不过javac对于我们这个例子来说太过庞大了。在Java里面除了javac和字节码类库外，使用字节码生成的例子还有很多，如Web服务器中的JSP编译器，编译时植入的AOP框

架，还有很常用的动态代理技术，甚至在使用反射的时候虚拟机都有可能会在运行时生成字节码来提高执行速度。我们选择其中相对简单的动态代理来看看字节码生成技术是如何影响程序运作的。

相信许多Java开发人员都使用过动态代理，即使没有直接使用过`java.lang.reflect.Proxy`或实现过`java.lang.reflect.InvocationHandler`接口，应该也用过Spring来做过Bean的组织管理。如果使用过Spring，那大多数情况都会用过动态代理，因为如果Bean是面向接口编程，那么在Spring内部都是通过动态代理的方式来对Bean进行增强的。动态代理中所谓的“动态”，是针对使用Java代码实际编写了代理类的“静态”代理而言的，它的优势不在于省去了编写代理类那一点工作量，而是实

现了可以在原始类和接口还未知的时候，就确定代理类的代理行为，当代理类与原始类脱离直接联系后，就可以很灵活地重用于不同的应用场景之中。

代码清单9-1演示了一个最简单的动态代理的用法，原始的逻辑是打印一句“hello world”，代理类的逻辑是在原始类方法执行前打印一句“welcome”。我们先看一下代码，然后再分析JDK是如何做到的。

代码清单9-1 动态代理的简单示例

```
public class DynamicProxyTest{  
    interface IHello{  
        void sayHello () ;  
    }  
    static class Hello implements IHello{  
        @Override  
        public void sayHello () {  
            System.out.println ("hello world") ;  
        }  
    }  
}
```

```
}

}

static class DynamicProxy implements InvocationHandler{
    Object originalObj;
    Object bind (Object originalObj) {
        this.originalObj=originalObj;
        return
            Proxy.newProxyInstance (originalObj.getClass
originalObj.getClass () .getInterfaces () ,
this) ;
    }
    @Override
    public Object invoke (Object proxy,Method
method, Object[] args) throws Throwable{
        System.out.println ("welcome");
        return method.invoke (originalObj, args);
    }
}
public static void main (String[] args) {
    IHello hello= (IHello) new
DynamicProxy () .bind (new Hello () );
    hello.sayHello ();
}
}
```

运行结果如下：

```
welcome
hello world
```

上述代码里，唯一的“黑匣子”就是
Proxy.newProxyInstance () 方法，除此之外再没
有任何特殊之处。这个方法返回一个实现了
IHello的接口，并且代理了new Hello () 实例行
为的对象。跟踪这个方法的源码，可以看到程序
进行了验证、优化、缓存、同步、生成字节码、
显式类加载等操作，前面的步骤并不是我们关注
的重点，而最后它调用了
sun.misc.ProxyGenerator.generateProxyClass () 方
法来完成生成字节码的动作，这个方法可以在运
行时产生一个描述代理类的字节码byte[]数组。如
果想看一看这个在运行时产生的代理类中写了些
什么，可以在main () 方法中加入下面这句：

```
System.getProperties ().put ("sun.misc.Proxy
```

加入这句代码后再次运行程序，磁盘中将会产生一个名为“\$Proxy0.class”的代理类Class文件，反编译后可以看见如代码清单9-2所示的内容。

代码清单9-2 反编译的动态代理类的代码

```
package org.fenixsoft bytecode;
import java.lang.reflect.InvocationHandler;
import java.lang.reflect.Method;
import java.lang.reflect.Proxy;
import
java.lang.reflect.UndeclaredThrowableException;
public final class $Proxy0 extends Proxy
implements DynamicProxyTest.IHello
{
private static Method m3;
private static Method m1;
private static Method m0;
private static Method m2;
public $Proxy0 (InvocationHandler
paramInvocationHandler)
throws
{
super (paramInvocationHandler) ;
}
public final void sayHello ()
```

```
throws
{
try
{
this.h.invoke (this,m3, null) ;
return;
}
catch (RuntimeException
localRuntimeException)
{
throw localRuntimeException;
}
catch (Throwable localThrowable)
{
throw new
UndeclaredThrowableException (localThrowable) ;
}
}

//此处由于版面原因，省略equals () 、
hashCode () 、 toString () 三个方法的代码
//这3个方法的内容与sayHello () 非常相似。
static
{
try
{
m3=Class.forName ("org.fenixsoft.bytecode.Dyr
$IHHello") .getMethod ("sayHello", new
Class[0]) ;
m1=Class.forName ("java.lang.Object") .getMet
new Class[]
{Class.forName ("java.lang.Object") }) ;
m0=Class.forName ("java.lang.Object") .getMet
new Class[0]) ;
m2=Class.forName ("java.lang.Object") .getMet
```

```
new Class[0] );
    return;
}
catch (NoSuchMethodException
localNoSuchMethodException)
{
    throw new
NoSuchMethodError (localNoSuchMethodException.ge
}
catch (ClassNotFoundException
localClassNotFoundException)
{
    throw new
NoClassDefFoundError (localClassNotFoundException
}
}
}
```

这个代理类的实现代码也很简单，它为传入接口中的每一个方法，以及从java.lang.Object中继承来的equals（）、hashCode（）、
toString（）方法都生成了对应的实现，并且统一调用了InvocationHandler对象的invoke（）方法
(代码中的“this.h”就是父类Proxy中保存的
InvocationHandler实例变量)来实现这些方法的内

容，各个方法的区别不过是传入的参数和Method对象有所不同而已，所以无论调用动态代理的哪一个方法，实际上都是在执行InvocationHandler.invoke（）中的代理逻辑。

这个例子中并没有讲到generateProxyClass（）方法具体是如何产生代理类“\$Proxy0.class”的字节码的，大致的生成过程其实就是根据Class文件的格式规范去拼装字节码，但在实际开发中，以byte为单位直接拼装出字节码的应用场合很少见，这种生成方式也只能产生一些高度模板化的代码。对于用户的程序代码来说，如果有要大量操作字节码的需求，还是使用封装好的字节码类库比较合适。如果读者对动态代理的字节码拼装过程很感兴趣，可以在OpenJDK的jdk/src/share/classes/sun/misc目录下找

到sun.misc.ProxyGenerator的源码。

[1]如何获取OpenJDK源码，请参见本书第1章的相关内容。

9.2.4 Retrotranslator：跨越JDK版本

一般来说，以“做项目”为主的软件公司比较容易更新技术，在下一个项目中换一个技术框架、升级到最新的JDK版本，甚至把Java换成C#、C++来开发程序都是有可能的。但当公司发展壮大，技术有所积累，逐渐成为以“做产品”为主的软件公司后，自主选择技术的权利就会丧失掉，因为之前所积累的代码和技术都是用真金白银换来的，一个稳健的团队也不会随意地改变底层的技术。然而在飞速发展的程序设计领域，新技术总是日新月异、层出不穷，偏偏这些新技术又如鲜花之于蜜蜂一样，对程序员散发着天然的吸引力。

在Java世界里，每一次JDK大版本的发布，都伴随着一场大规模的技术革新，而对Java程序编写习惯改变最大的，无疑是JDK 1.5的发布。自动装箱、泛型、动态注解、枚举、变长参数、遍历循环（foreach循环）……事实上，在没有这些语法特性的年代，Java程序也照样能写，但是现在看来，上述每一种语法的改进几乎都是“必不可少”的。就如同习惯了24寸液晶显示器的程序员，很难习惯在15寸纯平显示器上编写代码。但假如“不幸”因为要保护现有投资、维持程序结构稳定等，必须使用1.5以前版本的JDK呢？我们没有办法把15寸显示器变成24寸的，但却可以跨越JDK版本之间的沟壑，把JDK 1.5中编写的代码放到JDK 1.4或1.3的环境中去部署使用。为了解决这个问题，一种名为“Java逆向移植”的工具

(Java Backporting Tools) 应运而生，
Retrotranslator^[1]是这类工具中较出色的一个。

Retrotranslator的作用是将JDK 1.5编译出来的Class文件转变为可以在JDK 1.4或1.3上部署的版本，它可以很好地支持自动装箱、泛型、动态注解、枚举、变长参数、遍历循环、静态导入这些语法特性，甚至还可以支持JDK 1.5中新增的集合改进、并发包以及对泛型、注解等的反射操作。了解了Retrotranslator这种逆向移植工具可以做什么以后，现在关心的是它是怎样做到的？

要想知道Retrotranslator如何在旧版本JDK中模拟新版本JDK的功能，首先要弄清楚JDK升级中会提供哪些新的功能。JDK每次升级新增的功能大致可以分为以下4类：

在编译器层面做的改进。如自动装箱拆箱，实际上就是编译器在程序中使用到包装对象的地方自动插入了很多Integer.valueOf()、Float.valueOf()之类的代码；变长参数在编译之后就自动转化成了一个数组来完成参数传递；泛型的信息则在编译阶段就已经擦除掉了（但是在元数据中还保留着），相应的地方被编译器自动插入了类型转换代码^[2]。

对Java API的代码增强。譬如JDK 1.2时代引入的java.util.Collections等一系列集合类，在JDK 1.5时代引入的java.util.concurrent并发包等。

需要在字节码中进行支持的改动。如JDK 1.7里面新加入的语法特性：动态语言支持，就需要在虚拟机中新增一条invokedynamic字节码指令来

实现相关的调用功能。不过字节码指令集一直处于相对比较稳定的状态，这种需要在字节码层面直接进行的改动是比较少见的。

虚拟机内部的改进。如JDK 1.5中实现的JSR-133^[3]规范重新定义的Java内存模型（Java Memory Model,JMM）、CMS收集器之类的改动，这类改动对于程序员编写代码基本是透明的，但会对程序运行时产生影响。

上述4类新功能中，Retrotranslator只能模拟前两类，对于后面两类直接在虚拟机内部实现的改进，一般所有的逆向移植工具都是无能为力的，至少不能完整地或者在可接受的效率上完成全部模拟，否则虚拟机设计团队也没有必要舍近求远地改动处于JDK底层的虚拟机。在可以模拟

的两类功能中，第二类模拟相对更容易实现一些，如JDK 1.5引入的java.util.concurrent包，实际是由多线程大师Doug Lea开发的一套并发包，在JDK 1.5出现之前就已经存在（那时候名字叫做dl.util.concurrent，引入JDK时由作者和JDK开发团队共同做了一些改进），所以要在旧的JDK中支持这部分功能，以独立类库的方式便可实现。

Retrotranslator中附带了一个名叫“backport-util-concurrent.jar”的类库（由另一个名为“Backport of JSR 166”的项目所提供）来代替JDK 1.5的并发包。

至于JDK在编译阶段进行处理的那些改进，Retrotranslator则是使用ASM框架直接对字节码进行处理。由于组成Class文件的字节码指令数量并没有改变，所以无论是JDK 1.3、JDK 1.4还是

JDK 1.5，能用字节码表达的语义范围应该是一致的。当然，肯定不可能简单地把Class的文件版本号从49.0改回48.0就能解决问题了，虽然字节码指令的数量没有变化，但是元数据信息和一些语法支持的内容还是要做相应的修改。以枚举为例，在JDK 1.5中增加了enum关键字，但是Class文件常量池的CONSTANT_Class_info类型常量并没有发生任何语义变化，仍然是代表一个类或接口的符号引用，没有加入枚举，也没有增加过“CONSTANT_Enum_info”之类的“枚举符号引用”常量。所以使用enum关键字定义常量，虽然从Java语法上看起来与使用class关键字定义类、使用interface关键字定义接口是同一层次的，但实际上这是由Javac编译器做出来的假象，从字节码的角度来看，枚举仅仅是一个继承于

`java.lang.Enum`、自动生成了`values()` 和
`valueOf()` 方法的普通Java类而已。

Retrotranslator对枚举所做的主要处理就是把枚举类的父类从“`java.lang.Enum`”替换为它运行时类库中包含的“`net.sf.retrotranslator.runtime.java.lang.Enum_`”，然后再在类和字段的访问标志中抹去`ACC_ENUM`标志位。当然，这只是处理的总体思路，具体的实现要比上面说的复杂得多。可以想象既然两个父类实现都不一样，`values()` 和`valueOf()` 的方法自然需要重写，常量池需要引入大量新的来自父类的符号引用，这些都是实现细节。图9-3是一个使用JDK 1.5编译的枚举类与被Retrotranslator转换处理后的字节码的对比图。




图 9-3 Retrotranslator 处理前后的枚举类字节码对比

[1] Retrotranslator 官方站点：

<http://retrotranslator.sf.net>。

[2] 如果想了解编译器在这个阶段所做的各种动作的详细信息，那么可以参考 10.3 节。

[3] JSR-133: Java Memory Model and Thread

Specification Revision (Java内存模型和线程规范修订)。

9.3 实战：自己动手实现远程执行功能

不知道读者在做程序维护的时候是否遇到过这类情形：排查问题的过程中，想查看内存中的一些参数值，却又没有办法把这些值输出到界面或日志中，又或者定位到某个缓存数据有问题，但缺少缓存的统一管理界面，不得不重启服务才能清理这个缓存。类似的需求有一个共同的特点，那就是只要在服务中执行一段程序代码，就可以定位或排除问题，但就是偏偏找不到可以让服务器执行临时代码的途径，这时候就会希望Java服务器中也有提供类似Groovy Console的功能。

JDK 1.6之后提供了Compiler API，可以动态地编译Java程序，虽然这样达不到动态语言的灵活度，但让服务器执行临时代码的需求就可以得到解决了。在JDK 1.6之前，也可以通过其他方式来做到，譬如写一个JSP文件上传到服务器，然后在浏览器中运行它，或者在服务端程序中加入一个BeanShell Script、JavaScript等的执行引擎（如Mozilla Rhino^[1]）去执行动态脚本。在本章的实战部分，我们将使用前面学到的关于类加载及虚拟机执行子系统的知识去实现在服务端执行临时代码的功能。

9.3.1 目标

首先，在实现“在服务端执行临时代码”这个

需求之前，先来明确一下本次实战的具体目标，
我们希望最终的产品是这样的：

不依赖JDK版本，能在目前还普遍使用的
JDK中部署，也就是使用JDK 1.4~JDK 1.7都可
以运行。

不改变原有服务端程序的部署，不依赖任何
第三方类库。

不侵入原有程序，即无须改动原程序的任何
代码，也不会对原有程序的运行带来任何影响。

考虑到BeanShell Script或JavaScript等脚本编写
起来不太方便，“临时代码”需要直接支持Java语
言。

“临时代码”应当具备足够的自由度，不需要

依赖特定的类或实现特定的接口。这里写的是“不需要”而不是“不可以”，当“临时代码”需要引用其他类库时也没有限制，只要服务端程序能使用的，临时代码应当都能直接引用。

“临时代码”的执行结果能返回到客户端，执行结果可以包括程序中输出的信息及抛出的异常等。

看完上面列出的目标，你觉得完成这个需求需要做多少工作呢？也许答案比大多数人所想的都要简单一些：5个类，250行代码（含注释），大约一个半小时左右的开发时间就可以了，现在就开始编写程序吧！

[1]Rhino站点：<http://www.mozilla.org/rhino/>，
Rhino已被收编入JDK 1.6中。

9.3.2 思路

在程序实现的过程中，我们需要解决以下3个问题：

如何编译提交到服务器的Java代码？

如何执行编译之后的Java代码？

如何收集Java代码的执行结果？

对于第一个问题，我们有两种思路可以选择，一种是使用tools.jar包（在Sun JDK/lib目录下）中的com.sun.tools.javac.Main类来编译Java文件，这其实和使用Javac命令编译是一样的。这种思路的缺点是引入了额外的JAR包，而且把程

序“绑死”在Sun的JDK上了，要部署到其他公司的JDK中还得把tools.jar带上（虽然JRockit和J9虚拟机也有这个JAR包，但它总不是标准所规定必须存在的）。另外一种思路是直接在客户端编译好，把字节码而不是Java代码传到服务端，这听起来好像有点投机取巧，一般来说确实不应该假定客户端一定具有编译代码的能力，但是既然程序员会写Java代码去给服务端排查问题，那么很难想象他的机器上会连编译Java程序的环境都没有。

对于第二个问题，简单地一想：要执行编译后的Java代码，让类加载器加载这个类生成一个Class对象，然后反射调用一下某个方法就可以了（因为不实现任何接口，我们可以借用一下Java中人人皆知的“main（）”方法）。但我们还应该

考虑得更周全些：一段程序往往不是编写、运行一次就能达到效果，同一个类可能要反复地修改、提交、执行。另外，提交上去的类要能访问服务端的其他类库才行。还有，既然提交的是临时代码，那提交的Java类在执行完后就应当能卸载和回收。

最后的一个问题，我们想把程序往标准输出（`System.out`）和标准错误输出（`System.err`）中打印的信息收集起来，但标准输出设备是整个虚拟机进程全局共享的资源，如果使用`System.setOut()`/`System.setErr()`方法把输出流重定向到自己定义的`PrintStream`对象上固然可以收集输出信息，但也会对原有程序产生影响：会把其他线程向标准输出中打印的信息也收集了。虽然这些并不是不能解决的问题，不过为了达到

完全不影响原程序的目的，我们可以采用另外一种办法，即直接在执行的类中把对System.out的符号引用替换为我们准备的PrintStream的符号引用，依赖前面学习的知识，做到这一点并不困难。

9.3.3 实现

在程序实现部分，我们主要看一下代码及其注释。首先看看实现过程中需要用到的4个支持类。第一个类用于实现“同一个类的代码可以被多次加载”这个需求，即用于解决9.3.1节中列举的第2个问题的HotSwapClassLoader，具体程序如代码清单9-3所示。

代码清单9-3 HotSwapClassLoader的实现

```
 /**
 *为了多次载入执行类而加入的加载器<br>
 *把defineClass方法开放出来，只有外部显式调用的时候
才会使用到loadByte方法
 *由虚拟机调用时，仍然按照原有的双亲委派规则使用
loadClass方法进行类加载
 *
 *@author zzm
 */
public class HotSwapClassLoader extends
```

```
ClassLoader{  
    public HotSwapClassLoader () {  
        super (HotSwapClassLoader.class.getClassLoader());  
    }  
    public Class loadByte (byte[] classByte) {  
        return defineClass (null, classByte, 0,  
classByte.length);  
    }  
}
```

HotSwapClassLoader所做的事情仅仅是公开父类（即java.lang.ClassLoader）中的protected方法defineClass（），我们将会使用这个方法把提交执行的Java类的byte[]数组转变为Class对象。HotSwapClassLoader中并没有重写loadClass（）或findClass（）方法，因此如果不考虑外部手工调用loadByte（）方法的话，这个类加载器的类查找范围与它的父类加载器是完全一致的，在被虚拟机调用时，它会按照双亲委派模型交给父类加载。构造函数中指定为加载HotSwapClassLoader

类的类加载器作为父类加载器，这一步是实现提交的执行代码可以访问服务端引用类库的关键，下面我们来看看代码清单9-3。

第二个类是实现将java.lang.System替换为我们自己定义的HackSystem类的过程，它直接修改符合Class文件格式的byte[]数组中的常量池部分，将常量池中指定内容的CONSTANT_Utf8_info常量替换为新的字符串，具体代码如代码清单9-4所示。ClassModifier中涉及对byte[]数组操作的部分，主要是将byte[]与int和String互相转换，以及把对byte[]数据的替换操作封装在代码清单9-5所示的ByteUtils中。

代码清单9-4 ClassModifier的实现

```
/**
```

```
*修改Class文件，暂时只提供修改常量池常量的功能
*@author zzm
*/
public class ClassModifier{
    /**
     *Class文件中常量池的起始偏移
    */
    private static final int
CONSTANT_POOL_COUNT_INDEX=8;
    /**
     *CONSTANT_Utf8_info常量的tag标志
    */
    private static final int
CONSTANT_Utf8_info=1;
    /**
     *常量池中11种常量所占的长度，CONSTANT_Utf8_info
型常量除外，因为它不是定长的
    */
    private static final
int[]CONSTANT_ITEM_LENGTH={-1, -1, -1, 5, 5, 9,
9, 3, 3, 5, 5, 5};
    private static final int u1=1;
    private static final int u2=2;
    private byte[]classByte;
    public ClassModifier (byte[]classByte) {
        this.classByte=classByte;
    }
    /**
     *修改常量池中CONSTANT_Utf8_info常量的内容
     *@param oldStr修改前的字符串
     *@param newStr修改后的字符串
     *@return修改结果
    */
    public byte[]modifyUTF8Constant (String
```

```
oldStr, String newStr) {
    int cpc=getConstantPoolCount () ;
    int offset=CONSTANT_POOL_COUNT_INDEX+u2;
    for (int i=0; i<cpc; i++) {
        int
tag=ByteUtils.bytes2Int (classByte,offset,u1) ;
        if (tag==CONSTANT_Utf8_info) {
            int
len=ByteUtils.bytes2Int (classByte,offset+u1,
u2) ;
            offset+= (u1+u2) ;
            String
str=ByteUtils.bytes2String (classByte,offset,len
            if (str.equalsIgnoreCase (oldStr) ) {
                byte[] strBytes=ByteUtils.string2Bytes (newSt
                byte[] strLen=ByteUtils.int2Bytes (newStr.length
u2) ;
                classByte=ByteUtils.bytesReplace (classByte,c
u2, u2, strLen) ;
                classByte=ByteUtils.bytesReplace (classByte,c
                return classByte;
            }else{
                offset+=len;
            }
        }else{
            offset+=CONSTANT_ITEM_LENGTH[tag];
        }
    }
    return classByte;
}
/***
 *获取常量池中常量的数量
 *@return常量池数量
 */
```

```
public int getConstantPoolCount () {  
    return  
ByteUtils.bytes2Int (classByte, CONSTANT_POOL_COU  
    }  
    }
```

代码清单9-5 ByteUtils的实现

```
/**  
 *Bytes数组处理工具  
 *@author  
 */  
public class ByteUtils{  
    public static int bytes2Int (byte[]b,int  
start,int len) {  
        int sum=0;  
        int end=start+len;  
        for (int i=start; i<end; i++) {  
            int n= ( (int) b[i] ) &0xff;  
            n<<= (-len) *8;  
            sum=n+sum;  
        }  
        return sum;  
    }  
    public static byte[]int2Bytes (int value,int  
len) {  
        byte[]b=new byte[len];  
        for (int i=0; i<len; i++) {  
            b[len-i-1]= (byte) ( (value>>8*i) &0xff) ;  
        }  
        return b;
```

```
    }
    public static String
bytes2String (byte[]b,int start,int len) {
    return new String (b,start,len) ;
}
    public static byte[]string2Bytes (String
str) {
    return str.getBytes () ;
}
    public static
byte[]bytesReplace (byte[]originalBytes,int
offset,int len,byte[]replaceBytes) {
    byte[]newBytes=new
byte[originalBytes.length+
(replaceBytes.length-len)];
    System.arraycopy (originalBytes, 0,
newBytes, 0, offset) ;
    System.arraycopy (replaceBytes, 0,
newBytes,offset,replaceBytes.length) ;
    System.arraycopy (originalBytes,offset+len,new
offset-len) ;
    return newBytes;
}
}
```

经过ClassModifier处理后的byte[]数组才会传
给HotSwapClassLoader.loadByte () 方法进行类
加载，byte[]数组在这里替换符号引用之后，与客

客户端直接在Java代码中引用HackSystem类再编译生成的Class是完全一样的。这样的实现既避免了客户端编写临时执行代码时要依赖特定的类（不然无法引入HackSystem），又避免了服务端修改标准输出后影响到其他程序的输出。下面我们来看看代码清单9-4和代码清单9-5。

最后一个类就是前面提到过的用来代替java.lang.System的HackSystem，这个类中的方法看起来不少，但其实除了把out和err两个静态变量改成使用ByteArrayOutputStream作为打印目标的同一个PrintStream对象，以及增加了读取、清理ByteArrayOutputStream中内容的getBufferString（）和clearBuffer（）方法外，就再没有其他新鲜的内容了。其余的方法全部都来自于System类的public方法，方法名字、参数、返

回值都完全一样，并且实现也是直接转调了System类的对应方法而已。保留这些方法的目的，是为了在System被替换成HackSystem之后，执行代码中调用的System的其余方法仍然可以继续使用，HackSystem的实现如代码清单9-6所示。

代码清单9-6 HackSystem的实现

```
 /**
 *为JavaClass劫持java.lang.System提供支持
 *除了out和err外，其余的都直接转发给System处理
 *
 *@author zzm
 */
public class HackSystem{
    public final static InputStream
in=System.in;
    private static ByteArrayOutputStream
buffer=new ByteArrayOutputStream();
    public final static PrintStream out=new
PrintStream(buffer);
    public final static PrintStream err=out;
    public static String getBufferString(){
        return buffer.toString();
    }
    public static void clearBuffer(){
    }
}
```

```
buffer.reset () ;  
}  
public static void setSecurityManager (final  
SecurityManager s) {  
    System.setSecurityManager (s) ;  
}  
public static SecurityManager  
getSecurityManager () {  
    return System.getSecurityManager () ;  
}  
public static long currentTimeMillis () {  
    return System.currentTimeMillis () ;  
}  
public static void arraycopy (Object src,int  
srcPos, Object dest,int destPos,int length) {  
    System.arraycopy (src,srcPos,dest,destPos,length)  
}  
public static int identityHashCode (Object  
x) {  
    return System.identityHashCode (x) ;  
}  
//下面所有的方法都与java.lang.System的名称一样  
//实现都是字节转调System的对应方法  
//因版面原因，省略了其他方法  
}
```

至此，4个支持类已经讲解完毕，我们来看看最后一个类JavaClassExecuter，它是提供给外部调用的入口，调用前面几个支持类组装逻辑，

完成类加载工作。JavaClassExecuter只有一个 execute（）方法，用输入的符合Class文件格式的 byte[] 数组替换 java.lang.System 的符号引用后，使用 HotSwapClassLoader 加载生成一个 Class 对象，由于每次执行 execute（）方法都会生成一个新的类加载器实例，因此同一个类可以实现重复加载。然后，反射调用这个 Class 对象的 main（）方法，如果期间出现任何异常，将异常信息打印到 HackSystem.out 中，最后把缓冲区中的信息作为方法的结果返回。JavaClassExecuter 的实现代码如代码清单 9-7 所示。

代码清单 9-7 JavaClassExecuter 的实现

```
/**  
 * JavaClass 执行工具  
 *  
 * @author zzm
```

```
/*
public class JavaClassExecuter{
 /**
 *执行外部传过来的代表一个Java类的byte数组<br>
 *将输入类的byte数组中代表java.lang.System的
CONSTANT_Utf8_info常量修改为劫持后的HackSystem类
 *执行方法为该类的static main (String[]args) 方法，输出结果为该类向System.out/err输出的信息
 *@param classByte代表一个Java类的byte数组
 *@return执行结果
 */
public static String
execute (byte[]classByte) {
    HackSystem.clearBuffer () ;
    ClassModifier cm=new
ClassModifier (classByte) ;
    byte[]modiBytes=cm.modifyUTF8Constant ("java,
    HotSwapClassLoader loader=new
HotSwapClassLoader () ;
    Class clazz=loader.loadByte (modiBytes) ;
    try{
        Method method=clazz.getMethod ("main", new
Class[]{String[].class}) ;
        method.invoke (null,new String[]{null}) ;
    }catch (Throwable e) {
        e.printStackTrace (HackSystem.out) ;
    }
    return HackSystem.getBufferString () ;
}
```

9.3.4 验证

远程执行功能的编码到此就完成了，接下来就要检验一下我们的劳动成果了。如果只是测试的话，那么可以任意写一个Java类，内容无所谓，只要向System.out输出信息即可，取名为TestClass，同时放到服务器C盘的根目录中。然后，建立一个JSP文件并加入如代码清单9-8所示的内容，就可以在浏览器中看到这个类的运行结果了。

代码清单9-8 测试JSP

```
<%@page import="java.lang.*"%>
<%@page import="java.io.*"%>
<%@page
import="org.fenixsoft.classloading.execute.*"%>
```

```
<%  
InputStream is=new  
FileInputStream ("c:/TestClass.class") ;  
byte[]b=new byte[is.available () ];  
is.read (b) ;  
is.close () ;  
out.println (<textarea style='width: 1000;  
height=800'>");  
out.println (JavaClassExecuter.execute (b) ) ;  
out.println ("</textarea>");  
%>
```

当然，上面的做法只是用于测试和演示，实际使用这个JavaExecuter执行器的时候，如果还要手工复制一个Class文件到服务器上就没有什么意义了。笔者给这个执行器写了一个“外壳”，是一个Eclipse插件，可以把Java文件编译后传输到服务器中，然后把执行器的返回结果输出到Eclipse的Console窗口里，这样就可以在有灵感的时候随时写几行调试代码，放到测试环境的服务器上立即运行了。虽然实现简单，但效果很不错，对调

试问题也非常有用，如图9-4所示。



图 9-4 JavaClassExecuter的使用

9.4 本章小结

本书第6~9章介绍了Class文件格式、类加载及虚拟机执行引擎几部分内容，这些内容是虚拟机中必不可少的组成部分，只有了解了虚拟机如何执行程序，才能更好地理解怎样写出优秀的代码。

关于虚拟机执行子系统的介绍到此就结束了，通过这4章的讲解，我们描绘了一个虚拟机应该怎样运行Class文件的概念模型。对于具体到某个虚拟机的实现，为了使实现简单、清晰，或者为了更快的运行速度，在虚拟机内部的运作跟概念模型可能会有非常大的差异，但从最终的执行结果来看应该是一致的。从第10章开始，我们

将探索虚拟机在语法和运行性能上是如何对程序编写做出各种优化的。

第四部分 程序编译与代码优化

第10章 早期（编译期）优化

第11章 晚期（运行期）优化

第10章 早期（编译期）优化

从计算机程序出现的第一天起，对效率的追求就是程序天生的坚定信仰，这个过程犹如一场没有终点、永不停歇的F1方程式竞赛，程序员是车手，技术平台则是在赛道上飞驰的赛车。

10.1 概述

Java语言的“编译期”其实是一段“不确定”的操作过程，因为它可能是指一个前端编译器（其实叫“编译器的前端”更准确一些）把*.java文件转变成*.class文件的过程；也可能是指虚拟机的后端运行期编译器（JIT编译器，Just In Time Compiler）把字节码转变成机器码的过程；还可能是指使用静态提前编译器（AOT编译器，

Ahead Of Time Compiler) 直接把*.java文件编译成本地机器代码的过程。下面列举了这3类编译过程中一些比较有代表性的编译器。

前端编译器：Sun的Javac、Eclipse JDT中的增量式编译器（ECJ）^[1]。

JIT编译器：HotSpot VM的C1、C2编译器。

AOT编译器：GNU Compiler for the Java（GCJ）^[2]、Excelsior JET^[3]。

这3类过程中最符合大家对Java程序编译认知的应该是第一类，在本章的后续文字里，笔者提到的“编译期”和“编译器”都仅限于第一类编译过程，把第二类编译过程留到下一章中讨论。限制了编译范围后，我们对于“优化”二字的定义就需

要宽松一些，因为Javac这类编译器对代码的运行效率几乎没有任何优化措施（在JDK 1.3之后，Javac的-O优化参数就不再有意义）。虚拟机设计团队把对性能的优化集中到了后端的即时编译器中，这样可以让那些不是由Javac产生的Class文件（如JRuby、Groovy等语言的Class文件）也同样能享受到编译器优化所带来的好处。但是Javac做了许多针对Java语言编码过程的优化措施来改善程序员的编码风格和提高编码效率。相当多新生的Java语法规特性，都是靠编译器的“语法糖”来实现，而不是依赖虚拟机的底层改进来支持，可以说，Java中即时编译器在运行期的优化过程对于程序运行来说更重要，而前端编译器在编译期的优化过程对于程序编码来说关系更加密切。

[1]JDT官方站点：<http://www.eclipse.org/jdt/>。

[2]GCJ官方站点：<http://gcc.gnu.org/java/>。

[3]Excelsior JET官方站点：<http://www.excelsior-usa.com/>。

10.2 Javac编译器

分析源码是了解一项技术的实现内幕最有效的手段，Javac编译器不像HotSpot虚拟机那样使用C++语言（包含少量C语言）实现，它本身就是一个由Java语言编写的程序，这为纯Java的程序员了解它的编译过程带来了很大的便利。

10.2.1 Javac的源码与调试

Javac的源码存放在

JDK_SRC_HOME/langtools/src/share/classes/com/sun中^[1]，除了JDK自身的API外，就只引用了JDK_SRC_HOME/langtools/src/share/classes/com/sun里面的代码，调试环境建立起来简单方便，因为

基本上不需要处理依赖关系。

以Eclipse IDE环境为例，先建立一个名为“Compiler_javac”的Java工程，然后把JDK_SRC_HOME/langtools/src/share/classes/com/sun目录下的源文件全部复制到工程的源码目录中，如图10-1所示。




图 10-1 Eclipse 中的 Javac 工程

导入代码期间，源码文件“AnnotationProxyMaker.java”可能会提示“Access Restriction”，被 Eclipse 拒绝编译，如图 10-2 所示。

```
/**  
 * Returns a dynamic proxy for an annotation mirror.  
 */  
private Annotation generateAnnotation() {  
    return AnnotationParser.annotationForMap(annotationType,  
} // Access restriction: The method annotationForMap(Class, Map<String, Object>) :  
// AnnotationParser is not accessible due to restriction on required library  
D:\_DevSpace\jdk1.6.0_21\jre\lib\rt.jar  
/**
```

图 10-2 AnnotationProxyMaker被拒绝编译

这是由于Eclipse的JRE System Library中默认包含了一系列的代码访问规则（Access Rules），如果代码中引用了这些访问规则所禁止引用的类，就会提示这个错误。可以通过添加一条允许访问JAR包中所有类的访问规则来解决这个问题，如图10-3所示。




图 10-3 设置访问规则

导入了Javac的源码后，就可以运行 com.sun.tools.javac.Main 的 main() 方法来执行编译了，与命令行中使用Javac的命令没有什么区别，编译的文件与参数在Eclipse的“Debug Configurations”面板中的“Arguments”页签中指定。

虚拟机规范严格定义了Class文件的格式，但是《Java虚拟机规范（第2版）》中，虽然有专门

的一章“Compiling for the Java Virtual Machine”，但都是以举例的形式描述，并没有对如何把Java源码文件转变为Class文件的编译过程进行十分严格的规定，这导致Class文件编译在某种程度上是与具体JDK实现相关的，在一些极端情况，可能出现一段代码Javac编译器可以编译，但是ECJ编译器就不可以编译的问题（10.3.1节中将会给出这样的例子）。从Sun Javac的代码来看，编译过程大致可以分为3个过程，分别是：

解析与填充符号表过程。

插入式注解处理器的注解处理过程。

分析与字节码生成过程。

这3个步骤之间的关系与交互顺序如图10-4所

示。



图 10-4 Javac的编译过程^[2]

Javac编译动作的入口是

com.sun.tools.javac.main.JavaCompiler类，上述3个过程的代码逻辑集中在这个类的compile（）和compile2（）方法中，其中主体代码如图10-5所示，整个编译最关键的处理就由图中标注的8个方法来完成，下面我们具体看一下这8个方法实现了什么功能。



图 10-5 Javac编译过程的主体代码

[1]关于如何获取OpenJDK源码，请参考本书第1章。

[2]图片来源：

http://openjdk.java.net/groups/compiler/doc/compilation_overview/index.html，本书对相关术语进行了翻译。

10.2.2 解析与填充符号表

解析步骤由图10-5中的parseFiles（）方法（图10-5中的过程1.1）完成，解析步骤包括了经典程序编译原理中的词法分析和语法分析两个过程。

1. 词法、语法分析

词法分析是将源代码的字符流转变为标记（Token）集合，单个字符是程序编写过程的最小元素，而标记则是编译过程的最小元素，关键字、变量名、字面量、运算符都可以成为标记，如“int a=b+2”这句代码包含了6个标记，分别是int、a、=、b、+、2，虽然关键字int由3个字符构

成，但是它只是一个Token，不可再拆分。在Javac的源码中，词法分析过程由com.sun.tools.javac.parser.Scanner类来实现。

语法分析是根据Token序列构造抽象语法树的过程，抽象语法树（Abstract Syntax Tree,AST）是一种用来描述程序代码语法结构的树形表示方式，语法树的每一个节点都代表着程序代码中的一个语法结构（Construct），例如包、类型、修饰符、运算符、接口、返回值甚至代码注释等都可以是一个语法结构。

图10-6是根据Eclipse AST View插件分析出来的某段代码的抽象语法树视图，读者可以通过这张图对抽象语法树有一个直观的认识。在Javac的源码中，语法分析过程由

com.sun.tools.javac.parser.Parser类实现，这个阶段
产出的抽象语法树由
com.sun.tools.javac.tree.JCTree类表示，经过这个
步骤之后，编译器就基本不会再对源码文件进行
操作了，后续的操作都建立在抽象语法树之上。




图 10-6 抽象语法树结构视图

2. 填充符号表

完成了语法分析和词法分析之后，下一步就

是填充符号表的过程，也就是图10-5中enterTrees（）方法（图10-5中的过程1.2）所做的事情。符号表（Symbol Table）是由一组符号地址和符号信息构成的表格，读者可以把它想象成哈希表中K-V值对的形式（实际上符号表不一定是哈希表实现，可以是有序符号表、树状符号表、栈结构符号表等）。符号表中所登记的信息在编译的不同阶段都要用到。在语义分析中，符号表所登记的内容将用于语义检查（如检查一个名字的使用和原先的说明是否一致）和产生中间代码。在目标代码生成阶段，当对符号名进行地址分配时，符号表是地址分配的依据。

在Javac源代码中，填充符号表的过程由com.sun.tools.javac.comp.Enter类实现，此过程的出口是一个待处理列表（To Do List），包含了每

一个编译单元的抽象语法树的顶级节点，以及 package-info.java（如果存在的话）的顶级节点。

10.2.3 注解处理器

在JDK 1.5之后，Java语言提供了对注解（Annotation）的支持，这些注解与普通的Java代码一样，是在运行期间发挥作用的。在JDK 1.6中实现了JSR-269规范^[1]，提供了一组插入式注解处理器的标准API在编译期间对注解进行处理，我们可以把它看做是一组编译器的插件，在这些插件里面，可以读取、修改、添加抽象语法树中的任意元素。如果这些插件在处理注解期间对语法树进行了修改，编译器将回到解析及填充符号表的过程重新处理，直到所有插入式注解处理器都没有再对语法树进行修改为止，每一次循环称为一个Round，也就是图10-4中的回环过程。

有了编译器注解处理的标准API后，我们的代码才有可能干涉编译器的行为，由于语法树中的任意元素，甚至包括代码注释都可以在插件之中访问到，所以通过插入式注解处理器实现的插件在功能上有很大的发挥空间。只要有足够的创意，程序员可以使用插入式注解处理器来实现许多原本只能在编码中完成的事情，本章最后会给出一个使用插入式注解处理器的简单实战。

在Javac源码中，插入式注解处理器的初始化过程是在initPorcessAnnotations（）方法中完成的，而它的执行过程则是在processAnnotations（）方法中完成的，这个方法判断是否还有新的注解处理器需要执行，如果有的话，通过com.sun.tools.javac.processing.JavacProcessingEnvir

类的doProcessing（）方法生成一个新的JavaCompiler对象对编译的后续步骤进行处理。

[1]JSR-269：Pluggable Annotations Processing API（插入式注解处理API）。

10.2.4 语义分析与字节码生成

语法分析之后，编译器获得了程序代码的抽象语法树表示，语法树能表示一个结构正确的源程序的抽象，但无法保证源程序是符合逻辑的。而语义分析的主要任务是对结构上正确的源程序进行上下文有关性质的审查，如进行类型审查。举个例子，假设有如下的3个变量定义语句：

```
int a=1;
boolean b=false;
char c=2;
```

后续可能出现的赋值运算：

```
int d=a+c;
int d=b+c;
char d=a+c;
```

后续代码中如果出现了如上3种赋值运算的话，那它们都能构成结构正确的语法树，但是只有第1种的写法在语义上是没有问题的，能够通过编译，其余两种在Java语言中是不合逻辑的，无法编译（是否合乎语义逻辑必须限定在具体的语言与具体的上下文环境之中才有意义。如在C语言中，a、b、c的上下文定义不变，第2、3种写法都是可以正确编译）。

1. 标注检查

Javac的编译过程中，语义分析过程分为标注检查以及数据及控制流分析两个步骤，分别由图10-5中所示的attribute（）和flow（）方法（分别对应图10-5中的过程3.1和过程3.2）完成。

标注检查步骤检查的内容包括诸如变量使用

前是否已被声明、变量与赋值之间的数据类型是否能够匹配等。在标注检查步骤中，还有一个重要的动作称为常量折叠，如果我们在代码中写了如下定义：

```
int a=1+2;
```

那么在语法树上仍然能看到字面量“1”、“2”以及操作符“+”，但是在经过常量折叠之后，它们将会被折叠为字面量“3”，如图10-7所示，这个插入式表达式（Infix Expression）的值已经在语法树上标注出来了

（ConstantExpressionValue: 3）。由于编译期间进行了常量折叠，所以在代码里面定义“`a=1+2`”比起直接定义“`a=3`”，并不会增加程序运行期哪怕仅仅一个CPU指令的运算量。

```
• INITIALIZER
  • InfixExpression [105, 5]
    • > (Expression) type binding: int
      NAME: 'int'
      KEY: 'I'
      IS RECOVERED: false
      QUALIFIED NAME: 'int'
      KIND: isPrimitive
    • > CREATE ARRAY TYPE (+1): int[]
      BINARY NAME: 'I'
      ANNOTATIONS (0)
      >java element: null
      Boxing: false; Unboxing: false
      ConstantExpressionValue: 3
  • LEFT_OPERAND
    • > NumberLiteral [105, 1]
    OPERATOR: '+'
  • RIGHT_OPERAND
    • > NumberLiteral [109, 1]
```

图 10-7 常量折叠

标注检查步骤在Javac源码中的实现类是
com.sun.tools.javac.comp.Attr类和
com.sun.tools.javac.comp.Check类。

2. 数据及控制流分析

数据及控制流分析是对程序上下文逻辑更进一步的验证，它可以检查出诸如程序局部变量在使用前是否有赋值、方法的每条路径是否都有返回值、是否所有的受查异常都被正确处理了等问题。编译时期的数据及控制流分析与类加载时的数据及控制流分析的目的基本上是一致的，但校验范围有所区别，有一些校验项只有在编译期或运行期才能进行。下面举一个关于final修饰符的数据及控制流分析的例子，见代码清单10-1。

代码清单10-1 final语义校验

```
//方法一带有final修饰
public void foo (final int arg) {
    final int var=0;
    //do something
}
```

```
//方法二没有final修饰
public void foo (int arg) {
    int var=0;
    //do something
}
```

在这两个foo（）方法中，第一种方法的参数和局部变量定义使用了final修饰符，而第二种方法则没有，在代码编写时程序肯定会受到final修饰符的影响，不能再改变arg和var变量的值，但是这两段代码编译出来的Class文件是没有任何一点区别的，通过第6章的讲解我们已经知道，局部变量与字段（实例变量、类变量）是有区别的，它在常量池中没有CONSTANT_Fieldref_info的符号引用，自然就没有访问标志（Access_Flags）的信息，甚至可能连名称都不会保留下来（取决于编译时的选项），自然在Class文件中不可能知道一个局部变量是不是声明

为final了。因此，将局部变量声明为final，对运行期是没有影响的，变量的不变性仅仅由编译器在编译期间保障。在Javac的源码中，数据及控制流分析的入口是图10-5中的flow（）方法（对应图10-5中的过程3.2），具体操作由com.sun.tools.javac.comp.Flow类来完成。

3.解语法糖

语法糖（Syntactic Sugar），也称糖衣语法，是由英国计算机科学家彼得·约翰·兰达（Peter J.Landin）发明的一个术语，指在计算机语言中添加的某种语法，这种语法对语言的功能并没有影响，但是更方便程序员使用。通常来说，使用语法糖能够增加程序的可读性，从而减少程序代码出错的机会。

Java在现代编程语言之中属于“低糖语言”（相对于C#及许多其他JVM语言来说），尤其是JDK 1.5之前的版本，“低糖”语法也是Java语言被怀疑已经“落后”的一个表面理由。Java中最常用的语法糖主要是前面提到过的泛型（泛型并不一定都是语法糖实现，如C#的泛型就是直接由CLR支持的）、变长参数、自动装箱/拆箱等，虚拟机运行时不支持这些语法，它们在编译阶段还原回简单的基础语法结构，这个过程称为解语法糖。Java的这些语法糖被解除后是什么样子，将在10.3节中详细讲述。

在Javac的源码中，解语法糖的过程由desugar()方法触发，在com.sun.tools.javac.comp.TransTypes类和com.sun.tools.javac.comp.Lower类中完成。

4. 字节码生成

字节码生成是Javac编译过程的最后一个阶段，在Javac源码里面由com.sun.tools.javac.jvm.Gen类来完成。字节码生成阶段不仅仅是把前面各个步骤所生成的信息（语法树、符号表）转化成字节码写到磁盘中，编译器还进行了少量的代码添加和转换工作。

例如，前面章节中多次提到的实例构造器<init>()方法和类构造器<clinit>()方法就是在这个阶段添加到语法树之中的（注意，这里的实例构造器并不是指默认构造函数，如果用户代码中没有提供任何构造函数，那编译器将会添加一个没有参数的、访问性（public、protected或private）与当前类一致的默认构造函数，这个工

作在填充符号表阶段就已经完成），这两个构造器的产生过程实际上是一个代码收敛的过程，编译器会把语句块（对于实例构造器而言是“{}”块，对于类构造器而言是“static{}”块）、变量初始化（实例变量和类变量）、调用父类的实例构造器（仅仅是实例构造器，`<clinit>()`方法中无须调用父类的`<clinit>()`方法，虚拟机会自动保证父类构造器的执行，但在`<clinit>()`方法中经常会生成调用`java.lang.Object`的`<init>()`方法的代码）等操作收敛到`<init>()`和`<clinit>()`方法之中，并且保证一定是按先执行父类的实例构造器，然后初始化变量，最后执行语句块的顺序进行，上面所述的动作由`Gen.normalizeDefs()`方法来实现。除了生成构造器以外，还有其他的一些代码替换工作用于优

化程序的实现逻辑，如把字符串的加操作替换为 StringBuffer或StringBuilder（取决于目标代码的版本是否大于或等于JDK 1.5）的append（）操作等。

完成了对语法树的遍历和调整之后，就会把填充了所有所需信息的符号表交给 com.sun.tools.javac.jvm.ClassWriter类，由这个类的writeClass（）方法输出字节码，生成最终的 Class文件，到此为止整个编译过程宣告结束。

10.3 Java语法糖的味道

几乎各种语言或多或少都提供过一些语法糖来方便程序员的代码开发，这些语法糖虽然不会提供实质性的功能改进，但是它们或能提高效率，或能提升语法的严谨性，或能减少编码出错的机会。不过也有一种观点认为语法糖并不一定都是有益的，大量添加和使用“含糖”的语法，容易让程序员产生依赖，无法看清语法糖的糖衣背后，程序代码的真实面目。

总而言之，语法糖可以看做是编译器实现的一些“小把戏”，这些“小把戏”可能会使得效率“大提升”，但我们也应该去了解这些“小把戏”背后的真实世界，那样才能利用好它们，而不是被它们

所迷惑。

10.3.1 泛型与类型擦除

泛型是JDK 1.5的一项新增特性，它的本质是参数化类型（Parametersized Type）的应用，也就是说所操作的数据类型被指定为一个参数。这种参数类型可以用在类、接口和方法的创建中，分别称为泛型类、泛型接口和泛型方法。

泛型思想早在C++语言的模板（Template）中就开始生根发芽，在Java语言处于还没有出现泛型的版本时，只能通过Object是所有类型的父类和类型强制转换两个特点的配合来实现类型泛化。例如，在哈希表的存取中，JDK 1.5之前使用HashMap的get（）方法，返回值就是一个Object

对象，由于Java语言里面所有的类型都继承于java.lang.Object，所以Object转型成任何对象都是有可能的。但是也因为有无限的可能性，就只有程序员和运行期的虚拟机才知道这个Object到底是个什么类型的对象。在编译期间，编译器无法检查这个Object的强制转型是否成功，如果仅仅依赖程序员去保障这项操作的正确性，许多ClassCastException的风险就会转嫁到程序运行期之中。

泛型技术在C#和Java之中的使用方式看似相同，但实现上却有着根本性的分歧，C#里面泛型无论在程序源码中、编译后的IL中（Intermediate Language，中间语言，这时候泛型是一个占位符），或是运行期的CLR中，都是切实存在的，List<int>与List<String>就是两个不同的类型，

它们在系统运行期生成，有自己的虚方法表和类型数据，这种实现称为类型膨胀，基于这种方法实现的泛型称为真实泛型。

Java语言中的泛型则不一样，它只在程序源码中存在，在编译后的字节码文件中，就已经替换为原来的原生类型（Raw Type，也称为裸类型）了，并且在相应的地方插入了强制转型代码，因此，对于运行期的Java语言来说，`ArrayList<int>`与`ArrayList<String>`就是同一个类，所以泛型技术实际上是Java语言的一颗语法糖，Java语言中的泛型实现方法称为类型擦除，基于这种方法实现的泛型称为伪泛型。

代码清单10-2是一段简单的Java泛型的例子，我们可以看一下它编译后的结果是怎样的。

代码清单10-2 泛型擦除前的例子

```
public static void main (String[]args) {  
    Map<String, String>map=new HashMap<  
String, String> () ;  
    map.put ("hello", "你好") ;  
    map.put ("how are you?", "吃了没? ") ;  
    System.out.println (map.get ("hello")) ;  
    System.out.println (map.get ("how are  
you?")) ;  
}
```

把这段Java代码编译成Class文件，然后再用字节码反编译工具进行反编译后，将会发现泛型都不见了，程序又变回了Java泛型出现之前的写法，泛型类型都变回了原生类型，如代码清单10-3所示。

代码清单10-3 泛型擦除后的例子

```
public static void main (String[]args) {  
    Map map=new HashMap () ;  
    map.put ("hello", "你好") ;
```

```
map.put ("how are you?", "吃了没？");  
System.out.println ((String)  
map.get ("hello"));  
System.out.println ((String) map.get ("how  
are you?"));  
}
```

当初JDK设计团队为什么选择类型擦除的方式来实现Java语言的泛型支持呢？是因为实现简单、兼容性考虑还是别的原因？我们已不得而知，但确实有不少人对Java语言提供的伪泛型颇有微词，当时甚至连《Thinking in Java》一书的作者Bruce Eckel也发表了一篇文章《这不是泛型！》^[1]来批评JDK 1.5中的泛型实现。

在当时众多的批评之中，有一些是比较表面的，还有一些从性能上说泛型会由于强制转型操作和运行期缺少针对类型的优化等从而导致比C#的泛型慢一些，则是完全偏离了方向，姑且不论

Java泛型是不是真的会比C#泛型慢，选择从性能的角度上评价用于提升语义准确性的泛型思想就不太恰当。但笔者也并非在为Java的泛型辩护，它在某些场景下确实存在不足，笔者认为通过擦除法来实现泛型丧失了一些泛型思想应有的优雅，例如代码清单10-4的例子。

代码清单10-4 当泛型遇见重载1

```
public class GenericTypes{
    public static void method (List<String>
list) {
        System.out.println ("invoke method (List<
String>list) ");
    }
    public static void method (List<Integer>
list) {
        System.out.println ("invoke method (List<
Integer>list) ");
    }
}
```

请想一想，上面这段代码是否正确，能否编译执行？也许你已经有了答案，这段代码是不能被编译的，因为参数List<Integer>和List<String>编译之后都被擦除了，变成了一样的原生类型List<E>，擦除动作导致这两种方法的特征签名变得一模一样。初步看来，无法重载的原因已经找到了，但真的就是如此吗？只能说，泛型擦除成相同的原生类型只是无法重载的其中一部分原因，请再接着看一看代码清单10-5中的内容。

代码清单10-5 当泛型遇见重载2

```
public class GenericTypes{
    public static String method (List<String>
list) {
        System.out.println ("invoke method (List<
String>list) ");
        return "";
    }
    public static int method (List<Integer>
list) {
```

```
System.out.println ("invoke method (List< Integer>list) " );
return 1;
}
public static void main (String[]args) {
method (new ArrayList<String> () );
method (new ArrayList<Integer> () );
}
}
```

执行结果：

```
invoke method (List<String>list)
invoke method (List<Integer>list)
```

代码清单10-5与代码清单10-4的差别是两个method方法添加了不同的返回值，由于这两个返回值的加入，方法重载居然成功了，即这段代码可以被编译和执行^[2]了。这是对Java语言中返回值不参与重载选择的基本认知的挑战吗？

代码清单10-5中的重载当然不是根据返回值

来确定的，之所以这次能编译和执行成功，是因为两个method（）方法加入了不同的返回值后才能共存在一个Class文件之中。第6章介绍Class文件方法表（method_info）的数据结构时曾经提到过，方法重载要求方法具备不同的特征签名，返回值并不包含在方法的特征签名之中，所以返回值不参与重载选择，但是在Class文件格式之中，只要描述符不是完全一致的两个方法就可以共存。也就是说，两个方法如果有相同的名称和特征签名，但返回值不同，那它们也是可以合法地共存于一个Class文件中的。

由于Java泛型的引入，各种场景（虚拟机解析、反射等）下的方法调用都可能对原有的基础产生影响和新的需求，如在泛型类中如何获取传入的参数化类型等。因此，JCP组织对虚拟机规

范做出了相应的修改，引入了诸如Signature、LocalVariableTypeTable等新的属性用于解决伴随泛型而来的参数类型的识别问题，Signature是其中最重要的一项属性，它的作用就是存储一个方法在字节码层面的特征签名^[3]，这个属性中保存的参数类型并不是原生类型，而是包括了参数化类型的信息。修改后的虚拟机规范^[4]要求所有能识别49.0以上版本的Class文件的虚拟机都要能正确地识别Signature参数。

从上面的例子可以看到擦除法对实际编码带来的影响，由于List<String>和List<Integer>擦除后是同一个类型，我们只能添加两个并不需要实际使用到的返回值才能完成重载，这是一种毫无优雅和美感可言的解决方案，并且存在一定语意上的混乱，譬如上面脚注中提到的，必须用

Sun JDK 1.6的Javac才能编译成功，其他版本或者ECJ编译器都可能拒绝编译。

另外，从Signature属性的出现我们还可以得出结论，擦除法所谓的擦除，仅仅是对方法的Code属性中的字节码进行擦除，实际上元数据中还是保留了泛型信息，这也是我们能通过反射手段取得参数化类型的根本依据。

[1]原文地址：<http://www.anyang-window.com.cn/quotthis-is-not-a-genericquot-bruce-eckel-eyes-of-the-generic-java/>。

[2]测试的时候请使用Sun JDK 1.6的Javac编译器进行编译，其他编译器，如Eclipse JDT的ECJ编译器，仍然可能会拒绝编译这段代码，ECJ编译时会提示“Method method (List<String>) has the

same erasure method (List<E>) as another method in type GenericTypes”。

[3]在《Java虚拟机规范（第2版）》（JDK 1.5修改后的版本）的“§ 4.4.4 Signatures”章节及《Java语言规范（第3版）》的“§ 8.4.2 Method Signature”章节中分别定义了字节码层面的方法特征签名，以及Java代码层面的方法特征签名，特征签名最重要的任务就是作为方法独一无二且不可重复的ID，在Java代码中的方法特征签名只包括了方法名称、参数顺序及参数类型，而在字节码中的特征签名还包括方法返回值及受查异常表，本书中如果指的是字节码层面的方法签名，笔者会加入限定语进行说明，也请读者根据上下文语境注意区分。

[4]JDK

1.5对虚拟机规范修改：

<http://jcp.org/aboutJava/communityprocess/maintena924/index.html>。

10.3.2 自动装箱、拆箱与遍历循环

从纯技术的角度来讲，自动装箱、自动拆箱与遍历循环（Foreach循环）这些语法糖，无论是实现上还是思想上都不能和上文介绍的泛型相比，两者的难度和深度都有很大差距。专门拿出一节来讲解它们只有一个理由：毫无疑问，它们是Java语言里使用得最多的语法糖。我们通过代码清单10-6和代码清单10-7中所示的代码来看看这些语法糖在编译后会发生什么样的变化。

代码清单10-6 自动装箱、拆箱与遍历循环

```
public static void main (String[]args) {  
    List<Integer>list=Arrays.asList (1, 2, 3,  
4) ;  
    //如果在JDK 1.7中，还有另外一颗语法糖 [1]  
    //能让上面这句代码进一步简写成List<Integer>
```

```
list=[1, 2, 3, 4];
    int sum=0;
    for (int i: list) {
        sum+=i;
    }
    System.out.println (sum) ;
}
```

代码清单10-7 自动装箱、拆箱与遍历循环

编译之后

```
public static void main (String[]args) {
List list=Arrays.asList (new Integer[]{ 
    Integer.valueOf (1) ,
    Integer.valueOf (2) ,
    Integer.valueOf (3) ,
    Integer.valueOf (4) }) ;
int sum=0;
for (Iterator
localIterator=list.iterator () ;
localIterator.hasNext () ; ) {
    int i= ( (Integer)
localIterator.next () ) .intValue () ;
    sum+=i;
}
System.out.println (sum) ;
}
```

代码清单10-6中一共包含了泛型、自动装箱、自动拆箱、遍历循环与变长参数5种语法糖，代码清单10-7则展示了它们在编译后的变化。泛型就不必说了，自动装箱、拆箱在编译之后被转化成了对应的包装和还原方法，如本例中的Integer.valueOf（）与Integer.intValue（）方法，而遍历循环则把代码还原成了迭代器的实现，这也是为何遍历循环需要被遍历的类实现Iterable接口的原因。最后再看看变长参数，它在调用的时候变成了一个数组类型的参数，在变长参数出现之前，程序员就是使用数组来完成类似功能的。

这些语法糖虽然看起来很简单，但也不见得就没有任何值得我们注意的地方，代码清单10-8演示了自动装箱的一些错误用法。

代码清单10-8 自动装箱的陷阱

```
public static void main (String[]args) {  
    Integer a=1;  
    Integer b=2;  
    Integer c=3;  
    Integer d=3;  
    Integer e=321;  
    Integer f=321;  
    Long g=3L;  
    System.out.println (c==d) ;  
    System.out.println (e==f) ;  
    System.out.println (c== (a+b) ) ;  
    System.out.println (c.equals (a+b) ) ;  
    System.out.println (g== (a+b) ) ;  
    System.out.println (g.equals (a+b) ) ;  
}
```

阅读完代码清单10-8，读者不妨思考两个问题：一是这6句打印语句的输出是什么？二是这6句打印语句中，解除语法糖后参数会是什么样子？这两个问题的答案可以很容易试验出来，笔者就暂且略去答案，希望读者自己上机实践一下。无论读者的回答是否正确，鉴于包装类

的“==”运算在不遇到算术运算的情况下不会自动拆箱，以及它们equals（）方法不处理数据转型的关系，笔者建议在实际编码中尽量避免这样使用自动装箱与拆箱。

[1]在本章完稿之后，此语法糖随着Project Coin一起被划分到JDK 1.8中了，在JDK 1.7里不会包括。

10.3.3 条件编译

许多程序设计语言都提供了条件编译的途径，如C、C++中使用预处理器指示符（`#ifdef`）来完成条件编译。C、C++的预处理器最初的任务是解决编译时的代码依赖关系（如非常常用的`#include`预处理命令），而在Java语言之中并没有使用预处理器，因为Java语言天然的编译方式（编译器并非一个个地编译Java文件，而是将所有编译单元的语法树顶级节点输入到待处理列表后再进行编译，因此各个文件之间能够互相提供符号信息）无须使用预处理器。那Java语言是否有办法实现条件编译呢？

Java语言当然也可以进行条件编译，方法就

是使用条件为常量的if语句。如代码清单10-9所示，此代码中的if语句不同于其他Java代码，它在编译阶段就会被“运行”，生成的字节码之中只包括“System.out.println ("block 1") ; ”一条语句，并不会包含if语句及另外一个分子中的“System.out.println ("block 2") ; ”

代码清单10-9 Java语言的条件编译

```
public static void main (String[]args) {  
    if (true) {  
        System.out.println ("block 1") ;  
    }else{  
        System.out.println ("block 2") ;  
    }  
}
```

上述代码编译后Class文件的反编译结果：

```
public static void main (String[]args) {  
    System.out.println ("block 1") ;
```

}

只能使用条件为常量的if语句才能达到上述效果，如果使用常量与其他带有条件判断能力的语句搭配，则可能在控制流分析中提示错误，被拒绝编译，如代码清单10-10所示的代码就会被编译器拒绝编译。

代码清单10-10 不能使用其他条件语句来完成条件编译

```
public static void main (String[]args) {  
    //编译器将会提示“Unreachable code”  
    while (false) {  
        System.out.println ("");  
    }  
}
```

Java语言中条件编译的实现，也是Java语言的一颗语法糖，根据布尔常量值的真假，编译器

将会把分支中不成立的代码块消除掉，这一工作将在编译器解除语法糖阶段（`com.sun.tools.javac.comp.Lower`类中）完成。由于这种条件编译的实现方式使用了if语句，所以它必须遵循最基本的Java语法，只能写在方法体内部，因此它只能实现语句基本块（Block）级别的条件编译，而没有办法实现根据条件调整整个Java类的结构。

除了本节中介绍的泛型、自动装箱、自动拆箱、遍历循环、变长参数和条件编译之外，Java语言还有不少其他的语法糖，如内部类、枚举类、断言语句、对枚举和字符串（在JDK 1.7中支持）的switch支持、try语句中定义和关闭资源（在JDK 1.7中支持）等，读者可以通过跟踪Javac源码、反编译Class文件等方式了解它们的

本质实现，囿于篇幅，笔者就不再一一介绍了。

10.4 实战：插入式注解处理器

JDK编译优化部分在本书中并没有设置独立的实战章节，因为我们开发程序，考虑的主要是程序会如何运行，很少会有针对程序编译的需求。也因为这个原因，在JDK的编译子系统里面，提供给用户直接控制的功能相对较少，除了第11章会介绍的虚拟机JIT编译的几个相关参数以外，我们就只有使用JSR-296中定义的插入式注解处理器API来对JDK编译子系统的行为产生一些影响。

但是笔者并不认为相对于前两部分介绍的内存管理子系统和字节码执行子系统，JDK的编译子系统就不那么重要。一套编程语言中编译子系

统的优劣，很大程度上决定了程序运行性能的好坏和编码效率的高低，尤其在Java语言中，运行期即时编译与虚拟机执行子系统非常紧密地互相依赖、配合运作（第11章将主要讲解这方面的内容）。了解JDK如何编译和优化代码，有助于我们写出适合JDK自优化的程序。下面我们回到本章的实战中，看看插入式注解处理器API能实现什么功能。

10.4.1 实战目标

通过阅读Javac编译器的源码，我们知道编译器在把Java程序源码编译为字节码的时候，会对Java程序源码做各方面的检查校验。这些校验主要以程序“写得对不对”为出发点，虽然也有各种

WARNING的信息，但总体来讲还是较少去校验程序“写得好不好”。有鉴于此，业界出现了许多针对程序“写得好不好”的辅助校验工具，如CheckStyle、FindBug、Klocwork等。这些代码校验工具有一些是基于Java的源码进行校验，还有一些是通过扫描字节码来完成，在本节的实战中，我们将会使用注解处理器API来编写一款拥有自己编码风格的校验工具：

NameCheckProcessor。

当然，由于我们的实战都是为了学习和演示技术原理，而不是为了做出一款能媲美CheckStyle等工具的产品来，所以NameCheckProcessor的目标也仅定为对Java程序命名进行检查，根据《Java语言规范（第3版）》中第6.8节的要求，Java程序命名应当符合下列格

式的书写规范。

类（或接口）：符合驼式命名法，首字母大写。

方法：符合驼式命名法，首字母小写。

字段：

●类或实例变量：符合驼式命名法，首字母小写。

●常量：要求全部由大写字母或下划线构成，并且第一个字符不能是下划线。

上文提到的驼式命名法（Camel Case Name），正如它的名称所表示的那样，是指混合使用大小写字母来分割构成变量或函数的名字，

犹如驼峰一般，这是当前Java语言中主流的命名规范，我们的实战目标就是为Javac编译器添加一个额外的功能，在编译程序时检查程序名是否符合上述对类（或接口）、方法、字段的命名要求^[1]。

[1]在JDK的sample/javac/processing目录中有这次实战的源码（稍微复杂一些，但总体上差距不大），读者可以阅读参考。

10.4.2 代码实现

要通过注解处理器API实现一个编译器插件，首先需要了解这组API的一些基本知识。我们实现注解处理器的代码需要继承抽象类 javax.annotation.processing.AbstractProcessor，这个抽象类中只有一个必须覆盖的abstract方法：“process（）”，它是Javac编译器在执行注解处理器代码时要调用的过程，我们可以从这个方法的第一个参数“annotations”中获取到此注解处理器所要处理的注解集合，从第二个参数“roundEnv”中访问到当前这个Round中的语法树节点，每个语法树节点在这里表示为一个Element。在JDK 1.6新增的javax.lang.model包中定

义了16类Element，包括了Java代码中最常用的元素，如：“包（PACKAGE）、枚举（ENUM）、类（CLASS）、注解（ANNOTATION_TYPE）、接口（INTERFACE）、枚举值（ENUM_CONSTANT）、字段（FIELD）、参数（PARAMETER）、本地变量（LOCAL_VARIABLE）、异常（EXCEPTION_PARAMETER）、方法（METHOD）、构造函数（CONSTRUCTOR）、静态语句块（STATIC_INIT，即static{}块）、实例语句块（INSTANCE_INIT，即{}块）、参数化类型（TYPE_PARAMETER，既泛型尖括号内的类型）和未定义的其他语法树节点（OTHER）”。除了process（）方法的传入参数之外，还有一个很常用的实例变

量“processingEnv”，它是AbstractProcessor中的一个protected变量，在注解处理器初始化的时候（init（）方法执行的时候）创建，继承了AbstractProcessor的注解处理器代码可以直接访问到它。它代表了注解处理器框架提供的一个上下文环境，要创建新的代码、向编译器输出信息、获取其他工具类等都需要用到这个实例变量。

注解处理器除了process（）方法及其参数之外，还有两个可以配合使用的Annotations：

@SupportedAnnotationTypes和

@SupportedSourceVersion，前者代表了这个注解处理器对哪些注解感兴趣，可以使用星号“*”作为通配符代表对所有的注解都感兴趣，后者指出这个注解处理器可以处理哪些版本的Java代码。

每一个注解处理器在运行的时候都是单例的，如果不需要改变或生成语法树的内容，process（）方法就可以返回一个值为false的布尔值，通知编译器这个Round中的代码未发生变化，无须构造新的JavaCompiler实例，在这次实战的注解处理器中只对程序命名进行检查，不需要改变语法树的内容，因此process（）方法的返回值都是false。关于注解处理器的API，笔者就简单介绍这些，对这个领域有兴趣的读者可以阅读相关的帮助文档。下面来看看注解处理器NameCheckProcessor的具体代码，如代码清单10-11所示。

代码清单10-11 注解处理器

NameCheckProcessor

```
//可以用"*"表示支持所有Annotations
@SupportedAnnotationTypes ("*")
//只支持JDK 1.6的Java代码
@SupportedSourceVersion (SourceVersion.RELEASE_6)
public class NameCheckProcessor extends
AbstractProcessor{
    private NameChecker nameChecker;
    /**
     *初始化名称检查插件
     */
    @Override
    public void init (ProcessingEnvironment
processingEnv) {
        super.init (processingEnv) ;
        nameChecker=new
NameChecker (processingEnv) ;
    }
    /**
     *对输入的语法树的各个节点进行名称检查
     */
    @Override
    public boolean process (Set<?extends
TypeElement>annotations,RoundEnvironment
roundEnv) {
        if (! roundEnv.processingOver () ) {
            for (Element element:
roundEnv.getRootElements () )
                nameChecker.checkNames (element) ;
        }
        return false;
    }
}
```

从上面代码可以看出，NameCheckProcessor能处理基于JDK 1.6的源码，它不限于特定的注解，对任何代码都“感兴趣”，而在process（）方法中是把当前Round中的每一个RootElement传递到一个名为NameChecker的检查器中执行名称检查逻辑，NameChecker的代码如代码清单10-12所示。

代码清单10-12 命名检查器NameChecker

```
 /**
 * 程序名称规范的编译器插件: <br>
 * 如果程序命名不合规范, 将会输出一个编译器的WARNING
信息
 */
public class NameChecker{
    private final Messager messager;
    NameCheckScanner nameCheckScanner=new
NameCheckScanner () ;
    NameChecker (ProcessingEnvironment
processsingEnv) {
        this.messager=processsingEnv.getMessager () ;
    }
}
```

```
/**
```

*对Java程序命名进行检查，根据《Java语言规范（第3版）》第6.8节的要求，Java程序命名应当符合下列格式：

```
*
```

```
*<ul>
```

```
*<li>类或接口：符合驼式命名法，首字母大写。
```

```
*<li>方法：符合驼式命名法，首字母小写。
```

```
*<li>字段：
```

```
*<ul>
```

```
*<li>类、实例变量：符合驼式命名法，首字母小写。
```

```
*<li>常量：要求全部大写。
```

```
*</ul>
```

```
*</ul>
```

```
*/
```

```
public void checkNames (Element element) {
```

```
    nameCheckScanner.scan (element) ;
```

```
}
```

```
/**
```

*名称检查器实现类，继承了JDK 1.6中新提供的
ElementScanner6


```
*将会以Visitor模式访问抽象语法树中的元素
```

```
*/
```

```
private class NameCheckScanner extends
```

```
ElementScanner6<Void,Void>{
```

```
/**
```

*此方法用于检查Java类

```
*/
```

```
@Override
```

```
public Void visitType (TypeElement e,Void
```

p) {

```
    scan (e.getTypeParameters () , p) ;
```

```
    checkCamelCase (e,true) ;
```

```
    super.visitType (e,p) ;
```

```
    return null;
```

```
}

/**
 * 检查方法命名是否合法
 */
@Override
public Void
visitExecutable (ExecutableElement e,Void p) {
    if (e.getKind () ==METHOD) {
        Name name=e.getSimpleName () ;
        if
            (name.contentEquals (e.getEnclosingElement (
                messenger.printMessage (WARNING, "一个普通方
法"""+name+"""不应当与类名重复，避免与构造函数产生混
淆", e) ;
        checkCamelCase (e, false) ;
    }
    super.visitExecutable (e,p) ;
    return null;
}
/**
 * 检查变量命名是否合法
 */
@Override
public Void visitVariable (VariableElement
e,Void p) {
    //如果这个Variable是枚举或常量，则按大写命名检查,
    //否则按照驼式命名法规则检查
    if (e.getKind ()
==ENUM_CONSTANT||e.getConstantValue () !
=null||heuristicallyConstant (e) )
        checkAllCaps (e) ;
    else
        checkCamelCase (e, false) ;
    return null;
```

```
}

/**
 *判断一个变量是否是常量
 */
private boolean
heuristicallyConstant (VariableElement e) {
    if (e.getEnclosingElement () .getKind () ==INTERFACE)
        return true;
    else if (e.getKind () ==FIELD&& e.getModifiers () .containsAll (EnumSet.of (PUBLI
        return true;
    else{
        return false;
    }
}
/**
```

*检查传入的Element是否符合驼式命名法，如果不符合，则输出警告信息

```
*/
private void checkCamelCase (Element e,boolean initialCaps) {
    String
name=e.getSimpleName () .toString () ;
    boolean previousUpper=false;
    boolean conventional=true;
    int firstCodePoint=name.codePointAt (0) ;
    if (Character.isUpperCase (firstCodePoint) )
{
    previousUpper=true;
    if (! initialCaps) {
        messager.printMessage (WARNING, "名
称""+name+""应当以小写字母开头", e) ;
        return;
```

```
    }
} else
if (Character.isLowerCase (firstCodePoint) ) {
    if (initialCaps) {
        messager.printMessage (WARNING, "名
称""+name+"应当以大写字母开头", e);
        return;
    }
} else
conventional=false;
if (conventional) {
int cp=firstCodePoint;
for (int i=Character.charCount (cp) ; i<
name.length () ; i+=Character.charCount (cp) ) {
    cp=name.codePointAt (i);
    if (Character.isUpperCase (cp) ) {
        if (previousUpper) {
            conventional=false;
            break;
        }
        previousUpper=true;
    } else
        previousUpper=false;
    }
}
if (! conventional)
messager.printMessage (WARNING, "名
称""+name+"应当符合驼式命名法 (Camel Case
Names) ", e);
}
/***
 * 大写命名检查，要求第一个字母必须是大写的英文字母，
其余部分可以是下划线或大写字母
 */
```

```
private void checkAllCaps (Element e) {  
    String  
    name=e.getSimpleName () .toString () ;  
    boolean conventional=true;  
    int firstCodePoint=name.codePointAt (0) ;  
    if (!  
        Character.isUpperCase (firstCodePoint) )  
        conventional=false;  
    else{  
        boolean previousUnderscore=false;  
        int cp=firstCodePoint;  
        for (int i=Character.charCount (cp) ; i<  
name.length () ; i+=Character.charCount (cp) ) {  
            cp=name.codePointAt (i) ;  
            if (cp== (int) '_') {  
                if (previousUnderscore) {  
                    conventional=false;  
                    break;  
                }  
                previousUnderscore=true;  
            }else{  
                previousUnderscore=false;  
                if (! Character.isUpperCase (cp) && !  
Character.isDigit (cp) )  
                {  
                    conventional=false;  
                    break;  
                }  
            }  
        }  
        if (! conventional)  
            messenger.printMessage (WARNING, "常  
量"""+name+"""应当全部以大写字母或下划线命名， 并且以字母
```

```
开头", e);  
}  
}  
}
```

NameChecker的代码看起来有点长，但实际上注释占了很大一部分，其实即使算上注释也不到190行。它通过一个继承于 javax.lang.model.util.ElementScanner6 的 NameCheckScanner 类，以 Visitor 模式来完成对语法树的遍历，分别执行 visitType() 、 visitVariable() 和 visitExecutable() 方法来访问类、字段和方法，这3个 visit 方法对各自的命名规则做相应的检查， checkCamelCase() 与 checkAllCaps() 方法则用于实现驼式命名法和全大写命名规则的检查。

整个注解处理器只需 NameCheckProcessor 和

NameChecker两个类就可以全部完成，为了验证我们的实战成果，代码清单10-13中提供了一段命名规范的“反面教材”代码，其中的每一个类、方法及字段的命名都存在问题，但是使用普通的Javac编译这段代码时不会提示任何一个Warning信息。

代码清单10-13 包含了多处不规范命名的代码样例

```
public class BADLY_NAMED_CODE{
    enum colors{
        red,blue,green;
    }
    static final int_FORTY_TWO=42;
    public static int
NOT_A_CONSTANT=_FORTY_TWO;
    protected void BADLY_NAMED_CODE () {
        return;
    }
    public void NOTcamelCASEmethodName () {
        return;
    }
}
```

}

10.4.3 运行与测试

我们可以通过Javac命令的“-processor”参数来执行编译时需要附带的注解处理器，如果有多个注解处理器的话，用逗号分隔。还可以使用-XprintRounds和-XprintProcessorInfo参数来查看注解处理器运作的详细信息，本次实战中的NameCheckProcessor的编译及执行过程如代码清单10-14所示。

代码清单10-14 注解处理器的运行过程

```
D: \src>javac
org/fenixsoft/compile/NameChecker.java
D: \src>javac
org/fenixsoft/compile/NameCheckProcessor.java
D: \src>javac-processor
org.fenixsoft.compile.NameCheckProcessor
org/fenixsoft/compile/BADLY_NAMED_CODE.java
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

3: 警告：名称"BADLY_NAMED_CODE"应当符合驼式命名法
(Camel Case Names)

```
public class BADLY_NAMED_CODE{  
    ^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

5: 警告：名称"colors"应当以大写字母开头

```
enum colors{  
    ^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

6: 警告：常量"red"应当全部以大写字母或下划线命名，并且以字母开头

```
red,blue,green;  
^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

6: 警告：常量"blue"应当全部以大写字母或下划线命名，并且以字母开头

```
red,blue,green;  
^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

6: 警告：常量"green"应当全部以大写字母或下划线命名，并且以字母开头

```
red,blue,green;  
^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

9: 警告：常量"_FORTY_TWO"应当全部以大写字母或下划线命名，并且以字母开头

```
static final int _FORTY_TWO=42;  
^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

11: 警告：名称"NOT_A_CONSTANT"应当以小写字母开头

```
public static int
```

NOT_A_CONSTANT=_FORTY_TWO;
^

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

13: 警告：名称"Test"应当以小写字母开头

```
protected void Test () {  
    ^
```

org\fenixsoft\compile\BADLY_NAMED_CODE.java:

17: 警告：名称"NOTcamelCASEmethodNAME"应当以小写字母开头

```
public void NOTcamelCASEmethodNAME () {  
    ^
```

10.4.4 其他应用案例

NameCheckProcessor的实战例子只演示了JSR-269嵌入式注解处理器API中的一部分功能，基于这组API支持的项目还有用于校验Hibernate标签使用正确性的Hibernate Validator Annotation Processor^[1]（本质上与NameCheckProcessor所做的事情差不多）、自动为字段生成getter和setter方法的Project Lombok^[2]（根据已有元素生成新的语法树元素）等，读者有兴趣的话可以参考它们官方站点的相关内容。

[1] 官方站点：

<http://www.hibernate.org/subprojects/validator.html>。

[2] 官方站点：<http://projectlombok.org/>。

10.5 本章小结

在本章中，我们从编译器源码实现的层次上了解了Java源代码编译为字节码的过程，分析了Java语言中泛型、主动装箱/拆箱、条件编译等多种语法糖的前因后果，并实战练习了如何使用插入式注解处理器来完成一个检查程序命名规范的编译器插件。如本章概述中所说的那样，在前端编译器中，“优化”手段主要用于提升程序的编码效率，之所以把Javac这类将Java代码转变为字节码的编译器称做“前端编译器”，是因为它只完成了从程序到抽象语法树或中间字节码的生成，而在此之后，还有一组内置于虚拟机内部的“后端编译器”完成了从字节码生成本地机器码的过程，即前面多次提到的即时编译器或JIT编译器，

这个编译器的编译速度及编译结果的优劣，是衡量虚拟机性能一个很重要的指标。在第11章中，我们将会介绍即时编译器的运作和优化过程。

第11章 晚期（运行期）优化

从计算机程序出现的第一天起，对效率的追求就是程序天生的坚定信仰，这个过程犹如一场没有终点、永不停歇的F1方程式竞赛，程序员是车手，技术平台则是在赛道上飞驰的赛车。

11.1 概述

在部分的商用虚拟机（Sun HotSpot、IBM J9）中，Java程序最初是通过解释器（Interpreter）进行解释执行的，当虚拟机发现某个方法或代码块的运行特别频繁时，就会把这些代码认定为“热点代码”（Hot Spot Code）。为了提高热点代码的执行效率，在运行时，虚拟机将

会把这些代码编译成与本地平台相关的机器码，并进行各种层次的优化，完成这个任务的编译器称为即时编译器（Just In Time Compiler，下文中简称JIT编译器）。

即时编译器并不是虚拟机必需的部分，Java虚拟机规范并没有规定Java虚拟机内必须要有即时编译器存在，更没有限定或指导即时编译器应该如何去实现。但是，即时编译器编译性能的好坏、代码优化程度的高低却是衡量一款商用虚拟机优秀与否的最关键的指标之一，它也是虚拟机中最核心且最能体现虚拟机技术水平的部分。在本章中，我们将走进虚拟机的内部，探索即时编译器的运作过程。

由于Java虚拟机规范没有具体的约束规则去

限制即时编译器应该如何实现，所以这部分功能完全是与虚拟机具体实现（Implementation Specific）相关的内容，如无特殊说明，本章提及的编译器、即时编译器都是指HotSpot虚拟机内的即时编译器，虚拟机也是特指HotSpot虚拟机。不过，本章的大部分内容是描述即时编译器的行为，涉及编译器实现层面的内容较少，而主流虚拟机中即时编译器的行为又有很多相似和相通之处，因此，对其他虚拟机来说也具有较高的参考意义。

11.2 HotSpot虚拟机内的即时编译器

在本节中，我们将要了解HotSpot虚拟机内的即时编译器的运作过程，同时，还要解决以下几个问题：

为何HotSpot虚拟机要使用解释器与编译器并存的架构？

为何HotSpot虚拟机要实现两个不同的即时编译器？

程序何时使用解释器执行？何时使用编译器执行？

哪些程序代码会被编译为本地代码？如何编译为本地代码？

如何从外部观察即时编译器的编译过程和编译结果？

11.2.1 解释器与编译器

尽管并不是所有的Java虚拟机都采用解释器与编译器并存的架构，但许多主流的商用虚拟机，如HotSpot、J9等，都同时包含解释器与编译器^[1]。解释器与编译器两者各有优势：当程序需要迅速启动和执行的时候，解释器可以首先发挥作用，省去编译的时间，立即执行。在程序运行后，随着时间的推移，编译器逐渐发挥作用，把越来越多的代码编译成本地代码之后，可以获取更高的执行效率。当程序运行环境中内存资源限制较大（如部分嵌入式系统中），可以使用解释

执行节约内存，反之可以使用编译执行来提升效率。同时，解释器还可以作为编译器激进优化时的一个“逃生门”，让编译器根据概率选择一些大多数时候都能提升运行速度的优化手段，当激进优化的假设不成立，如加载了新类后类型继承结构出现变化、出现“罕见陷阱”（Uncommon Trap）时可以通过逆优化（Deoptimization）退回到解释状态继续执行（部分没有解释器的虚拟机中也会采用不进行激进优化的C1编译器^[2]担任“逃生门”的角色），因此，在整个虚拟机执行架构中，解释器与编译器经常配合工作，如图11-1所示。




图 11-1 解释器与编译器的交互

HotSpot虚拟机中内置了两个即时编译器，分别称为Client Compiler和Server Compiler，或者简称为C1编译器和C2编译器（也叫Opto编译器）。目前主流的HotSpot虚拟机（Sun系列JDK 1.7及之前版本的虚拟机）中，默认采用解释器与其中一个编译器直接配合的方式工作，程序使用哪个编译器，取决于虚拟机运行的模式，HotSpot虚拟机会根据自身版本与宿主机器的硬件性能自动选择运行模式，用户也可以使用“-client”或“-server”参

数去强制指定虚拟机运行在Client模式或Server模式。

无论采用的编译器是Client Compiler还是 Server Compiler，解释器与编译器搭配使用的方式在虚拟机中称为“混合模式”（Mixed Mode），用户可以使用参数“-Xint”强制虚拟机运行于“解释模式”（Interpreted Mode），这时编译器完全不介入工作，全部代码都使用解释方式执行。另外，也可以使用参数“-Xcomp”强制虚拟机运行于“编译模式”（Compiled Mode）^[3]，这时将优先采用编译方式执行程序，但是解释器仍然要在编译无法进行的情况下介入执行过程，可以通过虚拟机的“-version”命令的输出结果显示这3种模式，如代码清单11-1所示，请注意黑体字部分。

代码清单11-1 虚拟机执行模式

```
C: \>java-version
java version"1.6.0_22"
Java (TM) SE Runtime Environment (build
1.6.0_22-b04)
    Dynamic Code Evolution 64-Bit Server
VM (build 0.2-b02-internal, 19.0-b04-
internal,mixed mode)

C: \>java-Xint-version
java version"1.6.0_22"
Java (TM) SE Runtime Environment (build
1.6.0_22-b04)
    Dynamic Code Evolution 64-Bit Server
VM (build 0.2-b02-internal, 19.0-b04-
internal,interpreted mode)

C: \>java-Xcomp-version
java version"1.6.0_22"
Java (TM) SE Runtime Environment (build
1.6.0_22-b04)
    Dynamic Code Evolution 64-Bit Server
VM (build 0.2-b02-internal, 19.0-b04-
internal,compiled mode)
```

由于即时编译器编译本地代码需要占用程序运行时间，要编译出优化程度更高的代码，所花费的时间可能更长；而且想要编译出优化程度更

高的代码，解释器可能还要替编译器收集性能监控信息，这对解释执行的速度也有影响。为了在程序启动响应速度与运行效率之间达到最佳平衡，HotSpot虚拟机还会逐渐启用分层编译（Tiered Compilation）^[4]的策略，分层编译的概念在JDK 1.6时期出现，后来一直处于改进阶段，最终在JDK 1.7的Server模式虚拟机中作为默认编译策略被开启。分层编译根据编译器编译、优化的规模与耗时，划分出不同的编译层次，其中包括：

第0层，程序解释执行，解释器不开启性能监控功能（Profiling），可触发第1层编译。

第1层，也称为C1编译，将字节码编译为本地代码，进行简单、可靠的优化，如有必要将加

入性能监控的逻辑。

第2层（或2层以上），也称为C2编译，也是将字节码编译为本地代码，但是会启用一些编译耗时较长的优化，甚至会根据性能监控信息进行一些不可靠的激进优化。

实施分层编译后，Client Compiler和Server Compiler将会同时工作，许多代码都可能会被多次编译，用Client Compiler获取更高的编译速度，用Server Compiler来获取更好的编译质量，在解释执行的时候也无须再承担收集性能监控信息的任务。

[1]作为三大商用虚拟机之一的JRockit是个例外，它内部没有解释器，因此会存在本书中所说的“启动响应时间长”之类的缺点，但它主要是

面向服务端的应用，这类应用一般不会重点关注启动时间。

[2]在虚拟机中习惯将Client Compiler称为C1，将Server Compiler称为C2。

[3]在最新的Sun HotSpot中，已经去掉了-Xcomp参数。

[4]Tiered Compilation的概念在JDK 1.6时期出现，但JDK 1.7之前需要使用-XX: +TieredCompilation参数来手动开启，如果不开启分层编译策略，而虚拟机又运行在Server模式，Server Compiler需要性能监控信息提供编译依据，则可以由解释器收集性能监控信息供Server Compiler使用。分层编译的相关资料可参见：

<http://weblogs.java.net/blog/forax/archive/2010/09/compilation>。

11.2.2 编译对象与触发条件

上文中提到过，在运行过程中会被即时编译器编译的“热点代码”有两类，即：

被多次调用的方法。

被多次执行的循环体。

前者很好理解，一个方法被调用得多了，方法体内代码执行的次数自然就多，它成为“热点代码”是理所当然的。而后者则是为了解决一个方法只被调用过一次或少量的几次，但是方法体内部存在循环次数较多的循环体的问题，这样循环体的代码也被重复执行多次，因此这些代码也应该认为是“热点代码”。

对于第一种情况，由于是由方法调用触发的编译，因此编译器理所当然地会以整个方法作为编译对象，这种编译也是虚拟机中标准的JIT编译方式。而对于后一种情况，尽管编译动作是由循环体所触发的，但编译器依然会以整个方法（而不是单独的循环体）作为编译对象。这种编译方式因为编译发生在方法执行过程之中，因此形象地称之为栈上替换（On Stack Replacement，简称为OSR编译，即方法栈帧还在栈上，方法就被替换了）。

读者可能还会有疑问，在上面的文字描述中，无论是“多次执行的方法”，还是“多次执行的代码块”，所谓“多次”都不是一个具体、严谨的用语，那到底多少次才算“多次”呢？还有一个问题，就是虚拟机如何统计一个方法或一段代码被

执行过多少次呢？解决了这两个问题，也就回答了即时编译被触发的条件。

判断一段代码是不是热点代码，是不是需要触发即时编译，这样的行为称为热点探测（Hot Spot Detection），其实进行热点探测并不一定要知道方法具体被调用了多少次，目前主要的热点探测判定方式有两种^[1]，分别如下。

基于采样的热点探测（Sample Based Hot Spot Detection）：采用这种方法的虚拟机会周期性地检查各个线程的栈顶，如果发现某个（或某些）方法经常出现在栈顶，那这个方法就是“热点方法”。基于采样的热点探测的好处是实现简单、高效，还可以很容易地获取方法调用关系（将调用堆栈展开即可），缺点是很难精确地确

认一个方法的热度，容易因为受到线程阻塞或别的外界因素的影响而扰乱热点探测。

基于计数器的热点探测（Counter Based Hot Spot Detection）：采用这种方法的虚拟机会为每个方法（甚至是代码块）建立计数器，统计方法的执行次数，如果执行次数超过一定的阈值就认为它是“热点方法”。这种统计方法实现起来麻烦一些，需要为每个方法建立并维护计数器，而且不能直接获取到方法的调用关系，但是它的统计结果相对来说更加精确和严谨。

在HotSpot虚拟机中使用的是第二种——基于计数器的热点探测方法，因此它为每个方法准备了两类计数器：方法调用计数器（Invocation Counter）和回边计数器（Back Edge Counter）。

在确定虚拟机运行参数的前提下，这两个计数器都有一个确定的阈值，当计数器超过阈值溢出了，就会触发JIT编译。

我们首先来看看方法调用计数器。顾名思义，这个计数器就用于统计方法被调用的次数，它的默认阈值在Client模式下是1500次，在Server模式下是10 000次，这个阈值可以通过虚拟机参数-XX: CompileThreshold来人为设定。当一个方法被调用时，会先检查该方法是否存在被JIT编译过的版本，如果存在，则优先使用编译后的本地代码来执行。如果不存在已被编译过的版本，则将此方法的调用计数器值加1，然后判断方法调用计数器与回边计数器值之和是否超过方法调用计数器的阈值。如果已超过阈值，那么将会向即时编译器提交一个该方法的代码编译请求。

如果不做任何设置，执行引擎并不会同步等待编译请求完成，而是继续进入解释器按照解释方式执行字节码，直到提交的请求被编译器编译完成。当编译工作完成之后，这个方法的调用入口地址就会被系统自动改写成新的，下一次调用该方法时就会使用已编译的版本。整个JIT编译的交互过程如图11-2所示。




图 11-2 方法调用计数器触发即时编译

如果不做任何设置，方法调用计数器统计的

并不是方法被调用的绝对次数，而是一个相对的执行频率，即一段时间之内方法被调用的次数。当超过一定的时间限度，如果方法的调用次数仍然不足以让它提交给即时编译器编译，那这个方法的调用计数器就会被减少一半，这个过程称为方法调用计数器热度的衰减（Counter Decay），而这段时间就称为此方法统计的半衰周期（Counter Half Life Time）。进行热度衰减的动作是在虚拟机进行垃圾收集时顺便进行的，可以使用虚拟机参数-XX: -UseCounterDecay来关闭热度衰减，让方法计数器统计方法调用的绝对次数，这样，只要系统运行时间足够长，绝大部分方法都会被编译成本地代码。另外，可以使用-XX: CounterHalfLifeTime参数设置半衰周期的时间，单位是秒。

现在我们再来看看另外一个计数器——回边计数器，它的作用是统计一个方法中循环体代码执行的次数^[2]，在字节码中遇到控制流向后跳转的指令称为“回边”（Back Edge）。显然，建立回边计数器统计的目的就是为了触发OSR编译。

关于回边计数器的阈值，虽然HotSpot虚拟机也提供了一个类似于方法调用计数器阈值-XX:CompileThreshold的参数-XX: BackEdgeThreshold供用户设置，但是当前的虚拟机实际上并未使用此参数，因此我们需要设置另外一个参数-XX:OnStackReplacePercentage来间接调整回边计数器的阈值，其计算公式如下。

虚拟机运行在Client模式下，回边计数器阈值计算公式为：

方法调用计数器阈值（CompileThreshold）

×OSR比率（OnStackReplacePercentage）/100

其中OnStackReplacePercentage默认值为933，

如果都取默认值，那Client模式虚拟机的回边计数器的阈值为13995。

虚拟机运行在Server模式下，回边计数器阈值的计算公式为：

方法调用计数器阈值（CompileThreshold）

×（OSR比率（OnStackReplacePercentage） - 解释器监控比率（InterpreterProfilePercentage） / 100

其中OnStackReplacePercentage默认值为140，

InterpreterProfilePercentage默认值为33，如果都取默认值，那Server模式虚拟机回边计数器的阈值

为10700。

当解释器遇到一条回边指令时，会先查找将要执行的代码片段是否有已经编译好的版本，如果有，它将会优先执行已编译的代码，否则就把回边计数器的值加1，然后判断方法调用计数器与回边计数器值之和是否超过回边计数器的阈值。当超过阈值的时候，将会提交一个OSR编译请求，并且把回边计数器的值降低一些，以便继续在解释器中执行循环，等待编译器输出编译结果，整个执行过程如图11-3所示。




图 11-3 回边计数器触发即时编译

与方法计数器不同，回边计数器没有计数热度衰减的过程，因此这个计数器统计的就是该方法循环执行的绝对次数。当计数器溢出的时候，它还会把方法计数器的值也调整到溢出状态，这样下次再进入该方法的时候就会执行标准编译过程。

最后需要提醒一点，图11-2和图11-3都仅仅描述了Client VM的即时编译方式，对于Server VM来说，执行情况会比上面的描述更复杂一些。从理论上了解过编译对象和编译触发条件后，我们再从HotSpot虚拟机的源码中观察一下，在MethodOop.hpp（一个methodOop对象代表了一个Java方法）中，定义了Java方法在虚拟机中的内存布局，如下所示：

```
// |-----  
// | header  
// | klass  
// |-----  
// | constMethodOop          (oop)  
// | constants                (oop)  
// |-----  
// | methodData               (oop)  
// | interp_invocation_count  
// |-----  
// | access_flags  
// | vtable_index  
// |-----  
// | result_index (C++ interpreter only)  
// |-----  
// | method_size           | max_stack  
// | max_locals            | size_of_parameters  
// |-----  
// |intrinsic_id| flags    | throwout_count  
// |-----  
// | num_breakpoints       | (unused)  
// |-----  
// | invocation_counter  
// | backedge_counter  
// |-----  
// |           prev_time (tiered only, 64 bit wide)  
// |  
// |-----  
// |           rate (tiered)  
// |-----  
// | code                  (pointer)  
// | i2i                   (pointer)  
// | adapter                (pointer)  
// | from_compiled_entry   (pointer)  
// | from_interpreted_entry (pointer)  
// |-----  
// | native_function        (present only if native)  
// | signature_handler      (present only if native)  
// |-----
```

在这个内存布局中，一行长度为32 bit，从中可以清楚地看到方法调用计数器和回边计数器所在的位置和长度。还有from_compiled_entry和from_interpreted_entry这两个方法的入口。

[1]除这两种方式外，还有其他热点代码的探测方式，如基于“踪迹”（Trace）的热点探测在最近相当流行，像FireFox中的TraceMonkey和Dalvik中新的JIT编译器都用了这种热点探测方式。

[2]准确地说，应当是回边的次数而不是循环次数，因为并非所有的循环都是回边，如空循环实际上就可以视为自己跳转到自己的过程，因此并不算作控制流向后跳转，也不会被回边计数器统计。

11.2.3 编译过程

在默认设置下，无论是方法调用产生的即时编译请求，还是OSR编译请求，虚拟机在代码编译器还未完成之前，都仍然将按照解释方式继续执行，而编译动作则在后台的编译线程中进行。用户可以通过参数-XX: -BackgroundCompilation 来禁止后台编译，在禁止后台编译后，一旦达到JIT的编译条件，执行线程向虚拟机提交编译请求后将会一直等待，直到编译过程完成后再开始执行编译器输出的本地代码。

那么在后台执行编译的过程中，编译器做了什么事情呢？Server Compiler和Client Compiler两个编译器的编译过程是不一样的。对于Client

Compiler来说，它是一个简单快速的三段式编译器，主要的关注点在于局部性的优化，而放弃了许多耗时较长的全局优化手段。

在第一个阶段，一个平台独立的前端将字节码构造成一种高级中间代码表示（High-Level Intermediate Representaion, HIR）。HIR使用静态单分配（Static Single Assignment, SSA）的形式来代表代码值，这可以使得一些在HIR的构造过程之中和之后进行的优化动作更容易实现。在此之前编译器会在字节码上完成一部分基础优化，如方法内联、常量传播等优化将会在字节码被构造成 HIR之前完成。

在第二个阶段，一个平台相关的后端从HIR中产生低级中间代码表示（Low-Level

Intermediate Representation,LIR），而在此之前会在HIR上完成另外一些优化，如空值检查消除、范围检查消除等，以便让HIR达到更高效的代码表示形式。

最后阶段是在平台相关的后端使用线性扫描算法（Linear Scan Register Allocation）在LIR上分配寄存器，并在LIR上做窥孔（Peephole）优化，然后产生机器代码。Client Compiler的大致执行过程如图11-4所示。




图 11-4 Client Compiler 架构

而 Server Compiler 则是专门面向服务端的典型应用并为服务端的性能配置特别调整过的编译器，也是一个充分优化过的高级编译器，几乎能达到 GNU C++ 编译器使用 -O2 参数时的优化强度，它会执行所有经典的优化动作，如无用代码消除（Dead Code Elimination）、循环展开（Loop Unrolling）、循环表达式外提（Loop Expression

Hoisting)、消除公共子表达式 (Common Subexpression Elimination)、常量传播 (Constant Propagation)、基本块重排序 (Basic Block Reordering) 等，还会实施一些与 Java 语言特性密切相关的优化技术，如范围检查消除 (Range Check Elimination)、空值检查消除 (Null Check Elimination)，不过并非所有的空值检查消除都是依赖编译器优化的，有一些是在代码运行过程中自动优化了) 等。另外，还可能根据解释器或 Client Compiler 提供的性能监控信息，进行一些不稳定的激进优化，如守护内联 (Guarded Inlining)、分支频率预测 (Branch Frequency Prediction) 等。本章的下半部分将会挑选上述的一部分优化手段进行分析和讲解。

Server Compiler 的寄存器分配器是一个全局

图着色分配器，它可以充分利用某些处理器架构（如RISC）上的大寄存器集合。以即时编译的标准来看，Server Compiler无疑是比较缓慢的，但它的编译速度依然远远超过传统的静态优化编译器，而且它相对于Client Compiler编译输出的代码质量有所提高，可以减少本地代码的执行时间，从而抵消了额外的编译时间开销，所以也有很多非服务端的应用选择使用Server模式的虚拟机运行。

在本节中，涉及了许多编译原理和代码优化中的概念名词，没有这方面基础的读者，阅读起来会感觉到抽象和理论化。有这种感觉并不奇怪，JIT编译过程本来就是一个虚拟机中最体现技术水平也是最复杂的部分，不可能以较短的篇幅就介绍得很详细，另外，这个过程对Java开发来

说是透明的，程序员平时无法感知它的存在，还好HotSpot虚拟机提供了两个可视化的工具，让我们可以“看见”JIT编译器的优化过程，在稍后笔者将演示这个过程。

11.2.4 查看及分析即时编译结果

一般来说，虚拟机的即时编译过程对用户程序是完全透明的，虚拟机通过解释执行代码还是编译执行代码，对于用户来说并没有什么影响（执行结果没有影响，速度上会有很大差别），在大多数情况下用户也没有必要知道。但是虚拟机也提供了一些参数用来输出即时编译和某些优化手段（如方法内联）的执行状况，本节将介绍如何从外部观察虚拟机的即时编译行为。

本节中提到的运行参数有一部分需要Debug或FastDebug版虚拟机的支持，Product版的虚拟机无法使用这部分参数。如果读者使用的是根据本书第1章的内容自己编译的JDK，注意将

SKIP_DEBUG_BUILD或SKIP_FASTDEBUG_BUILD参数设置为false，也可以在OpenJDK网站上直接下载FastDebug版的JDK（从JDK 6u25之后Oracle官网就不再提供FastDebug的JDK下载了）。注意，本节中所有的测试都基于代码清单11-2所示的Java代码。

代码清单11-2 测试代码

```
public static final int NUM=15000;
public static int doubleValue (int i) {
    //这个空循环用于后面演示JIT代码优化过程
    for (int j=0; j<100000; j++) ;
    return i*2;
}
public static long calcSum () {
    long sum=0;
    for (int i=1; i<=100; i++) {
        sum+=doubleValue (i) ;
    }
    return sum;
}
public static void main (String[]args) {
    for (int i=0; i<NUM; i++) {
```

```
    calcSum();  
}  
}
```

首先运行这段代码，并且确认这段代码是否触发了即时编译，要知道某个方法是否被编译过，可以使用参数-XX: +PrintCompilation要求虚拟机在即时编译时将被编译成本地代码的方法名称打印出来，如代码清单11-3所示（其中带有“%”的输出说明是由回边计数器触发的OSR编译）。

代码清单11-3 被即时编译的代码

```
VM option '+PrintCompilation'  
310 1 java.lang.String: charAt (33 bytes)  
329 2 org.fenixsoft.jit.Test: calcSum (26  
bytes)  
329 3 org.fenixsoft.jit.Test: doubleValue (4  
bytes)  
332 1%org.fenixsoft.jit.Test: main@5 (20  
bytes)
```

从代码清单11-3输出的确认信息中可以确认 main()、calcSum() 和doubleValue() 方法已经被编译，我们还可以加上参数-XX:
+PrintInlining要求虚拟机输出方法内联信息，如代码清单11-4所示。

代码清单11-4 内联信息

```
VM option'+PrintCompilation'
VM option'+PrintInlining'
273 1 java.lang.String: charAt (33 bytes)
291 2 org.fenixsoft.jit.Test: calcSum (26
bytes)
@9 org.fenixsoft.jit.Test: doubleValue
inline (hot)
294 3 org.fenixsoft.jit.Test: doubleValue (4
bytes)
295 1%org.fenixsoft.jit.Test: main@5 (20
bytes)
@5 org.fenixsoft.jit.Test: calcSum
inline (hot)
@9 org.fenixsoft.jit.Test: doubleValue
inline (hot)
```

从代码清单11-4的输出中可以看到方法doubleValue () 被内联编译到calcSum () 中，而calcSum () 又被内联编译到方法main () 中，所以虚拟机再次执行main () 方法的时候（举例而已，main () 方法并不会运行两次），calcSum () 和doubleValue () 方法都不会再被调用，它们的代码逻辑都被直接内联到main () 方法中了。

除了查看哪些方法被编译之外，还可以进一步查看即时编译器生成的机器码内容，不过如果虚拟机输出一串0和1，对于我们的阅读来说是没有意义的，机器码必须反汇编成基本的汇编语言才可能被阅读。虚拟机提供了一组通用的反汇编接口^[1]，可以接入各种平台下的反汇编适配器来使用，如使用32位80x86平台则选用hsdis-i386适

配器，其余平台的适配器还有hsdis-amd64、hsdis-sparc和hsdis-sparcv9等，可以下载或自己编译出反汇编适配器^[2]，然后将其放置在JRE/bin/client或/server目录下，只要与jvm.dll的路径相同即可被虚拟机调用。在为虚拟机安装了反汇编适配器之后，就可以使用-XX:+PrintAssembly参数要求虚拟机打印编译方法的汇编代码了，具体的操作可以参考本书4.2.7节。

如果没有HSDIS插件支持，也可以使用-XX: +PrintOptoAssembly（用于Server VM）或-XX: +PrintLIR（用于Client VM）来输出比较接近最终结果的中间代码表示，代码清单11-2被编译后部分反汇编（使用-XX: +PrintOptoAssembly）的输出结果如代码清单11-5所示。从阅读角度来说，使用-XX:

+PrintOptoAssembly参数输出的伪汇编结果包含了更多的信息（主要是注释），利于阅读并理解虚拟机JIT编译器的优化结果。

代码清单11-5 本地机器码反汇编信息（部分）

```
.....  
000 B1: #N1<-BLOCK HEAD IS JUNK Freq: 1  
000 pushq rbp  
subq rsp, #16#Create frame  
nop#nop for patch_verified_entry  
006 movl RAX,RDX#spill  
008 sall RAX, #1  
00a addq rsp, 16#Destroy frame  
popq rbp  
testl rax,  
[rip+#offset_to_poll_page]#Safepoint: poll for  
GC  
.....
```

前面提到的使用-XX: +PrintAssembly参数输出反汇编信息需要Debug或者FastDebug版的虚拟

机才能直接支持，如果使用Product版的虚拟机，
则需要加入参数-XX：

+UnlockDiagnosticVMOptions打开虚拟机诊断模式
后才能使用。

如果除了本地代码的生成结果外，还想再进一步跟踪本地代码生成的具体过程，那还可以使用参数-XX：+PrintCFGToFile（使用Client Compiler）或-XX：PrintIdealGraphFile（使用Server Compiler）令虚拟机将编译过程中各个阶段的数据（例如，对C1编译器来说，包括字节码、HIR生成、LIR生成、寄存器分配过程、本地代码生成等数据）输出到文件中。然后使用Java HotSpot Client Compiler Visualizer^[3]（用于分析Client Compiler）或Ideal Graph Visualizer^[4]（用于分析Server Compiler）打开这些数据文件进行分

析。以Server Compiler为例，笔者分析一下JIT编译器的代码生成过程。

Server Compiler的中间代码表示是一种名为Ideal的SSA形式程序依赖图（Program Dependence Graph），在运行Java程序的JVM参数中加入“-XX: PrintIdealGraphLevel=2-XX: PrintIdealGraphFile=ideal.xml”，编译后将产生一个名为ideal.xml的文件，它包含了Server Compiler编译代码的过程信息，可以使用Ideal Graph Visualizer对这些信息进行分析。

Ideal Graph Visualizer加载ideal.xml文件后，在Outline面板上将显示程序运行过程中编译过的方法列表，如图11-5所示。这里列出的方法是代码清单11-2中的测试代码，其中doubleValue（）

方法出现了两次，这是由于该方法的编译结果存在标准编译和OSR编译两个版本。在代码清单11-2中，笔者特别为doubleValue（）方法增加了一个空循环，这个循环对方法的运算结果不会产生影响，但如果没有任何优化，执行空循环会占用CPU时间，到今天还有许多程序设计的入门教程把空循环当做程序延时的手段来介绍，在Java中这样的做法真的能起到延时的作用吗？




图 11-5 编译过的方法列表

展开方法根节点，可以看到下面罗列了方法优化过程的各个阶段（根据优化措施的不同，每个方法所经过的阶段也会有所差别）的Ideal图，我们先打开“After Parsing”这个阶段。上文提到，

JIT编译器在编译一个Java方法时，首先要把字节码解析成某种中间表示形式，然后才可以继续做分析和优化，最终生成代码。“After Parsing”就是Server Compiler刚完成解析，还没有做任何优化时的Ideal图表示。在打开这个图后，读者会看到其中有很多有颜色的方块，如图11-6所示。每一个方块就代表了一个程序的基本块（Basic Block），基本块的特点是只有唯一的一个入口和唯一的一个出口，只要基本块中第一条指令执行了，那么基本块内所有执行都会按照顺序仅执行一次。

代码清单11-2的doubleValue（）方法虽然只有简单的两行字，但是按基本块划分后，形成的图形结构要比想象中复杂得多，这一方面是要满足Java语言所定义的安全需要（如类型安全、空

指针检查) 和Java虚拟机的运作需要(如 Safepoint轮询)，另一方面是由于有些程序代码中一行语句就可能形成好几个基本块(例如循环)。对于例子中的doubleValue()方法，如果忽略语言安全检查的基本块，可以简单理解为按顺序执行了以下几件事情：

- 1) 程序入口，建立栈帧。
- 2) 设置 $j=0$ ，进行Safepoint轮询，跳转到4)
的条件检查。
- 3) 执行 $j++$ 。
- 4) 条件检查，如果 $j < 100000$ ，跳转到3)。
- 5) 设置 $i=i*2$ ，进行Safepoint轮询，函数返回。





图 11-6 基本块图示 (1)

以上几个步骤，反映到Ideal Graph Visualizer的图上，就是如图11-7所示的内容。这样我们要看空循环是否优化，或者何时优化，只要观察代表循环的基本块是否消除，或者何时消除就可以。

了。

要观察到这一点，可以在Outline面板上右键点击“Difference to current graph”，让软件自动分析指定阶段与当前打开的Ideal图之间的差异，如果基本块被消除了，将会以红色显示。对“After Parsing”和“PhaseIdealLoop 1”阶段的Ideal图进行差异分析，发现在“PhaseIdealLoop 1”阶段循环操作被消除了，如图11-8所示，这也就说明空循环实际上是不会被执行的。

B7



B6




图 11-7 基本块图示 (2)




图 11-8 基本块图示 (3)

从“After Parsing”阶段开始，一直到最后的“Final Code”阶段，可以看到`doubleValue()`方

法的Ideal图从繁到简的变迁过程，这也是Java虚拟机在尽力优化代码的过程。到了最后的“Final Code”阶段，不仅空循环的开销消除了，许多语言安全和Safepoint轮询的操作也一起消除了，因为编译器判断即使不做这些安全保障，虚拟机也不会受到威胁。

最后提醒一下读者，要输出CFG或IdealGraph文件，需要一个Debug版或FastDebug版的虚拟机支持，Product版的虚拟机无法输出这些文件。

[1]相关信息：

<http://wikis.sun.com/display/HotSpotInternals/Print%20CFG>

[2]HSDIS的源码可以从以下地址获取：

<http://hg.openjdk.java.net/jdk7/hotspot/hotspot/file/>

另外，相关网站可以下载一个已经编译好了的适

合32位80x86平台使用的反汇编适配器，如在ITeye的高级语言虚拟机圈子的共享区
(<http://hllvm.group.iteye.com/group/share>) 中可以下载。

[3] 官方站点：

[http://java.net/projects/c1visualizer/。](http://java.net/projects/c1visualizer/)

[4] 官方站点：

[http://ssw.jku.at/General/Staff/TW/igv.html。](http://ssw.jku.at/General/Staff/TW/igv.html)

11.3 编译优化技术

Java程序员有一个共识，以编译方式执行本地代码比解释方式更快，之所以有这样的共识，除去虚拟机解释执行字节码时额外消耗时间的原因外，还有一个很重要的原因就是虚拟机设计团队几乎把对代码的所有优化措施都集中在了即时编译器之中（在JDK 1.3之后，Javac就去除了-O选项，不会生成任何字节码级别的优化代码了），因此一般来说，即时编译器产生的本地代码会比Javac产生的字节码更加优秀^[1]。下面，笔者将介绍一些HotSpot虚拟机的即时编译器在生成代码时采用的代码优化技术。

11.3.1 优化技术概览

在Sun官方的Wiki上，HotSpot虚拟机设计团队列出了一个相对比较全面的、在即时编译器中采用的优化技术列表^[2]（见表11-1），其中有不少经典编译器的优化手段，也有许多针对Java语言（准确地说是针对运行在Java虚拟机上的所有语言）本身进行的优化技术，本节将对这些技术进行概括性的介绍，在后面几节中，再挑选若干重要且典型的优化，与读者一起看看优化前后的代码产生了怎样的变化。

表 11-1 即时编译器优化技术一览

| 类 型 | 优 化 技 术 |
|---|---|
| 编译器策略 (compiler tactics) | 延迟编译 (delayed compilation) |
| | 分层编译 (tiered compilation) |
| | 栈上替换 (on-stack replacement) |
| | 延迟优化 (delayed reoptimization) |
| | 程序依赖图表示 (program dependence graph representation) |
| | 静态单赋值表示 (static single assignment representation) |
| | 乐观空值断言 (optimistic nullness assertions) |
| | 乐观类型断言 (optimistic type assertions) |
| | 乐观类型增强 (optimistic type strengthening) |
| | 乐观数组长度增强 (optimistic array length strengthening) |
| 基于性能监控的优化技术 (profile-based techniques) | 裁剪未被选择的分支 (untaken branch pruning) |
| | 乐观的多态内联 (optimistic N-morphic inlining) |
| | 分支频率预测 (branch frequency prediction) |
| | 调用频率预测 (call frequency prediction) |
| | 精确类型推断 (exact type inference) |
| | 内存值推断 (memory value inference) |
| | 内存值跟踪 (memory value tracking) |
| | 常量折叠 (constant folding) |
| | 重组 (reassociation) |
| | 操作符退化 (operator strength reduction) |
| 基于证据的优化技术 (proof-based techniques) | 空值检查消除 (null check elimination) |
| | 类型检测退化 (type test strength reduction) |
| | 类型检测消除 (type test elimination) |
| | 代数化简 (algebraic simplification) |
| | 公共子表达式消除 (common subexpression elimination) |
| | |
| | |

| 类 型 | 优化技术 |
|--|--|
| 数据流敏感重写 (flow-sensitive rewrites) | 条件常量传播 (conditional constant propagation) 基于流承载的类型缩减转换 (flow-carried type narrowing) 无用代码消除 (dead code elimination) |
| 语言相关的优化技术 (language-specific techniques) | 类型继承关系分析 (class hierarchy analysis) 去虚拟化 (devirtualization) 符号常量传播 (symbolic constant propagation) 自动装箱消除 (autobox elimination) 逃逸分析 (escape analysis) 锁消除 (lock elision) 锁膨胀 (lock coarsening) 消除反射 (de-reflection) |
| 内存及代码位置变换 (memory and placement transformation) | 表达式提升 (expression hoisting) 表达式下沉 (expression sinking) 冗余存储消除 (redundant store elimination) 相邻存储合并 (adjacent store fusion) 交汇点分离 (merge-point splitting) |
| 循环变换 (loop transformations) | 循环展开 (loop unrolling) 循环剥离 (loop peeling) 安全点消除 (safepoint elimination) 迭代范围分离 (iteration range splitting) 范围检查消除 (range check elimination) 循环向量化 (loop vectorization) 内联 (inlining) |
| 全局代码调整 (global code shaping) | 全局代码外提 (global code motion) 基于热度的代码布局 (heat-based code layout) Switch 调整 (switch balancing) |
| 控制流图变换 (control flow graph transformation) | 本地代码编排 (local code scheduling) 本地代码封包 (local code bundling) 延迟槽填充 (delay slot filling) 着色图寄存器分配 (graph-coloring register allocation) 线性扫描寄存器分配 (linear scan register allocation) 复写聚合 (copy coalescing) 常量分裂 (constant splitting) 复写移除 (copy removal) 地址模式匹配 (address mode matching) 指令窥孔优化 (instruction peephole) 基于确定有限状态机的代码生成 (DFA-based code generator) |

上述的优化技术看起来很多，而且从名字看

都显得有点“高深莫测”，虽然实现这些优化也许确实有些难度，但大部分技术理解起来都并不困难。为了消除读者对这些优化技术的陌生感，笔者举一个简单的例子，即通过大家熟悉的Java代码变化来展示其中几种优化技术是如何发挥作用的（仅使用Java代码来表示而已）。首先从原始代码开始，如代码清单11-6所示^[3]。

代码清单11-6 优化前的原始代码

```
static class B{
    int value;
    final int get () {
        return value;
    }
    public void foo () {
        y=b.get ();
        //.....do stuff.....
        z=b.get ();
        sum=y+z;
    }
}
```

首先需要明确的是，这些代码优化变换是建立在代码的某种中间表示或机器码之上，绝不是建立在Java源码之上的，为了展示方便，笔者使用了Java语言的语法来表示这些优化技术所发挥的作用。

代码清单11-6的代码已经非常简单了，但是仍有许多优化的余地。第一步进行方法内联（Method Inlining），方法内联的重要性要高于其他优化措施，它的主要目的有两个，一是去除方法调用的成本（如建立栈帧等），二是为其他优化建立良好的基础，方法内联膨胀之后可以便于在更大范围上采取后续的优化手段，从而获取更好的优化效果。因此，各种编译器一般都会把内联优化放在优化序列的最靠前位置。内联后的代码如代码清单11-7所示。

代码清单11-7 内联后的代码

```
public void foo () {  
    y=b.value;  
    //.....do stuff.....  
    z=b.value;  
    sum=y+z;  
}
```

第二步进行冗余访问消除（Redundant Loads Elimination），假设代码中间注释掉的“dostuff.....”所代表的操作不会改变b.value的值，那就可以把“z=b.value”替换为“z=y”，因为上一句“y=b.value”已经保证了变量y与b.value是一致的，这样就可以不再去访问对象b的局部变量了。如果把b.value看做是一个表达式，那也可以把这项优化看成是公共子表达式消除（Common Subexpression Elimination），优化后的代码如代

码清单11-8所示。

代码清单11-8 冗余存储消除的代码

```
public void foo () {  
    y=b.value;  
    //.....do stuff.....  
    z=y;  
    sum=y+z;  
}
```

第三步我们进行复写传播（Copy

Propagation），因为在这些程序的逻辑中并没有必要使用一个额外的变量“z”，它与变量“y”是完全相等的，因此可以使用“y”来代替“z”。复写传播之后程序如代码清单11-9所示。

代码清单11-9 复写传播的代码

```
public void foo () {  
    y=b.value;
```

```
//.....do stuff.....  
y=y;  
sum=y+y;  
}
```

第四步我们进行无用代码消除（Dead Code Elimination）。无用代码可能是永远不会被执行的代码，也可能是完全没有意义的代码，因此，它又形象地称为“Dead Code”，在代码清单11-9中，“y=y”是没有意义的，把它消除后的程序如代码清单11-10所示。

代码清单11-10 进行无用代码消除的代码

```
public void foo () {  
    y=b.value;  
    //.....do stuff.....  
    sum=y+y;  
}
```

经过四次优化之后，代码清单11-10与代码清

单11-6所达到的效果是一致的，但是前者比后者省略了许多语句（体现在字节码和机器码指令上的差距会更大），执行效率也会更高。编译器的这些优化技术实现起来也许比较复杂，但是要理解它们的行为对于一个普通的程序员来说是没有困难的，接下来，我们将继续查看如下的几项最有代表性的优化技术是如何运作的，它们分别是：

语言无关的经典优化技术之一：公共子表达式消除。

语言相关的经典优化技术之一：数组范围检查消除。

最重要的优化技术之一：方法内联。

最前沿的优化技术之一：逃逸分析。

[1]本地代码与字节码两者是无法直接比较的，准确地说应当是指：由编译器优化得到的本地代码与由解释器解释字节码后实际执行的本地代码之间的对比。

[2]地址：

<http://wikis.sun.com/display/HotSpotInternals/Perfor>

[3]本例修改自：

http://download.oracle.com/docs/cd/E13150_01/jroc

11.3.2 公共子表达式消除

公共子表达式消除是一个普遍应用于各种编译器的经典优化技术，它的含义是：如果一个表达式E已经计算过了，并且从先前的计算到现在E中所有变量的值都没有发生变化，那么E的这次出现就成为了公共子表达式。对于这种表达式，没有必要花时间再对它进行计算，只需要直接用前面计算过的表达式结果代替E就可以了。如果这种优化仅限于程序的基本块内，便称为局部公共子表达式消除（Local Common Subexpression Elimination），如果这种优化的范围涵盖了多个基本块，那就称为全局公共子表达式消除（Global Common Subexpression Elimination）。举

个简单的例子来说明它的优化过程，假设存在如下代码：

```
int d= (c * b) *12+a+ (a+b * c) ;
```

如果这段代码交给Javac编译器则不会进行任何优化，那生成的代码将如代码清单11-11所示，是完全遵照Java源码的写法直译而成的。

代码清单11-11 未做任何优化的字节码

```
iload_2//b
imul//计算b * c
bipush 12//推入12
imul//计算 (c * b) *12
iload_1//a
iadd//计算 (c * b) *12+a
iload_1//a
iload_2//b
iload_3//c
imul//计算b * c
iadd//计算a+b * c
iadd//计算 (c * b) *12+a+ (a+b * c)
istore 4
```

当这段代码进入到虚拟机即时编译器后，它将进行如下优化：编译器检测到“ $c * b$ ”与“ $b * c$ ”是一样的表达式，而且在计算期间 b 与 c 的值是不变的。因此，这条表达式就可能被视为：

```
int d=E*12+a+ (a+E) ;
```

这时，编译器还可能（取决于哪种虚拟机的编译器以及具体的上下文而定）进行另外一种优化：代数化简（Algebraic Simplification），把表达式变为：

```
int d=E*13+a*2;
```

表达式进行变换之后，再计算起来就可以节省一些时间了。如果读者还对其他的经典编译优

化技术感兴趣，可以参考《编译原理》（俗称“龙书”，推荐使用Java的程序员阅读2006年版的“紫龙书”）中的相关章节。

11.3.3 数组边界检查消除

数组边界检查消除（Array Bounds Checking Elimination）是即时编译器中的一项语言相关的经典优化技术。我们知道Java语言是一门动态安全的语言，对数组的读写访问也不像C、C++那样在本质上是裸指针操作。如果有一个数组`foo[]`，在Java语言中访问数组元素`foo[i]`的时候系统将会自动进行上下界的范围检查，即检查`i`必须满足`i >= 0 && i < foo.length`这个条件，否则将抛出一个运行时异常：

`java.lang.ArrayIndexOutOfBoundsException`。这对软件开发者来说是一件很好的事情，即使程序员没有专门编写防御代码，也可以避免大部分的溢

出攻击。但是对于虚拟机的执行子系统来说，每次数组元素的读写都带有一次隐含的条件判定操作，对于拥有大量数组访问的程序代码，这无疑也是一种性能负担。

无论如何，为了安全，数组边界检查肯定是非常必要的，但数组边界检查是不是必须在运行期间一次不漏地检查则是可以“商量”的事情。例如下面这个简单的情况：数组下标是一个常量，如`foo[3]`，只要在编译期根据数据流分析来确定`foo.length`的值，并判断下标“3”没有越界，执行的时候就无须判断了。更加常见的情况是数组访问发生在循环之中，并且使用循环变量来进行数组访问，如果编译器只要通过数据流分析就可以判定循环变量的取值范围永远在区间`[0, foo.length)`之内，那在整个循环中就可以把数组

的上下界检查消除，这可以节省很多次的条件判断操作。

将这个数组边界检查的例子放在更高的角度来看，大量的安全检查令编写Java程序比编写C/C++程序容易很多，如数组越界会得到`ArrayIndexOutOfBoundsException`异常，空指针访问会得到`NullPointerException`，除数为零会得到`ArithmaticException`等，在C/C++程序中出现类似的问题，一不小心就会出现`Segment Fault`信号或者Window编程中常见的“xxx内存不能为Read/Write”之类的提示，处理不好程序就直接崩溃退出了。但这些安全检查也导致了相同的程序，Java要比C/C++做更多的事情（各种检查判断），这些事情就成为一种隐式开销，如果处理不好它们，就很可能成为一个Java语言比

C/C++更慢的因素。要消除这些隐式开销，除了如数组边界检查优化这种尽可能把运行期检查提到编译期完成的思路之外，另外还有一种避免思路——隐式异常处理，Java中空指针检查和算术运算中除数为零的检查都采用了这种思路。举个例子，例如程序中访问一个对象（假设对象叫foo）的某个属性（假设属性叫value），那以Java伪代码来表示虚拟机访问foo.value的过程如下。

```
if (foo != null) {  
    return foo.value;  
} else {  
    throw new NullPointerException();  
}
```

在使用隐式异常优化之后，虚拟机会把上面伪代码所表示的访问过程变为如下伪代码。

```
try{
```

```
return foo.value;  
}catch (segment_fault) {  
uncommon_trap ();  
}
```

虚拟机会注册一个Segment Fault信号的异常处理器（伪代码中的uncommon_trap（）），这样当foo不为空的时候，对value的访问是不会额外消耗一次对foo判空的开销的。代价就是当foo真的为空时，必须转入到异常处理器中恢复并抛出NullPointException异常，这个过程必须从用户态转到内核态中处理，结束后再回到用户态，速度远比一次判空检查慢。当foo极少为空的时候，隐式异常优化是值得的，但假如foo经常为空的话，这样的优化反而会让程序更慢，还好HotSpot虚拟机足够“聪明”，它会根据运行期收集到的Profile信息自动选择最优方案。

与语言相关的其他消除操作还有不少，如自动装箱消除（Autobox Elimination）、安全点消除（Safepoint Elimination）、消除反射（Dereflection）等，笔者就不再一一介绍了。

11.3.4 方法内联

在前面的讲解之中我们提到过方法内联，它是编译器最重要的优化手段之一，除了消除方法调用的成本之外，它更重要的意义是为其他优化手段建立良好的基础，如代码清单11-12所示的简单例子就揭示了内联对其他优化手段的意义：事实上`testInline()`方法的内部全部都是无用的代码，如果不做内联，后续即使进行了无用代码消除的优化，也无法发现任何“Dead Code”，因为如果分开来看，`foo()`和`testInline()`两个方法里面的操作都可能是有意义的。

代码清单11-12 未做任何优化的字节码

```
public static void foo (Object obj) {
```

```
if (obj != null) {  
    System.out.println ("do something");  
}  
}  
  
public static void  
testInline (String []args) {  
    Object obj=null;  
    foo (obj);  
}
```

方法内联的优化行为看起来很简单，不过是把目标方法的代码“复制”到发起调用的方法之中，避免发生真实的方法调用而已。但实际上Java虚拟机中的内联过程远远没有那么简单，因为如果不是即时编译器做了一些特别的努力，按照经典编译原理的优化理论，大多数的Java方法都无法进行内联。

无法内联的原因其实在第8章中讲解Java方法解析和分派调用的时候就已经介绍过。只有使用invokespecial指令调用的私有方法、实例构造

器、父类方法以及使用`invokestatic`指令进行调用的静态方法才是在编译期进行解析的，除了上述4种方法之外，其他的Java方法调用都需要在运行时进行方法接收者的多态选择，并且都有可能存在多于一个版本的方法接收者（最多再除去被`final`修饰的方法这种特殊情况，尽管它使用`invokevirtual`指令调用，但也是非虚方法，Java语言规范中明确说明了这点），简而言之，Java语言中默认的实例方法是虚方法。

对于一个虚方法，编译期做内联的时候根本无法确定应该使用哪个方法版本，如果以代码清单11-7中把“`b.get()`”内联为“`b.value`”为例的话，就是不依赖上下文就无法确定`b`的实际类型是什么。假如有`ParentB`和`SubB`两个具有继承关系的类，并且子类重写了父类的`get()`方法，那

么，是要执行父类的get（）方法还是子类的get（）方法，需要在运行期才能确定，编译期无法得出结论。

由于Java语言提倡使用面向对象的编程方式进行编程，而Java对象的方法默认就是虚方法，因此Java间接鼓励了程序员使用大量的虚方法来完成程序逻辑。根据上面的分析，如果内联与虚方法之间产生“矛盾”，那该怎么办呢？是不是为了提高执行性能，就要到处使用final关键字去修饰方法呢？

为了解决虚方法的内联问题，Java虚拟机设计团队想了很多办法，首先是引入了一种名为“类型继承关系分析”（Class Hierarchy Analysis,CHA）的技术，这是一种基于整个应用

程序的类型分析技术，它用于确定在目前已加载的类中，某个接口是否有多于一种的实现，某个类是否存在子类、子类是否为抽象类等信息。

编译器在进行内联时，如果是非虚方法，那么直接进行内联就可以了，这时候的内联是有稳定前提保障的。如果遇到虚方法，则会向CHA查询此方法在当前程序下是否等多个目标版本可供选择，如果查询结果只有一个版本，那也可以进行内联，不过这种内联就属于激进优化，需要预留一个“逃生门”（Guard条件不成立时的Slow Path），称为守护内联（Guarded Inlining）。如果程序的后续执行过程中，虚拟机一直没有加载到会令这个方法的接收者的继承关系发生变化的类，那这个内联优化的代码就可以一直使用下去。但如果加载了导致继承关系发生变化的新

类，那就需要抛弃已经编译的代码，退回到解释状态执行，或者重新进行编译。

如果向CHA查询出来的结果是有多个版本的目标方法可供选择，则编译器还将会进行最后一次努力，使用内联缓存（Inline Cache）来完成方法内联，这是一个建立在目标方法正常入口之前的缓存，它的工作原理大致是：在未发生方法调用之前，内联缓存状态为空，当第一次调用发生后，缓存记录下方法接收者的版本信息，并且每次进行方法调用时都比较接收者版本，如果以后进来的每次调用的方法接收者版本都是一样的，那这个内联还可以一直用下去。如果发生了方法接收者不一致的情况，就说明程序真正使用了虚方法的多态特性，这时才会取消内联，查找虚方法表进行方法分派。

所以说，在许多情况下虚拟机进行的内联都是一种激进优化，激进优化的手段在高性能的商用虚拟机中很常见，除了内联之外，对于出现概率很小（通过经验数据或解释器收集到的性能监控信息确定概率大小）的隐式异常、使用概率很小的分支等都可以被激进优化“移除”，如果真的出现了小概率事件，这时才会从“逃生门”回到解释状态重新执行。

11.3.5 逃逸分析

逃逸分析（Escape Analysis）是目前Java虚拟机中比较前沿的优化技术，它与类型继承关系分析一样，并不是直接优化代码的手段，而是为其他优化手段提供依据的分析技术。

逃逸分析的基本行为就是分析对象动态作用域：当一个对象在方法中被定义后，它可能被外部方法所引用，例如作为调用参数传递到其他方法中，称为方法逃逸。甚至还有可能被外部线程访问到，譬如赋值给类变量或可以在其他线程中访问的实例变量，称为线程逃逸。

如果能证明一个对象不会逃逸到方法或线程

之外，也就是别的方法或线程无法通过任何途径访问到这个对象，则可能为这个变量进行一些高效的优化，如下所示。

栈上分配（Stack Allocation）：Java虚拟机中，在Java堆上分配创建对象的内存空间几乎是Java程序员都清楚的常识了，Java堆中的对象对于各个线程都是共享和可见的，只要持有这个对象的引用，就可以访问堆中存储的对象数据。虚拟机的垃圾收集系统可以回收堆中不再使用的对象，但回收动作无论是筛选可回收对象，还是回收和整理内存都需要耗费时间。如果确定一个对象不会逃逸出方法之外，那让这个对象在栈上分配内存将会是一个很不错的主意，对象所占用的内存空间就可以随栈帧出栈而销毁。在一般应用中，不会逃逸的局部对象所占的比例很大，如果

能使用栈上分配，那大量的对象就会随着方法的结束而自动销毁了，垃圾收集系统的压力将会小很多。

同步消除（Synchronization Elimination）：线程同步本身是一个相对耗时的过程，如果逃逸分析能够确定一个变量不会逃逸出线程，无法被其他线程访问，那这个变量的读写肯定就不会有竞争，对这个变量实施的同步措施也就可以消除掉。

标量替换（Scalar Replacement）：标量（Scalar）是指一个数据已经无法再分解成更小的数据来表示了，Java虚拟机中的原始数据类型（int、long等数值类型以及reference类型等）都不能再进一步分解，它们就可以称为标量。相对

的，如果一个数据可以继续分解，那它就称作聚合量（Aggregate），Java中的对象就是最典型的聚合量。如果把一个Java对象拆散，根据程序访问的情况，将其使用到的成员变量恢复原始类型来访问就叫做标量替换。如果逃逸分析证明一个对象不会被外部访问，并且这个对象可以被拆散的话，那程序真正执行的时候将可能不创建这个对象，而改为直接创建它的若干个被这个方法使用到的成员变量来代替。将对象拆分后，除了可以让对象的成员变量在栈上（栈上存储的数据，有很大的概率会被虚拟机分配至物理机器的高速寄存器中存储）分配和读写之外，还可以为后续进一步的优化手段创建条件。

关于逃逸分析的论文在1999年就已经发表，但直到Sun JDK 1.6才实现了逃逸分析，而且直到

现在这项优化尚未足够成熟，仍有很大的改进余地。不成熟的原因主要是不能保证逃逸分析的性能收益必定高于它的消耗。如果要完全准确地判断一个对象是否会逃逸，需要进行数据流敏感的一系列复杂分析，从而确定程序各个分支执行时对此对象的影响。这是一个相对高耗时的过程，如果分析完后发现没有几个不逃逸的对象，那这些运行期耗用的时间就白白浪费了，所以目前虚拟机只能采用不那么准确，但时间压力相对较小的算法来完成逃逸分析。还有一点是，基于逃逸分析的一些优化手段，如上面提到的“栈上分配”，由于HotSpot虚拟机目前的实现方式导致栈上分配实现起来比较复杂，因此在HotSpot中暂时还没有做这项优化。

在测试结果中，实施逃逸分析后的程序在

MicroBenchmarks中往往能运行出不错的成绩，但是在实际的应用程序，尤其是大型程序中反而发现实施逃逸分析可能出现效果不稳定的情况，或因分析过程耗时但却无法有效判别出非逃逸对象而导致性能（即时编译的收益）有所下降，所以在很长的一段时间里，即使是Server Compiler，也默认不开启逃逸分析^[1]，甚至在某些版本（如JDK 1.6 Update 18）中还曾经短暂地完全禁止了这项优化。

如果有需要，并且确认对程序运行有益，用户可以使用参数-XX: +DoEscapeAnalysis来手动开启逃逸分析，开启之后可以通过参数-XX: +PrintEscapeAnalysis来查看分析结果。有了逃逸分析支持之后，用户可以使用参数-XX: +EliminateAllocations来开启标量替换，使用

+XX: +EliminateLocks来开启同步消除，使用参数-XX: +PrintEliminateAllocations查看标量的替换情况。

尽管目前逃逸分析的技术仍不是十分成熟，但是它却是即时编译器优化技术的一个重要的发展方向，在今后的虚拟机中，逃逸分析技术肯定会支撑起一系列实用有效的优化技术。

[1]在JDK 1.6 Update 23的Server Compiler中才开始默认开启了逃逸分析。

11.4 Java与C/C++的编译器对比

大多数程序员都认为C/C++会比Java语言快，甚至觉得从Java语言诞生以来“执行速度缓慢”的帽子就应当扣在它的头顶，这种观点的出现是由于Java刚出现的时候即时编译技术还不成熟，主要靠解释器执行的Java语言性能确实比较低下。但目前即时编译技术已经十分成熟，Java语言有可能在速度上与C/C++一争高下吗？要想知道这个问题的答案，让我们从两者的编译器谈起[1]。

Java与C/C++的编译器对比实际上代表了最经典的即时编译器与静态编译器的对比，很大程度上也决定了Java与C/C++的性能对比的结果，

因为无论是C/C++还是Java代码，最终编译之后被机器执行的都是本地机器码，哪种语言的性能更高，除了它们自身的API库实现得好坏以外，其余的比较就成了一场“拼编译器”和“拼输出代码质量”的游戏。当然，这种比较也是剔除了开发效率的片面对比，语言间孰优孰劣、谁快谁慢的问题都是很难有结果的争论，下面我们就回到正题，看看这两种语言的编译器各有什么种优势。

Java虚拟机的即时编译器与C/C++的静态优化编译器相比，可能会由于下列这些原因而导致输出的本地代码有一些劣势（下面列举的也包括一些虚拟机执行子系统的性能劣势）：

第一，因为即时编译器运行占用的是用户程序的运行时间，具有很大的时间压力，它能提供

的优化手段也严重受制于编译成本。如果编译速度不能达到要求，那用户将在启动程序或程序的某部分察觉到重大延迟，这点使得即时编译器不敢随便引入大规模的优化技术，而编译的时间成本在静态优化编译器中并不是主要的关注点。

第二，Java语言是动态的类型安全语言，这就意味着需要由虚拟机来确保程序不会违反语言语义或访问非结构化内存。从实现层面上看，这就意味着虚拟机必须频繁地进行动态检查，如实例方法访问时检查空指针、数组元素访问时检查上下界范围、类型转换时检查继承关系等。对于这类程序代码没有明确写出的检查行为，尽管编译器会努力进行优化，但是总体上仍然要消耗不少的运行时间。

第三，Java语言中虽然没有virtual关键字，但是使用虚方法的频率却远远大于C/C++语言，这意味着运行时对方法接收者进行多态选择的频率要远远大于C/C++语言，也意味着即时编译器在进行一些优化（如前面提到的方法内联）时的难度要远大于C/C++的静态优化编译器。

第四，Java语言是可以动态扩展的语言，运行时加载新的类可能改变程序类型的继承关系，这使得很多全局的优化都难以进行，因为编译器无法看见程序的全貌，许多全局的优化措施都只能以激进优化的方式来完成，编译器不得不时刻注意并随着类型的变化而在运行时撤销或重新进行一些优化。

第五，Java语言中对象的内存分配都是堆上

进行的，只有方法中的局部变量才能在栈上分配^[2]。而C/C++的对象则有多种内存分配方式，既可能在堆上分配，又可能在栈上分配，如果可以在栈上分配线程私有的对象，将减轻内存回收的压力。另外，C/C++中主要由用户程序代码来回收分配的内存，这就不存在无用对象筛选的过程，因此效率上（仅指运行效率，排除了开发效率）也比垃圾收集机制要高。

上面说了一大堆Java语言相对C/C++的劣势，不是说Java就真的不如C/C++了，相信读者也注意到了，Java语言的这些性能上的劣势都是为了换取开发效率上的优势而付出的代价，动态安全、动态扩展、垃圾回收这些“拖后腿”的特性都为Java语言的开发效率做出了很大贡献。

何况，还有许多优化是Java的即时编译器能做而C/C++的静态优化编译器不能做或者不好做的。例如，在C/C++中，别名分析（Alias Analysis）的难度就要远高于Java。Java的类型安全保证了在类似如下代码中，只要ClassA和ClassB没有继承关系，那对象objA和objB就绝不可能是同一个对象，即不会是同一块内存两个不同别名。

```
void foo (ClassA objA, ClassB objB) {  
    objA.x=123;  
    objB.y=456;  
    //只要objB.y不是objA.x的别名，下面就可以保证输出为  
123  
    print (objA.x);  
}
```

确定了objA和objB并非对方的别名后，许多与数据依赖相关的优化才可以进行（重排序、变

量代换）。具体到这个例子中，就是无须担心 objB.y其实与objA.x指向同一块内存，这样就可以安全地确定打印语句中的objA.x为123。

Java编译器另外一个红利是由它的动态性所带来的，由于C/C++编译器所有优化都在编译期完成，以运行期性能监控为基础的优化措施它都无法进行，如调用频率预测（Call Frequency Prediction）、分支频率预测（Branch Frequency Prediction）、裁剪未被选择的分支（Untaken Branch Pruning）等，这些都会成为Java语言独有的性能优势。

[1]C/C++与Java孰优孰劣、谁快谁慢这类话题已经争论了十几年，双方的支持者从来都没有说服过对方，有朋友好意提醒过笔者不要跳入这种语

言性能争论的“火坑”，把这节移除掉。笔者在此也特别说明，本节的目的仅是从编译和执行的角度来探讨两者的差异，并不是去评判孰优孰劣。

[2]Java中非逃逸对象的标量替换优化可以看做是一种高度优化后的栈上分配，但它相当于把对象拆散成局部变量再进行的栈上分配，而不是C/C++那种程序代码可控的栈上分配方式。

11.5 本章小结

第10~11两章分别介绍了Java程序从源码编译成字节码和从字节码编译成本地机器码的过程，Javac字节码编译器与虚拟机内的JIT编译器的执行过程合并起来其实就等同于一个传统编译器所执行的编译过程。

本章中，我们着重了解了虚拟机的热点探测方法、HotSpot的即时编译器、编译触发条件，以及如何从虚拟机外部观察和分析JIT编译的数据和结果，还选择了几种常见的编译期优化技术进行讲解。对Java编译器的深入了解，有助于在工作中分辨哪些代码是编译器可以帮我们处理的，哪些代码需要自己调节以便更适合编译器的优化。

第五部分 高效并发

第12章 Java内存模型与线程

第13章 线程安全与锁优化

第12章 Java内存模型与线程

并发处理的广泛应用是使得Amdahl定律代替摩尔定律^[1]成为计算机性能发展源动力的根本原因，也是人类“压榨”计算机运算能力的最有力武器。

12.1 概述

多任务处理在现代计算机操作系统中几乎已是一项必备的功能了。在许多情况下，让计算机同时去做几件事情，不仅是因为计算机的运算能力强大了，还有一个很重要的原因是计算机的运算速度与它的存储和通信子系统速度的差距太大，大量的时间都花费在磁盘I/O、网络通信或者数据库访问上。如果不希望处理器在大部分时间

里都处于等待其他资源的状态，就必须使用一些手段去把处理器的运算能力“压榨”出来，否则就会造成很大的浪费，而让计算机同时处理几项任务则是最容易想到、也被证明是非常有效的“压榨”手段。

除了充分利用计算机处理器的能力外，一个服务端同时对多个客户端提供服务则是另一个更具体的并发应用场景。衡量一个服务性能的高低好坏，每秒事务处理数（Transactions Per Second, TPS）是最重要的指标之一，它代表着一秒内服务端平均能响应的请求总数，而TPS值与程序的并发能力又有非常密切的关系。对于计算量相同的任务，程序线程并发协调得越有条不紊，效率自然就会越高；反之，线程之间频繁阻塞甚至死锁，将会大大降低程序的并发能力。

服务端是Java语言最擅长的领域之一，这个领域的应用占了Java应用中最大的一块份额^[2]，不过如何写好并发应用程序却又是服务端程序开发的难点之一，处理好并发方面的问题通常需要更多的编码经验来支持。幸好Java语言和虚拟机提供了许多工具，把并发编程的门槛降低了不少。并且各种中间件服务器、各类框架都努力地替程序员处理尽可能多的线程并发细节，使得程序员在编码时能更关注业务逻辑，而不是花费大部分时间去关注此服务会同时被多少人调用、如何协调硬件资源。无论语言、中间件和框架如何先进，开发人员都不能期望它们能独立完成所有并发处理的事情，了解并发的内幕也是成为一个高级程序员不可缺少的课程。

“高效并发”是本书讲解Java虚拟机的最后一部分，将会向读者介绍虚拟机如何实现多线程、多线程之间由于共享和竞争数据而导致的一系列问题及解决方案。

[1]Amdahl定律通过系统中并行化与串行化的比重来描述多处理器系统能获得的运算加速能力，摩尔定律则用于描述处理器晶体管数量与运行效率之间的发展关系。这两个定律的更替代表了近年来硬件发展从追求处理器频率到追求多核心并行处理的发展过程。

[2]必须以代码的总体规模来衡量，服务端应用不能与JavaCard、移动终端这些领域去比绝对数量。

12.2 硬件的效率与一致性

在正式讲解Java虚拟机并发相关的知识之前，我们先花费一点时间去了解一下物理计算机中的并发问题，物理机遇到的并发问题与虚拟机中的情况有不少相似之处，物理机对并发的处理方案对于虚拟机的实现也有相当大的参考意义。

“让计算机并发执行若干个运算任务”与“更充分地利用计算机处理器的效能”之间的因果关系，看起来顺理成章，实际上它们之间的关系并没有想象中的那么简单，其中一个重要的复杂性来源是绝大多数的运算任务都不可能只靠处理器“计算”就能完成，处理器至少要与内存交互，如读取运算数据、存储运算结果等，这个I/O操作

是很难消除的（无法仅靠寄存器来完成所有运算任务）。由于计算机的存储设备与处理器的运算速度有几个数量级的差距，所以现代计算机系统都不得不加入一层读写速度尽可能接近处理器运算速度的高速缓存（Cache）来作为内存与处理器之间的缓冲：将运算需要使用到的数据复制到缓存中，让运算能快速进行，当运算结束后再从缓存同步回内存之中，这样处理器就无须等待缓慢的内存读写了。

基于高速缓存的存储交互很好地解决了处理器与内存的速度矛盾，但是也为计算机系统带来更高的复杂度，因为它引入了一个新的问题：缓存一致性（Cache Coherence）。在多处理器系统中，每个处理器都有自己的高速缓存，而它们又共享同一主内存（Main Memory），如图12-1所

示。当多个处理器的运算任务都涉及同一块主内存区域时，将可能导致各自的缓存数据不一致，如果真的发生这种情况，那同步回到主内存时以谁的缓存数据为准呢？为了解决一致性的问题，需要各个处理器访问缓存时都遵循一些协议，在读写时要根据协议来进行操作，这类协议有MSI、MESI（Illinois Protocol）、MOSI、Synapse、Firefly及Dragon Protocol等。在本章中将会多次提到的“内存模型”一词，可以理解为在特定的操作协议下，对特定的内存或高速缓存进行读写访问的过程抽象。不同架构的物理机器可以拥有不一样的内存模型，而Java虚拟机也有自己的内存模型，并且这里介绍的内存访问操作与硬件的缓存访问操作具有很高的可比性。




图 12-1 处理器、高速缓存、主内存间的交互关系

除了增加高速缓存之外，为了使得处理器内部的运算单元能尽量被充分利用，处理器可能会对输入代码进行乱序执行（Out-Of-Order Execution）优化，处理器会在计算之后将乱序执行的结果重组，保证该结果与顺序执行的结果是一致的，但并不保证程序中各个语句计算的先后顺序与输入代码中的顺序一致，因此，如果存在一个计算任务依赖另外一个计算任务的中间结

果，那么其顺序性并不能靠代码的先后顺序来保证。与处理器的乱序执行优化类似，Java虚拟机的即时编译器中也有类似的指令重排序（Instruction Reorder）优化。

12.3 Java内存模型

Java虚拟机规范中试图定义一种Java内存模型^[1]（Java Memory Model,JMM）来屏蔽掉各种硬件和操作系统的内存访问差异，以实现让Java程序在各种平台下都能达到一致的内存访问效果。在此之前，主流程序语言（如C/C++等）直接使用物理硬件和操作系统的内存模型，因此，会由于不同平台上内存模型的差异，有可能导致程序在一套平台上并发完全正常，而在另外一套平台上并发访问却经常出错，因此在某些场景就必须针对不同的平台来编写程序。

定义Java内存模型并非一件容易的事情，这个模型必须定义得足够严谨，才能让Java的并发

内存访问操作不会产生歧义；但是，也必须定义得足够宽松，使得虚拟机的实现有足够的自由空间去利用硬件的各种特性（寄存器、高速缓存和指令集中某些特有的指令）来获取更好的执行速度。经过长时间的验证和修补，在JDK 1.5（实现了JSR-133^[2]）发布后，Java内存模型已经成熟和完善起来了。

12.3.1 主内存与工作内存

Java内存模型的主要目标是定义程序中各个变量的访问规则，即在虚拟机中将变量存储到内存和从内存中取出变量这样的底层细节。此处的变量（Variables）与Java编程中所说的变量有所区别，它包括了实例字段、静态字段和构成数组

对象的元素，但不包括局部变量与方法参数，因为后者是线程私有的^[3]，不会被共享，自然就不会存在竞争问题。为了获得较好的执行效能，Java内存模型并没有限制执行引擎使用处理器的特定寄存器或缓存来和主内存进行交互，也没有限制即时编译器进行调整代码执行顺序这类优化措施。

Java内存模型规定了所有的变量都存储在主内存（Main Memory）中（此处的主内存与介绍物理硬件时的主内存名字一样，两者也可以互相类比，但此处仅是虚拟机内存的一部分）。每条线程还有自己的工作内存（Working Memory，可与前面讲的处理器高速缓存类比），线程的工作内存中保存了被该线程使用到的变量的主内存副本拷贝^[4]，线程对变量的所有操作（读取、赋值

等)都必须在工作内存中进行,而不能直接读写主内存中的变量^[5]。不同的线程之间也无法直接访问对方工作内存中的变量,线程间变量值的传递均需要通过主内存来完成,线程、主内存、工作内存三者的交互关系如图12-2所示。

这里所讲的主内存、工作内存与本书第2章所讲的Java内存区域中的Java堆、栈、方法区等并不是同一个层次的内存划分,这两者基本上是没有关系的,如果两者一定要勉强对应起来,那从变量、主内存、工作内存的定义来看,主内存主要对应于Java堆中的对象实例数据部分^[6],而工作内存则对应于虚拟机栈中的部分区域。从更低层次上说,主内存就直接对应于物理硬件的内存,而为了获取更好的运行速度,虚拟机(甚至是硬件系统本身的优化措施)可能会让工作内存

优先存储于寄存器和高速缓存中，因为程序运行时主要访问读写的是工作内存。




图 12-2 线程、主内存、工作内存三者的交互关系（请与图12-1对比）

[1] 本书中的Java内存模型都特指目前正在使用的，即在JDK 1.2之后建立起来并在JDK 1.5中完备过的内存模型。

[2] JSR-133: Java Memory Model and Thread Specification Revision (Java内存模型和线程规范修订)。

[3]此处请读者注意区分概念：如果局部变量是一个reference类型，它引用的对象在Java堆中可被各个线程共享，但是reference本身在Java栈的局部变量表中，它是线程私有的。

[4]有不少读者会对这段描述中的“拷贝副本”提出疑问，如“假设线程中访问一个10MB的对象，也会把这10MB的内存复制一份拷贝出来吗？”，事实上并不会如此，这个对象的引用、对象中某个在线程访问到的字段是有可能存在拷贝的，但不会有虚拟机实现成把整个对象拷贝A一次。

[5]根据Java虚拟机规范的规定，volatile变量依然有工作内存的拷贝，但是由于它特殊的操作顺序性规定（后文会讲到），所以看起来如同直接在主内存中读写访问一般，因此这里的描述对于volatile也并不存在例外。

[6]除了实例数据，Java堆还保存了对象的其他信息，对于HotSpot虚拟机来讲，有Mark Word（存储对象哈希码、GC标志、GC年龄、同步锁等信息）、Klass Point（指向存储类型元数据的指针）及一些用于字节对齐补白的填充数据（如果实例数据刚好满足8字节对齐的话，则可以不存在补白）。

12.3.2 内存间交互操作

关于主内存与工作内存之间具体的交互协议，即一个变量如何从主内存拷贝到工作内存、如何从工作内存同步回主内存之类的实现细节，Java内存模型中定义了以下8种操作来完成，虚拟机实现时必须保证下面提及的每一种操作都是原子的、不可再分的（对于double和long类型的变量来说，load、store、read和write操作在某些平台上允许有例外，这个问题在12.3.4节再讲）[\[1\]](#)。

lock（锁定）：作用于主内存的变量，它把一个变量标识为一条线程独占的状态。

unlock（解锁）：作用于主内存的变量，它

把一个处于锁定状态的变量释放出来，释放后的变量才可以被其他线程锁定。

read（读取）：作用于主内存的变量，它把一个变量的值从主内存传输到线程的工作内存中，以便随后的**load**动作使用。

load（载入）：作用于工作内存的变量，它把**read**操作从主内存中得到的变量值放入工作内存的变量副本中。

use（使用）：作用于工作内存的变量，它把工作内存中一个变量的值传递给执行引擎，每当虚拟机遇到一个需要使用到变量的值的字节码指令时将会执行这个操作。

assign（赋值）：作用于工作内存的变量，

它把一个从执行引擎接收到的值赋给工作内存的变量，每当虚拟机遇到一个给变量赋值的字节码指令时执行这个操作。

store（存储）：作用于工作内存的变量，它把工作内存中一个变量的值传送到主内存中，以便随后的**write**操作使用。

write（写入）：作用于主内存的变量，它把**store**操作从工作内存中得到的变量的值放入主内存的变量中。

如果要把一个变量从主内存复制到工作内存，那就要顺序地执行**read**和**load**操作，如果要把变量从工作内存同步回主内存，就要顺序地执行**store**和**write**操作。注意，Java内存模型只要求上述两个操作必须按顺序执行，而没有保证是连

续执行。也就是说，read与load之间、store与write之间是可插入其他指令的，如对主内存中的变量a、b进行访问时，一种可能出现顺序是read a、read b、load b、load a。除此之外，Java内存模型还规定了在执行上述8种基本操作时必须满足如下规则：

不允许read和load、store和write操作之一单独出现，即不允许一个变量从主内存读取了但工作内存不接受，或者从工作内存发起回写了但主内存不接受的情况出现。

不允许一个线程丢弃它的最近的assign操作，即变量在工作内存中改变了之后必须把该变化同步回主内存。

不允许一个线程无原因地（没有发生过任何

assign操作) 把数据从线程的工作内存同步回主内存中。

一个新的变量只能在主内存中“诞生”，不允许在工作内存中直接使用一个未被初始化(load或assign)的变量，换句话说，就是对一个变量实施use、store操作之前，必须先执行过了assign和load操作。

一个变量在同一个时刻只允许一条线程对其进行lock操作，但lock操作可以被同一条线程重复执行多次，多次执行lock后，只有执行相同次数的unlock操作，变量才会被解锁。

如果对一个变量执行lock操作，那将会清空工作内存中此变量的值，在执行引擎使用这个变量前，需要重新执行load或assign操作初始化变量

的值。

如果一个变量事先没有被lock操作锁定，那就不允许对它执行unlock操作，也不允许去unlock一个被其他线程锁定住的变量。

对一个变量执行unlock操作之前，必须先把此变量同步回主内存中（执行store、write操作）。

这8种内存访问操作以及上述规则限定，再加上稍后介绍的对volatile的一些特殊规定，就已经完全确定了Java程序中哪些内存访问操作在并发下是安全的。由于这种定义相当严谨但又十分烦琐，实践起来很麻烦，所以在12.3.6节中笔者将介绍这种定义的一个等效判断原则——先行发生原则，用来确定一个访问在并发环境下是否安

全。

[1] 基于理解难度和严谨性考虑，最新的JSR-133文档中，已经放弃采用这8种操作去定义Java内存模型的访问协议了（仅是描述方式改变了，Java内存模型并没有改变）。

12.3.3 对于volatile型变量的特殊规则

关键字volatile可以说是Java虚拟机提供的最轻量级的同步机制，但是它并不容易完全被正确、完整地理解，以至于许多程序员都习惯不去使用它，遇到需要处理多线程数据竞争问题的时候一律使用synchronized来进行同步。了解volatile变量的语义对后面了解多线程操作的其他特性很有意义，在本节中我们将多花费一些时间去弄清楚volatile的语义到底是什么。

Java内存模型对volatile专门定义了一些特殊的访问规则，在介绍这些比较拗口的规则定义之前，笔者先用不那么正式但通俗易懂的语言来介绍一下这个关键字的作用。

当一个变量定义为volatile之后，它将具备两种特性，第一是保证此变量对所有线程的可见性，这里的“可见性”是指当一条线程修改了这个变量的值，新值对于其他线程来说是可以立即得知的。而普通变量不能做到这一点，普通变量的值在线程间传递均需要通过主内存来完成，例如，线程A修改一个普通变量的值，然后向主内存进行回写，另外一条线程B在线程A回写完成了之后再从主内存进行读取操作，新变量值才会对线程B可见。

关于volatile变量的可见性，经常会被开发人员误解，认为以下描述成立：“volatile变量对所有线程是立即可见的，对volatile变量所有的写操作都能立刻反应到其他线程之中，换句话说，volatile变量在各个线程中是一致的，所以基于

volatile变量的运算在并发下是安全的”。这句话的论据部分并没有错，但是其论据并不能得出“基于volatile变量的运算在并发下是安全的”这个结论。volatile变量在各个线程的工作内存中不存在一致性问题（在各个线程的工作内存中，volatile变量也可以存在不一致的情况，但由于每次使用之前都要先刷新，执行引擎看不到不一致的情况，因此可以认为不存在一致性问题），但是Java里面的运算并非原子操作，导致volatile变量的运算在并发下一样是不安全的，我们可以通过一段简单的演示来说明原因，请看代码清单12-1中演示的例子。

代码清单12-1 volatile的运算

```
/**  
 *volatile变量自增运算测试
```

```
*  
*@author zzm  
*/  
public class VolatileTest{  
    public static volatile int race=0;  
    public static void increase () {  
        race++;  
    }  
    private static final int THREADS_COUNT=20;  
    public static void main (String[]args) {  
        Thread[]threads=new Thread[THREADS_COUNT];  
        for (int i=0; i<THREADS_COUNT; i++) {  
            threads[i]=new Thread (new Runnable () {  
                @Override  
                public void run () {  
                    for (int i=0; i<10000; i++) {  
                        increase () ;  
                    }  
                }  
            } );  
            threads[i].start () ;  
        }  
        //等待所有累加线程都结束  
        while (Thread.activeCount () >1)  
            Thread.yield () ;  
        System.out.println (race) ;  
    }  
}
```

这段代码发起了20个线程，每个线程对race变量进行10000次自增操作，如果这段代码能够

正确并发的话，最后输出的结果应该是200000。读者运行完这段代码之后，并不会获得期望的结果，而且会发现每次运行程序，输出的结果都不一样，都是一个小于200000的数字，这是为什么呢？

问题就出现在自增运算“race++”之中，我们用Javap反编译这段代码后会得到代码清单12-2，发现只有一行代码的increase（）方法在Class文件中是由4条字节码指令构成的（return指令不是由race++产生的，这条指令可以不计算），从字节码层面上很容易就分析出并发失败的原因了：当getstatic指令把race的值取到操作栈顶时，volatile关键字保证了race的值在此时是正确的，但是在执行iconst_1、iadd这些指令的时候，其他线程可能已经把race的值加大了，而在操作栈顶

的值就变成了过期的数据，所以putstatic指令执行后就可能把较小的race值同步回主内存之中。

代码清单12-2 VolatileTest的字节码

```
public static void increase () ;  
Code:  
Stack=2, Locals=0, Args_size=0  
0: getstatic#13; //Field race: I  
3: iconst_1  
4: iadd  
5: putstatic#13; //Field race: I  
8: return  
LineNumberTable:  
line 14: 0  
line 15: 8
```

客观地说，笔者在此使用字节码来分析并发问题，仍然是不严谨的，因为即使编译出来只有一条字节码指令，也并不意味执行这条指令就是一个原子操作。一条字节码指令在解释执行时，解释器将要运行许多行代码才能实现它的语义，

如果是编译执行，一条字节码指令也可能转化成若干条本地机器码指令，此处使用-XX:

+PrintAssembly参数输出反汇编来分析会更加严谨一些，但考虑到读者阅读的方便，并且字节码已经能说明问题，所以此处使用字节码来分析。

由于volatile变量只能保证可见性，在不符合以下两条规则的运算场景中，我们仍然要通过加锁（使用synchronized或java.util.concurrent中的原子类）来保证原子性。

运算结果并不依赖变量的当前值，或者能够确保只有单一的线程修改变量的值。

变量不需要与其他的状态变量共同参与不变约束。

而在像如下的代码清单12-3所示的这类场景就很适合使用volatile变量来控制并发，当shutdown（）方法被调用时，能保证所有线程中执行的doWork（）方法都立即停下来。

代码清单12-3 volatile的使用场景

```
volatile boolean shutdownRequested;
public void shutdown () {
    shutdownRequested=true;
}
public void doWork () {
    while (! shutdownRequested) {
        //do stuff
    }
}
```

使用volatile变量的第二个语义是禁止指令重排序优化，普通的变量仅仅会保证在该方法的执行过程中所有依赖赋值结果的地方都能获取到正确的结果，而不能保证变量赋值操作的顺序与程

序代码中的执行顺序一致。因为在一个线程的方法执行过程中无法感知到这点，这也就是Java内存模型中描述的所谓的“线程内表现为串行的语言”（Within-Thread As-If-Serial Semantics）。

上面的描述仍然不太容易理解，我们还是继续通过一个例子来看看为何指令重排序会干扰程序的并发执行，演示程序如代码清单12-4所示。

代码清单12-4 指令重排序

```
Map configOptions;
char[] configText;
//此变量必须定义为volatile
volatile boolean initialized=false;
//假设以下代码在线程A中执行
//模拟读取配置信息，当读取完成后将initialized设置
为true以通知其他线程配置可用
configOptions=new HashMap();
configText=readConfigFile(fileName);
processConfigOptions(configText,configOption
initialized=true;
//假设以下代码在线程B中执行
```

```
//等待initialized为true，代表线程A已经把配置信息  
初始化完成  
while (! initialized) {  
    sleep();  
}  
//使用线程A中初始化好的配置信息  
doSomethingWithConfig();
```

代码清单12-4中的程序是一段伪代码，其中描述的场景十分常见，只是我们在处理配置文件时一般不会出现并发而已。如果定义initialized变量时没有使用volatile修饰，就可能会由于指令重排序的优化，导致位于线程A中最后一句的代码“initialized=true”被提前执行（这里虽然使用Java作为伪代码，但所指的重排序优化是机器级的优化操作，提前执行是指这句话对应的汇编代码被提前执行），这样在线程B中使用配置信息的代码就可能出现错误，而volatile关键字则可以避免此类情况的发生^[1]。

指令重排序是并发编程中最容易让开发人员产生疑惑的地方，除了上面伪代码的例子之外，笔者再举一个可以实际操作运行的例子来分析volatile关键字是如何禁止指令重排序优化的。代码清单12-5是一段标准的DCL单例代码，可以观察加入volatile和未加入volatile关键字时所生成汇编代码的差别（如何获得JIT的汇编代码，请参考4.2.7节）。

代码清单12-5 DCL单例模式

```
public class Singleton{  
    private volatile static Singleton instance;  
    public static Singleton getInstance () {  
        if (instance==null) {  
            synchronized (Singleton.class) {  
                if (instance==null) {  
                    instance=new Singleton () ;  
                }  
            }  
        }  
        return instance;  
    }  
}
```

```
}

public static void main (String[]args) {
    Singleton.getInstance () ;
}
```

编译后，这段代码对instance变量赋值部分如代码清单12-6所示。

代码清单12-6

```
0x01a3de0f: mov$0x3375cdb0, %esi; .....beb0cd75
33
    ; {oop ('Singleton') }
0x01a3de14: mov%eax, 0x150 (%esi) ; .....
89865001 0000
0x01a3de1a: shr$0x9, %esi; .....c1ee09
0x01a3de1d: movb$0x0, 0x1104800 (%esi) ; .....
c6860048 100100
0x01a3de24: lock addl$0x0, (%esp) ; .....
f0830424 00
    ; *putstatic instance
    ; -
Singleton: getInstance@24
```

通过对比就会发现，关键变化在于有volatile

修饰的变量，赋值后（前面mov%eax, 0x150 (%esi) 这句便是赋值操作）多执行了一个“lock addl \$ 0x0, (%esp)”操作，这个操作相当于一个内存屏障（Memory Barrier或Memory Fence，指重排序时不能把后面的指令重排序到内存屏障之前的位置），只有一个CPU访问内存时，并不需要内存屏障；但如果两个或更多CPU访问同一块内存，且其中有一个在观测另一个，就需要内存屏障来保证一致性了。这句指令中的“addl \$ 0x0, (%esp)”（把ESP寄存器的值加0）显然是一个空操作（采用这个空操作而不是空操作指令nop是因为IA32手册规定lock前缀不允许配合nop指令使用），关键在于lock前缀，查询IA32手册，它的作用是使得本CPU的Cache写入了内存，该写入动作也会引起别的CPU或者别的

内核无效化（Invalidate）其Cache，这种操作相当于对Cache中的变量做了一次前面介绍Java内存模式中所说的“store和write”操作^[2]。所以通过这样一个空操作，可让前面volatile变量的修改对其他CPU立即可见。

那为何说它禁止指令重排序呢？从硬件架构上讲，指令重排序是指CPU采用了允许将多条指令不按程序规定的顺序分开发送给各相应电路单元处理。但并不是说指令任意重排，CPU需要能正确处理指令依赖情况以保障程序能得出正确的执行结果。譬如指令1把地址A中的值加10，指令2把地址A中的值乘以2，指令3把地址B中的值减去3，这时指令1和指令2是有依赖的，它们之间的顺序不能重排—— $(A+10) * 2$ 与 $A*2+10$ 显然不相等，但指令3可以重排到指令1、2之前或者

中间，只要保证CPU执行后面依赖到A、B值的操作时能获取到正确的A和B值即可。所以在本内CPU中，重排序看起来依然是有序的。因此，
lock addl \$ 0x0, (%esp) 指令把修改同步到内存时，意味着所有之前的操作都已经执行完成，这样便形成了“指令重排序无法越过内存屏障”的效果。

解决了volatile的语义问题，再来看看在众多保障并发安全的工具中选用volatile的意义——它能让我们的代码比使用其他的同步工具更快吗？在某些情况下，volatile的同步机制的性能确实要优于锁（使用synchronized关键字或java.util.concurrent包里面的锁），但是由于虚拟机对锁实行的许多消除和优化，使得我们很难量化地认为volatile就会比synchronized快多少。如果

让volatile自己与自己比较，那可以确定一个原则：volatile变量读操作的性能消耗与普通变量几乎没有什么差别，但是写操作则可能会慢一些，因为它需要在本地代码中插入许多内存屏障指令来保证处理器不发生乱序执行。不过即便如此，大多数场景下volatile的总开销仍然要比锁低，我们在volatile与锁之中选择的唯一依据仅仅是volatile的语义能否满足使用场景的需求。

在本节的最后，我们回头看一下Java内存模型中对volatile变量定义的特殊规则。假定T表示一个线程，V和W分别表示两个volatile型变量，那么在进行read、load、use、assign、store和write操作时需要满足如下规则：

只有当线程T对变量V执行的前一个动作是

load的时候，线程T才能对变量V执行use动作；并且，只有当线程T对变量V执行的后一个动作是use的时候，线程T才能对变量V执行load动作。线程T对变量V的use动作可以认为是和线程T对变量V的load、read动作相关联，必须连续一起出现（这条规则要求在工作内存中，每次使用V前都必须先从主内存刷新最新的值，用于保证能看见其他线程对变量V所做的修改后的值）。

只有当线程T对变量V执行的前一个动作是assign的时候，线程T才能对变量V执行store动作；并且，只有当线程T对变量V执行的后一个动作是store的时候，线程T才能对变量V执行assign动作。线程T对变量V的assign动作可以认为是和线程T对变量V的store、write动作相关联，必须连续一起出现（这条规则要求在工作内存中，每次

修改V后都必须立刻同步回主内存中，用于保证其他线程可以看到自己对变量V所做的修改）。

假定动作A是线程T对变量V实施的use或assign动作，假定动作F是和动作A相关联的load或store动作，假定动作P是和动作F相应的对变量V的read或write动作；类似的，假定动作B是线程T对变量W实施的use或assign动作，假定动作G是和动作B相关联的load或store动作，假定动作Q是和动作G相应的对变量W的read或write动作。如果A先于B，那么P先于Q（这条规则要求volatile修饰的变量不会被指令重排序优化，保证代码的执行顺序与程序的顺序相同）。

[1]volatile屏蔽指令重排序的语义在JDK 1.5中才被完全修复，此前的JDK中即使将变量声明为

volatile也仍然不能完全避免重排序所导致的问题（主要是volatile变量前后的代码仍然存在重排序问题），这点也是在JDK 1.5之前的Java中无法安全地使用DCL（双锁检测）来实现单例模式的原因。

[2]Doug Lea列出了各种处理器架构下的内存屏障指令：

<http://g.oswego.edu/dl/jmm/cookbook.html>。

12.3.4 对于long和double型变量的特殊规则

Java内存模型要求lock、unlock、read、load、assign、use、store、write这8个操作都具有原子性，但是对于64位的数据类型（long和double），在模型中特别定义了一条相对宽松的规定：允许虚拟机将没有被volatile修饰的64位数据的读写操作划分为两次32位的操作来进行，即允许虚拟机实现选择可以不保证64位数据类型的load、store、read和write这4个操作的原子性，这点就是所谓的long和double的非原子性协定（Nonatomic Treatment of double and long Variables）。

如果有多个线程共享一个并未声明为volatile的long或double类型的变量，并且同时对它们进行读取和修改操作，那么某些线程可能会读取到一个既非原值，也不是其他线程修改值的代表了“半个变量”的数值。

不过这种读取到“半个变量”的情况非常罕见（在目前商用Java虚拟机中不会出现），因为Java内存模型虽然允许虚拟机不把long和double变量的读写实现成原子操作，但允许虚拟机选择把这些操作实现为具有原子性的操作，而且还“强烈建议”虚拟机这样实现。在实际开发中，目前各种平台下的商用虚拟机几乎都选择把64位数据的读写操作作为原子操作来对待，因此我们在编写代码时一般不需要把用到的long和double变量专门声明为volatile。

12.3.5 原子性、可见性与有序性

介绍完Java内存模型的相关操作和规则，我们再整体回顾一下这个模型的特征。Java内存模型是围绕着在并发过程中如何处理原子性、可见性和有序性这3个特征来建立的，我们逐个来看一下哪些操作实现了这3个特性。

原子性（Atomicity）：由Java内存模型来直接保证的原子性变量操作包括read、load、assign、use、store和write，我们大致可以认为基本数据类型的访问读写是具备原子性的（例外就是long和double的非原子性协定，读者只要知道这件事情就可以了，无须太过在意这些几乎不会发生的例外情况）。

如果应用场景需要一个更大范围的原子性保证（经常会遇到），Java内存模型还提供了lock和unlock操作来满足这种需求，尽管虚拟机未把lock和unlock操作直接开放给用户使用，但是却提供了更高层次的字节码指令monitorenter和monitorexit来隐式地使用这两个操作，这两个字节码指令反映到Java代码中就是同步块——synchronized关键字，因此在synchronized块之间的操作也具备原子性。

可见性（Visibility）：可见性是指当一个线程修改了共享变量的值，其他线程能够立即得知这个修改。上文在讲解volatile变量的时候我们已详细讨论过这一点。Java内存模型是通过在变量修改后将新值同步回主内存，在变量读取前从主内存刷新变量值这种依赖主内存作为传递媒介的

方式来实现可见性的，无论是普通变量还是 volatile 变量都是如此，普通变量与 volatile 变量的区别是，volatile 的特殊规则保证了新值能立即同步到主内存，以及每次使用前立即从主内存刷新。因此，可以说 volatile 保证了多线程操作时变量的可见性，而普通变量则不能保证这一点。

除了 volatile 之外，Java 还有两个关键字能实现可见性，即 synchronized 和 final。同步块的可见性是由“对一个变量执行 unlock 操作之前，必须先把此变量同步回主内存中（执行 store、write 操作）”这条规则获得的，而 final 关键字的可见性是指：被 final 修饰的字段在构造器中一旦初始化完成，并且构造器没有把“this”的引用传递出去（this 引用逃逸是一件很危险的事情，其他线程有可能通过这个引用访问到“初始化了一半”的对

象），那在其他线程中就能看见final字段的值。如代码清单12-7所示，变量i与j都具备可见性，它们无须同步就能被其他线程正确访问。

代码清单12-7 final与可见性

```
public static final int i;
public final int j;
static{
    i=0;
    //do something
}
{
    //也可以选择在构造函数中初始化
    j=0;
    //do something
}
```

有序性（Ordering）：Java内存模型的有序性在前面讲解volatile时也详细地讨论过了，Java程序中天然的有序性可以总结为一句话：如果在本线程内观察，所有的操作都是有序的；如果在一

个线程中观察另一个线程，所有的操作都是无序的。前半句是指“线程内表现为串行的语义”（Within-Thread As-If-Serial Semantics），后半句是指“指令重排序”现象和“工作内存与主内存同步延迟”现象。

Java语言提供了volatile和synchronized两个关键字来保证线程之间操作的有序性，volatile关键字本身就包含了禁止指令重排序的语义，而synchronized则是由“一个变量在同一个时刻只允许一条线程对其进行lock操作”这条规则获得的，这条规则决定了持有同一个锁的两个同步块只能串行地进入。

介绍完并发中3种重要的特性后，读者有没有发现synchronized关键字在需要这3种特性的时

候都可以作为其中一种的解决方案？看起来很“万能”吧。的确，大部分的并发控制操作都能使用synchronized来完成。synchronized的“万能”也间接造就了它被程序员滥用的局面，越“万能”的并发控制，通常会伴随着越大的性能影响，这点我们将在第13章讲解虚拟机锁优化时再介绍。

12.3.6 先行发生原则

如果Java内存模型中所有的有序性都仅仅靠volatile和synchronized来完成，那么有一些操作将会变得很烦琐，但是我们在编写Java并发代码的时候并没有感觉到这一点，这是因为Java语言中有一个“先行发生”（happens-before）的原则。这个原则非常重要，它是判断数据是否存在竞争、线程是否安全的主要依据，依靠这个原则，我们可以通过几条规则一揽子地解决并发环境下两个操作之间是否可能存在冲突的所有问题。

现在就来看看“先行发生”原则指的是什么。先行发生是Java内存模型中定义的两项操作之间的偏序关系，如果说操作A先行发生于操作B，其

也就是说在发生操作B之前，操作A产生的影响能被操作B观察到，“影响”包括修改了内存中共享变量的值、发送了消息、调用了方法等。这句话不难理解，但它意味着什么呢？我们可以举个例子来说明一下，如代码清单12-8中所示的这3句伪代码。

代码清单12-8 先行发生原则示例1

```
//以下操作在线程A中执行  
i=1;  
//以下操作在线程B中执行  
j=i;  
//以下操作在线程C中执行  
i=2;
```

假设线程A中的操作“`i=1`”先行发生于线程B的操作“`j=i`”，那么可以确定在线程B的操作执行后，变量j的值一定等于1，得出这个结论的依据

有两个：一是根据先行发生原则，“ $i=1$ ”的结果可以被观察到；二是线程C还没“登场”，线程A操作结束之后没有其他线程会修改变量*i*的值。现在再来考虑线程C，我们依然保持线程A和线程B之间的先行发生关系，而线程C出现在线程A和线程B的操作之间，但是线程C与线程B没有先行发生关系，那*j*的值会是多少呢？答案是不确定！1和2都有可能，因为线程C对变量*i*的影响可能会被线程B观察到，也可能不会，这时候线程B就存在读取到过期数据的风险，不具备多线程安全性。

下面是Java内存模型下一些“天然的”先行发生关系，这些先行发生关系无须任何同步器协助就已经存在，可以在编码中直接使用。如果两个操作之间的关系不在此列，并且无法从下列规则推导出来的话，它们就没有顺序性保障，虚拟机

可以对它们随意地进行重排序。

程序次序规则（Program Order Rule）：在一个线程内，按照程序代码顺序，书写在前面的操作先行发生于书写在后面的操作。准确地说，应该是控制流顺序而不是程序代码顺序，因为要考虑分支、循环等结构。

管程锁定规则（Monitor Lock Rule）：一个unlock操作先行发生于后面对同一个锁的lock操作。这里必须强调的是同一个锁，而“后面”是指时间上的先后顺序。

volatile变量规则（Volatile Variable Rule）：对一个volatile变量的写操作先行发生于后面对这个变量的读操作，这里的“后面”同样是指时间上的先后顺序。

线程启动规则（Thread Start Rule）： Thread 对象的start（）方法先行发生于此线程的每一个动作。

线程终止规则（Thread Termination Rule）： 线程中的所有操作都先行发生于对此线程的终止检测， 我们可以通过Thread.join（）方法结束、 Thread.isAlive（）的返回值等手段检测到线程已经终止执行。

线程中断规则（Thread Interruption Rule）： 对线程interrupt（）方法的调用先行发生于被中断线程的代码检测到中断事件的发生， 可以通过 Thread.interrupted（）方法检测到是否有中断发生。

对象终结规则（Finalizer Rule）：一个对象的初始化完成（构造函数执行结束）先行发生于它的finalize（）方法的开始。

传递性（Transitivity）：如果操作A先行发生于操作B，操作B先行发生于操作C，那就可以得出操作A先行发生于操作C的结论。

Java语言无须任何同步手段保障就能成立的先行发生规则就只有上面这些了，笔者演示一下如何使用这些规则去判定操作间是否具备顺序性，对于读写共享变量的操作来说，就是线程是否安全，读者还可以从下面这个例子中感受一下“时间上的先后顺序”与“先行发生”之间有什么不同。演示例子如代码清单12-9所示。

代码清单12-9 先行发生原则示例2

```
private int value=0;  
pubilc void setValue (int value) {  
    this.value=value;  
}  
public int getValue () {  
    return value;  
}
```

代码清单12-9中显示的是一组再普通不过的getter/setter方法，假设存在线程A和B，线程A先（时间上的先后）调用了“`setValue (1)`”，然后线程B调用了同一个对象的“`getValue ()`”，那么线程B收到的返回值是什么？

我们依次分析一下先行发生原则中的各项规则，由于两个方法分别由线程A和线程B调用，不在一个线程中，所以程序次序规则在这里不适用；由于没有同步块，自然就不会发生lock和unlock操作，所以管程锁定规则不适用；由于

value变量没有被volatile关键字修饰，所以volatile变量规则不适用；后面的线程启动、终止、中断规则和对象终结规则也和这里完全没有关系。因为没有一个适用的先行发生规则，所以最后一条传递性也无从谈起，因此我们可以判定尽管线程A在操作时间上先于线程B，但是无法确定线程B中“`getValue ()`”方法的返回结果，换句话说，这里面的操作不是线程安全的。

那怎么修复这个问题呢？我们至少有两种比较简单的方案可以选择：要么把getter/setter方法都定义为synchronized方法，这样就可以套用管程锁定规则；要么把value定义为volatile变量，由于setter方法对value的修改不依赖value的原值，满足volatile关键字使用场景，这样就可以套用volatile变量规则来实现先行发生关系。

通过上面的例子，我们可以得出结论：一个操作“时间上的先发生”不代表这个操作会是“先行发生”，那如果一个操作“先行发生”是否就能推导出这个操作必定是“时间上的先发生”呢？很遗憾，这个推论也是不成立的，一个典型的例子就是多次提到的“指令重排序”，演示例子如代码清单12-10所示。

代码清单12-10 先行发生原则示例3

```
//以下操作在同一个线程中执行
int i=1;
int j=2;
```

代码清单12-10的两条赋值语句在同一个线程之中，根据程序次序规则，“int i=1”的操作先行发生于“int j=2”，但是“int j=2”的代码完全可能先

被处理器执行，这并不影响先行发生原则的正确性，因为我们在这条线程之中没有办法感知到这点。

上面两个例子综合起来证明了一个结论：时间先后顺序与先行发生原则之间基本没有太大的关系，所以我们衡量并发安全问题的时候不要受到时间顺序的干扰，一切必须以先行发生原则为准。

12.4 Java与线程

并发不一定要依赖多线程（如PHP中很常见的多进程并发），但是在Java里面谈论并发，大多数都与线程脱不开关系。既然我们这本书探讨的话题是Java虚拟机的特性，那讲到Java线程，我们就从Java线程在虚拟机中的实现开始讲起。

12.4.1 线程的实现

我们知道，线程是比进程更轻量级的调度执行单位，线程的引入，可以把一个进程的资源分配和执行调度分开，各个线程既可以共享进程资源（内存地址、文件I/O等），又可以独立调度（线程是CPU调度的基本单位）。

主流的操作系统都提供了线程实现，Java语言则提供了在不同硬件和操作系统平台下对线程操作的统一处理，每个已经执行start（）且还未结束的java.lang.Thread类的实例就代表了一个线程。我们注意到Thread类与大部分的Java API有显著的差别，它的所有关键方法都是声明为Native的。在Java API中，一个Native方法往往意味着这个方法没有使用或无法使用平台无关的手段来实现（当然也可能是为了执行效率而使用Native方法，不过，通常最高效率的手段也就是平台相关的手段）。正因为如此，作者把本节的标题定为“线程的实现”而不是“Java线程的实现”。

实现线程主要有3种方式：使用内核线程实现、使用用户线程实现和使用用户线程加轻量级

进程混合实现。

1. 使用内核线程实现

内核线程（Kernel-Level Thread,KLT）就是直接由操作系统内核（Kernel，下称内核）支持的线程，这种线程由内核来完成线程切换，内核通过操纵调度器（Scheduler）对线程进行调度，并负责将线程的任务映射到各个处理器上。每个内核线程可以视为内核的一个分身，这样操作系统就有能力同时处理多件事情，支持多线程的内核就叫做多线程内核（Multi-Threads Kernel）。

程序一般不会直接去使用内核线程，而是去使用内核线程的一种高级接口——轻量级进程（Light Weight Process,LWP），轻量级进程就是我们通常意义上所讲的线程，由于每个轻量级进

程都由一个内核线程支持，因此只有先支持内核线程，才能有轻量级进程。这种轻量级进程与内核线程之间1:1的关系称为一对一的线程模型，如图12-3所示。




图 12-3 轻量级进程与内核线程之间1:1的关系

由于内核线程的支持，每个轻量级进程都成为一个独立的调度单元，即使有一个轻量级进程

在系统调用中阻塞了，也不会影响整个进程继续工作，但是轻量级进程具有它的局限性：首先，由于是基于内核线程实现的，所以各种线程操作，如创建、析构及同步，都需要进行系统调用。而系统调用的代价相对较高，需要在用户态（User Mode）和内核态（Kernel Mode）中来回切换。其次，每个轻量级进程都需要有一个内核线程的支持，因此轻量级进程要消耗一定的内核资源（如内核线程的栈空间），因此一个系统支持轻量级进程的数量是有限的。

2. 使用用户线程实现

从广义上来讲，一个线程只要不是内核线程，就可以认为是用户线程（User Thread, UT），因此，从这个定义上来讲，轻量级

进程也属于用户线程，但轻量级进程的实现始终是建立在内核之上的，许多操作都要进行系统调用，效率会受到限制。

而狭义上的用户线程指的是完全建立在用户空间的线程库上，系统内核不能感知线程存在的实现。用户线程的建立、同步、销毁和调度完全在用户态中完成，不需要内核的帮助。如果程序实现得当，这种线程不需要切换到内核态，因此操作可以是非常快速且低消耗的，也可以支持规模更大的线程数量，部分高性能数据库中的多线程就是由用户线程实现的。这种进程与用户线程之间1：N的关系称为一对多的线程模型，如图12-4所示。




图 12-4 进程与用户线程之间1: N的关系

使用用户线程的优势在于不需要系统内核支援，劣势也在于没有系统内核的支援，所有的线程操作都需要用户程序自己处理。线程的创建、切换和调度都是需要考虑的问题，而且由于操作系统只把处理器资源分配到进程，那诸如“阻塞如何处理”、“多处理器系统中如何将线程映射到

其他处理器上”这类问题解决起来将会异常困难，甚至不可能完成。因而使用用户线程实现的程序一般都比较复杂^[1]，除了以前在不支持多线程的操作系统中（如DOS）的多线程程序与少数有特殊需求的程序外，现在使用用户线程的程序越来越少了，Java、Ruby等语言都曾经使用过用户线程，最终又都放弃使用它。

3. 使用用户线程加轻量级进程混合实现

线程除了依赖内核线程实现和完全由用户程序自己实现之外，还有一种将内核线程与用户线程一起使用的实现方式。在这种混合实现下，既存在用户线程，也存在轻量级进程。用户线程还是完全建立在用户空间中，因此用户线程的创建、切换、析构等操作依然廉价，并且可以支持

大规模的用户线程并发。而操作系统提供支持的轻量级进程则作为用户线程和内核线程之间的桥梁，这样可以使用内核提供的线程调度功能及处理器映射，并且用户线程的系统调用要通过轻量级线程来完成，大大降低了整个进程被完全阻塞的风险。在这种混合模式中，用户线程与轻量级进程的数量比是不定的，即为N: M的关系，如图12-5所示，这种就是多对多的线程模型。

许多UNIX系列的操作系统，如Solaris、HP-UX等都提供了N: M的线程模型实现。




图 12-5 用户线程与轻量级进程之间N: M的关系

4. Java线程的实现

Java线程在JDK 1.2之前，是基于称为“绿色线程”（Green Threads）的用户线程实现的，而在JDK 1.2中，线程模型替换为基于操作系统原生线程模型来实现。因此，在目前的JDK版本中，操

作系统支持怎样的线程模型，在很大程度上决定了Java虚拟机的线程是怎样映射的，这点在不同的平台上没有办法达成一致，虚拟机规范中也并未限定Java线程需要使用哪种线程模型来实现。线程模型只对线程的并发规模和操作成本产生影响，对Java程序的编码和运行过程来说，这些差异都是透明的。

对于Sun JDK来说，它的Windows版与Linux版都是使用一对一的线程模型实现的，一条Java线程就映射到一条轻量级进程之中，因为Windows和Linux系统提供的线程模型就是一对一的^[2]。

而在Solaris平台中，由于操作系统的线程特性可以同时支持一对一（通过Bound Threads或

Alternate Libthread实现) 及多对多(通过LWP/Thread Based Synchronization实现)的线程模型, 因此在Solaris版的JDK中也对应提供了两个平台专有的虚拟机参数: -XX:
+UseLWPSynchronization(默认值) 和-XX:
+UseBoundThreads来明确指定虚拟机使用哪种线程模型。

[1]此处所讲的“复杂”与“程序自己完成线程操作”, 并不限制程序中必须编写了复杂的实现用户线程的代码, 使用用户线程的程序, 很多都依赖特定的线程库来完成基本的线程操作, 这些复杂性都封装在线程库之中。

[2]Windows下有纤程包(Fiber Package), Linux下也有NGPT(在2.4内核的年代)来实现N: M模型, 但是它们都没有成为主流。

12.4.2 Java线程调度

线程调度是指系统为线程分配处理器使用权的过程，主要调度方式有两种，分别是协同式线程调度（Cooperative Threads-Scheduling）和抢占式线程调度（Preemptive Threads-Scheduling）。

如果使用协同式调度的多线程系统，线程的执行时间由线程本身来控制，线程把自己的工作执行完了之后，要主动通知系统切换到另外一个线程上。协同式多线程的最大好处是实现简单，而且由于线程要把自己的事情干完后才会进行线程切换，切换操作对线程自己是可知的，所以没有什么线程同步的问题。Lua语言中的“协同例程”就是这类实现。它的坏处也很明显：线程执

行时间不可控制，甚至如果一个线程编写有问题，一直不告知系统进行线程切换，那么程序就会一直阻塞在那里。很久以前的Windows 3.x系统就是使用协同式来实现多进程多任务的，相当不稳定，一个进程坚持不让出CPU执行时间就可能会导致整个系统崩溃。

如果使用抢占式调度的多线程系统，那么每个线程将由系统来分配执行时间，线程的切换不由线程本身来决定（在Java中，`Thread.yield()`可以让出执行时间，但是要获取执行时间的话，线程本身是没有什么办法的）。在这种实现线程调度的方式下，线程的执行时间是系统可控的，也不会有一个线程导致整个进程阻塞的问题，Java使用的线程调度方式就是抢占式调度^[1]。与前面所说的Windows 3.x的例子相对，在Windows

9x/NT内核中就是使用抢占式来实现多进程的，当一个进程出了问题，我们还可以使用任务管理器把这个进程“杀掉”，而不至于导致系统崩溃。

虽然Java线程调度是系统自动完成的，但是我们还是可以“建议”系统给某些线程多分配一点执行时间，另外的一些线程则可以少分配一点——这项操作可以通过设置线程优先级来完成。Java语言一共设置了10个级别的线程优先级（`Thread.MIN_PRIORITY`至`Thread.MAX_PRIORITY`），在两个线程同时处于Ready状态时，优先级越高的线程越容易被系统选择执行。

不过，线程优先级并不是太靠谱，原因是Java的线程是通过映射到系统的原生线程上来实

现的，所以线程调度最终还是取决于操作系统，虽然现在很多操作系统都提供线程优先级的概念，但是并不见得能与Java线程的优先级一一对应，如Solaris中有 2^{32} 种优先级，但Windows中就只有7种，比Java线程优先级多的系统还好说，中间留下一点空位就可以了，但比Java线程优先级少的系统，就不得不出现几个优先级相同的情况了，表12-1显示了Java线程优先级与Windows线程优先级之间的对应关系，Windows平台的JDK中使用了除THREAD_PRIORITY_IDLE之外的其余6种线程优先级。

表 12-1 Java 线程优先级与 Windows 线程优先级之间的对应关系

| Java 线程优先级 | Windows 线程优先级 |
|--------------------------|------------------------------|
| 1 (Thread.MIN_PRIORITY) | THREAD_PRIORITY_LOWEST |
| 2 | THREAD_PRIORITY_LOWEST |
| 3 | THREAD_PRIORITY_BELOW_NORMAL |
| 4 | THREAD_PRIORITY_BELOW_NORMAL |
| 5 (Thread.NORM_PRIORITY) | THREAD_PRIORITY_NORMAL |
| 6 | THREAD_PRIORITY_ABOVE_NORMAL |
| 7 | THREAD_PRIORITY_ABOVE_NORMAL |
| 8 | THREAD_PRIORITY_HIGHEST |
| 9 | THREAD_PRIORITY_HIGHEST |
| 10 (Thread.MAX_PRIORITY) | THREAD_PRIORITY_CRITICAL |

上文说到“线程优先级并不是太靠谱”，不仅仅是说在一些平台上不同的优先级实际会变得相同这一点，还有其他情况让我们不能太依赖优先级：优先级可能会被系统自行改变。例如，在 Windows 系统中存在一个称为“优先级推进器”（Priority Boosting，当然它可以被关闭掉）的功能，它的大致作用就是当系统发现一个线程执行得特别“勤奋努力”的话，可能会越过线程优先级去为它分配执行时间。因此，我们不能在程序中通过优先级来完全准确地判断一组状态都为

Ready的线程将会先执行哪一个。

[1]在JDK后续版本中有可能会提供协程(Coroutines) 方式来进行多任务处理，相关资料可参见：

<http://wikis.sun.com/display/mlvm/Coroutines>。

12.4.3 状态转换

Java语言定义了5种线程状态，在任意一个时间点，一个线程只能有且只有其中的一种状态，这5种状态分别如下。

新建（New）：创建后尚未启动的线程处于这种状态。

运行（Runnable）：Runnable包括了操作系统线程状态中的Running和Ready，也就是处于此状态的线程有可能正在执行，也有可能正在等待着CPU为它分配执行时间。

无限期等待（Waiting）：处于这种状态的线程不会被分配CPU执行时间，它们要等待被其他

线程显式地唤醒。以下方法会让线程陷入无限期的等待状态：

- 没有设置Timeout参数的Object.wait() 方法。

- 没有设置Timeout参数的Thread.join() 方法。

- LockSupport.park() 方法。

限期等待（Timed Waiting）：处于这种状态的线程也不会被分配CPU执行时间，不过无须等待被其他线程显式地唤醒，在一定时间之后它们会由系统自动唤醒。以下方法会让线程进入限期等待状态：

- Thread.sleep() 方法。

- 设置了Timeout参数的Object.wait（）方

法。

- 设置了Timeout参数的Thread.join（）方

法。

- LockSupport.parkNanos（）方法。

- LockSupport.parkUntil（）方法。

阻塞（Blocked）：线程被阻塞了，“阻塞状态”与“等待状态”的区别是：“阻塞状态”在等待着获取到一个排他锁，这个事件将在另外一个线程放弃这个锁的时候发生；而“等待状态”则是在等待一段时间，或者唤醒动作的发生。在程序等待进入同步区域的时候，线程将进入这种状态。

结束（Terminated）：已终止线程的线程状态，线程已经结束执行。

上述5种状态在遇到特定事件发生的时候将会互相转换，它们的转换关系如图12-6所示。




图 12-6 线程状态转换关系

12.5 本章小结

本章中，我们首先了解了虚拟机Java内存模型的结构及操作，然后讲解了原子性、可见性、有序性在Java内存模型中的体现，最后介绍了先行发生原则的规则及使用。另外，我们还了解了线程在Java语言之中是如何实现的。

关于“高效并发”这个话题，在本章中主要介绍了虚拟机如何实现“并发”，在第13章中，我们的主要关注点将是虚拟机如何实现“高效”，以及虚拟机对我们编写的并发代码提供了什么样的优化手段。

第13章 线程安全与锁优化

并发处理的广泛应用是使得Amdahl定律代替摩尔定律成为计算机性能发展源动力的根本原因，也是人类“压榨”计算机运算能力的最有力武器。

13.1 概述

在软件业发展的初期，程序编写都是以算法为核心的，程序员会把数据和过程分别作为独立的部分来考虑，数据代表问题空间中的客体，程序代码则用于处理这些数据，这种思维方式直接站在计算机的角度去抽象问题和解决问题，称为面向过程的编程思想。与此相对的是，面向对象

的编程思想是站在现实世界的角度去抽象和解决问题，它把数据和行为都看做是对象的一部分，这样可以让程序员能以符合现实世界的思维方式来编写和组织程序。

面向过程的编程思想极大地提升了现代软件开发的生产效率和软件可以达到的规模，但是现实世界与计算机世界之间不可避免地存在一些差异。例如，人们很难想象现实中的对象在一项工作进行期间，会被不停地中断和切换，对象的属性（数据）可能会在中断期间被修改和变“脏”，而这些事件在计算机世界中则是很正常的事情。有时候，良好的设计原则不得不向现实做出一些让步，我们必须让程序在计算机中正确无误地运行，然后再考虑如何将代码组织得更好，让程序运行得更快。对于这部分的主题“高效并发”来

讲，首先需要保证并发的正确性，然后在此基础上实现高效。本章先从如何保证并发的正确性和如何实现线程安全讲起。

13.2 线程安全

“线程安全”这个名称，相信稍有经验的程序员都会听说过，甚至在代码编写和走查的时候可能还会经常挂在嘴边，但是如何找到一个不太拗口的概念来定义线程安全却不是一件容易的事情，笔者尝试在Google中搜索它的概念，找到的是类似于“如果一个对象可以安全地被多个线程同时使用，那它就是线程安全的”这样的定义——并不能说它不正确，但是人们无法从中获取到任何有用的信息。

笔者认为《Java Concurrency In Practice》的作者Brian Goetz对“线程安全”有一个比较恰当的定义：“当多个线程访问一个对象时，如果不用

考虑这些线程在运行时环境下的调度和交替执行，也不需要进行额外的同步，或者在调用方进行任何其他的协调操作，调用这个对象的行为都可以获得正确的结果，那这个对象是线程安全的”。

这个定义比较严谨，它要求线程安全的代码都必须具备一个特征：代码本身封装了所有必要的正确性保障手段（如互斥同步等），令调用者无须关心多线程的问题，更无须自己采取任何措施来保证多线程的正确调用。这点听起来简单，但其实并不容易做到，在大多数场景中，我们都会将这个定义弱化一些，如果把“调用这个对象的行为”限定为“单次调用”，这个定义的其他描述也能够成立的话，我们就可以称它是线程安全了，为什么要弱化这个定义，现在暂且放下，稍

后再详细探讨。

13.2.1 Java语言中的线程安全

我们已经有了线程安全的一个抽象定义，那接下来就讨论一下在Java语言中，线程安全具体是如何体现的？有哪些操作是线程安全的？我们这里讨论的线程安全，就限定于多个线程之间存在共享数据访问这个前提，因为如果一段代码根本不会与其他线程共享数据，那么从线程安全的角度来看，程序是串行执行还是多线程执行对它来说是完全没有区别的。

为了更加深入地理解线程安全，在这里我们可以不把线程安全当做一个非真即假的二元排他选项来看待，按照线程安全的“安全程度”由强至

弱来排序，我们^[1]可以将Java语言中各种操作共享的数据分为以下5类：不可变、绝对线程安全、相对线程安全、线程兼容和线程对立。

1. 不可变

在Java语言中（特指JDK 1.5以后，即Java内存模型被修正之后的Java语言），不可变（Immutable）的对象一定是线程安全的，无论是对象的方法实现还是方法的调用者，都不需要再采取任何的线程安全保障措施，在第12章我们谈到final关键字带来的可见性时曾经提到过这一点，只要一个不可变的对象被正确地构建出来（没有发生this引用逃逸的情况），那其外部的可见状态永远也不会改变，永远也不会看到它在多个线程之中处于不一致的状态。“不可变”带来

的安全性是最简单和最纯粹的。

Java语言中，如果共享数据是一个基本数据类型，那么只要在定义时使用final关键字修饰它就可以保证它是不可变的。如果共享数据是一个对象，那就需要保证对象的行为不会对其状态产生任何影响才行，如果读者还没想明白这句话，不妨想一想java.lang.String类的对象，它是一个典型的不可变对象，我们调用它的substring（）、replace（）和concat（）这些方法都不会影响它原来的值，只会返回一个新构造的字符串对象。

保证对象行为不影响自己状态的途径有很多种，其中最简单的就是把对象中带有状态的变量都声明为final，这样在构造函数结束之后，它就是不可变的，例如代码清单13-1中

java.lang.Integer构造函数所示的，它通过将内部状态变量value定义为final来保障状态不变。

代码清单13-1 JDK中Integer类的构造函数

```
 /**
 *The value of the<code>Integer</code>.
 *@serial
 */
private final int value;
/**
 *Constructs a newly allocated<code>Integer
 </code>object that
 *represents the specified<code>int</code>
 value.
 *
 *{@param value the value to be represented by
 the
 *<code>Integer</code>object.
 */
public Integer (int value) {
this.value=value;
}
```

在Java API中符合不可变要求的类型，除了上面提到的String之外，常用的还有枚举类型，以

及java.lang.Number的部分子类，如Long和Double等数值包装类型， BigInteger和BigDecimal等大数据类型；但同为Number的子类型的原子类 AtomicInteger和AtomicLong则并非不可变的，读者不妨看看这两个原子类的源码，想一想为什么。

2. 绝对线程安全

绝对的线程安全完全满足Brian Goetz给出的线程安全的定义，这个定义其实是很严格的，一个类要达到“不管运行时环境如何，调用者都不需要任何额外的同步措施”通常需要付出很大的，甚至有时候是不切实际的代价。在Java API中标注自己是线程安全的类，大多数都不是绝对的线程安全。我们可以通过Java API中一个不

是“绝对线程安全”的线程安全类来看看这里的“绝对”是什么意思。

如果说java.util.Vector是一个线程安全的容器，相信所有的Java程序员对此都不会有异议，因为它的add（）、get（）和size（）这类方法都是被synchronized修饰的，尽管这样效率很低，但确实是安全的。但是，即使它所有的方法都被修饰成同步，也不意味着调用它的时候永远都不再需要同步手段了，请看一下代码清单13-2中的测试代码。

代码清单13-2 对Vector线程安全的测试

```
private static Vector<Integer>vector=new
Vector<Integer>();
public static void main (String[]args) {
while (true) {
for (int i=0; i<10; i++) {
```

```
vector.add (i) ;  
}  
Thread removeThread=new Thread (new  
Runnable () {  
    @Override  
    public void run () {  
        for (int i=0; i<vector.size () ; i++) {  
            vector.remove (i) ;  
        }  
    }  
});  
Thread printThread=new Thread (new  
Runnable () {  
    @Override  
    public void run () {  
        for (int i=0; i<vector.size () ; i++) {  
            System.out.println ( (vector.get (i)) ) ;  
        }  
    }  
});  
removeThread.start () ;  
printThread.start () ;  
//不要同时产生过多的线程，否则会导致操作系统假死  
while (Thread.activeCount () >20) ;  
}  
}
```

运行结果如下：

Exception in thread "Thread-132"
java.lang.ArrayIndexOutOfBoundsException:

```
Array index out of range: 17
at java.util.Vector.remove (Vector.java:
777)
at
org.fenixsoft.mulithread.VectorTest$1.run (Vecto
21)
at java.lang.Thread.run (Thread.java: 662)
```

很明显，尽管这里使用到的Vector的get（）、remove（）和size（）方法都是同步的，但是在多线程的环境中，如果不在方法调用端做额外的同步措施的话，使用这段代码仍然是不安全的，因为如果另一个线程恰好在错误的时间里删除了一个元素，导致序号i已经不再可用的话，再用i访问数组就会抛出一个ArrayIndexOutOfBoundsException。如果要保证这段代码能正确执行下去，我们不得不把removeThread和printThread的定义改成如代码清单13-3所示的样子。

代码清单13-3 必须加入同步以保证Vector访问的线程安全性

```
Thread removeThread=new Thread (new
Runnable () {
    @Override
    public void run () {
        synchronized (vector) {
            for (int i=0; i<vector.size () ; i++) {
                vector.remove (i);
            }
        }
    }
}) ;
Thread printThread=new Thread (new
Runnable () {
    @Override
    public void run () {
        synchronized (vector) {
            for (int i=0; i<vector.size () ; i++) {
                System.out.println ( (vector.get (i)) );
            }
        }
    }
}) ;
```

3.相对线程安全

相对的线程安全就是我们通常意义上所讲的线程安全，它需要保证对这个对象单独的操作是线程安全的，我们在调用的时候不需要做额外的保障措施，但是对于一些特定顺序的连续调用，就可能需要在调用端使用额外的同步手段来保证调用的正确性。上面代码清单13-2和代码清单13-3就是相对线程安全的明显的案例。

在Java语言中，大部分的线程安全类都属于这种类型，例如Vector、HashTable、Collections的synchronizedCollection（）方法包装的集合等。

4.线程兼容

线程兼容是指对象本身并不是线程安全的，但是可以通过在调用端正确地使用同步手段来保证对象在并发环境中可以安全地使用，我们平常

说一个类不是线程安全的，绝大多数时候指的是这一种情况。Java API中大部分的类都是属于线程兼容的，如与前面的Vector和HashTable相对应的集合类ArrayList和HashMap等。

5.线程对立

线程对立是指无论调用端是否采取了同步措施，都无法在多线程环境中并发使用的代码。由于Java语言天生就具备多线程特性，线程对立这种排斥多线程的代码是很少出现的，而且通常都是有害的，应当尽量避免。

一个线程对立的例子是Thread类的suspend（）和resume（）方法，如果有两个线程同时持有一个线程对象，一个尝试去中断线程，另一个尝试去恢复线程，如果并发进行的话，无

论调用时是否进行了同步，目标线程都是存在死锁风险的，如果suspend（）中断的线程就是即将要执行resume（）的那个线程，那就肯定要产生死锁了。也正是由于这个原因，suspend（）和resume（）方法已经被JDK声明废弃（@Deprecated）了。常见的线程对立的操作还有System.setIn（）、System.setOut（）和System.runFinalizersOnExit（）等。

[1]这种划分方法也是Brian Goetz在IBM developWorkers上发表的一篇论文中提出的，这里写“我们”纯粹是笔者下笔行文中的语言用法。

13.2.2 线程安全的实现方法

了解了什么是线程安全之后，紧接着的一个问题就是我们应该如何实现线程安全，这听起来似乎是一件由代码如何编写来决定的事情，确实，如何实现线程安全与代码编写有很大的关系，但虚拟机提供的同步和锁机制也起到了非常重要的作用。本节中，代码编写如何实现线程安全和虚拟机如何实现同步与锁这两者都会有所涉及，相对而言更偏重后者一些，只要读者了解了虚拟机线程安全手段的运作过程，自己去思考代码如何编写并不是一件困难的事情。

1.互斥同步

互斥同步（Mutual Exclusion& Synchronization）是常见的一种并发正确性保障手段。同步是指在多个线程并发访问共享数据时，保证共享数据在同一个时刻只被一个（或者是一些，使用信号量的时候）线程使用。而互斥是实现同步的一种手段，临界区（CriticalSection）、互斥量（Mutex）和信号量（Semaphore）都是主要的互斥实现方式。因此，在这4个字里面，互斥是因，同步是果；互斥是方法，同步是目的。

在Java中，最基本的互斥同步手段就是synchronized关键字，synchronized关键字经过编译之后，会在同步块的前后分别形成monitorenter和monitorexit这两个字节码指令，这两个字节码都需要一个reference类型的参数来指明要锁定和解锁的对象。如果Java程序中的synchronized明确指

定了对象参数，那就是这个对象的reference；如果没有明确指定，那就根据synchronized修饰的是实例方法还是类方法，去取对应的对象实例或Class对象来作为锁对象。

根据虚拟机规范的要求，在执行monitorenter指令时，首先要尝试获取对象的锁。如果这个对象没被锁定，或者当前线程已经拥有了那个对象的锁，把锁的计数器加1，相应的，在执行monitorexit指令时会将锁计数器减1，当计数器为0时，锁就被释放。如果获取对象锁失败，那当前线程就要阻塞等待，直到对象锁被另外一个线程释放为止。

在虚拟机规范对monitorenter和monitorexit的行为描述中，有两点是需要特别注意的。首先，

`synchronized`同步块对同一条线程来说是可重入的，不会出现自己把自己锁死的问题。其次，同步块在已进入的线程执行完之前，会阻塞后面其他线程的进入。第12章讲过，Java的线程是映射到操作系统的原生线程之上的，如果要阻塞或唤醒一个线程，都需要操作系统来帮忙完成，这就需要从用户态转换到核心态中，因此状态转换需要耗费很多的处理器时间。对于代码简单的同步块（如被`synchronized`修饰的`getter()`或`setter()`方法），状态转换消耗的时间有可能比用户代码执行的时间还要长。所以`synchronized`是Java语言中一个重量级（Heavyweight）的操作，有经验的程序员都会在确实必要的情况下才使用这种操作。而虚拟机本身也会进行一些优化，譬如在通知操作系统阻塞线程之前加入一段自旋等。

待过程，避免频繁地切入到核心态之中。

除了synchronized之外，我们还可以使用java.util.concurrent（下文称J.U.C）包中的重入锁（ReentrantLock）来实现同步，在基本用法上，ReentrantLock与synchronized很相似，他们都具备一样的线程重入特性，只是代码写法上有点区别，一个表现为API层面的互斥锁（lock（）和unlock（）方法配合try/finally语句块来完成），另一个表现为原生语法层面的互斥锁。不过，相比synchronized,ReentrantLock增加了一些高级功能，主要有以下3项：等待可中断、可实现公平锁，以及锁可以绑定多个条件。

等待可中断是指当持有锁的线程长期不释放锁的时候，正在等待的线程可以选择放弃等待，

改为处理其他事情，可中断特性对处理执行时间非常长的同步块很有帮助。

公平锁是指多个线程在等待同一个锁时，必须按照申请锁的时间顺序来依次获得锁；而非公平锁则不保证这一点，在锁被释放时，任何一个等待锁的线程都有机会获得锁。`synchronized`中的锁是非公平的，`ReentrantLock`默认情况下也是非公平的，但可以通过带布尔值的构造函数要求使用公平锁。

锁绑定多个条件是指一个`ReentrantLock`对象可以同时绑定多个`Condition`对象，而在`synchronized`中，锁对象的`wait()`和`notify()`或`notifyAll()`方法可以实现一个隐含的条件，如果要和多于一个的条件关联的时候，就不得不额

外地添加一个锁，而ReentrantLock则无须这样做，只需要多次调用newCondition（）方法即可。

如果需要使用上述功能，选用ReentrantLock是一个很好的选择，那如果是基于性能考虑呢？关于synchronized和ReentrantLock的性能问题，Brian Goetz对这两种锁在JDK 1.5与单核处理器，以及JDK 1.5与双Xeon处理器环境下做了一组吞吐量对比的实验^[1]，实验结果如图13-1和图13-2所示。

Single Processor (Windows)




图 13-1 JDK 1.5、单核处理器下两种锁的吞吐量对比

从图13-1和图13-2可以看出，多线程环境下 synchronized 的吞吐量下降得非常严重，而 ReentrantLock 则能基本保持在同一个比较稳定的水平上。与其说 ReentrantLock 性能好，还不如说 synchronized 还有非常大的优化余地。后续的技术发展也证明了这一点，JDK 1.6 中加入了很多针对

锁的优化措施（13.3节我们就会讲解这些优化措施），JDK 1.6发布之后，人们就发现synchronized与ReentrantLock的性能基本上是完全持平了。因此，如果读者的程序是使用JDK 1.6或以上部署的话，性能因素就不再是选择ReentrantLock的理由了，虚拟机在未来的性能改进中肯定也会更加偏向于原生的synchronized，所以还是提倡在synchronized能实现需求的情况下，优先考虑使用synchronized来进行同步。




图 13-2 JDK 1.5、双Xeon处理器下两种锁的吞吐量对比

2. 非阻塞同步

互斥同步最主要的问题就是进行线程阻塞和唤醒所带来的性能问题，因此这种同步也称为阻塞同步（Blocking Synchronization）。从处理问题的方式上说，互斥同步属于一种悲观的并发策略，总是认为只要不去做正确的同步措施（例如加锁），那就肯定会出现问题，无论共享数据是否真的会出现竞争，它都要进行加锁（这里讨论的是概念模型，实际上虚拟机会优化掉很大一部分不必要的加锁）、用户态核心态转换、维护锁计数器和检查是否有被阻塞的线程需要唤醒等操作。随着硬件指令集的发展，我们有了另外一个

选择：基于冲突检测的乐观并发策略，通俗地说，就是先进行操作，如果没有其他线程争用共享数据，那操作就成功了；如果共享数据有争用，产生了冲突，那就再采取其他的补偿措施（最常见的补偿措施就是不断地重试，直到成功为止），这种乐观的并发策略的许多实现都不需要把线程挂起，因此这种同步操作称为非阻塞同步（Non-Blocking Synchronization）。

为什么笔者说使用乐观并发策略需要“硬件指令集的发展”才能进行呢？因为我们需要操作和冲突检测这两个步骤具备原子性，靠什么来保证呢？如果这里再使用互斥同步来保证就失去意义了，所以我们只能靠硬件来完成这件事情，硬件保证一个从语义上看起来需要多次操作的行为只通过一条处理器指令就能完成，这类指令常用

的有：

测试并设置（Test-and-Set）。

获取并增加（Fetch-and-Increment）。

交换（Swap）。

比较并交换（Compare-and-Swap，下文称
CAS）。

加载链接/条件存储（Load-Linked/Store-
Conditional，下文称LL/SC）。

其中，前面的3条是20世纪就已经存在于大
多数指令集之中的处理器指令，后面的两条是现
代处理器新增的，而且这两条指令的目的和功能
是类似的。在IA64、x86指令集中有`cmpxchg`指令

完成CAS功能，在sparc-TSO也有casa指令实现，而在ARM和PowerPC架构下，则需要使用一对ldrex/strex指令来完成LL/SC的功能。

CAS指令需要有3个操作数，分别是内存位置（在Java中可以简单理解为变量的内存地址，用V表示）、旧的预期值（用A表示）和新值（用B表示）。CAS指令执行时，当且仅当V符合旧预期值A时，处理器用新值B更新V的值，否则它就不执行更新，但是无论是否更新了V的值，都会返回V的旧值，上述的处理过程是一个原子操作。

在JDK 1.5之后，Java程序中才可以使用CAS操作，该操作由sun.misc.Unsafe类里面的compareAndSwapInt（）和

`compareAndSwapLong()` 等几个方法包装提供，虚拟机在内部对这些方法做了特殊处理，即时编译出来的结果就是一条平台相关的处理器CAS指令，没有方法调用的过程，或者可以认为是无条件内联进去了^[2]。

由于`Unsafe`类不是提供给用户程序调用的类（`Unsafe.getUnsafe()` 的代码中限制了只有启动类加载器（Bootstrap ClassLoader）加载的Class才能访问它），因此，如果不采用反射手段，我们只能通过其他的Java API来间接使用它，如J.U.C包里面的整数原子类，其中的`compareAndSet()`和`getAndIncrement()`等方法都使用了`Unsafe`类的CAS操作。

我们不妨拿一段在第12章中没有解决的问题

代码来看看如何使用CAS操作来避免阻塞同步，代码如代码清单12-1所示。我们曾经通过这段20个线程自增10000次的代码来证明volatile变量不具备原子性，那么如何才能让它具备原子性呢？把“race++”操作或increase（）方法用同步块包裹起来当然是一个办法，但是如果改成如代码清单13-4所示的代码，那效率将会提高许多。

代码清单13-4 Atomic的原子自增运算

```
/*
*Atomic变量自增运算测试
*
*@author zzm
*/
public class AtomicTest{
    public static AtomicInteger race=new
AtomicInteger(0) ;
    public static void increase () {
        race.incrementAndGet () ;
    }
    private static final int THREADS_COUNT=20;
    public static void main (String[]args)
```

```
throws Exception{
    Thread[] threads=new Thread[THREADS_COUNT];
    for (int i=0; i<THREADS_COUNT; i++) {
        threads[i]=new Thread (new Runnable () {
            @Override
            public void run () {
                for (int i=0; i<10000; i++) {
                    increase () ;
                }
            }
        }) ;
        threads[i].start () ;
    }
    while (Thread.activeCount () >1)
        Thread.yield () ;
    System.out.println (race) ;
}
```

运行结果如下：

200000

使用AtomicInteger代替int后，程序输出了正确的结果，一切都要归功于incrementAndGet（）方法的原子性。它的实现其实非常简单，如代码

清单13-5所示。

代码清单13-5 incrementAndGet() 方法的 JDK源码

```
 /**
 *Atomically increment by one the current
value.
 *@return the updated value
 */
public final int incrementAndGet () {
for (; ) {
int current=get ();
int next=current+1;
if (compareAndSet (current,next) )
return next;
}
}
```

incrementAndGet() 方法在一个无限循环中，不断尝试将一个比当前值大1的新值赋给自己。如果失败了，那说明在执行“获取-设置”操作的时候值已经有了修改，于是再次循环进行下一

次操作，直到设置成功为止。

尽管CAS看起来很美，但显然这种操作无法涵盖互斥同步的所有使用场景，并且CAS从语义上来说并不是完美的，存在这样的一个逻辑漏洞：如果一个变量V初次读取的时候是A值，并且在准备赋值的时候检查到它仍然为A值，那我们就能说它的值没有被其他线程改变过了吗？如果在这段期间它的值曾经被改成了B，后来又被改回为A，那CAS操作就会误认为它从来没有被改变过。这个漏洞称为CAS操作的“ABA”问题。

J.U.C包为了解决这个问题，提供了一个带有标记的原子引用类“AtomicStampedReference”，它可以通过控制变量值的版本来保证CAS的正确性。不过目前来说这个类比较“鸡肋”，大部分情况下ABA问题不会影响程序并发的正确性，如果需要

解决ABA问题，改用传统的互斥同步可能会比原子类更高效。

3. 无同步方案

要保证线程安全，并不是一定就要进行同步，两者没有因果关系。同步只是保证共享数据争用时的正确性的手段，如果一个方法本来就不涉及共享数据，那它自然就无须任何同步措施去保证正确性，因此会有一些代码天生就是线程安全的，笔者简单地介绍其中的两类。

可重入代码（Reentrant Code）：这种代码也叫做纯代码（Pure Code），可以在代码执行的任何时候中断它，转而去执行另外一段代码（包括递归调用它本身），而在控制权返回后，原来的程序不会出现任何错误。相对线程安全来说，可

重入性是更基本的特性，它可以保证线程安全，即所有的可重入的代码都是线程安全的，但是并非所有的线程安全的代码都是可重入的。

可重入代码有一些共同的特征，例如不依赖存储在堆上的数据和公用的系统资源、用到的状态量都由参数中传入、不调用非可重入的方法等。我们可以通过一个简单的原则来判断代码是否具备可重入性：如果一个方法，它的返回结果是可以预测的，只要输入了相同的数据，就都能返回相同的结果，那它就满足可重入性的要求，当然也就是线程安全的。

线程本地存储（Thread Local Storage）：如果一段代码中所需要的数据必须与其他代码共享，那就看看这些共享数据的代码是否能保证在

同一个线程中执行？如果能保证，我们就可以把共享数据的可见范围限制在同一个线程之内，这样，无须同步也能保证线程之间不出现数据争用的问题。

符合这种特点的应用并不少见，大部分使用消费队列的架构模式（如“生产者-消费者”模式）都会将产品的消费过程尽量在一个线程中消费完，其中最重要的一个应用实例就是经典Web交互模型中的“一个请求对应一个服务器线程”（Thread-per-Request）的处理方式，这种处理方式的广泛应用使得很多Web服务端应用都可以使用线程本地存储来解决线程安全问题。

Java语言中，如果一个变量要被多线程访问，可以使用volatile关键字声明它为“易变的”；

如果一个变量要被某个线程独享，Java中就没有类似C++中`_declspec(thread)`^[3]这样的关键字，不过还是可以通过`java.lang.ThreadLocal`类来实现线程本地存储的功能。每一个线程的`Thread`对象中都有一个`ThreadLocalMap`对象，这个对象存储了一组以`ThreadLocal.threadLocalHashCode`为键，以本地线程变量为值的K-V值对，`ThreadLocal`对象就是当前线程的`ThreadLocalMap`的访问入口，每一个`ThreadLocal`对象都包含了一个独一无二的`threadLocalHashCode`值，使用这个值就可以在线程K-V值对中找回对应的本地线程变量。

[1]本例中的数据及图片来源于Brian Goetz为IBM developerWorks撰写的论文：《Java theory and practice: More flexible,scalable locking in JDK》

5.0》, 原文地址是:

http://www.ibm.com/developerworks/java/library/j-jtp10264/?S_TACT=105AGX52&S_CMP=cn-a-j。

[2]这种被虚拟机特殊处理的方法称为固有函数
(Intrinsics), 类似的固有函数还有Math.sin ()
等。

[3]在Visual C++中是“__declspec (thread)”关键字, 而在GCC中是“__thread”。

13.3 锁优化

高效并发是从JDK 1.5到JDK 1.6的一个重要改进，HotSpot虚拟机开发团队在这个版本上花费了大量的精力去实现各种锁优化技术，如适应性自旋（Adaptive Spinning）、锁消除（Lock Elimination）、锁粗化（Lock Coarsening）、轻量级锁（Lightweight Locking）和偏向锁（Biased Locking）等，这些技术都是为了在线程之间更高效地共享数据，以及解决竞争问题，从而提高程序的执行效率。

13.3.1 自旋锁与自适应自旋

前面我们讨论互斥同步的时候，提到了互斥

同步对性能最大的影响是阻塞的实现，挂起线程和恢复线程的操作都需要转入内核态中完成，这些操作给系统的并发性能带来了很大的压力。同时，虚拟机的开发团队也注意到在许多应用上，共享数据的锁定状态只会持续很短的一段时间，为了这段时间去挂起和恢复线程并不值得。如果物理机器有一个以上的处理器，能让两个或以上的线程同时并行执行，我们就可以让后面请求锁的那个线程“稍等一下”，但不放弃处理器的执行时间，看看持有锁的线程是否很快就会释放锁。为了让线程等待，我们只需让线程执行一个忙循环（自旋），这项技术就是所谓的自旋锁。

自旋锁在JDK 1.4.2中就已经引入，只不过默认是关闭的，可以使用-XX: +UseSpinning参数来开启，在JDK 1.6中就已经改为默认开启了。自旋

等待不能代替阻塞，且先不说对处理器数量的要求，自旋等待本身虽然避免了线程切换的开销，但它是要占用处理器时间的，因此，如果锁被占用的时间很短，自旋等待的效果就会非常好，反之，如果锁被占用的时间很长，那么自旋的线程只会白白消耗处理器资源，而不会做任何有用的工作，反而会带来性能上的浪费。因此，自旋等待的时间必须要有一定的限度，如果自旋超过了限定的次数仍然没有成功获得锁，就应当使用传统的方式去挂起线程了。自旋次数的默认值是10次，用户可以使用参数-XX: PreBlockSpin来更改。

在JDK 1.6中引入了自适应的自旋锁。自适应意味着自旋的时间不再固定了，而是由前一次在同一个锁上的自旋时间及锁的拥有者的状态来决

定。如果在同一个锁对象上，自旋等待刚刚成功获得过锁，并且持有锁的线程正在运行中，那么虚拟机就会认为这次自旋也很有可能再次成功，进而它将允许自旋等待持续相对更长的时间，比如100个循环。另外，如果对于某个锁，自旋很少成功获得过，那在以后要获取这个锁时将可能省略掉自旋过程，以避免浪费处理器资源。有了自适应自旋，随着程序运行和性能监控信息的不断完善，虚拟机对程序锁的状况预测就会越来越准确，虚拟机就会变得越来越“聪明”了。

13.3.2 锁消除

锁消除是指虚拟机即时编译器在运行时，对一些代码上要求同步，但是被检测到不可能存在共享数据竞争的锁进行消除。锁消除的主要判定依据来源于逃逸分析的数据支持（第11章已经讲解过逃逸分析技术），如果判断在一段代码中，堆上的所有数据都不会逃逸出去从而被其他线程访问到，那就可以把它们当做栈上数据对待，认为它们是线程私有的，同步加锁自然就无须进行。

也许读者会有疑问，变量是否逃逸，对于虚拟机来说需要使用数据分析来确定，但是程序员自己应该是很清楚的，怎么会在明知道不存在

数据争用的情况下要求同步呢？答案是有许多同步措施并不是程序员自己加入的，同步的代码在Java程序中的普遍程度也许超过了大部分读者的梦想。我们来看看代码清单13-6中的例子，这段非常简单的代码仅仅是输出3个字符串相加的结果，无论是源码字面上还是程序语义上都没有同步。

代码清单13-6 一段看起来没有同步的代码

```
public String concatString (String s1,  
String s2, String s3) {  
    return s1+s2+s3;  
}
```

我们也知道，由于String是一个不可变的类，对字符串的连接操作总是通过生成新的String对象来进行的，因此Javac编译器会对String连接做自

动优化。在JDK 1.5之前，会转化为StringBuffer对象的连续append（）操作，在JDK 1.5及以后的版本中，会转化为StringBuilder对象的连续append（）操作，即代码清单13-6中的代码可能会变成代码清单13-7的样子^[1]。

代码清单13-7 Javac转化后的字符串连接操作

```
public String concatString (String s1,
String s2, String s3) {
    StringBuffer sb=new StringBuffer () ;
    sb.append (s1) ;
    sb.append (s2) ;
    sb.append (s3) ;
    return sb.toString () ;
}
```

现在大家还认为这段代码没有涉及同步吗？每个StringBuffer.append（）方法中都有一个同步

块，锁就是sb对象。虚拟机观察变量sb，很快就会发现它的动态作用域被限制在concatString（）方法内部。也就是说，sb的所有引用永远不会“逃逸”到concatString（）方法之外，其他线程无法访问到它，因此，虽然这里有锁，但是可以被安全地消除掉，在即时编译之后，这段代码就会忽略掉所有的同步而直接执行了。

[1]客观地说，既然谈到锁消除与逃逸分析，那虚拟机就不可能是JDK 1.5之前的版本，实际上会转化为非线程安全的StringBuilder来完成字符串拼接，并不会加锁，但这也不影响笔者用这个例子证明Java对象中同步的普遍性。

13.3.3 锁粗化

原则上，我们在编写代码的时候，总是推荐将同步块的作用范围限制得尽量小——只在共享数据的实际作用域中才进行同步，这样是为了使得需要同步的操作数量尽可能变小，如果存在锁竞争，那等待锁的线程也能尽快拿到锁。

大部分情况下，上面的原则都是正确的，但是如果一系列的连续操作都对同一个对象反复加锁和解锁，甚至加锁操作是出现在循环体中的，那即使没有线程竞争，频繁地进行互斥同步操作也会导致不必要的性能损耗。

代码清单13-7中连续的append（）方法就属

于这类情况。如果虚拟机探测到有这样一串零碎的操作都对同一个对象加锁，将会把加锁同步的范围扩展（粗化）到整个操作序列的外部，以代码清单13-7为例，就是扩展到第一个append（）操作之前直至最后一个append（）操作之后，这样只需要加锁一次就可以了。

13.3.4 轻量级锁

轻量级锁是JDK 1.6之中加入的新型锁机制，它名字中的“轻量级”是相对于使用操作系统互斥量来实现的传统锁而言的，因此传统的锁机制就称为“重量级”锁。首先需要强调一点的是，轻量级锁并不是用来代替重量级锁的，它的本意是在没有多线程竞争的前提下，减少传统的重量级锁使用操作系统互斥量产生的性能消耗。

要理解轻量级锁，以及后面会讲到的偏向锁的原理和运作过程，必须从HotSpot虚拟机的对象（对象头部分）的内存布局开始介绍。HotSpot虚拟机的对象头（Object Header）分为两部分信息，第一部分用于存储对象自身的运行时数据，

如哈希码（HashCode）、GC分代年龄（Generational GC Age）等，这部分数据的长度在32位和64位的虚拟机中分别为32bit和64bit，官方称它为“Mark Word”，它是实现轻量级锁和偏向锁的关键。另外一部分用于存储指向方法区对象类型数据的指针，如果是数组对象的话，还会有一个额外的部分用于存储数组长度。

对象头信息是与对象自身定义的数据无关的额外存储成本，考虑到虚拟机的空间效率，Mark Word被设计成一个非固定的数据结构以便在极小的空间内存储尽量多的信息，它会根据对象的状态复用自己的存储空间。例如，在32位的HotSpot虚拟机中对象未被锁定的状态下，Mark Word的32bit空间中的25bit用于存储对象哈希码（HashCode），4bit用于存储对象分代年龄，2bit

用于存储锁标志位，1bit固定为0，在其他状态（轻量级锁定、重量级锁定、GC标记、可偏向）下对象的存储内容见表13-1。

表 13-1 HotSpot 虚拟机对象头 Mark Word

| 存储内容 | 标志位 | 状态 |
|----------------------|-----|-----------|
| 对象哈希码、对象分代年龄 | 01 | 未锁定 |
| 指向锁记录的指针 | 00 | 轻量级锁定 |
| 指向重量级锁的指针 | 10 | 膨胀（重量级锁定） |
| 空，不需要记录信息 | 11 | GC 标记 |
| 偏向线程 ID、偏向时间戳、对象分代年龄 | 01 | 可偏向 |

简单地介绍了对象的内存布局后，我们把话题返回到轻量级锁的执行过程上。在代码进入同步块的时候，如果此同步对象没有被锁定（锁标志位为“01”状态），虚拟机首先将在当前线程的栈帧中建立一个名为锁记录（Lock Record）的空间，用于存储锁对象目前的Mark Word的拷贝（官方把这份拷贝加了一个Displaced前缀，即 Displaced Mark Word），这时候线程堆栈与对象

头的状态如图13-3所示。

然后，虚拟机将使用CAS操作尝试将对象的Mark Word更新为指向Lock Record的指针。如果这个更新动作成功了，那么这个线程就拥有了该对象的锁，并且对象Mark Word的锁标志位（Mark Word的最后2bit）将转变为“00”，即表示此对象处于轻量级锁定状态，这时候线程堆栈与对象头的状态如图13-4所示。




图 13-3 轻量级锁CAS操作之前堆栈与对象的状态^[1]




图 13-4 轻量级锁CAS操作之后堆栈与对象的状态

如果这个更新操作失败了，虚拟机首先会检查对象的Mark Word是否指向当前线程的栈帧，如果只说明当前线程已经拥有了这个对象的锁，那就可以直接进入同步块继续执行，否则说明这

个锁对象已经被其他线程抢占了。如果有两条以上的线程争用同一个锁，那轻量级锁就不再有效，要膨胀为重量级锁，锁标志的状态值变为“10”，Mark Word中存储的就是指向重量级锁（互斥量）的指针，后面等待锁的线程也要进入阻塞状态。

上面描述的是轻量级锁的加锁过程，它的解锁过程也是通过CAS操作来进行的，如果对象的Mark Word仍然指向着线程的锁记录，那就用CAS操作把对象当前的Mark Word和线程中复制的Displaced Mark Word替换回来，如果替换成功，整个同步过程就完成了。如果替换失败，说明有其他线程尝试过获取该锁，那就要在释放锁的同时，唤醒被挂起的线程。

轻量级锁能提升程序同步性能的依据是“对于绝大部分的锁，在整个同步周期内都是不存在竞争的”，这是一个经验数据。如果没有竞争，轻量级锁使用CAS操作避免了使用互斥量的开销，但如果存在锁竞争，除了互斥量的开销外，还额外发生了CAS操作，因此在有竞争的情况下，轻量级锁会比传统的重量级锁更慢。

[1]图13-3和图13-4来源于HotSpot虚拟机的一位Senior Staff Engineer——Paul Hohensee所写的PPT “The Hotspot Java Virtual Machine” 。

13.3.5 偏向锁

偏向锁也是JDK 1.6中引入的一项锁优化，它的目的是消除数据在无竞争情况下的同步原语，进一步提高程序的运行性能。如果说轻量级锁是在无竞争的情况下使用CAS操作去消除同步使用的互斥量，那偏向锁就是在无竞争的情况下把整个同步都消除掉，连CAS操作都不做了。

偏向锁的“偏”，就是偏心的“偏”、偏袒的“偏”，它的意思是这个锁会偏向于第一个获得它的线程，如果在接下来的执行过程中，该锁没有被其他的线程获取，则持有偏向锁的线程将永远不需要再进行同步。

如果读者读懂了前面轻量级锁中关于对象头Mark Word与线程之间的操作过程，那偏向锁的原理理解起来就会很简单。假设当前虚拟机启用了偏向锁（启用参数-XX: +UseBiasedLocking，这是JDK 1.6的默认值），那么，当锁对象第一次被线程获取的时候，虚拟机将会把对象头中的标志位设为“01”，即偏向模式。同时使用CAS操作把获取到这个锁的线程的ID记录在对象的Mark Word之中，如果CAS操作成功，持有偏向锁的线程以后每次进入这个锁相关的同步块时，虚拟机都可以不再进行任何同步操作（例如Locking、Unlocking及对Mark Word的Update等）。

当有另外一个线程去尝试获取这个锁时，偏向模式就宣告结束。根据锁对象目前是否处于被锁定的状态，撤销偏向（Revoke Bias）后恢复到

未锁定（标志位为“01”）或轻量级锁定（标志位为“00”）的状态，后续的同步操作就如上面介绍的轻量级锁那样执行。偏向锁、轻量级锁的状态转化及对象Mark Word的关系如图13-5所示。




图 13-5 偏向锁、轻量级锁的状态转化及对象
Mark Word 的关系

偏向锁可以提高带有同步但无竞争的程序性能。它同样是一个带有效益权衡（Trade Off）性质的优化，也就是说，它并不一定总是对程序运

行有利，如果程序中大多数的锁总是被多个不同的线程访问，那偏向模式就是多余的。在具体问题具体分析的前提下，有时候使用参数-XX: -UseBiasedLocking来禁止偏向锁优化反而可以提升性能。

13.4 本章小结

本章介绍了线程安全所涉及的概念和分类、同步实现的方式及虚拟机的底层运作原理，并且介绍了虚拟机为了实现高效并发所采取的一系列锁优化措施。

许多资深的程序员都说过，能够写出高伸缩性的并发程序是一门艺术，而了解并发在系统底层是如何实现的，则是掌握这门艺术的前提条件，也是成长为高级程序员的必备知识之一。

附录

附录A 编译Windows版的OpenJDK

附录B 虚拟机字节码指令表

附录C HotSpot虚拟机主要参数表

附录D 对象查询语言（OQL）简介

附录E JDK历史版本轨迹

附录A 编译Windows版的OpenJDK

A.1 获取JDK源码

首先确定要使用的JDK版本，OpenJDK 6和OpenJDK 7都是开源的，源码都可以在它们的主页（<http://openjdk.java.net/>）上找到，OpenJDK 6的源码其实是从OpenJDK 7的某个基线中引出的，然后剥离掉JDK 1.7相关的代码，从而得到一份可以通过TCK 6的JDK 1.6实现，因此直接编译OpenJDK 7会更加“原汁原味”一些，其实这两个版本的编译过程差异并不大。

获取源码有两种方式。一种是通过Mercurial代码版本管理工具从Repository中直接取得源码（Repository地址：

<http://hg.openjdk.java.net/jdk7/jdk7>），这是最直接的方式，从版本管理中看变更轨迹比看什么 Release Note都来得实在，不过坏处自然是太麻烦了一些，尤其是Mercurial远不如SVN、ClearCase 或CVS之类的版本控制工具那样普及。另一种就是直接下载官方打包好的源码包了，可以从 Source Releases页面（地址：

<http://download.java.net/openjdk/jdk7/>）取得打包好的源码，一般来说大概一个月会更新一次，虽然不够及时，但的确方便了许多。笔者下载的是 OpenJDK 7 Early Access Source Build b121版，2010年12月9日发布的，大概81.7MB，解压后约308MB。

A.2 系统需求

如果可能，笔者建议尽量在Linux或Solaris上构建OpenJDK，这要比在Windows平台上轻松许多，而且网络上能找到的资料绝大部分都是在Linux上编译的。如果一定要在Windows平台上编译，建议读者认真阅读一下源码中的README-builds.html文档（无论在OpenJDK网站上还是在下载的源码包里面都有这份文档），因为编译过程中需要注意的细节非常多。虽然不至于像文档上所描述的“Building the source code for the JDK requires a high level of technical expertise. Sun provides the source code primarily for technical experts who want to conduct research（编译JDK需要很高的专业技术，Sun提供JDK源码是为了技术

专家进行研究之用）”那么夸张，但是如果读者是第一次编译，那在上面耗费一整天乃至更多的时间都很正常。

笔者在本次实战中演示的是在32位Windows 7平台下编译x86版的OpenJDK（也就是32位的JDK），如果需要编译x64版，那毫无疑问也需要一个64位的操作系统。另外，编译涉及的所有文件都必须存放在NTFS格式的文件系统中，因为FAT32格式无法支持大小写敏感的文件名。在官方文档上写着：编译至少需要512MB的内存和600MB的磁盘空间。512MB的内存基本上也可以凑合使用，不过600MB的磁盘空间仅仅是指存放OpenJDK源码和相关依赖项的空间，要完成编译，600MB肯定是无论如何都不够的，这次实战中所下载的工具、依赖项、源码，全部安装、解

压完成最少（最少是指只下载C++编译器，不下载VS的IDE）需要超过1GB的空间。

对系统的最后一点要求就是所有的文件，包括源码和依赖项目，都不要放在包含中文或空格的目录里面，这样做不是一定不可以，只是这样会为后续建立CYGWIN环境带来很多额外的工作，这是由于Linux和Windows的磁盘路径差别所导致的，我们也没有必要给自己找麻烦。

A.3 构建编译环境

准备编译环境的第一步是去安装一个CYGWIN^[1]。这是一个在Windows平台下模拟Linux运行环境的软件，提供了一系列的Linux命令支持。需要CYGWIN的原因是在编译中要使用GNU Make来执行Makefile文件（C/C++程序员肯定很熟悉，如果只使用Java，那把这个东西当做C++版本的ANT看待就可以了）。安装CYGWIN时不能直接默认安装，因为表A-1中所示的工具都不会进行默认安装，但又是编译过程中需要的，因此要在图A-1的安装界面中进行手工选择。

表 A-1 需要手工选择安装的 CYGWIN 工具

| 文件名 | 分类 | 包 | 描述 |
|----------|--------------|----------|--|
| ar.exe | Devel | binutils | The GNU assembler, linker and binary utilities |
| make.exe | Devel | make | The GNU version of the 'make' utility built for CYGWIN. |
| m4.exe | Interpreters | m4 | GNU implementation of the traditional Unix macro processor |
| cpio.exe | Utils | cpio | A program to manage archives of files |
| gawk.exe | Utils | awk | Pattern-directed scanning and processing language |
| file.exe | Utils | file | Determines file type using 'magic' numbers |

(续)

| 文件名 | 分类 | 包 | 描述 |
|-----------|---------|--------|--|
| zip.exe | Archive | zip | Package and compress (archive) files |
| unzip.exe | Archive | unzip | Extract compressed files in a ZIP archive |
| free.exe | System | procps | Display amount of free and used memory in the system |

CYGWIN 安装时的定制包选择界面如图A-1 所示：



图 A-1 CYGWIN安装界面

建立编译环境的第二步是安装编译器。JDK中最核心的代码（Java虚拟机及JDK中Native方法的实现等）是使用C++语言及少量的C语言编写的，官方文档中说他们的内部开发环境是在Microsoft Visual Studio C++2003（VS2003）中进

行编译，同时也在Microsoft Visual Studio C++2010（VS2010）中测试过，所以最好只选择这两个编译器之一进行编译。如果选择VS2010，那么在编译器之中已经包含了Windows SDK v 7.0a，否则可能还要自己去下载这个SDK，并且更新PlatformSDK目录。由于Visual Studio 2010的IDE是收费的，所以仅仅下载了VS2010 Express中提取出来的C++编译器，这部分是免费的，但单独安装好编译器比较麻烦。建议读者选择使用整套Visual Studio C++2010或Visual Studio C++2010 Express版进行编译。

需要特别注意的一点是，CYGWIN和VS2010安装之后都会在操作系统的PATH环境变量中写入自己的bin目录路径，必须检查并保证VS2010的bin目录一定要在CYGWIN的bin目录之前，因为

这两个软件的bin目录之中各自都有个连接器“link.exe”，但是只有VS2010中的连接器可以完成OpenJDK的编译。

准备JDK编译环境的第三步就是下载一个已经编译好了的JDK。这听起来也许有点滑稽——要用鸡蛋孵小鸡还真得必须先养一只母鸡呀？但仔细想想其实这个步骤很合理：因为JDK包含的各个部分（Hotspot、JDK API、JAXWS、JAXP……）有的是使用C++编写的，而更多的代码则是使用Java自身实现的，因此编译这些Java代码需要用到一个可用的JDK，官方称这个JDK为“Bootstrap JDK”。而编译OpenJDK 7的话，Bootstrap JDK必须使用JDK6 Update 14或之后的版本，笔者选用的是JDK6 Update 21。

最后一个步骤是下载一个Apache ANT,JDK中Java代码部分都是使用ANT脚本进行编译的，ANT版本要求在1.6.5以上，这部分是Java的基础知识，对本书的读者来说应该没有难度，笔者不再详述。

[1]CYGWIN下载地址：<http://www.cygwin.com/>。

A.4 准备依赖项

前面说过，OpenJDK中开放的源码并没有达到100%，还有极少量的无法开源的产权代码存在。OpenJDK承诺日后将逐步使用开源实现来替换掉这部分产权代码，但至少在今天，编译JDK还需要这部分闭源包，官方称之为“JDK Plug”^[1]，它们从前面的Source Releases页面就可以下载到。在Windows平台的JDK Plug是以Jar包的形式提供的，通过下面这条命令可以安装它：

```
java -jar jdk-7-ea-plug-b121-windows-i586-09_dec_2010.jar
```

运行后将会显示如图A-2所示的协议，点击ACCEPT接受协议，然后把Plug安装到指定目录

即可。安装完毕后建立一个环境变量“ALT_BINARY_PLUGS_PATH”，变量值为此JDK Plug的安装路径，后面编译程序时需要用到它。

除了要用到JDK Plug外，编译时还需要引用JDK的运行时包，这个是编译JDK中用Java代码编写的那部分所需要的，如果仅仅是想编译一个HotSpot虚拟机的话则可以不用。官方文档把这部分称为“Optional Import JDK”，可以直接使用前面Bootstrap JDK的运行时包，我们需要建立一个名为“ALT_JDK_IMPORT_PATH”的环境变量指向JDK的安装目录。



图 A-2 JDK Plug安装协议

然后是安装一个大于2.3版的FreeType^[2]，这是一个免费的字体渲染库，JDK的Swing部分和JConsole这类工具要使用到它。安装好后建立两个环境变量“ALT_FREETYPE_LIB_PATH”和“ALT_FREETYPE_INCLUDE_PATH”，分别指向FreeType安装目录下的bin目录和include目录。另外还有一点官方文档没有提到但必须要

做的事情是把FreeType的bin目录加入到PATH环境变量中。

然后下载Microsoft DirectX 9.0 SDK（Summer 2004），安装后大约有298MB，在微软官方网站上搜索一下就可以找到下载地址，它是免费的。安装后建立环境变量“ALT_DXSDK_PATH”指向DirectX 9.0 SDK的安装目录。

然后去寻找一个名为“MSVCR100.DLL”的动态链接库，如果读者在前面安装了全套的Visual Studio 2010，那这个文件在本机就能找到，否则上网搜索一下也能找到单独的下载地址，大概有744KB。建立环境变量“ALT_MSVCRRN_DLL_PATH”指向这个文件所在的目录。如果读者选择的是VS2003，这个文件

名应当为“MSVCR73.DLL”，应该在很多软件中都包含有这个文件，如果找不到的话，前面下载的“Bootstrap JDK”的bin目录中应该也有一个，直接拿来用吧。

[1]在2011年，JDK plug已经不再需要了，但在笔者写本次实战时使用的2010年12月9日发布的OpenJDK b121版还是需要这些JDK plug。

[2]FreeType主页：<http://www.freetype.org/>。

A.5 进行编译

现在需要下载的编译环境和依赖项目都准备齐全了，最后我们还需要对系统做一些设置以便编译能够顺利通过。

首先执行VS2010中的VCVARS32.BAT，这个批处理文件的目的主要是设置INCLUDE、LIB和PATH这几个环境变量，如果和笔者一样只是下载了编译器的话则需要手工设置它们，各个环境变量的设置值可以参考下面给出的代码清单A-1中的内容。批处理运行完之后建立“ALT_COMPILER_PATH”环境变量让Makefile知道在哪里可以找到编译器。

再建

立“ALT_BOOTDIR”和“ALT_JDK_IMPORT_PATH”两个环境变量指向前面提到的JDK 1.6的安装目录。建立“ANT_HOME”指向Apache ANT的安装目录。建立的环境变量很多，为了避免遗漏，笔者写了一个批处理文件以供读者参考，如代码清单A-1所示。

代码清单A-1 环境变量设置

```
SET ALT_BOOTDIR=D: /_DevSpace/JDK 1.6.0_21
SET
ALT_BINARY_PLUGS_PATH=D: /jdkBuild/jdk7plug/open
binary-plugs
    SET ALT_JDK_IMPORT_PATH=D: /_DevSpace/JDK
1.6.0_21
    SET ANT_HOME=D: /jdkBuild/apache-ant-1.7.0
    SET
ALT_MSVCRRNNDLL_PATH=D: /jdkBuild/msvcr100
    SET ALT_DXSDK_PATH=D: /jdkBuild/msdxsdk
    SET
ALT_COMPILER_PATH=D: /jdkBuild/vcpp2010.x86/bin
    SET
ALT_FREETYPE_HEADERS_PATH=D: /jdkBuild/freetype-
2.3.5-1-bin/include
```

```
SET
ALT_FREETYPE_LIB_PATH=D: /jdkBuild/freetype-
2.3.5-1-bin/bin
    SET
INCLUDE=D: /jdkBuild/vcpp2010.x86/include;
D: /jdkBuild/vcpp2010.x86/sdk/Include; %INCLUDE%
    SET LIB=D: /jdkBuild/vcpp2010.x86/lib;
D: /jdkBuild/vcpp2010.x86/sdk/Lib; %LIB%
    SET LIBPATH=D: /jdkBuild/vcpp2010.x86/lib;
%LIB%
    SET PATH=D: /jdkBuild/vcpp2010.x86/bin;
D: /jdkBuild/vcpp2010.x86/dll/x86;
D: /Software/OpenSource/cygwin/bin;
%ALT_FREETYPE_LIB_PATH%; %PATH%
```

最后还需要进行两项调整，虽然，官方文档没有说明这两项，但是必须做完才能保证编译过程的顺利通过：一项是取消环境变量 JAVA_HOME，这点很简单；另外一项是尽量在英文的操作系统上编译，如果不能在英文的系统上编译就把系统的文字格式调整为“英语（美国）”，在控制面板-区域和语言选项的第一个页签中可以设置。如果这个设置还不能更改就建立

一个“BUILD_CORBA”的环境变量，将值设置为 false，取消编译CORBA部分，否则Java IDL（idlj.exe）为*.idl文件生成CORBA适配器代码的时候会产生中文注释，而这些中文注释会因为字符集的问题而导致编译失败。

完成了上述的准备工作之后，我们终于可以开始编译了。进入控制台（Cmd.exe）后运行刚才准备好的设置环境变量的批处理文件，然后输入bash进入Bourne Again Shell环境（sh或ksh也可以）。如果JDK的安装源码中存在“jdk_generic_profile.sh”这个Shell脚本，先执行它，笔者下载的OpenJDK 7 B121版没有这个文件了，所以直接输入make sanity来检查我们前面所做的设置是否全部正确。如果一切顺利，那么几秒钟之后会有类似代码清单A-2所示的输出。

代码清单A-2 make sanity检查

```
D: \jdkBuild\openjdk7>bash  
bash-3.2$make sanity  
cygwin warning:  
MS-DOS style path detected:  
C: /Windows/system32/wscript.exe  
Preferred POSIX equivalent  
is: /cygdrive/c/Windows/system32/wscript.exe  
CYGWIN environment variable  
option "nodosfilewarning" turns off this warning.  
Consult the user's guide for more details  
about POSIX paths:  
http://cygwin.com/cygwin-ug-  
net/using.html#using-pathnames  
(cd./jdk/make&&\br/>.....因篇幅关系，中间省略了大量的输出内容.....  
OpenJDK-specific settings:  
FREETYPE_HEADERS_PATH=D: /jdkBuild/freetype-  
2.3.5-1-bin/include  
ALT_FREETYPE_HEADERS_PATH=D: /jdkBuild/freetype-  
2.3.5-1-bin/include  
FREETYPE_LIB_PATH=D: /jdkBuild/freetype-  
2.3.5-1-bin/bin  
ALT_FREETYPE_LIB_PATH=D: /jdkBuild/freetype-  
2.3.5-1-bin/bin  
OPENJDK Import Binary Plug Settings:  
IMPORT_BINARY_PLUGS=true  
BINARY_PLUGS_JARFILE=D: /jdkBuild/jdk7plug/op  
binary-plugs/jre/lib/rt-closed.jar  
ALT_BINARY_PLUGS_JARFILE=
```

```
BINARY_PLUGS_PATH=D: /jdkBuild/jdk7plug/open  
binary-plugs  
ALT_BINARY_PLUGS_PATH=D: /jdkBuild/jdk7plug/c  
binary-plugs  
BUILD_BINARY_PLUGS_PATH=J: /re/jdk/1.7.0/pron  
ALT_BUILD_BINARY_PLUGS_PATH=  
PLUG_LIBRARY_NAMES=  
Previous JDK Settings:  
PREVIOUS_RELEASE_PATH=USING-  
PREVIOUS_RELEASE_IMAGE  
ALT_PREVIOUS_RELEASE_PATH=  
PREVIOUS_JDK_VERSION=1.6.0  
ALT_PREVIOUS_JDK_VERSION=  
PREVIOUS_JDK_FILE=  
ALT_PREVIOUS_JDK_FILE=  
PREVIOUS_JRE_FILE=  
ALT_PREVIOUS_JRE_FILE=  
PREVIOUS_RELEASE_IMAGE=D: /_DevSpace/JDK  
1.6.0_21  
ALT_PREVIOUS_RELEASE_IMAGE=  
Sanity check passed.
```

Makefile的Sanity检查过程输出了编译所需的所有环境变量，如果看到“Sanity check passed.”，说明检查过程通过了，可以输入“make”执行整个Makefile，笔者使用Core i5/4GB RAM的机器编译整个JDK大概需要半个多小时。如果失败则需要

根据系统输出的失败原因，回头再检查一下对应的设置。并且最好在下一次编译之前先执行“make clean”来清理掉上次编译遗留的文件。

编译完成之后，打开OpenJDK源码下的build目录，看看是不是已经有一个编译好的JDK在那里等着了？执行一下“java-version”，看到以自己机器命名的JDK了吧，很有成就感吧！

附录B 虚拟机字节码指令表

| 字节码 | 助记符 | 指令含义 |
|------|-------------|---|
| 0x00 | nop | 什么都不做 |
| 0x01 | aconst_null | 将 null 推送至栈顶 |
| 0x02 | iconst_m1 | 将 int 型 -1 推送至栈顶 |
| 0x03 | iconst_0 | 将 int 型 0 推送至栈顶 |
| 0x04 | iconst_1 | 将 int 型 1 推送至栈顶 |
| 0x05 | iconst_2 | 将 int 型 2 推送至栈顶 |
| 0x06 | iconst_3 | 将 int 型 3 推送至栈顶 |
| 0x07 | iconst_4 | 将 int 型 4 推送至栈顶 |
| 0x08 | iconst_5 | 将 int 型 5 推送至栈顶 |
| 0x09 | lconst_0 | 将 long 型 0 推送至栈顶 |
| 0x0a | lconst_1 | 将 long 型 1 推送至栈顶 |
| 0x0b | fconst_0 | 将 float 型 0 推送至栈顶 |
| 0x0c | fconst_1 | 将 float 型 1 推送至栈顶 |
| 0x0d | fconst_2 | 将 float 型 2 推送至栈顶 |
| 0x0e | dconst_0 | 将 double 型 0 推送至栈顶 |
| 0x0f | dconst_1 | 将 double 型 1 推送至栈顶 |
| 0x10 | bipush | 将单字节的常量值 (-128~127) 推送至栈顶 |
| 0x11 | sipush | 将一个短整型常量值 (-32768~32767) 推送至栈顶 |
| 0x12 | ldc | 将 int、float 或 String 型常量值从常量池中推送至栈顶 |
| 0x13 | ldc_w | 将 int、float 或 String 型常量值从常量池中推送至栈顶 (宽索引) |
| 0x14 | ldc2_w | 将 long 或 double 型常量值从常量池中推送至栈顶 (宽索引) |
| 0x15 | iload | 将指定的 int 型本地变量推送至栈顶 |
| 0x16 | lload | 将指定的 long 型本地变量推送至栈顶 |
| 0x17 | fload | 将指定的 float 型本地变量推送至栈顶 |
| 0x18 | dload | 将指定的 double 型本地变量推送至栈顶 |
| 0x19 | aload | 将指定的引用类型本地变量推送至栈顶 |
| 0x1a | iload_0 | 将第一个 int 型本地变量推送至栈顶 |
| 0x1b | iload_1 | 将第二个 int 型本地变量推送至栈顶 |
| 0x1c | iload_2 | 将第三个 int 型本地变量推送至栈顶 |
| 0x1d | iload_3 | 将第四个 int 型本地变量推送至栈顶 |
| 0x1e | lload_0 | 将第一个 long 型本地变量推送至栈顶 |
| 0x1f | lload_1 | 将第二个 long 型本地变量推送至栈顶 |

| 字节码 | 助记符 | 指令含义 |
|------|----------|---------------------------------|
| 0x20 | lload_2 | 将第三个 long 型本地变量推送至栈顶 |
| 0x21 | lload_3 | 将第四个 long 型本地变量推送至栈顶 |
| 0x22 | fload_0 | 将第一个 float 型本地变量推送至栈顶 |
| 0x23 | fload_1 | 将第二个 float 型本地变量推送至栈顶 |
| 0x24 | fload_2 | 将第三个 float 型本地变量推送至栈顶 |
| 0x25 | fload_3 | 将第四个 float 型本地变量推送至栈顶 |
| 0x26 | dload_0 | 将第一个 double 型本地变量推送至栈顶 |
| 0x27 | dload_1 | 将第二个 double 型本地变量推送至栈顶 |
| 0x28 | dload_2 | 将第三个 double 型本地变量推送至栈顶 |
| 0x29 | dload_3 | 将第四个 double 型本地变量推送至栈顶 |
| 0x2a | aload_0 | 将第一个引用类型本地变量推送至栈顶 |
| 0x2b | aload_1 | 将第二个引用类型本地变量推送至栈顶 |
| 0x2c | aload_2 | 将第三个引用类型本地变量推送至栈顶 |
| 0x2d | aload_3 | 将第四个引用类型本地变量推送至栈顶 |
| 0x2e | iaload | 将 int 型数组指定索引的值推送至栈顶 |
| 0x2f | laload | 将 long 型数组指定索引的值推送至栈顶 |
| 0x30 | faload | 将 float 型数组指定索引的值推送至栈顶 |
| 0x31 | daload | 将 double 型数组指定索引的值推送至栈顶 |
| 0x32 | aaload | 将引用型数组指定索引的值推送至栈顶 |
| 0x33 | baload | 将 boolean 或 byte 型数组指定索引的值推送至栈顶 |
| 0x34 | caload | 将 char 型数组指定索引的值推送至栈顶 |
| 0x35 | saload | 将 short 型数组指定索引的值推送至栈顶 |
| 0x36 | istore | 将栈顶 int 型数值存入指定本地变量 |
| 0x37 | lstore | 将栈顶 long 型数值存入指定本地变量 |
| 0x38 | fstore | 将栈顶 float 型数值存入指定本地变量 |
| 0x39 | dstore | 将栈顶 double 型数值存入指定本地变量 |
| 0x3a | astore | 将栈顶引用型数值存入指定本地变量 |
| 0x3b | istore_0 | 将栈顶 int 型数值存入第一个本地变量 |
| 0x3c | istore_1 | 将栈顶 int 型数值存入第二个本地变量 |
| 0x3d | istore_2 | 将栈顶 int 型数值存入第三个本地变量 |
| 0x3e | istore_3 | 将栈顶 int 型数值存入第四个本地变量 |
| 0x3f | lstore_0 | 将栈顶 long 型数值存入第一个本地变量 |
| 0x40 | lstore_1 | 将栈顶 long 型数值存入第二个本地变量 |
| 0x41 | lstore_2 | 将栈顶 long 型数值存入第三个本地变量 |
| 0x42 | lstore_3 | 将栈顶 long 型数值存入第四个本地变量 |
| 0x43 | fstore_0 | 将栈顶 float 型数值存入第一个本地变量 |
| 0x44 | fstore_1 | 将栈顶 float 型数值存入第二个本地变量 |
| 0x45 | fstore_2 | 将栈顶 float 型数值存入第三个本地变量 |

| 字节码 | 助记符 | 指令含义 |
|------|----------|--|
| 0x46 | fstore_3 | 将栈顶 float 型数值存入第四个本地变量 |
| 0x47 | dstore_0 | 将栈顶 double 型数值存入第一个本地变量 |
| 0x48 | dstore_1 | 将栈顶 double 型数值存入第二个本地变量 |
| 0x49 | dstore_2 | 将栈顶 double 型数值存入第三个本地变量 |
| 0x4a | dstore_3 | 将栈顶 double 型数值存入第四个本地变量 |
| 0x4b | astore_0 | 将栈顶引用型数值存入第一个本地变量 |
| 0x4c | astore_1 | 将栈顶引用型数值存入第二个本地变量 |
| 0x4d | astore_2 | 将栈顶引用型数值存入第三个本地变量 |
| 0x4e | astore_3 | 将栈顶引用型数值存入第四个本地变量 |
| 0x4f | iastore | 将栈顶 int 型数值存入指定数组的指定索引位置 |
| 0x50 | lastore | 将栈顶 long 型数值存入指定数组的指定索引位置 |
| 0x51 | fastore | 将栈顶 float 型数值存入指定数组的指定索引位置 |
| 0x52 | dastore | 将栈顶 double 型数值存入指定数组的指定索引位置 |
| 0x53 | aastore | 将栈顶引用型数值存入指定数组的指定索引位置 |
| 0x54 | bastore | 将栈顶 boolean 或 byte 型数值存入指定数组的指定索引位置 |
| 0x55 | castore | 将栈顶 char 型数值存入指定数组的指定索引位置 |
| 0x56 | sastore | 将栈顶 short 型数值存入指定数组的指定索引位置 |
| 0x57 | pop | 将栈顶数值弹出（数值不能是 long 或 double 类型的） |
| 0x58 | pop2 | 将栈顶的一个（对于 long 或 double 类型）或两个数值（对于非 long 或 double 的其他类型）弹出 |
| 0x59 | dup | 复制栈顶数值并将复制值压入栈顶 |
| 0x5a | dup_x1 | 复制栈顶数值并将两个复制值压入栈顶 |
| 0x5b | dup_x2 | 复制栈顶数值并将三个（或两个）复制值压入栈顶 |
| 0x5c | dup2 | 复制栈顶一个（对于 long 或 double 类型）或两个（对于非 long 或 double 的其他类型）数值并将复制值压入栈顶 |
| 0x5d | dup2_x1 | dup_x1 指令的双倍版本 |
| 0x5e | dup2_x2 | dup_x2 指令的双倍版本 |
| 0x5f | swap | 将栈最顶端的两个数值互换（数值不能是 long 或 double 类型） |
| 0x60 | iadd | 将栈顶两 int 型数值相加并将结果压入栈顶 |
| 0x61 | ladd | 将栈顶两 long 型数值相加并将结果压入栈顶 |
| 0x62 | fadd | 将栈顶两 float 型数值相加并将结果压入栈顶 |
| 0x63 | dadd | 将栈顶两 double 型数值相加并将结果压入栈顶 |
| 0x64 | isub | 将栈顶两 int 型数值相减并将结果压入栈顶 |
| 0x65 | lsub | 将栈顶两 long 型数值相减并将结果压入栈顶 |
| 0x66 | fsub | 将栈顶两 float 型数值相减并将结果压入栈顶 |
| 0x67 | dsub | 将栈顶两 double 型数值相减并将结果压入栈顶 |
| 0x68 | imul | 将栈顶两 int 型数值相乘并将结果压入栈顶 |
| 0x69 | lmul | 将栈顶两 long 型数值相乘并将结果压入栈顶 |

| 字节码 | 助记符 | 指令含义 |
|------|-------|---------------------------------------|
| 0x6a | fmul | 将栈顶两个 float 型数值相乘并将结果压入栈顶 |
| 0x6b | dmul | 将栈顶两个 double 型数值相乘并将结果压入栈顶 |
| 0x6c | idiv | 将栈顶两个 int 型数值相除并将结果压入栈顶 |
| 0x6d | ldiv | 将栈顶两个 long 型数值相除并将结果压入栈顶 |
| 0x6e | fdiv | 将栈顶两个 float 型数值相除并将结果压入栈顶 |
| 0x6f | ddiv | 将栈顶两个 double 型数值相除并将结果压入栈顶 |
| 0x70 | irem | 将栈顶两个 int 型数值作取模运算并将结果压入栈顶 |
| 0x71 | lrem | 将栈顶两个 long 型数值作取模运算并将结果压入栈顶 |
| 0x72 | frem | 将栈顶两个 float 型数值作取模运算并将结果压入栈顶 |
| 0x73 | drem | 将栈顶两个 double 型数值作取模运算并将结果压入栈顶 |
| 0x74 | ineg | 将栈顶 int 型数值取负并将结果压入栈顶 |
| 0x75 | lneg | 将栈顶 long 型数值取负并将结果压入栈顶 |
| 0x76 | fneg | 将栈顶 float 型数值取负并将结果压入栈顶 |
| 0x77 | dneg | 将栈顶 double 型数值取负并将结果压入栈顶 |
| 0x78 | ishl | 将 int 型数值左移位指定位数并将结果压入栈顶 |
| 0x79 | lshl | 将 long 型数值左移位指定位数并将结果压入栈顶 |
| 0x7a | ishr | 将 int 型数值右(带符号)移位指定位数并将结果压入栈顶 |
| 0x7b | lshr | 将 long 型数值右(带符号)移位指定位数并将结果压入栈顶 |
| 0x7c | iushr | 将 int 型数值右(无符号)移位指定位数并将结果压入栈顶 |
| 0x7d | lushr | 将 long 型数值右(无符号)移位指定位数并将结果压入栈顶 |
| 0x7e | iand | 将栈顶两个 int 型数值作“按位与”并将结果压入栈顶 |
| 0x7f | land | 将栈顶两个 long 型数值作“按位与”并将结果压入栈顶 |
| 0x80 | ior | 将栈顶两个 int 型数值作“按位或”并将结果压入栈顶 |
| 0x81 | lor | 将栈顶两个 long 型数值作“按位或”并将结果压入栈顶 |
| 0x82 | ixor | 将栈顶两个 int 型数值作“按位异或”并将结果压入栈顶 |
| 0x83 | lxor | 将栈顶两个 long 型数值作“按位异或”并将结果压入栈顶 |
| 0x84 | iinc | 将指定 int 型变量增加指定值(如 i++、i--、i+=2 等) |
| 0x85 | i2l | 将栈顶 int 型数值强制转换成 long 型数值并将结果压入栈顶 |
| 0x86 | i2f | 将栈顶 int 型数值强制转换成 float 型数值并将结果压入栈顶 |
| 0x87 | i2d | 将栈顶 int 型数值强制转换成 double 型数值并将结果压入栈顶 |
| 0x88 | l2i | 将栈顶 long 型数值强制转换成 int 型数值并将结果压入栈顶 |
| 0x89 | l2f | 将栈顶 long 型数值强制转换成 float 型数值并将结果压入栈顶 |
| 0x8a | l2d | 将栈顶 long 型数值强制转换成 double 型数值并将结果压入栈顶 |
| 0x8b | f2i | 将栈顶 float 型数值强制转换成 int 型数值并将结果压入栈顶 |
| 0x8c | f2l | 将栈顶 float 型数值强制转换成 long 型数值并将结果压入栈顶 |
| 0x8d | f2d | 将栈顶 float 型数值强制转换成 double 型数值并将结果压入栈顶 |
| 0x8e | d2i | 将栈顶 double 型数值强制转换成 int 型数值并将结果压入栈顶 |
| 0x8f | d2l | 将栈顶 double 型数值强制转换成 long 型数值并将结果压入栈顶 |

| 字节码 | 助记符 | 指令含义 |
|------|--------------|---|
| 0x90 | d2f | 将栈顶 double 型数值强制转换成 float 型数值并将结果压入栈顶 |
| 0x91 | i2b | 将栈顶 int 型数值强制转换成 byte 型数值并将结果压入栈顶 |
| 0x92 | i2c | 将栈顶 int 型数值强制转换成 char 型数值并将结果压入栈顶 |
| 0x93 | i2s | 将栈顶 int 型数值强制转换成 short 型数值并将结果压入栈顶 |
| 0x94 | lcmp | 比较栈顶两 long 型数值的大小，并将结果(1、0或-1)压入栈顶 |
| 0x95 | fcmpl | 比较栈顶两 float 型数值的大小，并将结果(1、0或-1)压入栈顶；当其中一个数值为“NaN”时，将-1压入栈顶 |
| 0x96 | fcmpg | 比较栈顶两 float 型数值的大小，并将结果(1、0或-1)压入栈顶；当其中一个数值为“NaN”时，将1压入栈顶 |
| 0x97 | dcmpl | 比较栈顶两 double 型数值的大小，并将结果(1、0或-1)压入栈顶；当其中一个数值为“NaN”时，将-1压入栈顶 |
| 0x98 | dcmpg | 比较栈顶两 double 型数值的大小，并将结果(1、0或-1)压入栈顶；当其中一个数值为“NaN”时，将1压入栈顶 |
| 0x99 | ifeq | 当栈顶 int 型数值等于0时跳转 |
| 0x9a | ifne | 当栈顶 int 型数值不等于0时跳转 |
| 0x9b | iflt | 当栈顶 int 型数值小于0时跳转 |
| 0x9c | ifge | 当栈顶 int 型数值大于或等于0时跳转 |
| 0x9d | ifgt | 当栈顶 int 型数值大于0时跳转 |
| 0x9e | ifle | 当栈顶 int 型数值小于或等于0时跳转 |
| 0x9f | if_icmpne | 比较栈顶两 int 型数值的大小，当结果等于0时跳转 |
| 0xa0 | if_icmpne | 比较栈顶两 int 型数值的大小，当结果不等于0时跳转 |
| 0xa1 | if_icmplt | 比较栈顶两 int 型数值的大小，当结果小于0时跳转 |
| 0xa2 | if_icmpge | 比较栈顶两 int 型数值的大小，当结果大于或等于0时跳转 |
| 0xa3 | if_icmpgt | 比较栈顶两 int 型数值的大小，当结果大于0时跳转 |
| 0xa4 | if_icmple | 比较栈顶两 int 型数值的大小，当结果小于或等于0时跳转 |
| 0xa5 | if_acmpne | 比较栈顶两引用型数值，当结果相等时跳转 |
| 0xa6 | if_acmpne | 比较栈顶两引用型数值，当结果不相等时跳转 |
| 0xa7 | goto | 无条件跳转 |
| 0xa8 | jsr | 跳转至指定的16位offset位置，并将jsr的下一条指令地址压入栈顶 |
| 0xa9 | ret | 返回至本地变量指定的index的指令位置（一般与jsr或jsr_w联合使用） |
| 0xaa | tableswitch | 用于switch条件跳转，case值连续（可变长度指令） |
| 0xab | lookupswitch | 用于switch条件跳转，case值不连续（可变长度指令） |
| 0xac | ireturn | 从当前方法返回int |
| 0xad | lreturn | 从当前方法返回long |
| 0xae | freturn | 从当前方法返回float |
| 0xaf | dreturn | 从当前方法返回double |
| 0xb0 | areturn | 从当前方法返回对象引用 |
| 0xb1 | return | 从当前方法返回void |
| 0xb2 | getstatic | 获取指定类的静态域，并将其值压入栈顶 |

| 字节码 | 助记符 | 指令含义 |
|------|-----------------|---|
| 0xb3 | putstatic | 为指定的类的静态域赋值 |
| 0xb4 | getfield | 获取指定类的实例域，并将其值压入栈顶 |
| 0xb5 | putfield | 为指定的类的实例域赋值 |
| 0xb6 | invokevirtual | 调用实例方法 |
| 0xb7 | invokespecial | 调用超类构造方法，实例初始化方法，私有方法 |
| 0xb8 | invokestatic | 调用静态方法 |
| 0xb9 | invokeinterface | 调用接口方法 |
| 0xba | invokedynamic | 调用动态方法 |
| 0xbb | new | 创建一个对象，并将其引用值压入栈顶 |
| 0xbc | newarray | 创建一个指定的原始类型（如 int、float、char 等）的数组，并将其引用值压入栈顶 |
| 0xbd | anewarray | 创建一个引用型（如类、接口、数组）的数组，并将其引用值压入栈顶 |
| 0xbe | arraylength | 获得数组的长度值并压入栈顶 |
| 0xbf | athrow | 将栈顶的异常抛出 |
| 0xc0 | checkcast | 检验类型转换，检验未通过将抛出 ClassCastException |
| 0xc1 | instanceof | 检验对象是否是指定的类的实例，如果是，则将 1 压入栈顶，否则将 0 压入栈顶 |
| 0xc2 | monitorenter | 获得对象的锁，用于同步方法或同步块 |
| 0xc3 | monitorexit | 释放对象的锁，用于同步方法或同步块 |
| 0xc4 | wide | 扩展本地变量的宽度 |
| 0xc5 | multianewarray | 创建指定类型和指定维度的多维数组（执行该指令时，操作栈中必须包含各维度的长度值），并将其引用值压入栈顶 |
| 0xc6 | ifnull | 为 null 时跳转 |
| 0xc7 | ifnonnull | 不为 null 时跳转 |
| 0xc8 | goto_w | 无条件跳转（宽索引） |
| 0xc9 | jsr_w | 跳转至指定的 32 位 offset 位置，并将 jsr_w 的下一条指令地址压入栈顶 |

附录C HotSpot虚拟机主要参数表

本参数表以JDK 1.6为基础编写，JDK 1.6的HotSpot虚拟机有很多非稳定参数（Unstable Options，即以-XX：开头的参数，JDK 1.6的虚拟机中大概有660多个），使用-XX：
+PrintFlagsFinal参数可以输出所有参数的名称及默认值（默认不包括Diagnostic和Experimental的参数，如果需要，可以配合-XX：
+UnlockDiagnosticVMOptions/-XX：
+UnlockExperimentalVMOptions一起使用），下面的各个表格只包含了其中最常用的（或在本书中介绍到的）部分。参数使用的方式有如下3种：

-XX： +<option>开启option参数。

-XX: -<option>关闭option参数。

-XX: <option>=<value>将option参数的值设置为value。

C.1 内存管理参数

| 参数 | 默认值 | 使用介绍 |
|-----------------------------|--------------------------|--|
| DisableExplicitGC | 默认关闭 | 忽略来自 System.gc() 方法触发的垃圾收集 |
| ExplicitGCInvokesConcurrent | 默认关闭 | 当收到 System.gc() 方法提交的垃圾收集申请时，使用 CMS 收集器进行收集 |
| UseSerialGC | Client 模式的虚拟机默认开启，其他模式关闭 | 虚拟机运行在 Client 模式下的默认值，打开此开关后，使用 Serial+Serial Old 的收集器组合进行内存回收 |
| UseParNewGC | 默认关闭 | 打开此开关后，使用 ParNew+Serial Old 的收集器组合进行内存回收 |
| UseConcMarkSweepGC | 默认关闭 | 打开此开关后，使用 ParNew+CMS+Serial Old 的收集器组合进行内存回收。如果 CMS 收集器出现 Concurrent Mode Failure，则 Serial Old 收集器将作为后备收集器 |
| UseParallelGC | Server 模式的虚拟机默认开启，其他模式关闭 | 虚拟机运行在 Server 模式下的默认值，打开此开关后，使用 Parallel Scavenge+Serial Old 的收集器组合进行内存回收 |

(续)

| 参数 | 默认值 | 使用介绍 |
|--------------------------------|---|---|
| UseParallelOldGC | 默认关闭 | 打开此开关后，使用 Parallel Scavenge + Parallel Old 的收集器组合进行内存回收 |
| SurvivorRatio | 默认为 8 | 新生代中 Eden 区域与 Survivor 区域的容量比值 |
| PretenureSizeThreshold | 无默认值 | 直接晋升到老年代的对象大小，设置这个参数后，大于这个参数的对象将直接在老年代分配 |
| MaxTenuringThreshold | 默认值为 15 | 晋升到老年代的对象年龄。每个对象在坚持过一次 Minor GC 之后，年龄就增加 1，当超过这个参数值时就进入老年代 |
| UseAdaptiveSizePolicy | 默认开启 | 动态调整 Java 堆中各个区域的大小及进入老年代的年龄 |
| HandlePromotionFailure | JDK 1.5 及以前版本默认关闭，JDK 1.6 默认开启 | 是否允许分配担保失败，即老年代的剩余空间不足以应付新生代的整个 Eden 和 Survivor 区的所有对象都存活的极端情况 |
| ParallelGCThreads | 少于或等于 8 个 CPU 时默认值为 CPU 数量值，多于 8 个时比 CPU 数量值小 | 设置并行 GC 时进行内存回收的线程数 |
| GCTimeRatio | 默认值为 99 | GC 时间占总时间的比率，默认值为 99，即允许 1% 的 GC 时间。仅在使用 Parallel Scavenge 收集器时生效 |
| MaxGCPauseMillis | 无默认值 | 设置 GC 的最大停顿时间。仅在使用 Parallel Scavenge 收集器时生效 |
| CMSInitiatingOccupancyFraction | 默认值为 68 | 设置 CMS 收集器在老年代空间被使用多少后触发垃圾收集，仅在使用 CMS 收集器时生效 |
| UseCMSCompactAtFullCollection | 默认开启 | 设置 CMS 收集器在完成垃圾收集后是否要进行一次内存碎片整理。仅在使用 CMS 收集器时生效 |
| CMSFullGCsBeforeCompaction | 无默认值 | 设置 CMS 收集器在进行若干次垃圾收集后再启动一次内存碎片整理。仅在使用 CMS 收集器时生效 |
| ScavengeBeforeFullGC | 默认开启 | 在 Full GC 发生之前触发一次 Minor GC |
| UseGCOverheadLimit | 默认开启 | 禁止 GC 过程无限制地执行。如果过于频繁，就直接发生 OutOfMemory 异常 |
| UseTLAB | Server 模式默认开启 | 优先在本地线程缓冲区中分配对象，避免分配内存时的锁定过程 |
| MaxHeapFreeRatio | 默认值为 70 | 当 Xmx 值比 Xms 值大时，堆可以动态收缩和扩展，这个参数控制当堆空闲大于指定比率时自动收缩 |
| MinHeapFreeRatio | 默认值为 40 | 当 Xmx 值比 Xms 值大时，堆可以动态收缩和扩展，这个参数控制当堆空闲小于指定比率时自动扩展 |
| MaxPermSize | 大部分情况下默认值是 64MB | 永久代的最大值 |

C.2 即时编译参数

| 参数 | 默认值 | 使用介绍 |
|--------------------------|--|---|
| CompileThreshold | Client 模式下默认值是 1500, Server 模式下是 10000 | 触发方法即时编译的阈值 |
| OnStackReplacePercentage | Client 模式下默认值是 933, Server 模式下是 140 | OSR 比率，它是 OSR 即时编译阈值计算公式的一个参数，用于代替 BackEdgeThreshold 参数控制回边计数器的实际溢出阈值 |
| ReservedCodeCacheSize | 大部分情况下默认值是 32MB | 即时编译器编译的代码缓存的最大值 |

C.3 类型加载参数

| 参数 | 默认值 | 使用介绍 |
|-------------------------|------|--|
| UseSplitVerifier | 默认开启 | 使用依赖 StackMapTable 信息的类型检查代替数据流分析，以加快字节码校验速度 |
| FailOverToOldVerifier | 默认开启 | 当类型校验失败时，是否允许回到老的类型推导校验方式进行校验，如果开启则允许 |
| RelaxAccessControlCheck | 默认关闭 | 在校验阶段放松对类型访问性的限制 |

C.4 多线程相关参数

| 参数 | 默认值 | 使用介绍 |
|------------------------|---------------------------|------------------------------|
| UseSpinning | JDK 1.6 默认开启，JDK 1.5 默认关闭 | 开启自旋锁以避免线程频繁挂起和唤醒 |
| PreBlockSpin | 默认值为 10 | 使用自旋锁时默认的自旋次数 |
| UseThreadPriorities | 默认开启 | 使用本地线程优先级 |
| UseBiasedLocking | 默认开启 | 是否使用偏向锁，如果开启则使用 |
| UseFastAccessorMethods | 默认开启 | 当频繁反射执行某个方法时，生成字节码来加快反射的执行速度 |

C.5 性能参数

| 参数 | 默认值 | 使用介绍 |
|----------------|----------------------------|--|
| AggressiveOpts | JDK 1.6 默认开启, JDK 1.5 默认关闭 | 使用激进的优化特性, 这些特性一般是具备正面和负面双重影响的, 需要根据具体应用特点分析才能判定是否对性能有好处 |
| UseLargePages | 默认开启 | 如果可能, 使用大内存分页, 这项特性需要操作系统的支持 |

(续)

| 参数 | 默认值 | 使用介绍 |
|----------------------|---------|----------------------------|
| LargePageSizeInBytes | 默认为 4MB | 使用指定大小的内存分页, 这项特性需要操作系统的支持 |
| StringCache | 默认开启 | 是否使用字符串缓存, 开启则使用 |

C.6 调试参数

| 参数 | 默认值 | 使用介绍 |
|----------------------------|------|---|
| HeapDumpOnOutOfMemoryError | 默认关闭 | 在发生内存溢出异常时是否生成堆转储快照，关闭则不生成 |
| OnOutOfMemoryError | 无默认值 | 当虚拟机抛出内存溢出异常时，执行指定的命令 |
| OnError | 无默认值 | 当虚拟机抛出 ERROR 异常时，执行指定的命令 |
| PrintClassHistogram | 默认关闭 | 使用 [ctrl]-[break] 快捷键输出类统计状态，相当于 jmap-histo 的功能 |
| PrintConcurrentLocks | 默认关闭 | 打印 J.U.C 中锁的状态 |
| PrintCommandLineFlags | 默认关闭 | 打印启动虚拟机时输入的非稳定参数 |
| PrintCompilation | 默认关闭 | 打印方法即时编译信息 |
| PrintGC | 默认关闭 | 打印 GC 信息 |
| PrintGCDetails | 默认关闭 | 打印 GC 的详细信息 |
| PrintGCTimeStamps | 默认关闭 | 打印 GC 停顿耗时 |
| PrintTenuringDistribution | 默认关闭 | 打印 GC 后新生代各个年龄对象的大小 |
| TraceClassLoading | 默认关闭 | 打印类加载信息 |
| TraceClassUnloading | 默认关闭 | 打印类卸载信息 |
| PrintInlining | 默认关闭 | 打印方法的内联信息 |
| PrintCFGToFile | 默认关闭 | 将 CFG 图信息输出到文件，只有 DEBUG 版虚拟机才支持此参数 |
| PrintIdealGraphFile | 默认关闭 | 将 Ideal 图信息输出到文件，只有 DEBUG 版虚拟机才支持此参数 |
| UnlockDiagnosticVM_Options | 默认关闭 | 让虚拟机进入诊断模式，一些参数（如 PrintAssembly）需要在诊断模式中才能使用 |
| PrintAssembly | 默认关闭 | 打印即时编译后的二进制信息 |

附录D 对象查询语言（OQL）简介[1]

D.1 SELECT子句

SELECT子句用于确定查询语句需要从堆转储快照中选择什么内容。如果需要显示堆转储快照中的对象，并且浏览这些对象的引用关系，可以使用“*”，这与传统SQL语句中的习惯是一致的，如：

```
SELECT * FROM java.lang.String
```

1.选择特定的显示列

查询也可以选择特定的需要显示的字段，如：

```
SELECT toString (s) , s.count,s.value FROM  
java.lang.String s
```

查询可以用“@”符号来使用Java对象的内存属性访问器。MAT提供了一系列的内置函数来获取与分析相关的信息，如：

```
SELECT toString (s) ,  
s.@usedHeapSize,s.@retainedHeapSize FROM  
java.lang.String s
```

关于对象属性访问器的具体内容，可以参见下文的“属性访问器”。

2. 使用列别名

可以使用AS关键字来对选择的列进行命名，如：

```
SELECT toString (s) AS Value,
```

```
s.@usedHeapSize AS "Shallow Size",
s.@retainedHeapSize AS "Retained Size"
FROM java.lang.String s
```

可以使用“AS RETAINED SET”关键字来获得与选择对象相关联的对象集合，如：

```
SELECT AS RETAINED SET * FROM
java.lang.String
```

3. 拼合成为一个对象列表选择项目

可以使用“OBJECTS”关键字把SELECT子句中查找出来的数据项目转变为对象，如：

```
SELECT OBJECTS dominators (s) FROM
java.lang.String s
```

上面例子中，函数“dominators（）”将会返回一个对象数组，因此，如果没有“OBJECTS”关键

字，上面的查询将返回一组二维的对象数组的列表。通过使用关键字“OBJECTS”，我们迫使OQL把查询结果缩减为一维的对象列表。

4.排除重复对象

使用“DISTINCT”关键字可以排除结果集中的重复对象，如：

```
SELECT DISTINCT classof(s) FROM  
java.lang.String s
```

上面的例子中，函数“classof（）”的作用是返回对象所属的Java类，当然，所有字符串对象的所属类都是java.lang.String，因此，如果上面的查询中没有加入DISTINCT关键字，查询结果就会返回与快照中的字符串数量一样多的行记录，

并且每行记录的内容都是java.lang.String类型。

[1]本附录翻译自Eclipse Memory Analyzer Tool (MAT,Eclipse出品的内存分析工具) 的OQL帮助文档。

D.2 FROM子句

1.FROM子句指定需要查询的类

OQL查询需要在FROM子句定义的查询范围上进行操作。FROM子句可以接受的查询范围描述包括下列几种方式：

1) 通过类名进行查询，如：

```
SELECT * FROM java.lang.String
```

2) 通过正则表达式匹配一组类名进行查询，如：

```
SELECT * FROM "java\.lang\..*"
```

3) 通过类对象在堆转储快照中的地址进行查询, 如:

```
SELECT * FROM 0xe14a100
```

4) 通过对象在堆转储快照中的ID进行查询, 如:

```
SELECT * FROM 3022
```

5) 在子查询中的结果集中进行查询, 如:

```
SELECT * FROM (SELECT * FROM java.lang.Class  
c WHERE c implements  
org.eclipse.mat.snapshot.model.IClass)
```

上面的查询返回堆转储快照中所有实现了“org.eclipse.mat.snapshot.model.IClass”接口的类。下面的这句查询使用属性访问器达到了同样

的效果，它直接调用了ISnapshot对象的方法：

```
SELECT * FROM $snapshot.getClasses()
```

2. 包含子类

使用“INSTANCEOF”关键字把指定类的子类列入查询结果集之中，如：

```
SELECT * FROM INSTANCEOF  
java.lang.ref.Reference
```

这个查询的结果集中将会包含WeakReference、SoftReference和PhantomReference类型的对象，因为它们都继承自java.lang.ref.Reference。下面这句查询也有相同的结果：

```
SELECT * FROM  
$snapshot.getClassesByName ("java.lang.ref.Ref  
true")
```

3. 禁止查询类实例

在FROM子句中使用“OBJECTS”关键字可以禁止OQL把查询的范围解释为对象实例，如：

```
SELECT * FROM OBJECTS java.lang.String
```

这个查询的结果不是返回快照中所有的字符串，而是只有一个对象，也就是java.lang.String类对应的Class对象。

D.3 WHERE子句

1.>=、<=、>、<、[NOT]LIKE,
[NOT]IN（关系操作）

WHERE子句用于指定搜索的条件，即从查询结果中删除不需要的数据，如：

```
SELECT * FROM java.lang.String s WHERE  
s.count>=100  
SELECT * FROM java.lang.String s WHERE  
toString(s) LIKE".*day"  
SELECT * FROM java.lang.String s WHERE  
s.value NOT IN dominators(s)
```

2.=、!=（等于操作）

```
SELECT * FROM java.lang.String s WHERE  
toString(s) ="monday"
```

3.AND（条件“与”操作）

```
SELECT * FROM java.lang.String s WHERE  
s.count>100 AND s.@retainedHeapSize>  
s.@usedHeapSize
```

4.OR（条件“或”操作）

条件“或”操作可以应用于表达式、常量文本和子查询之中，如：

```
SELECT * FROM java.lang.String s WHERE  
s.count>1000 OR s.value.@length>1000
```

5.文字表达式

文字表达式包括了布尔值、字符串、整型、长整型和null，如：

```
SELECT * FROM java.lang.String s  
WHERE (s.count>1000) =true
```

```
WHERE toString (s) ="monday"
WHERE dominators (s) .size () =0
WHERE s.@retainedHeapSize>1024L
WHERE s.@GCRootInfo! =null
```

D.4 属性访问器

1. 访问堆转储快照中对象的字段

对象的内存属性可以通过传统的“点表示法”进行访问，格式为：

```
[<alias>.]<field>.<field>.<field>.....
```

2. 访问Java Bean属性

格式为：

```
[<alias>.]&<attribute>.....
```

使用@符号，OQL可以访问底层Java对象的内存属性。下表列出了一些常用的Java属性。

| 目标 | 接口 | 属性 | 含义 |
|--------|---------|------------------|------------------|
| 任意堆中对象 | Iobject | objectId | 快照中对象的 ID |
| | | objectAddress | 快照中对象的地址 |
| | | Class | 对象所属的类 |
| | | usedHeapSize | 对象的 ShallowSize |
| | | retainedHeapSize | 对象的 RetainedSize |
| | | displayName | 对象的显示名称 |
| 类对象 | Iclass | classLoaderId | 类加载器的 ID |
| 任意数组 | Iarray | length | 数组的长度 |

3. 调用OQL Java方法

格式为：

[<alias>.]<方法> ([<表达式>, <表达式>])

.....

加“（）”将会令MAT解释为一个OQL Java方法调用。这个方法的调用是通过反射执行的。常见的OQL Java方法如下：

| 目标 | 接口 | 方法 | 含义 |
|--------------|-----------|---|-------------------------|
| \$snapshot | Isnapshot | getClasses() | 获取所有类的集合 |
| | | getClassesByName(String name,boolean includeSubClasses) | 获取指定类的集合 |
| Class object | Iclass | hasSuperClass() | 如果对象有父类，则返回 true |
| | | isArrayType() | 如果 Class 是数组类型，则返回 true |

4.OQL的内建函数

格式为：

<function> (<parameter>)

| 函数名称 | 作用 |
|-----------------------|----------------------------|
| toHex(number) | 以十六进制的形式打印数字 |
| toString(object) | 返回对象的值，即使用一个字符串表示对象的内容 |
| dominators(object) | 返回直接持有指定对象的对象列表 |
| outbounds(object) | 获取对象的外部引用 |
| inbounds(object) | 获取对象的内部引用 |
| classof(object) | 获取对象所属的类型对象 |
| dominatorof(object) | 返回直接持有当前对象的对象列表，如果没有则返回 -1 |

D.5 OQL语言的BNF范式

| 目标 | 接口 | 方法 |
|----------------------|-----|---|
| SelectStatement | ::= | "SELECT" SelectList FromClause (WhereClause)? (UnionClause)? |
| SelectList | ::= | (("DISTINCT" "AS RETAINED SET")? ("*" "OBJECTS") SelectItem SelectItem ("," SelectItem)*) |
| SelectItem | ::= | (PathExpression EnvVarPathExpression) ("AS" (<STRING_LITERAL> <IDENTIFIER>)? <IDENTIFIER> </STRING_LITERAL>) |
| PathExpression | ::= | (ObjectFacet BuildInFunction) (." ObjectFacet)* |
| EnvVarPathExpression | ::= | ("\$" <IDENTIFIER>) (." ObjectFacet)* |
| ObjectFacet | ::= | (("@")? <IDENTIFIER> (ParameterList)?) |
| ParameterList | ::= | "((PrimaryExpression (." PrimaryExpression)*))?" |
| FromClause | ::= | "FROM" ("OBJECTS")? ("INSTANCEOF")? (FromItem "(" SelectStatement ")") (<IDENTIFIER>)? |
| FromItem | ::= | (ClassName <STRING_LITERAL> ObjectAddress ("," ObjectAddress)* ObjectId ("," ObjectId)* EnvVarPathExpression) |
| ClassName | ::= | (<IDENTIFIER> (":" <IDENTIFIER>)* ("[]")*) |

| 目标 | 接口 | 方法 |
|--------------------------|-----|---|
| ObjectAddress | ::= | <HEX_LITERAL> |
| ObjectId | ::= | <INTEGER_LITERAL> |
| WhereClause | ::= | "WHERE" ConditionalOrExpression |
| ConditionalOrExpression | ::= | ConditionalAndExpression ("or" ConditionalAndExpression)* |
| ConditionalAndExpression | ::= | EqualityExpression ("and" EqualityExpression)* |
| EqualityExpression | ::= | RelationalExpression (("=" RelationalExpression "!=" RelationalExpression))* |
| RelationalExpression | ::= | (PrimaryExpression (("<" PrimaryExpression ">" PrimaryExpression "<=" PrimaryExpression ">=" PrimaryExpression (LikeClause InClause) "implements" ClassName))?) |
| LikeClause | ::= | ("NOT")? "LIKE" <STRING_LITERAL> |
| InClause | ::= | ("NOT")? "IN" PrimaryExpression |
| PrimaryExpression | ::= | Literal |
| | | "((ConditionalOrExpression SubQuery))" |
| | | PathExpression |
| | | EnvVarPathExpression |
| SubQuery | ::= | SelectStatement |
| Function | ::= | (("toHex" "toString" "dominators" "outbounds" "inbounds" "classof" "dominatorof") "(" ConditionalOrExpression ")") |
| Literal | ::= | (<INTEGER_LITERAL> <LONG_LITERAL> <FLOATING_POINT_LITERAL> <CHARACTER_LITERAL> <STRING_LITERAL> BooleanLiteral NullLiteral) |
| BooleanLiteral | ::= | "true" |
| | | "false" |
| NullLiteral | ::= | <NULL> |
| UnionClause | ::= | ("UNION" "(" SelectStatement ")")+ |

附录E JDK历史版本轨迹

大部分的JDK历史版本（JDK 1.1.6之后的版本），以及JDK所附带的各种工具的历史版本，都可以从Oracle公司的网站[\[1\]](#)上下载到。

| 主版本 | 子版本及虚拟机版本 | 工程代号 | 发布日期 |
|---------|---|------------|------------|
| JDK 1.0 | JDK 1.0 | | 1996-01-23 |
| | JDK 1.0.1 | | |
| | JDK 1.0.2 | | |
| JDK 1.1 | JDK 1.1.0 | | 1997-02-18 |
| | JDK 1.1.1 | | |
| | JDK 1.1.2 | | |
| | JDK 1.1.3 | | |
| | JDK 1.1.4 | Sparkler | 1997-09-12 |
| | JDK 1.1.5 | Pumpkin | 1997-12-03 |
| | JDK 1.1.6 | Abigail | 1998-04-24 |
| | JDK 1.1.7 | Brutus | 1998-09-28 |
| JDK 1.2 | JDK 1.1.8 | Chelsea | 1999-04-08 |
| | JDK 1.2.0 | Playground | 1998-12-04 |
| | JDK 1.2.1 | (none) | 1999-03-30 |
| JDK 1.3 | JDK 1.2.2 | Cricket | 1999-07-08 |
| | JDK 1.3.0 (HotSpot 1.3.0-C) | Kestrel | 2000-05-08 |
| | JDK 1.3.0 Update 1 (HotSpot 1.3.0_01) | | |
| | JDK 1.3.0 Update 2 (HotSpot 1.3.0_02) | | |
| | JDK 1.3.0 Update 3 (HotSpot 1.3.0_03) | | |
| | JDK 1.3.0 Update 4 (HotSpot 1.3.0_04) | | |
| | JDK 1.3.0 Update 5 (HotSpot 1.3.0_05) | | |
| | JDK 1.3.1 (HotSpot 1.3.1) | Ladybird | 2001-05-17 |
| | JDK 1.3.1 Update 1 (HotSpot 1.3.1_01) | | |
| | JDK 1.3.1 Update 1a (HotSpot 1.3.1_01a) | | |
| | JDK 1.3.1 Update 2 (HotSpot 1.3.1_02) | | |
| | JDK 1.3.1 Update 3 (HotSpot 1.3.1_03) | | |
| | JDK 1.3.1 Update 4 (HotSpot 1.3.1_04) | | |
| | JDK 1.3.1 Update 5 (HotSpot 1.3.1_05) | | |

| 主版本 | 子版本及虚拟机版本 | 工程代号 | 发布日期 |
|---------|--|-------------|------------|
| JDK 1.3 | JDK 1.3.1 Update 6 (HotSpot 1.3.1_06) | | |
| | JDK 1.3.1 Update 7 (HotSpot 1.3.1_07) | | |
| | JDK 1.3.1 Update 8 (HotSpot 1.3.1_08) | | |
| | JDK 1.3.1 Update 9 (HotSpot 1.3.1_09) | | |
| | JDK 1.3.1 Update 10 (HotSpot 1.3.1_10) | | |
| | JDK 1.3.1 Update 11 (HotSpot 1.3.1_11) | | |
| | JDK 1.3.1 Update 12 (HotSpot 1.3.1_12) | | |
| | JDK 1.4.0 (HotSpot 1.4.0) | Merlin | 2002-02-13 |
| | JDK 1.4.0 Update 1 (HotSpot 1.4.0_01) | | |
| | JDK 1.4.0 Update 2 (HotSpot 1.4.0_02) | | |
| JDK 1.4 | JDK 1.4.0 Update 3 (HotSpot 1.4.0_03) | | |
| | JDK 1.4.0 Update 4 (HotSpot 1.4.0_04) | | |
| | JDK 1.4.1 (HotSpot 1.4.1) | Grasshopper | 2002-09-16 |
| | JDK 1.4.1 Update 1 (HotSpot 1.4.1_01) | | |
| | JDK 1.4.1 Update 2 (HotSpot 1.4.1_02) | | |
| | JDK 1.4.1 Update 3 (HotSpot 1.4.1_03) | | |
| | JDK 1.4.1 Update 4 (HotSpot 1.4.1_04) | | |
| | JDK 1.4.1 Update 5 (HotSpot 1.4.1_05) | | |
| | JDK 1.4.1 Update 6 (HotSpot 1.4.1_06) | | |
| | JDK 1.4.1 Update 7 (HotSpot 1.4.1_07) | | |
| | JDK 1.4.2 (HotSpot 1.4.2-b28) | Mantis | 2003-06-26 |
| | JDK 1.4.2 Update 1 (HotSpot 1.4.2_01) | | |
| | JDK 1.4.2 Update 2 (HotSpot 1.4.2_02) | | |
| | JDK 1.4.2 Update 3 (HotSpot 1.4.2_03) | | |
| | JDK 1.4.2 Update 4 (HotSpot 1.4.2_04) | | |
| | JDK 1.4.2 Update 5 (HotSpot 1.4.2_05) | | |
| | JDK 1.4.2 Update 6 (HotSpot 1.4.2_06) | | |
| | JDK 1.4.2 Update 7 (HotSpot 1.4.2_07) | | |
| | JDK 1.4.2 Update 8 (HotSpot 1.4.2_08-b03) | | |
| | JDK 1.4.2 Update 9 (HotSpot 1.4.2_09-b05) | | |
| | JDK 1.4.2 Update 10 (HotSpot 1.4.2_10-b03) | | |
| | JDK 1.4.2 Update 11 (HotSpot 1.4.2_11-b06) | | |
| | JDK 1.4.2 Update 12 (HotSpot 1.4.2_12-b03) | | |
| | JDK 1.4.2 Update 13 (HotSpot 1.4.2_13-b03) | | |
| | JDK 1.4.2 Update 14 (HotSpot 1.4.2_14-b05) | | |
| | JDK 1.4.2 Update 15 (HotSpot 1.4.2_15-b02) | | |
| | JDK 1.4.2 Update 16 (HotSpot 1.4.2_16-b01) | | |
| | JDK 1.4.2 Update 17 (HotSpot 1.4.2_17-b06) | | |

| 主版本 | 子版本及虚拟机版本 | 工程代号 | 发布日期 |
|---------|--|-----------|------------|
| JDK 1.4 | JDK 1.4.2 Update 18 (HotSpot 1.4.2_18-b06) | | |
| | JDK 1.4.2 Update 19 (HotSpot 1.4.2_19-b04) | | |
| JDK 1.5 | JDK 1.5.0 (HotSpot 1.5.0-b64) | Tiger | 2004-09-29 |
| | JDK 1.5.0 Update 1 (HotSpot 1.5.0_01) | | |
| | JDK 1.5.0 Update 2 (HotSpot 1.5.0_02-b09) | | |
| | JDK 1.5.0 Update 3 (HotSpot 1.5.0_03-b07) | | |
| | JDK 1.5.0 Update 4 (HotSpot 1.5.0_04-b05) | | |
| | JDK 1.5.0 Update 5 (HotSpot 1.5.0_05-b05) | | |
| | JDK 1.5.0 Update 6 (HotSpot 1.5.0_06-b05) | | |
| | JDK 1.5.0 Update 7 (HotSpot 1.5.0_07-b03) | | |
| | JDK 1.5.0 Update 8 (HotSpot 1.5.0_08-b03) | | |
| | JDK 1.5.0 Update 9 (HotSpot 1.5.0_09-b03) | | |
| | JDK 1.5.0 Update 10 (HotSpot 1.5.0_10-b02) | | |
| | JDK 1.5.0 Update 11 (HotSpot 1.5.0_11-b03) | | |
| | JDK 1.5.0 Update 12 (HotSpot 1.5.0_12-b04) | | |
| | JDK 1.5.0 Update 13 (HotSpot 1.5.0_13-b01) | | |
| | JDK 1.5.0 Update 14 (HotSpot 1.5.0_14-b03) | | |
| | JDK 1.5.0 Update 15 (HotSpot 1.5.0_15-b04) | | |
| | JDK 1.5.0 Update 16 (HotSpot 1.5.0_16-b02) | | |
| | JDK 1.5.0 Update 17 (HotSpot 1.5.0_17-b04) | | |
| | JDK 1.5.0 Update 18 (HotSpot 1.5.0_18-b02) | | |
| | JDK 1.5.0 Update 19 (HotSpot 1.5.0_19-b02) | | |
| | JDK 1.5.0 Update 20 (HotSpot 1.5.0_20-b02) | | |
| | JDK 1.5.0 Update 21 (HotSpot 1.5.0_21-b01) | | |
| | JDK 1.5.0 Update 22 (HotSpot 1.5.0_22-b03) | | |
| JDK 1.6 | JDK 1.5.1 | Dragonfly | 取消发布 |
| | JDK 1.6.0 (HotSpot 1.6.0-b105) | Mustang | 2006-12-11 |
| | JDK 1.6.0 Update 1 (HotSpot 1.6.0_01-b06) | | |
| | JDK 1.6.0 Update 2 | | |
| | JDK 1.6.0 Update 3 | | |
| | JDK 1.6.0 Update 4 (HotSpot 10.0-b19) | | |
| | JDK 1.6.0 Update 5 (HotSpot 10.0-b19) | | |
| | JDK 1.6.0 Update 6 | | |
| | JDK 1.6.0 Update 7 (HotSpot 10.0-b23) | | |
| | JDK 1.6.0 Update 10 (HotSpot 11.0-b15) | | |
| | JDK 1.6.0 Update 11 | | |
| | JDK 1.6.0 Update 12 | | |
| | JDK 1.6.0 Update 13 (HotSpot 11.3-b02) | | |

(续)

| 主版本 | 子版本及虚拟机版本 | 工程代号 | 发布日期 |
|---------|--|---------|------------|
| JDK 1.6 | JDK 1.6.0 Update 14 (HotSpot 14.0-b16) | | 2009-05-28 |
| | JDK 1.6.0 Update 15 (HotSpot 14.1-b02) | | |
| | JDK 1.6.0 Update 16 (HotSpot 14.2-b01) | | |
| | JDK 1.6.0 Update 17 (HotSpot 14.3-b01) | | |
| | JDK 1.6.0 Update 18 (HotSpot 16.0-b13) | | |
| | JDK 1.6.0 Update 19 (HotSpot 16.2-b04) | | |
| | JDK 1.6.0 Update 20 (HotSpot 16.3-b01) | | |
| | JDK 1.6.0 Update 21 (HotSpot 17.0-b17) | | 2010-07-10 |
| | JDK 1.6.0 Update 22 (HotSpot 17.1-b03) | | 2010-10-22 |
| | JDK 1.6.0 Update 23 (HotSpot 19.0-b09) | | 2010-12-08 |
| | JDK 1.6.0 Update 24 | | 2011-02-15 |
| | JDK 1.6.0 Update 25 | | 2011-03-21 |
| | JDK 1.6.0 Update 26 | | 2011-06-07 |
| | JDK 1.6.0 Update 27 | | 2011-08-16 |
| | JDK 1.6.0 Update 29 | | 2011-10-18 |
| | JDK 1.6.0 Update 30 | | 2011-12-12 |
| | JDK 1.6.0 Update 31 | | 2012-02-14 |
| | JDK 1.6.0 Update 32 | | 2012-04-26 |
| | JDK 1.6.0 Update 33 | | 2012-06-12 |
| | JDK 1.6.0 Update 34 | | 2012-08-14 |
| | JDK 1.6.0 Update 35 | | 2012-08-30 |
| | JDK 1.6.0 Update 37 | | 2012-10-16 |
| JDK 1.7 | JDK 1.7.0 | Dolphin | 2011-07-28 |
| | JDK 1.7.0 Update 1 | | 2011-10-18 |
| | JDK 1.7.0 Update 2 | | 2011-12-12 |
| | JDK 1.7.0 Update 3 | | 2012-02-14 |
| | JDK 1.7.0 Update 4 | | 2012-04-26 |
| | JDK 1.7.0 Update 5 | | 2012-06-12 |
| | JDK 1.7.0 Update 6 | | 2012-08-14 |
| | JDK 1.7.0 Update 7 | | 2012-08-30 |
| | JDK 1.7.0 Update 9 | | 2012-10-16 |
| | JDK 1.7.0 Update 10 | | 2012-11-20 |

1、小编希望和所有热爱生活，追求卓越的人成为朋友，小编：QQ和微信491256034备注书友！小编有300多万册电子书。您也可以在微信上呼唤我 放心，绝对不是微商，看我以前发的朋友圈，你就能看得出来的。

2、扫面下方二维码，关注我的公众号，回复电子书，既可以看到我这里的书单，回复对应的数字，我就能发给你，小编每天都往里更新10本左右，如果没有你想要的书籍，你给我留言，我在单独的发给你。

3、为了方便书友朋友找书和看书，小编自己做了一个电子书下载网站，网址：www.ireadweek.com



扫描二维码，加小编微信



扫描二维码，加小编个人公众

[1] 下载页面地址：

<http://www.oracle.com/technetwork/java/archive->

139210.html。

如果你不知道读什么书，
就关注这个微信号。



公众号名称：幸福的味道

公众号ID： d716-716

小编：行行：微信号：491256034

为了方便书友朋友找书和看书，小编自己做了一个电子书下载网站，网站名称：周读 网址：www.ireadweek.com 小编也和结交一些喜欢读书的朋友

“幸福的味道”已提供120个不同类型的书单

1、25岁前一定要读的25本书

2、20世纪最优秀的100部中文小说

3、10部豆瓣高评分的温情治愈系小说

4、有生之年，你一定要看的25部外国纯文学名著

5、有生之年，你一定要看的20部中国现当代名著

6、美国亚马逊编辑推荐的一生必读书单100本

7、30个领域30本不容错过的入门书

8、这20本书，是各领域的巅峰之作

9、这7本书，教你如何高效读书

10、80万书虫力荐的“给五星都不够”的30本书

.....

关注“幸福的味道”微信公众号，即可查看对应书单

如果你不知道读什么书，就关注这个微信号。